למידה חישובית
וכריית נתונים

הקורס - כללי

- הרצאות פרונטאליות
  - לאחר כל סדרה של הרצאות – תתקיים הרצאת תרגול
- הרכב הציון:
  - מבחן מסכם
- במהלך הקורס יועלו למודל 4 תרגילי בית
  - אין חובת הגשה
- <u>מומלץ לעשות את התרגילים</u>

מטרת הקורס

- חשיפה להתפתחות המואצת בעשורים האחרונים בתחום הלמידה החישובית.
- הכרה של המושגים הבסיסיים בתחום.
- הכרה של האלגוריתמים הבסיסיים בתחום.

ספרות

- Books:
  - Pattern classification, Duda, Hart, Stork, 2nd edition, 2001
  - Machine Learning, Tom Mitchell, McGraw Hill 1997
- Recommended courses (Especially for deep learning)
  - http://cs231n.stanford.edu/
  - https://www.coursera.org/learn/machine-learning
- Blogs

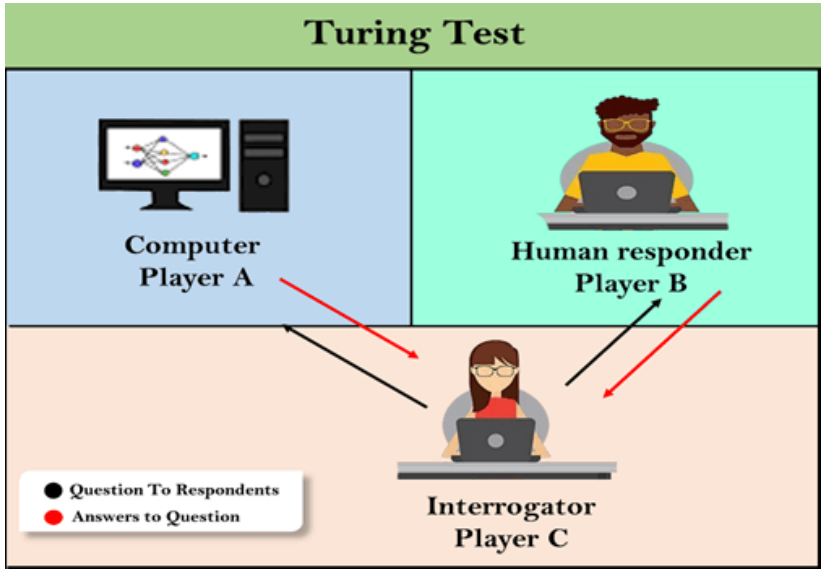
בעיקר הרצאות

נושאים לשיעורים הקרובים

- מהי למידת מכונה
- מתי משתמשים בלמידת מכונה
- מושגים בסיסיים בלמידה
- עקרונות בסיסיים בבניית מערכת למידה
- הערכת ביצועי מכונת למידה

האם למכונה יש בינה מלאכותית

- **מבחן טיורינג** הוא כינוי למבחן שהציע אלן טיורינג בשנת 1950. חוקר מקיים דיאלוג בשפה טבעית עם שני גורמים שאינו רואה, האחד **אדם** והשני **מכונה**. אם החוקר אינו מסוגל לקבוע בביטחון מי האדם ומי המכונה, אזי המכונה עברה בהצלחה את המבחן. ערוץ טקסטואלי בלבד.
- הפילוסוף **ג'ון סירל** (1980) - "החדר הסיני". הבנה אמיתית או טכנית???
- פרס **לובנר** ניתן מדי שנה למפתח של תוכנית שיחה, ובו זוכה התוכנית שנחשבת לאנושית ביותר באותה שנה.
  - בשנת 2008 התוכנית הזוכה הצליחה לשטות ברבע מהשופטים.
  - בשנת 2010 תוכנה בשם סוזט הצליחה לעבור את מבחן טיורינג.



"What **we want is a machine that can learn** from experience"

(Alan Turing, 1947)

האם אלן טיורינג היה מרוצה היום???

גילוי פנים במצלמות(שנות 2000)



2006 – 2012

PASCAL Visual Object Challenge
(20 object categories)

[Everingham et al. 2006-2012]

Image is CC BY-SA 3.0

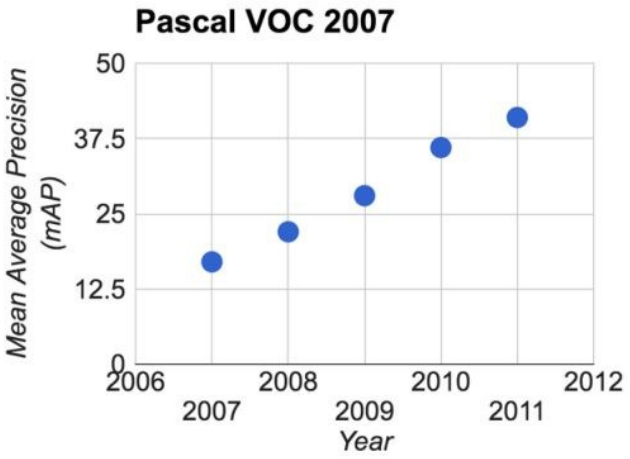




Image is CC0 1.0 public domain



This image is licensed under CC BY-SA 2.0; changes made



כמות הדטה המתוייגת גדלה...



IMAGENET

www.image-net.org

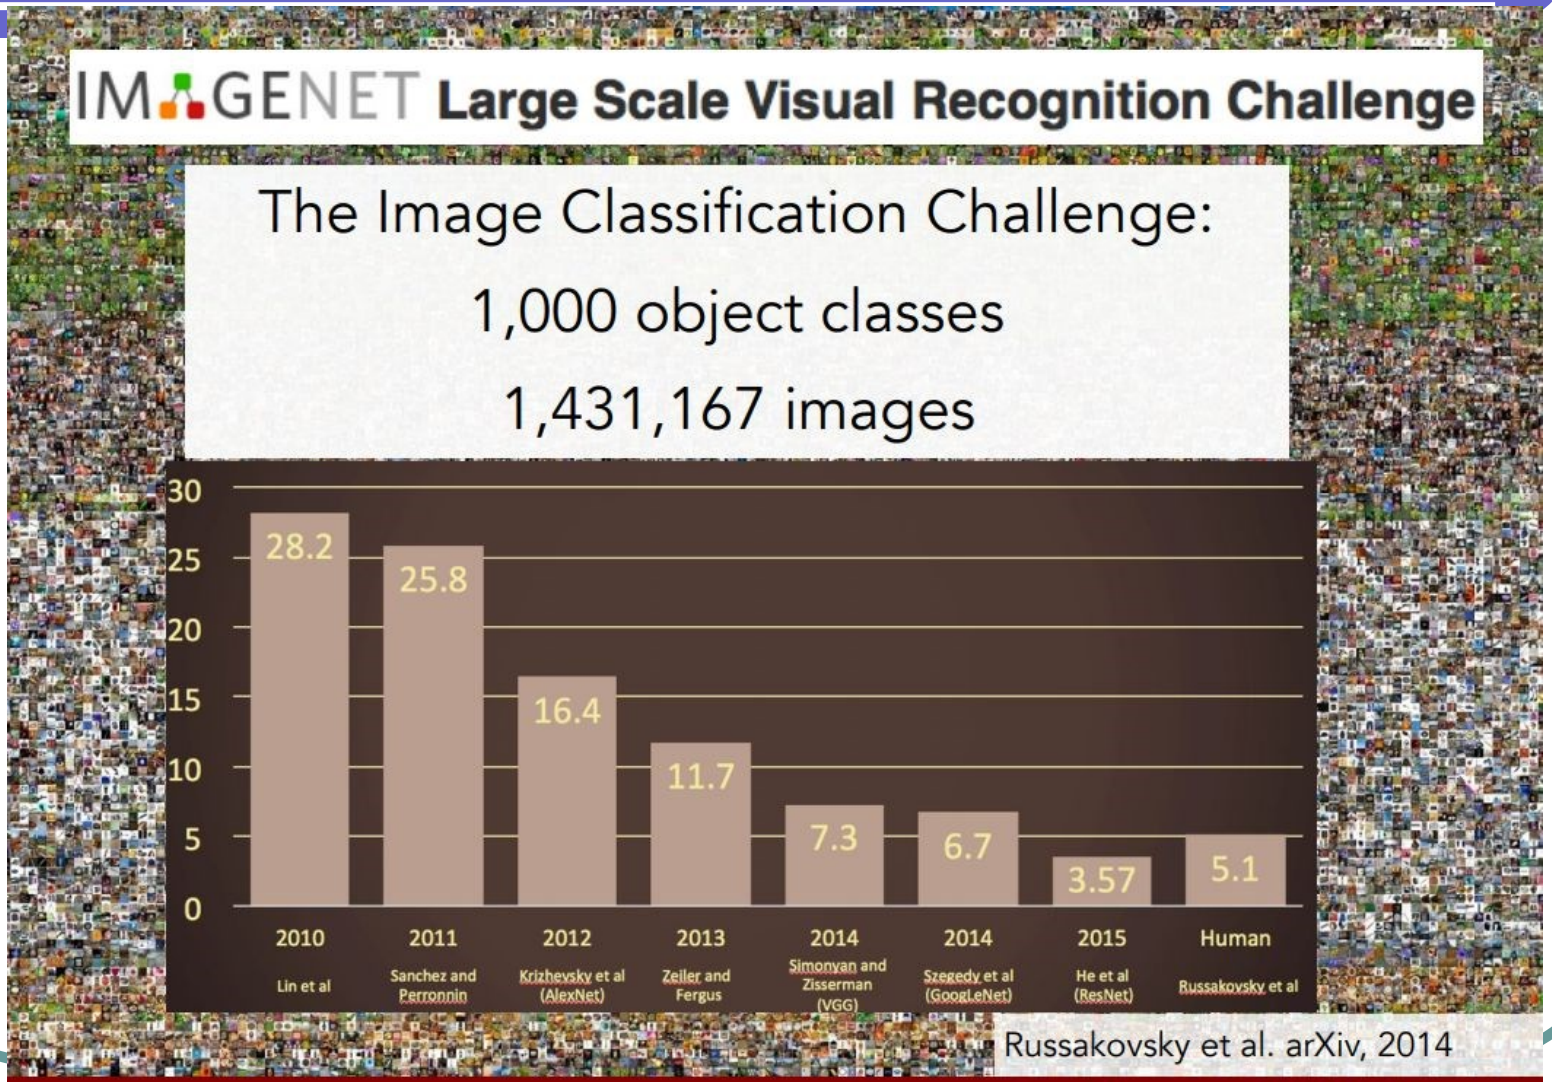
22K categories and **14M** images

- Animals
  - Bird
  - Fish
  - Mammal
  - Invertebrate
- Plants
  - Tree
  - Flower
- Food
- Materials
- Structures
- Artifact
  - Tools
  - Appliances
  - Structures
- Person
- Scenes
  - Indoor
  - Geological Formations
- Sport Activities

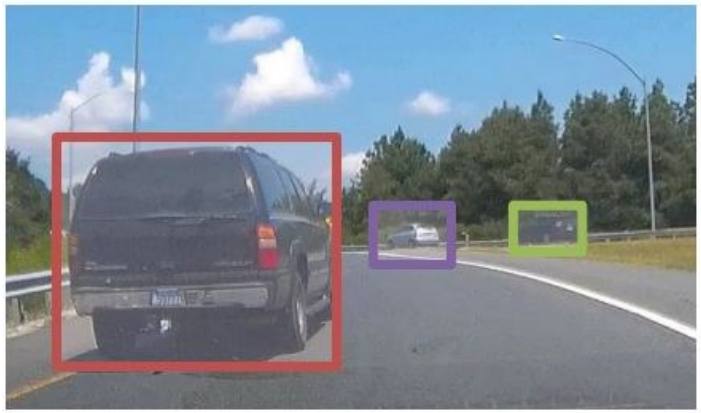


Deng, Dong, Socher, Li, Li, & Fei-Fei, 2009

2010 ……..


IMAGENET Large Scale Visual Recognition Challenge
The Image Classification Challenge:
1,000 object classes
1,431,167 images
30
25
20
15
10
5
0
28.2
25.8
16.4
11.7
7.3
6.7
3.57
5.1
2010
Lin et al
2011
Sanchez and Perronnin
2012
Krizhevsky et al (AlexNet)
2013
Zeiler and Fergus
2014
Simonyan and Zisserman (VGG)
2014
Szegedy et al (GoogLeNet)
2015
He et al (ResNet)
Human
Russakovsky et al
Russakovsky et al. arXiv, 2014

סוגים שונים של בעיות בראיה ממוחשבת

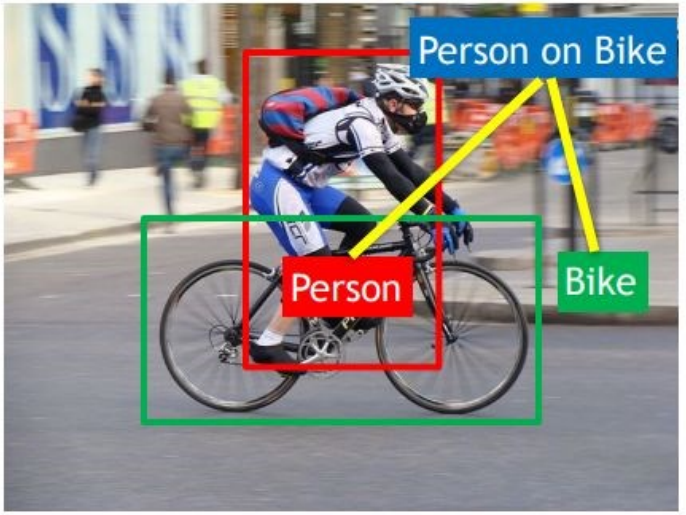


This image is licensed under CC BY-NC-SA 2.0; changes made

- Object detection
- Action classification
- Image captioning
- ...

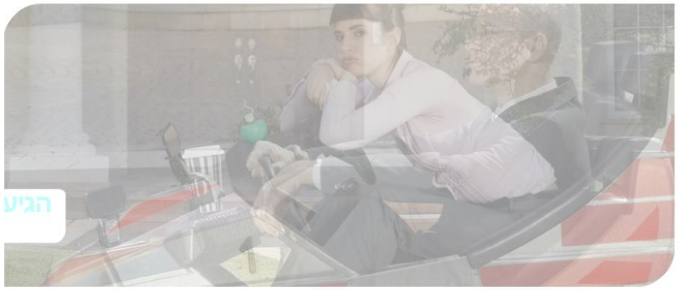


This image is licensed under CC BY-SA 2.0; changes made



This image is licensed under CC BY-SA 3.0; changes made

Mobileye



MOBILEYE

- מי אנחנו?
- פתרונות ויתרונות המערכת
- היכן ניתן לרכוש מערכת?
- הנחות בחברות הביטוח
- הטבות בחברות הליסינג
- שאלות ותשובות

Mobileye המערכת שמזהירה אותך לפני תאונה



Mobileye הינה מערכת למניעת תאונות דרכים המתריעה על מצבי סכנה בכביש בזמן אמת. המערכת מזהה מצבי סכנת התנגשות ומתריעה בפני הנהג בצורה ויזואלית וקולית על מנת להסב את תשומת לבו ולמנוע את התאונה האפשרית. התרעות הבטיחות של Mobileye מאפשרות לו להגיב בזמן אמת ולהיחלץ ממצבים מסוכנים. טכנולוגיית Mobileye אומצה על-ידי מרבית יצרני הרכב בעולם, בכללם: Volvo, BMW, GM.

מתקינים Mobileye במכונית ואומרים שלום להתנגשויות ולתאונות:

- התרעה לפני סטייה מהנתיב
- התרעה לפני התנגשות חזית-אחור
- התרעה לפני התנגשות בהולך רגל או רוכב אופניים (באור יום בלבד)
- התרעה על אי שמירת מרחק

חייגו 4505*

למידע נוסף ורכישה השאירו את פרטיכם ונציגנו יחזרו אליכם בהקדם:

שם:

טלפון: בחר

דוא"ל:

אני מאשר קבלת חומר פרסומי

שלח פרטים

עד 25% הנחה
על ביטוח הרכב בחברות אחרות



http://www.youtube.com/watch?v=H_wMyUEeIzQ

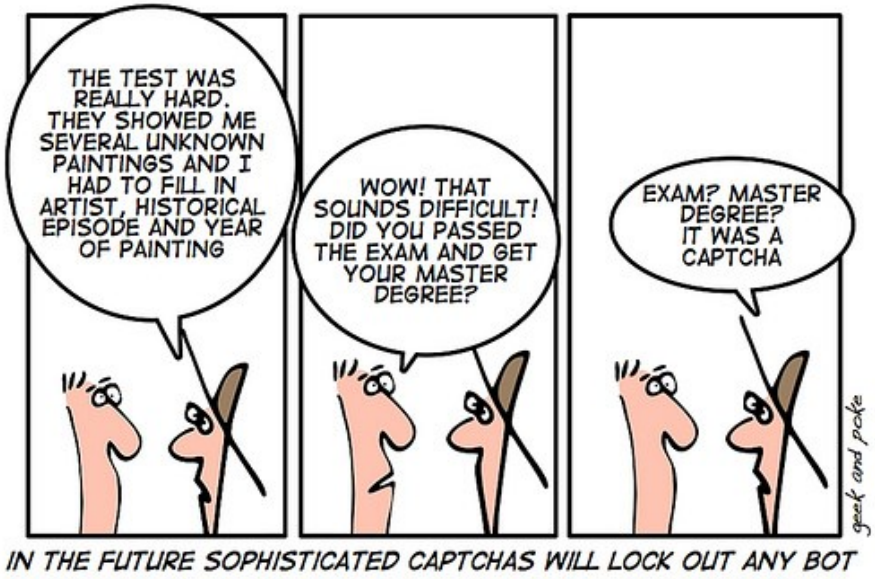
SIRI

- עוזר אישי חכם
  - עונה על שאלות
  - מבצע פעולות



CAPTCHA (Completely Automated Public Turing test)

- אתרי אינטרנט המעוניינים לוודא שהמשתמש שמולם הוא אדם ולא בוט, נותנים למשתמש מעין מבחן טיורינג, שאדם יעבור אותו בקלות, אך בוט יתקשה בכך.





http://www.winworld.com/store/featured/captcha.html

http://sem-group.net/search-engine-optimization-blog/is-your-/captcha-killing-your-business

בחזרה ל- CAPTCHA





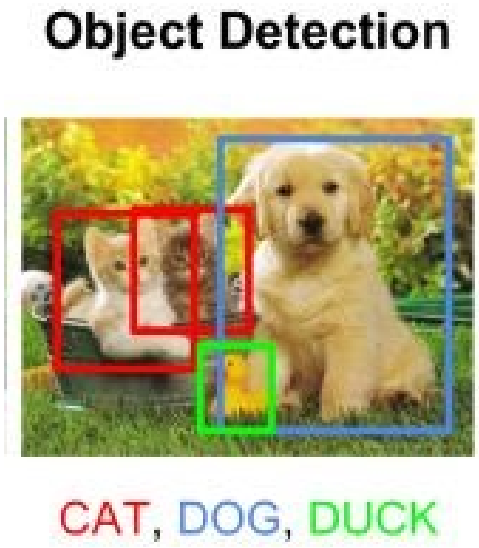
Complexity of recognizing chairs

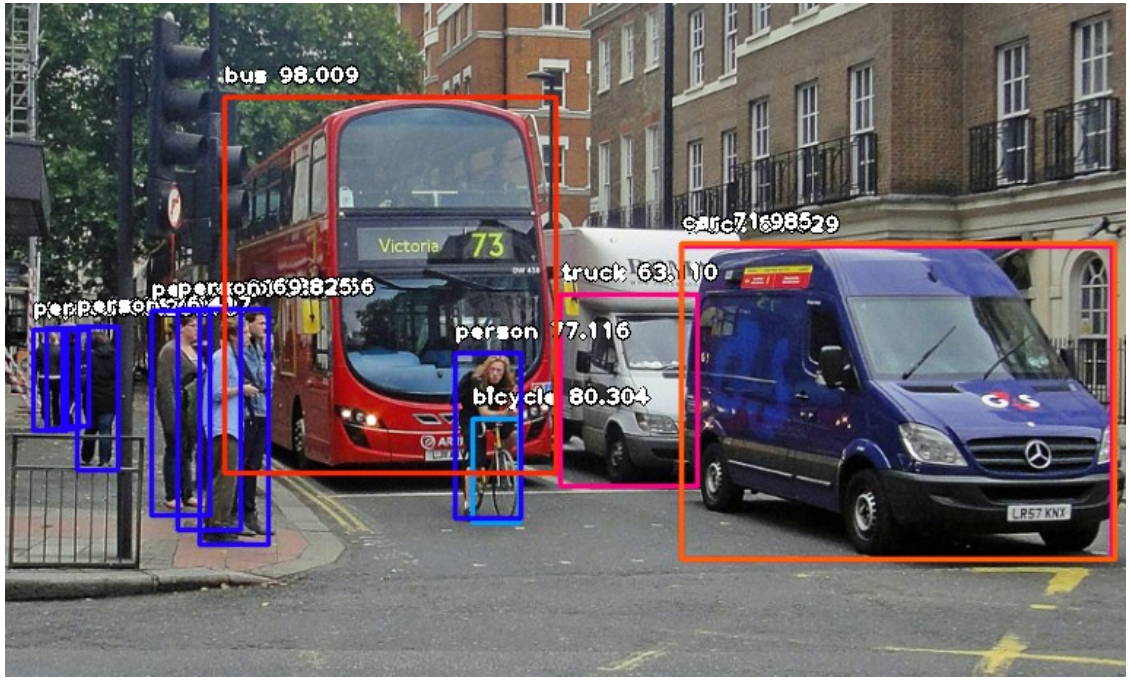


http://www.nada.kth.se/~hic/hic-papers/HIC-Ercim-News-53.pdf

יישומי למידת מכונה בעולם המודרני

Object Detection





https://towardsdatascience.com/object-detection-with-10-lines-of-code-d6cb4d86f606

Image Segmentation

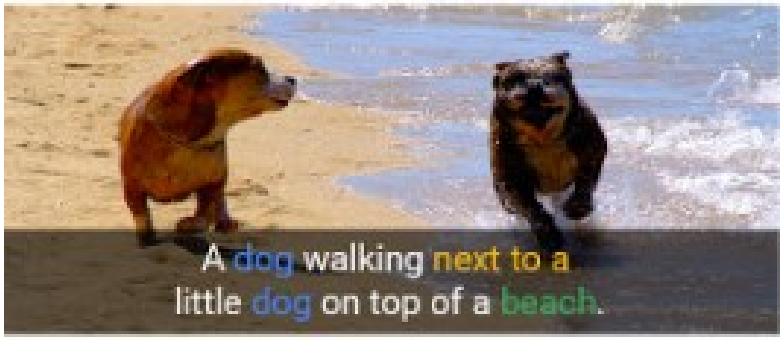




https://medium.com/nanonets/how-to-do-image-segmentation-using-deep-learning-c673cc5862ef

Automatic Image Caption Generation







"man in black shirt is playing guitar."



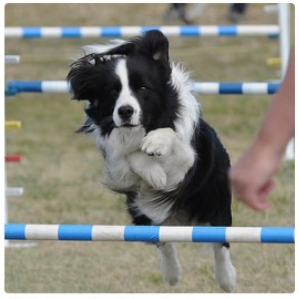
"construction worker in orange safety vest is working on road."



"two young girls are playing with lego toy."



"girl in pink dress is jumping in air."



"black and white dog jumps over bar."

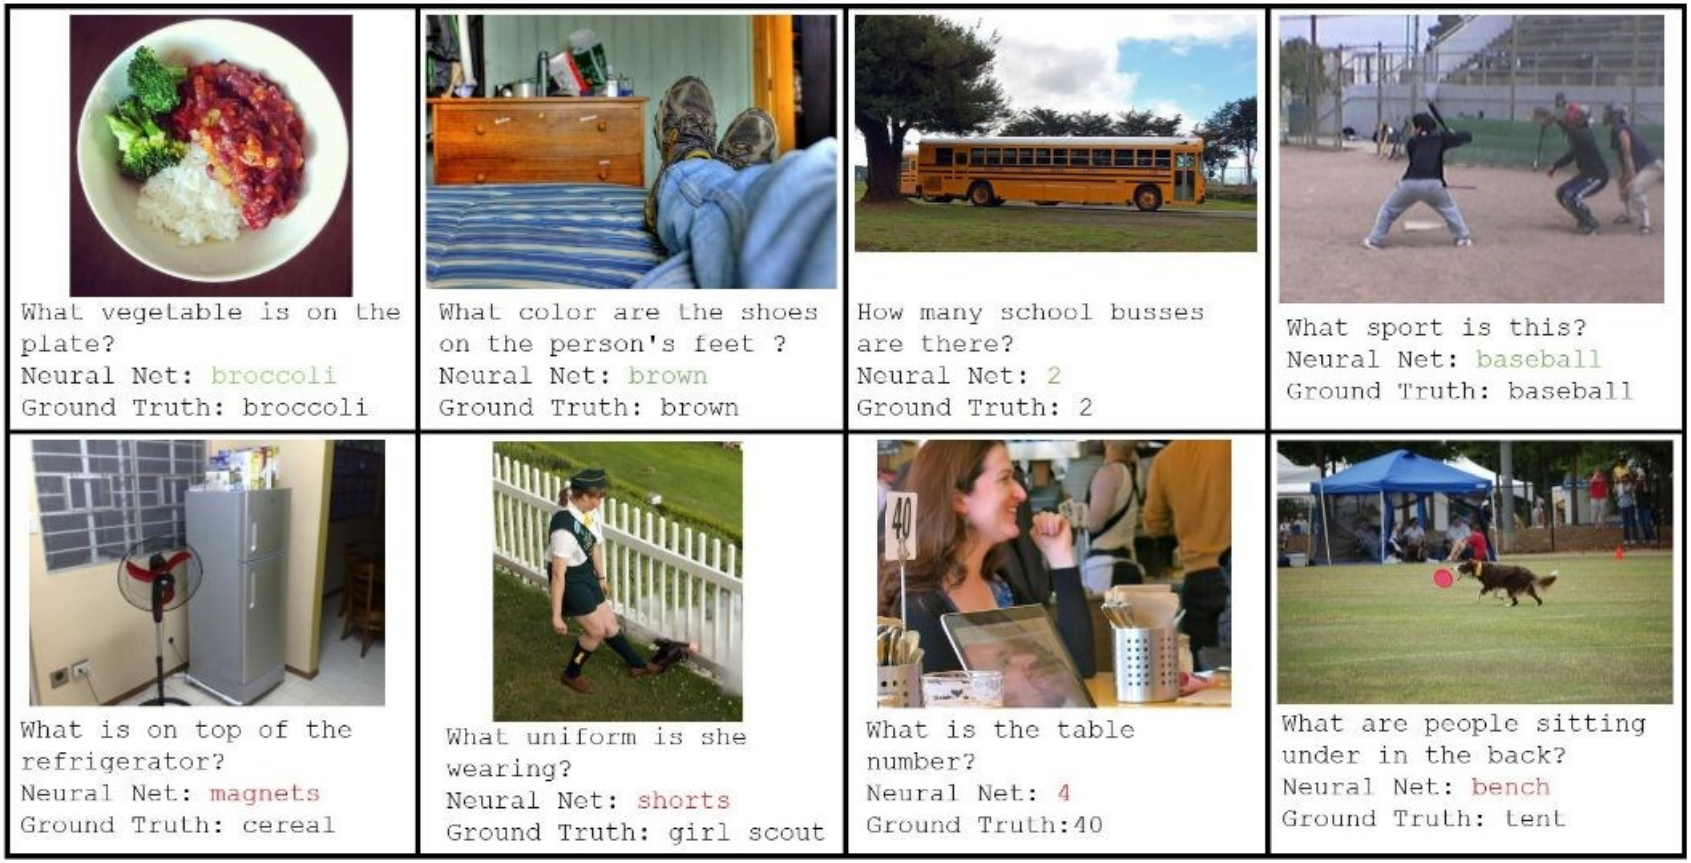


"young girl in pink shirt is swinging on swing."

https://www.analyticsvidhya.com/blog/2018/04/solving-an-image-captioning-task-using-deep-learning/

https://machinelearningmastery.com/inspirational-applications-deep-learning/

DL for Visual Question Answering



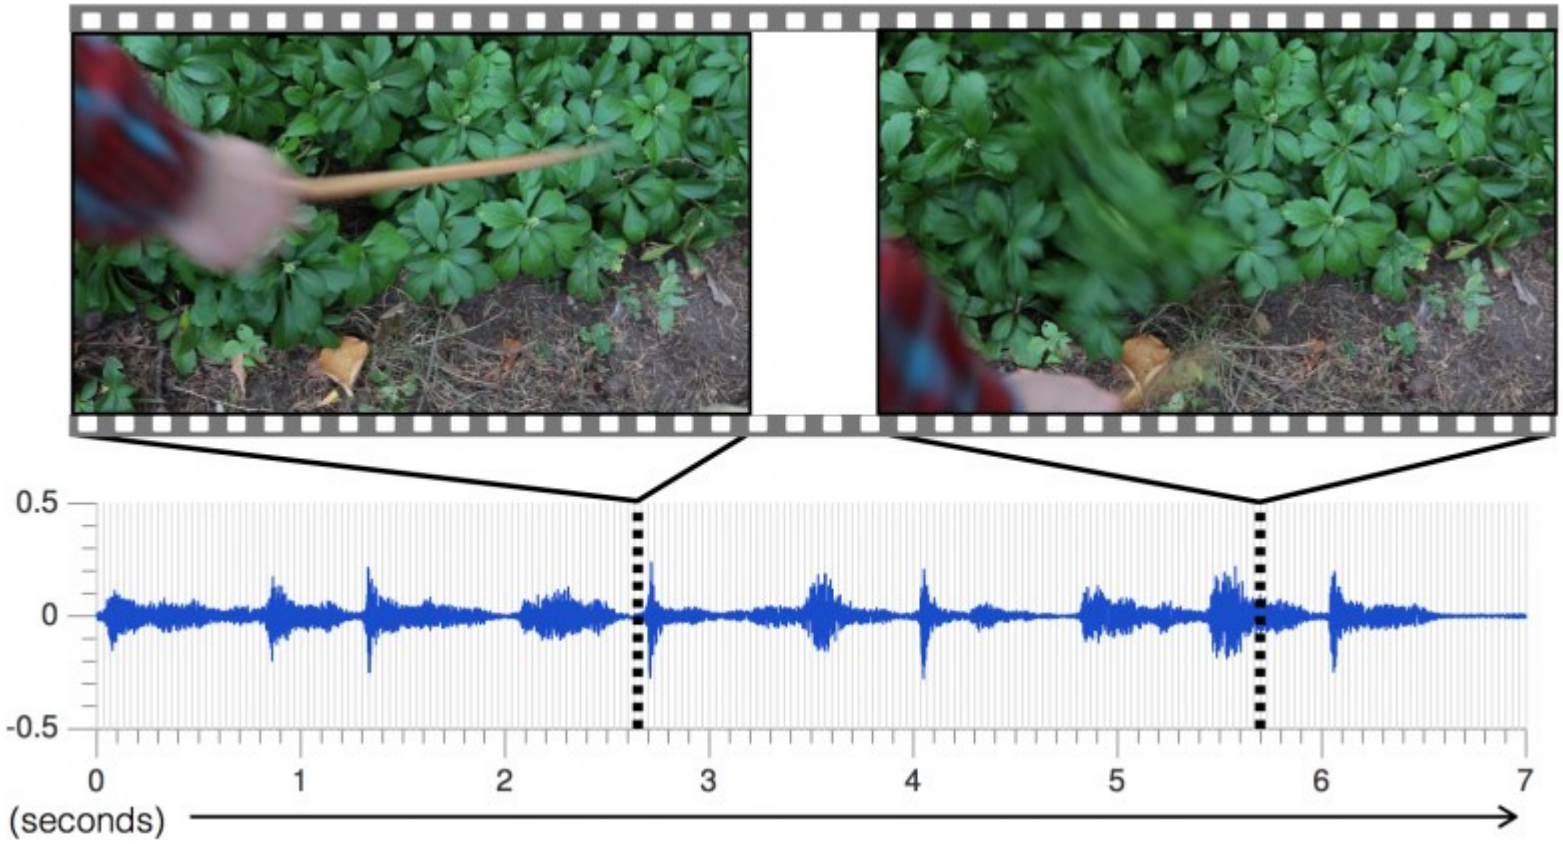
Demo: https://www.youtube.com/watch?v=RxOy_VqVqfc

Automatic Colorization



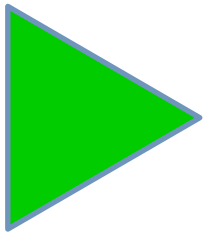
https://richzhang.github.io/colorization/

Automatically Adding Sounds To Silent Movies



http://news.mit.edu/2016/artificial-intelligence-produces-realistic-sounds-0613

DADDY'S CAR – GENERATED BY AI



https://www.youtube.com/watch?v=LSHZ_b05W7o

Generation (music/images/text)

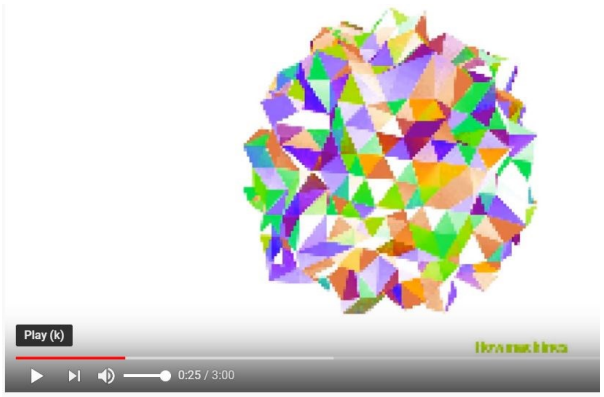
```
HENRY BOLINGBROKE:
My gracious uncle--

DUKE OF YORK:
As much disgraced to the court, the gods them speak,
And now in peace himself excuse thee in the world.

HORTENSIO:
Madam, 'tis not the cause of the counterfeit of the earth,
And leave me to the sun that set them on the earth
And leave the world and are revenged for thee.

GLOUCESTER:
I would they were talking with the very name of means
To make a puppet of a guest, and therefore, good Grumio,
Nor arm'd to prison, o' the clouds, of the whole field,
With the admire
With the feeding of thy chair, and we have heard it so,
I thank you, sir, he is a visor friendship with your silly your bed.
```

https://medium.com/tensorflow/complete-code-examples-for-machine-translation-with-attention-image-captioning-text-generation-51663d07a63d



Daddy's Car: a song composed by Artificial Intelligence - in the style of the Beatles

https://www.youtube.com/watch?v=LSHZ_b05W7o

https://thispersondoesnotexist.com/

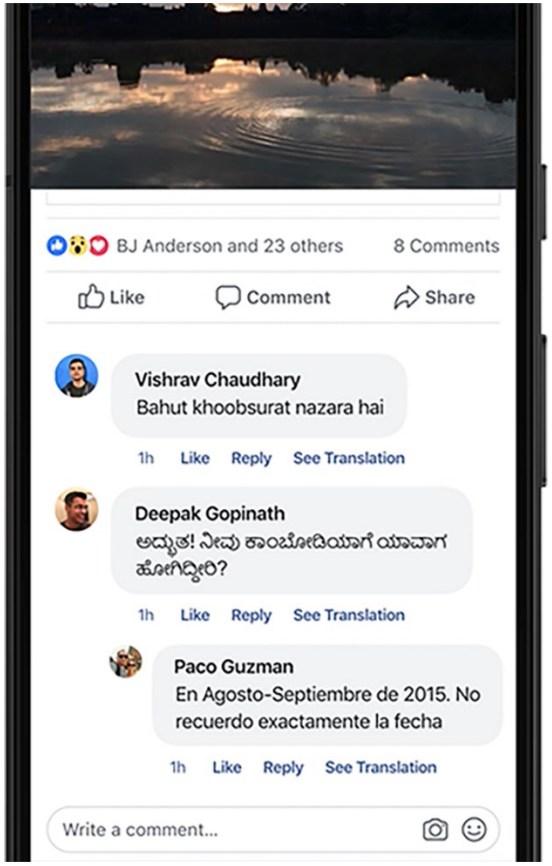


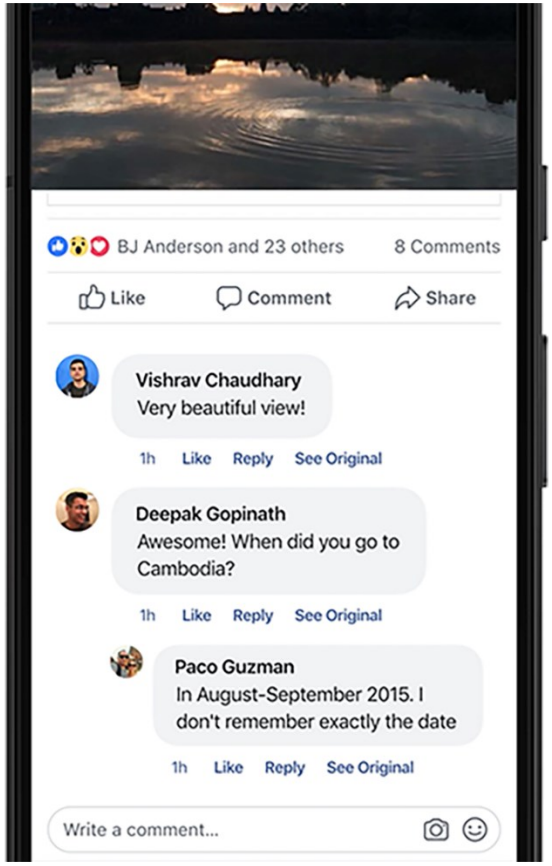
https://thispersondoesnotexist.com/





Automatic Machine Translation





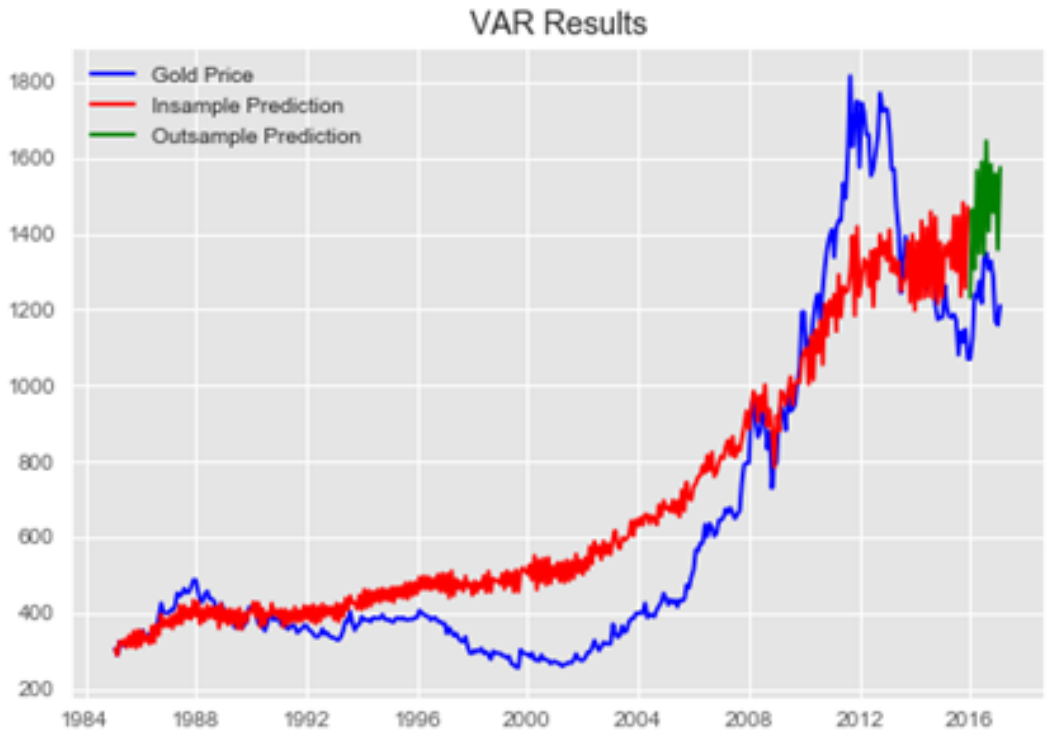
https://engineering.fb.com/ml-applications/expanding-automatic-machine-translation-to-more-languages/

Self-driving cars



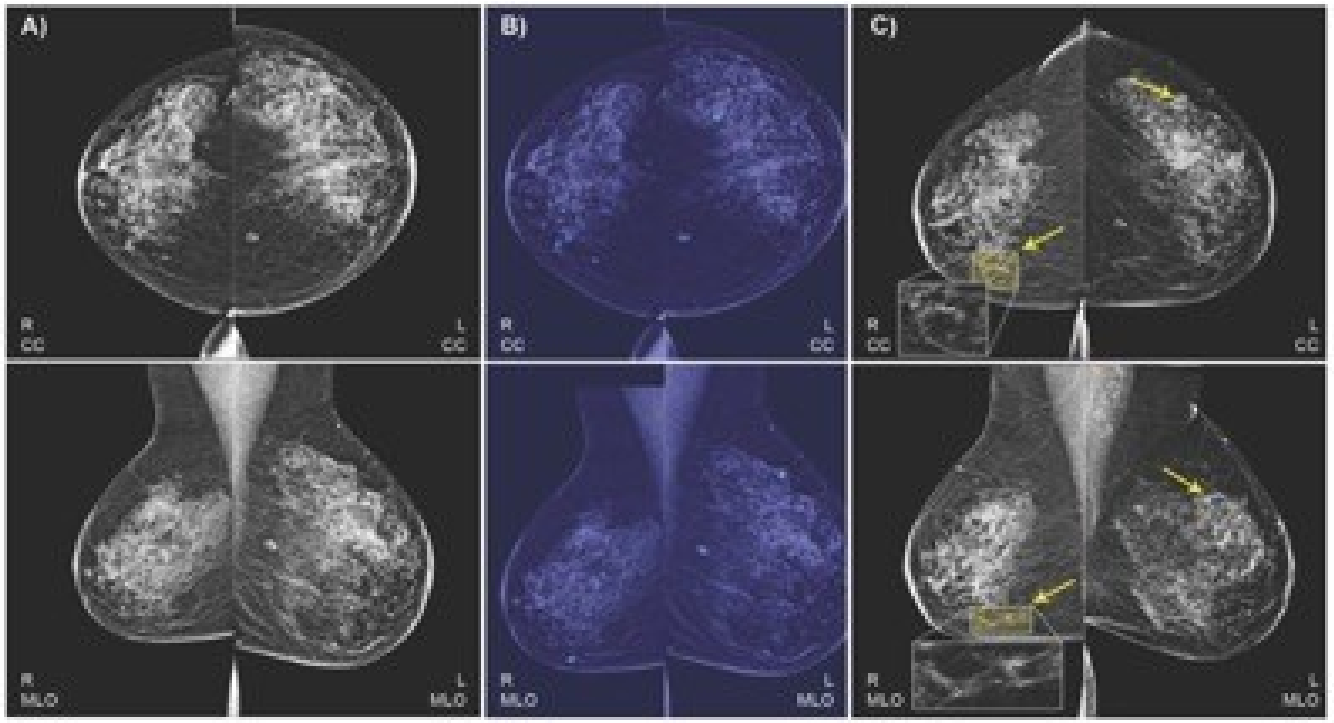
Full Self-Driving https://www.youtube.com/watch?v=tlThdr3O5Qo

Neural Networks in Finance



https://towardsdatascience.com/deep-learning-in-finance-9e088cb17c03

Deep Learning in Healthcare



https://www.ibm.com/blogs/research/2019/06/ai-models-radiologist-level-accuracy/

Deep Fake



https://www.youtube.com/watch?v=cQ54GDm1eL0

Why Now?

Neural Networks date back decades, so why the resurgence?

1952 Stochastic Gradient Descent

1958 Perceptron
- Learnable Weights

1986 Backpropagation
- Multi-Layer Perceptron

1995 Deep Convolutional NN
- Digit Recognition

1. Big Data

- Larger Datasets
- Easier Collection & Storage

IMAGENET

WIKIPEDIA The Free Encyclopedia



2. Hardware

- Graphics Processing Units (GPUs)
- Massively Parallelizable



3. Software

- Improved Techniques
- New Models
- Toolboxes

TensorFlow

יישומי למידה ממוחשבת

- בחיים אנו כל הזמן לומדים (ללכת, לדבר, לנהוג, קורס למידה...). גם יישומי למידת מכונה תופסים מקום נרחב בשנים האחרונות:
  - ראיה ממוחשבת
  - סיווג טקסטים (זיהוי כותב, זיהוי נושא המאמר)
  - לימוד במשחקים: שח, שש-בש...
  - כריית מידע: זיהוי חריגות בפעולות בנקאיות
  - רפואה

מהי למידה ?

- הגדרת ויקיפדיה:

שינוי יחסית קבוע ועקבי של התנהגות, הנובע מ***התנסות של הלומד***. תהליך הלמידה כולל הפנמה של מידע בצורה המאפשרת ***הכללה*** והסקת מסקנות או שינוי בלתי אמצעי (ישיר - ללא תיווך) בדרכי התנהגות. הלמידה יכולה להתרחש בדרך של ניסיון, הוראה או תצפית, ובדרך כלל ***תיועד להשגת מיומנות גבוהה יותר בביצוע מטלה מסוימת או לרכישת הבנה***.

קצת יותר פורמאלי...

נאמר כי מערכת לומדת מניסיון/דוגמאות עבור משימה ספציפית, אם ביצועי המערכת במשימה הספציפית משתפרים עם הניסיון/הדוגמאות המוזנות למערכת.

- למידה ממוחשבת – אנו עוסקים בשיפור אוטומטי של ***ביצועי המחשב*** בביצוע המשימות.

סוגים של מכונות למידה

- ***למידה מונחית - Supervised Learning***
  - ניסיון לחזות סיווג בהינתן קלט (בדר"כ מיוצג ע"י ווקטור). הקלט הוא אוסף דוגמאות מסווגות שסווגו ע"י המנחה.
- ***למידה בלתי מונחית - Unsupervised Learning***
  - ניסיון למציאת "תבניות"/"אשכולות" בתוך נתונים
  - הקלט לבעיה הוא אוסף דוגמאות בלתי-מסווגות
- ***למידה באמצעות חיזוקים - Reinforcement Learning***
  - למידת התנהגות בסביבה בה ה"סוכן" מקבל "פרסים"/"עונשים" מהסביבה ובהתאם לכך משפר את "התנהגותו"

Learning from examples (Supervised)










דוגמא ללמידה מונחית - גילוי אובייקטים בתמונה

דוגמאות של "פנים" ו-"לא פנים" כקלט למערכת

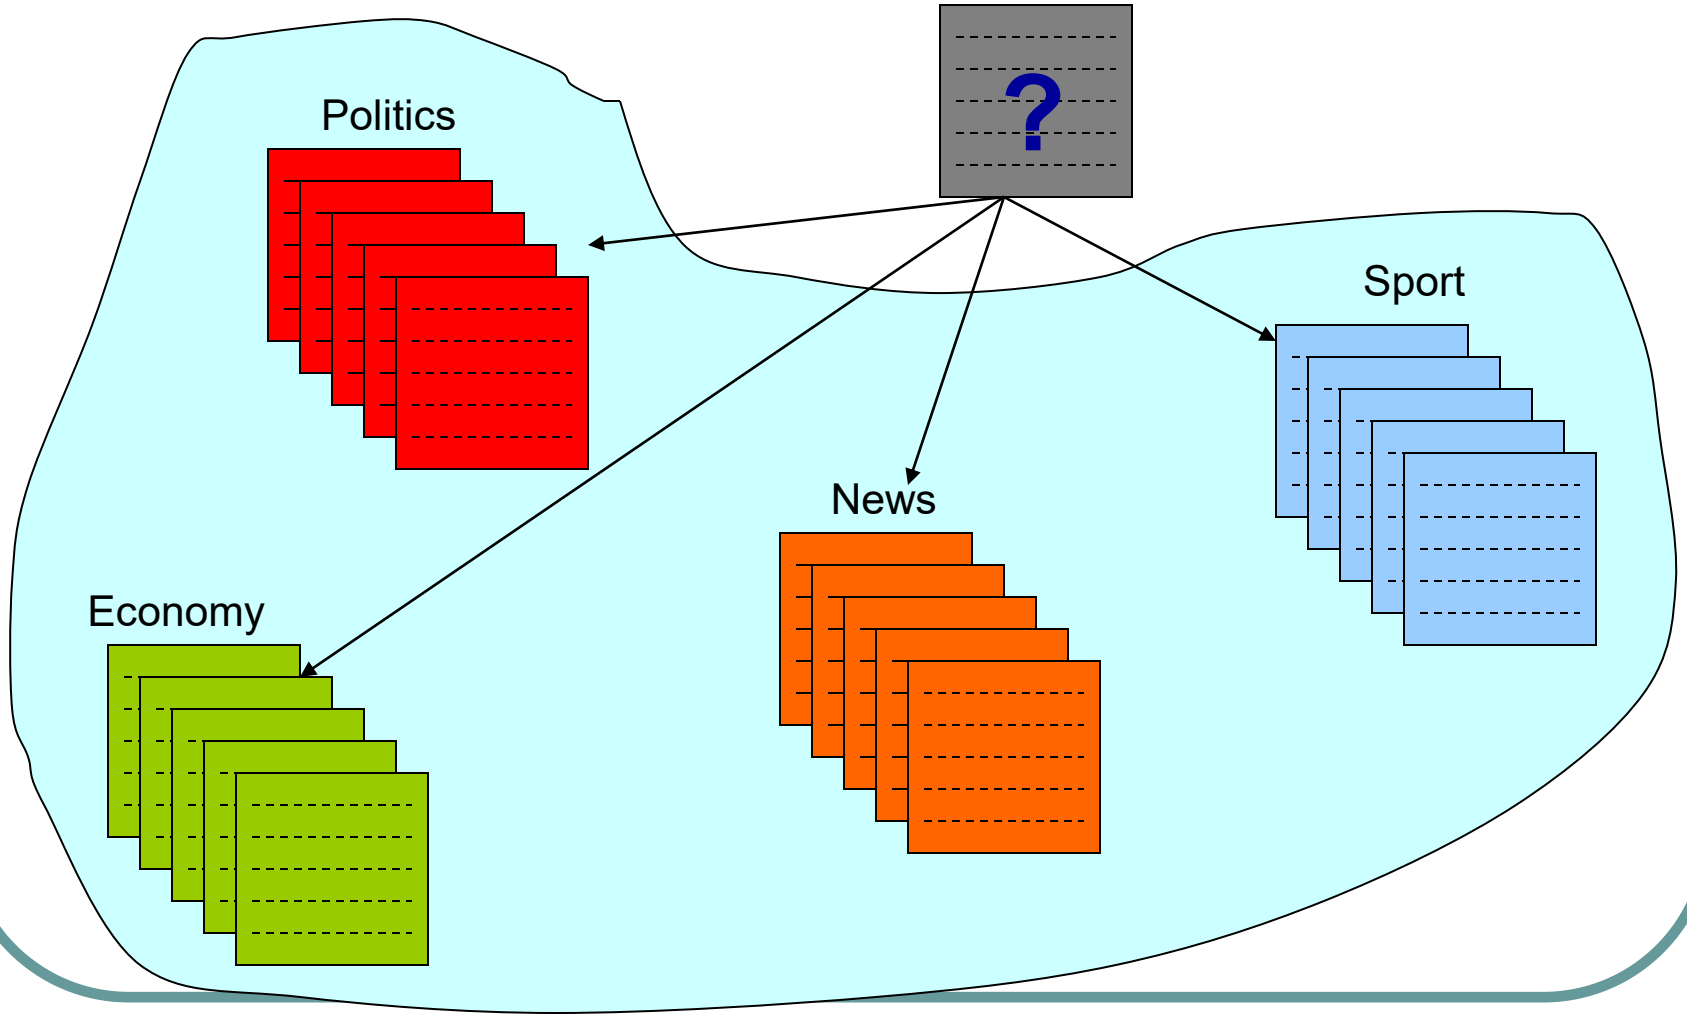
"פנים"	
"לא - פנים"	

בהינתן קלט חדש, המחשב צריך להכריע: האם זה "פנים"?



From Caltech Dataset

דוגמא ללמידה מונחית - סיווג טקסטים



דוגמא ללמידה מונחית - זיהוי פנים בתמונה

זהות ע"י מנחה

"1"

“2”

"3"

"4"



From FERET Dataset

דוגמא – סיווג טקסטים

	Label	נופש	מלון	דולר	כלכלה	בורסה	מאמן	כדורסל	כדורגל
Train	ספורט	1	35	22	12	4	56	94	34
	ספורט	32	10	51	0	0	11	6	41
	תיירות	699	31	44	93	10	1	1	4
	תיירות	57	2	34	12	1	31	7	38
	כלכלה	35	93	1	345	39	344	74	2
	כלכלה	12	44	859	931	46	14	64	90
	תיירות	791	190	88	52	35	7	0	0
	תיירות	167	23	32	61	678	93	8	4
	ספורט	74	490	73	36	18	478	23	163
Test	?	35	24	76	89	11	132	65	23

An example

Train

Label	x1	x2	x3	x4	x5	x6	x7	x8
1	54	35	22	12	132	56	94	77
1	32	0	21	945	235	11	41	37
2	699	31	44	93	110	41	-3	4
3	57	2	34	340	913	34	83	38
2	35	93	1	345	39	344	74	2
1	12	44	859	931	46	14	64	90
2	791	190	88	52	35	7	682	6012
3	167	23	32	61	678	93	8	4
3	74	490	73	739	910	478	23	63

Test

?	35	24	76	89	11	132	65	23

דוגמא ללמידה מונחית - קמעונאות – "יקנה מחשב או לא"

גיל	גובה שכר	מין	קנה מחשב
43	"גבוה"	ז	"כן"
31	"גבוה"	ז	"כן"
28	"בינוני"	ז	"כן"
32	"גבוה"	נ	"כן"
54	"נמוך"	ז	"לא"
19	"גבוה"	נ	"כן"
58	"גבוה"	נ	"כן"
72	"נמוך"	ז	"לא"
64	"בינוני"	נ	"לא"

האם האדם עם ה"פרופיל" הבא,
בהסתברות גבוהה יקנה או לא ?

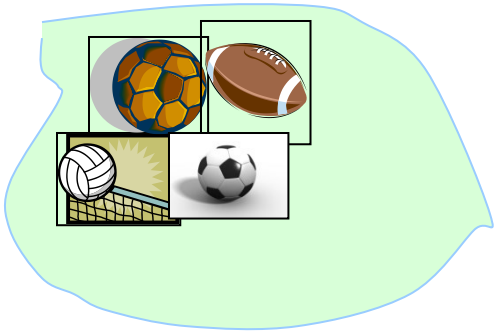
גיל	גובה שכר	מין	קנה מחשב
48	"גבוה"	נ	"לא"

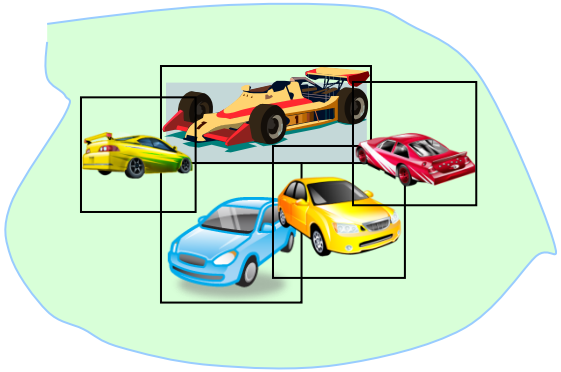
יכול להוביל את בעל החנות להחלטה,
האם "להשקיע" בלקוח זה או לא.

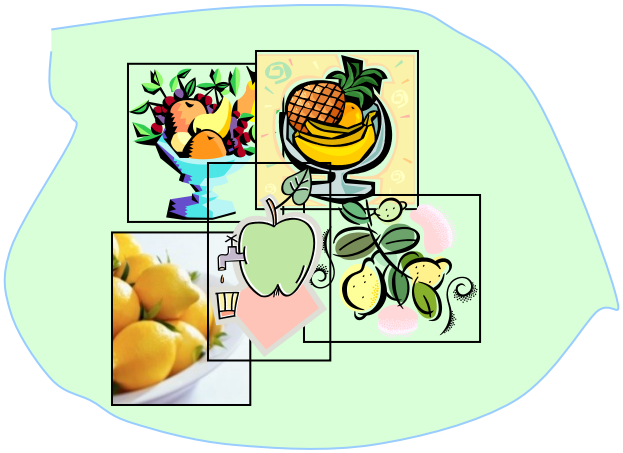
דוגמא ללמידה "לא מונחית" – מיון – חלוקה לקבוצות



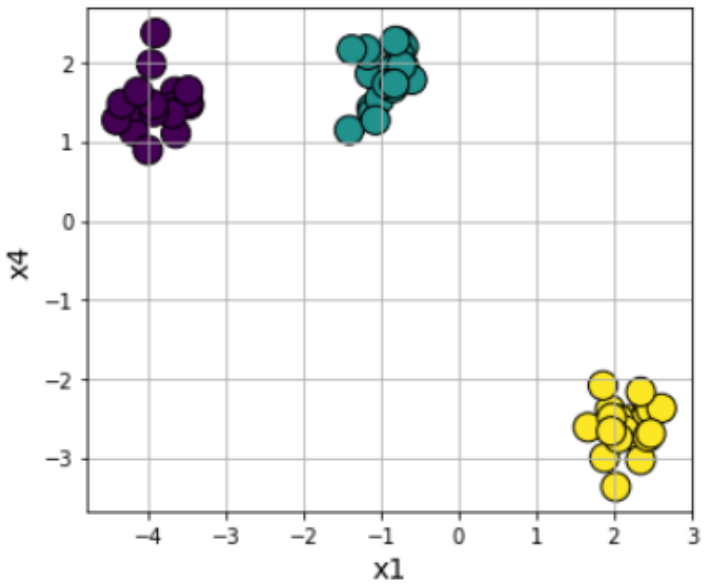
דוגמא ללמידה "לא מונחית" – מיון – חלוקה לקבוצות

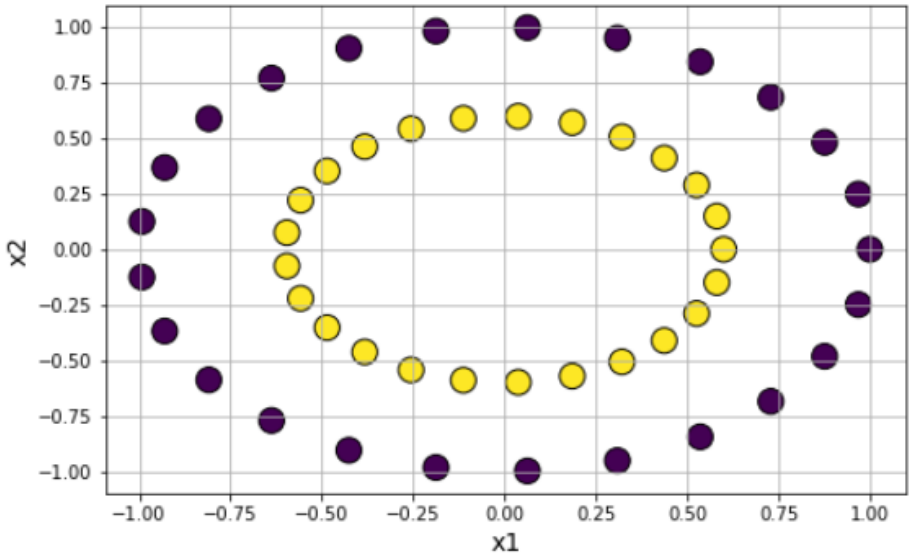






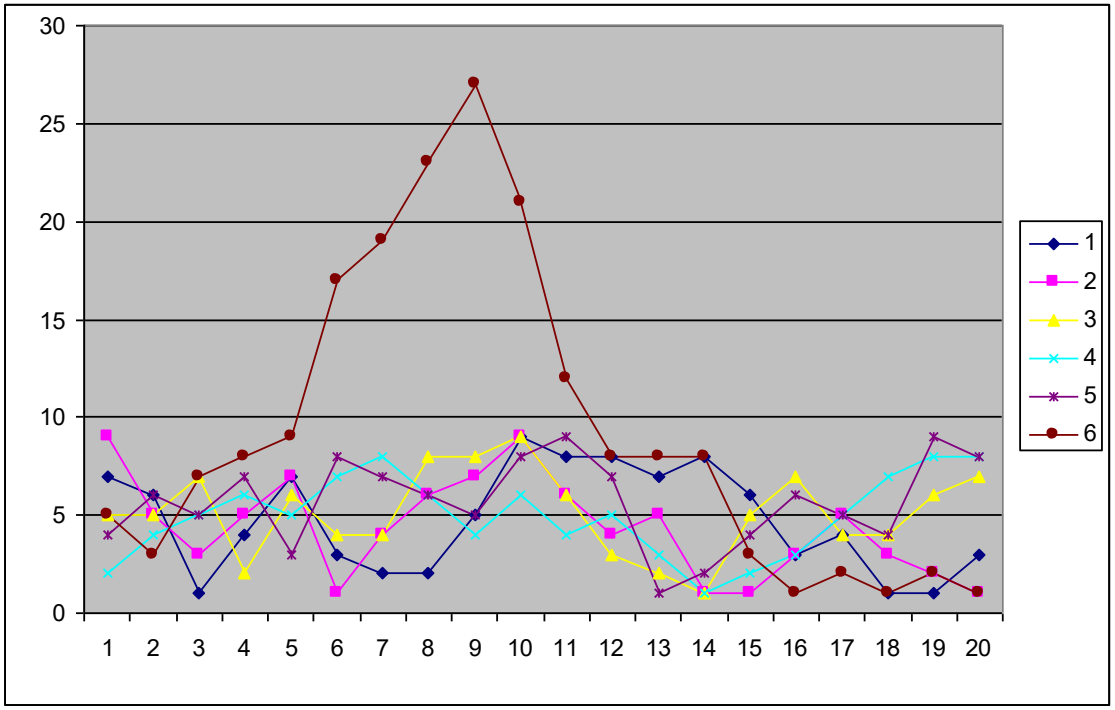
דוגמא ללמידה "לא מונחית" – מיון – חלוקה לקבוצות





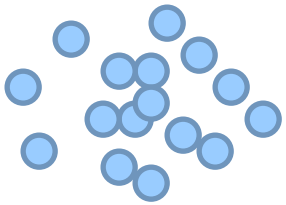
דוגמא ללמידה "לא מונחית" – זיהוי חריגויות

נתונים לנו נתוני התנהגות צריכה בכרטיס אשראי. האם יש כאן התנהגות שנראית חריגה???



Outlier detection

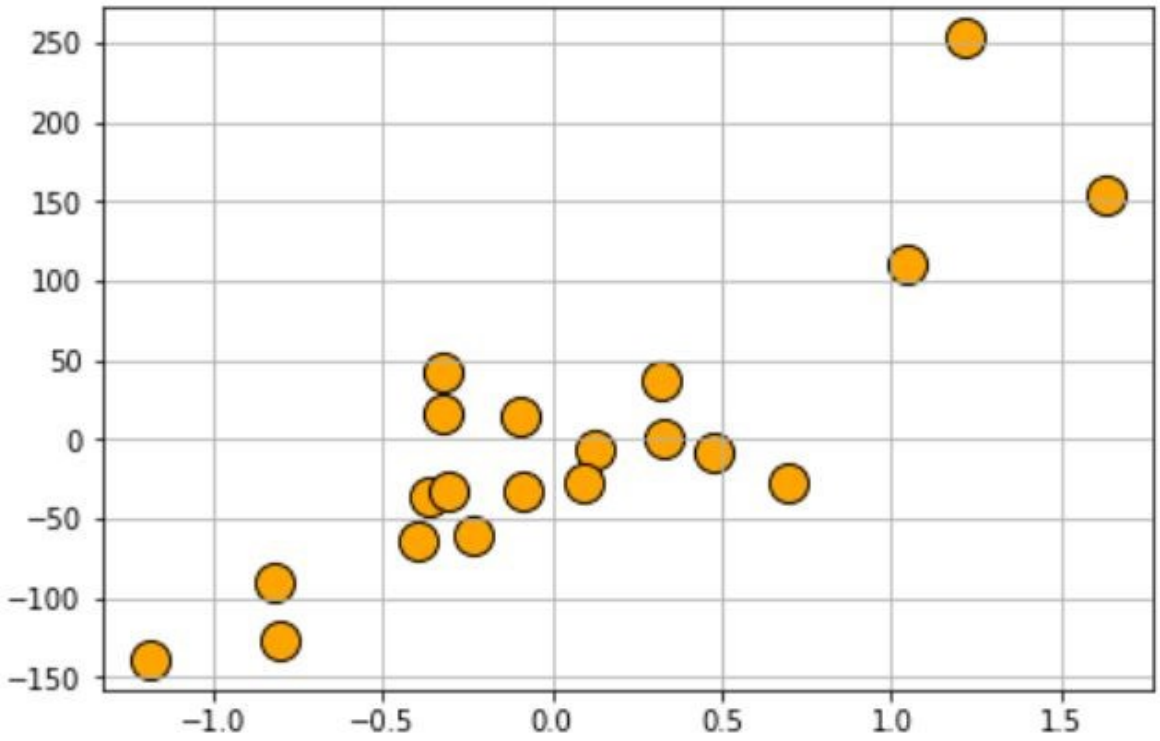
- Outlier – ווקטור שחורג באופן משמעותי משאר האובייקטים. (לא "רעש")
  - Global Outliers – חריגה ב"התנהגות" תקשורת מחשב
  - Contextual Outlier – הטמפ' היום 36 °
    - איפה?? איזו עונה



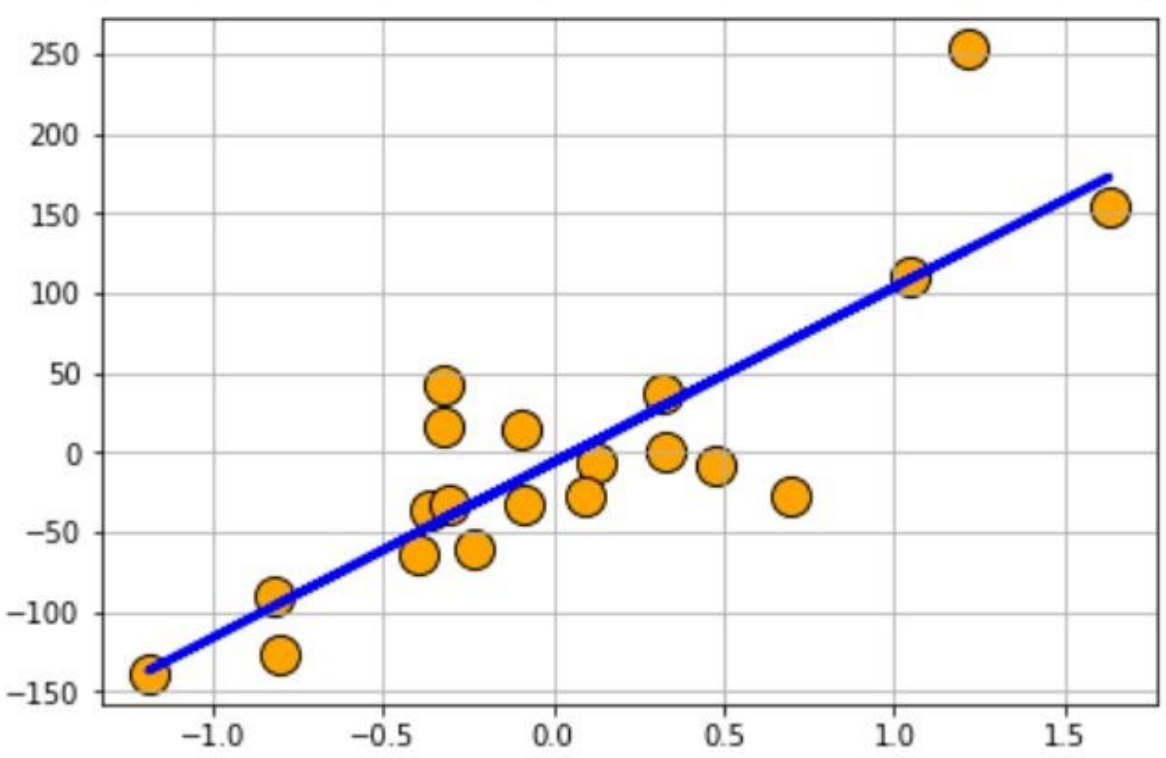
דוגמא ללמידה "לא מונחית" – זיהוי "תבניות התנהגות"

- נתונים אוסף של טרנזקציות של קונים בחנות
- ננסה לזהות "תבניות"
  - למשל קניה של מוצרים X,Y,Z מובילה בהסתברות גבוהה לקניה של מוצר T

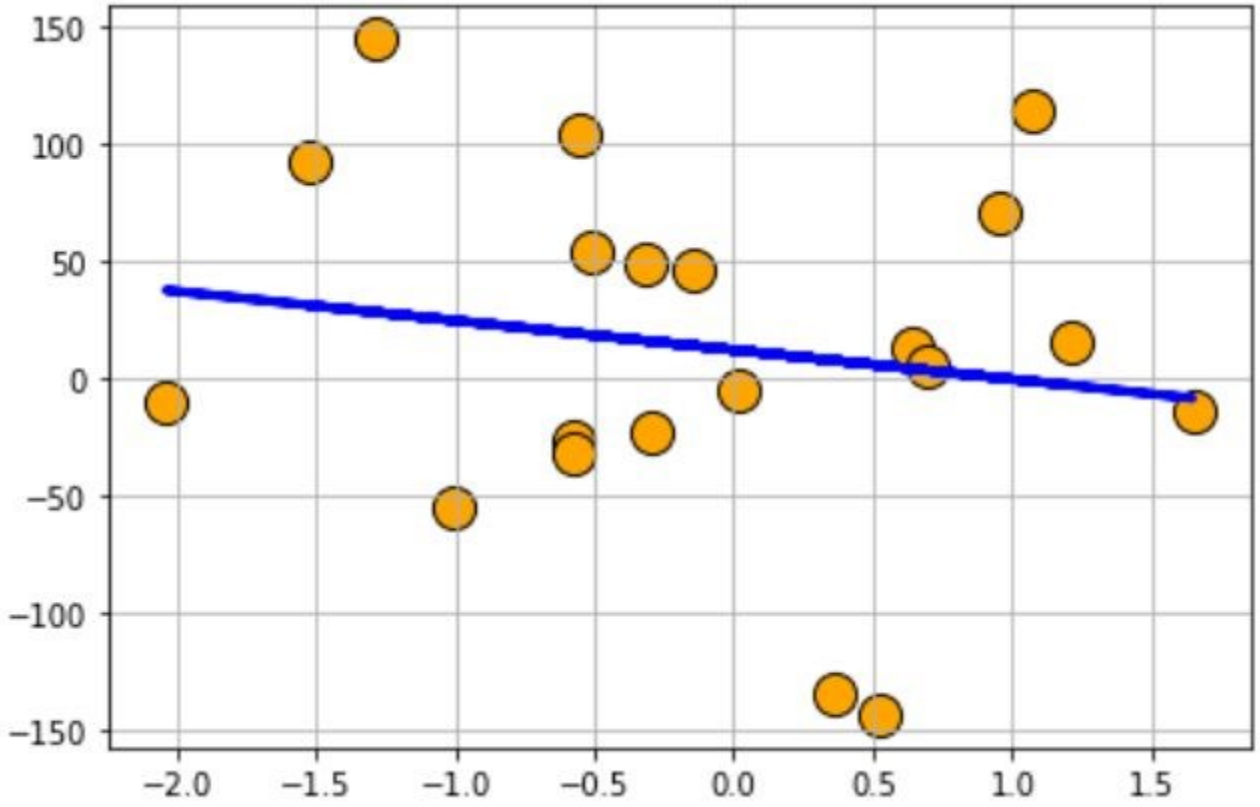
דוגמא ללמידה "מונחית" – רגרסיה



דוגמא ללמידה "מונחית" – רגרסיה



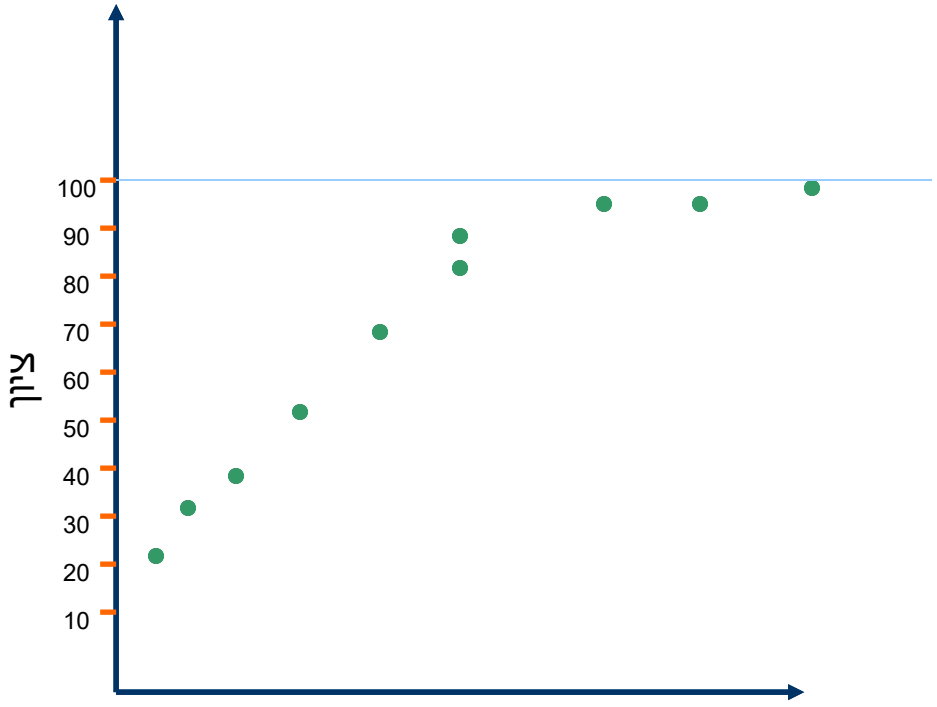
דוגמא ללמידה "מונחית" – רגרסיה



דוגמא ללמידה "מונחית" – רגרסיה

נתונים לנו ווקטורים במרחב עם ערך המוצמד לכל אחד מהם. (תצפיות)

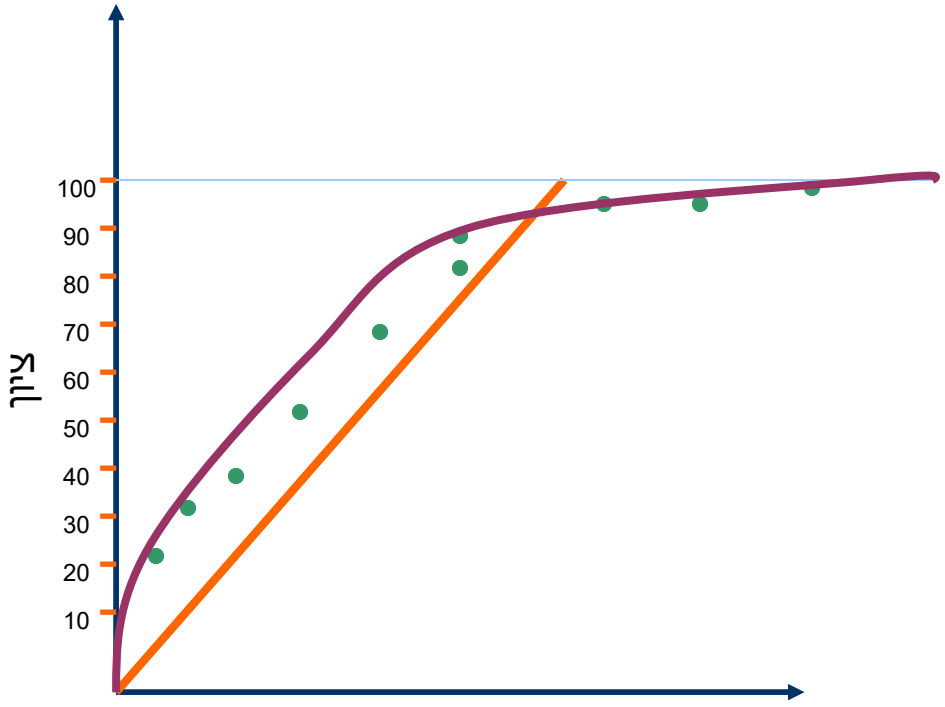
מצא משוואה אופטימלית כך שבהינתן ווקטור חדש, נוכל לשערך את ערכו.



דוגמא ללמידה "מונחית" – רגרסיה

נתונים לנו ווקטורים במרחב עם ערך המוצמד לכל אחד מהם. (תצפיות)

מצא משוואה אופטימלית כך שבהינתן ווקטור חדש, נוכל לשערך את ערכו.



למידה באמצעות חיזוקים

- הסוכן מקבל "חיזוקים" מהסביבה ובהתאם לכך "משפר" את התנהגותו

- דוגמאות:
  - שח, שש בש.
  - לימוד מסלול יציאה ממבוך.
  - קניה ומכירה של מניות.



מהי למידה חישובית

- בניית אלגוריתמים לחיזוי מנתונים

Data

- דוגמאות – data instances
- כל דוגמא מיוצגת ע"י feature vector (ווקטור המאפיינים)



(175, 82)



(194, 97)

האם הייצוג הזה (משקל, גובה) מספיק כדי לפתור את בעיית Face Recognition

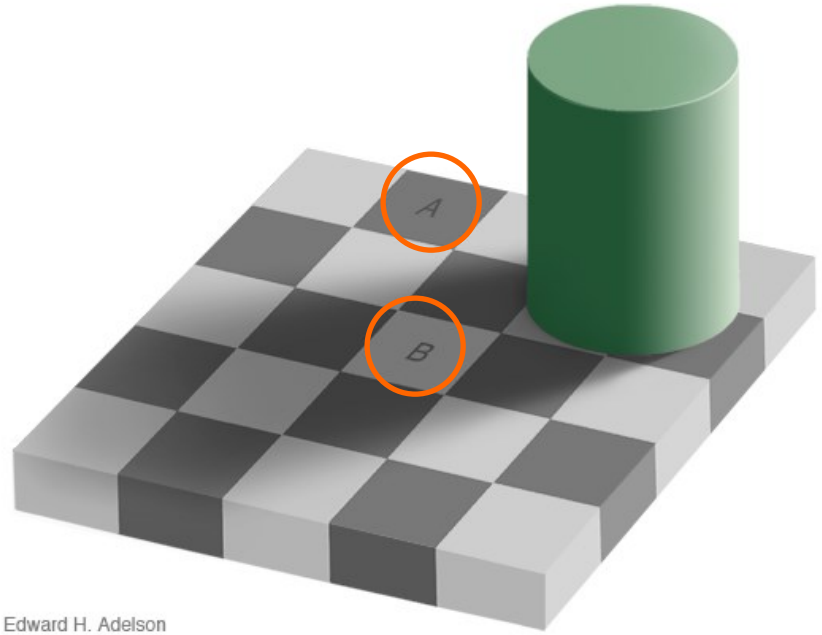
Feature vector

- ייצוג הדוגמאות צריך להיות ע"י מאפיינים "features" שעוזרים לפתור את הבעיה הספציפית אותה אנו מעוניינים לחזות
  - Features לבעיית Face Detection – יתכן ויהיו שונים מ-Features לבעיית Face Recognition
  - אם אנו רוצים לחזות סיכויים ששחקן יהיה סנטר טוב בכדורסל – יתכן שגובה ומשקל יהיו מאפיינים די טובים.

אינטואיציה אנושית מול מכונות למידה



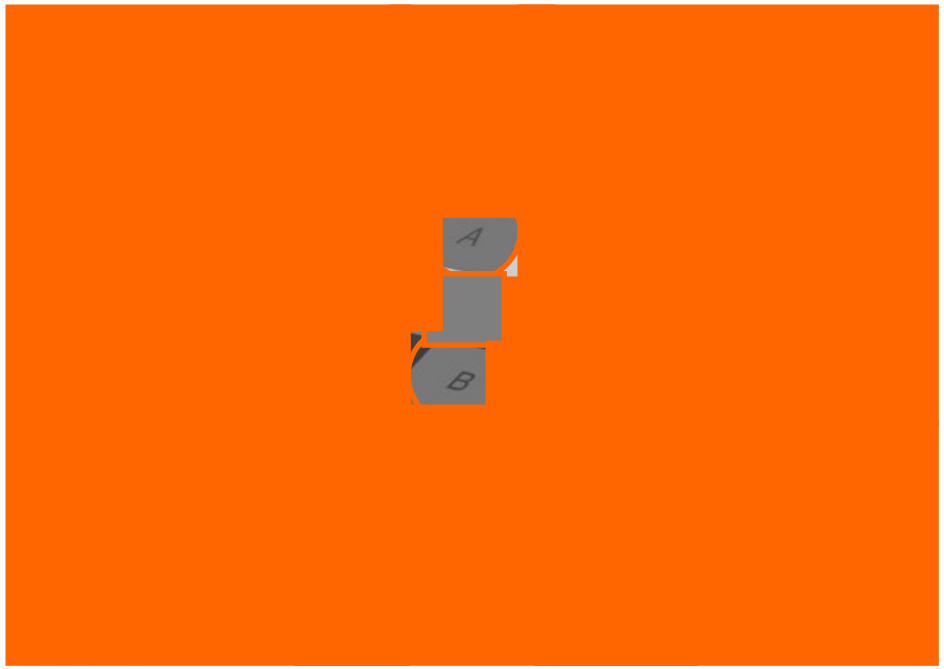
אינטואיציה אנושית מול מכונות למידה



Edward H. Adelson

http://web.mit.edu/persci/people/adelson/checkershadow_illusion.html
http://www.michaelbach.de/ot/lum_adelsonCheckShadow/index.html

אינטואיציה אנושית מול מכונות למידה



http://web.mit.edu/persci/people/adelson/checkershadow_illusion.html

מערכת למידה

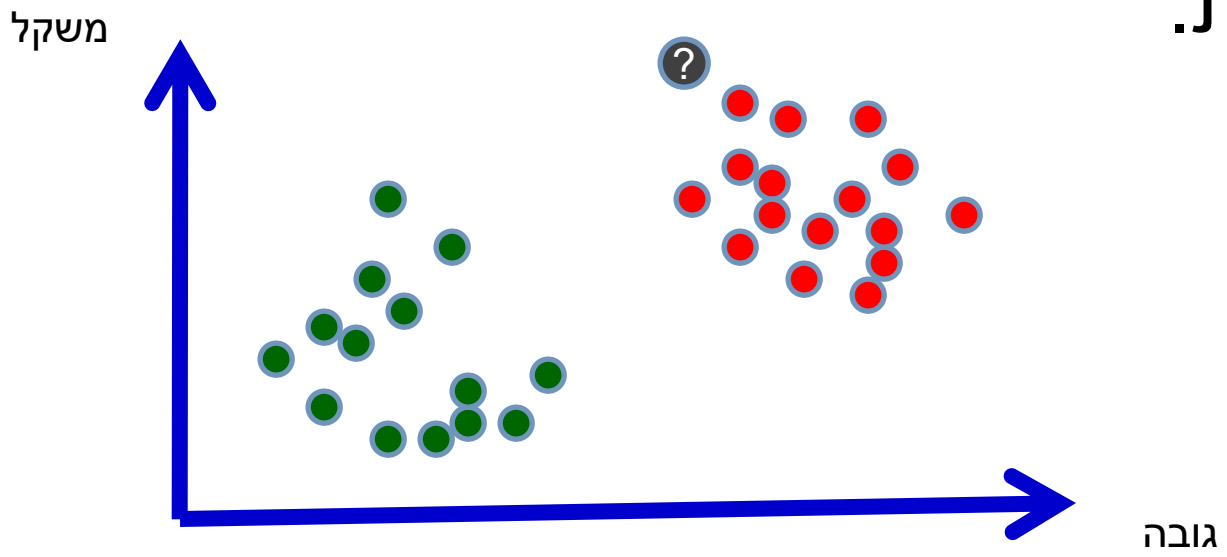
- <u>איסוף הנתונים - תצפיות</u>
  - מהם הנתונים למערכת? איזה הנחות אפשר להניח
- <u>ייצוג הנתונים</u>
  - מהי הדרך המתמטית המוצלחת לתיאור המערכת
- <u>מכונת למידה</u>
  - איזו שיטת למידה כדאי לבחור לבעיה הנוכחית
- <u>הערכת ביצועים</u>
  - מהם ביצועי המערכת? כמה מוצלח פתרנו את הבעיה

איסוף הנתונים – Data Collection

- השלב הראשון בבניית מכונה מונחית
  - לימוד המערכת ע"י דוגמאות
  - צריך דוגמאות...
- תכנון מע' face detection – אינטרנט, מאגרים אקדמאיים,
- מצלמות אבטחה, מידע רפואי, מידע מרשתות שיווק – מידע קיים אבל לא זמין בקלות

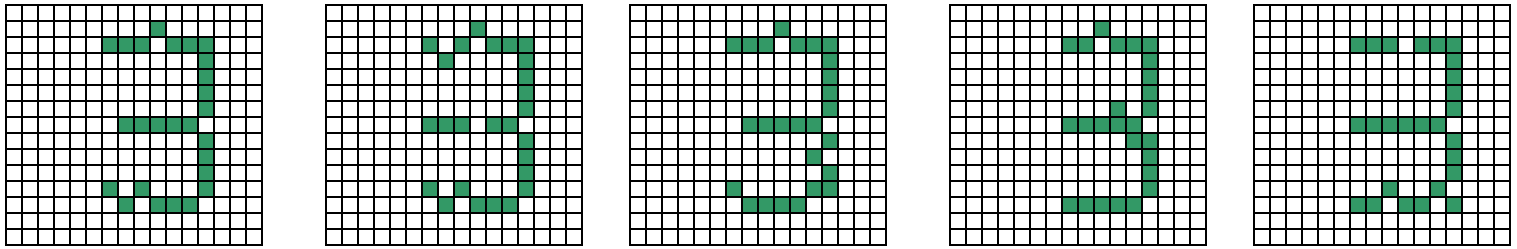
אלגוריתם למידה

- שימוש בדוגמאות (תצפיות) קיימות ע"מ לנסות לחזות תוצאה על דוגמא שעדיין לא "הוצגה" למערכת.



ייצוג חכם של הנתונים

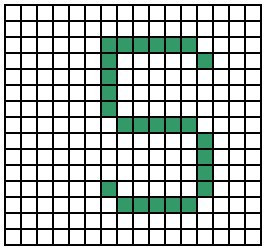
קבוצת אימון:

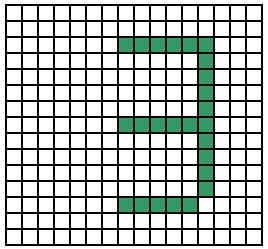


If the Descriptor is “The number of green pixels in the image”

בכל הדוגמאות שלמעלה מס' הפיקסלים הירוקים = 26

קבוצת מבחן:





מס' הפיקסלים הירוקים = 26 ← "3"

מס' הפיקסלים הירוקים = 25 → ~~"3"~~

תהליך "קדם-עיבוד" (pre-process)

- נתונים חסרים
  - למשל בטבלת "buy computer" , לעיתים יהיו חסרים נתוני "גובה שכר"
- טעויות בהזנה
  - למשל, בעמודת המשכורת ימצא הערך "10-"
- נתונים "רועשים"
  - לעיתים בגלל מכשור שונה, תהליך העברת המידע
- חוסר עקביות בהזנת הנתונים
  - תאריך רכישה: "12/05/2009" או 12-May-2010
  - דרוג: A,B,C ולעיתים 1,2,3

חשיבות שלב ה-pre-process

- <u>המטרה</u>: שיפור איכות הנתונים

החלטה איכותית

חייבת להתבסס על

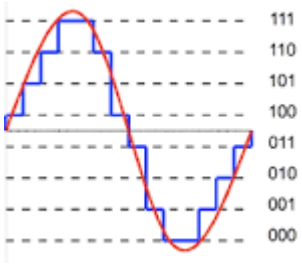
נתונים איכותיים

שלבים עיקריים בתהליך ה- pre-process

- דיגיטיזציה של הנתונים
  - למשל המרת טקסט לווקטורים מתמטיים מתארים
- ניקוי המידע (Data cleaning)
  - השלמת נתונים חסרים, הסרת outliers
- "המרת המידע" (Data transformation)
  - החלקת נתונים, נירמול הנתונים
- אינטגרציה בין נתונים שונים
  - כגון, מבסיסי נתונים שונים, ממצלמות שונות
- הפחתת מימד הנתונים
  - מציאת ייצוג לבעיה ע"י מס' מאפיינים מופחת

Digitization

- ייצוג אובייקט, תמונה, קול, מסמך, או אות כלשהוא (אנאלוגי בדר"כ) ע"י קבוצה בדידה של דגימות
  - Discretization
  - Quantization



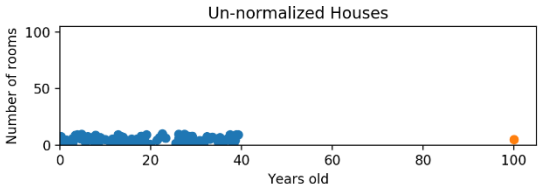


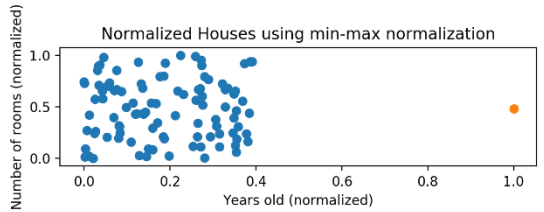
נירמול נתונים(Data normalization)

- מכשירי מדידה שונים עשויים להפיק נתונים בסקלות שונות, לכן נחפש טרנספורמציה של הערכים המקוריים לתחום אחיד.

- min-max normalization

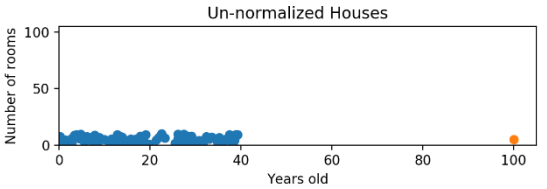
$$v' = \frac{v - min_A}{max_A - min_A}(new_max_A - new_min_A) + new_min_A$$

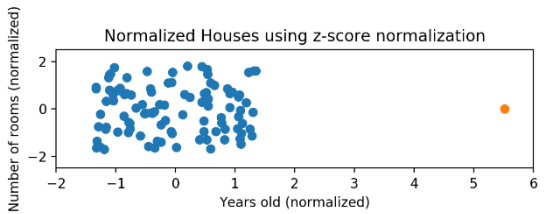




- z-score normalization

$$v' = \frac{v - mean_A}{stand_dev_A}$$





נירמול נתונים – שיטת min-max

- שיטת min-max: טרנספורמציה לינארית של הערכים המקוריים
- נניח ש-min_x ו-max_x הם הערכים המינימלי והמקסימלי הקיימים עבור "מתאר" X
- אנו רוצים למפות את התחום $[min_x\ max_x]$ לתחום $[new_min_x\ new_max_x]$

$$new_v = \frac{v - min_X}{max_X - min_X} \cdot (new_max_X - new_min_X) + new_min_X$$

נירמול נתונים – min-max method

- $min_x = 2$, $Max_x = 15$
- $new_min_x = 0$, $new_max_x = 1$

$$new_v = \frac{v - min_X}{max_X - min_X} \cdot (new_max_X - new_min_X) + new_min_X$$

$$new_v(x=4) = \frac{(4-2)}{(15-2)} \times (1-0) + 0 = \frac{2}{13}$$

$$new_v(x=15) = \frac{(15-2)}{(15-2)} \times (1-0) + 0 = \frac{13}{13} = 1$$

מה קורה כאשר מגיע נתון חדש שהערך שלו מחוץ לטווח $[min_x\ max_x]$

Z-score normalization – נירמול נתונים

$$new_v = \frac{v - \mu_X}{\sigma_X}$$

μ_x is the mean of X

Σ_x is the standard deviation of X

$$\mu_X = (2+7+4+15+8+9+11)/7 = 8$$

x	y
2	6
7	16
4	12
15	33
8	18
9	23
11	28
"-1000"	**18**

$$\sigma_X = \sqrt{\frac{(2-8)^2 + (7-8)^2 + (4-8)^2 + (15-8)^2 + (8-8)^2 + (9-8)^2 + (11-8)^2}{7}} = 4$$

$$new_v(x=4) = \frac{(4-8)}{4} = -1$$

$$new_v(x=15) = \frac{(15-8)}{4} = 1.75$$

EXTRAS (L_2)

Image Classification: A core task in Computer Vision

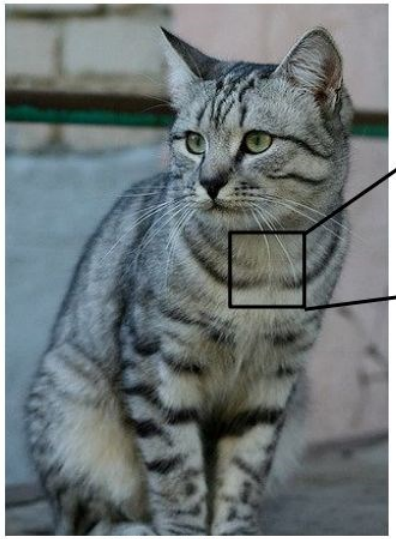


This image by Nikita is licensed under CC-BY 2.0

(assume given set of discrete labels)
{dog, cat, truck, plane, ...}

cat

The Problem: Semantic Gap



This image by Nikita is licensed under CC-BY 2.0

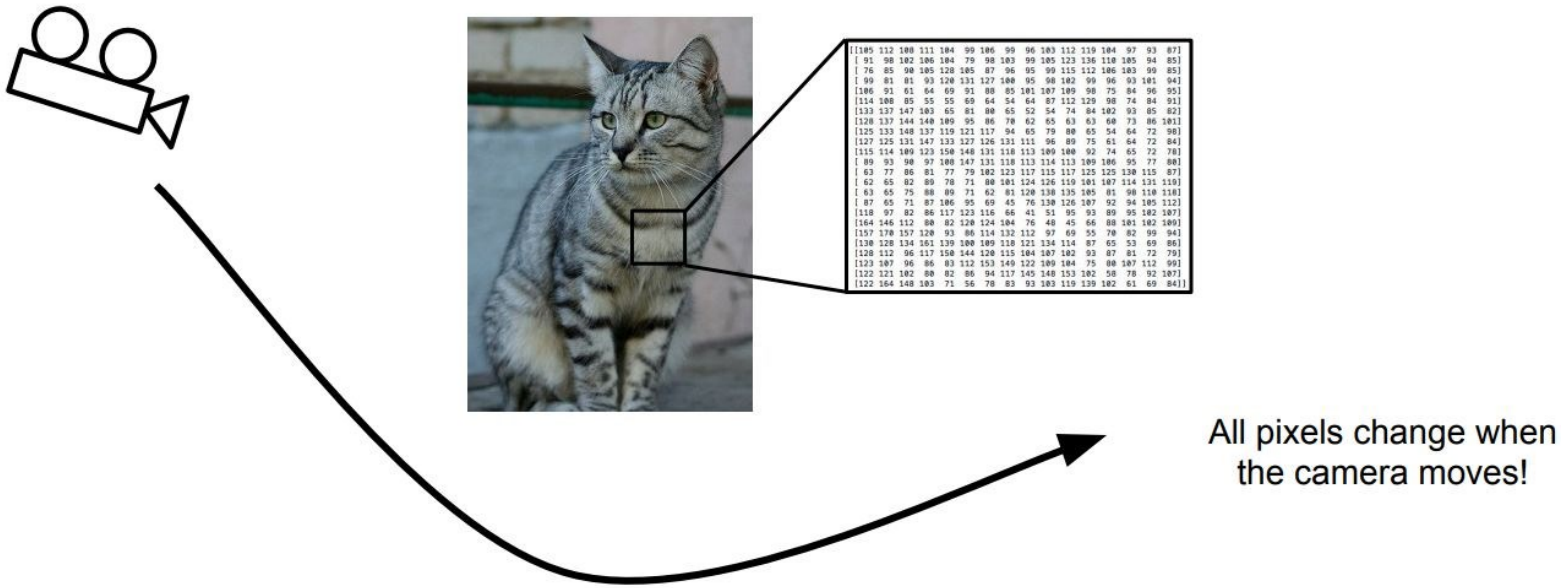
```
[[105 112 108 111 104  99 106  99  96 103 112 119 104  97  93  87]
 [ 91  98 102 106 104  79  98 103  99 105 123 136 110 105  94  85]
 [ 76  85  90 105 128 105  87  96  95  99 115 112 106 103  99  85]
 [ 99  81  81  93 120 131 127 100  95  98 102  99  96  93 101  94]
 [106  91  61  64  69  91  88  85 101 107 109  98  75  84  96  95]
 [114 108  85  55  55  69  64  54  64  87 112 129  98  74  84  91]
 [133 137 147 103  65  81  80  65  52  54  74  84 102  93  85  82]
 [128 137 144 140 109  95  86  70  62  65  63  63  60  73  86 101]
 [125 133 148 137 119 121 117  94  65  79  80  65  54  64  72  98]
 [127 125 131 147 133 127 126 131 111  96  89  75  61  64  72  84]
 [115 114 109 123 150 148 131 118 113 109 100  92  74  65  72  78]
 [ 89  93  90  97 108 147 131 118 113 114 113 109 106  95  77  80]
 [ 63  77  86  81  77  79 102 123 117 115 117 125 125 130 115  87]
 [ 62  65  82  89  78  71  80 101 124 126 119 101 107 114 131 119]
 [ 63  65  75  88  89  71  62  81 120 138 135 105  81  98 110 118]
 [ 87  65  71  87 106  95  69  45  76 130 126 107  92  94 105 112]
 [118  97  82  86 117 123 116  66  41  51  95  93  89  95 102 107]
 [164 146 112  80  82 120 124 104  76  48  45  66  88 101 102 109]
 [157 170 157 120  93  86 114 132 112  97  69  55  70  82  99  94]
 [130 128 134 161 139 100 109 118 121 134 114  87  65  53  69  86]
 [128 112  96 117 150 144 120 115 104 107 102  93  87  81  72  79]
 [123 107  96  86  83 112 153 149 122 109 104  75  80 107 112  99]
 [122 121 102  80  82  86  94 117 145 148 153 102  58  78  92 107]
 [122 164 148 103  71  56  78  83  93 103 119 139 102  61  69  84]]
```

What the computer sees

An image is just a big grid of numbers between [0, 255]:

e.g. 800 x 600 x 3
(3 channels RGB)

Challenges: Viewpoint variation



This image by Nikita is
licensed under CC-BY 2.0

Challenges: Illumination



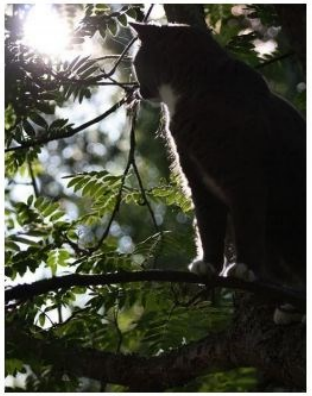
This image is CC0 1.0 public domain



This image is CC0 1.0 public domain

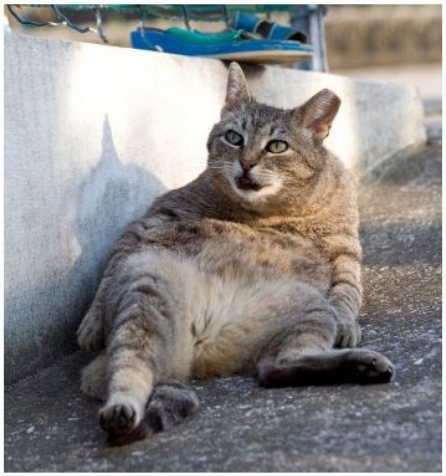


This image is CC0 1.0 public domain

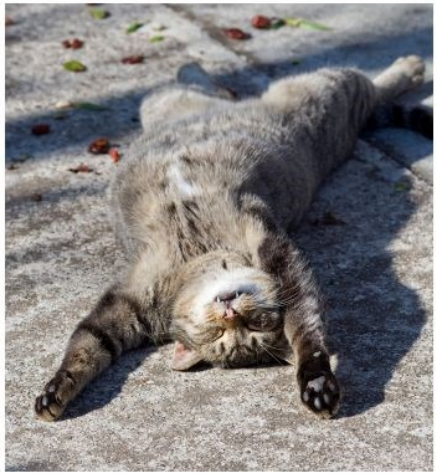


This image is CC0 1.0 public domain

Challenges: Deformation



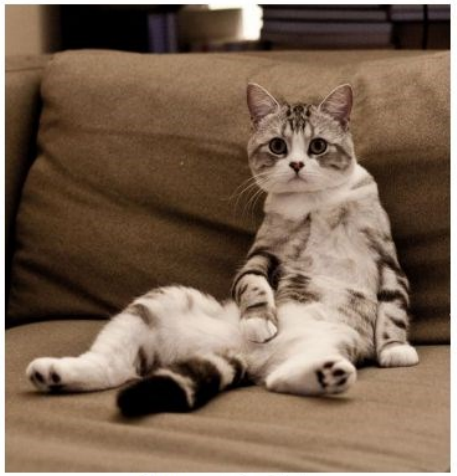
This image by Umberto Salvagnin is licensed under CC-BY 2.0



This image by Umberto Salvagnin is licensed under CC-BY 2.0



This image by sare bear is licensed under CC-BY 2.0



This image by Tom Thai is licensed under CC-BY 2.0

Challenges: Occlusion



This image is CC0 1.0 public domain



This image is CC0 1.0 public domain



This image by jonsson is licensed under CC-BY 2.0

Challenges: Background Clutter



This image is CC0 1.0 public domain



This image is CC0 1.0 public domain

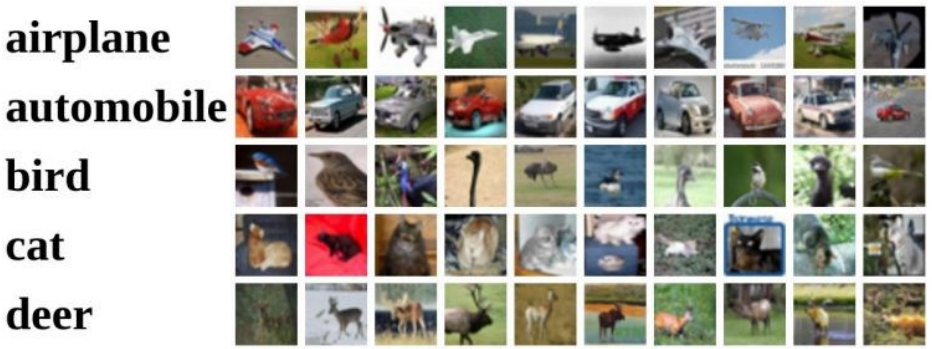
בסופו של דבר...כך נראית מערכת למידה

1. Collect a dataset of images and labels
2. Use Machine Learning to train a classifier
3. Evaluate the classifier on new images

```
def train(images, labels):
  # Machine learning!
  return model
```

```
def predict(model, test_images):
  # Use model to predict labels
  return test_labels
```

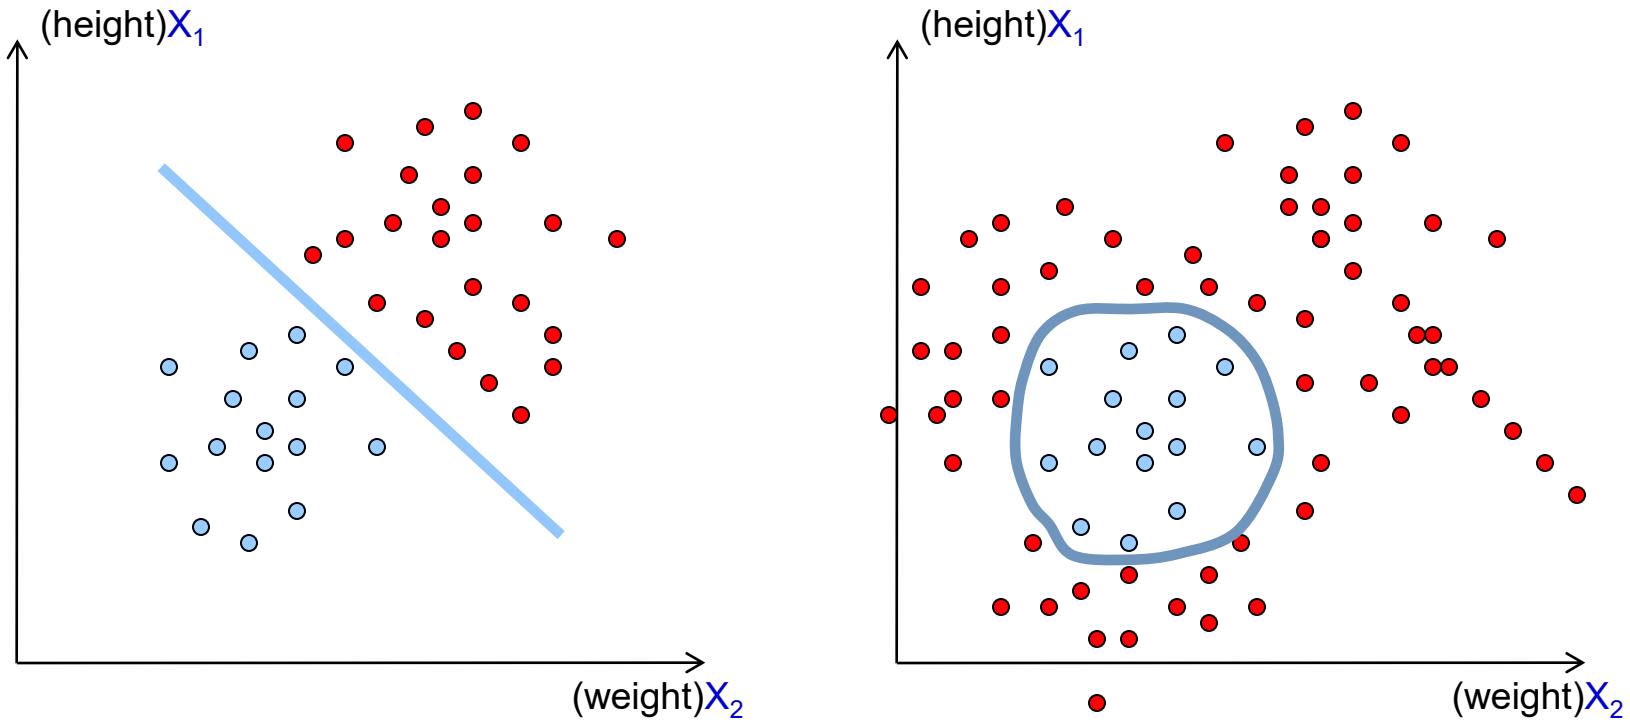
Example training set



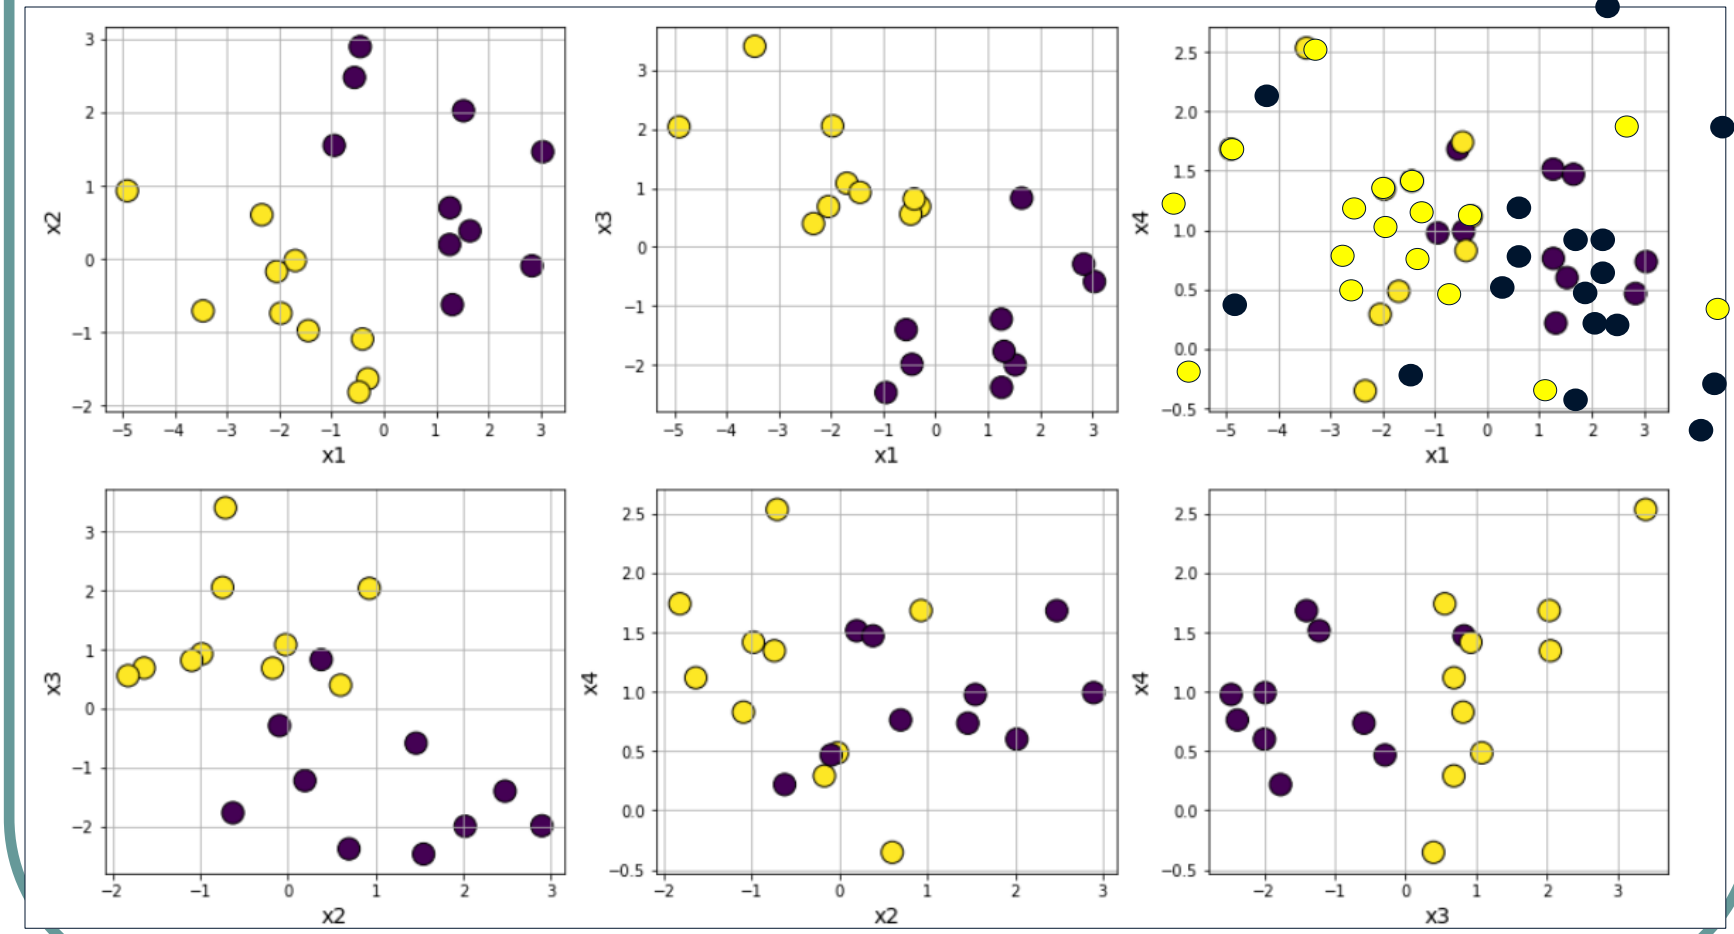
מושגים כלליים

- Linear separation vs. non-linear separation
- Binary problem vs. multi-class problem
- Generalization vs. Overfitting
- Generative model vs. Discriminative model
- Lazy algorithms vs. Eager algorithm
- ROC curve

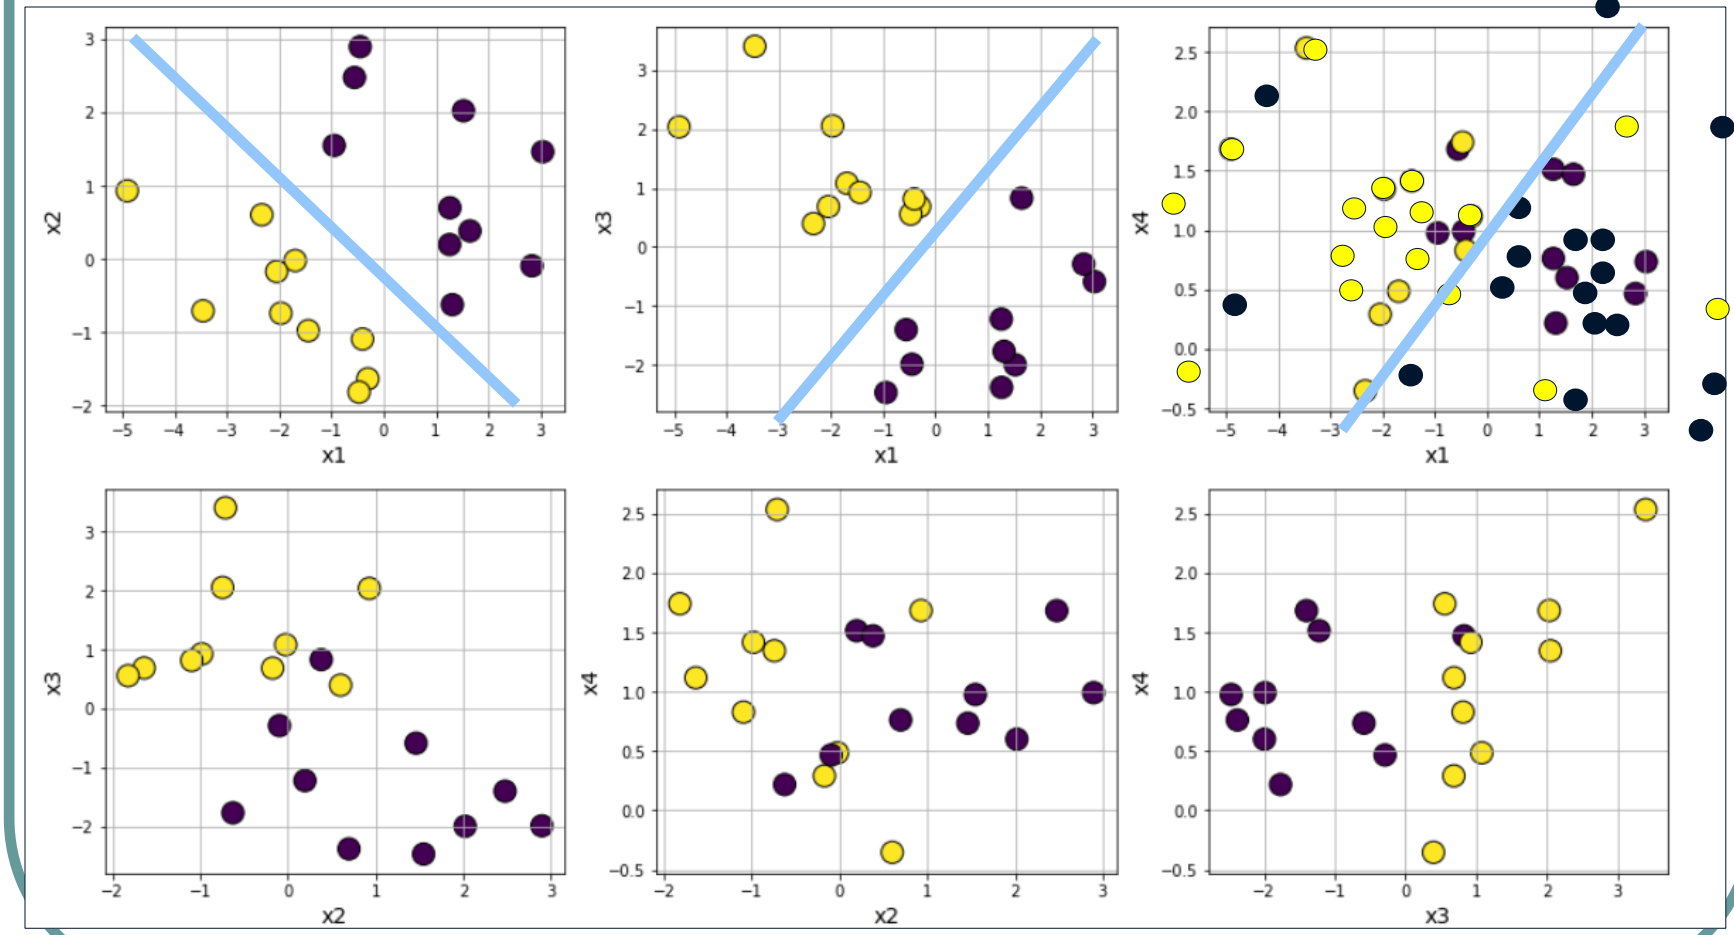
Linear separation vs. non-linear separation



Linear separation vs. non-linear separation



Linear separation vs. non-linear separation



הפרדה לינארית

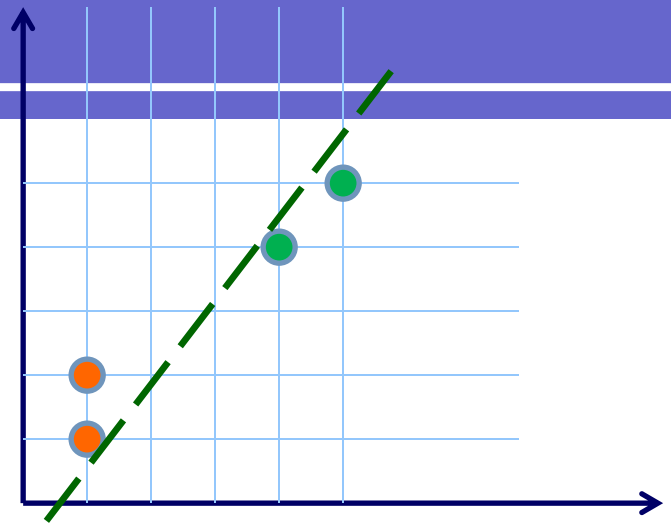
- שתי קבוצות A ו-B של ווקטורים n – מימדיים ניתנות להפרדה לינארית באופן מוחלט (absolutely lineary separable) אם קיימים n+1 מספרים ממשיים $w_1,w_2,w_3,\ldots,w_{n+1}$ כך ש:
- עבור כל נקודה $(x_1,x_2,\ldots x_n)$ הנמצאת ב-A מתקיים

$$\sum_{i=1}^{n} w_i x_i > w_{n+1}$$

- עבור כל נקודה $(x_1,x_2,\ldots x_n)$ הנמצאת ב-B מתקיים

$$\sum_{i=1}^{n} w_i x_i < w_{n+1}$$

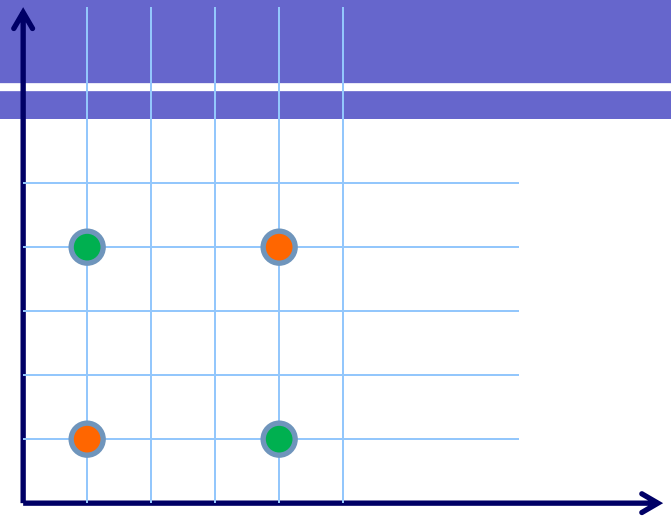
דוגמא 2D



- הווקטורים הבאים:
  - סיווג A (x_1=1, x_2=1)
  - סיווג A (x_1=1, x_2=2)
  - סיווג B (x_1=4, x_2=4)
  - סיווג B (x_1=5, x_2=5)
- ניתנים להפרדה לינארית באופן מוחלט כי קיים סט משקולות (w1=-4,w2=3, w3 = -2)
  - כך שעבור כל דוגמא ב-A מתקיים $\sum_{i=1}^{n} w_i x_i = w_1 x_1 + w_2 x_2 > w_3$
  - ועבור כל דוגמא ב-B מתקיים $\sum_{i=1}^{n} w_i x_i = w_1 x_1 + w_2 x_2 < w_3$

$$(x_1 = 1, x_2 = 1) \in A \rightarrow w_1 x_1 + w_2 x_2 > w_3 \rightarrow -4 \times 1 + 3 \times 1 > -2$$
$$(x_1 = 1, x_2 = 2) \in A \rightarrow w_1 x_1 + w_2 x_2 > w_3 \rightarrow -4 \times 1 + 3 \times 2 > -2$$
$$(x_1 = 4, x_2 = 4) \in B \rightarrow w_1 x_1 + w_2 x_2 > w_3 \rightarrow -4 \times 4 + 3 \times 4 < -2$$
$$(x_1 = 5, x_2 = 5) \in B \rightarrow w_1 x_1 + w_2 x_2 > w_3 \rightarrow -4 \times 5 + 3 \times 5 > -2$$

דוגמא 2D

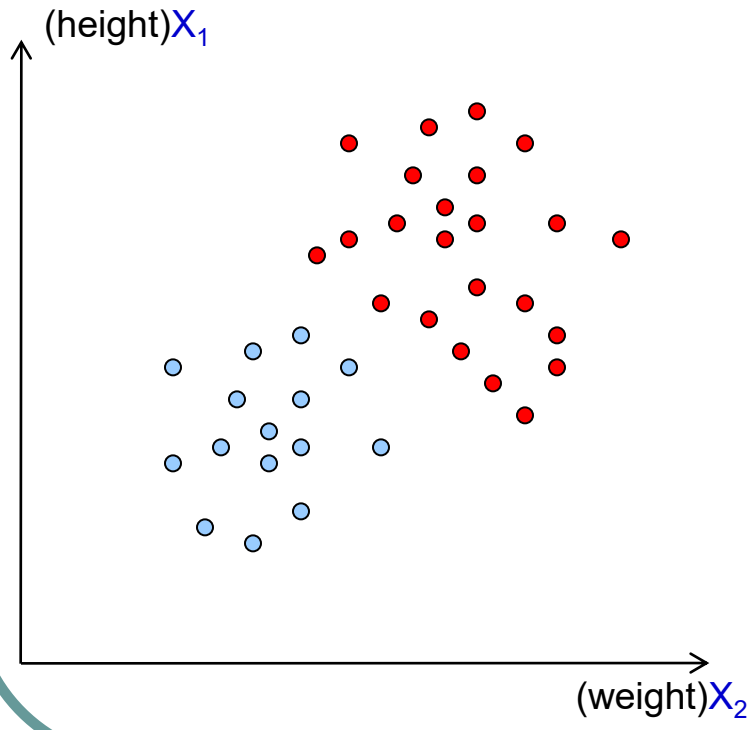


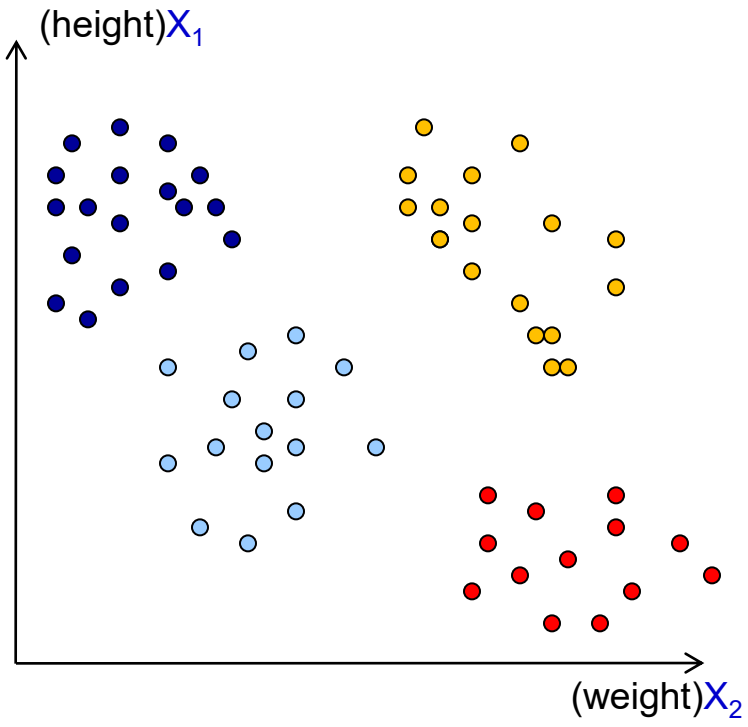
- הווקטורים הבאים:
  - (1,1) סיווג A
  - (4,4) סיווג A
  - (1,4) סיווג B
  - (4,1) סיווג B

- אינם ניתנים להפרדה לינארית באופן מוחלט כי לא ניתן למצוא סט משקולות
  - כך שעבור כל דוגמא ב-A מתקיים $\sum_{i=1}^{n} w_i x_i = w_1 x_1 + w_2 x_2 > w_3$
  - ועבור כל דוגמא ב-B מתקיים $\sum_{i=1}^{n} w_i x_i = w_1 x_1 + w_2 x_2 < w_3$

Binary problem vs. multi-class problem

- *One vs. All*
- *One vs. One*





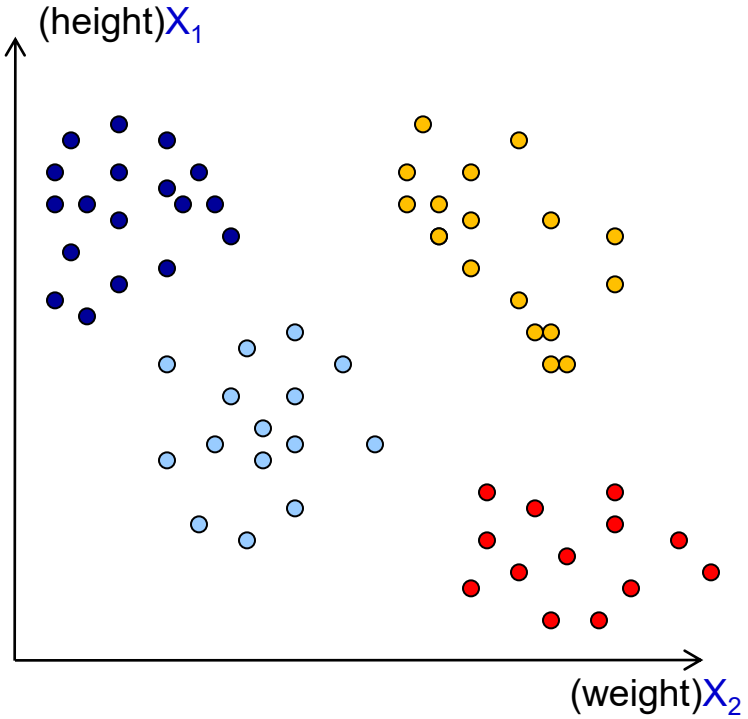
Binary problem vs. multi-class problem

- בהינתן שיש לנו אלגוריתם שפותר בעיות בינאריות אנו נדע לפתור גם בעיות multi-class
- שתי גישות אפשריות:
  - One vs. All
  - One vs. One

נניח שקיבלנו בעיה multi-class

- **<u>דוגמא:</u>**
- בעיית Face Recognition
- נתונות לנו דוגמאות של ארבעה אנשים שונים ואנו צריכים לבנות מודל כך שבהינתן דוגמא אנו יודעים לענות "מי האדם" (מתוך ארבעת האנשים)

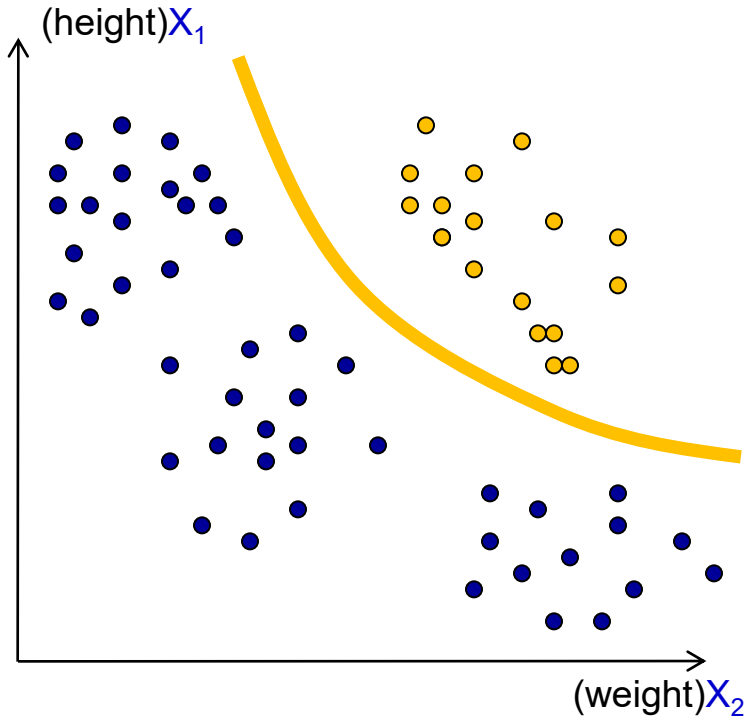
- זו בעיה שהיא multi-class אבל נניח שאנו יודעים לפתור רק בעיה בינארית



גישה א' לפתרון: One vs. All

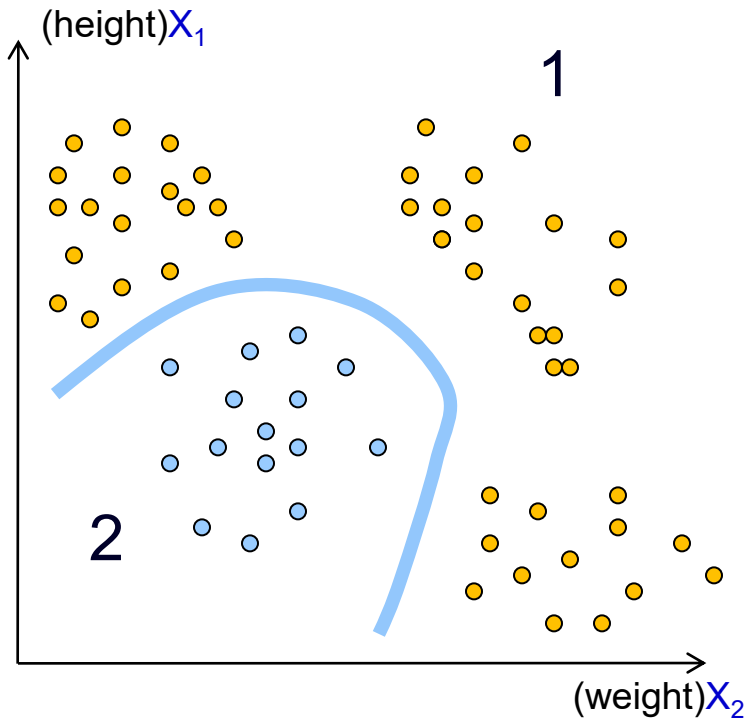
נחלק את הבעיה ל-4 בעיות בינאריות
ונריץ את אלגוריתם הלמידה עבור כל אחד מארבעת הבעיות

- אלגוריתם א'



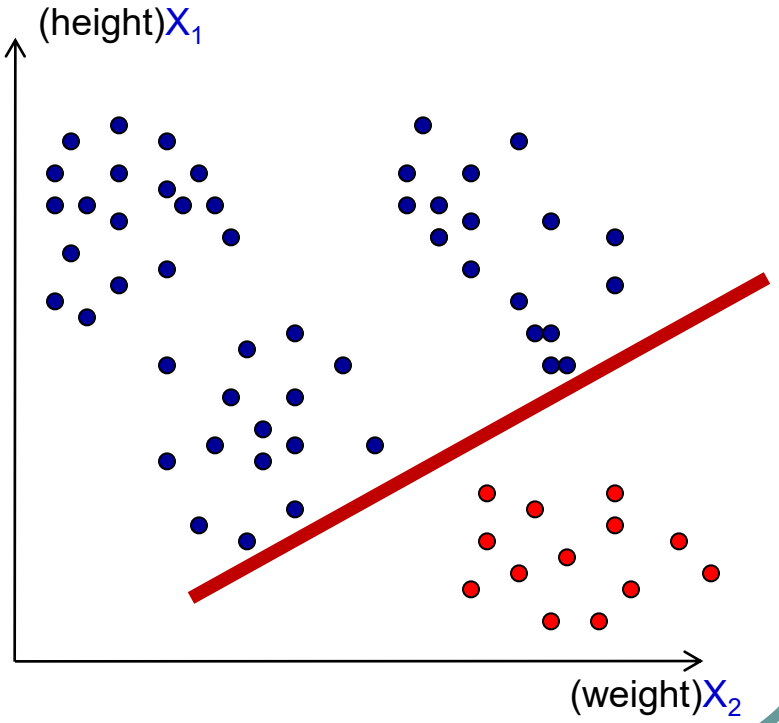
גישה א' לפתרון: One vs. All

- אלגוריתם בי'



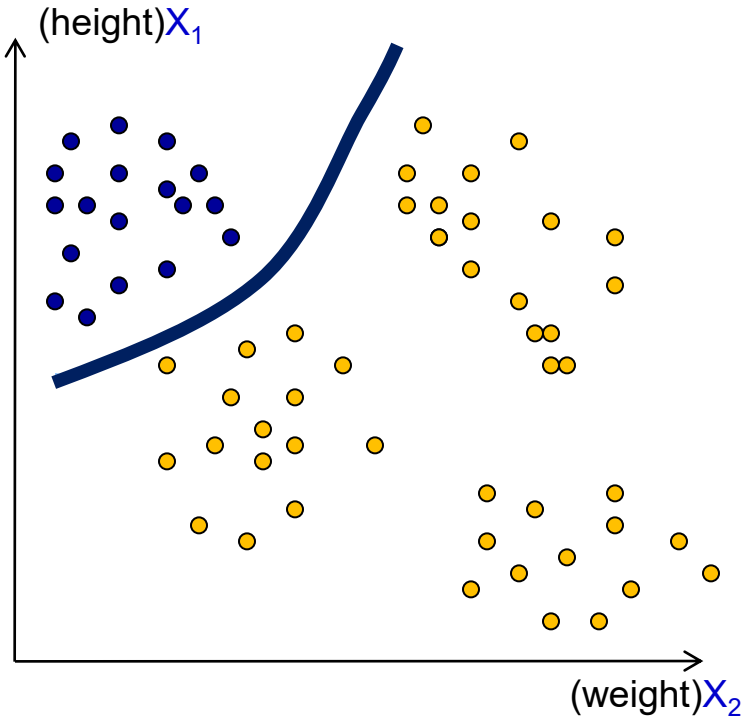
גישה א' לפתרון: One vs. All

- אלגוריתם ג'



גישה א' לפתרון: One vs. All

- אלגוריתם ד'



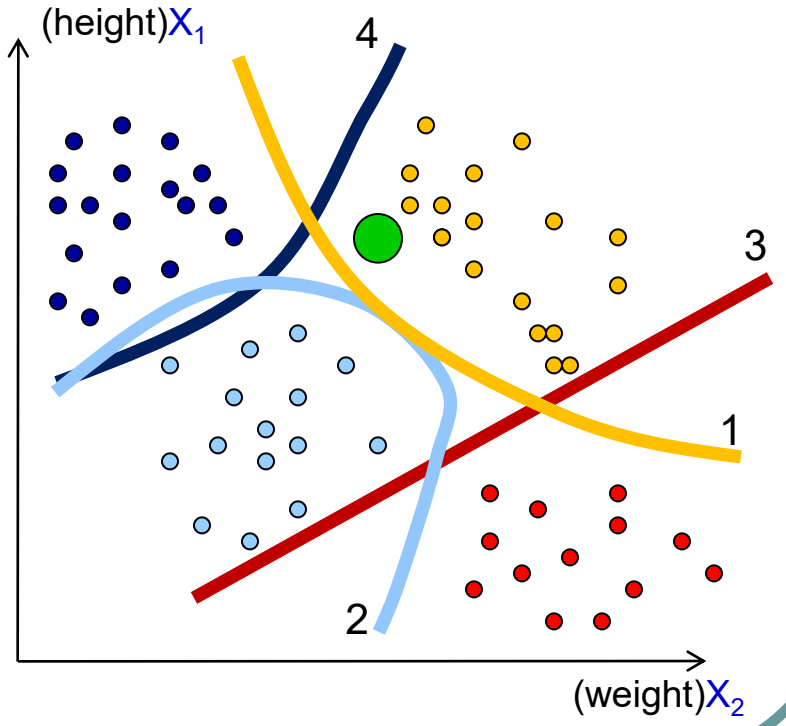
גישה א' לפתרון: One vs. All

כעת, בהינתן דוגמא לסיווג, נריץ את ארבעת האלגוריתמים שלימדנו ונראה איזו "מחלקה" זוכה ברוב ההצבעות

הצבעה 1 - (צהוב)
הצבעה 2 - (כחול, צהוב, אדום)
הצבעה 3 - (צהוב, כחול, תכלת)
הצבעה 4 - (צהוב, תכלת, אדום)

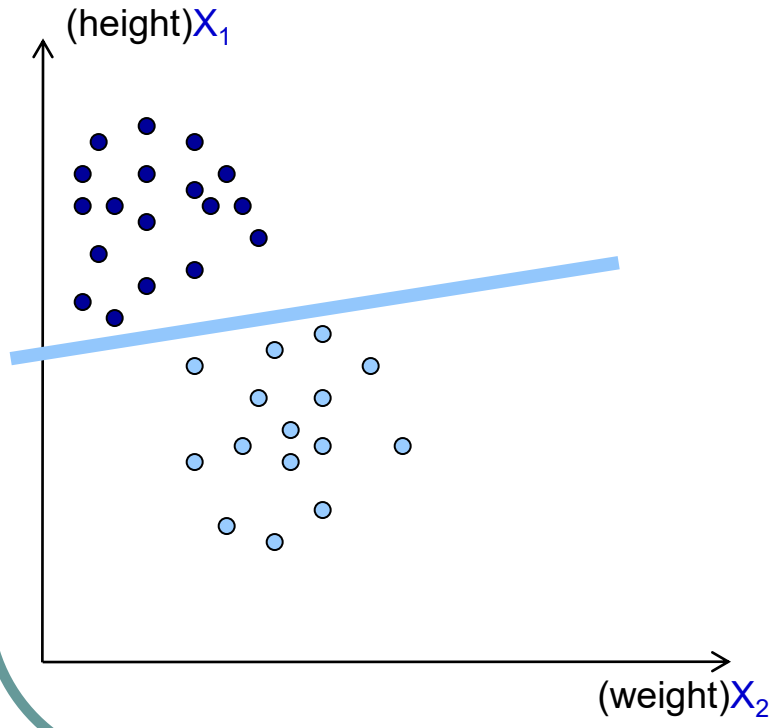
והמנצח:

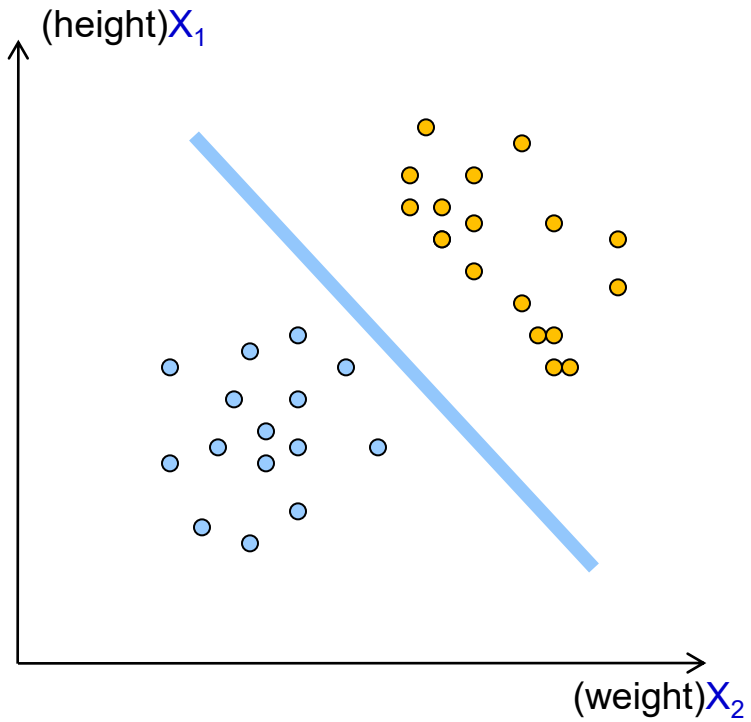
צהוב עם 4 קולות



גישה ב' לפתרון: One vs. One

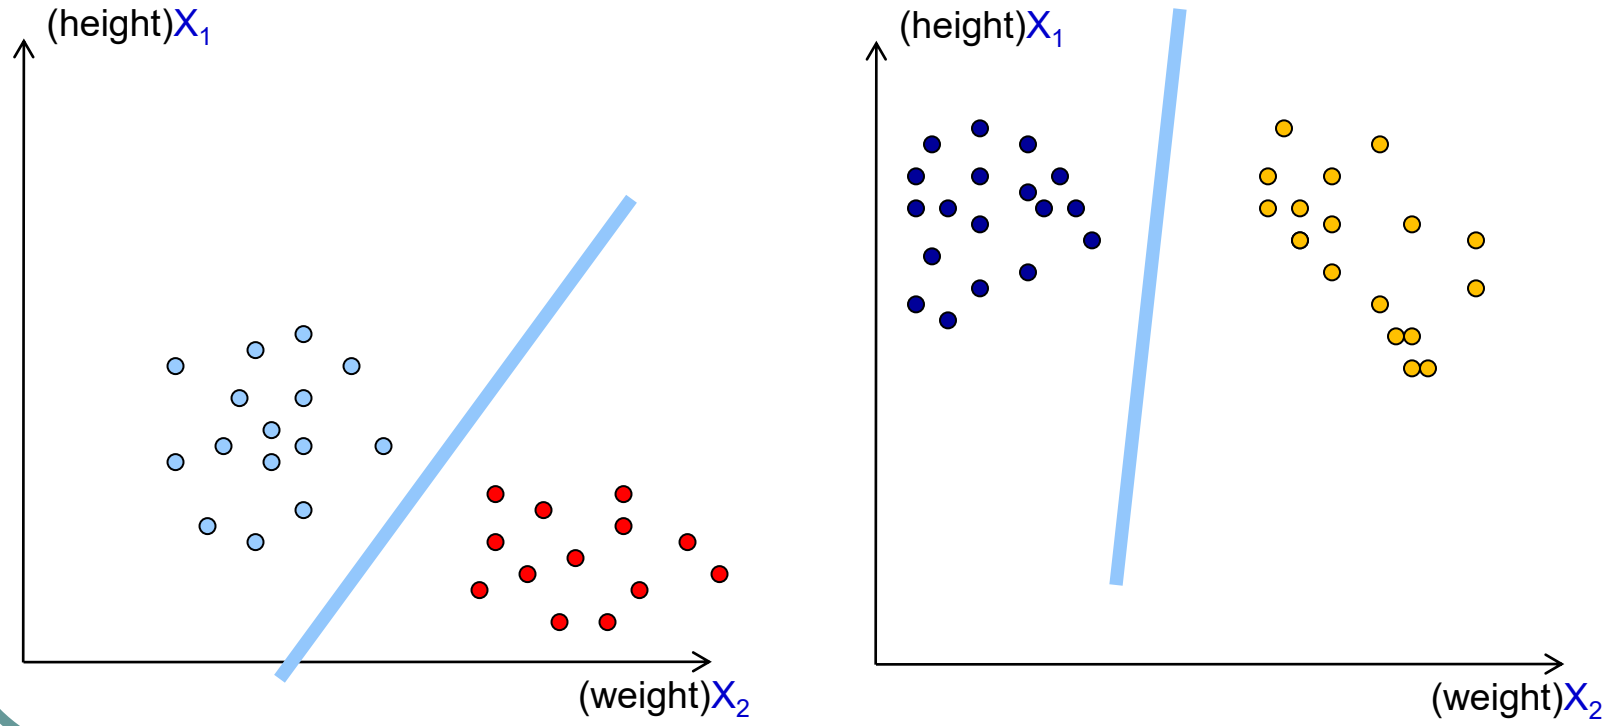
ניצור אלגוריתם למידה עבור כל זוג מחלקות





גישה ב' לפתרון: One vs. One

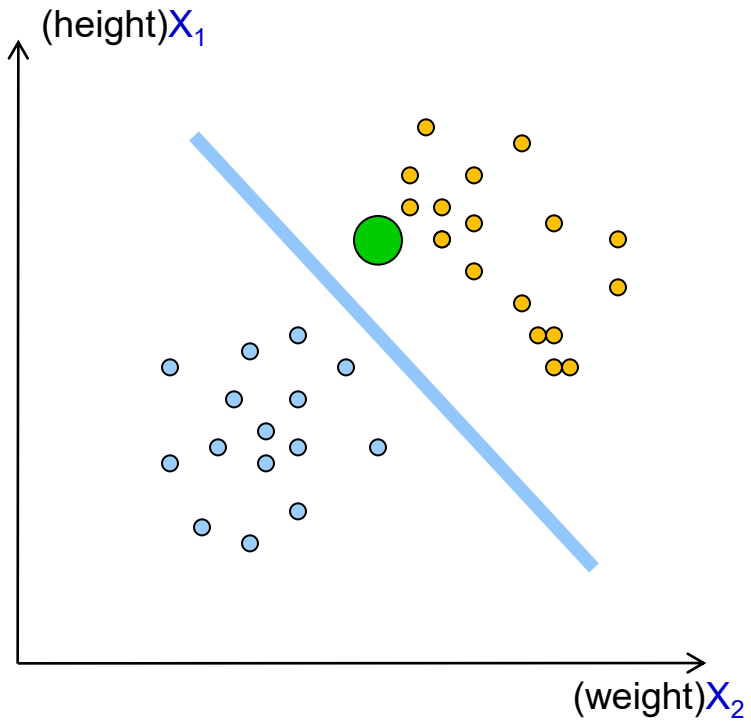
ניצור אלגוריתם למידה עבור כל זוג מחלקות



גישה ב' לפתרון: One vs. One

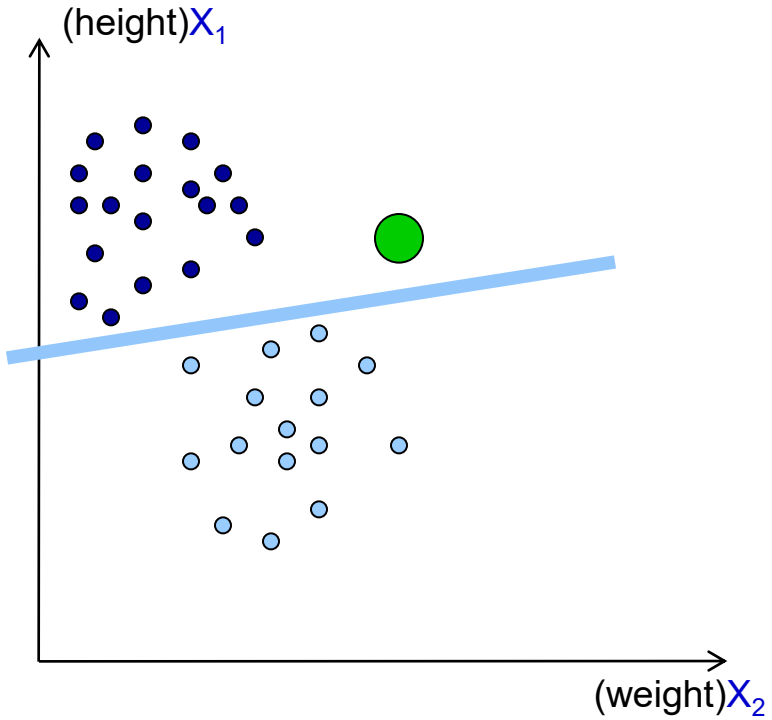
ונריץ את אלגוריתם הלמידה עבור כל זוג מחלקות

הצבעה 1 – 1 (צהוב)



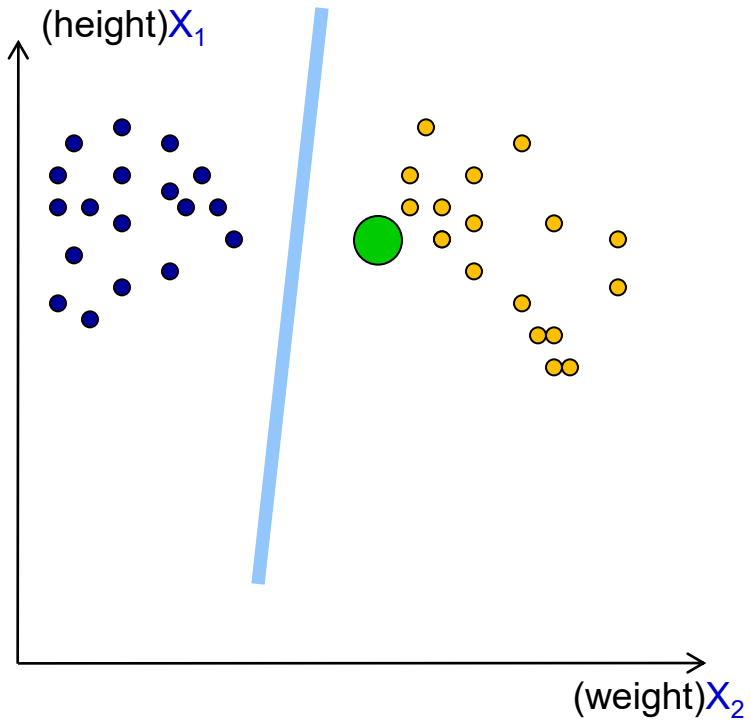
גישה ב' לפתרון: One vs. One

הצבעה 1 – 1 (צהוב)
הצבעה 2 - 1 (כחול)



גישה ב' לפתרון: One vs. One

הצבעה 1 – 1 (צהוב)
הצבעה 2 - 1 (כחול)
הצבעה 3 - 1 (צהוב)

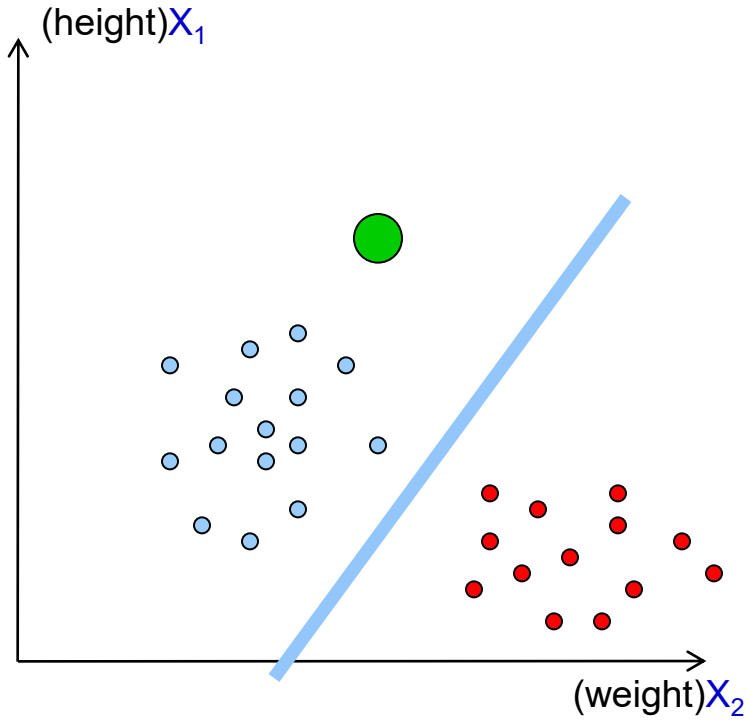


גישה ב' לפתרון: One vs. One

הצבעה 1 – 1 (צהוב)
הצבעה 2 - 1 (כחול)
הצבעה 3 - 1 (צהוב)
הצבעה 4 – 2 (תכלת)
...
...
...
הצבעה 6 - ...

והמנצח:

??? עם ??? קולות



One vs. One VS. One vs. All

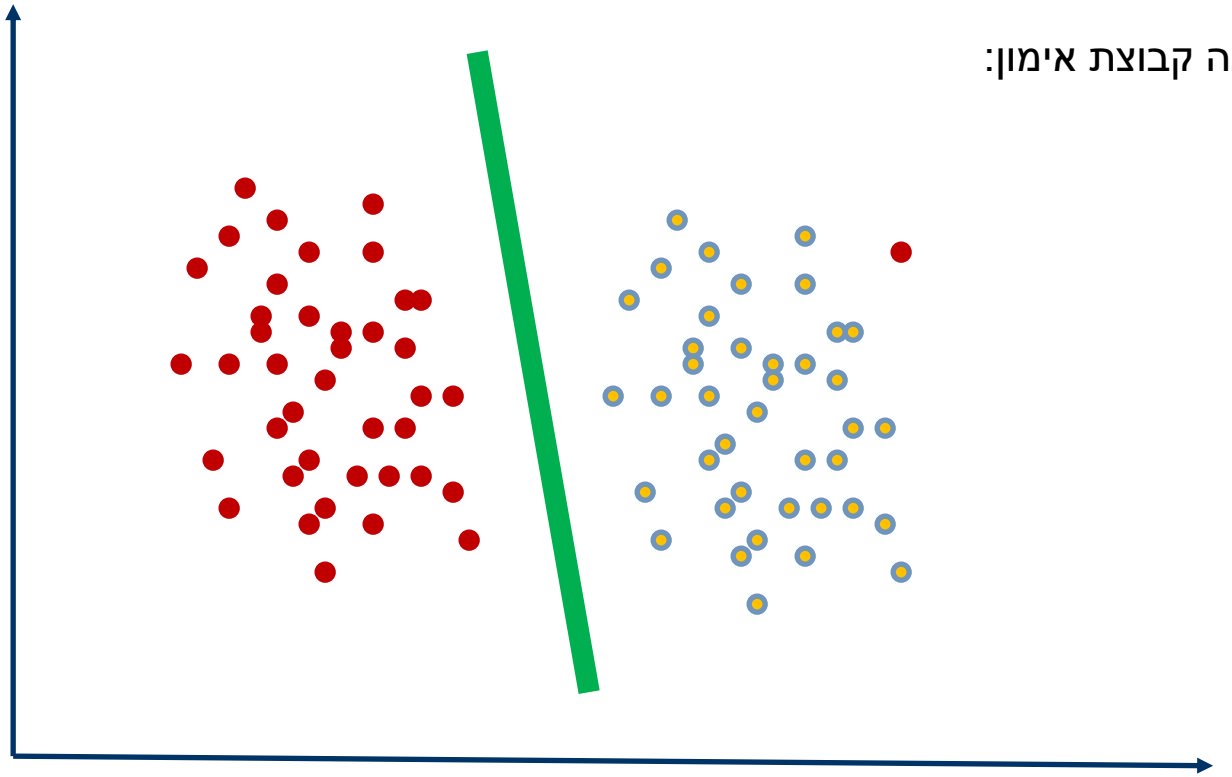
- כמה מסווגים נוצרים ???
- סיבוכיות כל מסווג בפני עצמו ???

הכללה בלמידה

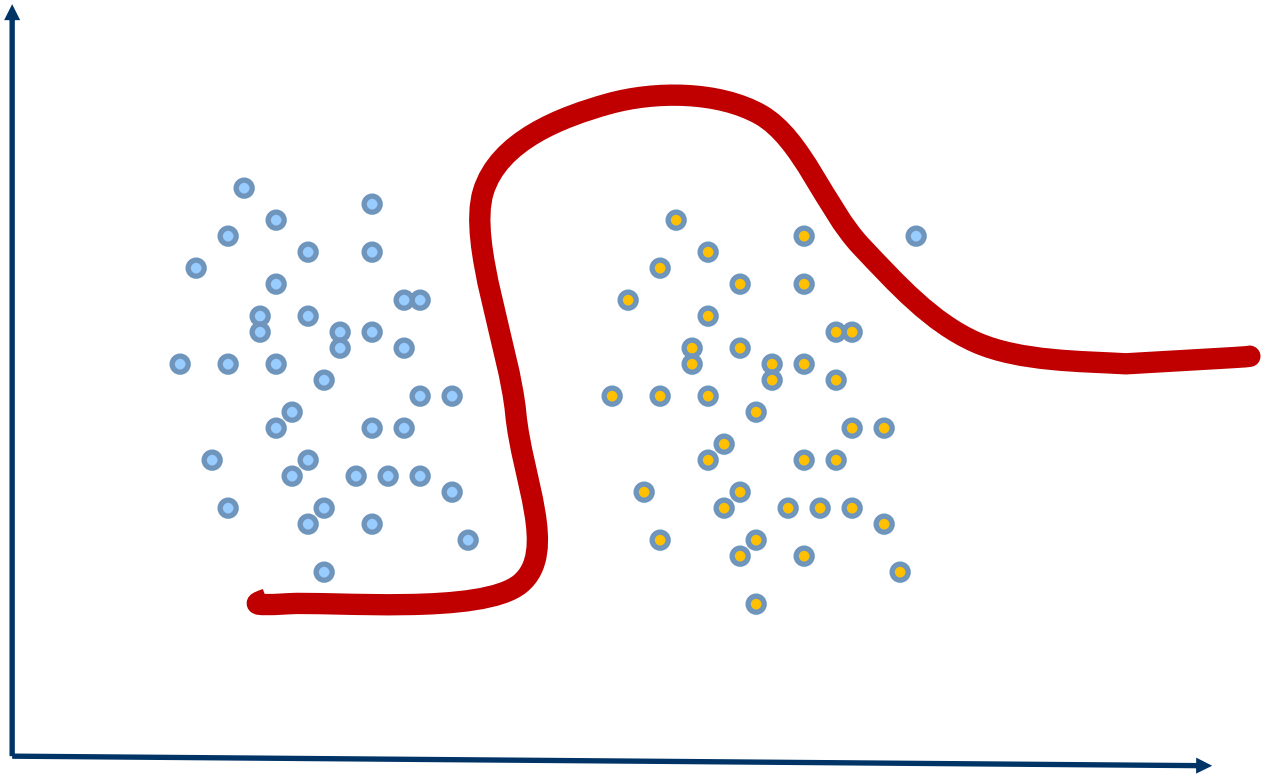
- סטודנט לומד למבחן בקורס -
  - אם הוא יודע לפתור רק את כל המבחנים שניתנו עד כה, ולא מסוגל להתמודד עם בעיה חדשה – overfitting
- בלמידת מחשב –
  - אם המחשב מסוגל לפתור עבור כל הדוגמאות שניתנו עד כה בצורה מושלמת, זה **עדיין לא אומר שהפתרון לבעיה חדשה יהיה איכותי**

מה נעדיף

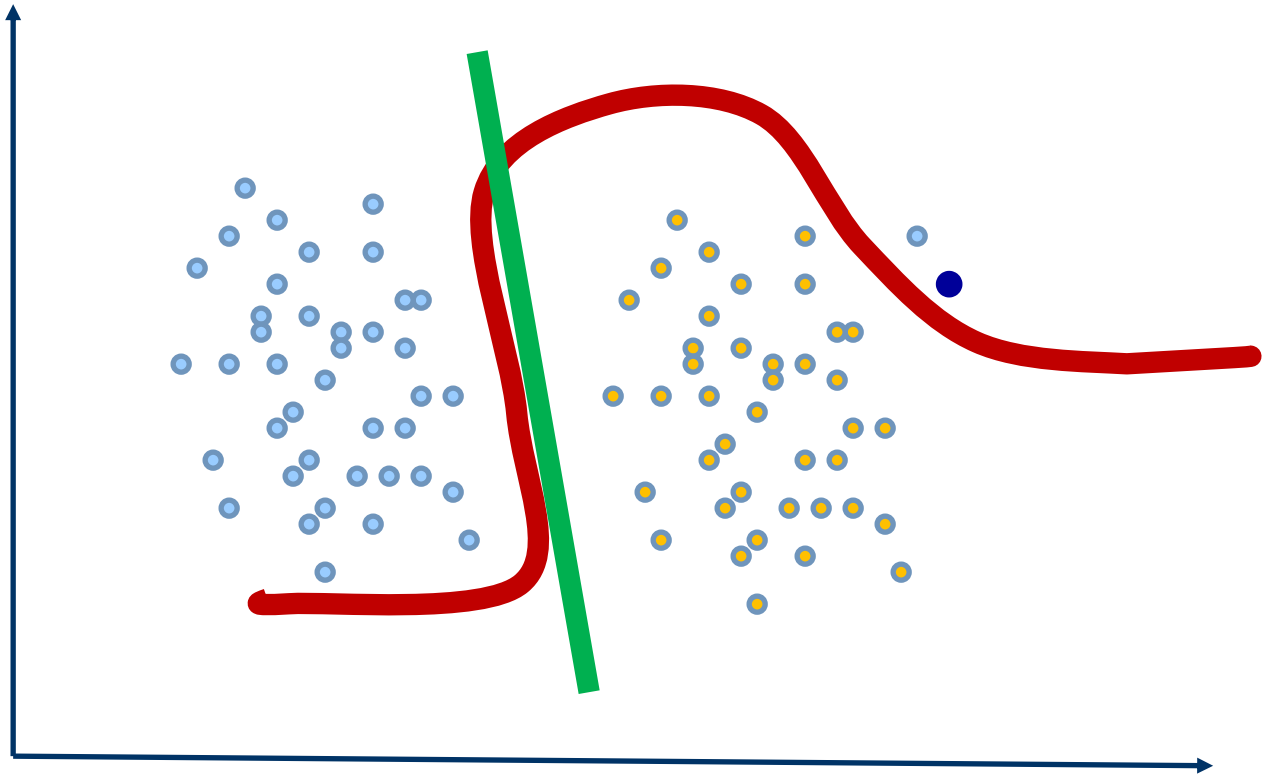
נתונה קבוצת אימון:



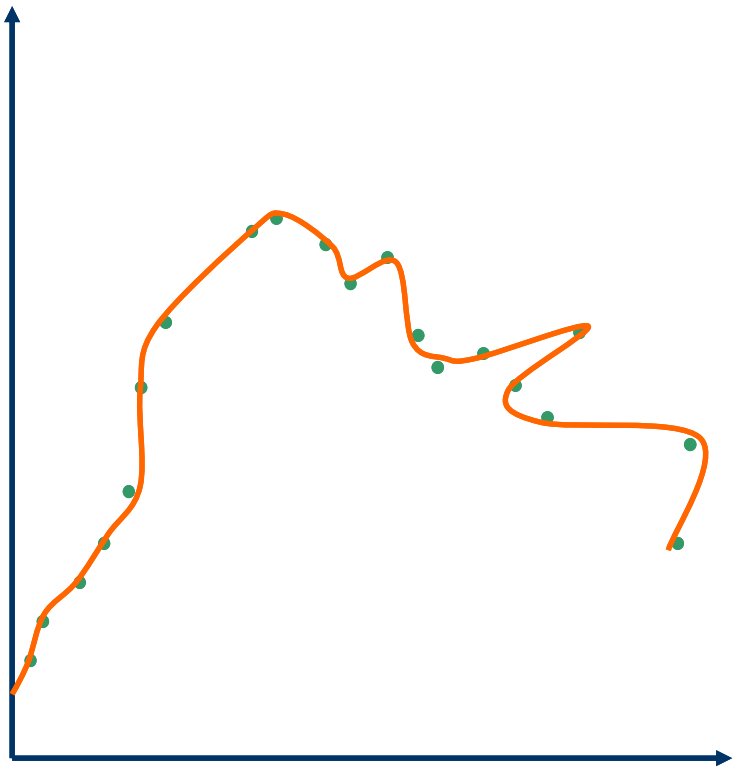
או...

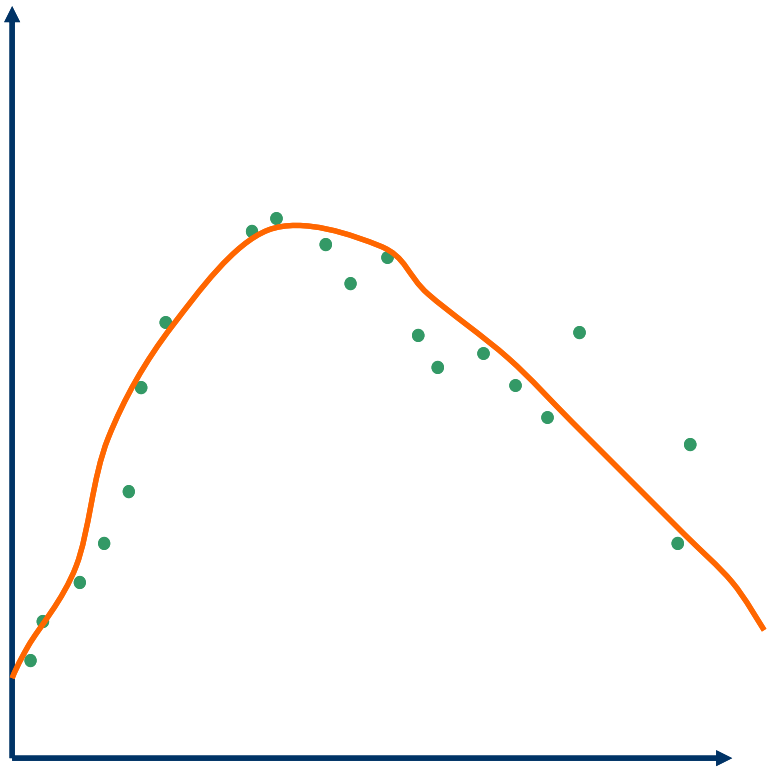


סיווג נקודה חדשה

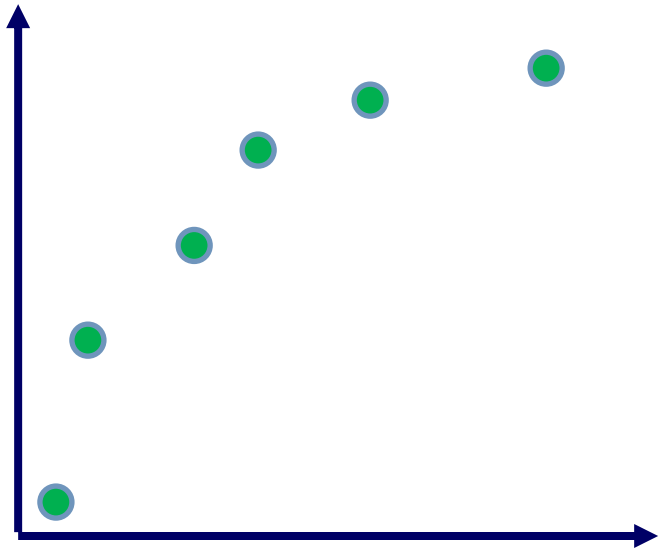


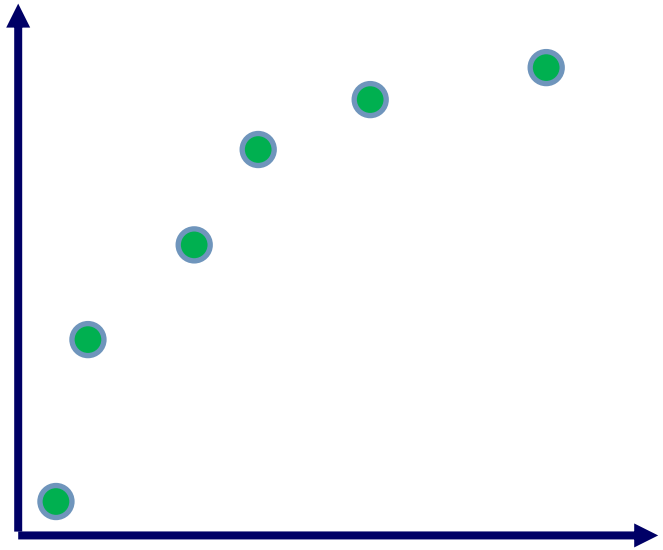
רגרסיה





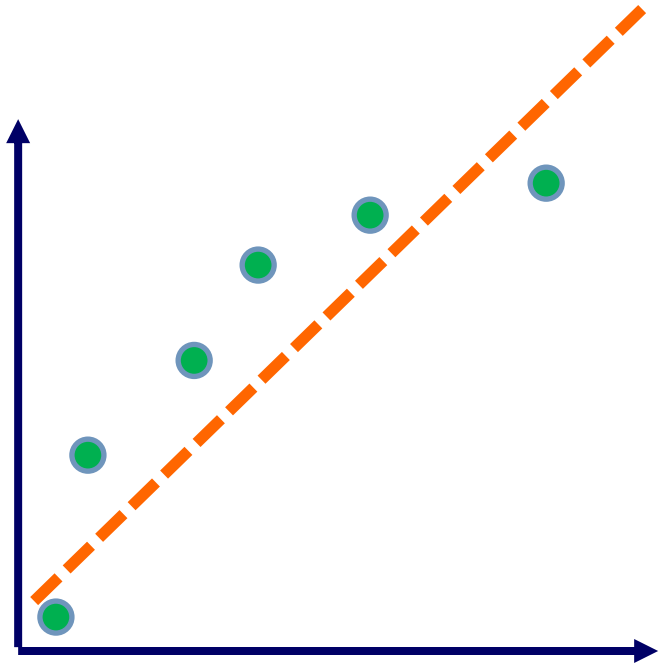
Regression – Overfitting vs. Underfitting



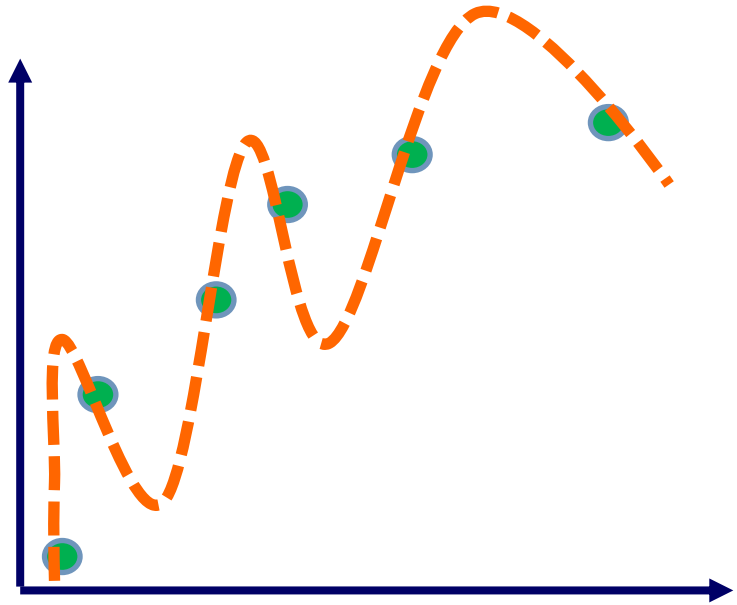


Regression – Overfitting vs. Underfitting

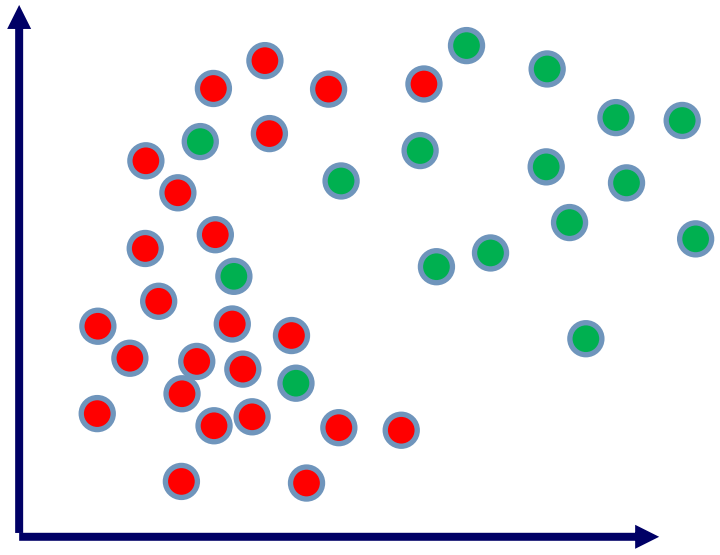
Underfitting

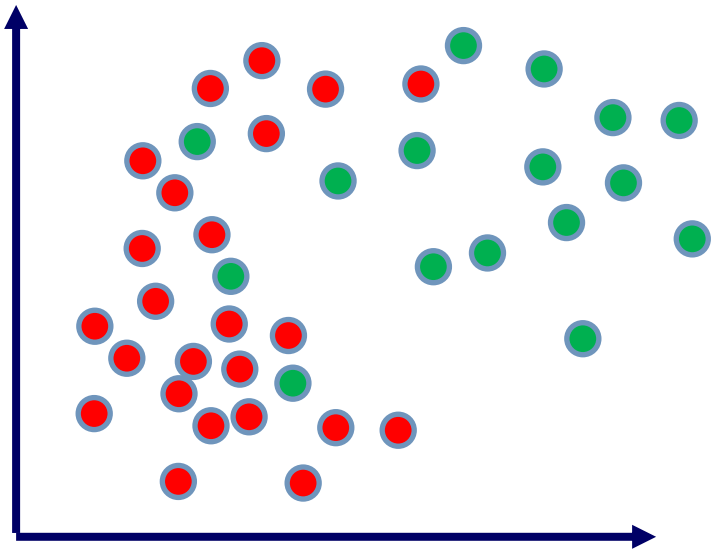


Overfitting



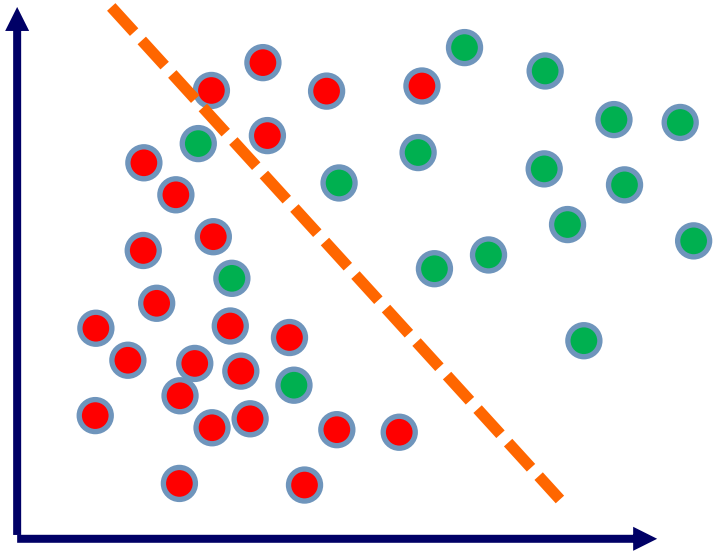
Classification – Overfitting vs. Underfitting



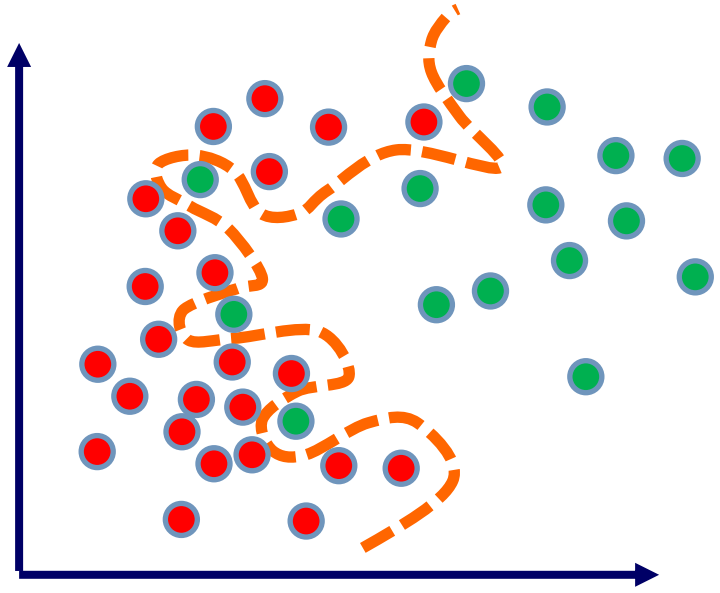


Classification – Overfitting vs. Underfitting

Underfitting



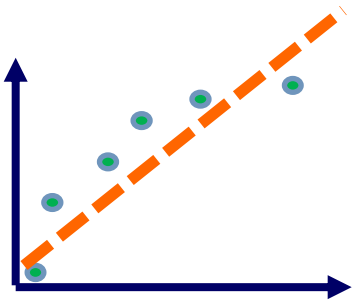
Overfitting



The Bias-Variance dilemma

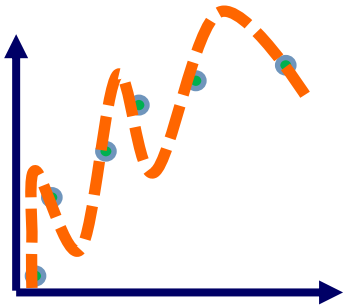
Bias which corresponds to underfitting,

Our model is *biased* in that it assumes that the data will behave in a certain fashion (linear, quadratic, etc.). There is, however, something wrong with the *model* itself in that it's not complex enough to model our data.

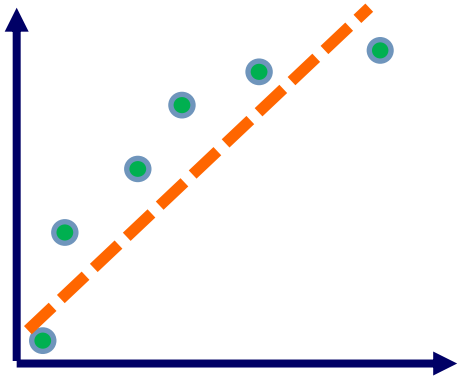


Variance which corresponds to overfitting.

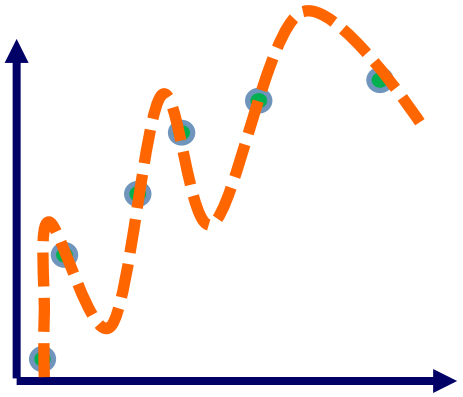
Our model uses a very complex curve to get as close to every data point as possible. Consequently, a model with high variance has very low bias because it makes little to no assumption about the data.



Regression – Overfitting vs. Underfitting



Low complexity
High Bias
Low Variance



High complexity
Low Bias
High Variance

Resolving The Dilemma

- Cross Validation
- Regularization

Hyper Parameters

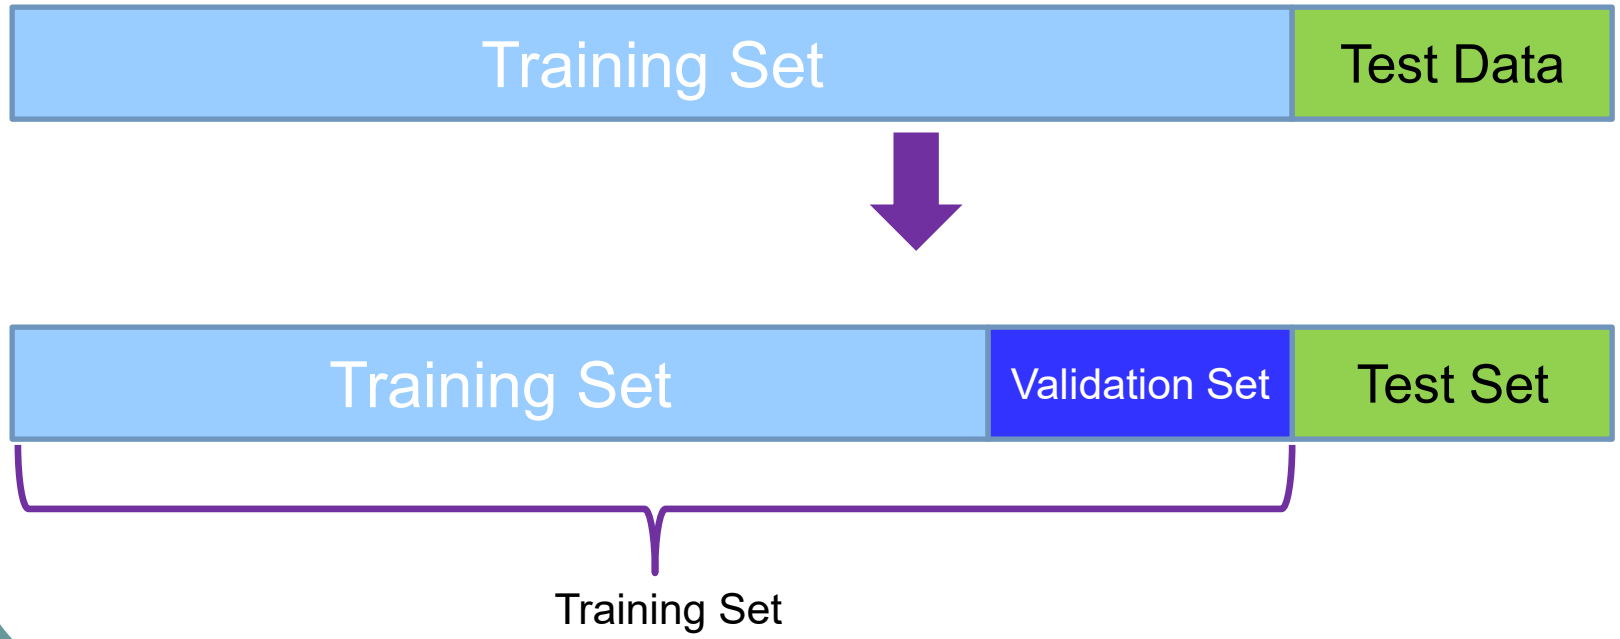
- באלגוריתמים רבים שנלמד יש פרמטרים אותם נרצה "לכוונן" כדי להגיע לביצועים אופטימליים של האלגוריתם. פרמטרים אלו נקראים Hyper-Parameters
- הדרך המוצלחת לכוונן פרמטרים אלו היא לנסות ערכים שונים עד שמגיעים לביצועים גבוהים.
- על איזו קבוצה נבחן ביצועים
  - אימון – נגיע ל-overfitting
  - מבחן – "לא פייר" – אסור לגעת במבחן לפני סיום כל הלמידה

Evaluate on the test set only a single time, at the very end.

אז מה עושים????

Validation set – הפתרון

Split your training set into training set and a validation set. Use validation set to tune all hyperparameters. At the end run a single time on the test set and report performance.



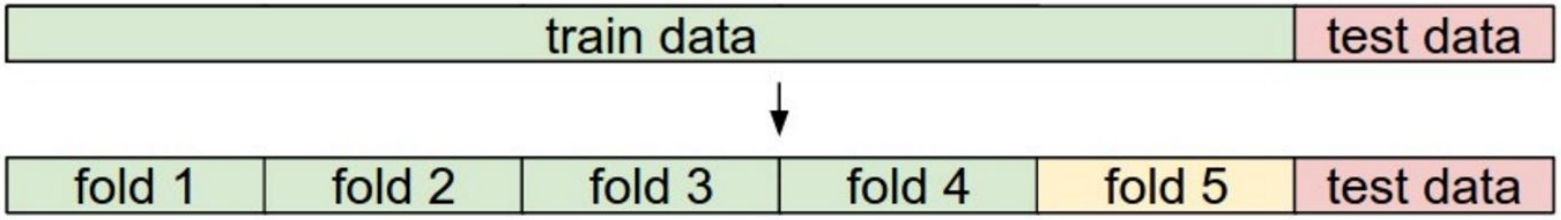
במקרים של מיעוט דוגמאות – Cross Validation

הרעיון:

חלוקה של קבוצת האימון ל-K קבוצות שונות (K fold cross validation)

בכל פעם (K פעמים) נשתמש (k-1) קבוצות לאימון ובקבוצה הנוספת למבחן

נמצע את ה"דיוק" על הקבוצות השונות.

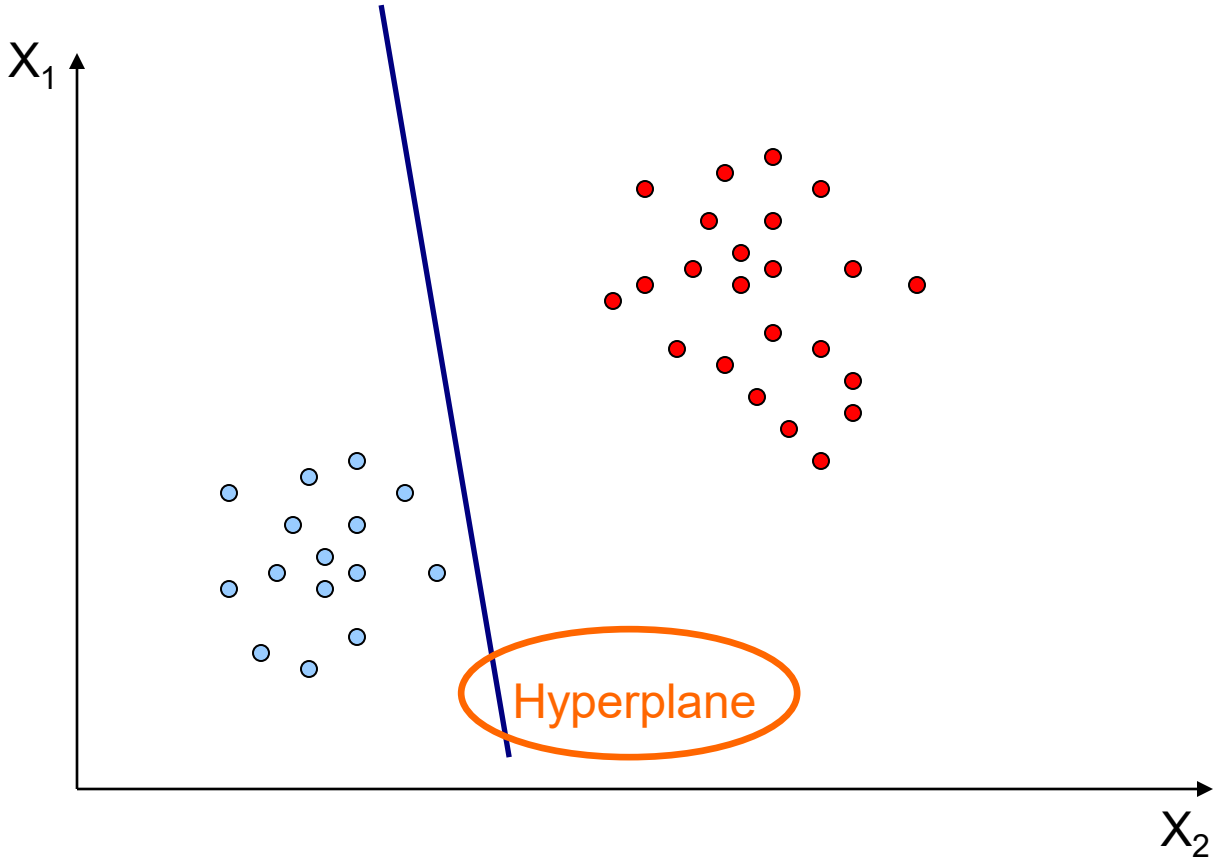


Regularization

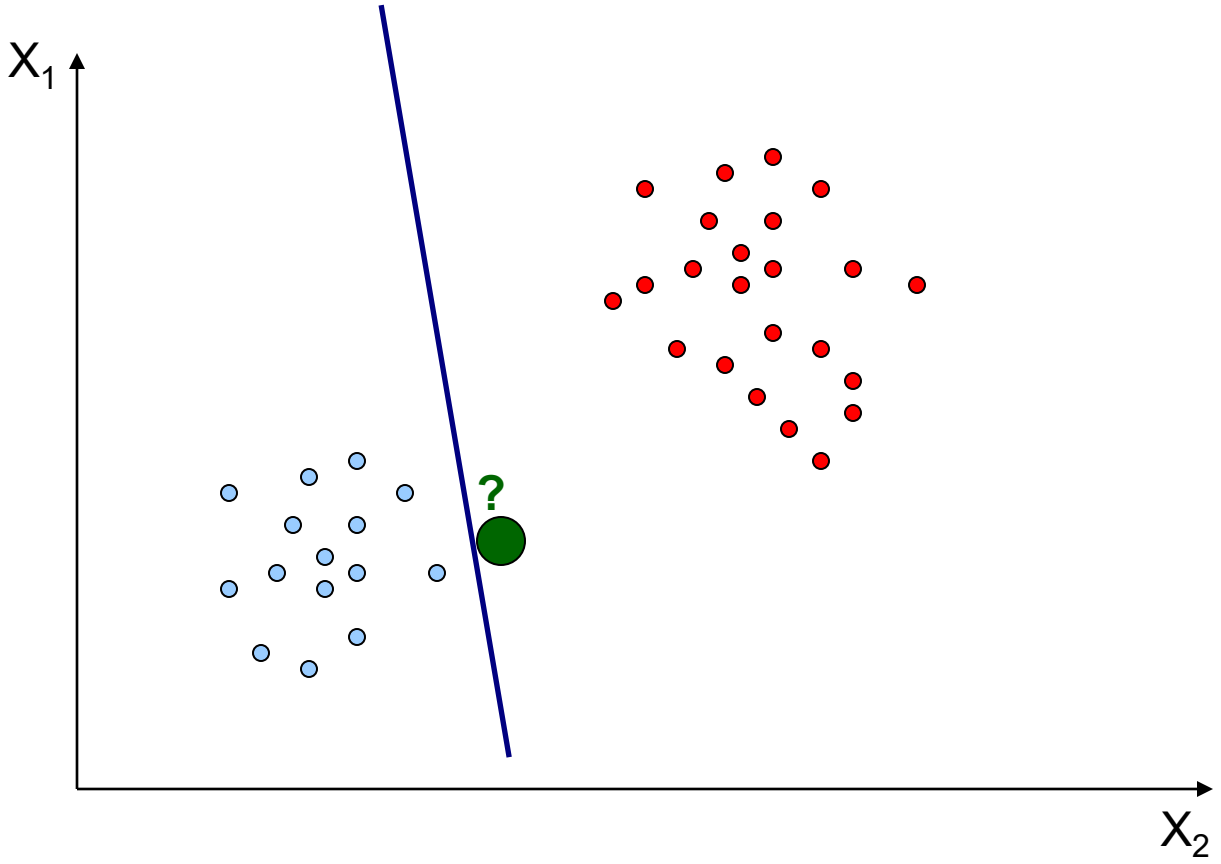
- In addition to rewarding your model as it models the training data well, penalize it for growing too complex.
- Regularization injects “bias” into the model by telling it not to become too complex.

$$\underbrace{\text{Cost (error on training)}}_{} + \underbrace{\text{Cost (complexity)}}_{}$$

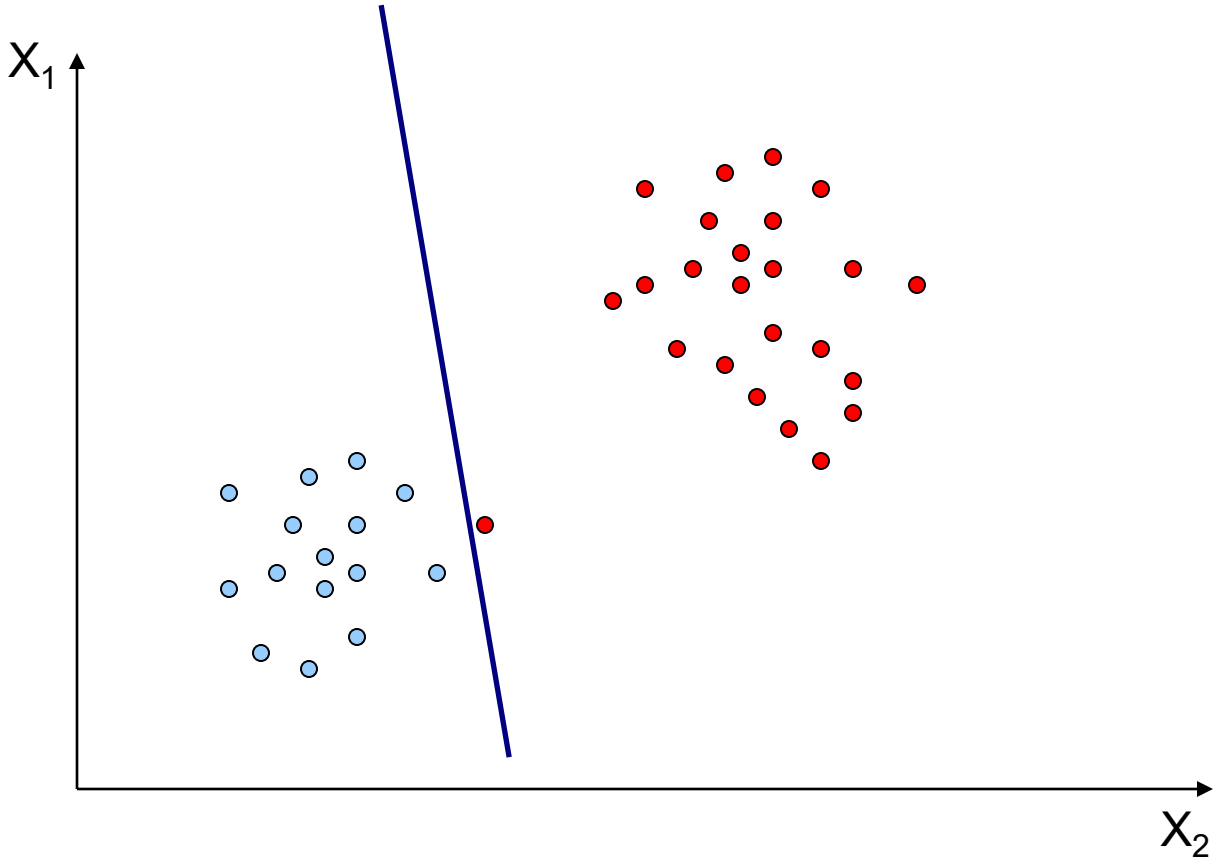
Generalizing vs. overfitting



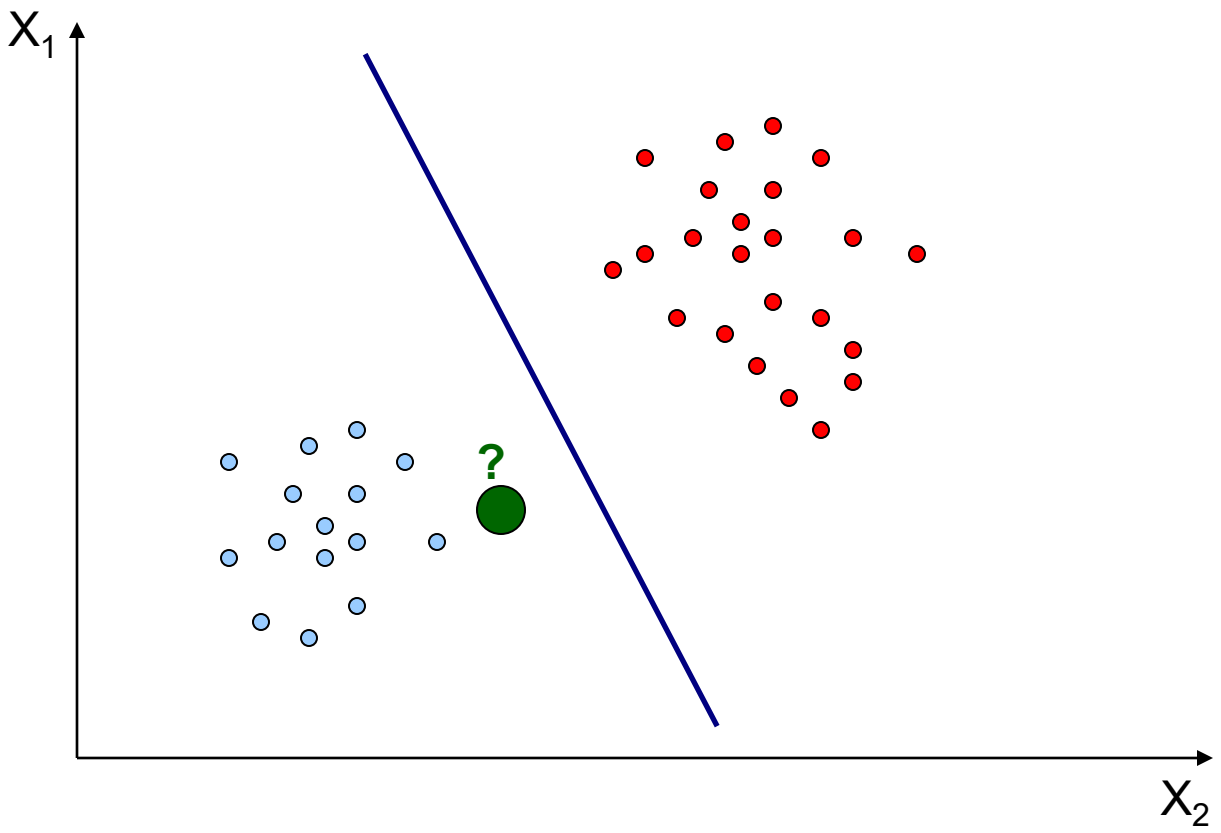
Generalizing vs. overfitting



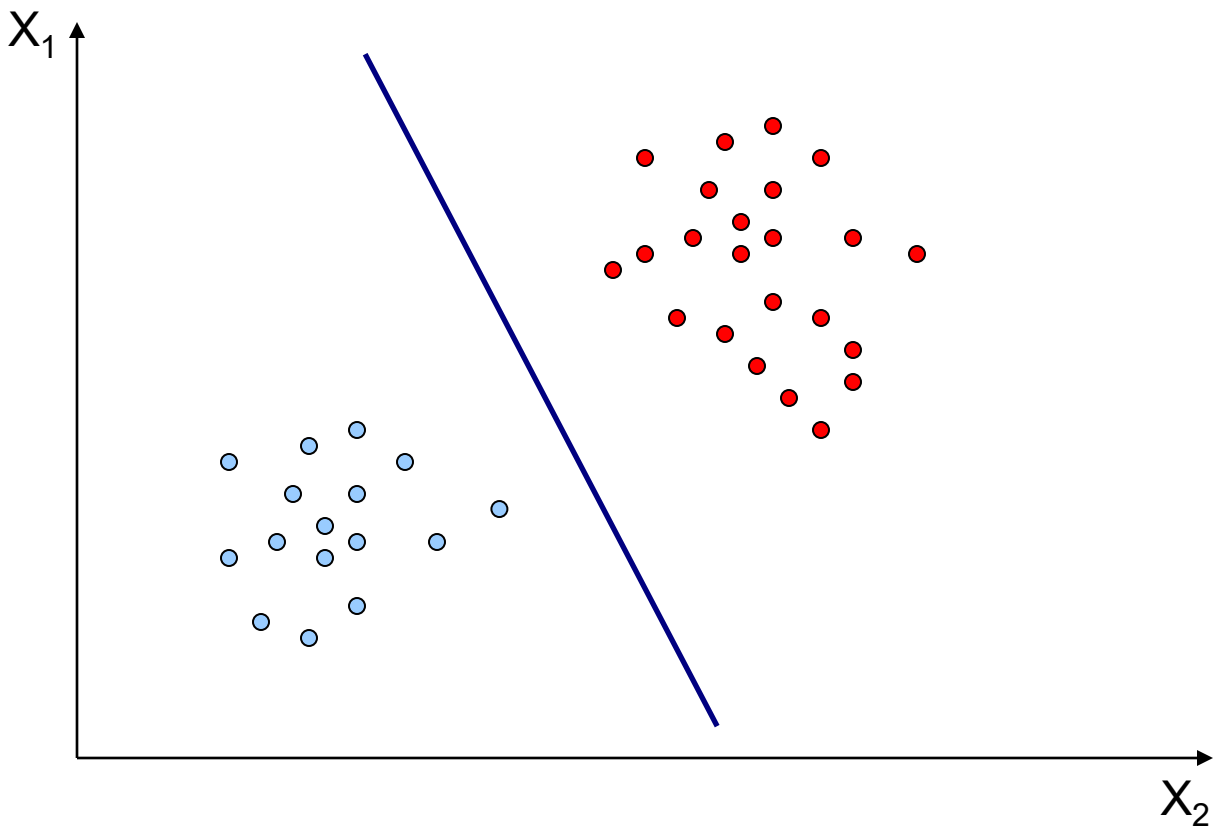
Generalizing vs. overfitting



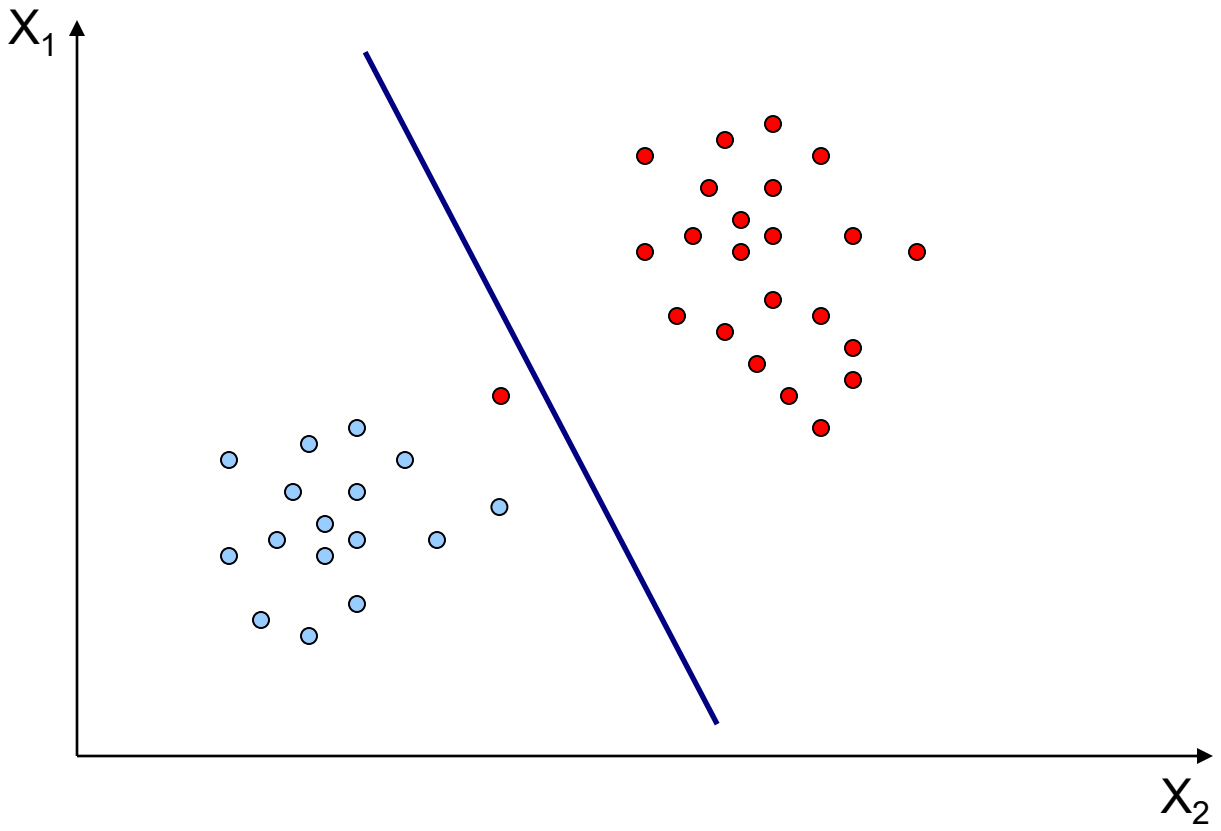
A better classifier…



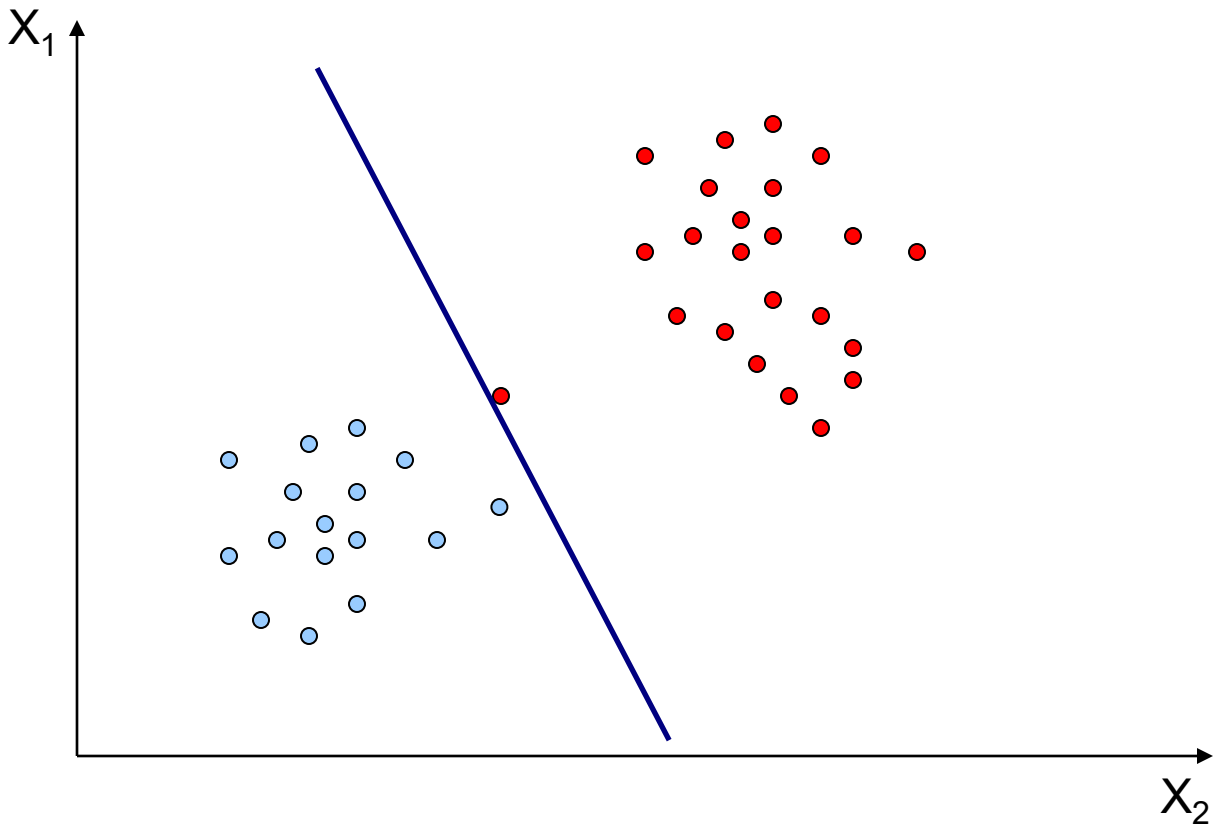
A better classifier…



Penalty



Penalty



Generative vs. discriminative models

Generative model –

Produces a probability density model over all variables in a system to compute classification and regression functions

Discriminative model –

No direct modeling the underlying distribution of the variables and features. Compute the input to output mappings.

Lazy algorithm vs. Eager algorithm

- **Lazy algorithm**
  - Defers data processing until it receives a new unlabelled data to classify it.
- **Eager learning algorithm**
  - Compiles its data into a model. Discards the training data after compilation of the model
- **Tradeoffs**
  - Lazy algorithms have fewer computational costs than eager algorithms during training
  - Lazy algorithms have greater storage requirements and higher computational costs on testing

רכיבי מערכת למידה

- *Input:* ***x*** *("Customer Data")*
- *Output:* *y ("buy/"does not buy")*
- *Target function*: ***x*** →Y (Ideal mapping)
- Data ($\boldsymbol{x}_1$,y_1), ($\boldsymbol{x}_2$,y_2),…. (Historical data)
- Loss function *L*



- Hypothesis: g: ***x*** →Y

מציאת פונקצית המטרה

- 1,3,5,7,9,11 -- **+1**
- 2,4,6,8,10,12 -- **+1**
- 4,2,5,7,8,14 -- **+1**
- 7,5,3,1,2,17 -- **-1**
- 3,5,1,2,8,1 -- **-1**
- 2,4,7,9,11,13 -- **-1**

f(5,3,1,9,11,14) = ???

האם תמיד קיימת פונקצית מטרה

- הטלת מטבע
  - עץ
  - עץ
  - עץ
  - עץ
  - עץ
  - עץ
  - ???

בעיית למידה

Learning problem

- Unknown distribution of inputs and outputs D
- Known loss function L.
  - Usually we will use: loss($y_{predicted}$, y_{actual}) = 1 ($y_{predicted} \neq y_{actual}$) otherwise 0

Hypothesis space H

- Space of functions mapping inputs to outputs

מרחב ההשערות לפתרון בעיית הלמידה

Learning algorithm

Searches in H to find a hypothesis minimizing the expected L on D, based on a Training set of examples.

Known supervised machine learning

- Many algorithms for different problems
  - Support Vector Machines
  - Decision trees
  - Artificial neural networks
  - K-Nearest Neighbor
  - Naïve Bayes classifier
  - GMM – Gaussian Mixture Model

- Theory is when you know everything but nothing work
- Practice is when everything works but no one knows why

- In Machine Learning, theory and practice are combined: nothing works and no one knows why.

מושגים עד כה...

- Training Set / Validation Set / Test Set
- Supervised / Unsupervised ML
- Labels / Classes
- Features
- Classification / Regression
- Overfitting / Generalization
- ML Hypothesis

Supervised Machine learning

- ***Input:*** Given a set of *n* labeled vectors:

$$\{x_i \in R^D, c_i\}, \qquad i = 1 \ldots n$$

  - Each x_i is a feature vector of length *D*
  - c_i is the class label (in the binary case +1,-1)

- ***Output:*** Given a new vector $\{x_i \in R^D\}$, we want to correctly classify it (or at least with a high probability)
  - i.e. finding its class label c_i

Building a ***Classifier***

How to evaluate performance?

False positive (FP)

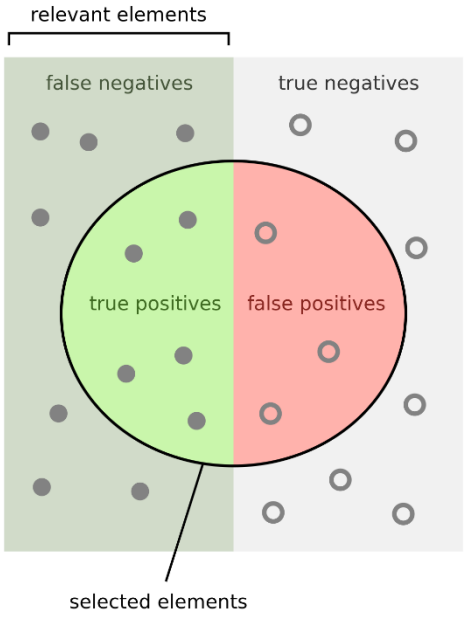
Classifiers output “Positive”. The truth is “Negative”

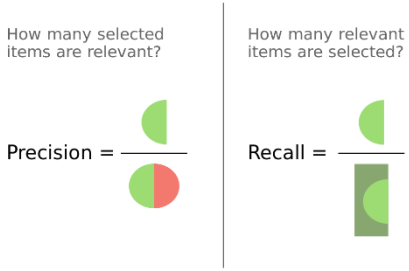
False negative (FN)

Classifiers output “Negatives”. The truth is “Positive”

Detection rate vs. False alarm rate

Recall vs. precision





Confusion Matrix

Prediction

Actual

	pos	neg	Total
p	True Positive	False Negative	P’
n	False Positive	True Negative	N’
Total	P	N	

הערכת ביצועי מערכת

- גילוי טקסטים העוסקים בספורט:
  - נתון אלגוריתם *H* לפתרון הבעיה
  - נתונים 6,000 טקסטים כ"מבחן"
  - 2,200 טקסטים עוסקים בנושא "ספורט" (P)
  - ז"א #N = 3,800
- מתוך P המערכת זיהתה 1900 טקסטים כעוסקים בנושא "ספורט"
- מתוך N המערכת זיהתה 422 טקסטים כעוסקים בנושא "ספורט"

הערכת ביצועי מערכת

Prediction

Actual	pos	neg	Total
p	1900	300	2200
n	422	3378	3800
Total	2322	3678	

%TP = 1900/2200 = 0.863

%FP = 422/3800 = 0.111

מדדים נוספים להערכת ביצועים

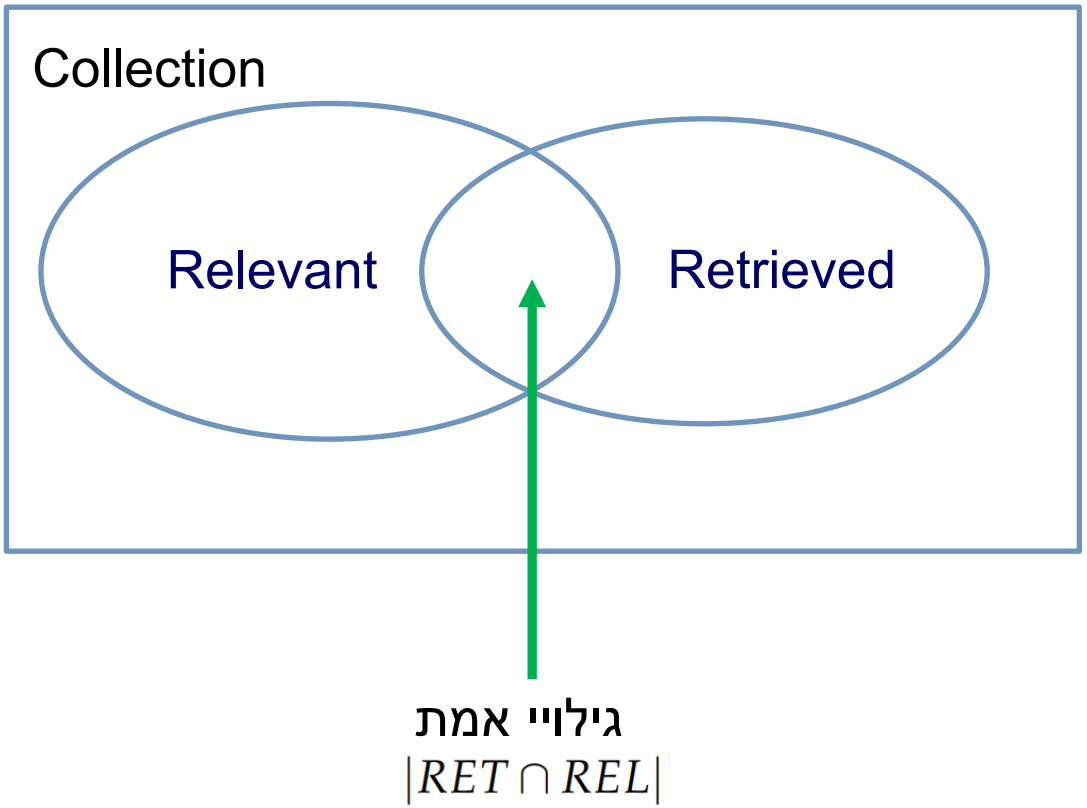
- נניח שברשותינו שתי מערכות לגילוי פנים.
- נבחנו ביצועי שתי המערכות:
  - מערכת א' – גילתה 100% מהפנים שעברו עם התראת שוא אחת בודדת בשעה
  - מערכת ב' - גילתה 100% מהפנים שעברו עם התראת שוא אחת בודדת בשעה

האם ביצועי המערכות שווים

מדדים נוספים להערכת ביצועים

- מערכת א' הופעלה בתנאי indoor במסדרון ללא תנועה כמעט ועבר רק אדם אחד
- מערכת ב' הופעלה בתנאי outdoor עם תנועה עמוסה ועברו 100 אנשים.

מדדים נוספים להערכת ביצועים Precision-Recall



$$\mathcal{R} = \frac{|RET \cap REL|}{|REL|}$$

$$\mathcal{P} = \frac{|RET \cap REL|}{|RET|}$$

מדדים נוספים להערכת ביצועים Precision-Recall

$$\mathrm{Precision} = \frac{\#TruePositives}{\#TruePositives + \#FalsePositives}$$

$$\mathrm{Precision}_A = \frac{1}{1+1} = \frac{1}{2}$$

$$\mathrm{Precision}_B = \frac{100}{100+1} = 0.99$$

Confusion Matrix - MultiClass

		Predicted			
		Class A	Class B	Class C	Total
Actual	Class A	**21**	7	3	31
	Class B	10	**15**	5	30
	Class C	0	3	**29**	32
	Total	31	25	37	93

דוגמא:

מחלקה A מופיעה בקבוצת האימון 31 מופעים.

21 מהמופעים מתגלים ע"י המערכת כמחלקה A.

7 מופעים נוספים של מחלקה A מתגלים כמחלקה B

3 מופעים נוספים של מחלקה A מתגלים כמחלקה C

10 מופעים של מחלקה B מתגלים ע"י המערכת כמחלקה A

Overall Accuracy = (21+15+29)/93 = 0.7

אפשר לראות שהמערכת נוטה "להתבלבל" בין מחלקה A לבין מחלקה B

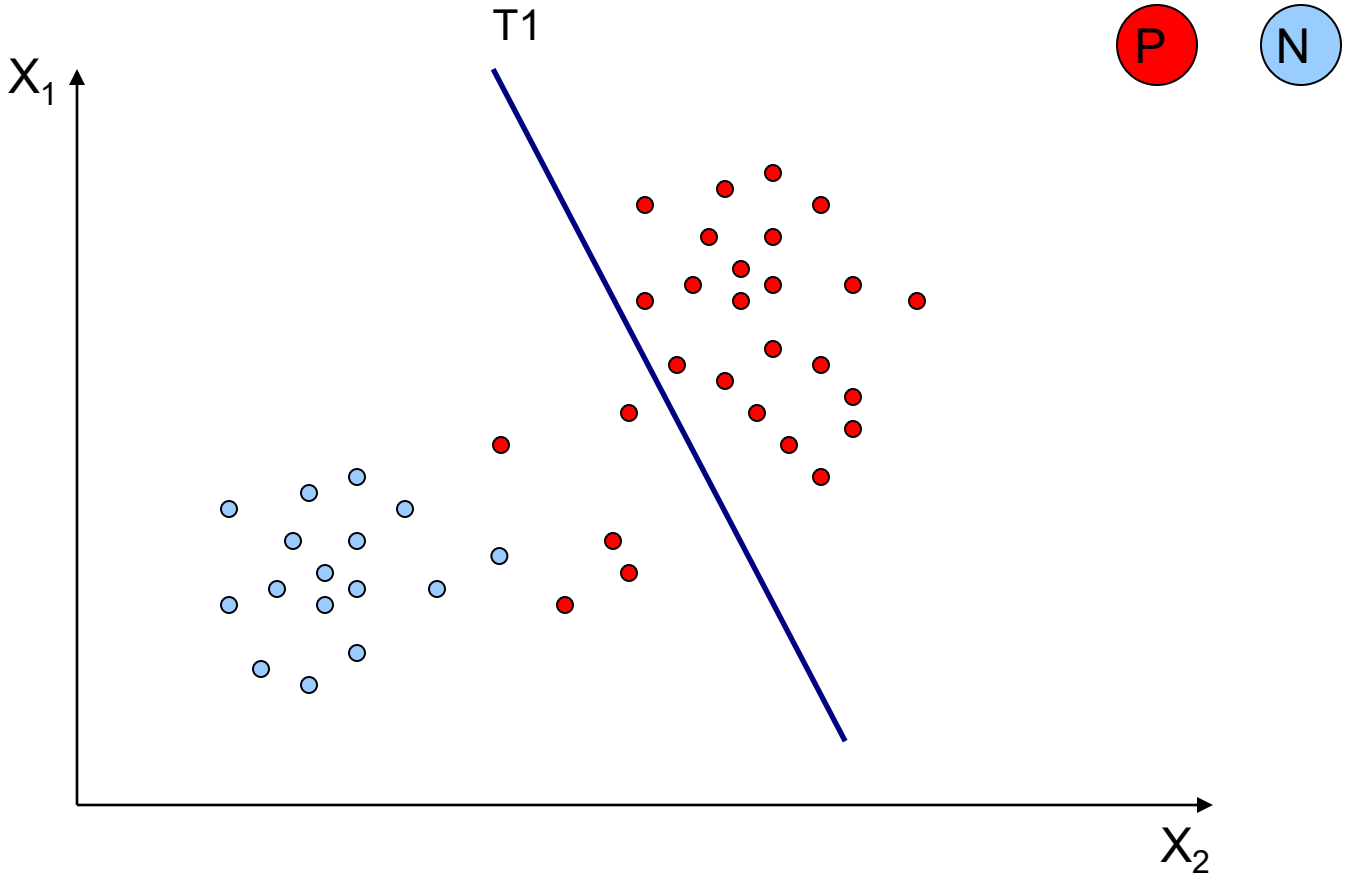
בחזרה לשאלת טקסטים העוסקים בספורט

- ונניח שמערכת אחרת פתרה את הבעיה:
  - מתוך P המערכת זיהתה 1650 טקסטים כעוסקים בנושא "ספורט"
  - מתוך N המערכת זיהתה 125 טקסטים כעוסקים בנושא "ספורט"

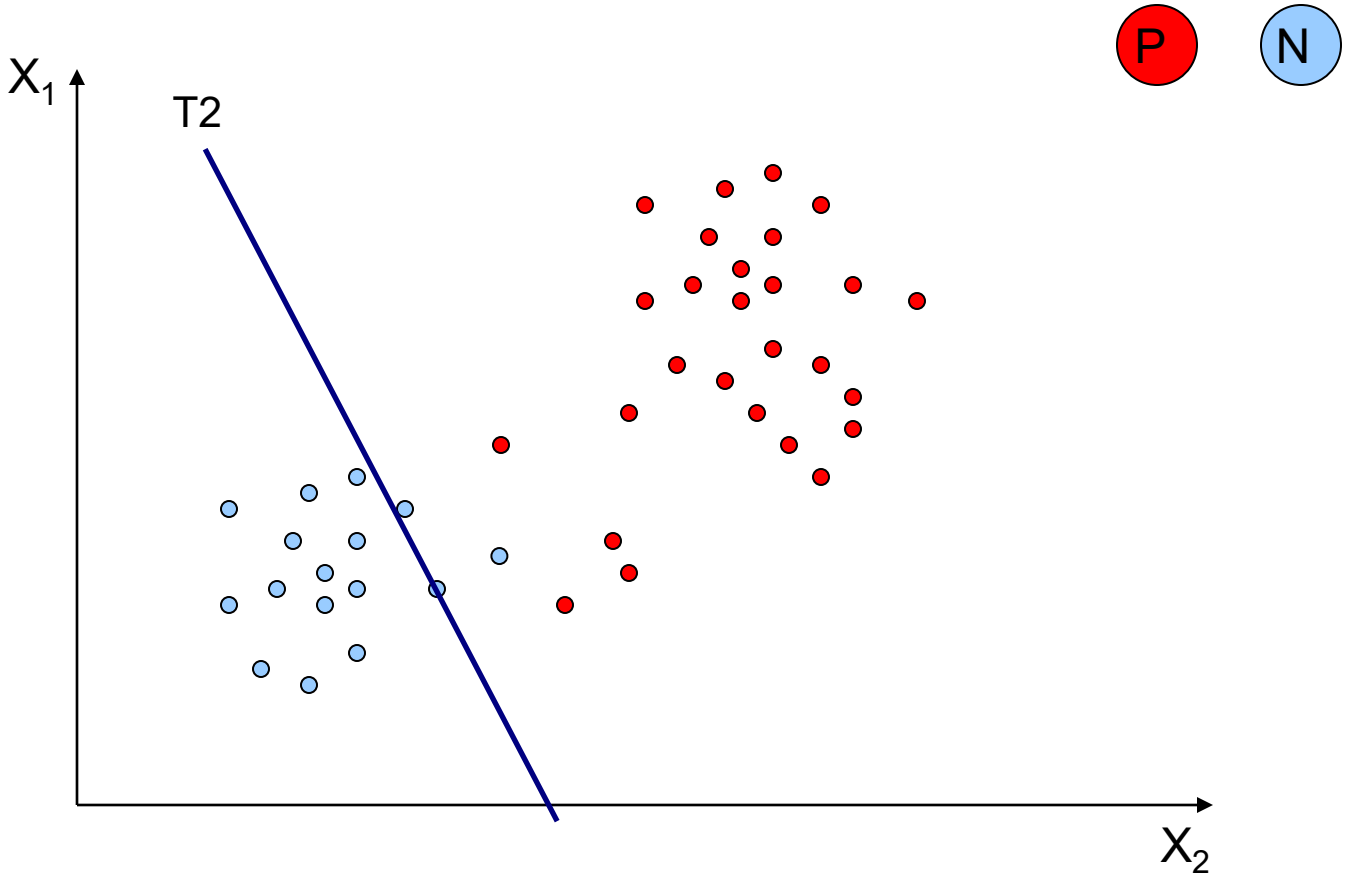
%TP = 1650/2200 = 0.75

%FP = 125/3800 = 0.032

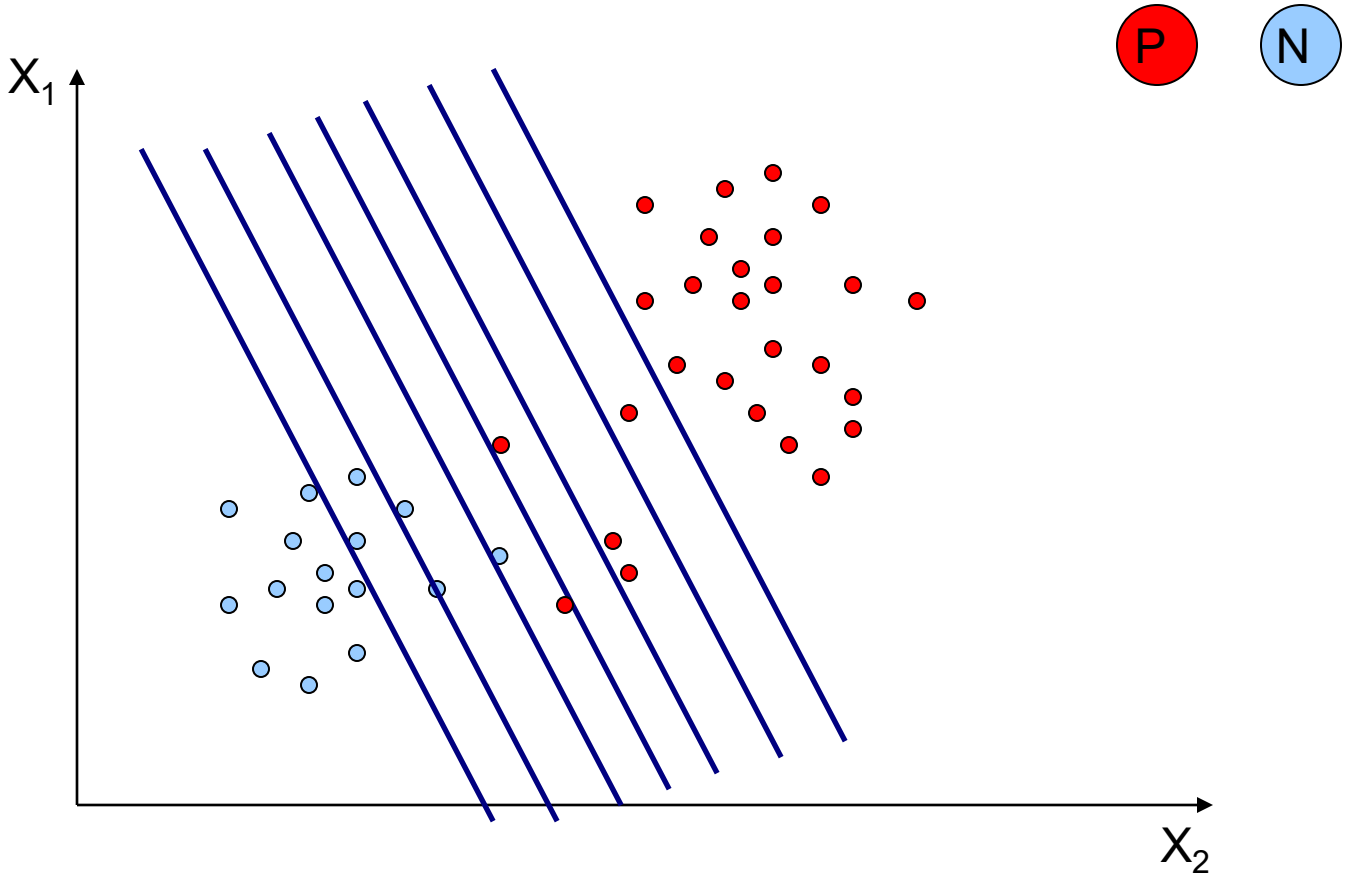
CLASSIFIER THRESHOLD



CLASSIFIER THRESHOLD



CLASSIFIER THRESHOLD

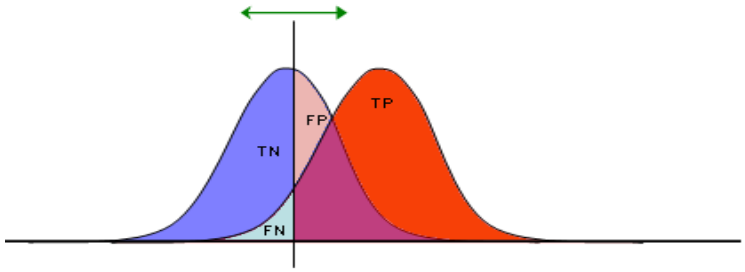


Why to use a graphic representation?

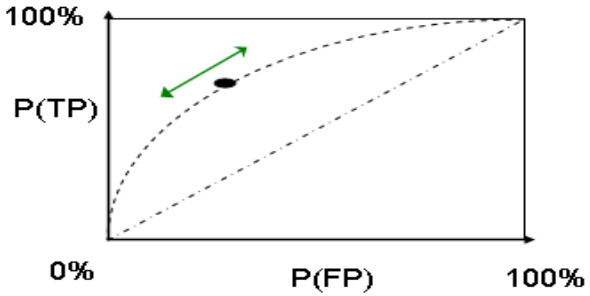
- Which one is better?

%TP = 0.86, %FP = 0.11

%TP = 0.75, %FP = 0.03



TP	FP
FN	TN
1	1



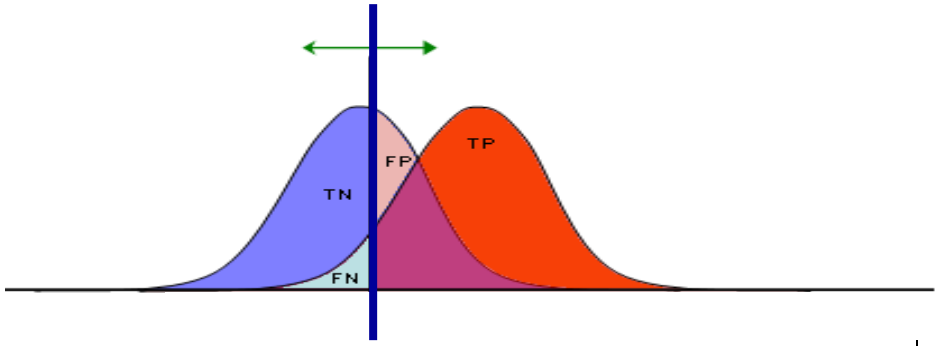
predicted → / real ↓	*Class_pos*	*Class_neg*
Class_pos	TP	FN
Class_neg	FP	TN

$$\text{TPR (sensitivity)} = \frac{TP}{TP + FN}$$

$$\text{FPR (1-specificity)} = \frac{FP}{TN + FP}$$

From wiki

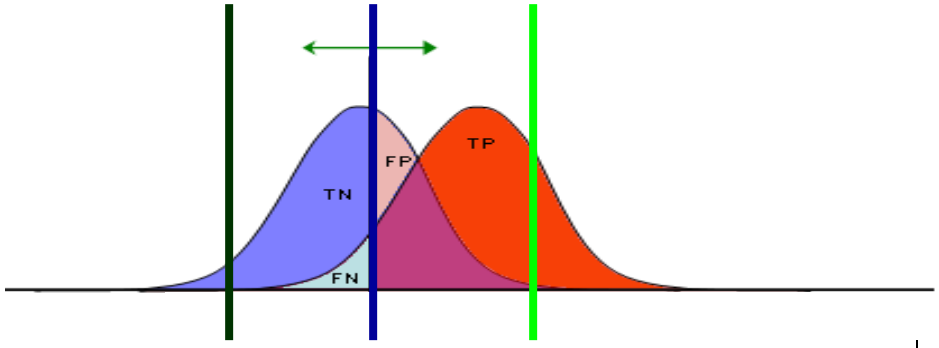
Why to use a graphic representation?



True Positive Rate

False Positive Rate

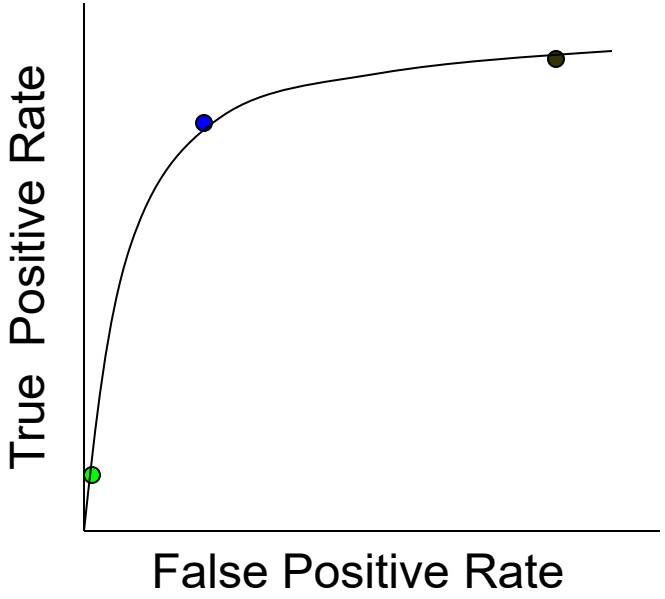
ROC curve



predicted → real ↓	*Class_pos*	*Class_neg*
Class_pos	TP	FN
Class_neg	FP	TN

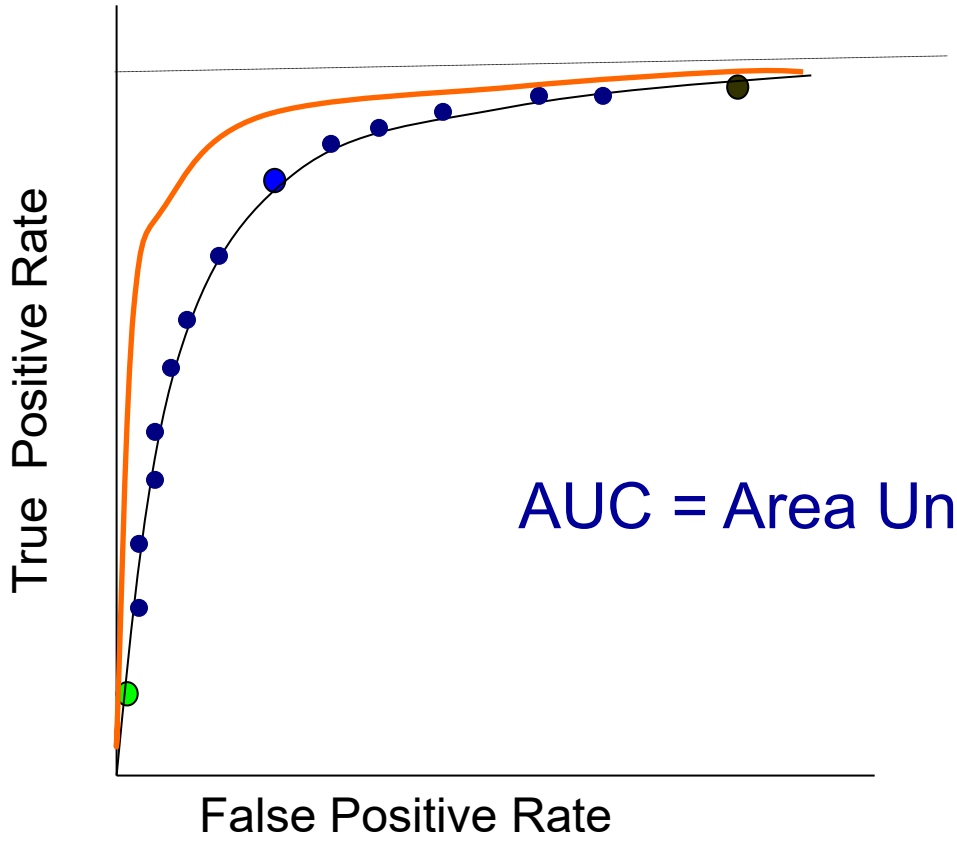
$$\text{TPR (sensitivity)} = \frac{TP}{TP + FN}$$

$$\text{FPR (1-specificity)} = \frac{FP}{TN + FP}$$



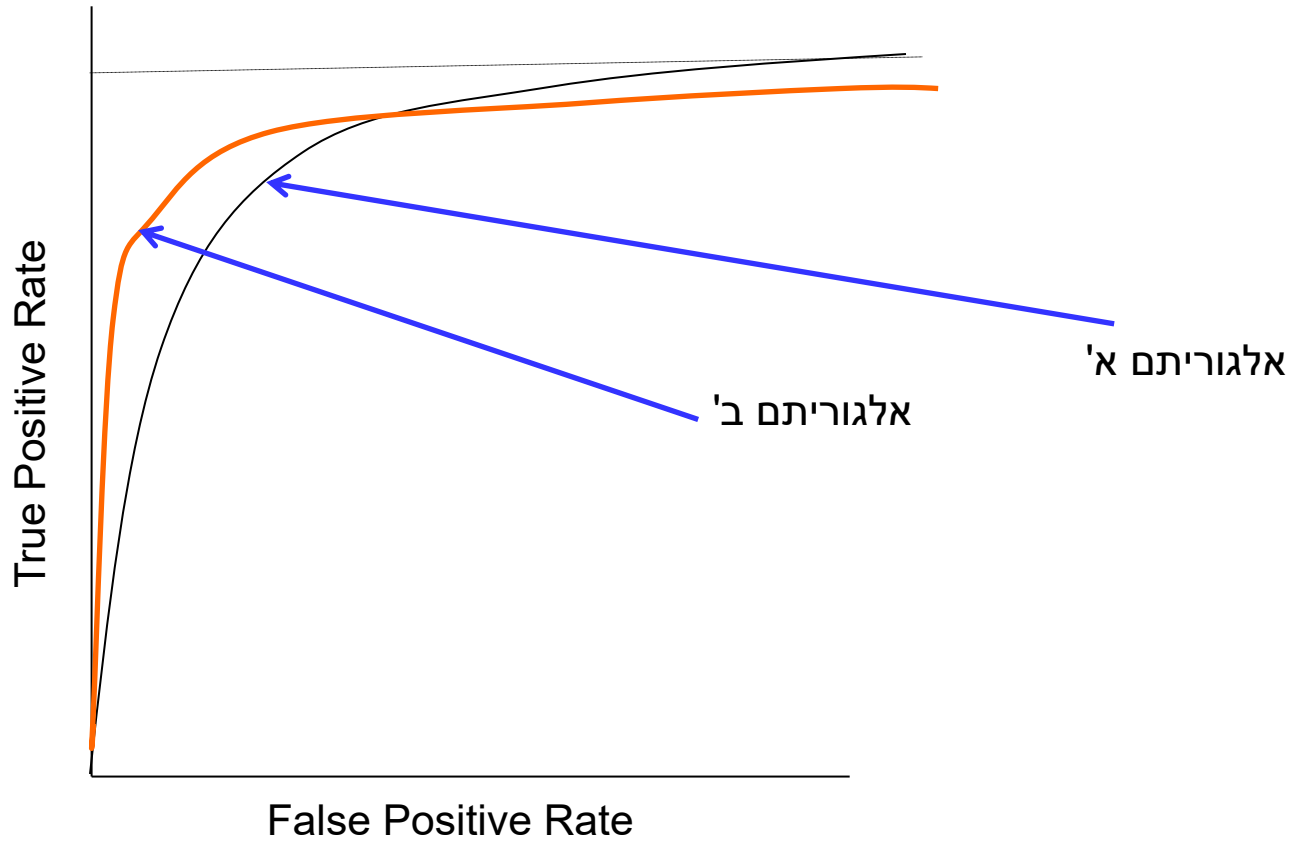
Comparing ROC curves

ROC = Receiver Operating Characteristic



AUC = Area Under Curve

איזה גרף טוב יותר?

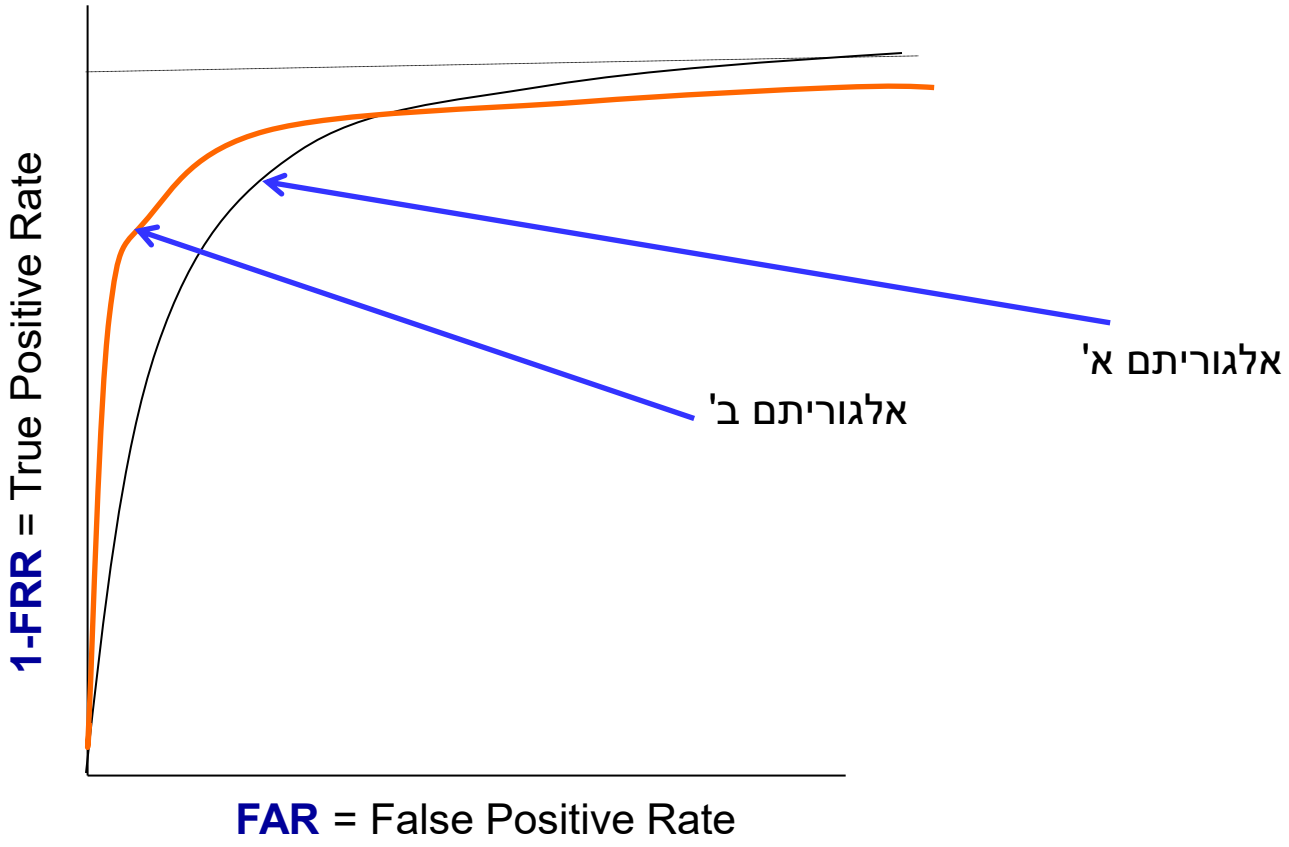


ומדדים רבים נוספים

- False Accept Rate (FAR) - measures the percent of invalid inputs which are incorrectly accepted.
- False Rejection Rate (FRR) - It measures the percent of valid inputs which are incorrectly rejected.
- Equal Error Rate (EER) - the rate at which both accept and reject errors are equal.

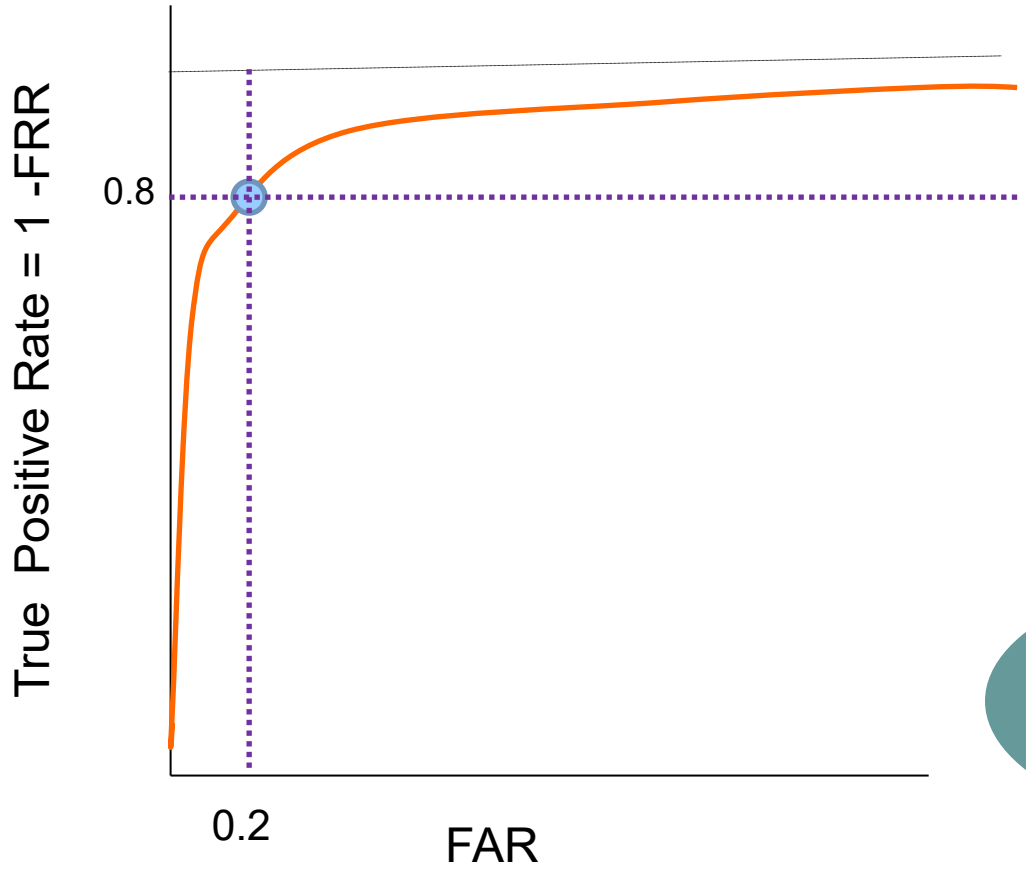
- The system with the lower EER is most accurate.

איזה גרף טוב יותר?



Comparing ROC curves

ROC = Receiver Operating Characteristic



האידיאלי
מבחינתנו:

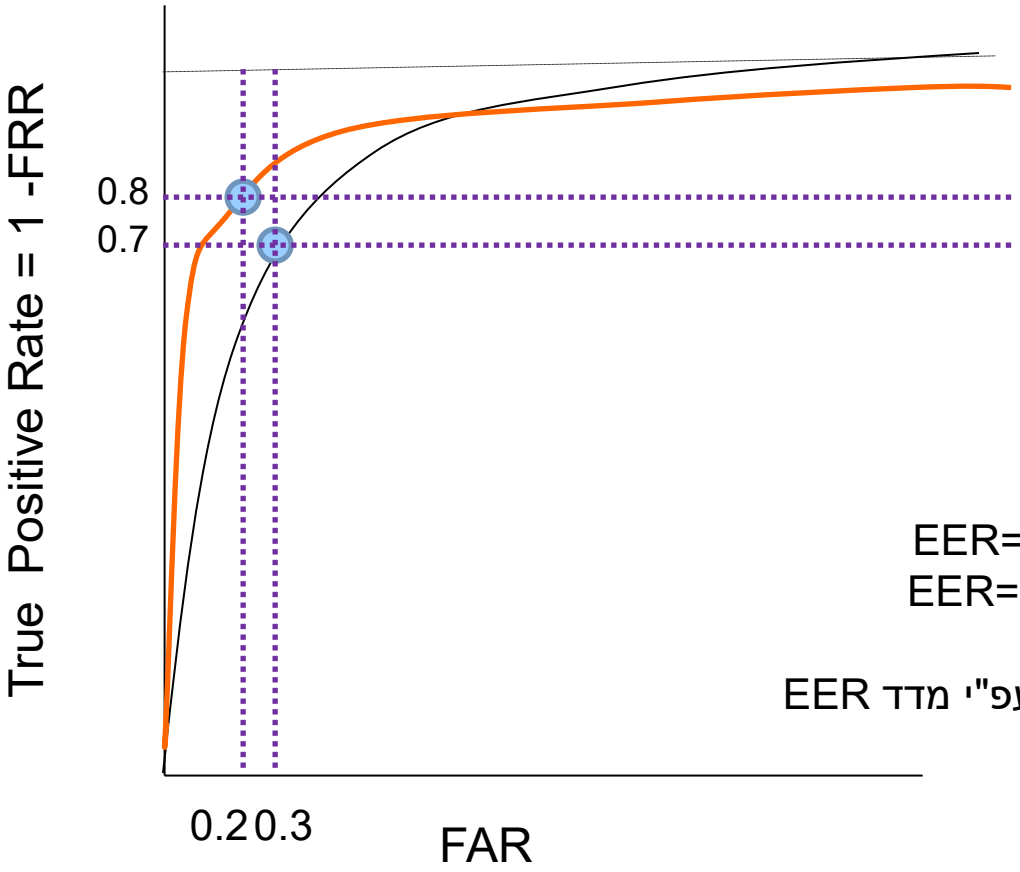
EER = 0

ה-EER היא
נקודת ה"ברך"

**מה מעניין
בנקודת ה"ברך"**

Comparing ROC curves

ROC = Receiver Operating Characteristic



אלגוריתם א' – EER=0.3
אלגוריתם ב' – EER=0.2

לכן אלגוריתם ב' טוב יותר עפ"י מדד EER