תרגול:

Decision Trees, KNN, Naïve Bayes

תרגיל

- קיבלנו את קבוצת האימון הבאה המייצגת 5 תצפיות של "כלב" ו-5 תצפיות של "חתול". אנו רוצים לייצר מסווג כך שבהינתן תצפית חדשה נדע לסווג אותה כ"כלב" או כ"חתול"
- נייצג כלב כ-P וחתול כ-N
- כל תצפית מיוצגת לנו ע"י ווקטור באורך 4
  - X1 – יכול לקבל אחד מהערכים {0,1}
  - X2 – יכול לקבל אחד מהערכים {0,1,2}
  - X3 – יכול לקבל אחד מהערכים {0,1,2}
  - X4 – יכול לקבל אחד מהערכים {0,1}

קבוצת האימון

תצפית #	x1	x2	x3	x4	סיווג
1	0	0	1	1	*P*
2	1	0	1	1	*P*
3	1	2	2	1	*P*
4	0	1	1	1	*P*
5	0	2	0	0	*P*
6	1	0	2	0	*N*
7	0	0	2	0	*N*
8	0	1	2	1	*N*
9	1	0	1	0	*N*
10	1	1	2	1	*N*

נשמור לנו 40% מהקבוצה כ"מבחן" ונלמד על ה-60% הנותרים

תצפית #	x1	x2	x3	x4	סיווג
1	0	0	1	1	*P*
2	1	0	1	1	*P*
3	1	2	2	1	*P*
4	0	1	1	1	*P*
5	0	2	0	0	*P*
6	1	0	2	0	*N*
7	0	0	2	0	*N*
8	0	1	2	1	*N*
9	1	0	1	0	*N*
10	1	1	2	1	*N*

כעת קבוצת האימון שלנו מורכבת

תצפית #	x1	x2	x3	x4	סיווג
1	0	0	1	1	*P*
2	1	0	1	1	*P*
3	1	2	2	1	*P*
6	1	0	2	0	*N*
7	0	0	2	0	*N*
8	0	1	2	1	*N*

אנתרופיה

Shannon entropy is the average self-information (expected value) over all possible values of X

$$H(X) = E_{x\sim P}[I(x)] = \sum_{i=1}^{n} p(x_i)\, I(x_i) = -\sum_{i=1}^{n} p(x_i)\, log_b(p(x_i)),$$

High vs. Low Entropy

- "High Entropy"
  - A uniform-like distribution
  - קשה לחזות
- "Low Entropy"
  - A varied (peaks and valleys) distribution
  - יותר קל לחזות

אנתרופיה מותנית

Y "קונה מחשב"	X "גיל"
"כן"	צעיר
"כן"	צעיר
"כן"	בינוני
"לא"	צעיר
"כן"	בינוני
"לא"	זקן
"לא"	צעיר
"לא"	זקן

האנתרופיה מותנית H(Y|X) הינה ממוצע משוקלל של האנתרופיות ה"ספציפיות" של Y

$$H(Y \mid X) = \sum_j P(X = \alpha_j) H(Y \mid X = \alpha_j)$$

H(Y|X=צעיר) = 1 P(X=צעיר) = 0.5

H(Y|X=בינוני) = 0 P(X=בינוני) = 0.25

H(Y|X=זקן) = 0 P(X=זקן) = 0.25

H(Y|X) = 0.5 x 1 + 0.25 x 0 + 0.25 x 0 = 0.5

Information Gain

- Gain(Y|X) הינה ההפחתה הצפויה באנתרופיה של Y בגלל מיון עפ"י תכונה X

$$Gain(Y \mid X) = H(Y) - H(Y \mid X)$$

צריך לשלוח מסר Y. כמה ביטים יחסכו בממוצע אם שני הצדדים בתקשורת יודעים את X

נתחיל עם בניית "עץ החלטה"

- אנו צריכים למצוא את התכונה שה-infogain שלה הוא הגבוה ביותר, כלומר התכונה האינפורמטיבית ביותר.
- Y – הסיווג. H – אנתרופיה, IG – InfoGain

$$IG(Y \mid x_i) = H(Y) - H(Y \mid x_i) \qquad \forall x_i$$

$$H(Y) = -p(P) \times \log_2 p(P) - p(N) \times \log_2 p(N)$$

$$p(P) = \frac{1}{2}, p(N) = \frac{1}{2}$$

$$\log_2(\frac{1}{2}) = -1$$

$$H(Y) = -\frac{1}{2} \times -1 - \frac{1}{2} \times -1 = 1$$

תצפית #	x1	x2	x3	x4	סיווג
1	0	0	1	1	*P*
2	1	0	1	1	*P*
3	1	2	2	1	*P*
6	1	0	2	0	*N*
7	0	0	2	0	*N*
8	0	1	2	1	*N*

נחשב את ה-infogain של x1

$$IG(Y \mid x_1) = H(Y) - H(Y \mid x_1)$$

$$H(Y \mid x_1) = p(x_1 = 0) \times H(Y \mid x_1 = 0) + p(x_1 = 1) \times H(Y \mid x_1 = 1)$$

$$p(x_1 = 0) = \frac{1}{2}, p(x_1 = 1) = \frac{1}{2}$$

$$H(Y \mid x_1 = 0) = -\frac{1}{3}\log_2\frac{1}{3} - \frac{2}{3}\log_2\frac{2}{3} = -\frac{1}{3} \times -1.584 - \frac{2}{3} \times -0.584 = 0.918$$

$$H(Y \mid x_1 = 1) - \frac{1}{3}\log_2\frac{1}{3} - \frac{2}{3}\log_2\frac{2}{3} = -\frac{1}{3} \times -1.584 - \frac{2}{3} \times -0.584 = 0.918$$

$$H(Y \mid x_1) = \frac{1}{2} \times 0.918 + \frac{1}{2} \times 0.918 = 0.918$$

$$IG(Y \mid x_1) = H(Y) - H(Y \mid x_1) = 1 - 0.918 = 0.082$$

נחשב את ה-infogain של x2

$$IG(Y \mid x_2) = H(Y) - H(Y \mid x_2)$$

$$H(Y \mid x_2) = p(x_2 = 0) \times H(Y \mid x_2 = 0) + p(x_2 = 1) \times H(Y \mid x_2 = 1) + p(x_2 = 2) \times H(Y \mid x_2 = 2)$$

$$p(x_2 = 0) = \frac{2}{3}, p(x_2 = 1) = \frac{1}{6}, p(x_2 = 2) = \frac{1}{6}$$

$$H(Y \mid x_2 = 0) = 1, \quad H(Y \mid x_2 = 1) = 0, \quad H(Y \mid x_2 = 2) = 0$$

$$H(Y \mid x_2) = 1 \times \frac{2}{3} + 0 \times \ldots + 0 \times \ldots = \frac{2}{3}$$

$$IG(Y \mid x_2) = H(Y) - H(Y \mid x_2) = 1 - \frac{2}{3} = \frac{1}{3}$$

נחשב את ה-infogain של x3

$$IG(Y \mid x_3) = H(Y) - H(Y \mid x_3)$$

$$H(Y \mid x_3) = p(x_3 = 0) \times H(Y \mid x_3 = 0) + p(x_3 = 1) \times H(Y \mid x_3 = 1) + p(x_3 = 2) \times H(Y \mid x_3 = 2)$$

$$p(x_3 = 0) = 0, p(x_3 = 1) = \frac{1}{3}, p(x_3 = 2) = \frac{2}{3}$$

$$H(Y \mid x_3 = 0) = .., \quad H(Y \mid x_3 = 1) = 0,$$

$$H(Y \mid x_3 = 2) = -\frac{1}{4}\log_2\frac{1}{4} - \frac{3}{4}\log_2\frac{3}{4} = -\frac{1}{4} \times 2 - \frac{3}{4} \times -0.415 = 0.811$$

$$H(Y \mid x_3) = 0 \times .. + \frac{1}{3} \times 0 + \frac{2}{3} \times 0.811 = 0.54$$

$$IG(Y \mid x_3) = H(Y) - H(Y \mid x_3) = 1 - 0.54 = 0.46$$

נחשב את ה-infogain של x4

$$IG(Y \mid x_4) = H(Y) - H(Y \mid x_4)$$

$$H(Y \mid x_4) = p(x_4 = 0) \times H(Y \mid x_4 = 0) + p(x_4 = 1) \times H(Y \mid x_4 = 1)$$

$$p(x_4 = 0) = \frac{1}{3}, p(x_4 = 1) = \frac{2}{3}$$

$$H(Y \mid x_4 = 0) = 0, \quad H(Y \mid x_4 = 1) = 0.811,$$

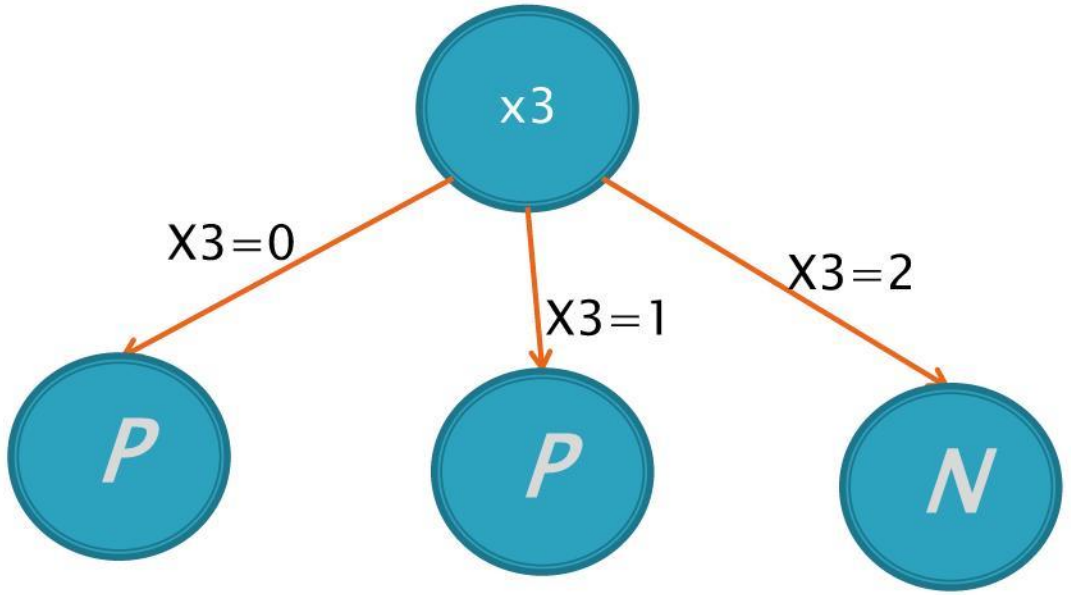
$$H(Y \mid x_4) = 0 \times .. + \frac{1}{3} \times 0 + \frac{2}{3} \times 0.811 = 0.54$$

$$IG(Y \mid x_4) = H(Y) - H(Y \mid x_4) = 1 - 0.54 = 0.46$$

עד כה...

$$IG(y|x_1) = 0.082$$
$$IG(y|x_2) = 0.3333$$
$$IG(y|x_3) = 0.46$$
$$IG(y|x_4) = 0.46$$

תכונות x3 ו-x4 שוות באיכותן. נבחר שרירותית ב-x3



תצפית #	x1	x2	x3	x4	סיווג
1	0	0	1	1	*P*
2	1	0	1	1	*P*
3	1	2	2	1	*P*
6	1	0	2	0	*N*
7	0	0	2	0	*N*
8	0	1	2	1	*N*

כעת נחלק את קבוצת האימון לצורך הרמה הבאה

- כל השורות בהן $x3=0$ – אין כאלו
- כל השורות בהן $x3=1$ – אין לנו מה להמשיך לפצל את העץ

# תצפית	x1	x2	x3	x4	סיווג
1	0	0	1	1	*P*
2	1	0	1	1	*P*

- כל השורות בהן $x3=2$

# תצפית	x1	x2	x3	x4	סיווג
3	1	2	2	1	*P*
6	1	0	2	0	*N*
7	0	0	2	0	*N*
8	0	1	2	1	*N*

ונחזור על התהליך כאשר x3 "מחוץ למשחק"

- כל השורות בהן x3=0 – אין כאלו
- כל השורות בהן x3=1 - אין לנו מה להמשיך לפצל את

תצפית #	x1	x2	x4	סיווג
1	0	0	1	*P*
2	1	0	1	*P*

- כל השורות בהן x3=2

תצפית #	x1	x2	x4	סיווג
3	1	2	1	*P*
6	1	0	0	*N*
7	0	0	0	*N*
8	0	1	1	*N*

תצפית #	x1	x2	x4	סיווג
3	1	2	1	*P*
6	1	0	0	*N*
7	0	0	0	*N*
8	0	1	1	*N*

נפצל עבור x3=2

$$H(Y) = -\frac{1}{4}\log_2\frac{1}{4} - \frac{3}{4}\log_2\frac{3}{4} = 0.811$$

$$IG(Y \mid x_1) = H(Y) - H(Y \mid x_1)$$

$$H(Y \mid x_1) = p(x_1 = 0) \times H(Y \mid x_1 = 0) + p(x_1 = 1) \times H(Y \mid x_1 = 1)$$

$$p(x_1 = 0) = \frac{1}{2}, p(x_1 = 1) = \frac{1}{2}$$

$$H(Y \mid x_1 = 0) = 0, \quad H(Y \mid x_1 = 1) = 1$$

$$H(Y \mid x_1) = 0 \times \ldots + 1 \times 0.5 = 0.5$$

$$IG(Y \mid x_1) = H(Y) - H(Y \mid x_1) = 0.8111 - 0.5 = 0.3111$$

נפצל עבור x3=2

תצפית #	x1	x2	x4	סיווג
3	1	2	1	*P*
6	1	0	0	*N*
7	0	0	0	*N*
8	0	1	1	*N*

$$H(Y) = -\frac{1}{4}\log_2\frac{1}{4} - \frac{3}{4}\log_2\frac{3}{4} = 0.811$$

$$IG(Y \mid x_2) = H(Y) - H(Y \mid x_2)$$

$$H(Y \mid x_2) = p(x_2 = 0) \times H(Y \mid x_2 = 0) + p(x_2 = 1) \times H(Y \mid x_2 = 1) + p(x_2 = 2) \times H(Y \mid x_2 = 2)$$

$$p(x_2 = 0) = \frac{1}{2}, p(x_2 = 1) = \frac{1}{4}, p(x_2 = 2) = \frac{1}{4}$$

$$H(Y \mid x_2 = 0) = 0, \quad H(Y \mid x_2 = 1) = 0, \quad H(Y \mid x_2 = 2) = 0$$

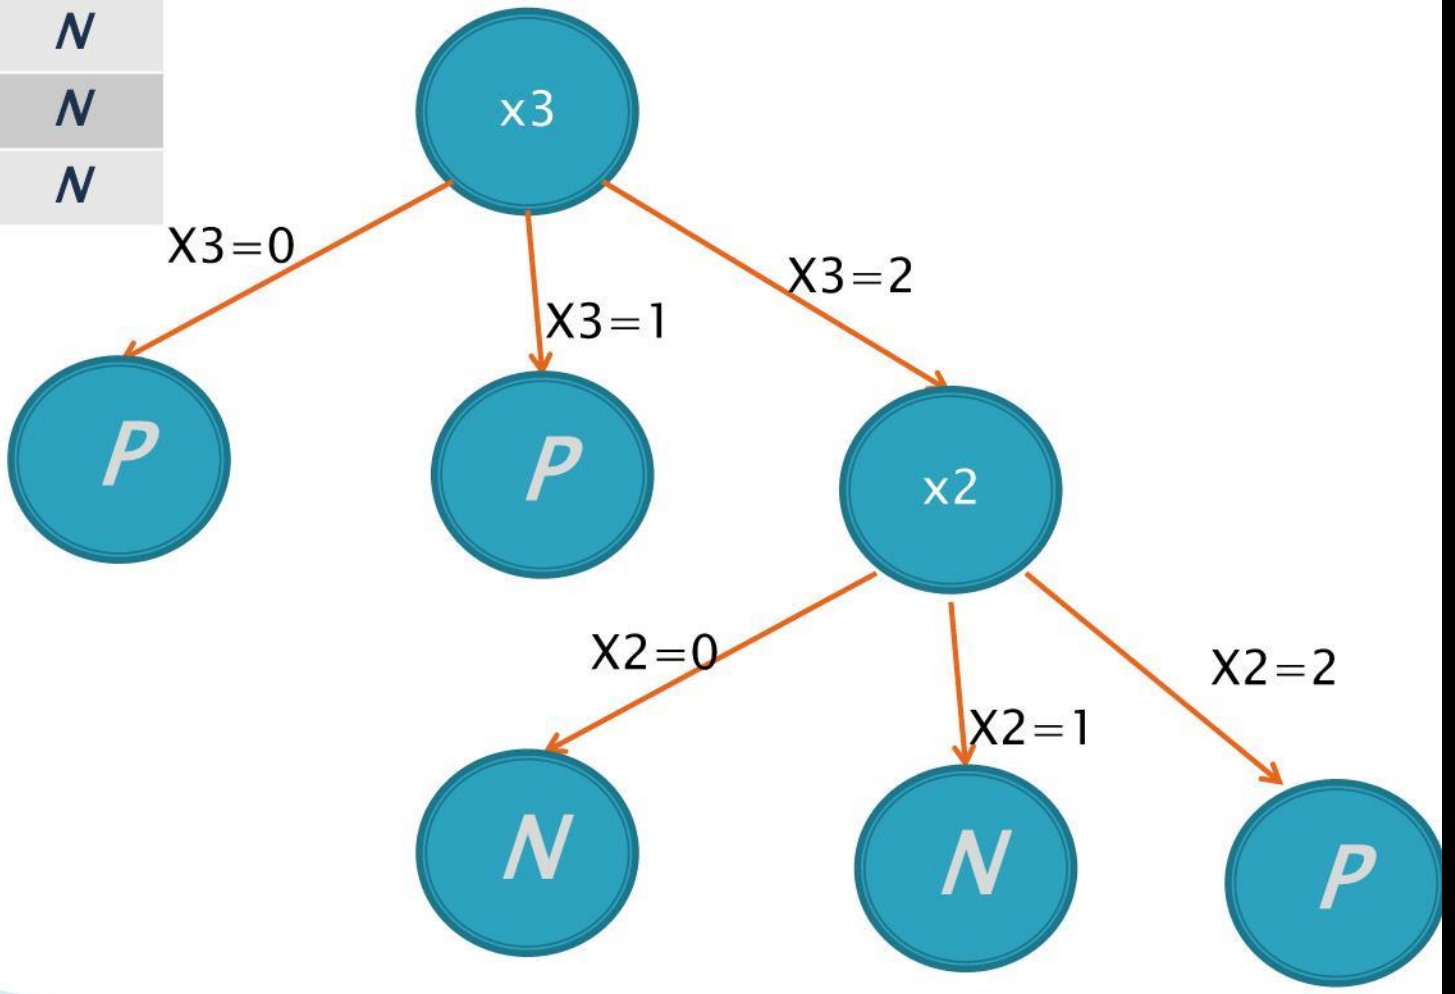
$$H(Y \mid x_2) = 0 \times \frac{1}{2} + 0 \times \frac{1}{4} + 0 \times \frac{1}{4} = 0$$

$$IG(Y \mid x_2) = H(Y) - H(Y \mid x_2) = 0.8111 - 0 = 0.8111$$

כלומר x2 מביא אותנו לרווח המקסימלי ולכן כבר אפשר להחליט שנמיין על-פיו.

עץ ההחלטה

תצפית #	x1	x2	x3	x4	סיווג
1	0	0	1	1	*P*
2	1	0	1	1	*P*
3	1	2	2	1	*P*
6	1	0	2	0	*N*
7	0	0	2	0	*N*
8	0	1	2	1	*N*



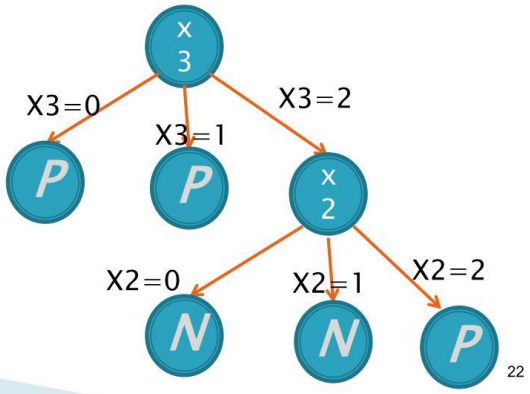
ננתח ביצועים על קבוצת המבחן

תצפית #	x1	x2	x3	x4	סיווג	סיווג עפ"י עץ החלטה
4	0	1	1	1	*P*	*P*
5	0	2	0	0	*P*	*P*
9	1	0	1	0	*N*	*P*
10	1	1	2	1	*N*	*N*

TPR = 2/2

FPR = ½

Precision = 2/3



22

true negative (TN)

eqv. with correct rejection

false positive (FP)

eqv. with false alarm, Type I error

false negative (FN)

eqv. with miss, Type II error

---

sensitivity, recall, hit rate, or true positive rate (TPR)

$$\mathrm{TPR} = \frac{\mathrm{TP}}{\mathrm{P}} = \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FN}} = 1 - \mathrm{FNR}$$

specificity, selectivity or true negative rate (TNR)

$$\mathrm{TNR} = \frac{\mathrm{TN}}{\mathrm{N}} = \frac{\mathrm{TN}}{\mathrm{TN} + \mathrm{FP}} = 1 - \mathrm{FPR}$$

precision or positive predictive value (PPV)

$$\mathrm{PPV} = \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FP}} = 1 - \mathrm{FDR}$$

fall-out or false positive rate (FPR)

$$\mathrm{FPR} = \frac{\mathrm{FP}}{\mathrm{N}} = \frac{\mathrm{FP}}{\mathrm{FP} + \mathrm{TN}} = 1 - \mathrm{TNR}$$

K-nearest Neighbors

- "Instance-Based" approach
  - אינטואיציה: נסווג דוגמא חדשה בהתבסס על **הדמיון** שלה לדוגמאות מקבוצת האימון.
  - עבור דוגמא חדשה $X \in R^D$ מצא את K ה"שכנים הקרובים" של הדוגמא (כמובן שכנים עליהם ידוע הסיווג) וסווג עפ"י הסיווג של רוב השכנים.

Distance Metrics

Minkowski distance

$$d(i,j)=\sqrt[q]{(|x_{i_1}-x_{j_1}|^q+|x_{i_2}-x_{j_2}|^q+...+|x_{i_p}-x_{j_p}|^q)}$$

(*q = 1*), Manhattan distance (semi-metric distance)

(A.K.A Manhattan, taxicab, L_1 norm)

$$d(i,j)=|x_{i_1}-x_{j_1}|+|x_{i_2}-x_{j_2}|+...+|x_{i_p}-x_{j_p}|$$

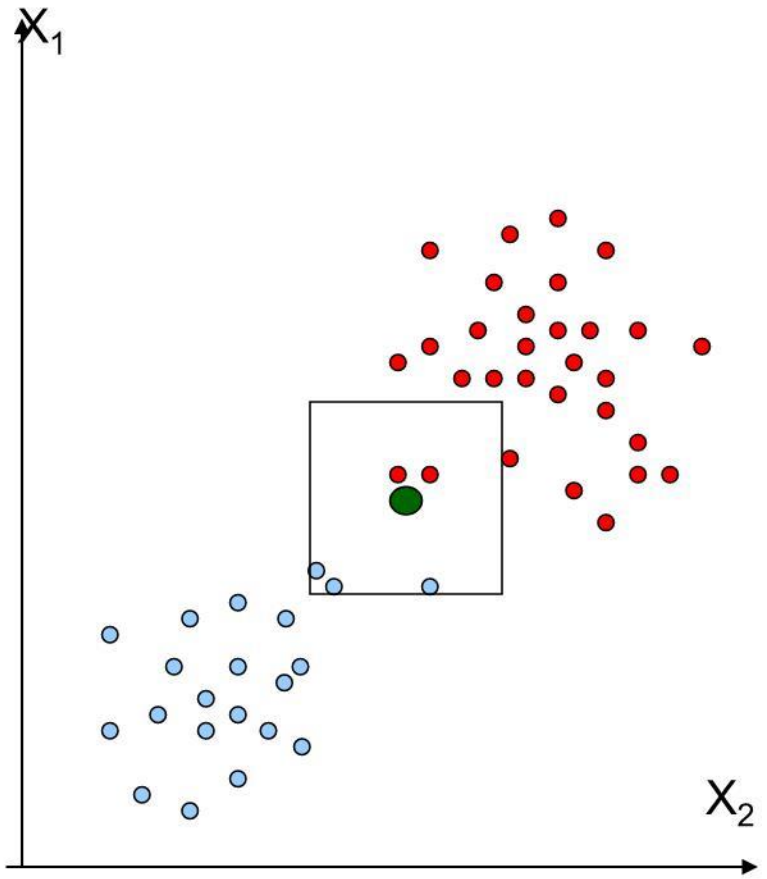
(*q = 2*), Euclidean distance (metric distance)

$$d(i,j)=\sqrt{(|x_{i_1}-x_{j_1}|^2+|x_{i_2}-x_{j_2}|^2+...+|x_{i_p}-x_{j_p}|^2)}$$

($q \to \infty$), "supremum" (L_{max} norm, L_∞ norm) distance.

The maximum difference between any component of the vectors

ומה נעשה במצב כזה?



For k=5: Classify as blue

(3 “says” blue, 2 says “Red”)

נפתור כעת את הבעיה באמצעות KNN

- KNN הינו אלגוריתם "עצלן" (lazy). לא בונה מודל אלא מסווג את הדוגמא כאשר היא מגיעה.
- צריכים להגדיר באלגוריתם זה את:
  - K – מס' השכנים הקרובים – **נגדיר K=3**
  - מטריקת המרחק – **נעבוד עם מטריקה אוקלידית**
  - משקול מאפיינים – $\sigma_4=3, \sigma_3=2, \sigma_2=1, \sigma_1=9, \sigma$
  - משקול מרחקים = $1/d^2$

נראה כיצד מסווגים את הדוגמא הראשונה מקבוצת המבחן

- הווקטור $x_1=0,\ x_2=1,\ x_3=1,\ x_4=1$
- נבדוק את המרחק מכל דוגמא בקבוצת האימון

# תצפית	x 1	x 2	x 3	x 4	Y	Distance from (0,1,1,1)
1	0	0	1	1	*P*	$\sqrt{9\times(0-0)^2+1\times(0-1)^2+2\times(1-1)^2+3\times(1-1)^2}=\sqrt{1}$
2	1	0	1	1	*P*	$\sqrt{9\times(1-0)^2+1\times(0-1)^2+2\times(1-1)^2+3\times(1-1)^2}=\sqrt{10}$
3	1	2	2	1	*P*	$\sqrt{9\times(1-0)^2+1\times(2-1)^2+2\times(2-1)^2+3\times(1-1)^2}=\sqrt{12}$
6	1	0	2	0	*N*	$\sqrt{9\times(1-0)^2+1\times(0-1)^2+2\times(2-1)^2+3\times(0-1)^2}=\sqrt{15}$
7	0	0	2	0	*N*	$\sqrt{9\times(0-0)^2+1\times(0-1)^2+2\times(2-1)^2+3\times(0-1)^2}=\sqrt{6}$
8	0	1	2	1	*N*	$\sqrt{9\times(0-0)^2+1\times(1-1)^2+2\times(2-1)^2+3\times(1-1)^2}=\sqrt{2}$

נבחן מיהם 3 השכנים הקרובים

# תצפית	x 1	x 2	x 3	x 4	Y	Distance from (0,1,1,1)
1	0	0	1	1	*P*	$\sqrt{9\times(0-0)^2+1\times(0-1)^2+2\times(1-1)^2+3\times(1-1)^2}=\sqrt{1}$
2	1	0	1	1	*P*	$\sqrt{9\times(1-0)^2+1\times(0-1)^2+2\times(1-1)^2+3\times(1-1)^2}=\sqrt{10}$
3	1	2	2	1	*P*	$\sqrt{9\times(1-0)^2+1\times(2-1)^2+2\times(2-1)^2+3\times(1-1)^2}=\sqrt{12}$
6	1	0	2	0	*N*	$\sqrt{9\times(1-0)^2+1\times(0-1)^2+2\times(2-1)^2+3\times(0-1)^2}=\sqrt{15}$
7	0	0	2	0	*N*	$\sqrt{9\times(0-0)^2+1\times(0-1)^2+2\times(2-1)^2+3\times(0-1)^2}=\sqrt{6}$
8	0	1	2	1	*N*	$\sqrt{9\times(0-0)^2+1\times(1-1)^2+2\times(2-1)^2+3\times(1-1)^2}=\sqrt{2}$

שקלול מרחקים

- שלושת השכנים הקרובים
  - P – מרחק $\sqrt{1}$
  - N – מרחק $\sqrt{6}$
  - N – מרחק $\sqrt{2}$
- ללא שקלול מרחקים היינו מסווגים כ-N
- עם שקלול מרחקים – שקלול ה"חיוביים" גדול משקלול ה"שליליים" ולכן נסווג כ-P

$$N: \frac{1}{\sqrt{6}^2} + \frac{1}{\sqrt{2}^2} = \frac{1}{6} + \frac{1}{2} = \frac{2}{3}$$

$$P: \frac{1}{\sqrt{1}^2} = \frac{1}{1} = 1$$

הרעיון הכללי

- בהינתן ווקטור לסיווג – $(x_1,x_2,x_3 \ldots\ldots x_n)$

  ננסה להעריך את ההסתברות עבור כל סיווג C_i השייך לקבוצה C ולבחור את הסיווג עם ההסתברות הגבוהה ביותר.

- $P(C_1|\, x_1, x_2, x_3 \ldots\ldots x_n)$
- $P(C_2|\, x_1, x_2, x_3 \ldots\ldots x_n)$
- $P(C_3|\, x_1, x_2, x_3 \ldots\ldots x_n)$
- …

$$h = \underset{c \in C}{argmax}\, P(c|x)$$

Naïve Bayes Classifier

- Using Bayes rule:

$$P(c \mid x_1, x_2, \ldots\ldots x_D) = \frac{P(C)P(x_1, x_2, \ldots\ldots x_D \mid C)}{P(x_1, x_2, \ldots\ldots x_D)}$$

- Select the feature set such that each feature x_i is independent of every other feature x_j.

$$P(x_1, x_2, \ldots\ldots x_D \mid c) = P(x_1 \mid c)P(x_2 \mid c)P(x_3 \mid c)\ldots P(x_D \mid c) = \prod_{i=1}^{D} P(x_i \mid c)$$

נסווג עפ"י naïve bayes

- נחשב את ההסתברות לקבלת P בהינתן הדוגמא
- נחשב את ההסתברות לקבלת N בהינתן הדוגמא
- ונכריע לפי ההסתברות הגבוהה יותר

- If P(P|x1,x2,x3,x4) > P(N|x1,x2,x3,x4)
  - Decide P
- Else
  - Decide N

$$P(P \mid x1, x2, x3, x4) = \frac{P(P) \times P(x1, x2, x3, x4 \mid P)}{P(x1, x2, x3, x4)}$$

$$P(N \mid x1, x2, x3, x4) = \frac{P(N) \times P(x1, x2, x3, x4 \mid N)}{P(x1, x2, x3, x4)}$$

המכנה לא רלוונטי כי מופיע גם ב- pos וגם ב-neg
במקרה שלנו P(P) = P(N)

$$P(x1, x2, x3, x4 \mid P) \overset{?}{<} P(x1, x2, x3, x4 \mid N)$$

תצפית #	x 1	x 2	x 3	x 4	Y
1	0	0	1	1	*P*
2	1	0	1	1	*P*
3	1	2	2	1	*P*
6	1	0	2	0	*N*
7	0	0	2	0	*N*
8	0	1	2	1	*N*

נחשב עבור ה"חיוביים"

נניח שהמשתנים בלתי תלויים זה בזה

$$P(x1, x2, x3, x4 \mid P) = P(x_1 \mid P) \times P(x_2 \mid P) \times P(x_3 \mid P) \times P(x_4 \mid P)$$

נבחן על הדוגמא (0,1,1,1)

$$P(x1 = 0, x2 = 1, x3 = 1, x4 = 1 \mid P) = P(x_1 = 0 \mid P) \times P(x_2 = 1 \mid P) \times P(x_3 = 1 \mid P) \times P(x_4 = 1 \mid P)$$

$$= \frac{1}{3} \times 0 \times \frac{2}{3} \times 1$$

יש צורך בהחלקה. נניח שיש לנו בסיס נתונים וירטואלי נוסף בו מתקיים שמתוך 50 שורות נוספות "חיוביות" (m=50) מתקיים שב-10 מתוכן x2=1 (p=10/50)

$$P(x2 = 1 \mid P) = \frac{10 + 0}{50 + 3} = \frac{10}{53}$$

$$P(x1 = 0, x2 = 1, x3 = 1, x4 = 1 \mid P) = \frac{1}{3} \times \frac{10}{53} \times \frac{2}{3} \times 1 = 0.041$$

תצפית #	x 1	x 2	x 3	x 4	Y
1	0	0	1	1	*P*
2	1	0	1	1	*P*
3	1	2	2	1	*P*
6	1	0	2	0	*N*
7	0	0	2	0	*N*
8	0	1	2	1	*N*

נחשב עבור ה"שליליים"

נניח שהמשתנים בלתי תלויים זה בזה

$$P(x1,x2,x3,x4 \mid N) = P(x_1 \mid N) \times P(x_2 \mid N) \times P(x_3 \mid N) \times P(x_4 \mid N)$$

נבחן על הדוגמא (0,1,1,1)

$$P(x1=0,x2=1,x3=1,x4=1 \mid N) = P(x_1=0 \mid N) \times P(x_2=1 \mid N) \times P(x_3=1 \mid N) \times P(x_4=1 \mid N)$$

$$= \frac{1}{3} \times \frac{1}{3} \times 0 \times \frac{1}{3}$$

יש צורך בהחלקה. נניח שיש לנו בסיס נתונים וירטואלי נוסף בו מתקיים שמתוך 50 שורות נוספות "שליליות" (m=50) מתקיים שב-10 מתוכן x3=1 (p=10/50)

$$P(x3=1 \mid N) = \frac{10+0}{50+3} = \frac{10}{53}$$

$$P(x1=0,x2=1,x3=1,x4=1 \mid N) = \frac{1}{3} \times \frac{1}{3} \times \frac{10}{53} \times \frac{1}{3} \times 1 = 0.006$$

הכרעה

- קיבלנו ש

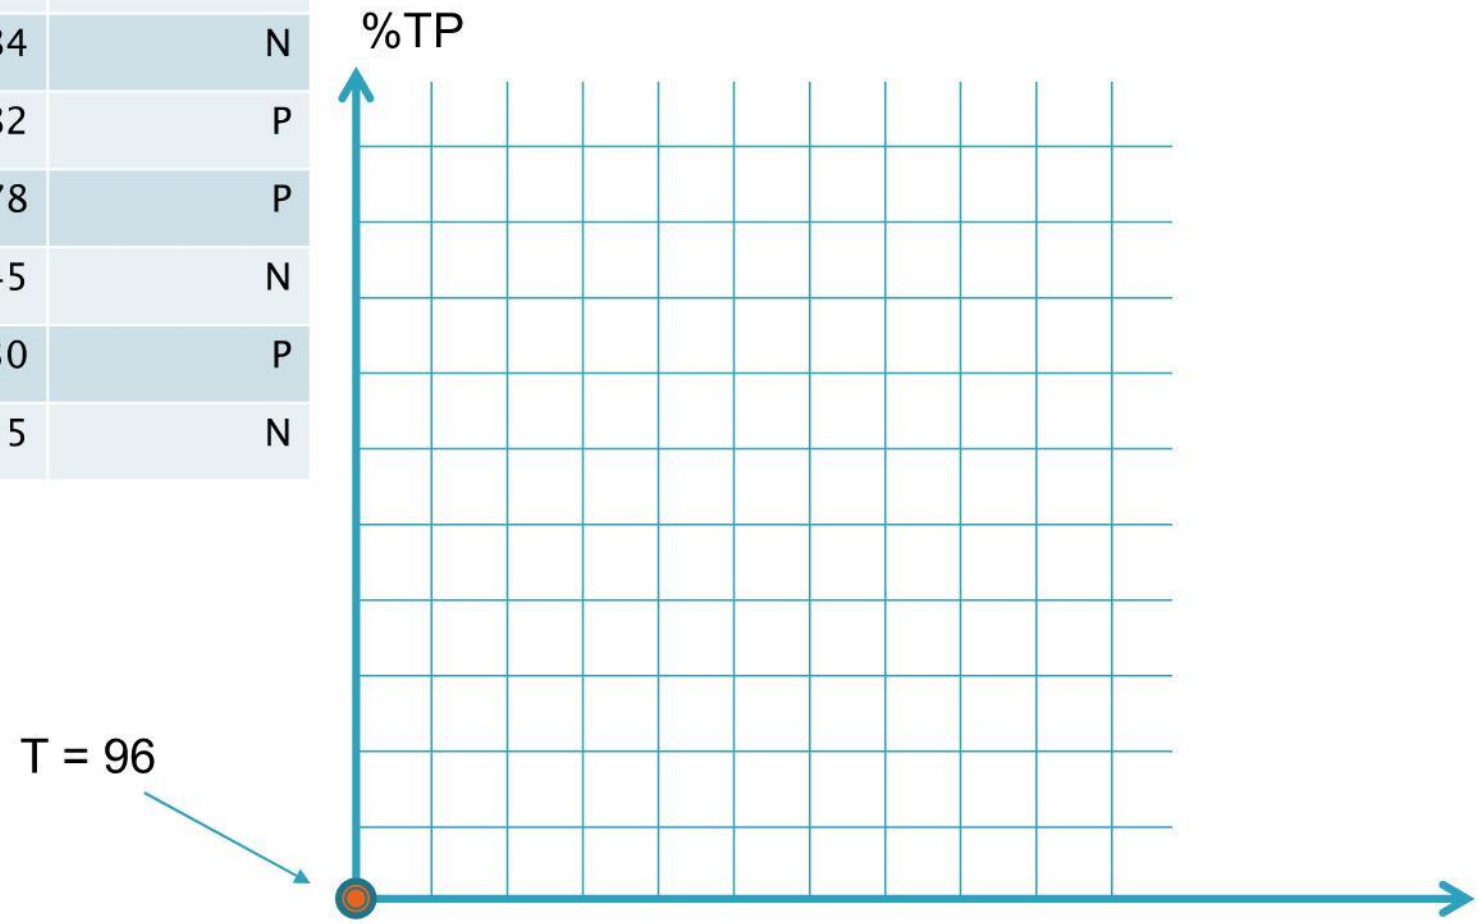
$$P(x1, x2, x3, x4 \mid P) > P(x1, x2, x3, x4 \mid N)$$

- ולכן נסווג את הדוגמא כ-POS

Test#	probability	סיווג אמיתי
1	95	P
2	90	P
3	84	N
4	82	P
5	78	P
6	45	N
7	30	P
8	5	N

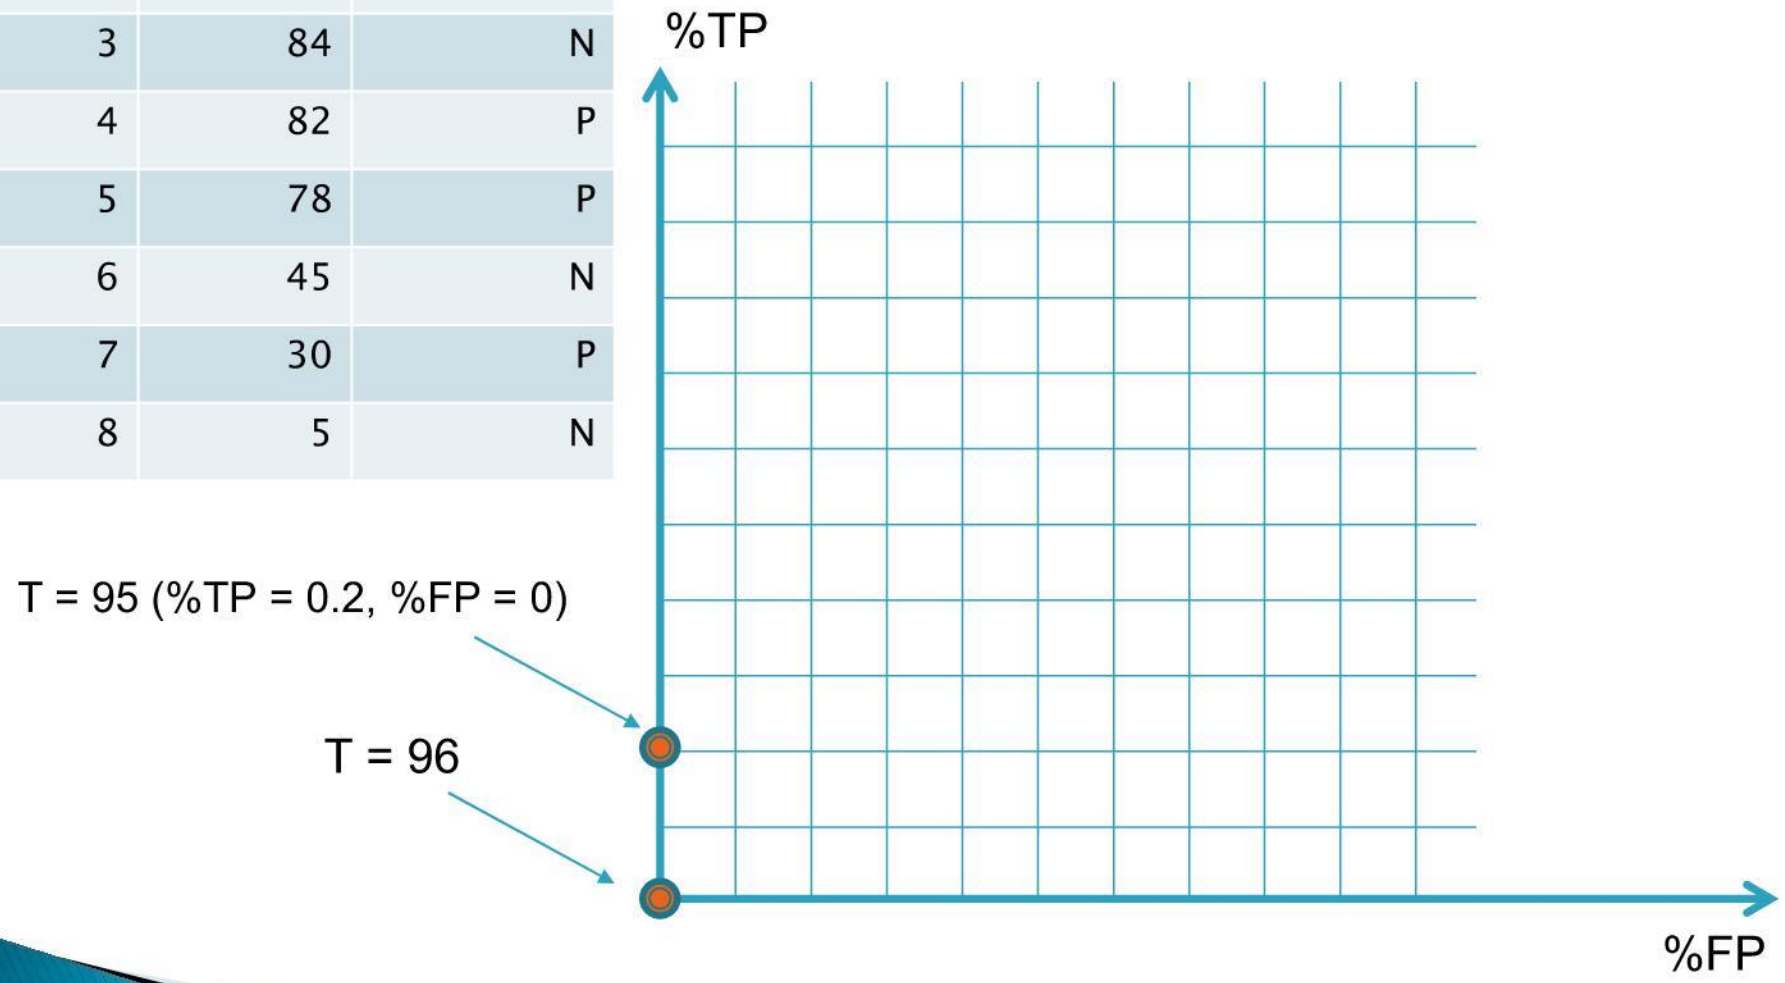
בנינו מודל למידה על קבוצת אימון של שתי מחלקות
יצרנו מודל הסתברותי שמחזיר לנו הסתברות שהדוגמא חיובית.
בהינתן קבוצת המבחן שבטבלה, החיזוי של האלגוריתם על כל דוגמא והסיווג האמיתי – צייר את גרף ROC

Test#	probability	סיווג אמיתי
1	95	P
2	90	P
3	84	N
4	82	P
5	78	P
6	45	N
7	30	P
8	5	N

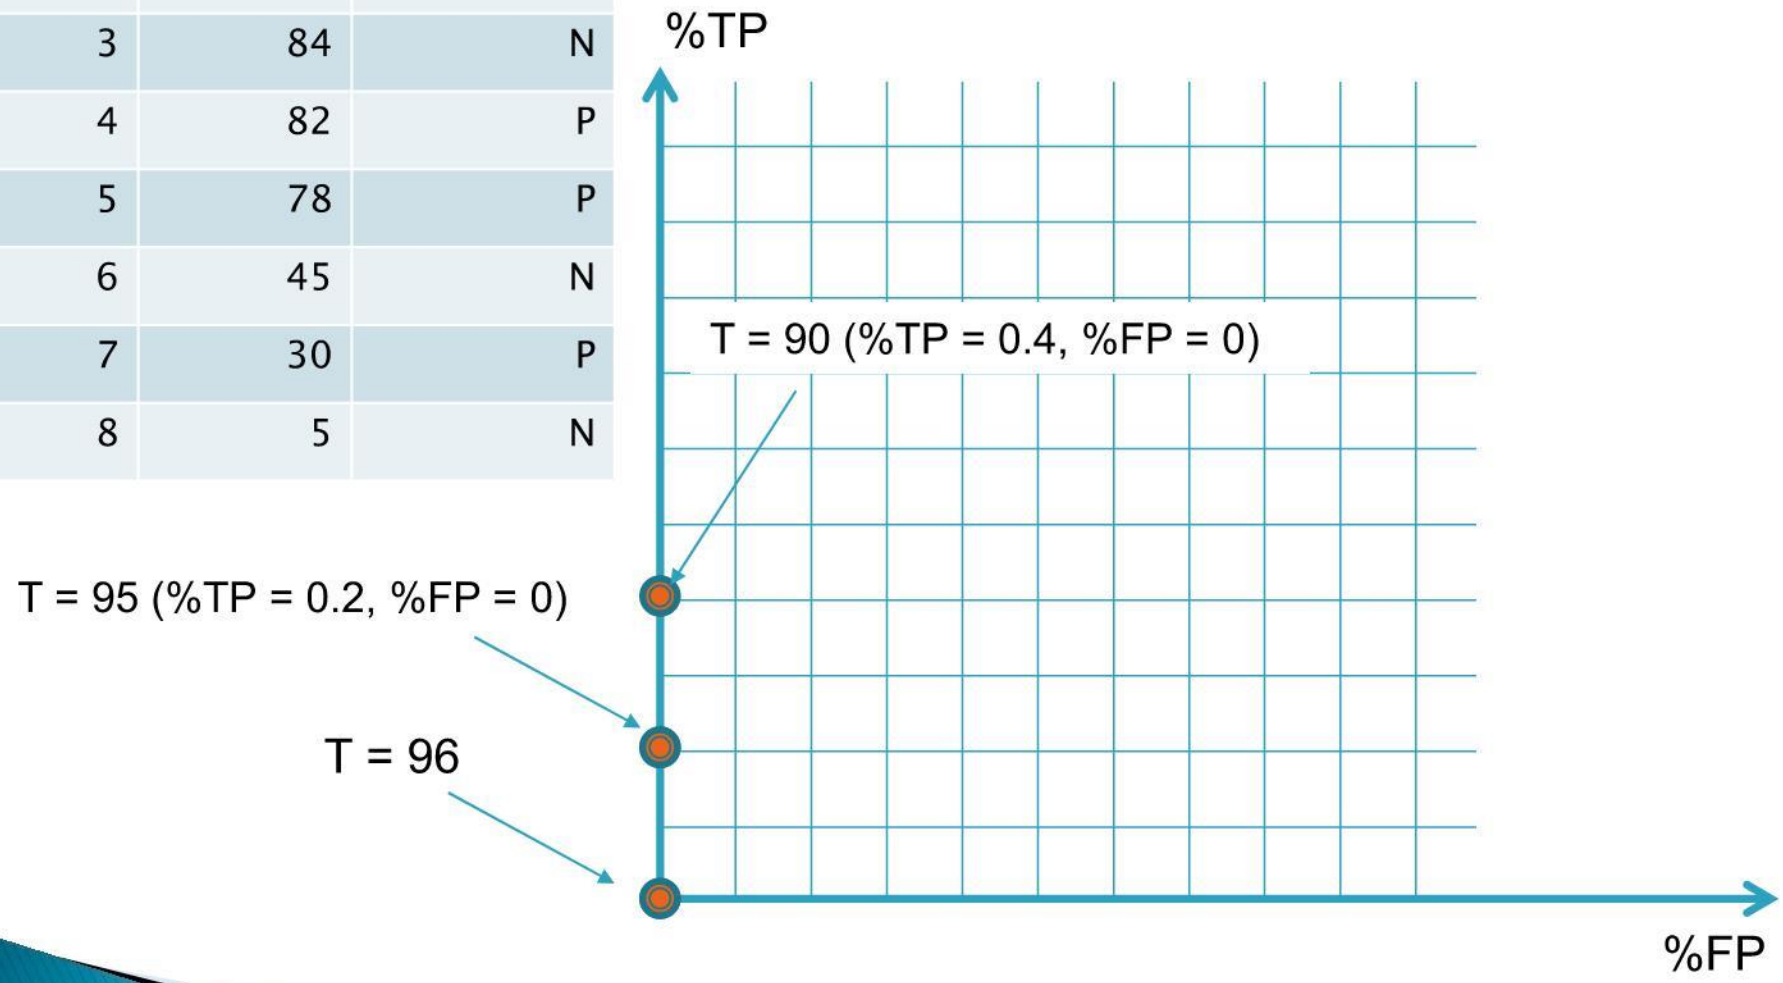


חשב את ה-AUC

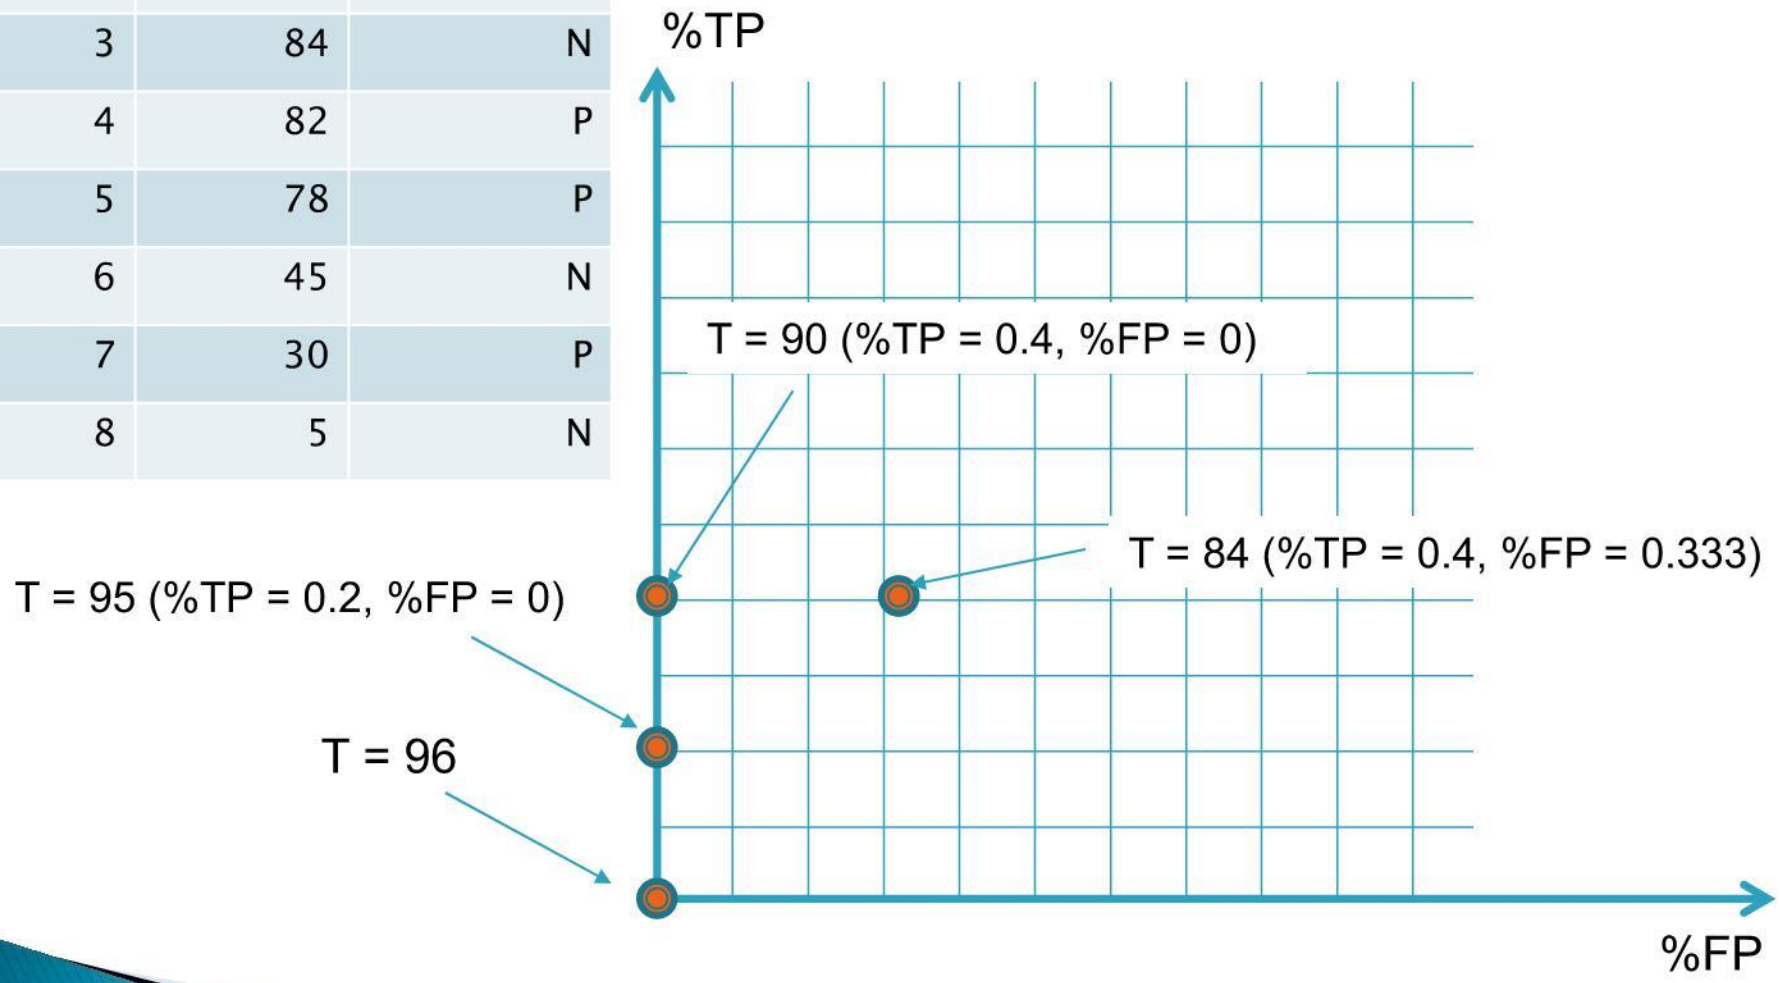
Test#	probability	סיווג אמיתי
1	95	P
2	90	P
3	84	N
4	82	P
5	78	P
6	45	N
7	30	P
8	5	N



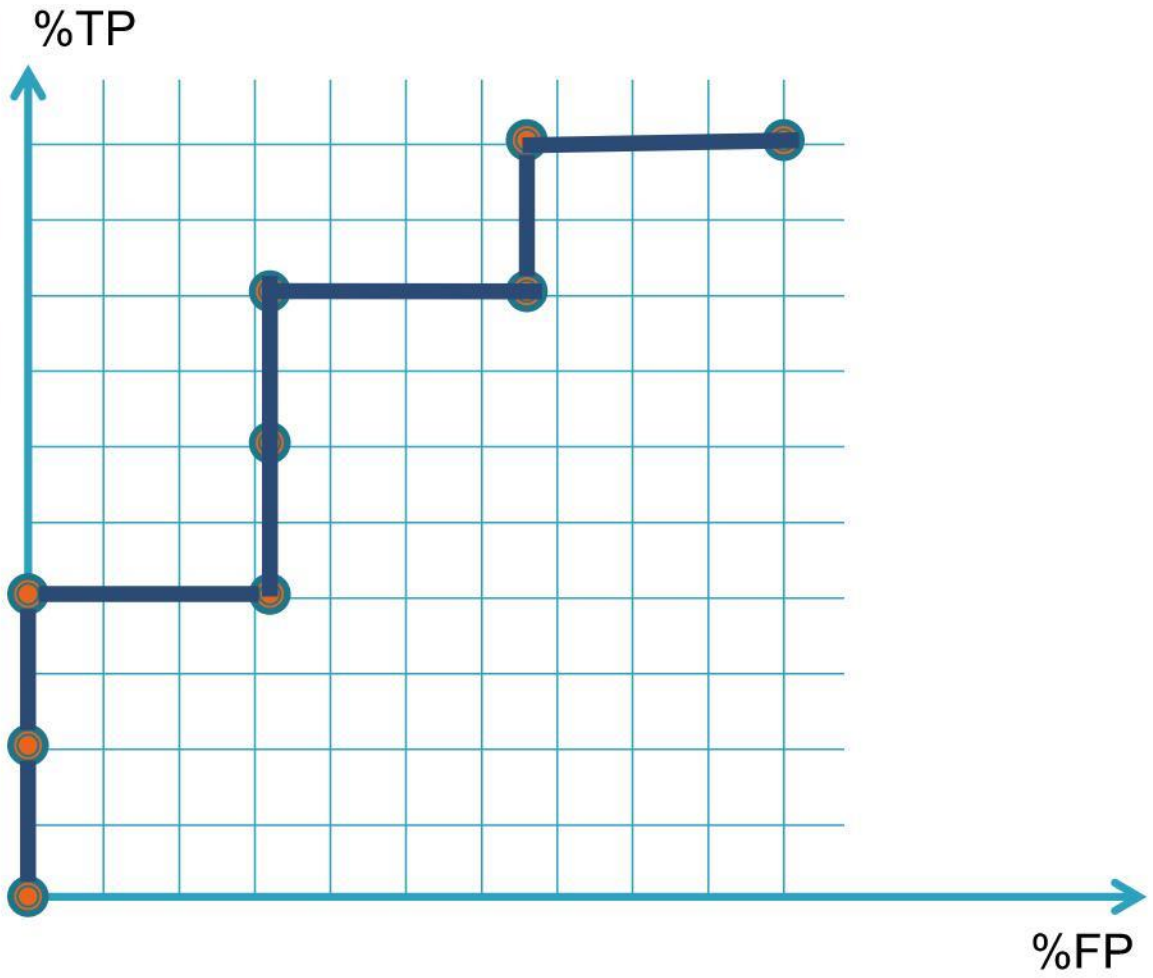
Test#	probability	סיווג אמיתי
1	95	P
2	90	P
3	84	N
4	82	P
5	78	P
6	45	N
7	30	P
8	5	N



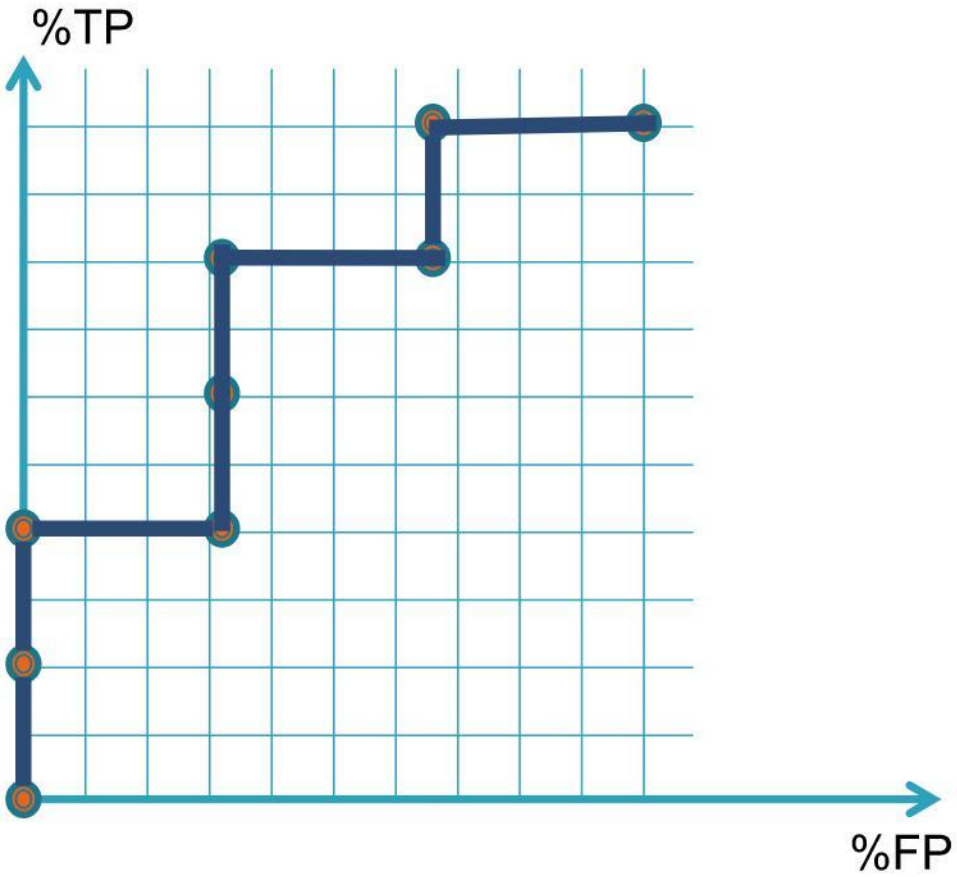
Test#	probability	סיווג אמיתי
1	95	P
2	90	P
3	84	N
4	82	P
5	78	P
6	45	N
7	30	P
8	5	N



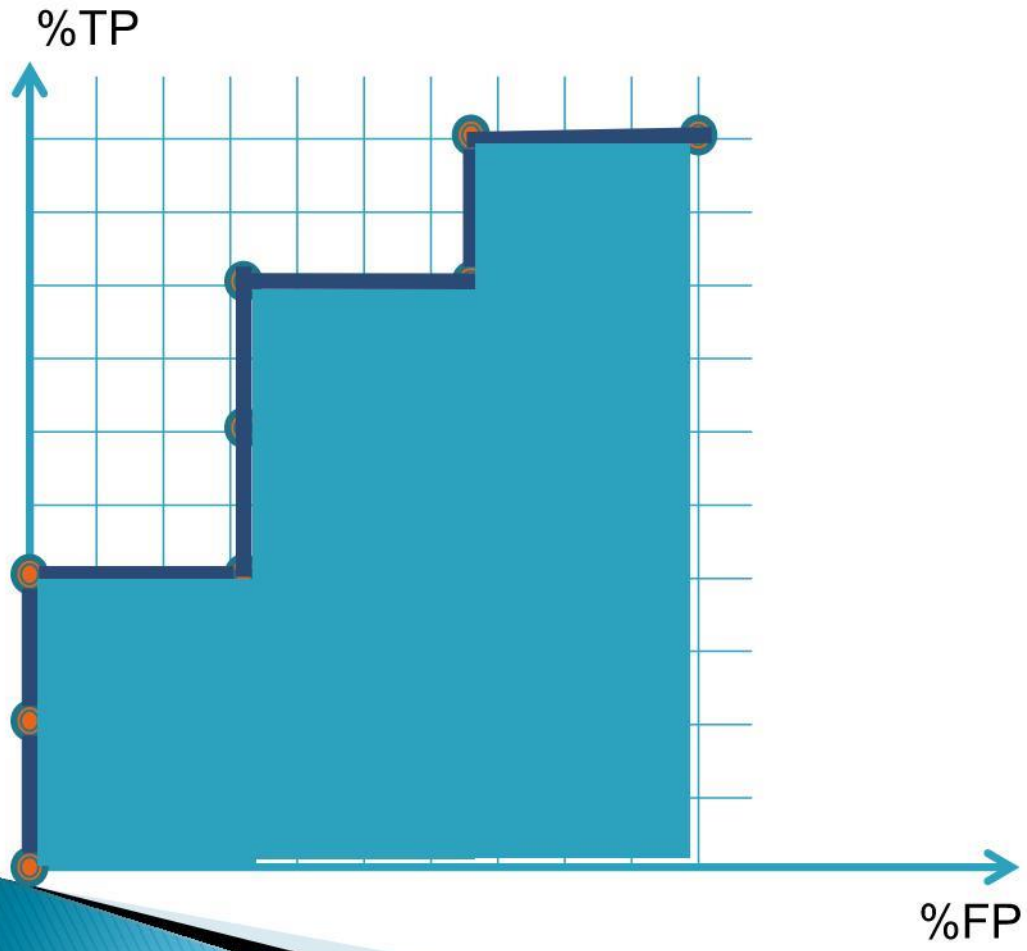
Test#	probability	סיווג אמיתי
1	95	P
2	90	P
3	84	N
4	82	P
5	78	P
6	45	N
7	30	P
8	5	N



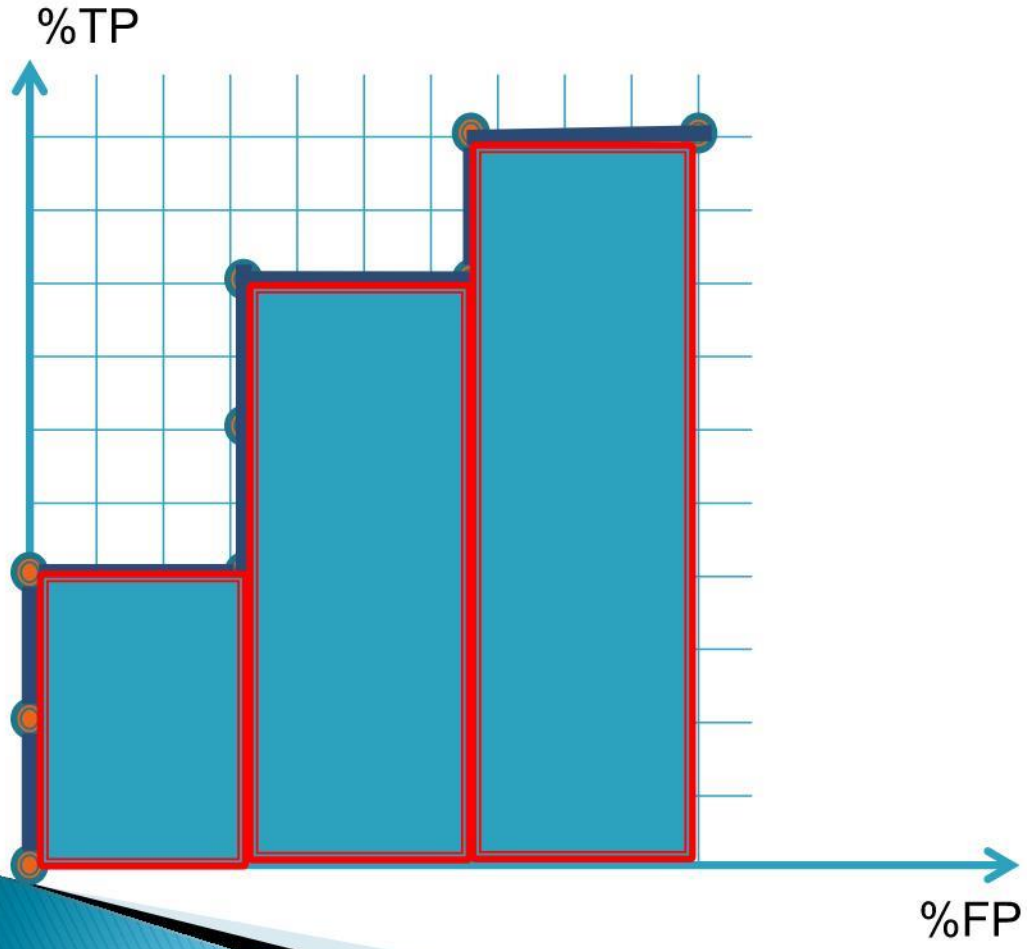
חשב את ה-AUC



חשב את ה-AUC



חשב את ה-AUC



$$\frac{2}{5}\times\frac{1}{3}+\frac{4}{5}\times\frac{1}{3}+1\times\frac{1}{3}$$

$$=\frac{2+4+5}{15}=\frac{11}{15}$$

Naïve Bayes

שאלה 1 (20 נקודות):

נתונים בעיית הלמידה הבאה: בהינתן הצבעה של חבר כנסת בשלוש הצבעות שונות (הצבעה יכולה לקבל אחד מהערכים: "בעד"-1/"נגד" - 0/"נמנע" - 2), יש צורך לחזות האם חבר הכנסת הוא "POS" או "NEG".

נתונה קבוצת האימון הבאה:

#	הצבעה 1 Vote1	הצבעה 2 Vote2	הצבעה 3 Vote3	class
1	**2**	**1**	**0**	**POS**
2	**1**	**0**	**1**	**POS**
4	**1**	0	**2**	**NEG**
5	**1**	0	**2**	**NEG**
6	**0**	**1**	**1**	**NEG**

ב. (7 נקודות) סווג את הווקטור (vote1 = 1, vote2 = 1, vote3 = 1) עפ"י אלגוריתם Naïve Bayes. במידה שנדרשת "החלקה" יש לבצעה עם הפרמטרים m=10, p=0.2 (כלומר בסיס נתונים וירטואלי נוסף בגודל 10, עם הסתברות למאורע של 20%)

ניתן להניח שהמאפיינים בלתי תלויים

Naïve Bayes

פתרון: נבדוק את ההסתברות לקבלת POS ונבדוק מהי ההסתברות לקבלת NEG ונבחר את הגבוה מבין השניים:

Naïve Bayes

פתרון: נבדוק את ההסתברות לקבלת POS ונבדוק מהי ההסתברות לקבלת NEG ונבחר את הגבוה מבין השניים:

$$P(P \mid v1=1, v2=1, v3=1) = \frac{P(v1=1, v2=1, v3=1 \mid P) \times P(P)}{P(v1=1, v2=1, v3=1)}$$

$$P(N \mid v1=1, v2=1, v3=1) = \frac{P(v1=1, v2=1, v3=1 \mid N) \times P(N)}{P(v1=1, v2=1, v3=1)}$$

המכנה זהה, ולכן לא מעניין

Naïve Bayes

$$P("P") = 2/5$$

Naïve Bayes

$$P("P") = 2/5$$

$$P(v1 = 1, v2 = 1, v3 = 1 \mid "P") = P(v1 = 1 \mid "P") \times P(v2 = 1 \mid "P") \times P(v3 = 1 \mid "P")$$

Naïve Bayes

$$P("P") = 2/5$$

$$P(v1=1, v2=1, v3=1 \mid "P") = P(v1=1 \mid "P") \times P(v2=1 \mid "P") \times P(v3=1 \mid "P")$$

$$P(v1=1 \mid "P") = \frac{1}{2}, P(v2=1 \mid "P") = \frac{1}{2}, P(v3=1 \mid "P") = \frac{1}{2}$$

Naïve Bayes

$$P("P") = 2/5$$

$$P(v1=1, v2=1, v3=1 \mid "P") = P(v1=1 \mid "P") \times P(v2=1 \mid "P") \times P(v3=1 \mid "P")$$

$$P(v1=1 \mid "P") = \frac{1}{2}, P(v2=1 \mid "P") = \frac{1}{2}, P(v3=1 \mid "P") = \frac{1}{2}$$

$$P(v1=1, v2=1, v3=1 \mid "P") = \frac{1}{2} \times \frac{1}{2} \times \frac{1}{2} \times \frac{2}{5} = \frac{2}{40} = \frac{1}{20}$$

Naïve Bayes

$$P("P") = 2/5$$

$$P("N") = 3/5$$

$$P(v1=1, v2=1, v3=1 \mid "P") = P(v1=1 \mid "P") \times P(v2=1 \mid "P") \times P(v3=1 \mid "P")$$

$$P(v1=1, v2=1, v3=1 \mid "N") = P(v1=1 \mid "N") \times P(v2=1 \mid "N") \times P(v3=1 \mid "N")$$

$$P(v1=1 \mid "P") = \frac{1}{2}, P(v2=1 \mid "P") = \frac{1}{2}, P(v3=1 \mid "P") = \frac{1}{2}$$

$$P(v1=1 \mid "N") = \frac{2}{3}, P(v2=1 \mid "N") = \frac{1}{3}, P(v3=1 \mid "N") = \frac{1}{3}$$

$$P(v1=1, v2=1, v3=1 \mid "P") = \frac{1}{2} \times \frac{1}{2} \times \frac{1}{2} \times \frac{2}{5} = \frac{2}{40} = \frac{1}{20}$$

$$P(v1=1, v2=1, v3=1 \mid "N") = \frac{2}{3} \times \frac{1}{3} \times \frac{1}{3} \times \frac{3}{5} = \frac{6}{135}$$

$$\frac{1}{20} = \frac{6}{120} > \frac{6}{135}$$

2. נתונה טבלת האימון הבאה (נתונים המאפיינים feature1, feature2, feature3 ויש צורך לחזות את class):

Feature1	Feature2	Feature3	Class
0	1	1	P
1	0	0	P
0	0	1	N
1	1	0	N
0	0	0	P
1	1	1	P
1	1	0	N

א. (10 נקודות) מוצע האלגוריתם הבא לפתרון הבעיה:

```
if (feature1 == 1) then class = 'P' else class = 'N'
```

חשבו את ה True-Positive ואת ה-False Positive של האלגוריתם המוצע על קבוצת האימון.

ב. (8 נקודות) טענה: אם נמצא אלגוריתם שפותר לנו באופן מושלם את השורות שבטבלה, הרי שמצאנו אלגוריתם למידה מושלם לבעיה ונוכל לחזות בצורה איכותית מידע חדש בהינתן feature1,feature2,feature3. הסבירו האם נכון או לא. הסבר בנימוקיכם את המושג overfitting.

ג. (7 נקודות) מהם החסרונות של lazy algorithm ? ציינו אלגוריתם lazy שנלמד בקורס והסבירו כיצד הוא פועל.

3. התייחסו לטבלה משאלה 2.

א. (7 נקודות) חשבו את האנתרופיה של class. ניתן להשאיר את הפתרון עם log.

ב. (18 נקודות) על פי אלגוריתם Naïve Bayes מה יהיה סיווג הדוגמא הבאה: (הניחו שהמאפיינים בלתי תלויים זה בזה)

Feature1=0 Feature2=0 Feature3=1

Feature1	Feature2	Feature3	Class
0	1	1	P
1	0	0	P
0	0	1	N
1	1	0	N
0	0	0	P
1	1	1	P
1	1	0	N

א. (10 נקודות) מוצע האלגוריתם הבא לפתרון הבעיה:

```
if (feature1 == 1) then class = 'P' else class = 'N'
```

חשבו את ה True-Positive ואת ה-False Positive של האלגוריתם המוצע על קבוצת האימון.

if (feature1 == 1) then class = 'P' else class = 'N'

פתרון:

ראשית, נבחן את תוצאות האלגוריתם על כל אחד מהווקטורים בקבוצת האימון (עמודת Predicted). כל שורה עבורה feature1 = 1 תקבל חיזוי P. כל שורה עבורה feature1 = 0 תקבל חיזוי N

	Feature1	Feature2	Feature3	Class	**Predicted**
1	0	1	1	P	
2	1	0	0	P	
3	0	0	1	N	
4	1	1	0	N	
5	0	0	0	P	
6	1	1	1	P	
7	1	1	0	N	

if (feature1 == 1) then class = 'P' else class = 'N'

פתרון:

ראשית, נבחן את תוצאות האלגוריתם על כל אחד מהווקטורים בקבוצת האימון (עמודת Predicted). כל שורה עבורה feature1 = 1 תקבל חיזוי P. כל שורה עבורה feature1 = 0 תקבל חיזוי N

	Feature1	Feature2	Feature3	Class	Predicted
1	0	1	1	P	N
2	1	0	0	P	
3	0	0	1	N	
4	1	1	0	N	
5	0	0	0	P	
6	1	1	1	P	
7	1	1	0	N	

if (feature1 == 1) then class = 'P' else class = 'N'

פתרון:

ראשית, נבחן את תוצאות האלגוריתם על כל אחד מהווקטורים בקבוצת האימון (עמודת Predicted). כל שורה עבורה feature1 = 1 תקבל חיזוי P. כל שורה עבורה feature1 = 0 תקבל חיזוי N

	Feature1	Feature2	Feature3	Class	Predicted
1	0	1	1	P	N
2	1	0	0	P	P
3	0	0	1	N	
4	1	1	0	N	
5	0	0	0	P	
6	1	1	1	P	
7	1	1	0	N	

if (feature1 == 1) then class = 'P' else class = 'N'

פתרון:

ראשית, נבחן את תוצאות האלגוריתם על כל אחד מהווקטורים בקבוצת האימון (עמודת Predicted). כל שורה עבורה feature1 = 1 תקבל חיזוי P. כל שורה עבורה feature1 = 0 תקבל חיזוי N

	Feature1	Feature2	Feature3	Class	Predicted
1	0	1	1	P	N
2	1	0	0	P	P
3	0	0	1	N	N
4	1	1	0	N	P
5	0	0	0	P	N
6	1	1	1	P	P
7	1	1	0	N	P

if (feature1 == 1) then class = 'P' else class = 'N'

	Feature1	Feature2	Feature3	Class	Predicted
1	0	1	1	P	N
2	1	0	0	P	P
3	0	0	1	N	N
4	1	1	0	N	P
5	0	0	0	P	N
6	1	1	1	P	P
7	1	1	0	N	P

TP(True-Positive) – מס' הפעמים בהם חזינו 'P' וה"אמת" הינה אכן P (שורות 2,6)

מתוך סך המקרים בהם ה"אמת" היא P (שורות 1,2,5,6), כלומר TP = 2/4 = 0.5

FP(False-Positive) – מס' הפעמים בהם חזינו 'P' וה"אמת" הינה N (שורות 4,7)

מתוך סך המקרים בהם האמת היא N (שורות 3,4,7), כלומר FP = 2/3 = 0.6666

ב. (8 נקודות) טענה: אם נמצא אלגוריתם שפותר לנו באופן מושלם את השורות שבטבלה, הרי שמצאנו אלגוריתם למידה מושלם לבעיה ונוכל לחזות בצורה איכותית מידע חדש בהינתן feature1,feature2,feature3. הסבירו האם נכון או לא. הסבר בנימוקיכם את המושג overfitting.

ב. (8 נקודות) טענה: אם נמצא אלגוריתם שפותר לנו באופן מושלם את השורות שבטבלה, הרי שמצאנו אלגוריתם למידה מושלם לבעיה ונוכל לחזות בצורה איכותית מידע חדש בהינתן feature1,feature2,feature3. הסבירו האם נכון או לא. הסבר בנימוקיכם את המושג overfitting.

פתרון:

הטענה אינה נכונה. אחת הבעיות המרכזיות ב"עולם" הלמידה הינה חוסר היכולת **להכליל** מעולם ה"אימון" לעולם ה"מבחן", כלומר מציאת מודל המתאים בצורה מצויינת לעולם האימון אך לא לעולם המבחן כך ש**בהינתן דוגמא חדשה שהמערכת לא "ראתה" בשלב הלימוד, המערכת לא מסוגלת לחזות את סיווגה בצורה איכותית**.

Overfitting פירושו התאמת המודל באדיקות לעולם האימון ללא יכולת הכללה ו"הבנה" עבור דוגמאות חדשות. הזכרנו במהלך הקורס מס' דוגמאות ל-overfitting למשל הדוגמא של סטודנט לומד למבחן. צריך לזכור גם למשל בהתייחס לטבלה שלמעלה (ובכלל) שבדר"כ אין לנו בשלב האימון את כל הצירופים האפשריים כקלט למערכת.

ג. (7 נקודות) מהם החסרונות של lazy algorithm ? ציינו אלגוריתם lazy שנלמד בקורס והסבירו כיצד הוא פועל.

ג. (7 נקודות) מהם החסרונות של lazy algorithm ? ציינו אלגוריתם lazy שנלמד בקורס והסבירו כיצד הוא פועל.

פתרון:

הזכרנו במהלך הקורס שני חסרונות עיקריים:

"מקום" – נדרש לאחסן את כל דוגמאות האימון גם במכונה שמריצה את האלגוריתם בניגוד לאלגוריתם eager שבו נבנה מודל ואין צורך לשמור את כל הדוגמאות במכונה המריצה.

"זמן ריצה" – בזמן הריצה, אנו עוברים על כל הדוגמאות הקיימות ע"מ לקבוע את הסיווג ולא משתמשים רק בפונק' מתמטית.

למדנו, אלגוריתם K-Nearest-Neighbor שבו בשלב שצריכים לסווג דוגמא חדשה אנו צריכים למצוא את המרחק של הדוגמא החדשה מכל אחד מווקטורי האימון (צריך להגדיר מטריקת מרחק) ולסווג את הדוגמא החדשה עפ"י K השכנים הקרובים ביותר (צריך כמובן להגדיר את K).

Feature1	Feature2	Feature3	Class
0	1	1	P
1	0	0	P
0	0	1	N
1	1	0	N
0	0	0	P
1	1	1	P
1	1	0	N

3. התייחסו לטבלה משאלה 1.

א. (7 נקודות) חשבו את האנתרופיה של class. ניתן להשאיר את הפתרון עם log.

Feature1	Feature2	Feature3	Class
0	1	1	P
1	0	0	P
0	0	1	N
1	1	0	N
0	0	0	P
1	1	1	P
1	1	0	N

3. התייחסו לטבלה משאלה 1.

א. (7 נקודות) חשבו את האנתרופיה של class. ניתן להשאיר את הפתרון עם log.

פתרון:

ההסתברות לקבלת P הינה 4/7. ההסתברות לקבלת N הינה 3/7

$$Entropy(Class) = -\frac{4}{7}\log_2(\frac{4}{7}) - \frac{3}{7}\log_2(\frac{3}{7})$$