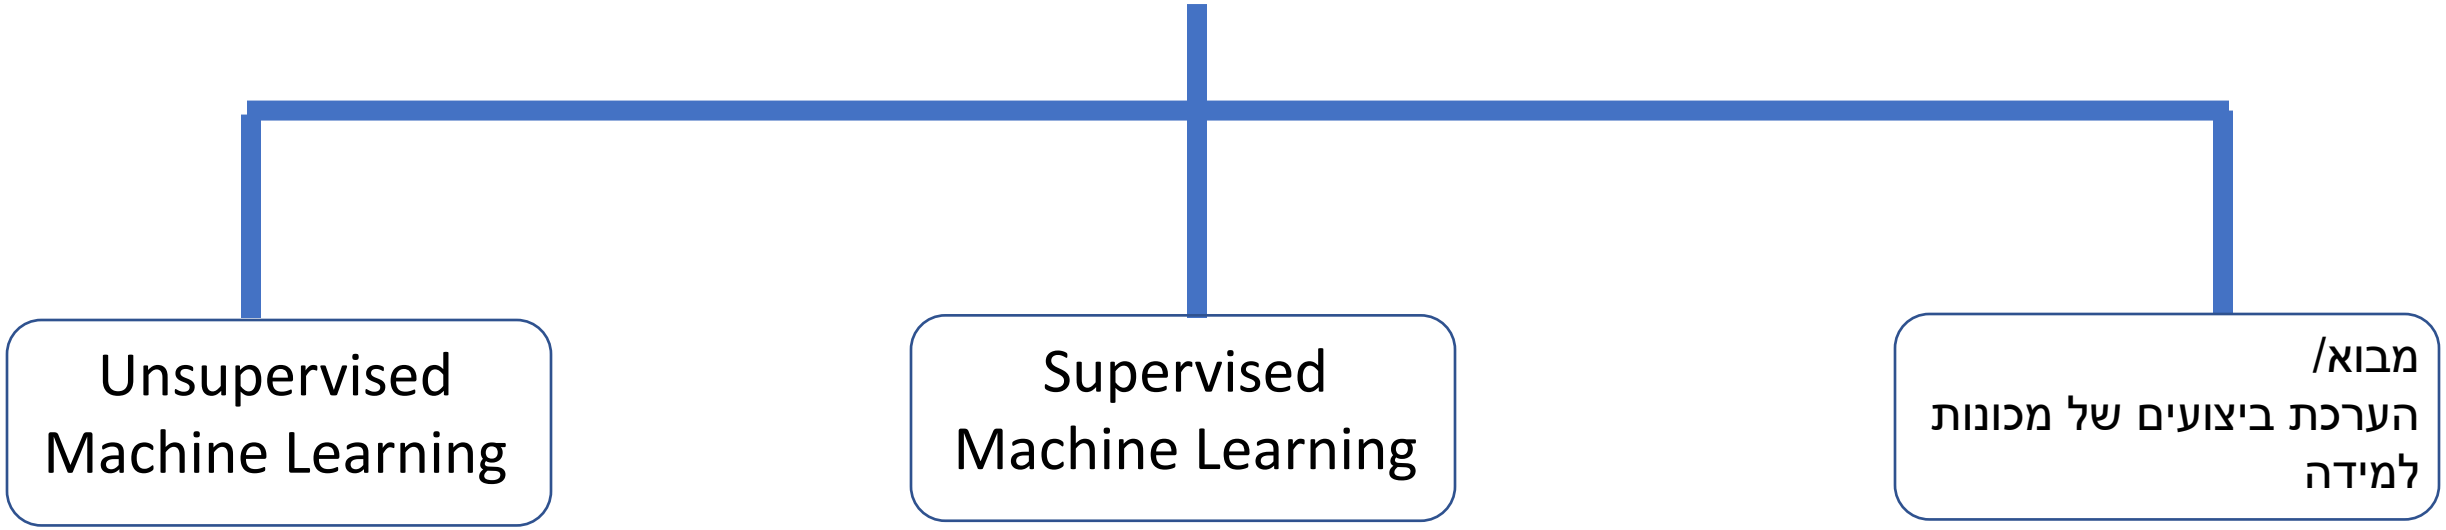
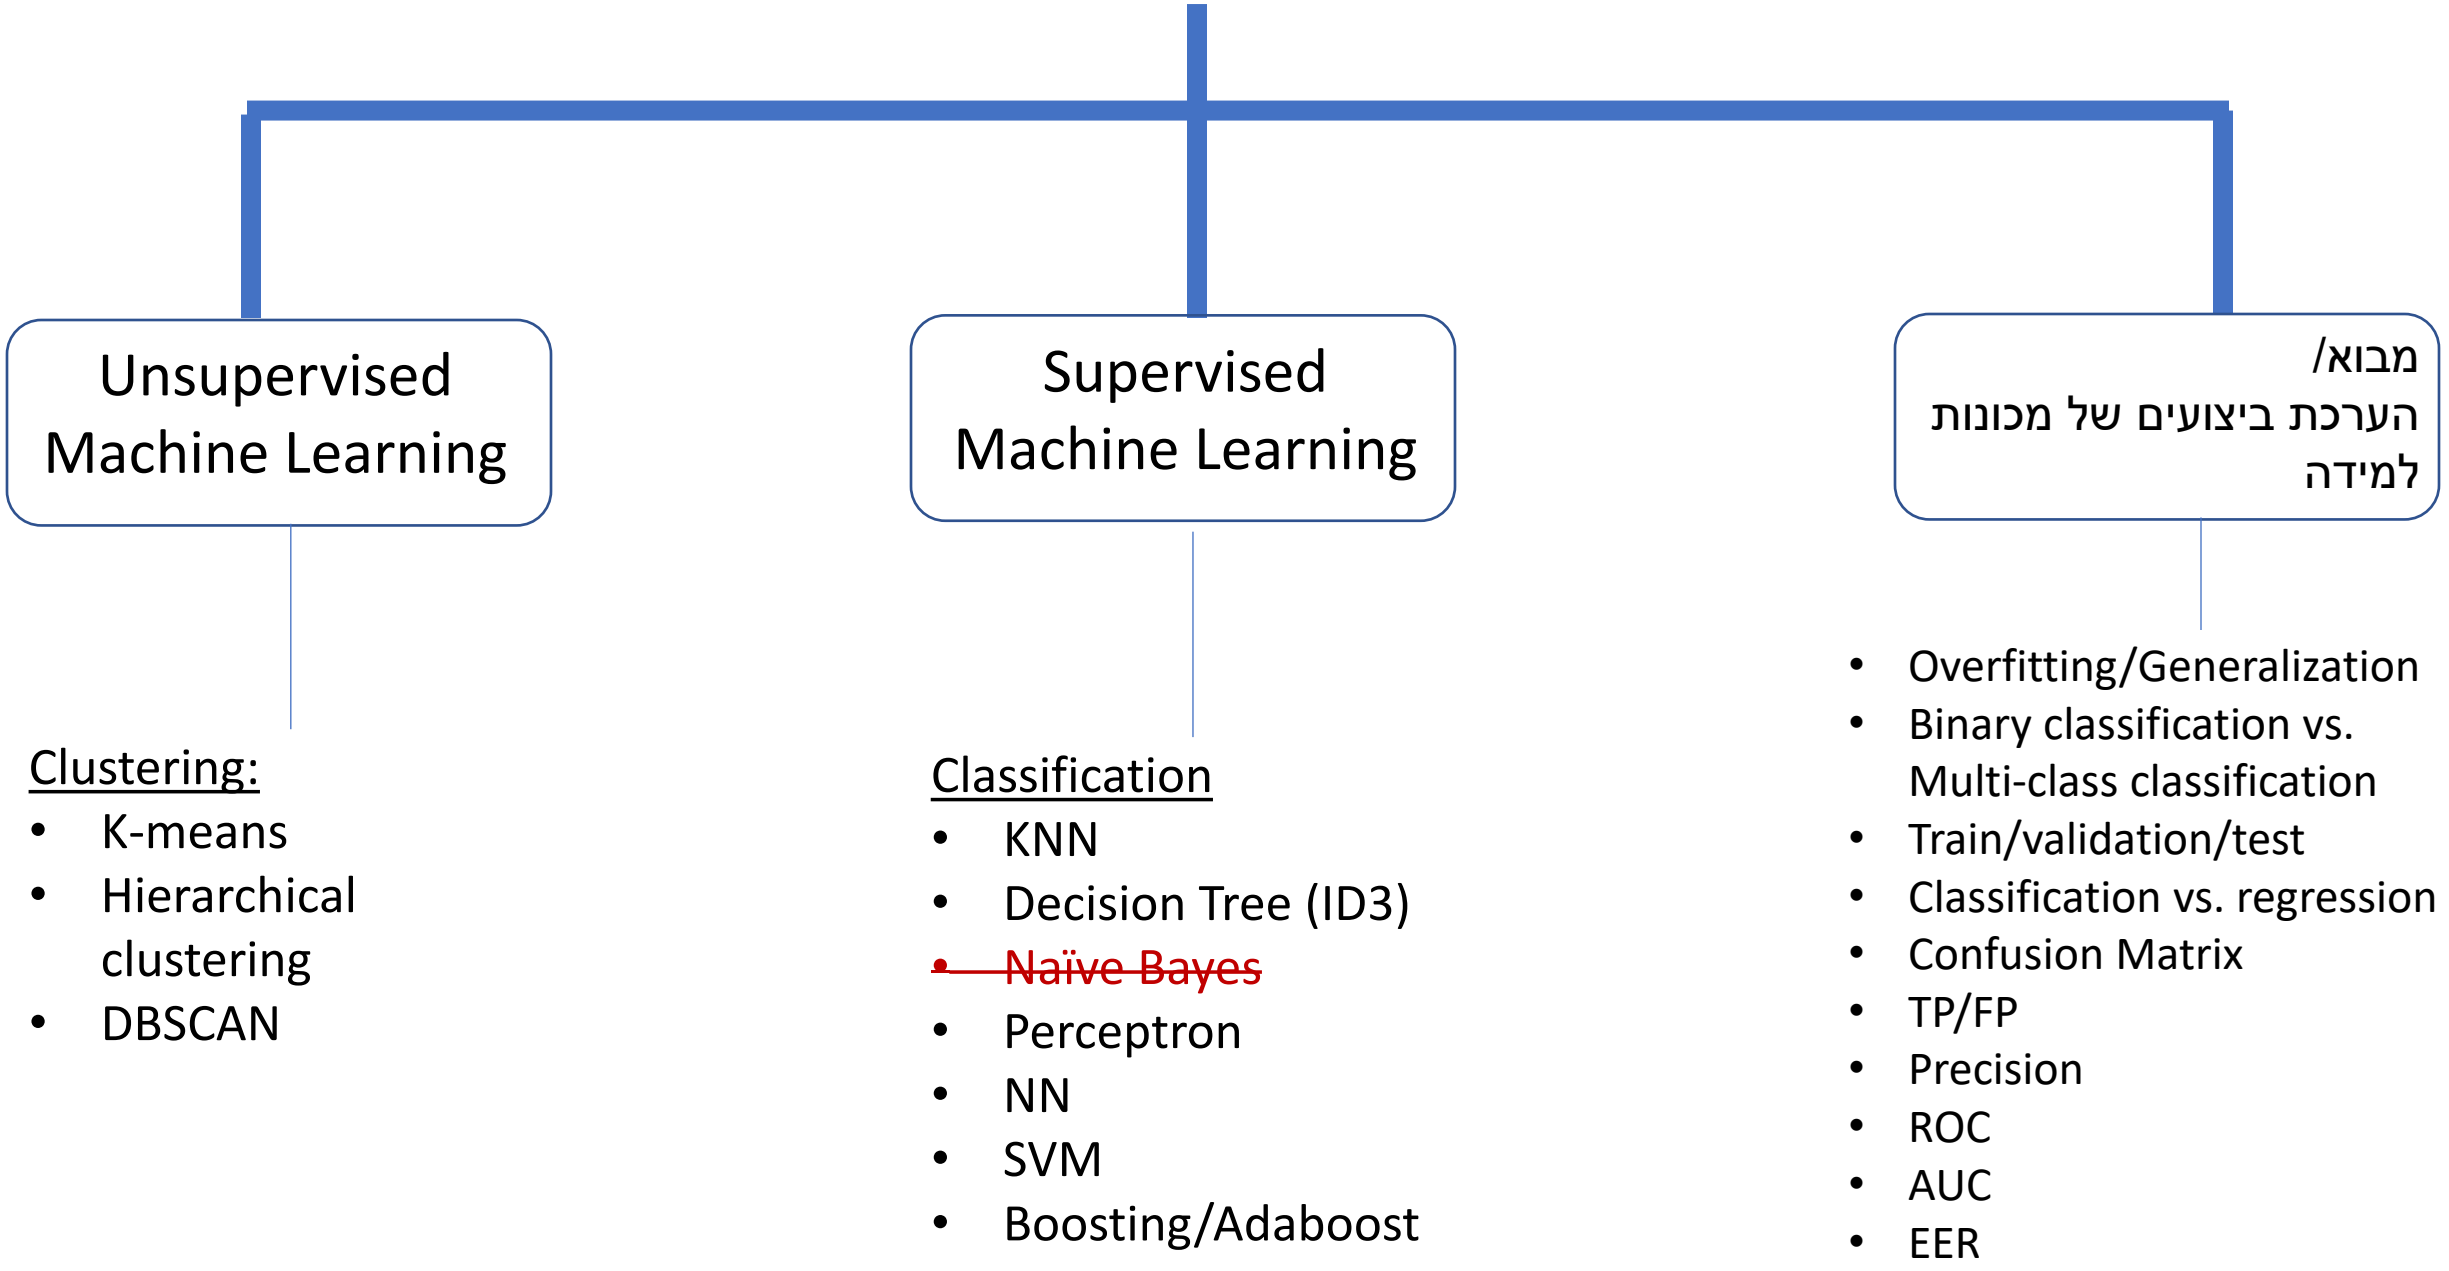
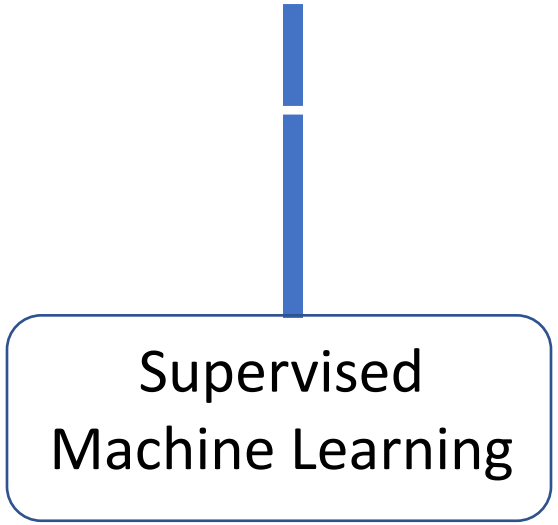
שיעור חזרה

שימו לב:
בחומר למבחן –
גם נושאים/פרטים שלא נסקרים בשיעור החזרה
אך נלמדו במהלך הקורס


מבוא/
הערכת ביצועים של מכונות
למידה
Supervised
Machine Learning
Unsupervised
Machine Learning

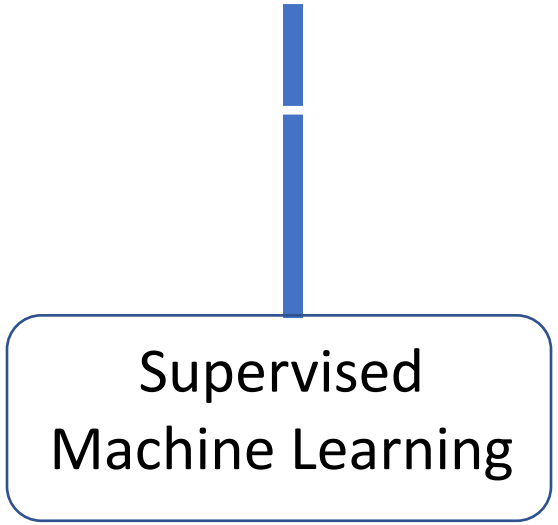

Unsupervised Machine Learning
Supervised Machine Learning
מבוא/
הערכת ביצועים של מכונות למידה
Clustering:
• K-means
• Hierarchical clustering
• DBSCAN
Classification
• KNN
• Decision Tree (ID3)
• ~~Naïve Bayes~~
• Perceptron
• NN
• SVM
• Boosting/Adaboost
• Overfitting/Generalization
• Binary classification vs. Multi-class classification
• Train/validation/test
• Classification vs. regression
• Confusion Matrix
• TP/FP
• Precision
• ROC
• AUC
• EER



מטריקות מרחק, משקול מאפיינים, K,
משקול מרחקים

Classification

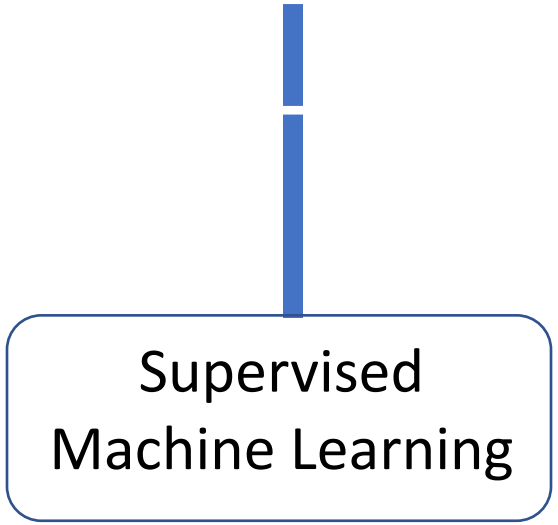
- KNN
- Decision Tree (ID3)
- Naïve Bayes
- Perceptron
- NN
- SVM
- Boosting/Adaboost



Classification

- KNN
- Decision Tree (ID3)
- Naïve Bayes
- Perceptron
- NN
- SVM
- Boosting/Adaboost

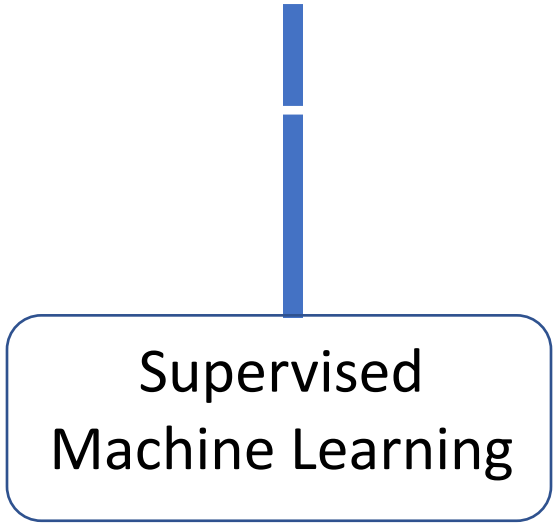
Entropy, Info-Gain, Bayes Rule, Occama's razor, Recursive building, Avoid overfitting



Classification

- KNN
- Decision Tree (ID3)
- ~~Naïve Bayes~~
- Perceptron
- NN
- SVM
- Boosting/Adaboost

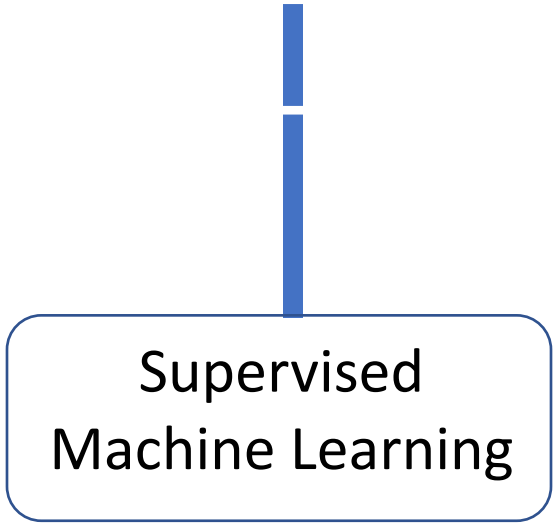
Bayes Rule, Features Independent, underflow, Smoothing



Classification

- KNN
- Decision Tree (ID3)
- Naïve Bayes
- Perceptron
- NN
- SVM
- Boosting/Adaboost

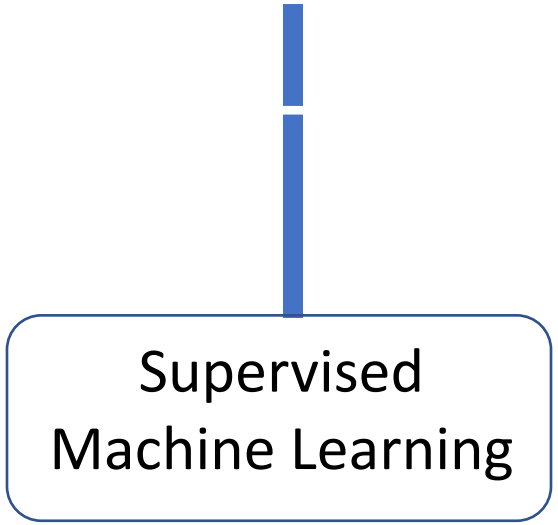
Gradient descent, Loss, Batch mode vs. SGD(ONLINE) Mode, Non-Linearity, משפט ההתכנסות של הפרספטרון



Classification

- KNN
- Decision Tree (ID3)
- Naïve Bayes
- Perceptron
- NN
- SVM
- Boosting/Adaboost

Linear Hard Margin , Soft Margin,
How to find W, Kernel Trick,



Classification

- KNN
- Decision Tree (ID3)
- Naïve Bayes
- Perceptron
- NN
- SVM
- Boosting/Adaboost

הצדקה תיאורטית
Weak classifier
חסם על השגיאה
רגישות ל-outliers

שאלה פתוחה 1 (20 נקודות)

נתונה טבלת האימון הבאה לבעיית סיווג:

Class	f2	f1
P	-4	-2
P	0	-2
P	2	0
P	0	-3
N	2	2
N	-2	2
N	-4	0

א. (7 נק') סווג את הווקטור (w1=1, w2 = 1) עפ"י אלגוריתם KNN עבור הפרמטרים הבאים. יש לפרט החישובים.

a. K=5

b. מטריקת מרחק L1

c. משקול מרחקים של 1/d

פתרון :

נחשב את המרחק של הווקטור (1,1) מכל הווקטורים

	Dist L1 from (1,1)	Class	f2	f1
	|-2-1|+|-4-1| = 8	P	-4	-2
	|-2-1|+|0-1| = 4	P	0	-2
	|0-1|+|2-1| = 2	P	2	0
	|-3-1|+|0-1| = 5	P	0	-3
	|2-1|+|2-1| = 2	N	2	2
	|2-1|+|-2-1| = 4	N	-2	2
	|0-1|+|-4-1| = 6	N	-4	0

5 הווקטורים הקרובים ביותר הם :

P: (0,2) (dist=2), (-2,0) (dist=4), (-3,0)(dist=5)

N: (2,2) (dist=2), (2,-2) (dist=4)

משקול חיוביים :

$$\frac{1}{2}+\frac{1}{4}+\frac{1}{5}$$

משקול שליליים :

$$\frac{1}{2}+\frac{1}{4}$$

משקול החיוביים גדול ממשקול השליליים ולכן נסווג כ-P

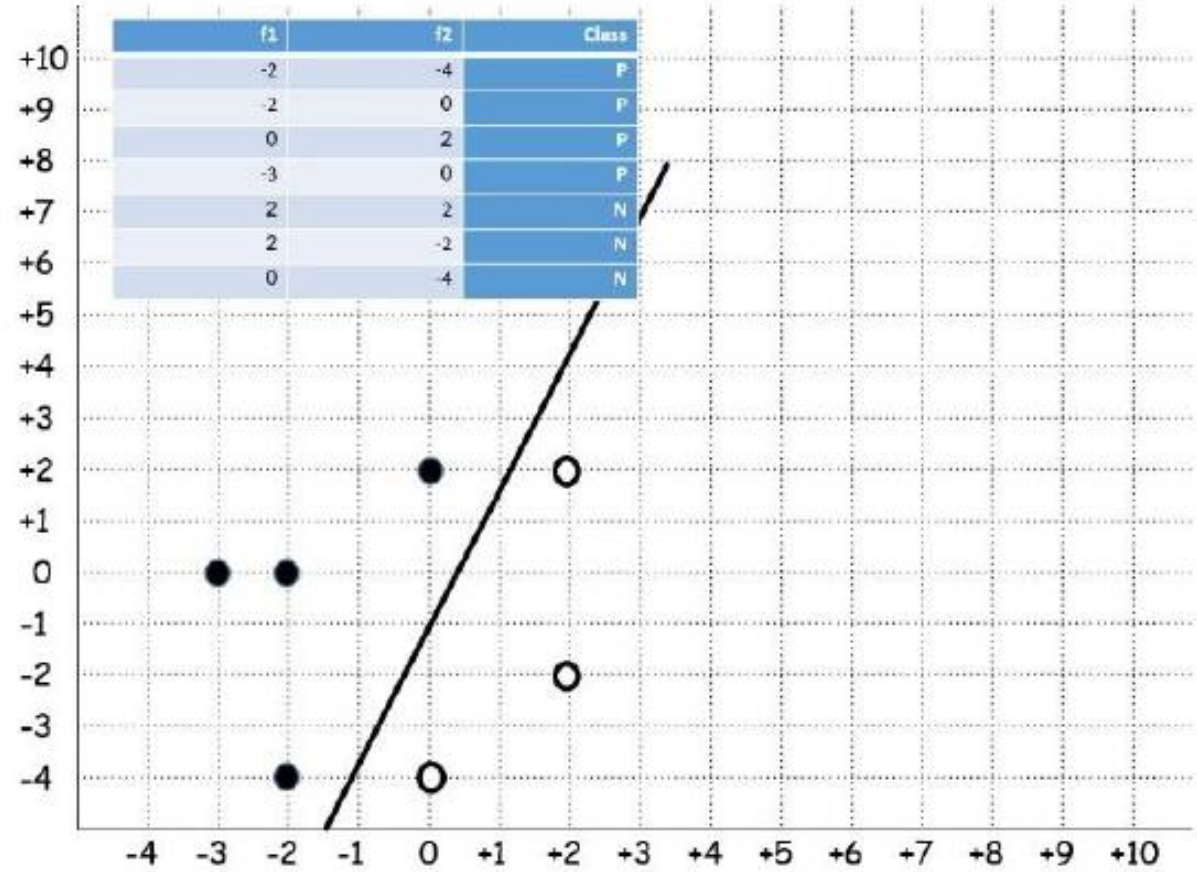
ב. (7 נק') צייר בצורה סכמטית את הווקטורים על גבי מערכת צירים והראה

a. מה יהיה פתרון SVM-HARD-MARGIN. נמק תשובתך

b. הצע פתרון אפשרי ל-SVM-SOFT-MARGIN. נמק תשובתך

ב. (7 נק') צייר בצורה סכמטית את הווקטורים על גבי מערכת צירים והראה

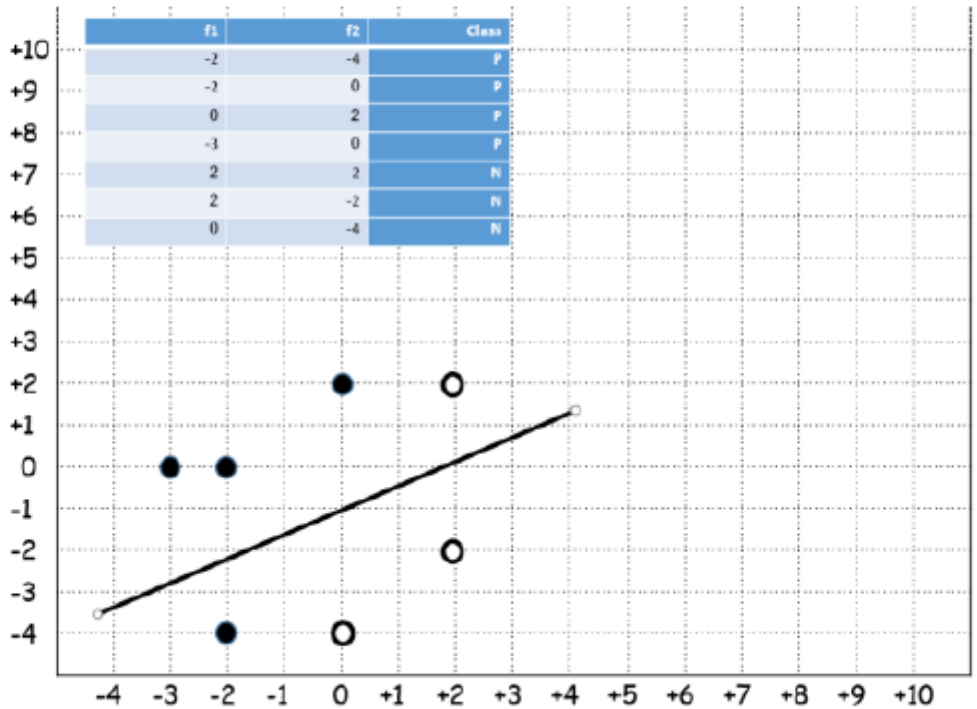
a. מה יהיה פתרון SVM-HARD-MARGIN. נמק תשובתך



b. הצע פתרון אפשרי ל-SVM-SOFT-MARGIN. נמק תשובתך

פתרון זהה לסעיף א'

פתרון נוסף אפשרי :



ג. (6 נק') חשב את %TP, %FP, %TN, %FN עבור משוואת הסיווג $SGN(-1 \times f1 - 2 \times f2 + 3)$ הצג ופרט חישובך.

ג. (6 נק') חשב את %TP, %FP, %TN, %FN עבור משוואת הסיווג $SGN(-1 \times f1 - 2 \times f2 + 3)$ הצג ופרט חישובך.

f1	f2	Class	$-1 \times f1 - 2 \times f2 + 3$	pred
-2	-4	P	13	P
-2	0	P	5	P
0	2	P	-1	N
-3	0	P	6	P
2	2	N	-3	N
2	-2	N	5	P
0	-4	N	11	P

שאלה פתוחה 2 (20 נקודות)

נתונים הווקטורים הבאים:

V1 = (2,10), V2 = (2,5), V3 = (8,4), V4 = (5,8), V5 = (7,5), V6 = (6,4), V7 = (1,2), V8 = (4,9)

מטריצה המפרטת את המרחק בריבוע (האוקלידי) בין כל שני ווקטורים נתונה להלן:

	V1	V2	V3	V4	V5	V6	V7	V8
V1	0	25	36	13	50	52	65	5
V2		0	37	18	25	17	10	20
V3			0	25	2	2	53	41
V4				0	13	17	52	2
V5					0	2	45	25
V6						0	29	29
V7							0	58
V8								0

א. (10 נקודות) הריצו אלגוריתם היררכי bottom-up. שימו לב: כאשר האלגוריתם מאפשר מס' איחודים אפשריים, יש לאחד את כולם באותה איטרציה. יש להציג בכל איטרציה כמה אשכולות התקבלו, ומי האשכולות המתקבלים בתום כל איטרציה. עצרו את האלגוריתם באיטרציה בה המרחק בריבוע הקטן ביותר לאיחוד גדול מ-10

	V1	V2	V3	V4	V5	V6	V7	V8
V1	0	25	36	13	50	52	65	5
V2		0	37	18	25	17	10	20
V3			0	25	2	2	53	41
V4				0	13	17	52	2
V5					0	2	45	25
V6						0	29	29
V7							0	58
V8								0

א. (10 נקודות) הריצו אלגוריתם הירכי bottom-up. שימו לב: כאשר האלגוריתם מאפשר מס' איחודים אפשריים, יש לאחד את כולם באותה איטרציה. יש להציג בכל איטרציה כמה אשכולות התקבלו, ומי האשכולות המתקבלים בתום כל איטרציה. עצרו את האלגוריתם באיטרציה בה המרחק בריבוע הקטן ביותר לאיחוד גדול מ-10

<u>פתרון:</u>

Iteration 1: 8 CLUSTERS: {V1},{V2},{V3},{V4},{V5},{V6},{V7},{V8}

נאחד את כל ה"אשכולות שמרחקן (בריבוע) 2:

Iteration 2: 5 CLUSTERS: {V1},{V2},{V3, V5, V6},{V4,V8},{V7}

נאחד את כל ה"אשכולות שמרחקן (בריבוע) 5:

Iteration 2: 4 CLUSTERS: {V2},{V3, V5, V6},{V4,V8, V1},{V7}

נאחד את כל ה"אשכולות שמרחקן (בריבוע) 10:

Iteration 2: 3 CLUSTERS: {V2, V7},{V3, V5, V6},{V4,V8, V1}

הגענו לתנאי העצירה

	V1	V2	V3	V4	V5	V6	V7	V8
V1	0	25	36	13	50	52	65	5
V2		0	37	18	25	17	10	20
V3			0	25	2	2	53	41
V4				0	13	17	52	2
V5					0	2	45	25
V6						0	29	29
V7							0	58
V8								0

ב. (10 נקודות) הריצו אלגוריתם DBSCAN עם הפרמטרים הבאים MINPTS = 2 (כאשר MINPTS כולל את הווקטור עצמו), $R = \sqrt{3}$ שימו לב שהמרחקים בטבלה הינם מרחקים בריבוע.

שרטט את הווקטורים על גריד בגודל 10X10 , תאר בפירוט את תהליך ההרצה. בסוף התהליך יש לתאר מיהם הווקטורים שיצאו כ-outliers ומיהם האשכולות שהתקבלו בסוף התהליך.

ב. (10 נקודות) הריצו אלגוריתם DBSCAN עם הפרמטרים הבאים MINPTS = 2 (כאשר MINPTS כולל את הווקטור עצמו), $R = \sqrt{3}$ שימו לב שהמרחקים בטבלה הינם מרחקים בריבוע.

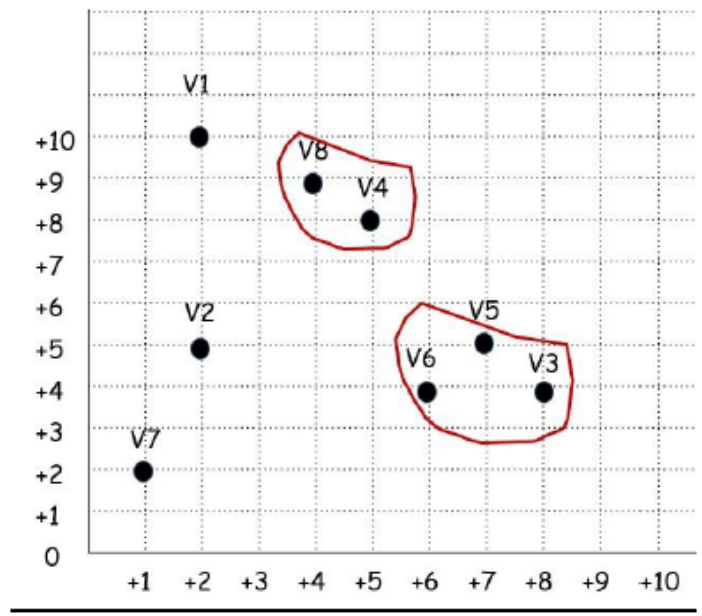
שרטט את הווקטורים על גריד בגודל 10X10 , תאר בפירוט את תהליך ההרצה. בסוף התהליך יש לתאר מיהם הווקטורים שיצאו כ-outliers ומיהם האשכולות שהתקבלו בסוף התהליך.

פתרון:

V1, V2, V7 – אין בסביבתן אף ווקטור ולכן וודאי שאינן core object או border object ולכן הן ווקטורי outliers

V8, V4 נמצאות במרחק $\sqrt{2}$ ולכן עומדות בקריטריוני האיחוד עבור minpts = 2 לכן יאוחדו לאשכול (לא משנה מאיזו נקודה מהן נתחיל)

V3, V5, V6 – גם יאוחדו לאשכול. נניח נתחיל מ-V3. אז V5יאוחד אליו ואז V6 יאוחד לV5. אם נתחיל מ-V5 אז יאוחד אליו V3 ואחכ יאוחד אליו V6



שאלה מספר 1:

נתון ה-confusion matrix הבא:

		Predicted	
		P	N
Actual	P	20	2
	N	10	20

1. %TP = 1/3, %FP = 20/22
2. %TP = 20/22, %FP = 2/3
3. %TP = 12/40, %FP = 40/52
4. %TP = 20/30, %FP = 2/22
5. %TP = 20/22, %FP = 1/3

נתון ה-confusion matrix הבא:

		Predicted	
		P	N
Actual	P	20	2
	N	10	20

$$\%TP = \frac{20}{22}$$

From real Positives, how many were detected as positive

Actual # of positives

$$\%FP = \frac{10}{30}$$

From actual negatives, how many were detected as positive

Actual # of Negatives

נתון ה-confusion matrix הבא:

		Predicted	
		P	N
Actual	P	20	2
	N	10	20

$$\%TP = \frac{\blacksquare}{\blacksquare}$$

נתון ה-confusion matrix הבא:

		Predicted	
		P	N
Actual	P	20	2
	N	10	20

$$\%TP = \frac{\blacksquare}{\blacksquare}$$

Actual # of positives

נתון ה-confusion matrix הבא:

		Predicted	
		P	N
Actual	P	20	2
	N	10	20

$$\%TP = \frac{\square}{22}$$

Actual # of positives

נתון ה-confusion matrix הבא:

		Predicted	
		P	N
Actual	P	20	2
	N	10	20

From real Positives, how many were detected as positive

$$\%TP = \frac{\square}{22}$$

Actual # of positives

נתון ה-confusion matrix הבא:

		Predicted	
		P	N
Actual	P	20	2
	N	10	20

$$\%TP = \frac{20}{22}$$

From real Positives, how many were detected as positive

Actual # of positives

נתון ה-confusion matrix הבא:

		Predicted	
		P	N
Actual	P	20	2
	N	10	20

$$\%TP = \frac{20}{22}$$

From real Positives, how many were detected as positive

Actual # of positives

$$\%FP = \frac{}{30}$$

Actual # of Negatives

נתון ה-confusion matrix הבא:

		Predicted	
		P	N
Actual	P	20	2
	N	10	20

$$\%TP = \frac{20}{22}$$

From real Positives, how many were detected as positive

Actual # of positives

$$\%FP = \frac{10}{30}$$

From actual negatives, how many were detected as positive

Actual # of Negatives

נתון ה-confusion matrix הבא:

		Predicted	
		P	N
Actual	P	20	2
	N	10	20

$$Precision = \frac{\blacksquare}{\blacksquare}$$

נתון ה-confusion matrix הבא:

		Predicted	
		P	N
Actual	P	20	2
	N	10	20

$$Precision = \frac{20}{30}$$

#of real detections

Total # of detections

שאלה מספר 1:

נתון ה-confusion matrix הבא:

		Predicted	
		P	N
Actual	P	20	2
	N	10	20

1. %TP = 1/3, %FP = 20/22
2. %TP = 20/22, %FP = 2/3
3. %TP = 12/40, %FP = 40/52
4. %TP = 20/30, %FP = 2/22
5. %TP = 20/22, %FP = 1/3

<u>שאלה מספר 2:</u>

אלגוריתם עץ החלטה ID3. בחר את התשובה המדוייקת ביותר

1. ככל שנוסיף יותר רמות בעץ – העץ יטה למצב *overfitting*-
2. עד רמה מסויימת בעץ – העץ יהיה מוצלח בהיבטי *overfitting*-, מרמה מסויימת בעץ - העץ יטה למצב - *overfitting*
3. אין קשר בין מס' הרמות בעץ ל-*overfitting* ✗
4. ככל שנוסיף יותר רמות בעץ – העץ יהיה מוצלח יותר בהיבטי *overfitting*-
5. עד רמה מסויימת בעץ – העץ יטה למצב של *overfitting*-, מרמה מסויימת בעץ - העץ יטה למצב *overfitting*-

שאלה מספר 2:

אלגוריתם עץ החלטה ID3. בחר את התשובה המדוייקת ביותר

1. ככל שנוסיף יותר רמות בעץ – העץ יטה למצב *overfitting*-
2. עד רמה מסויימת בעץ – העץ יהיה מוצלח בהיבטי *overfitting*-, מרמה מסויימת בעץ - העץ יטה למצב - *overfitting*
3. ✗ אין קשר בין מס' הרמות בעץ ל-*overfitting*
4. ✗ ככל שנוסיף יותר רמות בעץ – העץ יהיה מוצלח יותר בהיבטי *overfitting*-
5. עד רמה מסויימת בעץ – העץ יטה למצב של *overfitting*-, מרמה מסויימת בעץ - העץ יטה למצב *overfitting*-

שאלה מספר 2:

אלגוריתם עץ החלטה ID3. בחר את התשובה המדוייקת ביותר

1. ככל שנוסיף יותר רמות בעץ – העץ יטה למצב *overfitting*-
2. עד רמה מסויימת בעץ – העץ יהיה מוצלח בהיבטי *overfitting*-, מרמה מסויימת בעץ - העץ יטה למצב - *overfitting*
3. ✗ אין קשר בין מס' הרמות בעץ ל-*overfitting*
4. ✗ ככל שנוסיף יותר רמות בעץ – העץ יהיה מוצלח יותר בהיבטי *overfitting*-
5. עד רמה מסויימת בעץ – העץ יטה למצב של *overfitting*-, מרמה מסויימת בעץ - העץ יטה למצב *overfitting*-

שאלה מספר 2:

אלגוריתם עץ החלטה ID3. בחר את התשובה המדוייקת ביותר

1. ככל שנוסיף יותר רמות בעץ – העץ יטה למצב *overfitting*-
2. עד רמה מסויימת בעץ – העץ יהיה מוצלח בהיבטי *overfitting*-, מרמה מסויימת בעץ - העץ יטה למצב - *overfitting*
3. ✗ אין קשר בין מס' הרמות בעץ ל-*overfitting*
4. ✗ ככל שנוסיף יותר רמות בעץ – העץ יהיה מוצלח יותר בהיבטי *overfitting*-
5. ✗ עד רמה מסויימת בעץ – העץ יטה למצב של *overfitting*-, מרמה מסויימת בעץ - העץ יטה למצב *overfitting*-

שאלה מספר 2:

אלגוריתם עץ החלטה ID3. בחר את התשובה המדוייקת ביותר

1. ככל שנוסיף יותר רמות בעץ – העץ יטה למצב *overfitting*- ✗
2. עד רמה מסויימת בעץ – העץ יהיה מוצלח בהיבטי *overfitting*- , מרמה מסויימת בעץ - העץ יטה למצב - *overfitting*
3. אין קשר בין מס' הרמות בעץ ל-*overfitting* ✗
4. ככל שנוסיף יותר רמות בעץ – העץ יהיה מוצלח יותר בהיבטי *overfitting*- ✗
5. עד רמה מסויימת בעץ – העץ יטה למצב של *overfitting*- , מרמה מסויימת בעץ - העץ יטה למצב *overfitting*- ✗

שאלה מספר 2:

אלגוריתם עץ החלטה ID3. בחר את התשובה המדוייקת ביותר

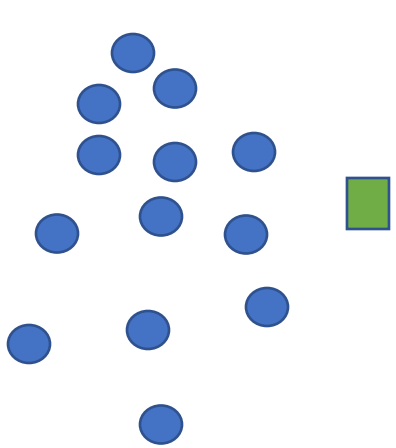
1. ככל שנוסיף יותר רמות בעץ – העץ יטה למצב *overfitting*-
2. עד רמה מסויימת בעץ – העץ יהיה מוצלח בהיבטי *overfitting*-, מרמה מסויימת בעץ - העץ יטה למצב - *overfitting*
3. אין קשר בין מס' הרמות בעץ ל-*overfitting*
4. ככל שנוסיף יותר רמות בעץ – העץ יהיה מוצלח יותר בהיבטי *overfitting*-
5. עד רמה מסויימת בעץ – העץ יטה למצב של *overfitting*-, מרמה מסויימת בעץ - העץ יטה למצב *overfitting*-

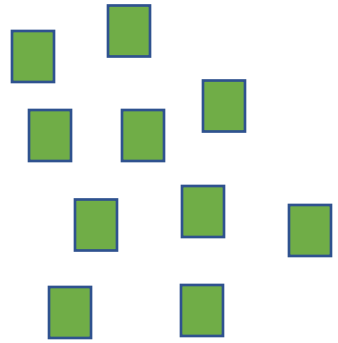
שאלה מספר 3:

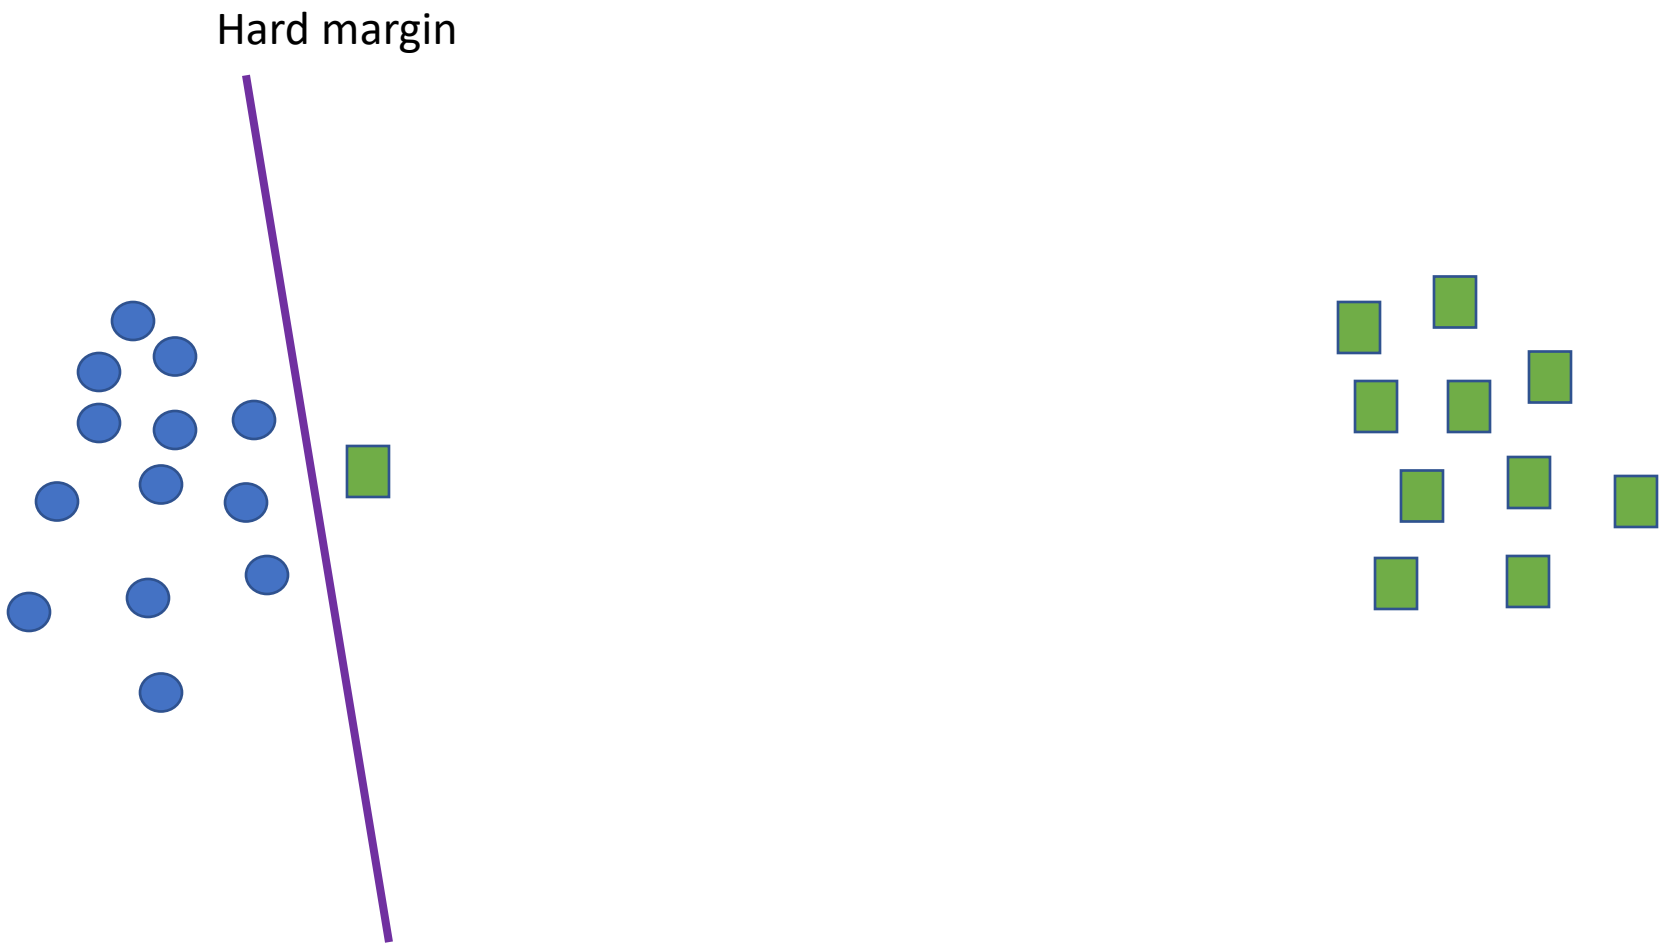
באלגוריתם svm-soft-margin

1. רק כאשר אין הפרדה לינארית יהיה טוב יותר מאלגוריתם הפרספטרון ללא תלות ב-C שנבחר
2. אנו משקללים את ה *margin* עם סכום מרחקי ה"טעויות" מהמישור שלהם
3. אנו משקללים את ה *margin* עם מספר ה"טעויות" המתקבל
4. לעולם יהיה טוב יותר מאלגוריתם הפרספטרון ללא תלות ב-C שנבחר
5. כאשר יש הפרדה לינארית, לעולם לא נשתמש ב-svm-soft-margin

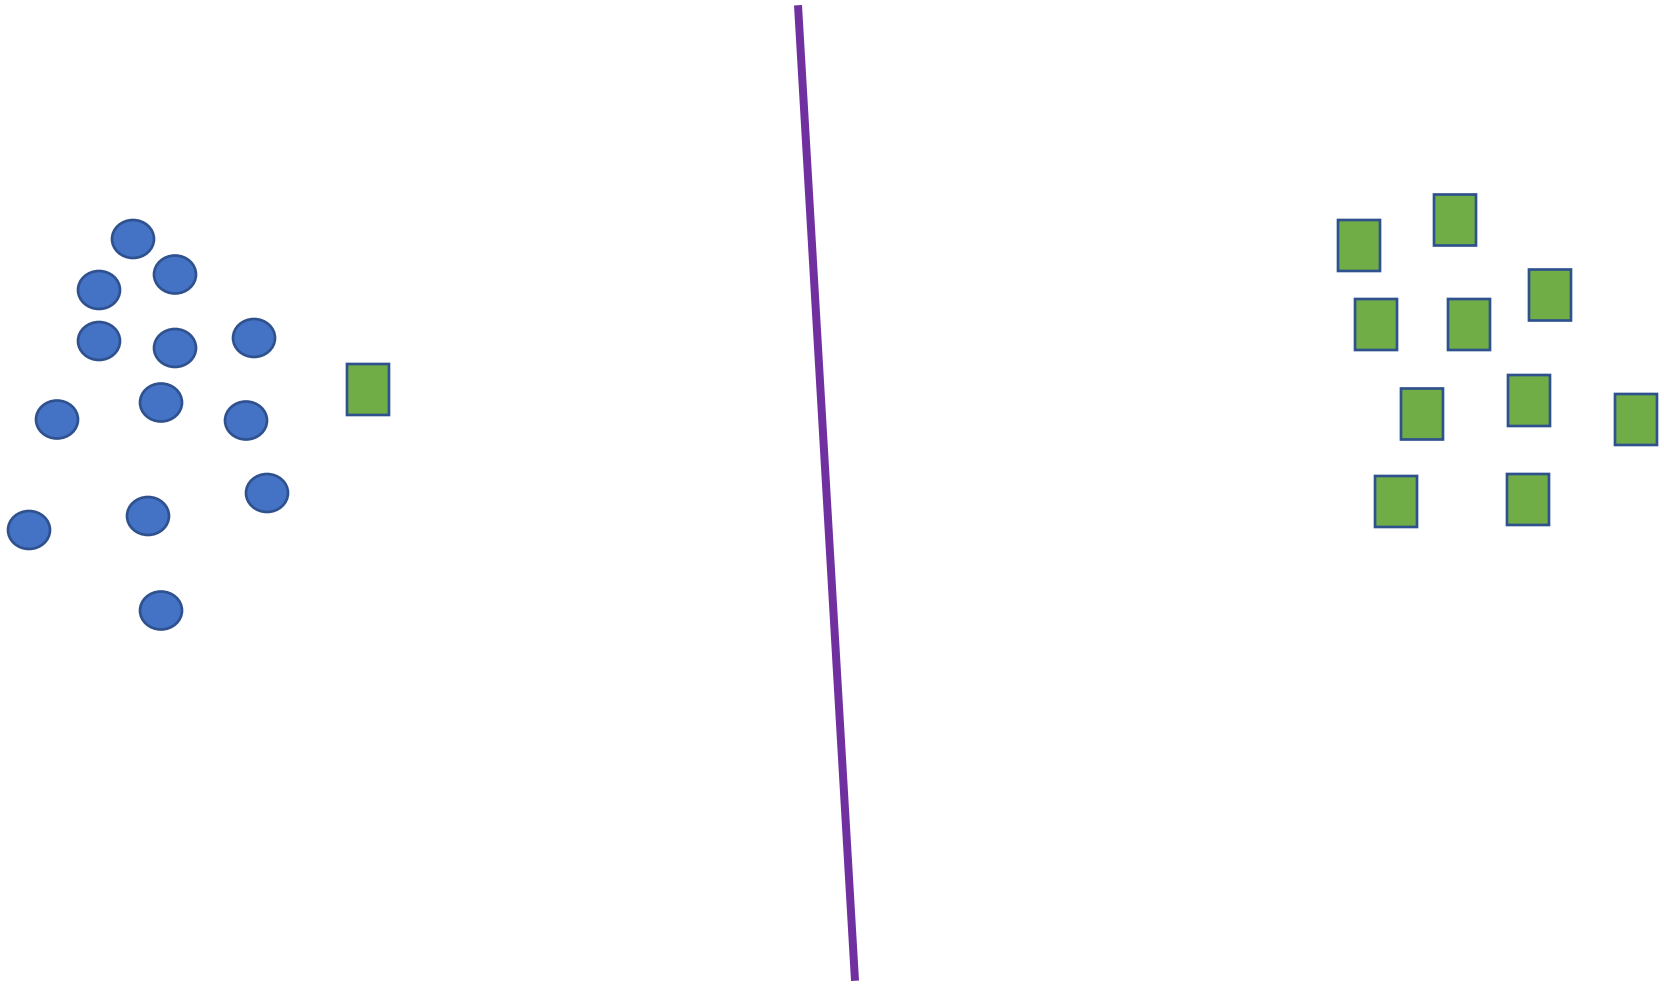







Hard margin

soft margin

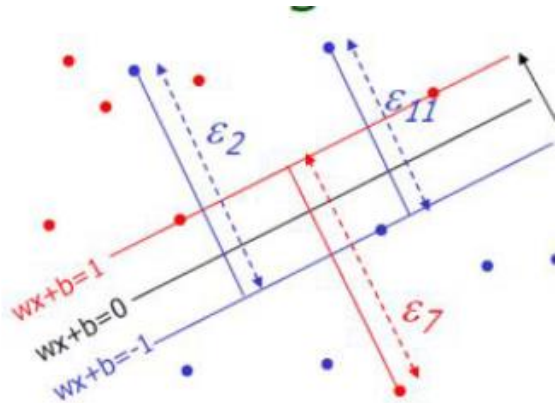


שאלה מספר 3:

באלגוריתם svm-soft-margin

1. רק כאשר אין הפרדה לינארית יהיה טוב יותר מאלגוריתם הפרספטרון ללא תלות ב-C שנבחר
2. אנו משקללים את ה *margin* עם סכום מרחקי ה"טעויות" מהמישור שלהם
3. ⊗ אנו משקללים את ה *margin* עם מספר ה"טעויות" המתקבל
4. לעולם יהיה טוב יותר מאלגוריתם הפרספטרון ללא תלות ב-C שנבחר
5. ⊗ כאשר יש הפרדה לינארית, לעולם לא נשתמש ב-svm-soft-margin

Minimize $$\frac{1}{2} w \cdot w + C \sum_{k=1}^{R} \varepsilon_k$$



Distance

שאלה מספר 3:

באלגוריתם svm-soft-margin

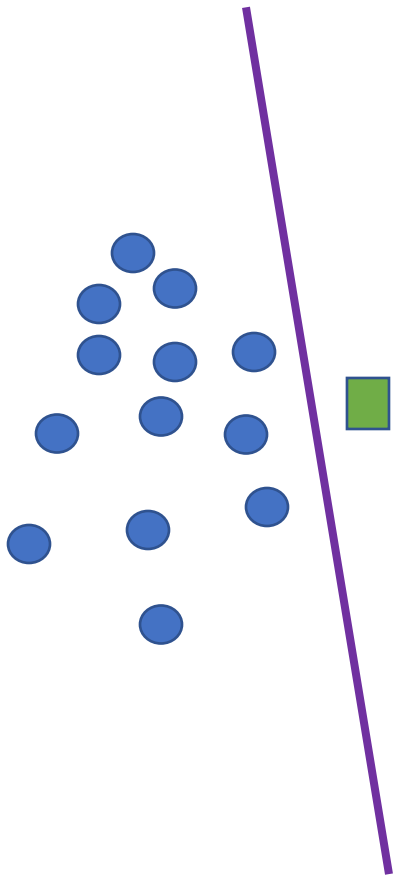
1. רק כאשר אין הפרדה לינארית יהיה טוב יותר מאלגוריתם הפרספטרון ללא תלות ב-C שנבחר
2. אנו משקללים את ה *margin* עם סכום מרחקי ה"טעויות" מהמישור שלהם
3. ⊗ אנו משקללים את ה *margin* עם מספר ה"טעויות" המתקבל
4. ⊗ לעולם יהיה טוב יותר מאלגוריתם הפרספטרון ללא תלות ב-C שנבחר
5. ⊗ כאשר יש הפרדה לינארית, לעולם לא נשתמש ב-svm-soft-margin

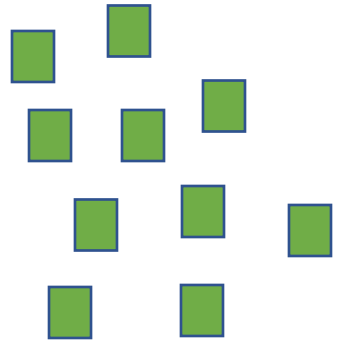
שאלה מספר 3:

באלגוריתם svm-soft-margin

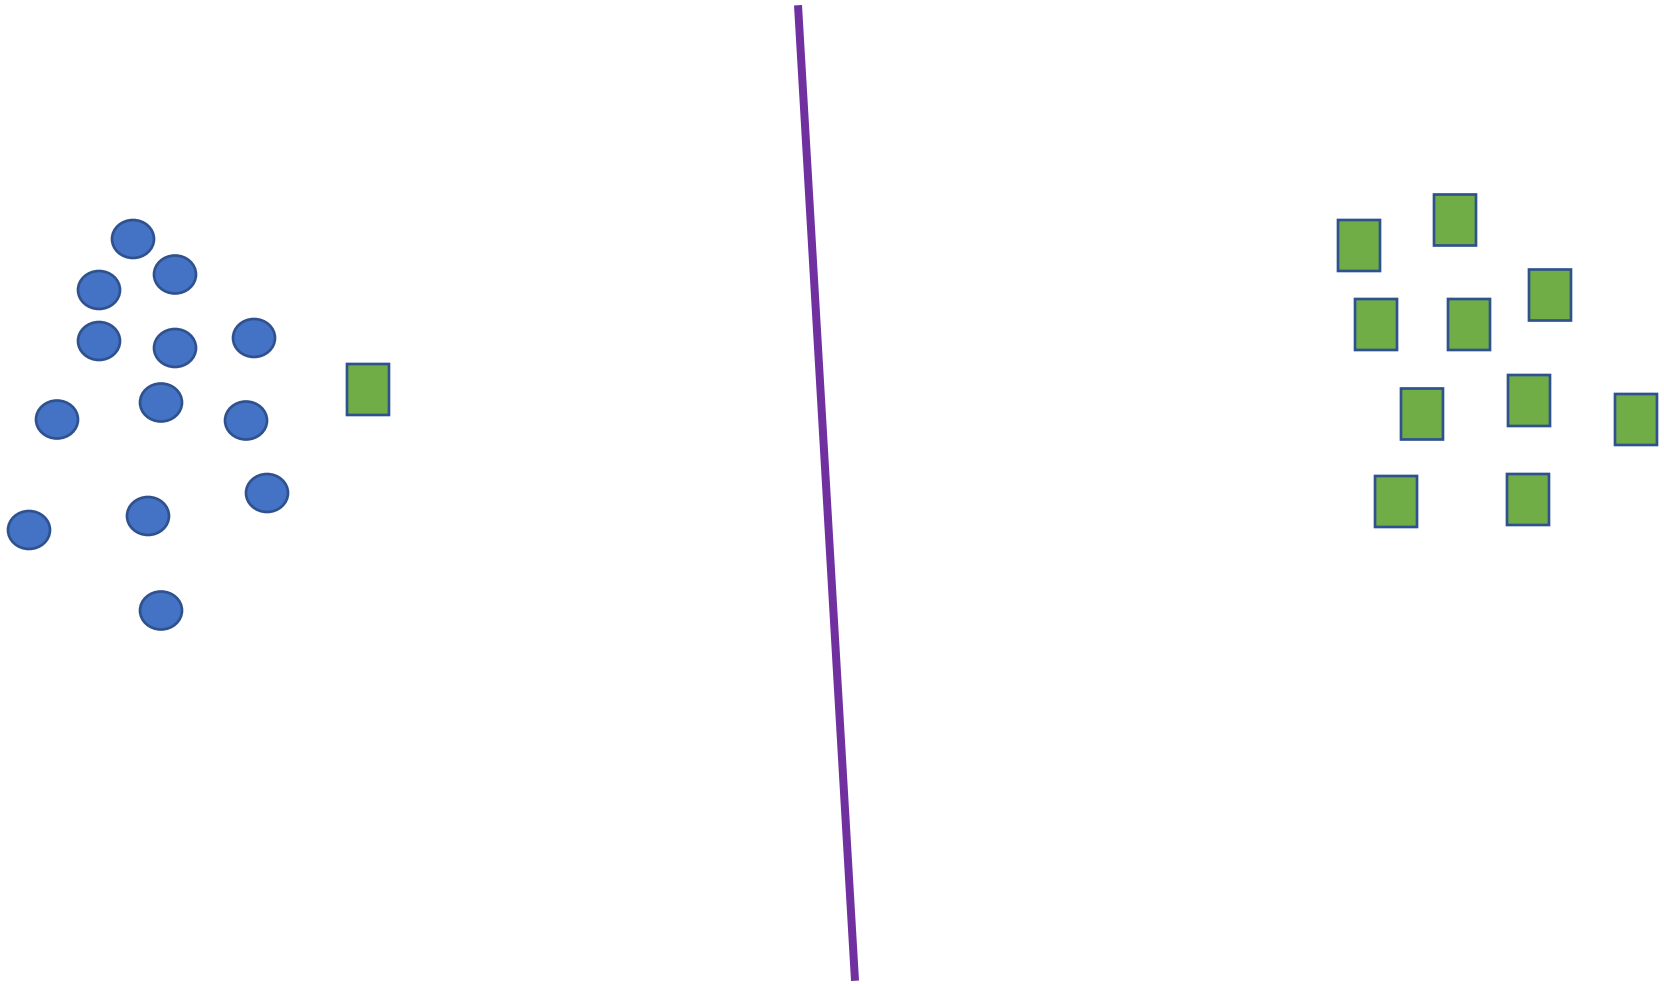
1. רק כאשר אין הפרדה לינארית יהיה טוב יותר מאלגוריתם הפרספטרון ללא תלות ב-C שנבחר
2. אנו משקללים את ה *margin* עם סכום מרחקי ה"טעויות" מהמישור שלהם
3. אנו משקללים את ה *margin* עם מספר ה"טעויות" המתקבל
4. לעולם יהיה טוב יותר מאלגוריתם הפרספטרון ללא תלות ב-C שנבחר
5. כאשר יש הפרדה לינארית, לעולם לא נשתמש ב-svm-soft-margin

Perceptron





soft margin



שאלה מספר 3:

באלגוריתם svm-soft-margin

1. רק כאשר אין הפרדה לינארית יהיה טוב יותר מאלגוריתם הפרספטרון ללא תלות ב-C שנבחר
2. אנו משקללים את ה *margin* עם סכום מרחקי ה"טעויות" מהמישור שלהם
3. אנו משקללים את ה *margin* עם מספר ה"טעויות" המתקבל
4. לעולם יהיה טוב יותר מאלגוריתם הפרספטרון ללא תלות ב-C שנבחר
5. כאשר יש הפרדה לינארית, לעולם לא נשתמש ב-svm-soft-margin

שאלה מספר 4:

אלגוריתם KMEANS

1. תמיד מובטח לנו שנגיע לdistortion הטוב ביותר
2. בסוף תהליך ההרצה, אם לא נוסיף תנאי עצירה, כל הווקטורים יהיו אשכול אחד
3. בסוף תהליך ההרצה, מס' האשכולות יהיה שווה לחצי מס' הווקטורים
4. ככל שערכו של K שואף למס' הוקטורים צפוי שה- distortion יגדל
5. ככל שערכו של K שואף למס' הוקטורים צפוי שה- distortion יקטן

שאלה מספר 4:

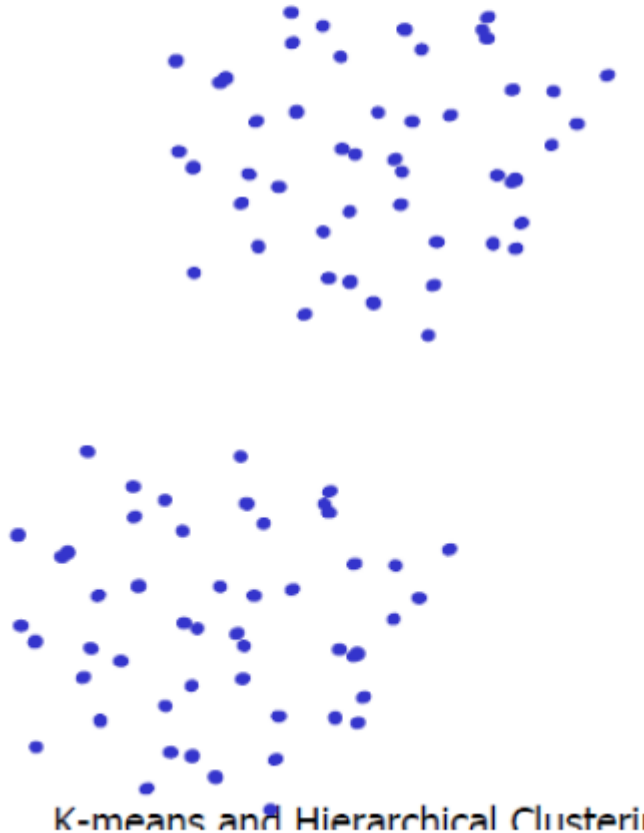
אלגוריתם KMEANS

1. תמיד מובטח לנו שנגיע לdistortion הטוב ביותר
2. בסוף תהליך ההרצה, אם לא נוסיף תנאי עצירה, כל הווקטורים יהיו אשכול אחד
3. בסוף תהליך ההרצה, מס' האשכולות יהיה שווה לחצי מס' הווקטורים
4. ככל שערכו של K שואף למס' הוקטורים צפוי שה- distortion יגדל
5. ככל שערכו של K שואף למס' הוקטורים צפוי שה- distortion יקטן

האם מובטח לנו למצוא את הקונפיגורציה האופטימאלית?

- לא בהכרח

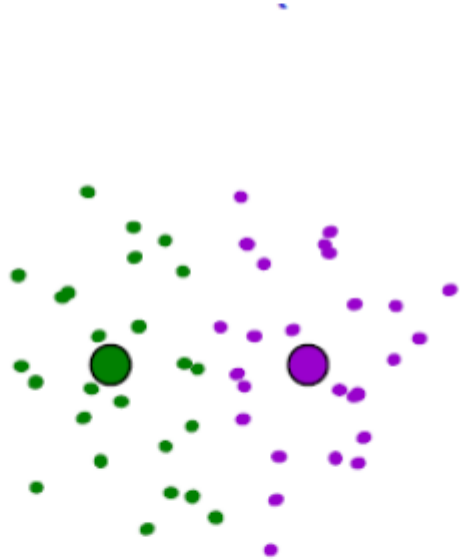


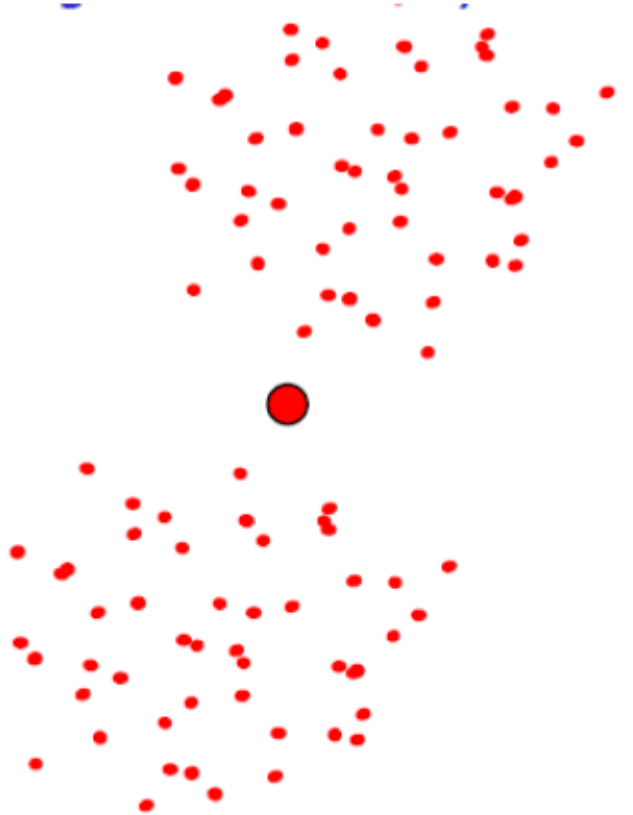


http://www.autonlab.org/tutorials/kmeans.html

K-means and Hierarchical Clustering

האם מובטח לנו למצוא את הקונפיגורציה האופטימאלית?





http://www.autonlab.org/tutorials/kmeans.html

K-means and Hierarchical Cluster

שאלה מספר 4:

אלגוריתם KMEANS

1. תמיד מובטח לנו שנגיע לdistortion הטוב ביותר
2. בסוף תהליך ההרצה, אם לא נוסיף תנאי עצירה, כל הווקטורים יהיו אשכול אחד
3. בסוף תהליך ההרצה, מס' האשכולות יהיה שווה לחצי מס' הווקטורים
4. ככל שערכו של K שואף למס' הוקטורים צפוי שה- distortion יגדל
5. ככל שערכו של K שואף למס' הוקטורים צפוי שה- distortion יקטן

Distortion =

$$\sum_{i=1}^{R}(x_i - center(x_i\ ))^2$$

שאלה

- אחד הקשיים באלגוריתם K-means הוא מציאת K
- מציעים לנו את האלגוריתם הבא:
  - נסה כל k אפשרי עד למציאת k שמביא אותנו למינימום סטיה (distortion)
- האם האלגוריתם טוב ?

- תשובה: כמובן אלגוריתם לא טוב.
  - יתכנס ל-k=n

שאלה מספר 4:

אלגוריתם KMEANS

1. תמיד מובטח לנו שנגיע לdistortion הטוב ביותר
2. בסוף תהליך ההרצה, אם לא נוסיף תנאי עצירה, כל הווקטורים יהיו אשכול אחד
3. בסוף תהליך ההרצה, מס' האשכולות יהיה שווה לחצי מס' הווקטורים
4. ככל שערכו של K שואף למס' הוקטורים צפוי שה- distortion יגדל
5. ככל שערכו של K שואף למס' הוקטורים צפוי שה- distortion יקטן

<u>שאלה מספר 4:</u>

אלגוריתם KMEANS

1. תמיד מובטח לנו שנגיע לdistortion הטוב ביותר
2. בסוף תהליך ההרצה, אם לא נוסיף תנאי עצירה, כל הווקטורים יהיו אשכול אחד
3. בסוף תהליך ההרצה, מס' האשכולות יהיה שווה לחצי מס' הווקטורים
4. ככל שערכו של K שואף למס' הוקטורים צפוי שה- distortion יגדל
5. ככל שערכו של K שואף למס' הוקטורים צפוי שה- distortion יקטן

שאלה מספר 6:

נתונה טבלת האימון הבאה:

מס' דוגמא	x1	x2	x3	class
1	2	1	2	P
2	1	2	2	P
3	2	1	2	P
4	1	2	2	N
5	2	2	2	N
6	1	2	2	N

מהו המאפיין עם האנתרופיה **הנמוכה** ביותר $H(class|x_j)$. אין צורך במחשבון אלא רק בהבנה של המונח אנתרופיה

1. *x2*
2. *x3*
3. *x1*
4. ל-*x2* ו-*x3* אותה האנתרופיה והיא הנמוכה
5. ל-*x1* ו-*x3* אותה האנתרופיה והיא הנמוכה

שאלה מספר 6:

נתונה טבלת האימון הבאה:

מס' דוגמא	x1	x2	x3	class
1	2	1	2	P
2	1	2	2	P
3	2	1	2	P
4	1	2	2	N
5	2	2	2	N
6	1	2	2	N

מהו המאפיין עם האנתרופיה **הנמוכה** ביותר $H(class|x_i)$. אין צורך במחשבון אלא רק בהבנה של המונח אנתרופיה

1. *x2*
2. *x3*
3. *x1*
4. ל-*x2* ו-*x3* אותה האנתרופיה והיא הנמוכה
5. ל-*x1* ו-*x3* אותה האנתרופיה והיא הנמוכה

X3 – ניתן לראות שידיעת ערכו לא משפיע על הוודאות שיש לנו בחיזוי

שאלה מספר 6:

נתונה טבלת האימון הבאה:

מס' דוגמא	x1	x2	x3	class
1	2	1	2	P
2	1	2	2	P
3	2	1	2	P
4	1	2	2	N
5	2	2	2	N
6	1	2	2	N

מהו המאפיין עם האנתרופיה **<u>הנמוכה</u>** ביותר $H(class|x_i)$. אין צורך במחשבון אלא רק בהבנה של המונח אנתרופיה

1. *x2*
2. *x3*
3. *x1*
4. ל-*x2* ו-*x3* אותה האנתרופיה והיא הנמוכה
5. ל-*x1* ו-*x3* אותה האנתרופיה והיא הנמוכה

X2 – רואים שכאשר ערכו 2 אז בוודאות N, כאשר ערכו 1 אז $\frac{2}{3}$ P

X3 – רואים שכאשר ערכו 2 אז $\frac{2}{3}$ P, , כאשר ערכו 1 אז $\frac{2}{3}$ N

לכן ברור שידיעת X2- משפרת לנו את החיזוי וחסר הוודאות בצורה הטובה ביותר.

שאלה מספר 7:

נתונה לנו משוואת הסיווג עבור SVM עם טריק הקרנל:

$$y(x) = SGN(\sum_{i=1}^{3}(y_i \propto_i K(x_i,x) - 0)$$

נתונים ה-SV שהתגלו (לא נתוני אמת – רק לצורך השאלה בבחינה)

	$\propto_i$	x_i
P	0.5	(1,1,1)
N	0.3	(0,0,0)

ונתון הקרנל $K = (a \cdot b + 1)^2$

כיצד יסווג הווקטור (2,2,2)

1. אין מספיק נתונים כדי לפתור
2. תוצאה 0, ולכן הסתברות זהה ל-P ול-N
3. תלוי במקדם ההחלקה
4. N
5. P

שאלה מספר 7:

נתונה לנו משוואת הסיווג עבור SVM עם טריק הקרנל:

$$y(x) = SGN(\sum_{i=1}^{3}(y_i \propto_i K(x_i,x) - 0)$$

נתונים ה-SV שהתגלו (לא נתוני אמת – רק לצורך השאלה בבחינה)

	$\propto_i$	x_i
P	0.5	(1,1,1)
N	0.3	(0,0,0)

ונתון הקרנל $K = (a \cdot b + 1)^2$

כיצד יסווג הווקטור (2,2,2)

1. אין מספיק נתונים כדי לפתור
2. תוצאה 0, ולכן הסתברות זהה ל-P ול-N
3. תלוי במקדם ההחלקה
4. N
5. P

$$y(2,2,2) = SGN(\alpha_1 y_1 K[(2,2,2)(x_1)] + \alpha_2 y_2 K[(2,2,2)(x_2)] - 0) =$$

Positive

שאלה מספר 7:

נתונה לנו משוואת הסיווג עבור SVM עם טריק הקרנל:

$$y(x) = SGN(\sum_{i=1}^{3}(y_i \propto_i K(x_i,x) - 0)$$

נתונים ה-SV שהתגלו (לא נתוני אמת – רק לצורך השאלה בבחינה)

	$\propto_i$	x_i
P	0.5	(1,1,1)
N	0.3	(0,0,0)

ונתון הקרנל $K = (a \cdot b + 1)^2$

כיצד יסווג הווקטור (2,2,2)

1. אין מספיק נתונים כדי לפתור
2. תוצאה 0, ולכן הסתברות זהה ל-P ול-N
3. תלוי במקדם ההחלקה
4. N
5. P

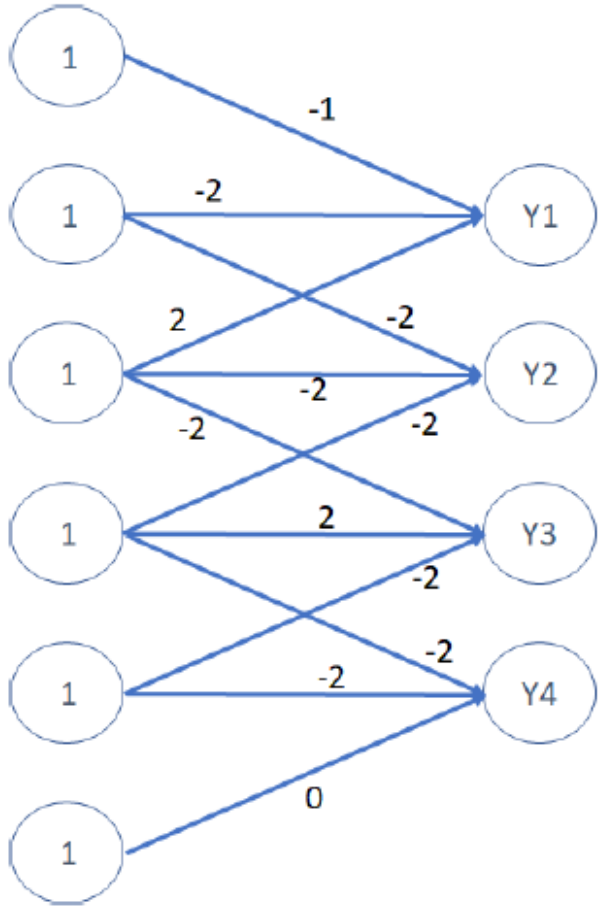
$$y(2,2,2) = SGN(\alpha_1 y_1 K[(2,2,2)(x_1)] + \alpha_2 y_2 K[(2,2,2)(x_2)] - 0) =$$

$$0.5 \times (+1) \times K[(2,2,2)(1,1,1) + 1]^2 + 0.3 \times (-1) \times K[(2,2,2)(0,0,0) + 1]^2$$

Positive

שאלה מספר 8:

רשת נוירונים לסיווג – נתונה הרשת הבאה:

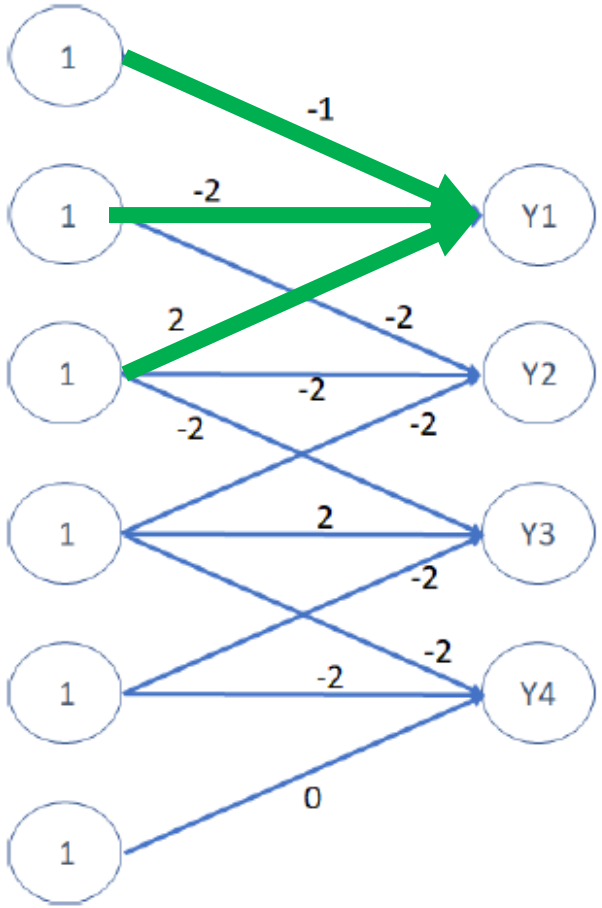


כיצד יסווג הווקטור שבכניסה (1,1,1,1,1)

1. Y1
2. Y4
3. Y2 ו-Y3 בהסתברות שווה
4. Y2
5. Y3

שאלה מספר 8:

רשת נוירונים לסיווג – נתונה הרשת הבאה:



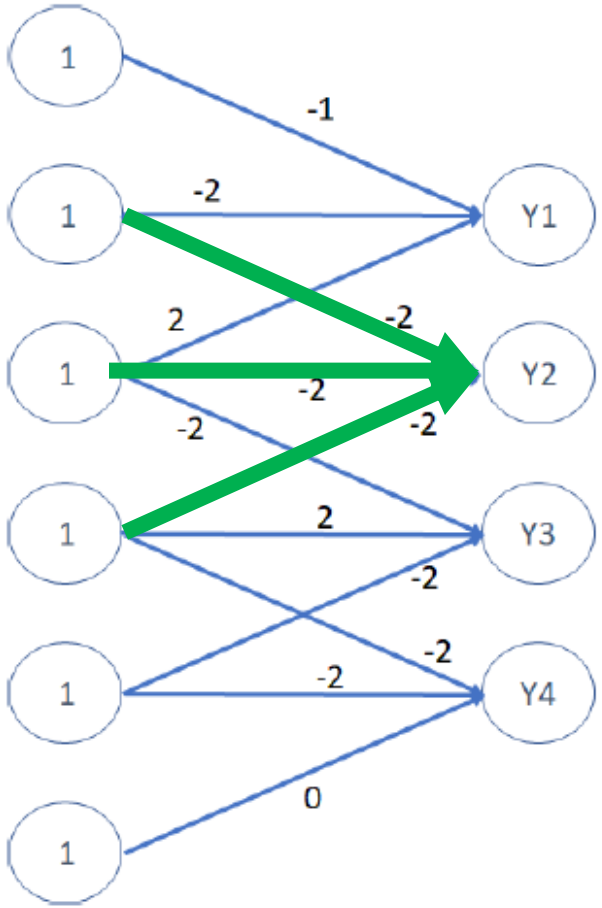
כיצד יסווג הווקטור שבכניסה (1,1,1,1,1)

1. Y1
2. Y4
3. Y2 ו-Y3 בהסתברות שווה
4. Y2
5. Y3

$$Y1 = -1 \times 1 + -2 \times 1 + 2 \times 1 = -1$$

שאלה מספר 8:

רשת נוירונים לסיווג – נתונה הרשת הבאה:



כיצד יסווג הווקטור שבכניסה (1,1,1,1,1)

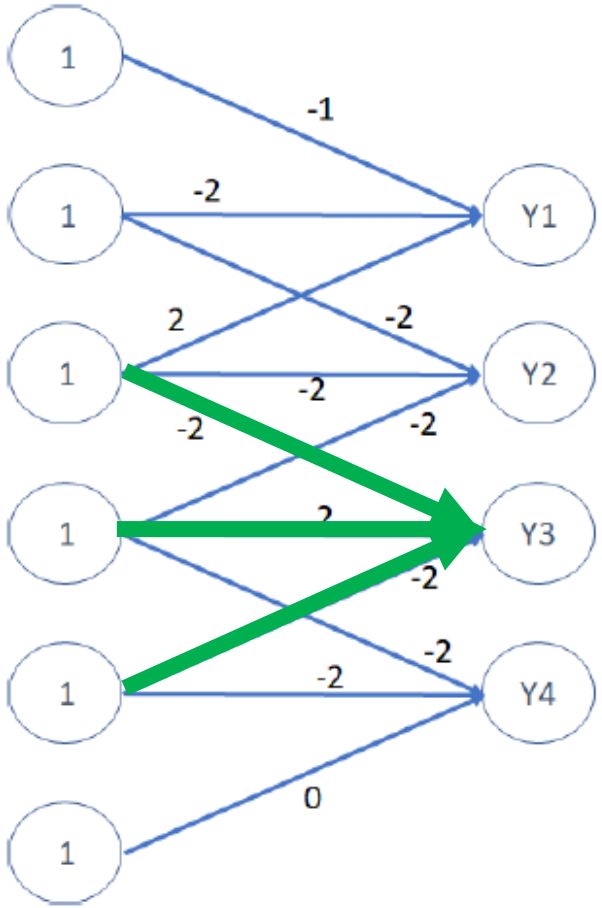
1. Y1
2. Y4
3. Y2 ו-Y3 בהסתברות שווה
4. Y2
5. Y3

$$Y1 = -1 \times 1 + -2 \times 1 + 2 \times 1 = -1$$

$$Y2 = -2 \times 1 + -2 \times 1 + (-2) \times 1 = -6$$

שאלה מספר 8:

רשת נוירונים לסיווג – נתונה הרשת הבאה:



כיצד יסווג הווקטור שבכניסה (1,1,1,1,1)

1. Y1
2. Y4
3. Y2 ו-Y3 בהסתברות שווה
4. Y2
5. Y3

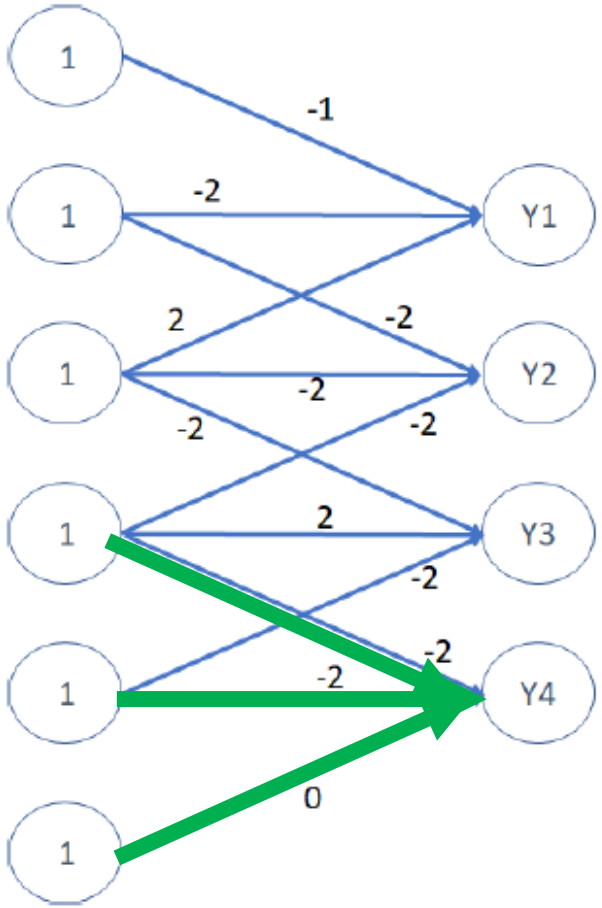
$$Y1 = -1 \times 1 + -2 \times 1 + 2 \times 1 = -1$$

$$Y2 = -2 \times 1 + -2 \times 1 + (-2) \times 1 = -6$$

$$Y3 = -2 \times 1 + 2 \times 1 + (-2) \times 1 = -2$$

שאלה מספר 8:

רשת נוירונים לסיווג – נתונה הרשת הבאה:



כיצד יסווג הווקטור שבכניסה (1,1,1,1,1)

1. Y1
2. Y4
3. Y2 ו-Y3 בהסתברות שווה
4. Y2
5. Y3

$$Y1 = -1 \times 1 + -2 \times 1 + 2 \times 1 = -1$$

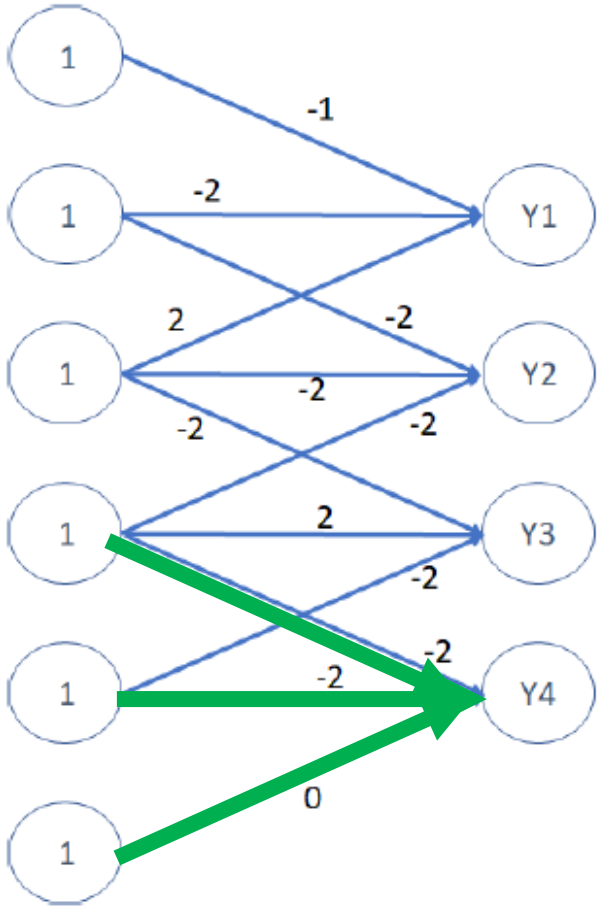
$$Y2 = -2 \times 1 + -2 \times 1 + (-2) \times 1 = -6$$

$$Y3 = -2 \times 1 + 2 \times 1 + (-2) \times 1 = -2$$

$$Y4 = -2 \times 1 + -2 \times 1 + 0 \times 1 = -4$$

שאלה מספר 8:

רשת נוירונים לסיווג – נתונה הרשת הבאה:



כיצד יסווג הווקטור שבכניסה (1,1,1,1,1)

1. Y1
2. Y4
3. Y2 ו-Y3 בהסתברות שווה
4. Y2
5. Y3

$$Y1 = -1 \times 1 + -2 \times 1 + 2 \times 1 = -1$$

$$Y2 = -2 \times 1 + -2 \times 1 + (-2) \times 1 = -6$$

$$Y3 = -2 \times 1 + 2 \times 1 + (-2) \times 1 = -2$$

$$Y4 = -2 \times 1 + -2 \times 1 + 0 \times 1 = -4$$

<u>שאלה מספר 9:</u>

אלגוריתם ADABOOST

1. מובטח לנו חסם על הטעות על קבוצת האימון
2. לא ניתן לייצר מס' *weak hypothesis* הגדול מחצי מכמות הווקטורים שבקבוצת האימון
3. ההיפוטזה הסופית המתקבלת הינה הצבעת רוב של המסווגים השונים שהתקבלו
4. לא מובטח לנו חסם על הטעות על קבוצת האימון
5. אינו רגיש לווקטורי *outliers*

שאלה מספר 10:

נתונה טבלת האימון הבאה:

מס' דוגמא	x1	x2	x3	class
1	2	2	2	P
2	2	2	2	P
4	3	3	3	N
5	3	3	3	N
6	3	3	3	N

אלו מהבאים יסווג **בוודאות** כ-P עפ"י אלגוריתם KNN

1. (f1=2.5, f2=2.5, f3=2.5), L1, K=5, ללא שקלול מרחקים
2. (f1=2.5, f2=2.5, f3=2.5), L1, K=5, עם שקלול מרחקים של 1/d
3. (f1=1, f2=1, f3=1), L1, K=5, עם שקלול מרחקים של 1/d
4. אין מספיק נתונים בשאלה
5. (f1=0, f2=0, f3=0), L1, K=5, ללא שקלול מרחקים.

			Dist L1 from (1,1,1)
	(2,2,2)	P	3
	(2,2,2)	P	3
	(3,3,3)	N	6
	(3,3,3)	N	6
	(3,3,3)	N	6

משקול P

$$\frac{1}{3}+\frac{1}{3}=\frac{2}{3}=\frac{4}{6}$$

משקול N

$$\frac{1}{6}+\frac{1}{6}+\frac{1}{6}=\frac{3}{6}$$

אלו מהאלגוריתמים הבאים (כפי שלמדנו בכיתה) מתאים בצורה ישירה לעבודה בבעיה "מרובת מחלקות".

1. *SVM, Decision Tree (ID3),Perceptron*
2. Neural Networks ,KNN, Naïve-Bayes, SVM
3. Naïve Bayes, SVM, Decision Trees (ID3), Neural Networks, KNN
4. SVM, Naïve Bayes, Decision Tree, Neural Networks, KNN
5. Neural Networks ,KNN, Naïve-Bayes, Decision Tree (ID3)

אלו מהאלגוריתמים הבאים (כפי שלמדנו בכיתה) מתאים בצורה ישירה לעבודה בבעיה "מרובת מחלקות".

1. *SVM, Decision Tree (ID3),Perceptron*
2. Neural Networks ,KNN, Naïve-Bayes, SVM
3. Naïve Bayes, SVM, Decision Trees (ID3), Neural Networks, KNN
4. SVM, Naïve Bayes, Decision Tree, Neural Networks, KNN
5. Neural Networks ,KNN, Naïve-Bayes, Decision Tree (ID3)