שאלה 1 (20 נקודות):

נתונה בעיית למידה - בהינתן המאפיינים feature1, feature2, feature3 יש צורך לחזות את class.

נתונה קבוצת האימון הבאה:

#	feature1	feature2	feature3	**class**
1	1	1	0	**P**
2	1	0	1	**P**
3	1	0	0	**N**
4	0	1	1	**N**

א. (7 נקודות) חשבו את ה – InfoGain של class בהינתן התכונה feature1 (ניתן להשאיר את התשובה כביטוי עם log).

פתרון:

$$InfoGain(class \mid feature1) = H(class) - H(class \mid feature1)$$

$$H(class) = -\frac{1}{2}\log_2\frac{1}{2} - \frac{1}{2}\log_2\frac{1}{2} = 1$$

$$H(class \mid feature1) = p(feature1 = 0) \times H(class \mid feature1 = 0) + p(feature1 = 1) \times H(class \mid feature1 = 1)$$

$$p(feature1 = 0) = \frac{1}{4}$$

$$H(class \mid feature1 = 0) = 0$$

$$p(feature1 = 1) = \frac{3}{4}$$

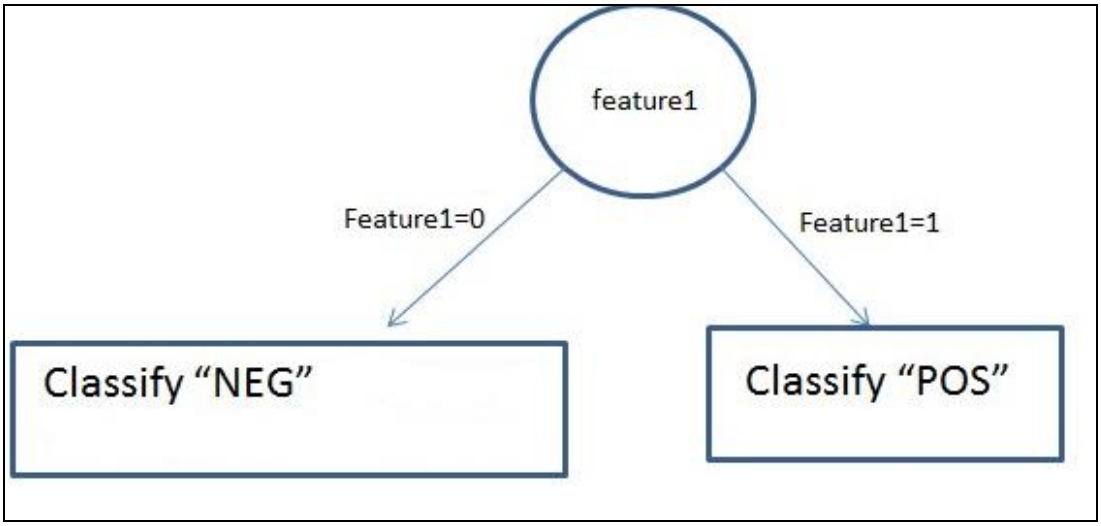
$$H(class \mid feature1 = 1) = -\frac{2}{3}\log_2\frac{2}{3} - \frac{1}{3}\log_2\frac{1}{3}$$

$$H(class \mid feature1) = \frac{1}{4} \times 0 + \frac{3}{4} \times (-\frac{2}{3}\log_2\frac{2}{3} - \frac{1}{3}\log_2\frac{1}{3}) = -\frac{1}{2}\log_2\frac{2}{3} - \frac{1}{4}\log_2\frac{1}{3}$$

$$InfoGain(class \mid feature1) = H(class) - H(class \mid feature1) = 1 - (-\frac{1}{2}\log_2\frac{2}{3} - \frac{1}{4}\log_2\frac{1}{3})$$

ב. (6 נקודות) בנה עץ החלטה בעל רמה אחת כאשר feature1 בראש העץ.

1. (3 נקודות) הצג את העץ



2. (3 נקודות) חשב את %TP ו-%FP

עפ"י אופציה א' - %TP = 100, %FP = 50

עפ"י אופציה ב' - %TP = 100, %FP = 100

ג. (7 נקודות) הרצנו את בעיית האופטימיזציה של אלגוריתם SVM לינארי והפתרון שקיבלנו הוא:

$$\alpha_1 = 1, \alpha_2 = 1, \alpha_3 = 1, \alpha_4 = 1, b = 0.5$$

פונקצית הסיווג הינה: $f(x) = SGN(w^T x - b)$

כיצד יסווג הווקטור (1,1,1)

$$w = \sum_{i=1}^{4} \alpha_i y_i x_i$$
$$= 1 \times 1 \times (1,1,0) + 1 \times 1 \times (1,0,1) + 1 \times -1 \times (1,0,0) + 1 \times -1 \times (0,1,1) =$$
$$= (1,1,0) + (1,01) - (1,0,0) - (0,1,1) = (1,0,0)$$
$$f(1,1,1) = \text{sgn}(\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}^T \times \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} - 0.5) = \text{sgn}(1 \times 1 + 0 \times 1 + 0 \times 1 - 0.5) = \text{sgn}(0.5)$$

$$classify("POS")$$

שאלה 2 (20 נקודות):

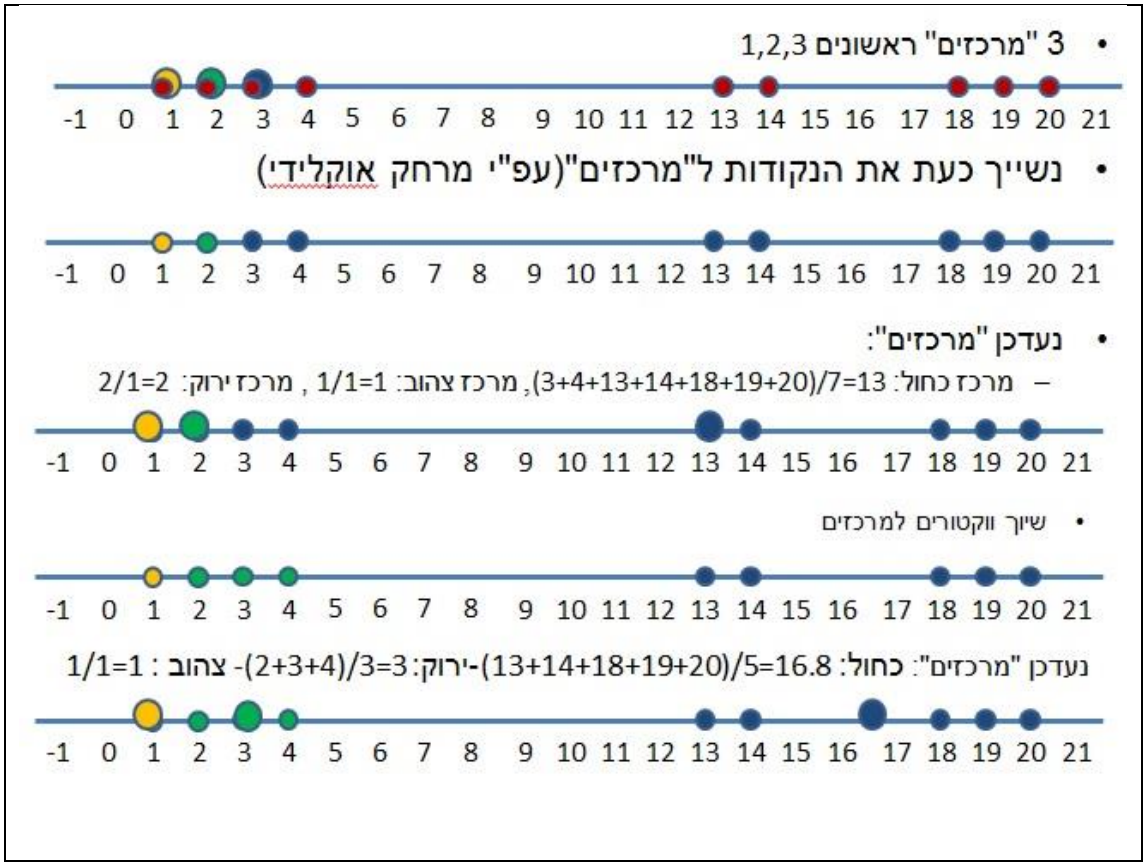
נתונה קבוצת הווקטורים הבאה (בעיה חד-מימדית מאפיין בודד f1)

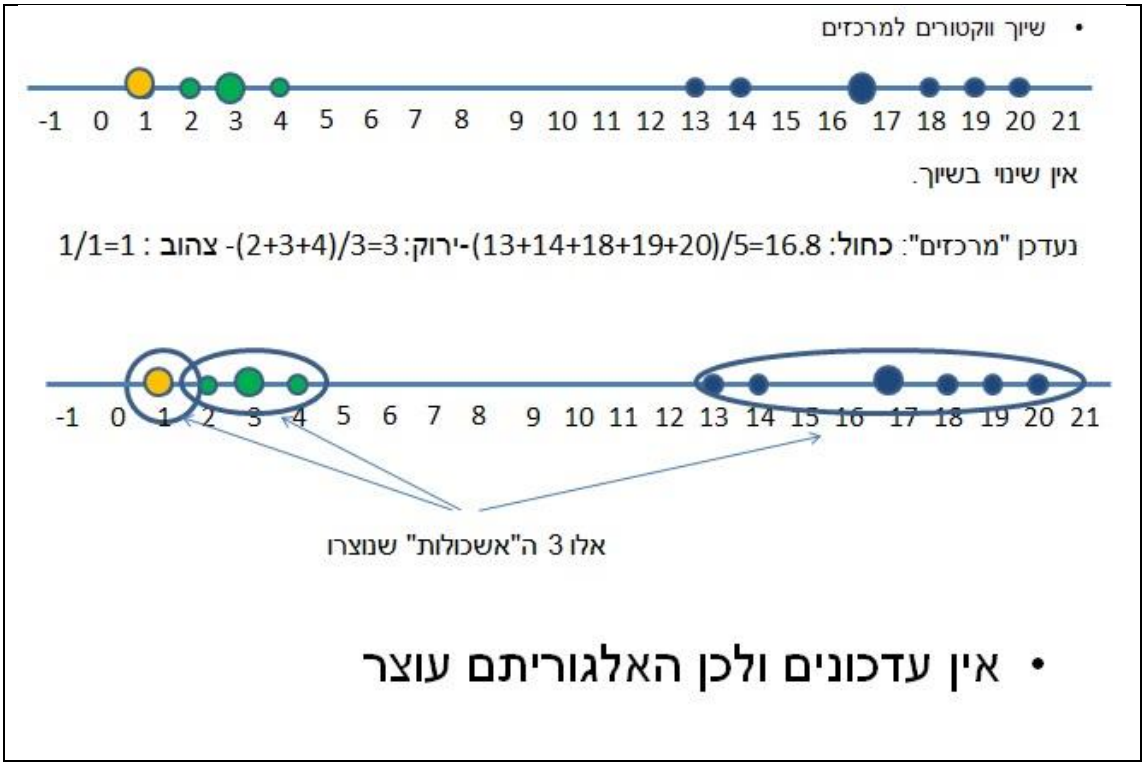
	Vector #1	Vector #2	Vector #3	Vector #4	Vector #5	Vector #6	Vector #7	Vector #8	Vector #9
f1	1	2	3	4	13	14	18	19	20

א. (8 נקודות) הרץ בפירוט את אלגוריתם האישכול k-means עבור k=3, מרחק אוקלידי. התחל את התהליך כך שהמרכזים הראשונים שנבחרו הינם ווקטורים #1,#2,#3

מהם האשכולות שנוצרו? לאיזה אשכול שייך כל ווקטור?

פתרון: כפי שציינתי במבחן, ניתן להימנע מחישובים מתמטיים רבים במקומות שברור וטריוואלי איזה ווקטור "הולך" לאיזה אשכול:





ב. (7 נקודות) האם ישנו אישכול "איכותי" יותר? אם כן, מהו? מהו המדד על-פיו קבעת שאישכול זה הוא טוב יותר?

את איכות ה"אישכול" אנו בוחנים לפי מדד ה-"סטיה" (distortion) של הווקטורים מהמרכזים אליהם הם משוייכים.

$cluster\,1:(1-1)^2=0$

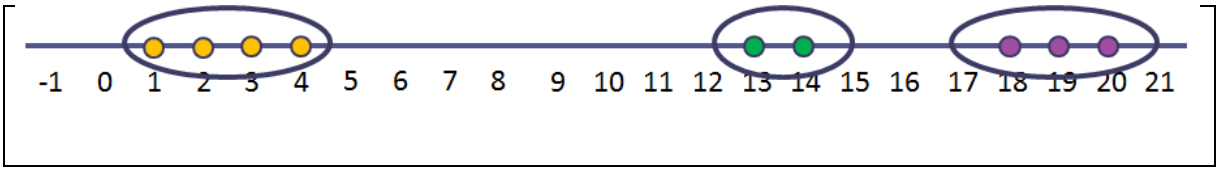
$cluster\,2:(2-3)^2+(3-3)^2+(4-3)^2=2$

$cluster\,3:(13-16.8)^2+(14-16.8)^2+(18-16.8)^2+(19-16.8)^2+(20-16.8)^2=$

$\approx 4^2+3^2+1^2+2^2+3^2\approx 39$

$Total:0+2+39=41$

לעומתה האופציה הבאה:



$cluster\,1:(1-2.5)^2+(2-2.5)^2+(3-2.5)^2+(4-2.5)^2=(-\frac{3}{2})^2+(\frac{1}{2})^2+(\frac{1}{2})^2+(\frac{3}{2})^2=\frac{20}{4}=5$

$cluster\,2:(13-13.5)^2+(14-13.5)^2=0.5$

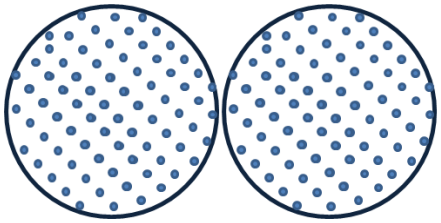
$cluster\,3:(18-19)^2+(19-19)^2+(20-19)^2=2$

$Total:5+0.5+2=7.5$

באופציה זו הסטייה קטנה יותר ולכן זהו אישכול טוב יותר.

ג. (5 נקודות) עבור הדוגמא הדו-מימדית הבאה, הראה את תוצאת אלגוריתם k-means, כלומר הראה את מרכזי האשכולות שייוצרו. אם יש יותר מאפשרות אחת הצג/תאר זאת. אנו מניחים שהאלגוריתם התחיל מבחירה אקראית של ווקטורים "אמיתיים", כלומר ווקטורים שקיימים בקבוצת האימון.

הראה את התוצאה עבור k=3



התפלגות אחידה של הווקטורים בשני מעגלים ברדיוס r.

פתרון: עבור k=3 (כפי שציינתי במבחן, אנו מניחים שיש מרחק קטן בין המעגלים)

