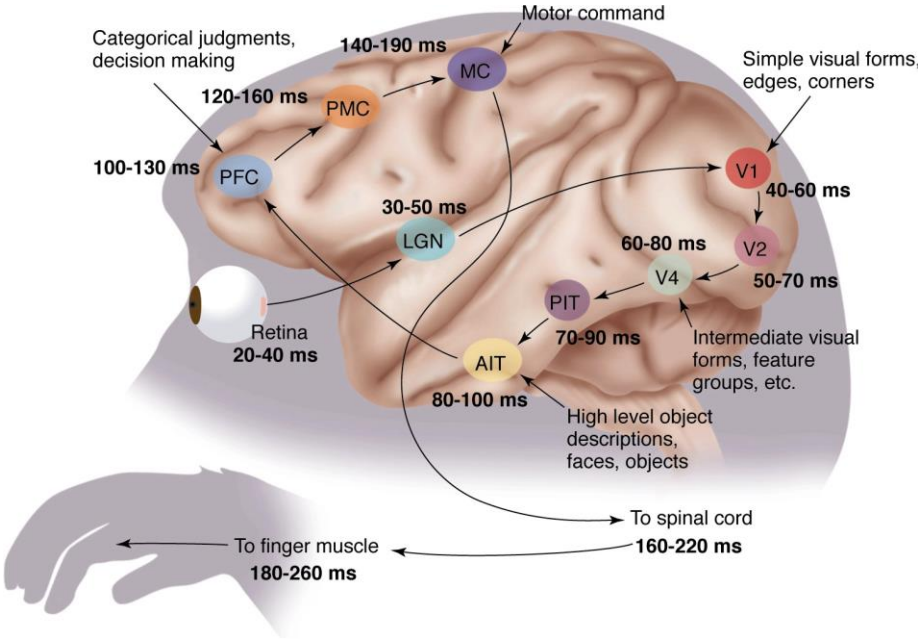
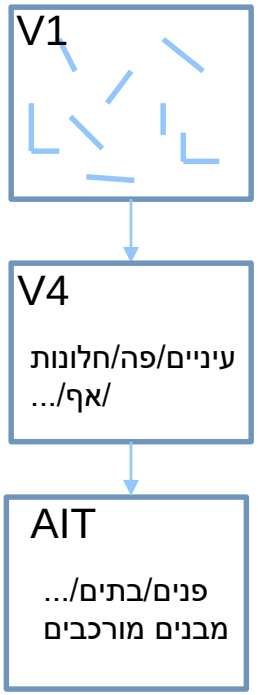
למידת מכונה

רשתות עצביות

Neural Networks

The Visual Cortex





Picture from Simon Thorpe

קליפת המוח הראייתית - הוא האזור המרכזי במוח בו מעובד מידע חזותי הנקלט בעין, מהווה חלק מקליפת המוח. קליפת הראייה כוללת בתוכה מספר אזורים, ולכל אזור תפקיד משלו בתהליך עיבוד המידע. אזורי הראייה הראשוניים כמו קליפת הראייה העיקרית מעבדים בעיקר מידע המהווה את בסיס לראייה, כמו קווים וקצוות, זיהוי תנועה, עומק וצבע, בעוד שאזורי ראייה אחרים במוח, כמו v2, v3, v4-, v5מעבדים מידע מורכב יותר כמו זיהוי צורות ותבניות, מקומות ופנים.

Loss function for multi-class

מדד ל- "שביעות הרצון" שלנו מהמסווג שבנינו





Cat	7.1	8	12
Dog	9	7.1	4
Lion	-2.2	3	15

$$\text{Total Loss} = \frac{1}{N}\sum_i L(f(x_i), y_i)$$

Multi-Class SVM Loss

מדד ל- "שביעות הרצון" שלנו מהמסווג שבנינו





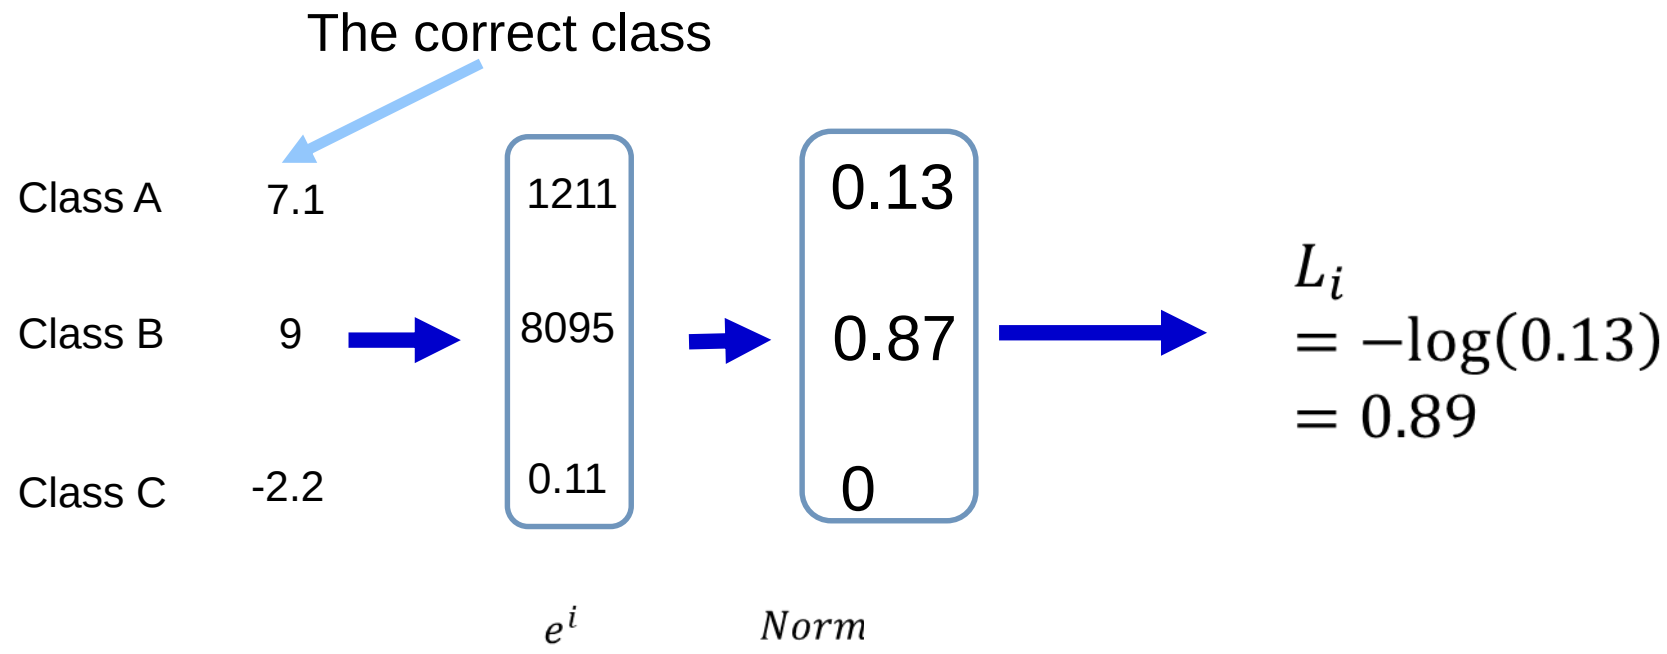
Cat	7.1	8	12
Dog	9	7.1	4
Lion	-2.2	3	15

$$L_i = \sum_{j \neq y_i} \begin{cases} 0 & \text{if } s_{y_i} \geq s_j + margin \\ s_j - s_{y_i} + margin & otherwise \end{cases}$$

Softmax

$$P(Y = k|X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

S is the classifier result



אלגוריתם backpropagation

- העיקרון - מעבר על השכבות "הלוך" ו"חזור" מס' פעמים ועדכון משקלים בכל איטרציה.

  - "הלוך" - "חלחול" המשקלים מה"כניסה" על פני הרשת עד קבלת תוצאת פלט מהרשת.
  - "חזור" - המשקלים מתוקנים שכבה אחר שכבה בעזרת חוק תיקון הטעות.

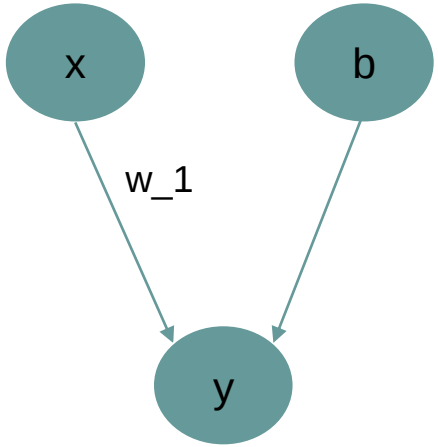
- חוזרים על התהליך עד שמתקיים תנאי עצירה.

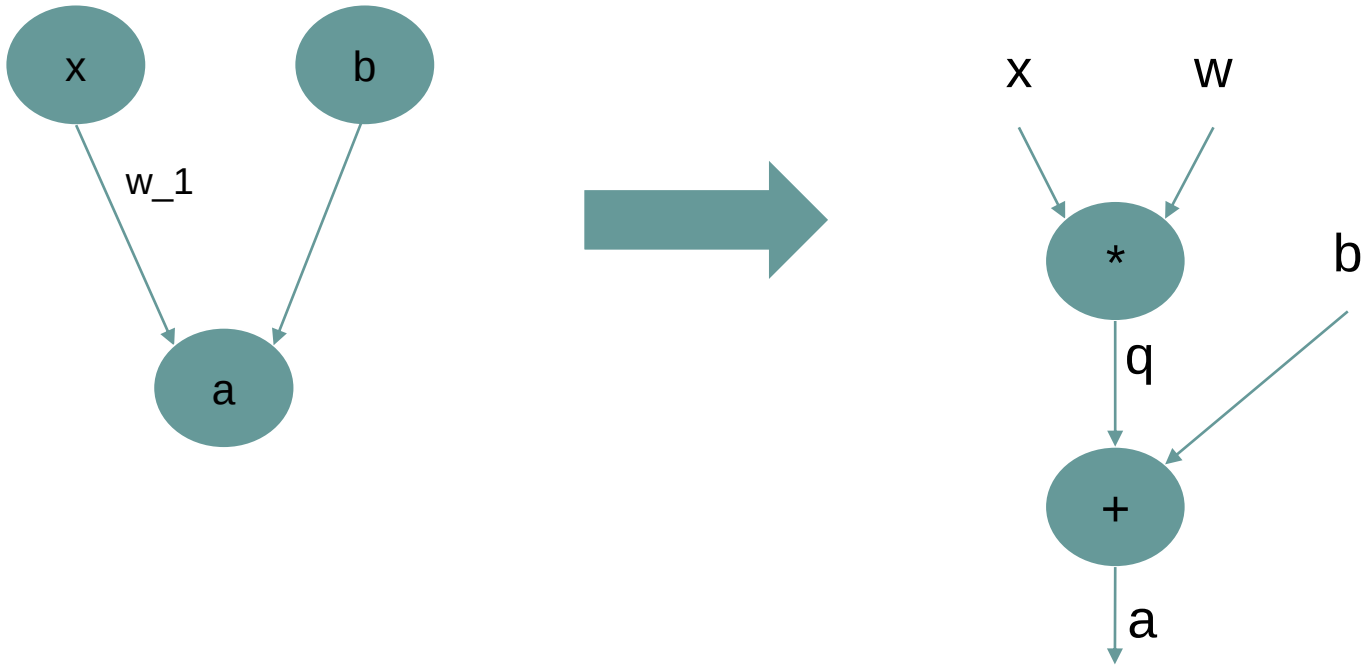
אלגוריתם backpropagation – סכימה כללית

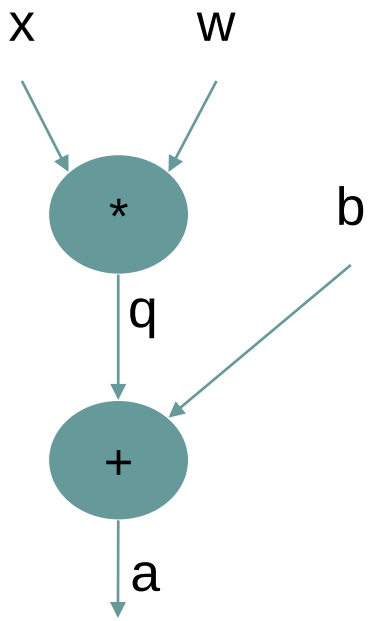
- עבור כל דוגמא בקבוצת האימון בצע עד להתכנסות
  - חשב את הפלט Y של הרשת לקלט זה
  - עדכן משקולות w_{ij} ברמת הפלט (כלומר המשקולות בין השכבה החבויה האחרונה לבין שכבת הפלט) עפ"י $\frac{\partial E}{\partial w_{ij}}$
  - בצע את התהליך לשכבה קודמת

- A NN is a computational graph
- In a computational graph, **nodes** are operations and **edges** are variables

- Here is a simple NN with one input, and bias (no activation)




x
b
w_1
a
x
w
*
b
q
+
a

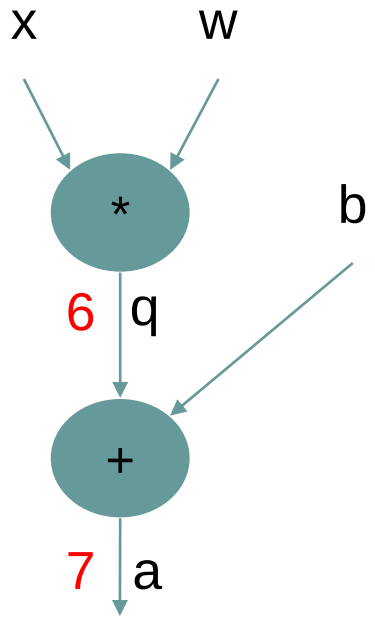


$$q = xw$$

$$a = q + b$$

$$x = 3$$
$$w = 2$$
$$b = 1$$

$$\rightarrow a = 7$$



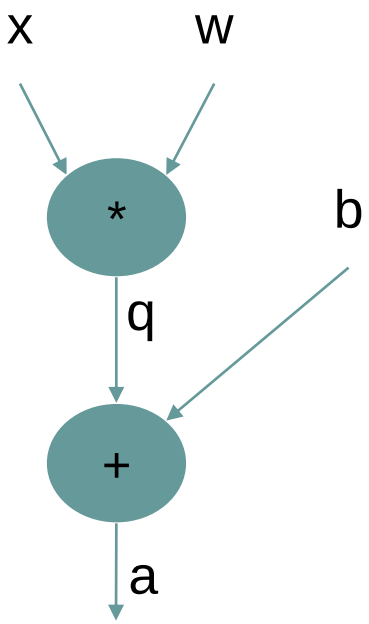
([3])x = np.array

([2])w = np.array

([1])b = np.array

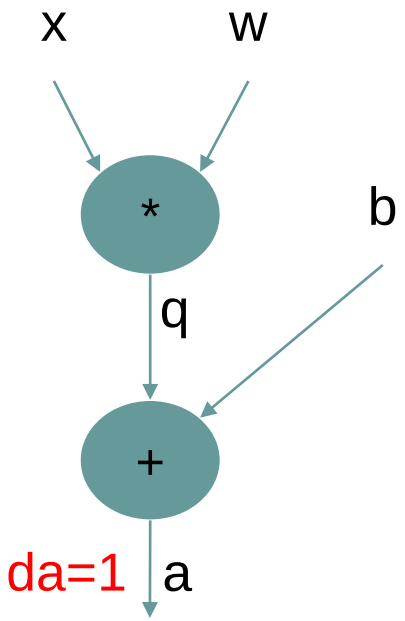
q = x * w

f = q + b



it with the given values, with "backward"

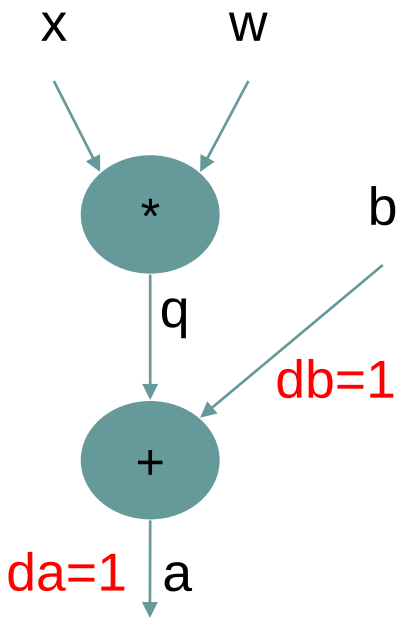
$$da = \frac{da}{da} = 1$$



$$x = 3$$
$$w = 2$$
$$b = 1$$
$$q = 6$$
$$a = 7$$

it with the given values, with "backward"

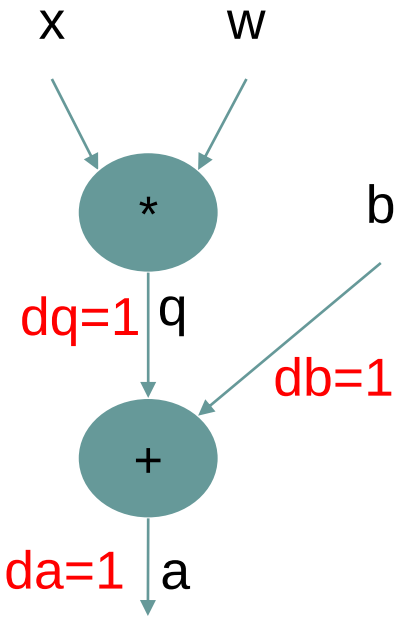
$$db = \frac{da}{da}\frac{da}{db} = 1$$



$$x = 3$$
$$w = 2$$
$$b = 1$$
$$q = 6$$
$$a = 7$$

it with the given values, with "backward"

$$dq = \frac{da}{da}\frac{da}{dq} = 1$$

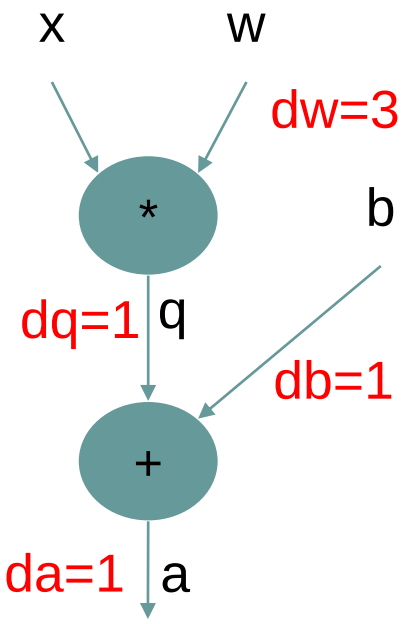


$$x = 3$$
$$w = 2$$
$$b = 1$$
$$q = 6$$
$$a = 7$$

it with the given values, with "backward"

$$dw = \frac{da}{dq}\frac{dq}{dw}$$

$$= dq\frac{dq}{dw} = x = 3$$

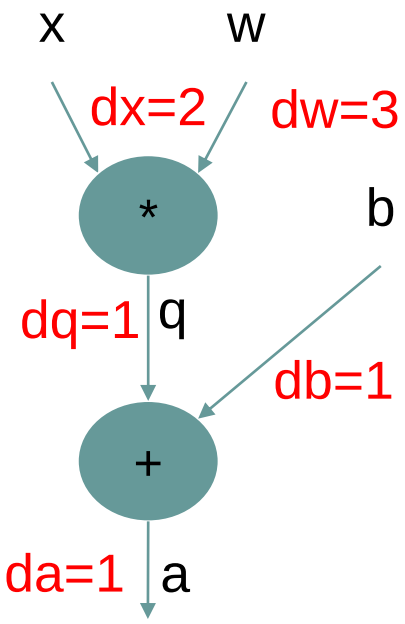


$$x = 3$$
$$w = 2$$
$$b = 1$$
$$q = 6$$
$$a = 7$$

it with the given values, with "backward" s

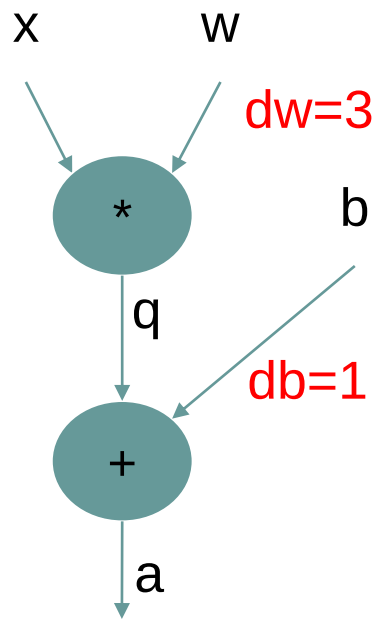
$$dx = \frac{da}{dq}\frac{dq}{dx}$$

$$dq\frac{dq}{dx} = w = 2$$

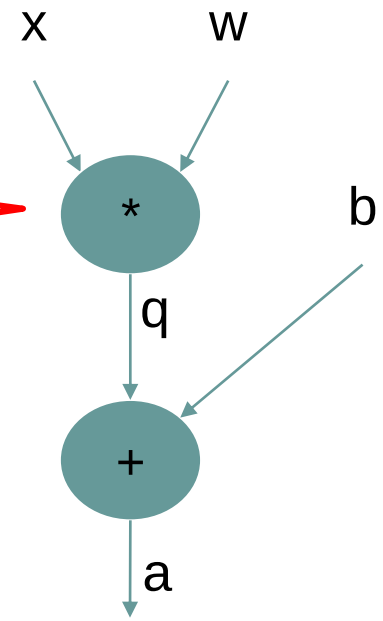


$$x = 3$$
$$w = 2$$
$$b = 1$$
$$q = 6$$
$$a = 7$$

In order to update weights, we only need to keep



This can be treated as a **“gate”**. A component in the computational graph, with forward and backward capabilities



```
class NN:
  def forward(self, inputs):
    t = inputs
    for gate in gates.sorted():
      t = gate.forward(t)
    return t

  def backward(self):
    for gate in gates.reversed():
      gate.backward()
```

