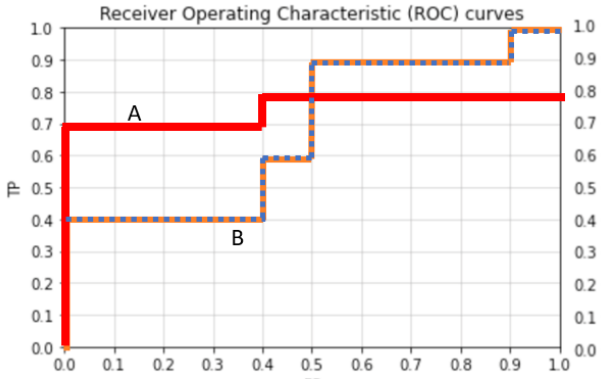
[q1]

Roc-Curve

נתון גרפי ROC Curve הבאים גרף A, גרף B ורוצים להעריך את ביצועי אלגוריתמי הלמידה A ו-B (בהתאמה).



במונחי EER גרף A טוב יותר. במונחי AUC גרף A טוב יותר.

AUC-A=0.4×0.7+0.6×0.8 = 0.76

AUC-B=0.4×0.4+0.1×0.6+0.4×0.9+0.1×1=0.68

EER is the point where %FP = (1-%TP) →

EER-A: (FP = 0.3, TP = 0.7)→EER = 0.3

EER-B: (FP = 0.4, TP = 0.6)→EER = 0.4

ככל שהEER נמוך יותר – הגרף טוב יותר

[q2]

היגדים

בחר את הסעיף בו <u>כל</u> האמרות הן נכונות

1) באלגוריתם עץ החלטה ID3, ככל שנוסיף עוד ועוד רמות בעץ עד לתנאי העצירה, אנו עשויים להגיע לoverfitting.

2) KNN הינו אלגוריתם שפותר בעיית MULTI-CLASS

3) אלגוריתם פרספטרון – אם ישנה הפרדה לינארית בקבוצת האימון, מובטח לנו שהאלגוריתם ימצא את המפריד הלינארי (לאחר מס' סופי של איטרציות)

4) אלגוריתם KMEANS הינו אלגוריתם unsupervised

[q3]

על מנת למצוא את המחלקה של קבוצת אימון נתונה (שלושה מאפיינים f_1, f_2, f_3), השתמשו באלגוריתם SVM לא לינארי עם הקרנל הבא:

$K(a,b) = (a \cdot b + 1)^2$

#	f_1	f_2	f_3	Class
1	1	1	1	1
2	2	2	2	1
3	3	3	3	-1
4	4	4	4	-1
5	5	5	5	-1

התקבלו הפרמטרים הבאים: (שימו לב – הנתונים אינם בהכרח פתרון נכון לקבוצת האימון אלא רק לצורך השאלה)

$\alpha_1 = 0, \alpha_2 = 0.666, \alpha_3 = 0.666, \alpha_4 = 0, \alpha_5 = 0$

b = 0

מהי הנוסחא המתאימה לסיווג הווקטור (2,2,6)

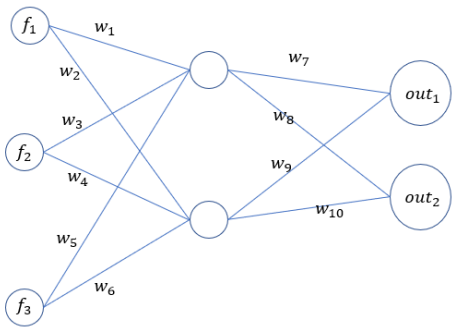
$SGN(0.666 \times (+1) \times [(2,2,2) \cdot (2,2,6)^T + 1]^2 + 0.666 \times (-1) \times [(3,3,3) \cdot (2,2,6)^T + 1]^2)$

זו נוסחת סיווג עם קרנל לא לינארי כפי שהראינו בהרצאות (אף הוכחנו שזו הנוסחא)

[q4]

רשתות עצביות (Neural Networks)

נתונה רשת הנוירונים הבאה:



נתונים ערכי w

$w_1 = 1, w_2 = 1, w_3 = 1, w_4 = 1, w_5 = 1, w_6 = 1$

$w_7 = 1, w_8 = -1, w_9 = 2, w_{10} = 3$

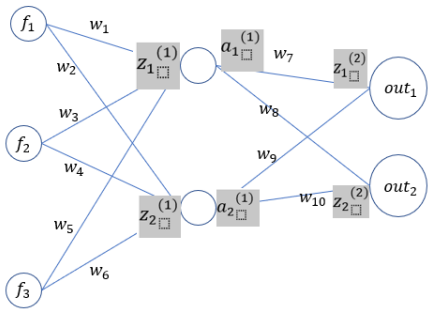
בכל הנוירונים בשכבה החבויה ובשכבת היציאה מפעילים פונקציית אקטיבציה של ערך סף 0

(עבור ערך 0 בדיוק מוצא האקטיבציה הינה 1.)

מה יהיה מוצא הרשת עבור הקלטים הבאים:

A: (1,1,1)

B: (-1,-1,-1)



$$z_1^{(1)} = w_1 \cdot f_1 + w_3 \cdot f_3 + w_5 \cdot f_5 = 1 \cdot 1 + 1 \cdot 1 + 1 \cdot 1 > 0$$

$$z_2^{(1)} = w_2 \cdot f_1 + w_4 \cdot f_3 + w_6 \cdot f_5 = 1 \cdot 1 + 1 \cdot 1 + 1 \cdot 1 > 0$$

$$a_1^{(1)} = 1$$

$$a_2^{(1)} = 1$$

$$z_1^{(2)} = w_7 \cdot a_1^{(1)} + w_9 \cdot a_2^{(1)} = 1 \cdot 1 + 2 \cdot 1 > 0 \rightarrow out_1 = 1$$

$$z_2^{(2)} = w_8 \cdot a_1^{(1)} + w_{10} \cdot a_2^{(1)} = -1 \cdot 1 + 3 \cdot 1 > 0 \rightarrow out_1 = 1$$

B:

$$z_1^{(1)} = w_1 \cdot f_1 + w_3 \cdot f_3 + w_5 \cdot f_5 = 1 \cdot -1 + 1 \cdot -1 + 1 \cdot -1 < 0$$

$$z_2^{(1)} = w_2 \cdot f_1 + w_4 \cdot f_3 + w_6 \cdot f_5 = 1 \cdot -1 + 1 \cdot -1 + 1 \cdot -1 < 0$$

$$a_1^{(1)} = -1$$

$$a_2^{(1)} = -1$$

$$z_1^{(2)} = w_7 \cdot a_1^{(1)} + w_9 \cdot a_2^{(1)} = 1 \cdot -1 + 2 \cdot -1 < 0 \rightarrow out_1 = -1$$

$$z_2^{(2)} = w_8 \cdot a_1^{(1)} + w_{10} \cdot a_2^{(1)} = -1 \cdot -1 + 3 \cdot -1 < 0 \rightarrow out_2 = -1$$

A: $\boldsymbol{out_1 = 1, out_2 = 1}$ $\boldsymbol{B: out_1 = -1, out_2 = -1}$

[q5]

נתונה טבלת האימון הבאה:

כיצד יסווג הווקטור (3,3,3) ע"י אלגוריתם KNN,

מטריקת L1,

k=3

מס' דוגמא	x1	x2	x3	class	Dist from (3,3,3)	
1	2	1	4	P	|3-2|+|3-1|+|3-4| = 4	
2	2	2	3	P	|3-2|+|3-2|+|3-3| = 2	
3	2	3	2	P	|3-2|+|3-3|+|3-2| = 2	
4	2	1	4	P	|3-2|+|3-1|+|3-4| = 4	
5	2	3	3	N	|3-2|+|3-3|+|3-3| = 1	
6	1	2	2	N	|3-1|+|3-2|+|3-2| = 4	
7	2	2	2	N	|3-2|+|3-2|+|3-2| = 3	
8	5	2	5	N	|3-5|+|3-2|+|3-5| = 5	

$P: \frac{1}{2}+\frac{1}{2}=1$

$N: \frac{1}{1}=1$

ללא שקלול מרחקים – יסווג כ-P, עם שקלול מרחקים של $\frac{1}{d}$ נקבל ציון זהה ל-P ול-N

[q6]

נתונה טבלת האימון הבאה:

מס' דוגמא	x1	x2	x3	class
1	2	1	4	P
2	2	2	1	P
3	2	1	B	P
4	2	1	2	P
5	2	2	A	N
6	1	2	2	N
7	2	2	2	N
8	2	2	1	N

כיצד יסווג הוקטור (2,2,2) בעזרת Naïve Bayes?

עבור כל ערך של A ושל B מחלקת N תנצח

$$P('P'|x1=2,x2=2,x3=2)=\frac{P(x1=2,x2=2,x3=2|'P')\times P('P')}{P(x1=2,x2=2,x3=2)}$$

$$P('N'|x1=2,x2=2,x3=2)=\frac{P(x1=2,x2=2,x3=2|'N')\times P('N')}{P(x1=2,x2=2,x3=2)}$$

$P(x1=2,x2=2,x3=2|'P')\times P('P')>?\ P(x1=2,x2=2,x3=2|'N')\times P('N')$

P('P') = 0.5, P('N') = 0.5

$P(x1=2,x2=2,x3=2|'P')>?\ (x1=2,x2=2,x3=2|'N')$

Naïve assumption (independence between features)

$P(x1=2,x2=2,x3=2|'P')>?\ (x1=2,x2=2,x3=2|'N')$

$$P(x1=2|'P')\times P(x2=2|'P')\times P(x3=2|'P')=\ 1\times\frac{1}{4}\times ?=\frac{1}{4}\cdot ?$$

$$P(x1=2|'N')\times P(x2=2|'N)\times P(x3=2|'N')=\frac{3}{4}\times 1\times ?=\frac{3}{4}\cdot ?$$

ע"מ שP יגביר סיכויים "לנצח" צריך לשים בו '2' בערך ה-A ובערך ה-B נשים משהן שאינו 2

$$P(x1=2|'P')\times P(x2=2|'P')\times P(x3=2|'P')=\ 1\times\frac{1}{4}\times ?=\frac{1}{4}\cdot\frac{2}{4}=\frac{2}{16}$$

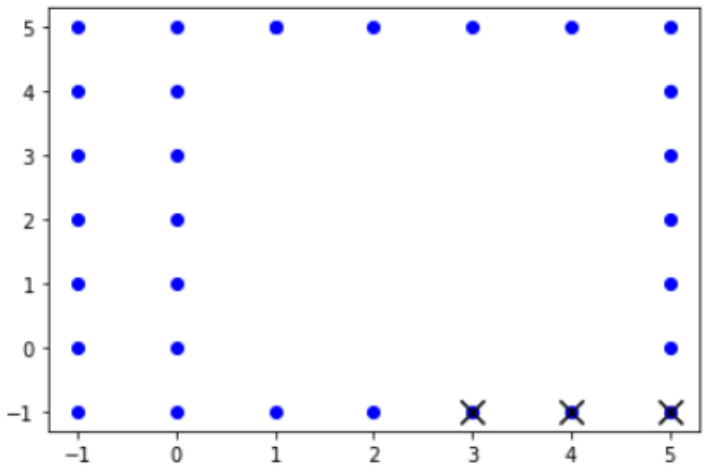
$$P(x1=2|'N')\times P(x2=2|'N)\times P(x3=2|'N')=\frac{3}{4}\times 1\times ?=\frac{3}{4}\cdot\frac{2}{4}=\frac{6}{16}$$

כלומר בכל מקרה מחלקת ה-N תנצח

[q7]

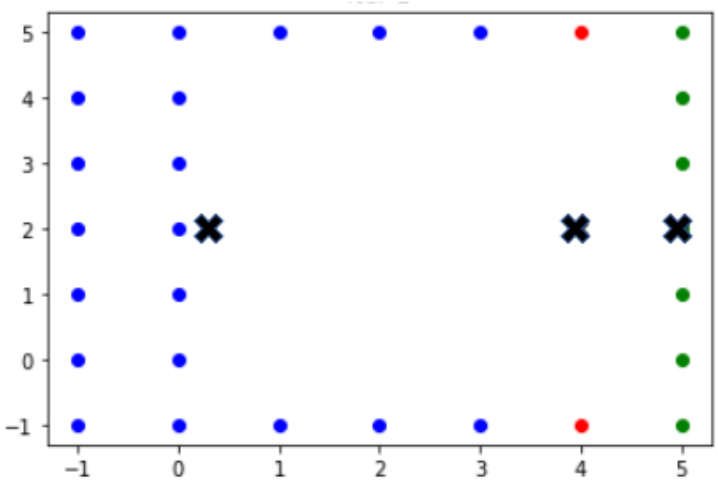
אלגוריתם k-means

נתונים הווקטורים הבאים, עבור k=3, מסומנים ב-x הווקטורים בהם איתחלנו את אלגוריתם k-means



הרצנו <u>צעד אחד</u> באלגוריתם. איזה מהבאים מתאים <u>לאחר צעד אחד</u> באלגוריתם?

(כל צבע מתאר אשכול שונה וה-X מתאר את "מרכז" האשכול)



[q8]

נתונה טבלת האימון הבאה:

מס' דוגמא	x1	x2	x3	class
1	2	1	1	P
2	2	2	1	P
3	2	1	1	P
4	2	2	1	P
5	2	1	2	N
6	1	2	3	N
7	2	1	4	N
8	2	2	5	N

[q8]

האנתרופיה של class בהינתן x1 H(class|x1) גדולה מאפס,

ניתן לראות שאין וודאות מוחלטת לפי x1. לפעמים בור ערך x1=2 נקבל P ולפעמים N

$$H(class|x_1) > 0$$

האנתרופיה של class בהינתן x2 שווה ל-1,

$$H(class|x_2) = 1$$

ניתן לראות שעבור x2=1 בחצי מהמקרים נקבל P ובחצי מהמקרים נקבל N
אותו דבר עבור x2=2

האינפו גיין של class בהינתן x3 שווה ל-1

$$IG(class|x_3) = 1$$

האנתרופיה ההתחלתית של class היא 1. ("חצי מהמקרים P-חצי מהמקרים N")
ניתן לראות שלכל ערך של x3 יש החלטה חד משמעית לכן האנתרופיה לפי x3 היא 0 לכן האינפוגיין הוא 1

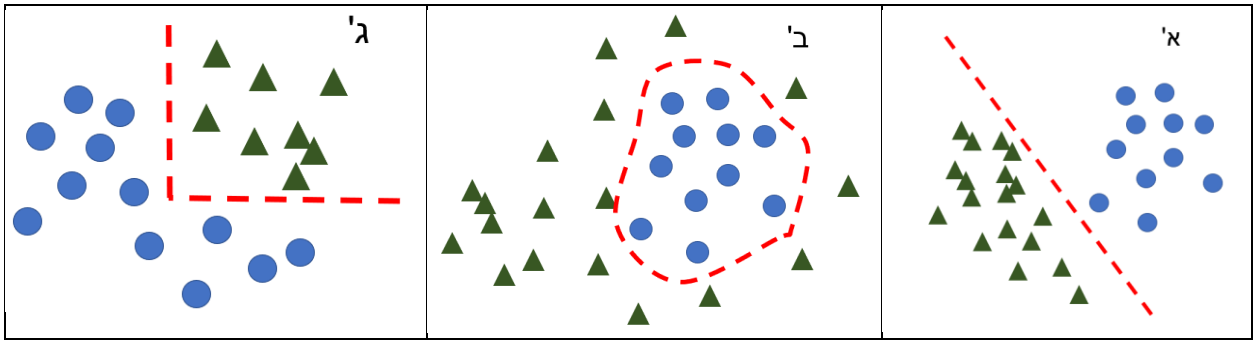
[q9]

בחר/י את האמרה הנכונה ביותר עבור אלגוריתם K-MEANS?

מובטח לנו שהאלגוריתם יתכנס, לא מובטח שיתכנס לתוצאה האופטימלית

[q10]

נתונות קבוצות האימון הבאות, עם המסווגים שהותאמו להן:



בחר/י את האימרה הנכונה ביותר

א' מתאים ל-SVM soft margin, ב' מתאים לרשת נוירונים, ג' מתאים לעץ החלטה