שאלה 1 (20 נקודות):

נתונה בעיית למידה - בהינתן המאפיינים feature1, feature2, feature3 יש צורך לחזות את class.

נתונה קבוצת האימון הבאה:

#	feature1	feature2	feature3	**class**
1	1	1	0	**P**
2	1	0	1	**P**
3	1	0	0	**N**
4	0	1	1	**N**

א. (7 נקודות) סווג את הווקטור (1,1,1) עפ"י KNN עבור k=1, מטריקת מרחק L1, משקול מרחקים של $1/d^2$, ללא משקול מאפיינים.

פתרון:

#	feature1	feature2	feature3	**class**	**מרחק מ-(1,1,1)**
1	1	1	0	**P**	**1** = |**1-0**|+|**1-1**|+|**1-1**|
2	1	0	1	**P**	**1** = |**1-1**|+|**0-1**|+|**1-1**|
3	1	0	0	**N**	**2** = |**1-0**|+|**1-0**|+|**1-1**|
4	0	1	1	**N**	**1** = |**1-1**|+|**1-1**|+|**1-0**|

יש לנו שלושה ווקטורים במרחק של 1, אין משמעות לשקלול מרחקים. מכיוון ששניים אומרים P ואחד N נסווג כ-P.

ב. (6 נקודות) סווג את הווקטור (1,1,1) עפ"י אלגוריתם Naïve-Bayes

נבדוק האם ההסתברות ל- P גדולה או קטנה מההסתברות ל-N

מניחים שהווקטורים בלתי תלויים

$$P(P \mid x1=1, x2=1, x3=1) = \frac{P(x1=1, x2=1, x3=1 \mid P)P(P)}{P(x1=1, x2=1, x3=1)}$$

$$P(N \mid x1=1, x2=1, x3=1) = \frac{P(x1=1, x2=1, x3=1 \mid N)P(N)}{P(x1=1, x2=1, x3=1)}$$

המכנה זהה ולכן לא "מעניין". P(P)=P(N) ולכן גם לא "מעניין"

$$P(x1=1,x2=1,x3=1|P)=P(x1=1|P)\times P(x2=1|P)\times P(x3=1|P)=1\times\frac{1}{2}\times\frac{1}{2}=\frac{1}{4}$$

$$P(x1=1,x2=1,x3=1|N)=P(x1=1|N)\times P(x2=1|N)\times P(x3=1|N)=\frac{1}{2}\times\frac{1}{2}\times\frac{1}{2}=\frac{1}{8}$$

ההסתברות לקבלת P גדולה מההסתברות לקבלת N, ולכן נסווג כ-P

ג. (7 נקודות) הרצנו את בעיית האופטימיזציה של אלגוריתם SVM עם קרנל פולינומיאלי (לא לינארי) והפתרון שקיבלנו הוא:

$$\alpha_1=7,\alpha_2=7,\alpha_3=11,\alpha_4=3,b=1.3$$

(הערה: הערכים הינם קירובים של התוצאה האמיתית וזאת כדי להקל על החישובים)

פונקצית הסיווג הינה:

$$\text{sgn}(\sum_i \alpha_i y_i K(x_i,x)-b)$$

משוואת הקרנל:

$$K(x\cdot y)=(\frac{1}{3}x\cdot y)^2$$

כיצד יסווג הווקטור (1,1,1)

פתרון:

$$\text{sgn}(7\times1\times K((1,1,0)(1,1,1))+7\times1\times K((1,0,1)(1,1,1))+11\times-1\times K((1,0,0)(1,1,1))+3\times-1\times K((0,1,1)(1,1,1))-1.3=$$

$$\text{sgn}(7\times\frac{(1,1,0)(1,1,1)^{T^2}}{9}+7\times\frac{(1,0,1)(1,1,1)^{T^2}}{9}-11\times\frac{(1,0,0)(1,1,1)^{T^2}}{9}-3\times\frac{(0,1,1)(1,1,1)^{T^2}}{9}-1.3)=$$

$$\text{sgn}(7\times\frac{4}{9}+7\times\frac{4}{9}-11\times\frac{1}{9}-3\times\frac{4}{9}-1.3)=\text{sgn}(\frac{28+28-11-12}{9}-1.3)=\text{sgn}(\frac{33}{9}-1.3)>0$$

לכן יסווג כחיובי.

שאלה 2 (20 נקודות):

נתונה קבוצת הווקטורים הבאה (בעיה חד-מימדית מאפיין בודד f1)

	Vector #1	Vector #2	Vector #3	Vector #4	Vector #5	Vector #6	Vector #7	Vector #8	Vector #9
f1	1	2	4	7	19	18	30	11	64

א. (8 נקודות) הרץ בפירוט אלגוריתם אישכול היררכי bottom-up (מרחק אוקלידי).

מרחק בין ווקטור לאשכול מוגדר כמרחק לווקטור הקרוב ביותר באשכול.

הרץ את האלגוריתם 4 איטרציות.

כמה אשכולות נוצרו? לאיזה אשכול שייך כל ווקטור?

איטרציה 1: נאחד את ווקטורים #1, #2 מכיוון שהמרחק ביניהם הוא הקטן ביותר (כמובן אפשר גם לבחור את #5,#6).

8 אשכולות: (#9),(#8),(#7),(#6),(#5),(#4),(#3),(#1,#2)

איטרציה 2: נאחד את ווקטורים #5, #6

7 אשכולות: (#9),(#8),(#7),(#5,#6),(#4),(#3),(#1,#2)

איטרציה 3: נאחד את ווקטור #3, לאשכול של (#1,#2)

6 אשכולות: (#9),(#8),(#7),(#5,#6),(#4),(#1,#2,#3)

איטרציה 4: נאחד את ווקטור #4, לאשכול של (#1,#2,#3)

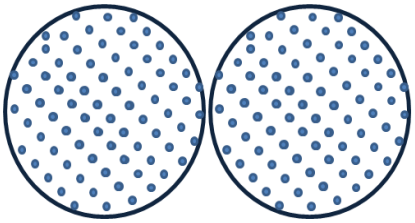
5 אשכולות: (#9),(#8),(#7),(#5,#6),(#1,#2,#3,#4)

ב. (6 נקודות) הצע מדד לעצירת אלגוריתם האישכול ההיררכי?

פתרון: מדד אפשרי לעצירת האלגוריתם – כאשר המרחק בין אשכול לאשכול הקרוב ביותר גדול מסף מסויים. (זה אומר כמובן שאנו לא נרצה לאחד אשכולות אלו והאלגוריתם יעצור)

ג. (6 נקודות) עבור הדוגמא הדו-מימדית הבאה, הראה את תוצאת אלגוריתם k-means, כלומר הראה את מרכזי האשכולות שייוצרו. אם יש יותר מאפשרות אחת הצג/תאר זאת. אנו מניחים שהאלגוריתם התחיל מבחירה אקראית של ווקטורים "אמיתיים", כלומר ווקטורים שקיימים בקבוצת האימון.

הראה את התוצאה עבור k=2



התפלגות אחידה של הווקטורים בשני מעגלים ברדיוס r.

פתרון: עבור k=2

