# Cluster Analysis

Unsupervised

- למנהל קשרי לקוחות יש חמישה עובדים ורוצה לחלק את הלקוחות ל-5 קבוצות כך שכל קבוצה תשויך למנהל אחר.
  - האתגר שלנו – ל"חשוף" 5 קבוצות "מעניינות"
  - הבעיה: אין לנו את ה- class label של כל קבוצה

# Clustering "אישכול"

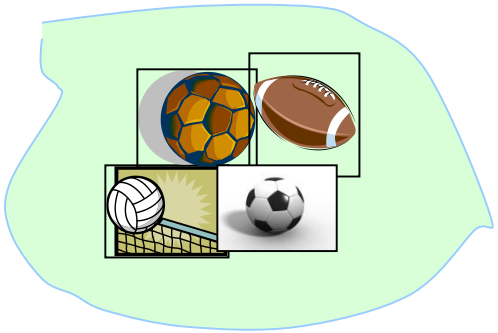
- Cluster Analysis היא הפעולה של חלוקת קבוצה לתתי קבוצות ("אשכולות"/Clusters) כך ש:
  - אובייקטים באותו אשכול "דומים" זה לזה
  - אובייקטים באשכולות שונים, אינם "דומים" זה לזה.

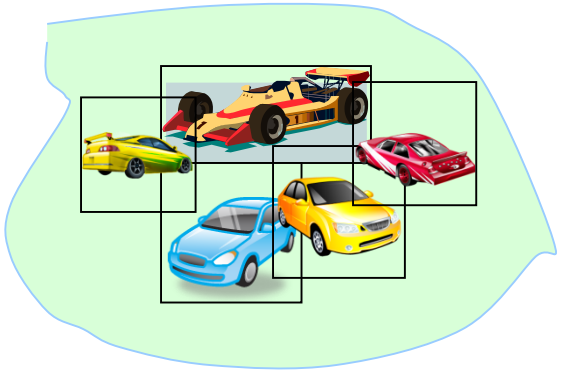
**Unsupervised**

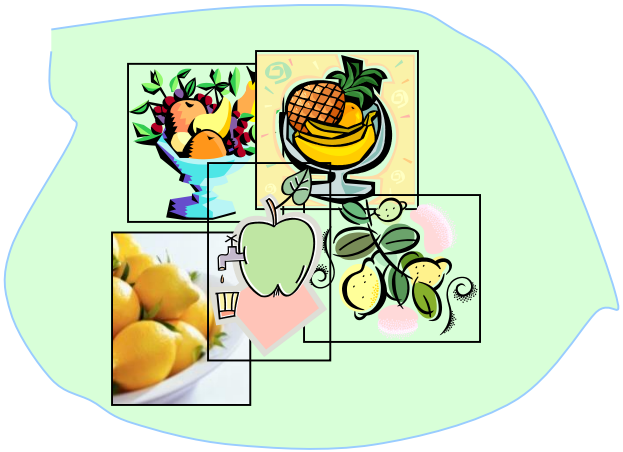
# מיון - חלוקה לקבוצות



# מיון - חלוקה לקבוצות







# Classification vs. Clustering

- סיווג (Classification) משייך אובייקטים ל"מחלקות" מוגדרות מראש
- "אישכול" (Clustering) מסיק חלוקה לקבוצות עפ"י אשכולות שנוצרים.

# יישומים

- "עיבוד תמונה" –
  - סגמנטציה
- חיפושים באינטרנט
  - סידור התוצאות בצורה מוצלחת יותר (עפ"י אשכולות עניין")
- צריכת מוצרים
  - סידור מוצרים בסופר לפי אשכולות
- חיפוש חריגים
  - למשל פעולות בכרטיסי אשראי

# גישות מרכזיות ב-Clustering

- שיטות **מבוססות חלוקה** (Partitioning) – בהינתן קבוצה של $n$ אובייקטים, חלק ל-$k$ תתי קבוצות (k<=n). כל תת קבוצה צריכה להכיל אובייקט אחד לפחות וכל אובייקט משוייך לקבוצה אחת בלבד.
- שיטות **היררכיות** – בונים מבנה היררכי של תתי הקבוצות
  - Agglomerative (bottom-up)
  - Divisive(top-down)
- שיטות מבוססות **צפיפות** (Density Based) – לא נסתכל רק על המרחק בין הנקודות על גם האם יש "מסלול" ביניהן

# שיטות מבוססות חלוקה

- בהינתן K - מצא חלוקה ל-K אשכולות שמביאה אותנו לאופטימיזציה
  - אופטימום גלובלי – עבור על כל החלוקות האפשריות ובחר את הטובה ביותר.
  - כל אשכול מיוצג ע"י מרכז האשכול

# Lossy Compression

Suppose you transmit the coordinates of points drawn randomly from this dataset.

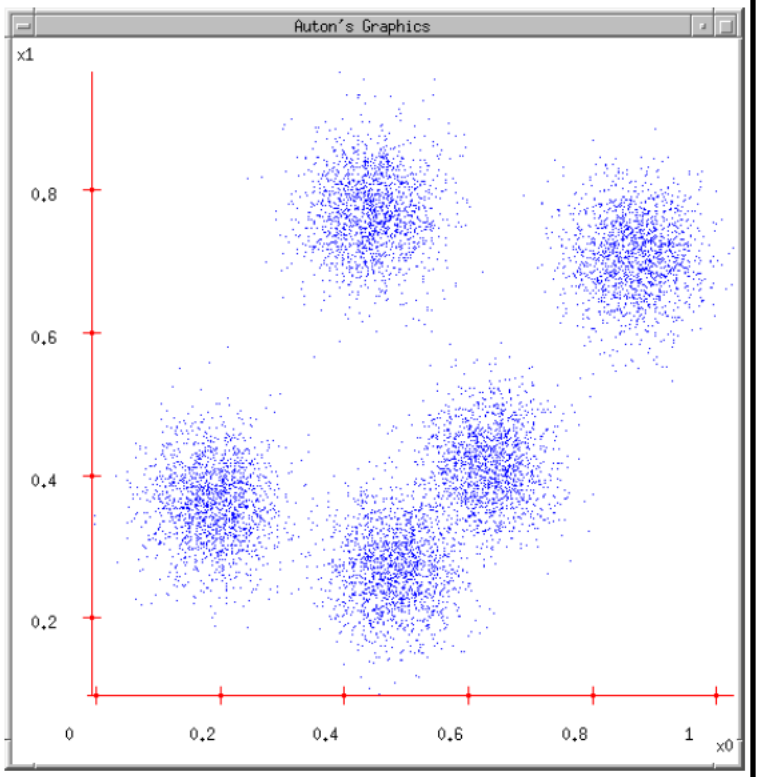
You can install decoding software at the receiver.

You're only allowed to send two bits per point.

It'll have to be a "lossy transmission".

Loss = Sum Squared Error between decoded coords and original coords.

What encoder/decoder will lose the least information?




Copyright © 2001, 2004, Andrew W. Moore



http://www.autonlab.org/tutorials/kmeans.html

# Idea One

Suppose you transmit the coordinates of points randomly from this d

You can install decod software at the receiver.

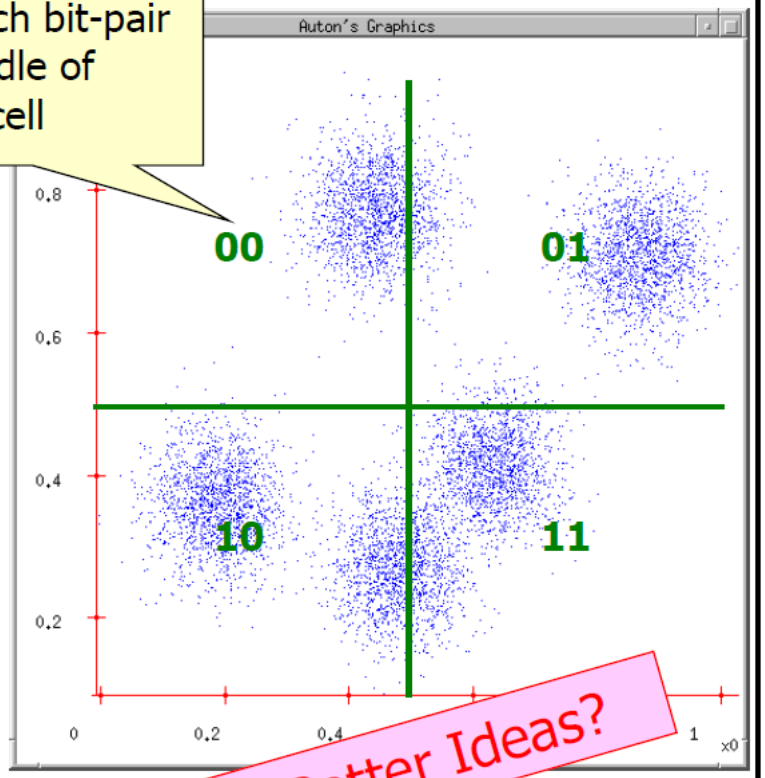
You're only allowed to send two bits per point.

It'll have to be a "lossy transmission".

Loss = Sum Squared Error between decoded coords and original coords.

What encoder/decoder will lose the least information?

Break into a grid, decode each bit-pair as the middle of each grid-cell




Any Better Ideas?

Copyright © 2001, 2004, Andrew W. Moore



http://www.autonlab.org/tutorials/kmeans.html

# Idea Two

Suppose you transmit the coordinates of poi
randomly from thi

You can install de
software at the receiver.

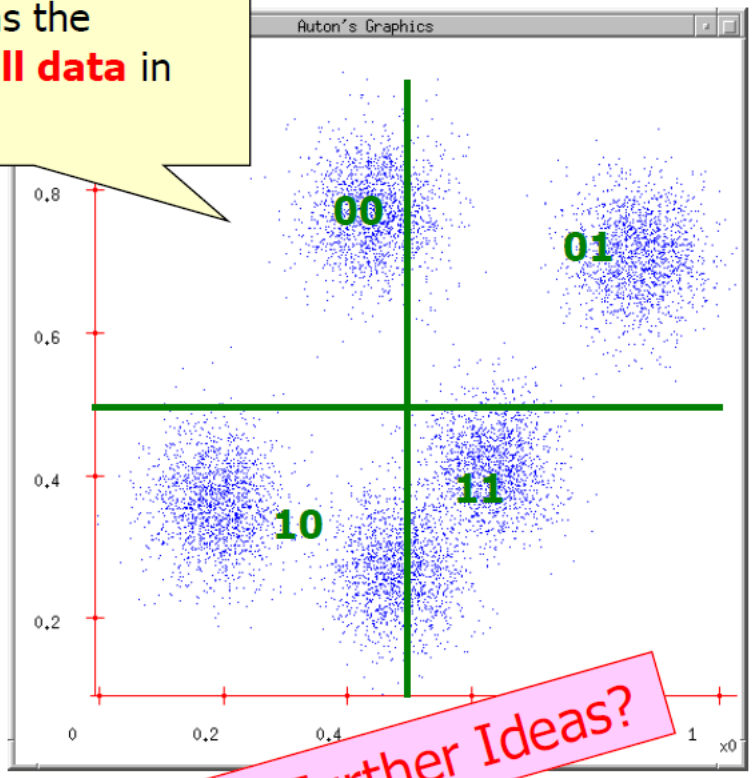
You're only allowed to send two bits per point.

It'll have to be a "lossy transmission".

Loss = Sum Squared Error between decoded coords and original coords.

What encoder/decoder will lose the least information?

Break into a grid, decode each bit-pair as the **centroid of all data** in that grid-cell




Any Further Ideas?

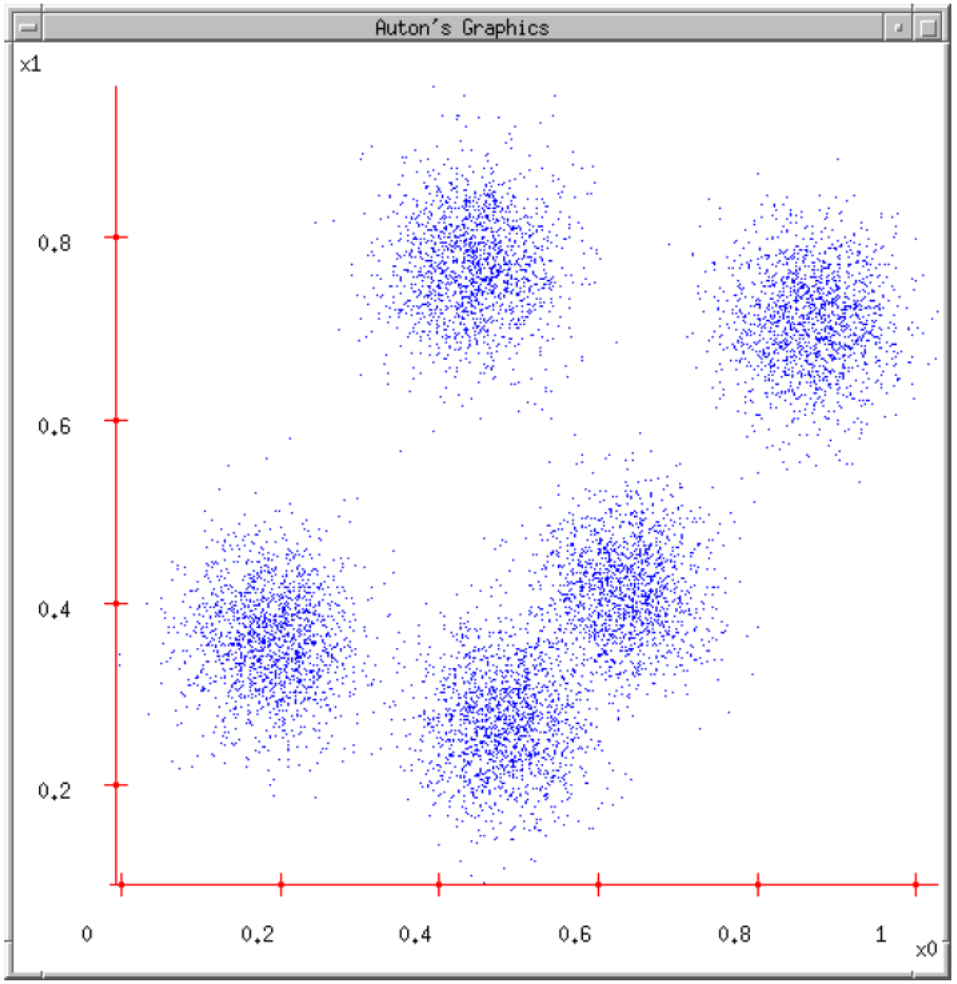
Copyright © 2001, 2004, Andrew W. Moore



http://www.autonlab.org/tutorials/kmeans.html

# K-means

1. Ask user how many clusters they'd like. *(e.g. k=5)*



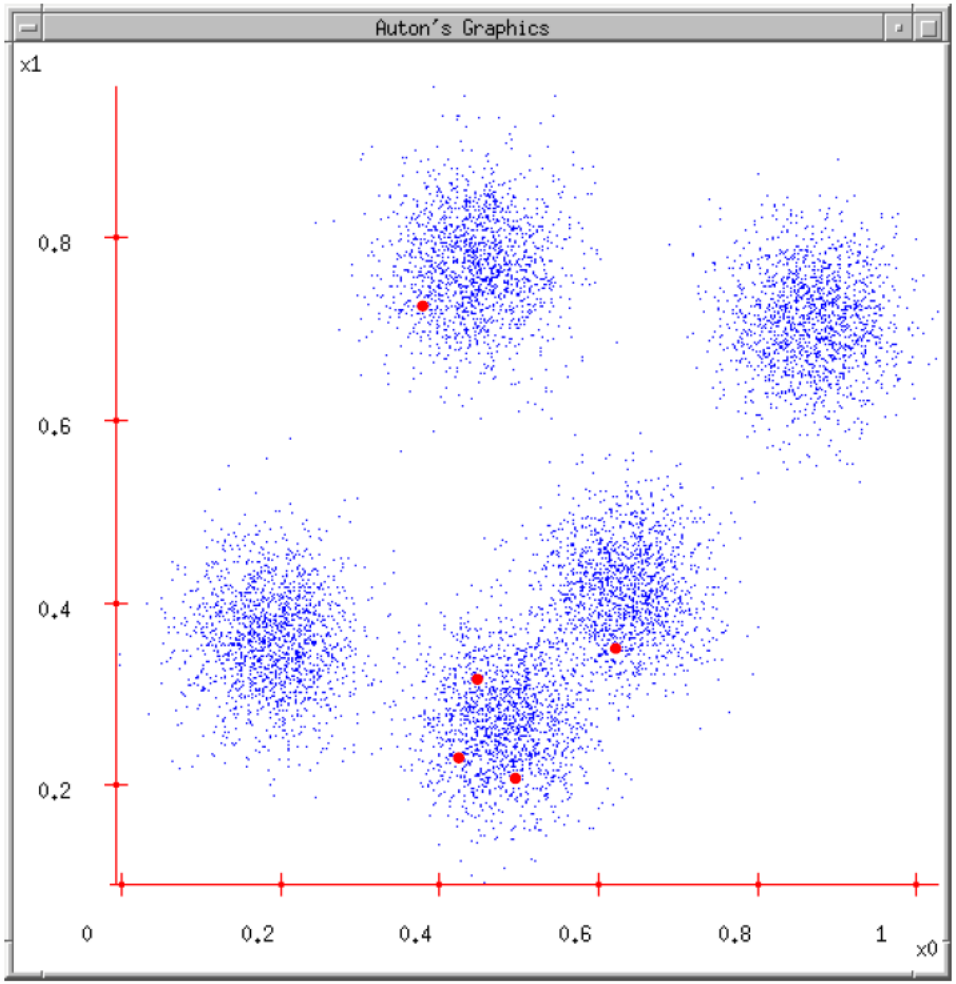

Copyright © 2001, 2004, Andrew W. Moore



http://www.autonlab.org/tutorials/kmeans.html

# K-means

1. Ask user how many clusters they'd like. *(e.g. k=5)*
2. Randomly guess k cluster Center locations



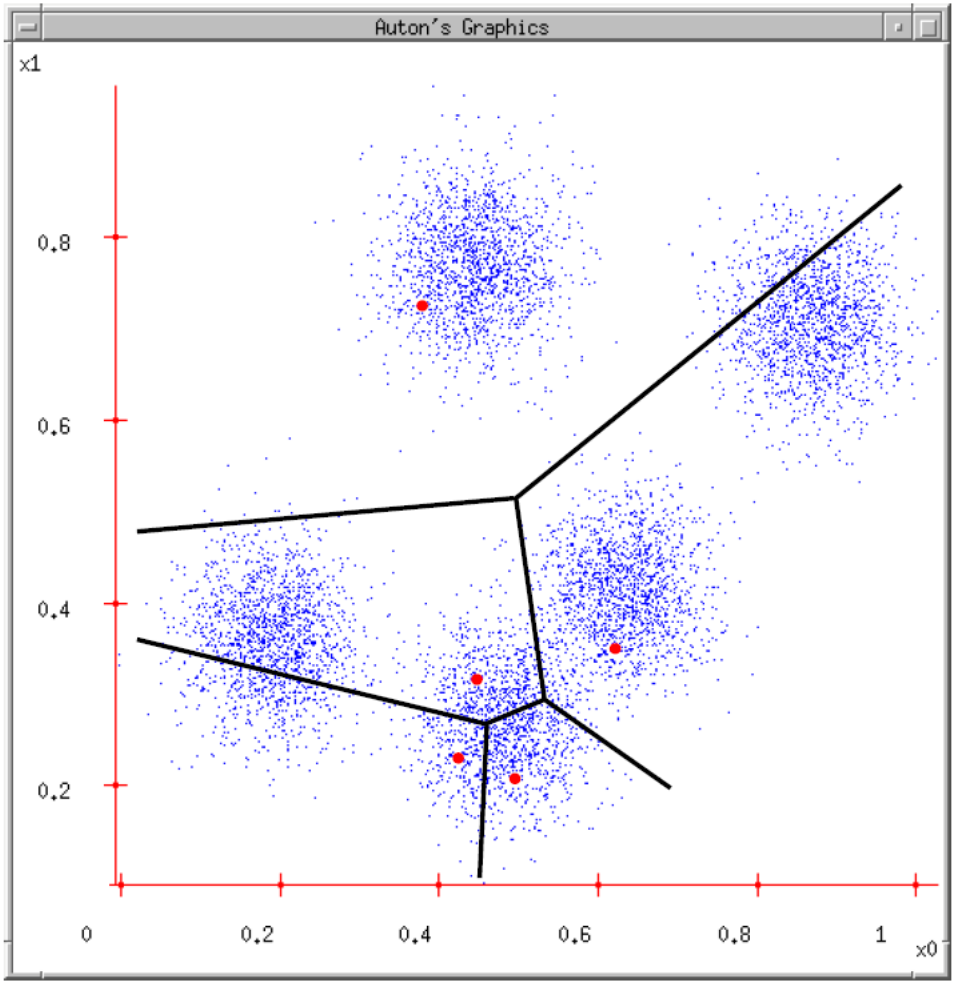

Copyright © 2001, 2004, Andrew W. Moore



http://www.autonlab.org/tutorials/kmeans.html

# K-means

1. Ask user how many clusters they'd like. *(e.g. k=5)*
2. Randomly guess k cluster Center locations
3. Each datapoint finds out which Center it's closest to. (Thus each Center "owns" a set of datapoints)



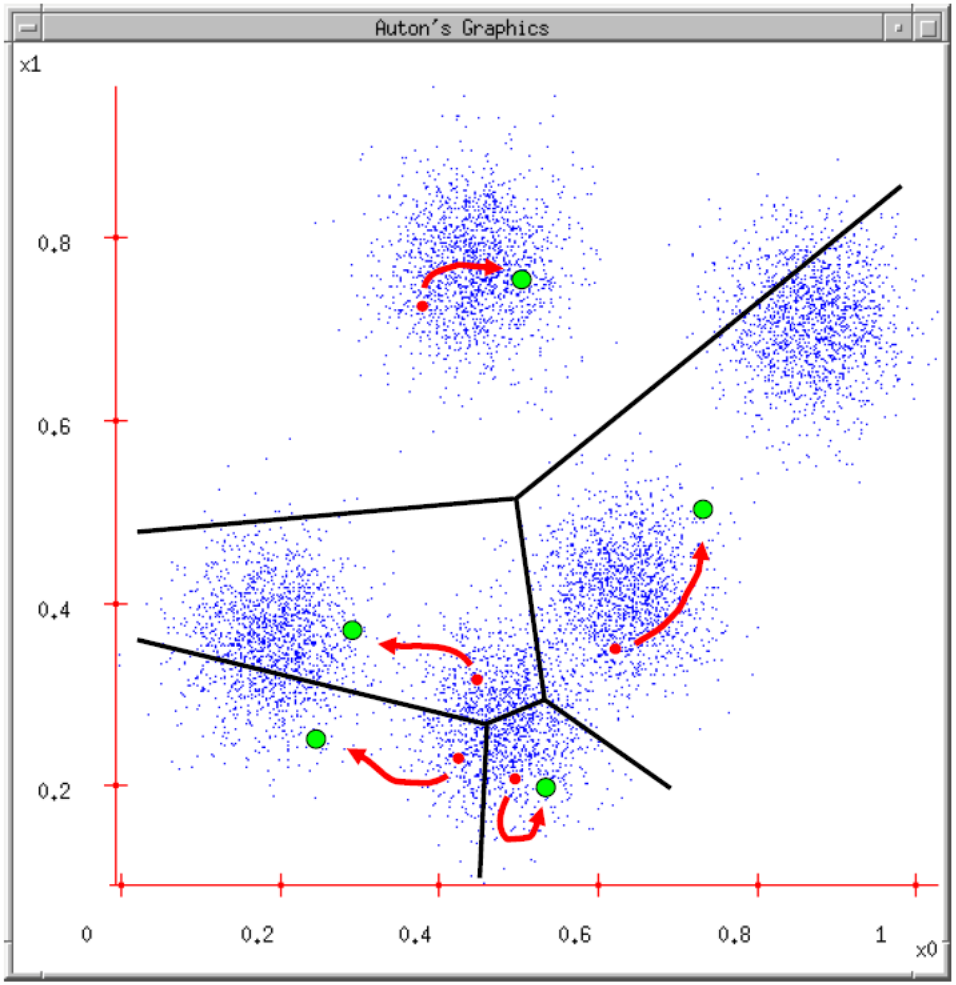

Copyright © 2001, 2004, Andrew W. Moore



http://www.autonlab.org/tutorials/kmeans.html

# K-means

1. Ask user how many clusters they'd like. *(e.g. k=5)*
2. Randomly guess k cluster Center locations
3. Each datapoint finds out which Center it's closest to.
4. Each Center finds the centroid of the points it owns



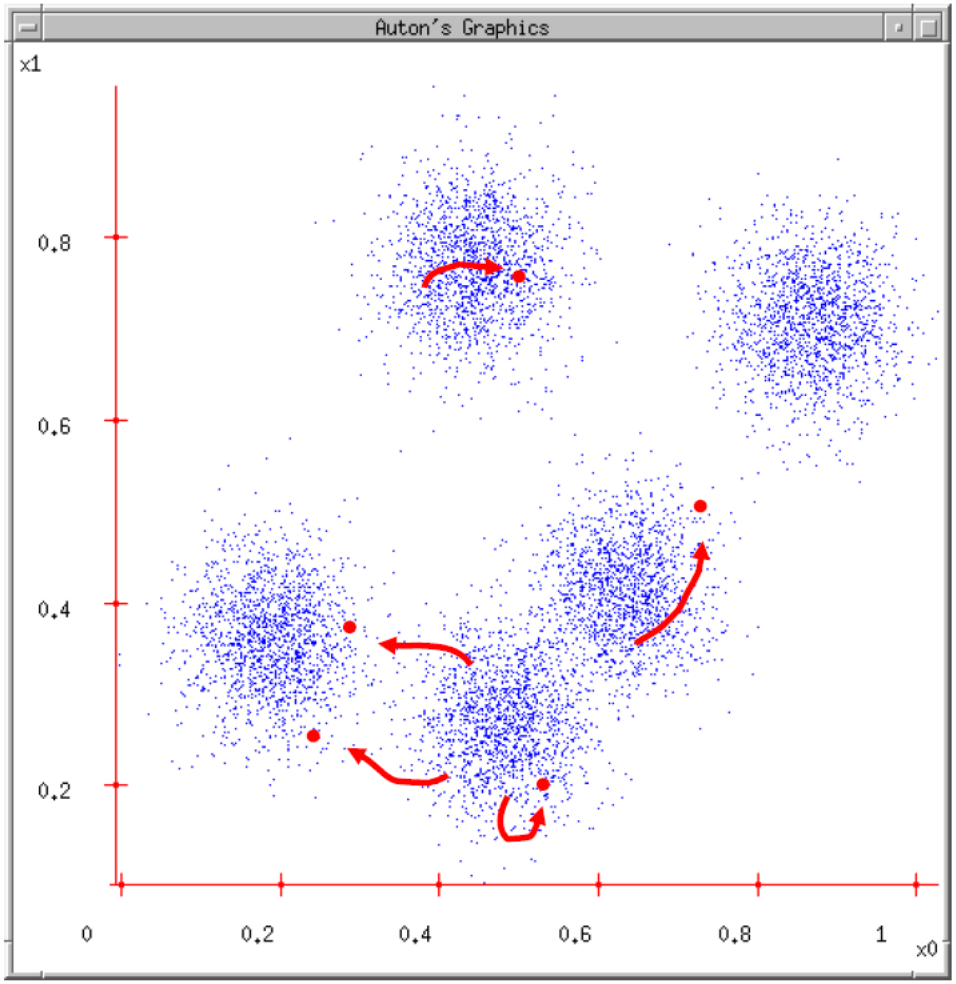

Copyright © 2001, 2004, Andrew W. Moore



http://www.autonlab.org/tutorials/kmeans.html

# K-means

1. Ask user how many clusters they'd like. *(e.g. k=5)*
2. Randomly guess k cluster Center locations
3. Each datapoint finds out which Center it's closest to.
4. Each Center finds the centroid of the points it owns...
5. ...and jumps there
6. ...Repeat until terminated!




Copyright © 2001, 2004, Andrew W. Moore



http://www.autonlab.org/tutorials/kmeans.html

# K-means Questions

- What is it trying to optimize?
- Are we sure it will terminate?
- Are we sure it will find an optimal clustering?
- How should we start it?
- How could we automatically choose the number of centers?

....we'll deal with these questions over the next few slides

Copyright © 2001, 2004, Andrew W. Moore



http://www.autonlab.org/tutorials/kmeans.html

# Distortion

Given..

•an encoder function: ENCODE : $\Re^m \rightarrow [1..k]$

•a decoder function: DECODE : $[1..k] \rightarrow \Re^m$

Define...

$$\text{Distortion} = \sum_{i=1}^{R} \left(\mathbf{x}_i - \text{DECODE}[\text{ENCODE}(\mathbf{x}_i)]\right)^2$$

Copyright © 2001, 2004, Andrew W. Moore



http://www.autonlab.org/tutorials/kmeans.html

# Distortion

Given..

- an encoder function: ENCODE : $\Re^m \rightarrow [1..k]$
- a decoder function: DECODE : $[1..k] \rightarrow \Re^m$

Define…

$$\text{Distortion} = \sum_{i=1}^{R} \left(\mathbf{x}_i - \text{DECODE}[\text{ENCODE}(\mathbf{x}_i)]\right)^2$$

We may as well write

$$\text{DECODE}[j] = \mathbf{c}_j$$

$$\text{so} \quad \text{Distortion} = \sum_{i=1}^{R} (\mathbf{x}_i - \mathbf{c}_{\text{ENCODE}(\mathbf{x}_i)})^2$$

Copyright © 2001, 2004, Andrew W. Moore



http://www.autonlab.org/tutorials/kmeans.html

# The Minimal Distortion (1)

$$\text{Distortion} = \sum_{i=1}^{R} (\mathbf{x}_i - \mathbf{c}_{\text{ENCODE}(\mathbf{x}_i)})^2$$

What properties must centers $\boldsymbol{c}_1$ , $\boldsymbol{c}_2$ , … , $\boldsymbol{c}_k$ have when distortion is minimized?

(1) $\boldsymbol{x}_i$ must be encoded by its nearest center

....why?

כי אחרת נוכל להחליף במרכז הקרוב יותר ולהפחית את הסטייה

$$\mathbf{c}_{\text{ENCODE}(\mathbf{x}_i)} = \arg\min_{\mathbf{c}_j \in \{\mathbf{c}_1, \mathbf{c}_2, \ldots \mathbf{c}_k\}} (\mathbf{x}_i - \mathbf{c}_j)^2$$

..at the minimal distortion

Copyright © 2001, 2004, Andrew W. Moore



http://www.autonlab.org/tutorials/kmeans.html

(2) The partial derivative of Distortion with respect to each center location must be zero.

$$\text{Distortion} = \sum_{i=1}^{R} (\mathbf{x}_i - \mathbf{c}_{\text{ENCODE}(\mathbf{x}_i)})^2$$

$$= \sum_{j=1}^{k} \sum_{i \in \text{OwnedBy}(\mathbf{c}_j)} (\mathbf{x}_i - \mathbf{c}_j)^2$$

$$\frac{\partial \text{Distortion}}{\partial \mathbf{c}_j} = \frac{\partial}{\partial \mathbf{c}_j} \sum_{i \in \text{OwnedBy}(\mathbf{c}_j)} (\mathbf{x}_i - \mathbf{c}_j)^2$$

$$= -2 \sum_{i \in \text{OwnedBy}(\mathbf{c}_j)} (\mathbf{x}_i - \mathbf{c}_j)$$

$$= 0 \text{ (for a minimum)}$$

Thus, at a minimum: $\mathbf{c}_j = \frac{1}{|\text{OwnedBy}(\mathbf{c}_j)|} \sum_{i \in \text{OwnedBy}(\mathbf{c}_j)} \mathbf{x}_i$

Copyright © 2001, 2004, Andrew W. Moore



http://www.autonlab.org/tutorials/kmeans.html

# At the minimum distortion

$$\text{Distortion} = \sum_{i=1}^{R} (\mathbf{x}_i - \mathbf{c}_{\text{ENCODE}(\mathbf{x}_i)})^2$$

What properties must centers $\boldsymbol{c}_1$ , $\boldsymbol{c}_2$ , … , $\boldsymbol{c}_k$ have when distortion is minimized?

(1) $\boldsymbol{x}_i$ must be encoded by its nearest center

(2) Each Center must be at the centroid of points it owns.

Copyright © 2001, 2004, Andrew W. Moore



http://www.autonlab.org/tutorials/kmeans.html

# אלגוריתם K-means

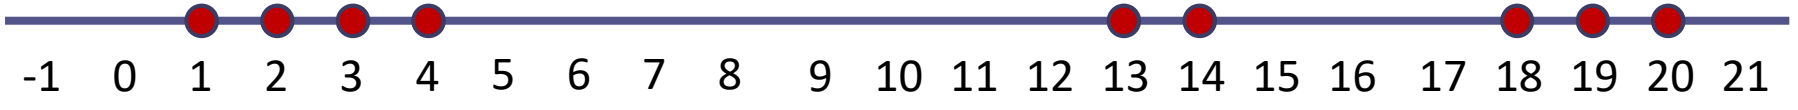
- נתון: אוסף ווקטורים ופרמטר K
- מצא חלוקה אופטימאלית שמחלקת ל-K אשכולות

- אלגוריתם:
  1. "נחש" K מרכזים
  2. שייך כל ווקטור ל"מרכז" הקרוב אליו
  3. חשב מרכזים מחדש ע"י מציאת מרכז האשכול
  4. חזור על צעדים 2-3 עד שאין יותר עדכונים

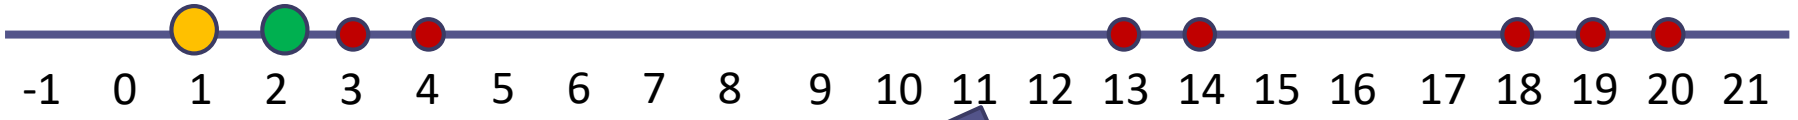
# דוגמא 1D

- נתונות הנקודות הבאות:
  - 1,2,3,4,13,14,18,19,20
- הרץ את אלגוריתם k-means על נקודות אלו.
  - הנח ש-k=2






- ננחש 2 "מרכזים" ראשונים 1,2



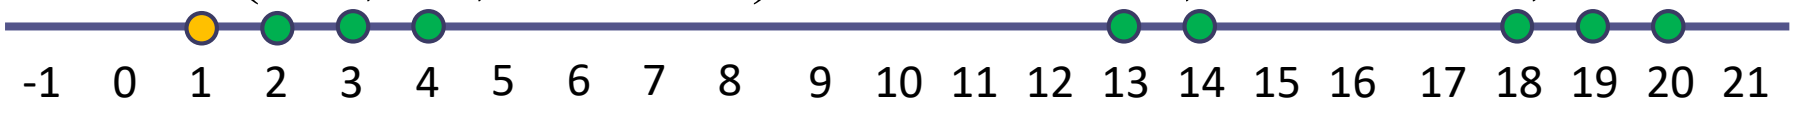

בחירה מאוד לא מושכלת




- נבחש 2 "מרכזים" ראשונים 1,2




- נשייך כעת את הנקודות ל"מרכזים"(עפ"י מרחק אוקלידי)




  - 4 קרוב יותר (אוקלידית) ל-2 מאשר ל-1
  - ...
  - 14 יותר קרוב (אוקלידית) ל-2 מאשר ל-1



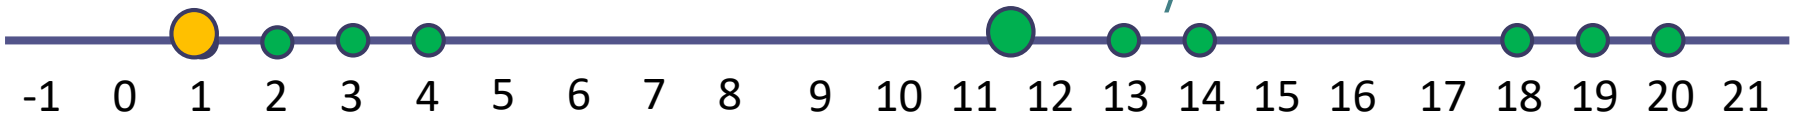

- נבחש 2 "מרכזים" ראשונים 1,2




- נשייך כעת את הנקודות ל"מרכזים"(עפ"י מרחק אוקלידי)

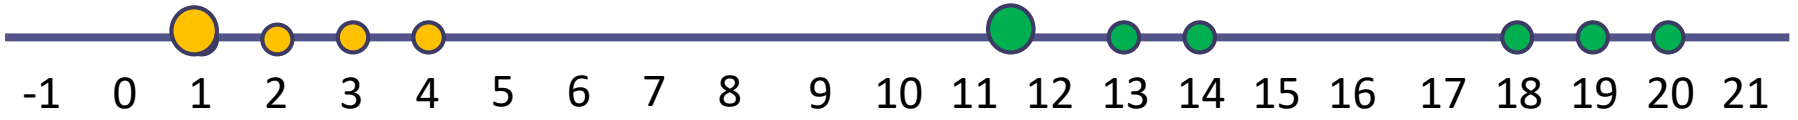



- נעדכן "מרכזים":
  - מרכז ירוק: (2+3+4+13+14+18+19+20)/8=11.6
  - מרכז כתום: 1/1=1






- נשייך כעת את הנקודות ל"מרכזים"

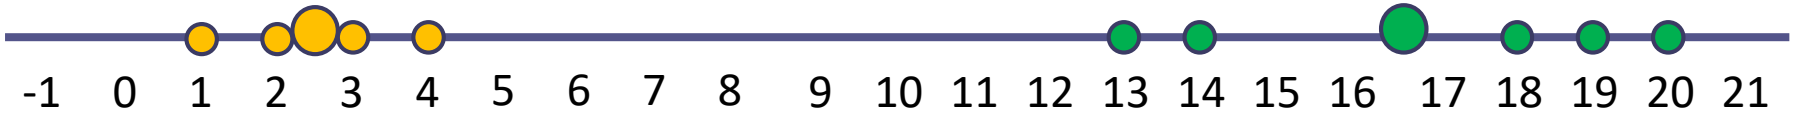



- נעדכן "מרכזים":
  - מרכז ירוק: (13+14+18+19+20)/5=16.8
  - מרכז כתום: (1+2+3+4)/4=2.5

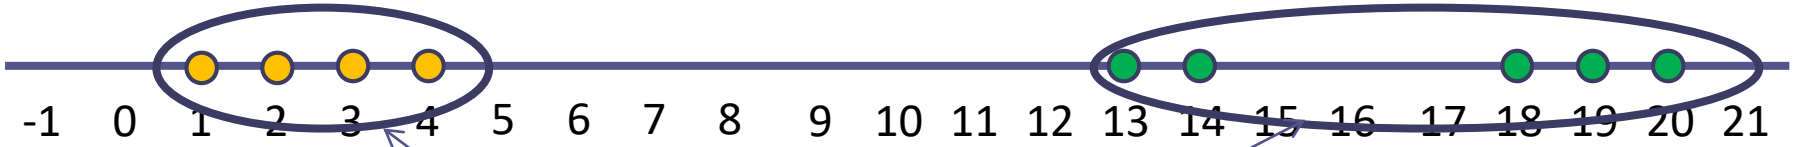



- שיוך נקודות ל"מרכזים"






- אין עדכונים ולכן האלגוריתם עוצר




אלו 2 ה"אשכולות" שנוצרו

# כעת נריץ עבור k=3

- נתונות הנקודות הבאות:
  - 1,2,3,4,13,14,18,19,20
- הרץ את אלגוריתם k-means על נקודות אלו.
  - הנח ש-k=3

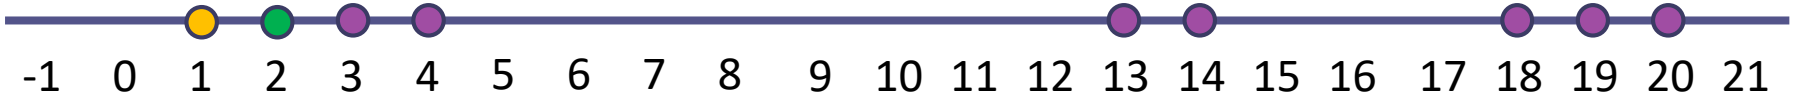




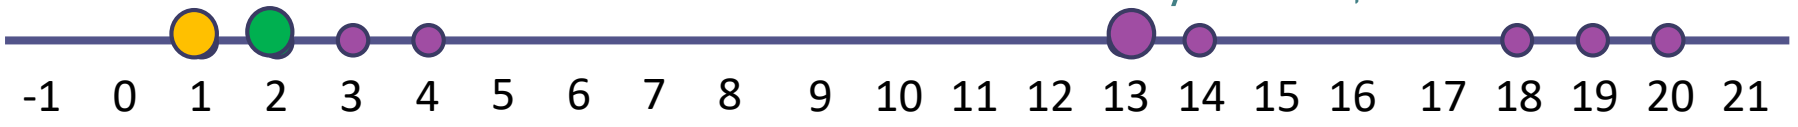

- ננחש 3 "מרכזים" ראשונים 1,2,3 (שוב בחירה מאוד לא מושכלת)




- נשייך כעת את הנקודות ל"מרכזים"(עפ"י מרחק אוקלידי)




- נעדכן "מרכזים":
  - מרכז סגול: (3+4+13+14+18+19+20)/7=13
  - מרכז כתום: 1/1=1
  - מרכז ירוק: 2/1=2






- נשייך כעת את הנקודות ל"מרכזים"

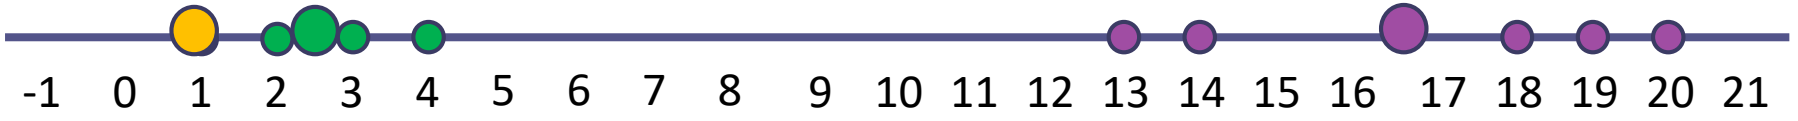



- נעדכן "מרכזים":
  - מרכז סגול: (13+14+18+19+20)/5=16.8
  - מרכז ירוק: (2+3+4)/4=2.5
  - מרכז כתום: 1/1=1

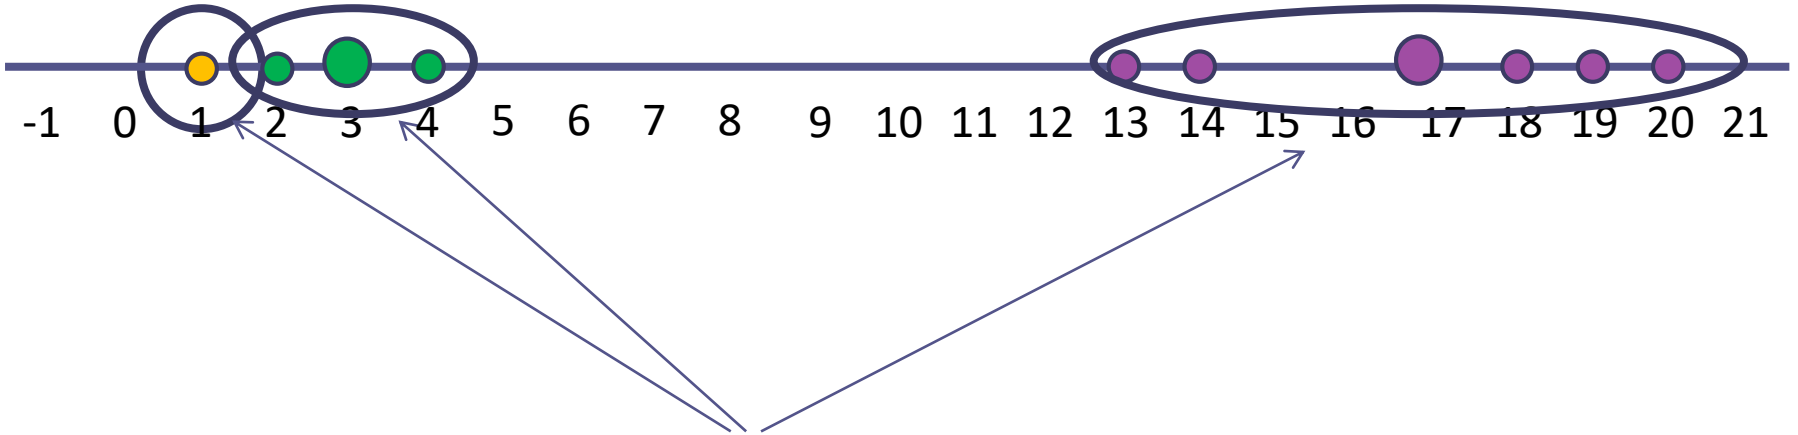



- שיוך נקודות ל"מרכזים"






- אין עדכונים ולכן האלגוריתם עוצר




אלו 3 ה"אשכולות" שנוצרו

# נחשב את הסטיה שנוצרה

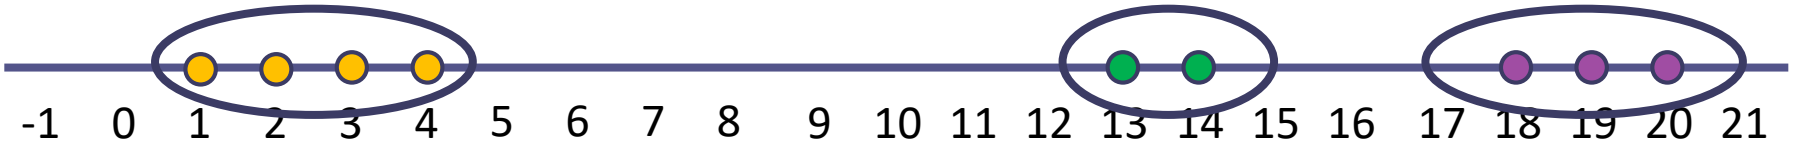
$$cluster1:(1-1)^2=0$$

$$cluster2:(2-3)^2+(3-3)^2+(4-3)^2=2$$

$$cluster3:(13-16.8)^2+(14-16.8)^2+(18-16.8)^2+(19-16.8)^2+(20-16.8)^2=38.8$$

$$Total:0+2+38.8=40.8$$

האם יכולנו למצוא סטיה קטנה יותר? – נבחן את האופציה הבאה




$$cluster1:(1-2.5)^2+(2-2.5)^2+(3-2.5)^2+(4-2.5)^2=5$$

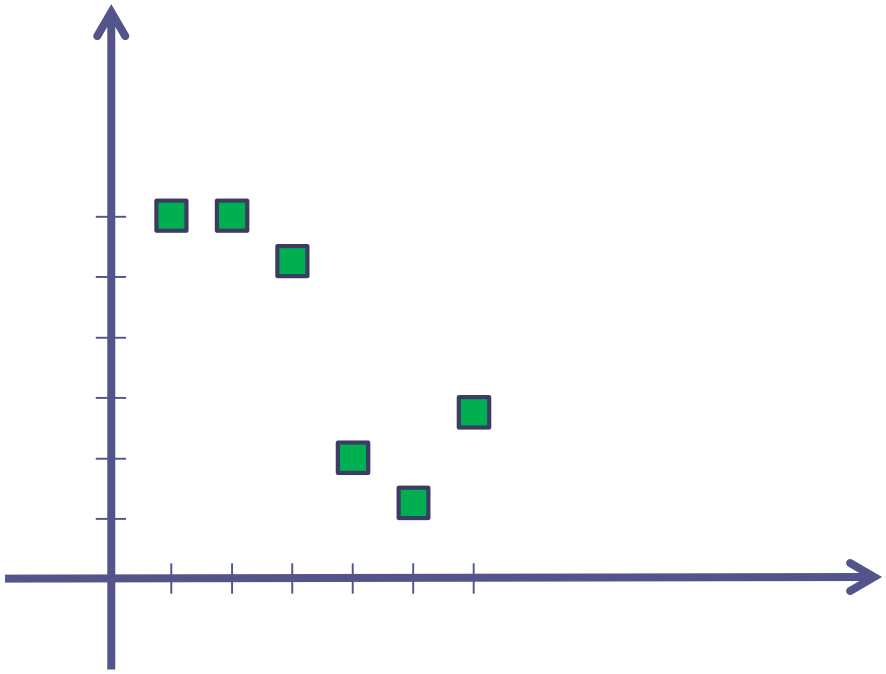
$$cluster2:(13-13.5)^2+(14-13.5)^2=0.5$$

$$cluster3:(18-19)^2+(19-19)^2+(20-19)^2=2$$

$$Total:5+0.5+2=7.5$$

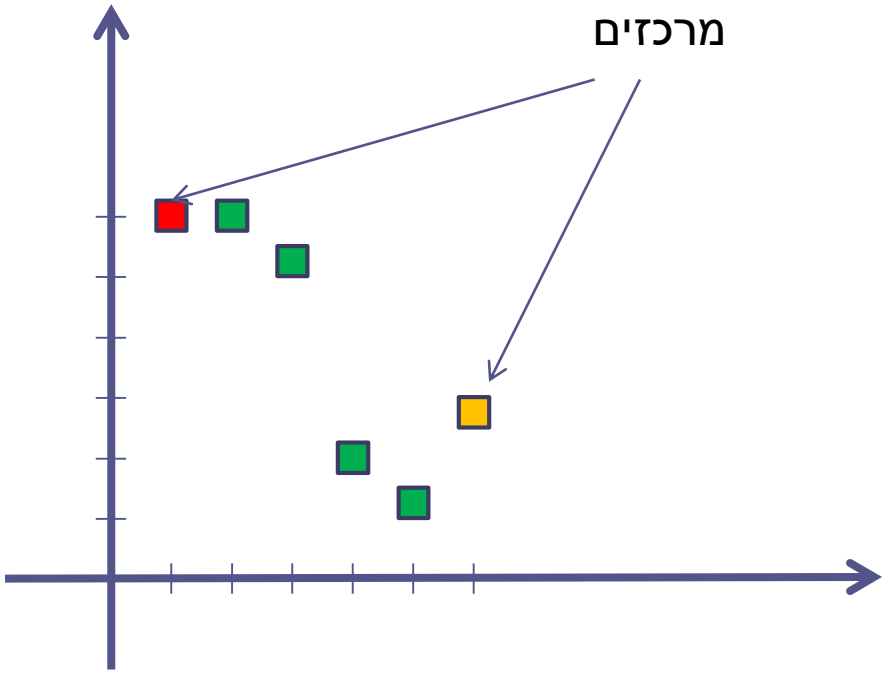
# תרגיל 2D

- נתונים הווקטורים הבאים:



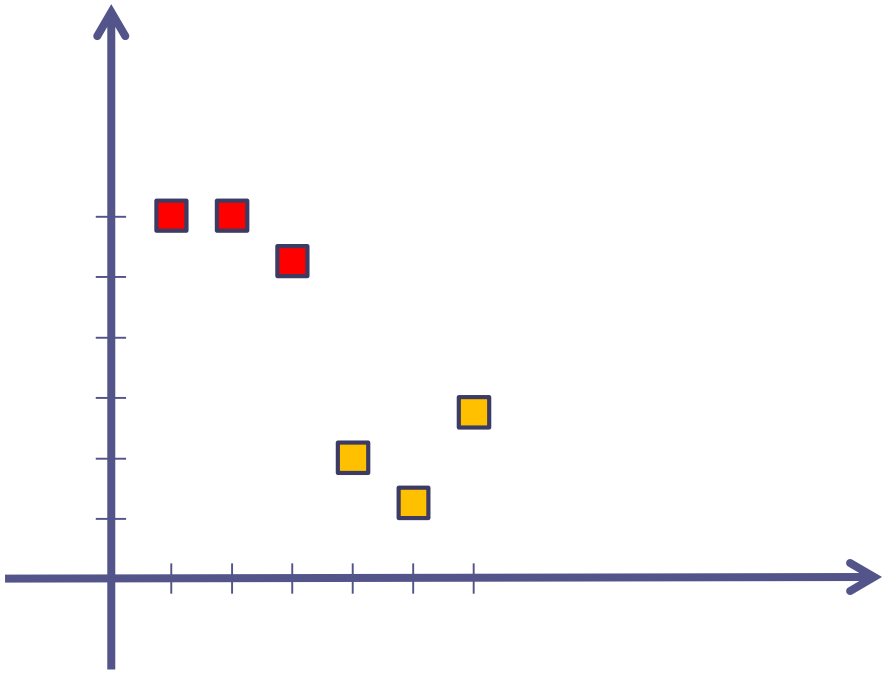
| x1 | x2 |
|---|---|
| 2 | 7 |
| 3 | 6 |
| 1 | 7 |
| 6 | 1 |
| 5 | 2 |
| 7 | 3 |

# קביעת מרכזים

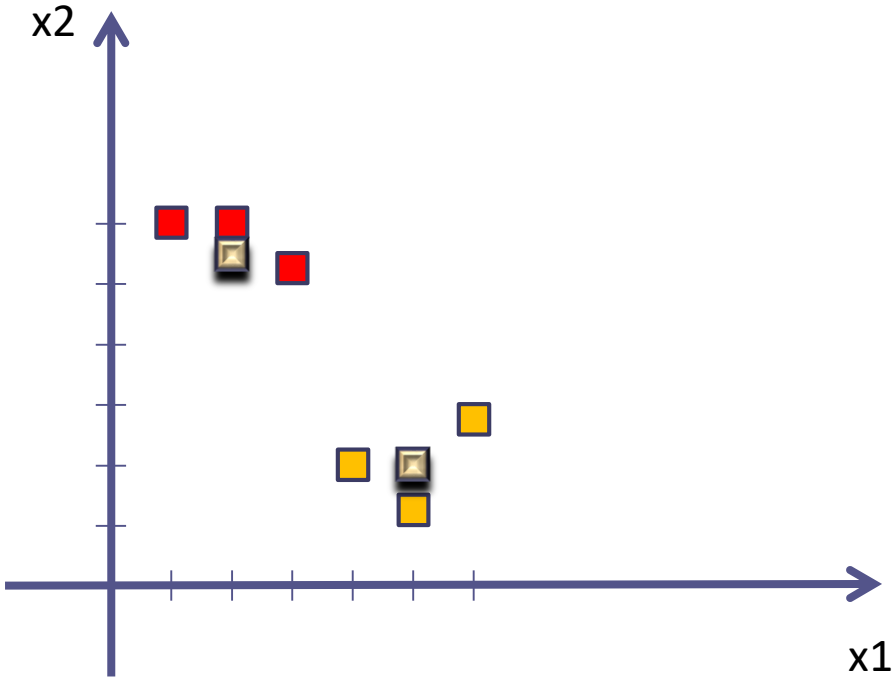


# שיוך ווקטורים למרכזים

- חישוב מרחקים (אוקלידי) של הווקטורים מהמרכזים ושיוך כל ווקטור למרכז הקרוב אליו



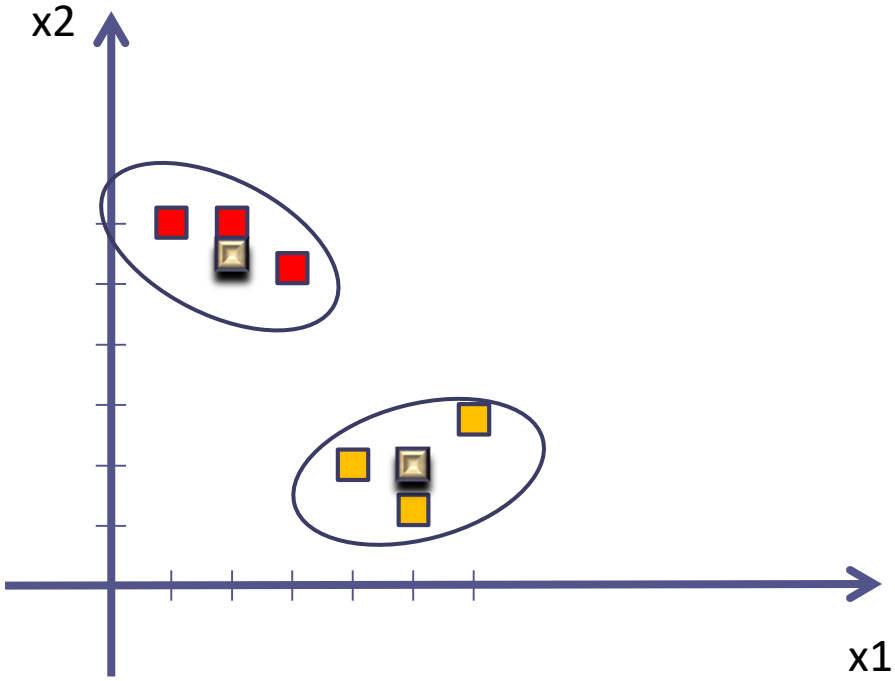
# עדכון מרכזים

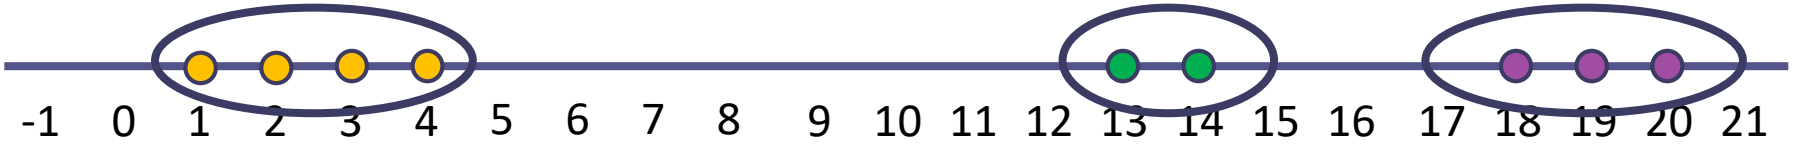



- מרכז אדום:
  - X1 =(1+2+3)/3=2
  - X2 = (7+7+6)/3 = 6.6
- מרכז צהוב:
  - X1 =(4+5+6)/3=5
  - X2 = (1+2+3)/3 = 2

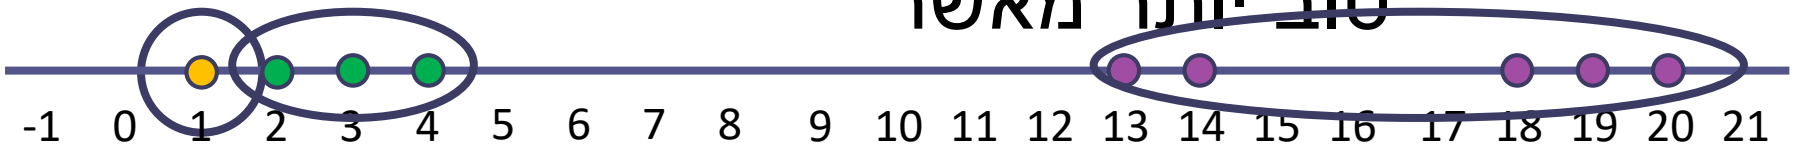
# שיוך ווקטורים למרכזים

- אין עדכון ולכן סיימנו את התהליך






טוב יותר מאשר




בחירה לא טובה של נקודות ההתחלה
הביאה אותנו למינימום מקומי

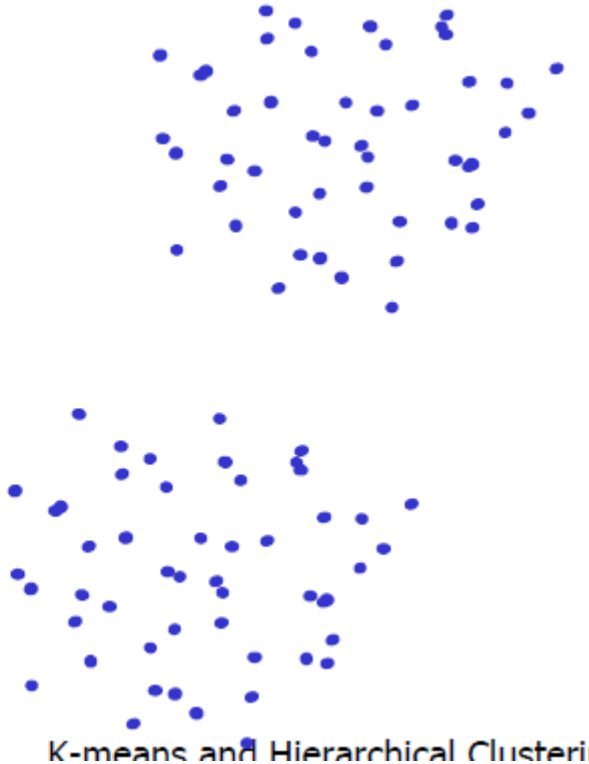
# האם מובטח לנו שהתהליך יתכנס?

- יש **מס' סופי של אפשרויות לחלק R ווקטורים ל-K קבוצות**
- כלומר, יש מס' סופי של מרכזים אפשריים
- אם השתנתה הקונפיגורציה (שינוי מרכזים/שיוך נקודות מחדש למרכזים) סימן שיש לנו "סטיה" קטנה יותר מאשר הייתה לפני כן.
- כלומר: בוודאי שבכל עדכון אנו מגיעים לקונפיגורציה שעדיין לא היינו בה לפני כן.
- ולכן מס' האיטרציות האפשריות הינו סופי.

# האם מובטח לנו למצוא את הקונפיגורציה האופטימאלית?

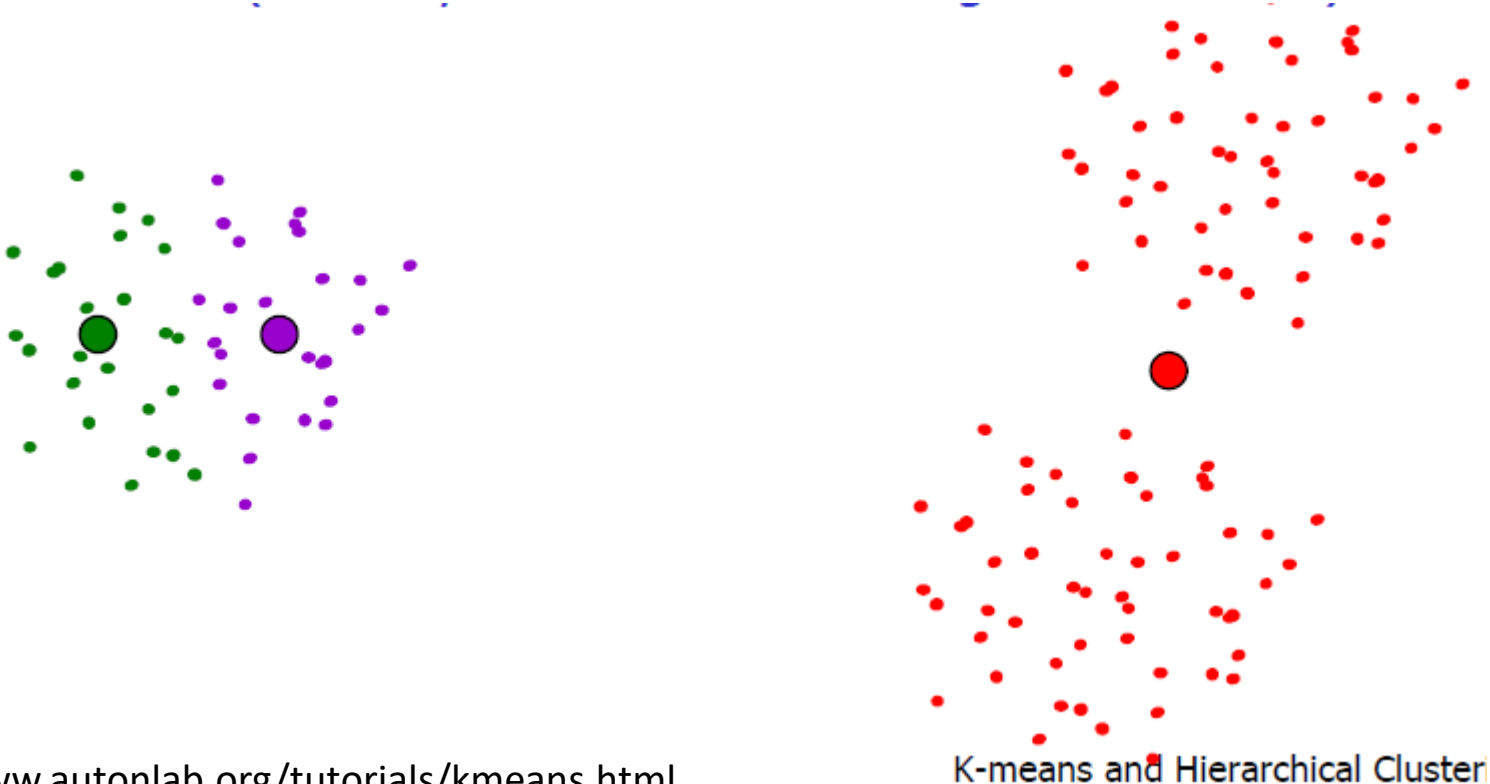
- לא בהכרח






http://www.autonlab.org/tutorials/kmeans.html

# האם מובטח לנו למצוא את הקונפיגורציה האופטימאלית?




http://www.autonlab.org/tutorials/kmeans.html

# שאלה

- אחד הקשיים באלגוריתם K-means הוא מציאת K
- מציעים לנו את האלגוריתם הבא:
  - נסה כל k אפשרי עד למציאת k שמביא אותנו למינימום סטיה (distortion)
- האם האלגוריתם טוב ?

# שאלה

- אחד הקשיים באלגוריתם K-means הוא מציאת K
- מציעים לנו את האלגוריתם הבא:
  - נסה כל k אפשרי עד למציאת k שמביא אותנו למינימום סטיה (distortion)
- האם האלגוריתם טוב ?

- תשובה: כמובן אלגוריתם לא טוב.
  - יתכנס ל-k=n

# Trying to find good optima

- Idea 1: Be careful about where you start
- Idea 2: Do many runs of k-means, each from a different random start configuration
- Many other ideas floating around.



Copyright © 2001, 2004, Andrew W. Moore

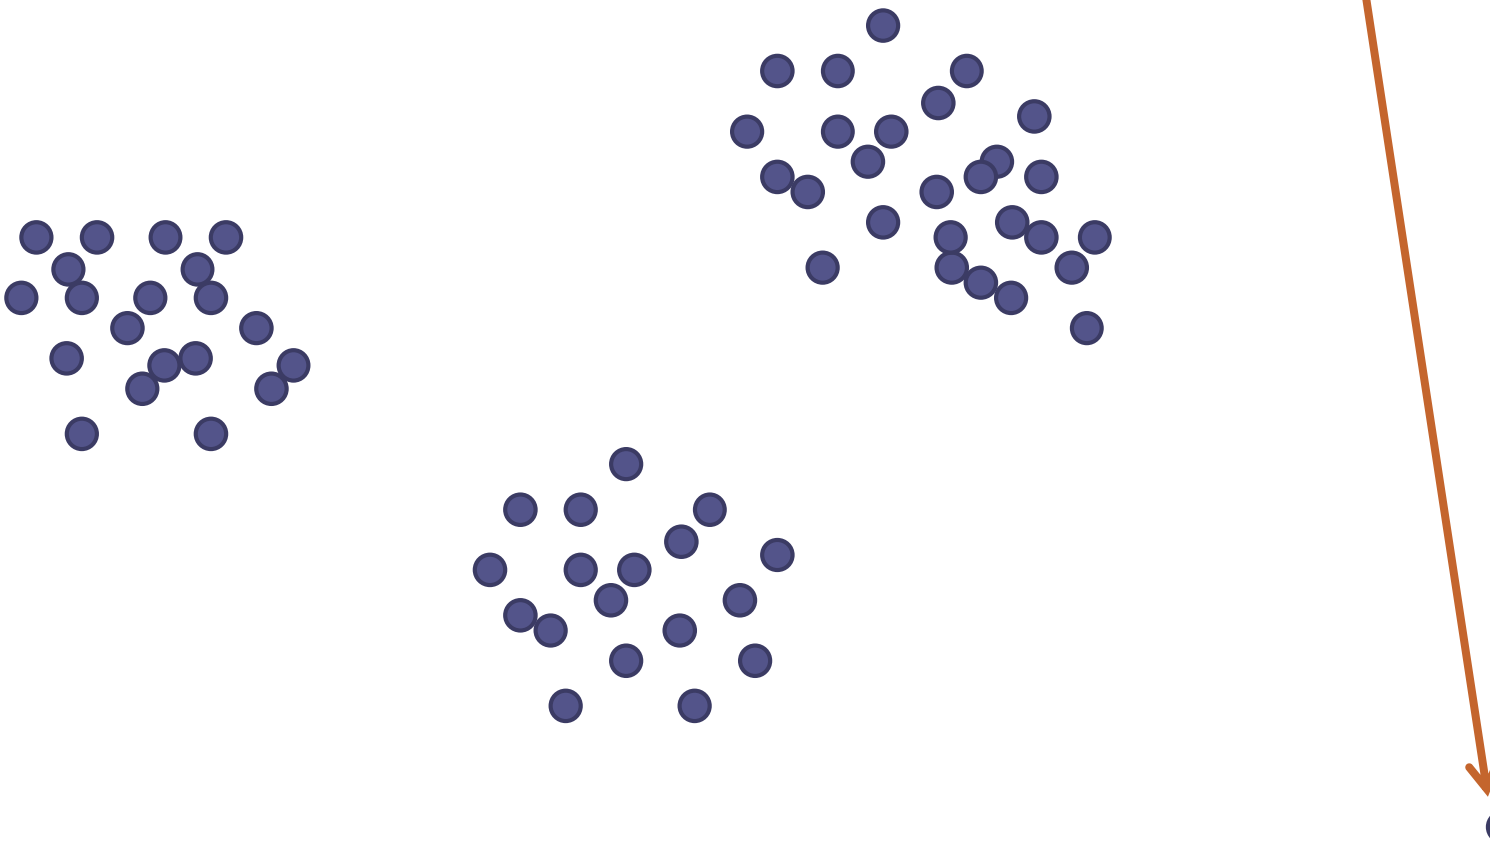


http://www.autonlab.org/tutorials/kmeans.html

# K-means - סיכום

- יתרונות:
  - קל למימוש
  - יעיל חישובית
- חסרונות:
  - עלול לעצור במינימום מקומי
  - מוגדר היטב כאשר ניתן לחשב ממוצע של מאפיין. מה נעשה עבור ערכים קטגוריים???
  - צריך להגדיר את K
  - רגיש ל-outliers

# רגישות ל-outliers



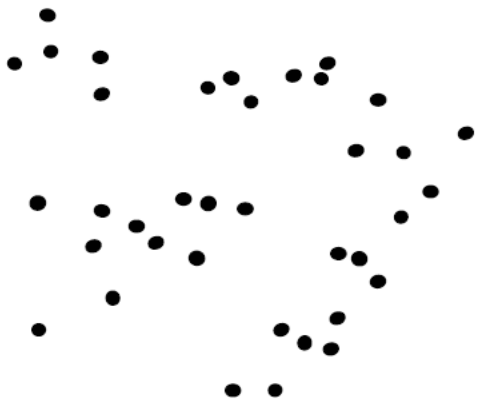
# K-mediods

- כדי לפתור את בעיית ה-outliers שב- k-means נקבע ש"מרכז" חייב להיות אחד האובייקטים בפועל (ולא הממוצע)
- הרעיון באלגוריתם:
  - "נחש" K-mediods (כלומר אובייקטים בפועל)
  - נסה לעדכן את ה-mediods באובייקטים אחרים ולבדוק האם השתפרת
- אלגוריתמים ידועים:
  - PAM – Partitioning Around Mediods
  - CLARA – Clustering Large Application

# שיטות היררכיות

- בונים מבנה היררכי של תתי הקבוצות
  - Agglomerative (bottom-up)
  - Divisive(top-down)

# Single Linkage Hierarchical Clustering



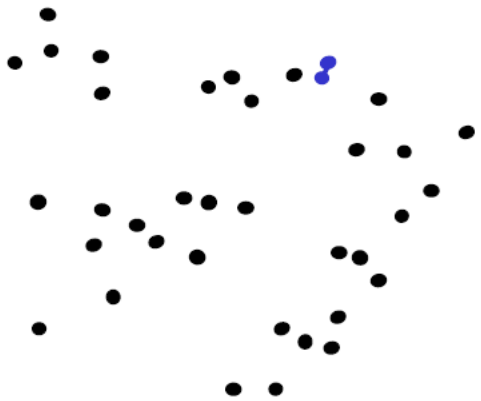
1. Say "Every point is its own cluster"

Copyright © 2001, 2004, Andrew W. Moore



http://www.autonlab.org/tutorials/kmeans.html

# Single Linkage Hierarchical Clustering



1. Say "Every point is its own cluster"
2. Find "most similar" pair of clusters

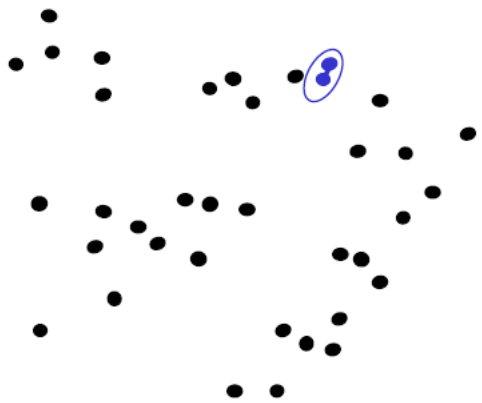


Copyright © 2001, 2004, Andrew W. Moore



http://www.autonlab.org/tutorials/kmeans.html

# Single Linkage Hierarchical Clustering



1. Say "Every point is its own cluster"
2. Find "most similar" pair of clusters
3. Merge it into a parent cluster

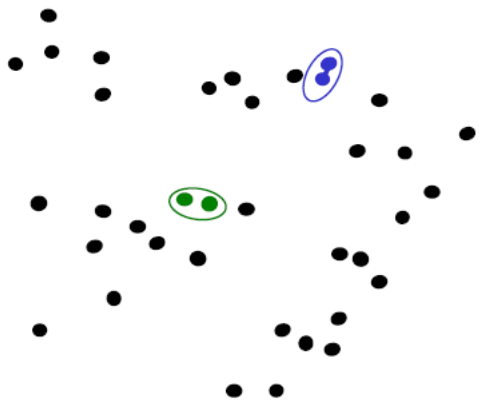


Copyright © 2001, 2004, Andrew W. Moore



http://www.autonlab.org/tutorials/kmeans.html

# Single Linkage Hierarchical Clustering



1. Say "Every point is its own cluster"
2. Find "most similar" pair of clusters
3. Merge it into a parent cluster
4. Repeat

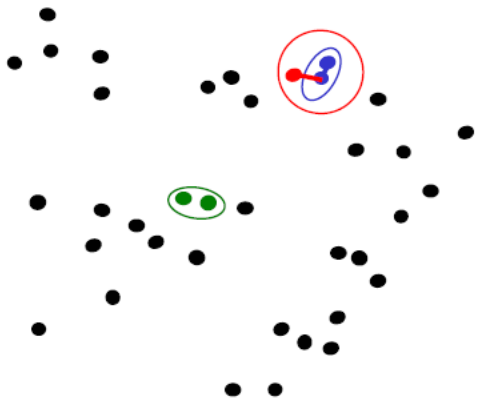


Copyright © 2001, 2004, Andrew W. Moore

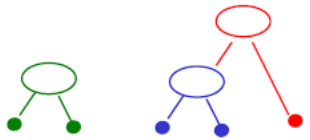


http://www.autonlab.org/tutorials/kmeans.html

# Single Linkage Hierarchical Clustering



1. Say "Every point is its own cluster"
2. Find "most similar" pair of clusters
3. Merge it into a parent cluster
4. Repeat

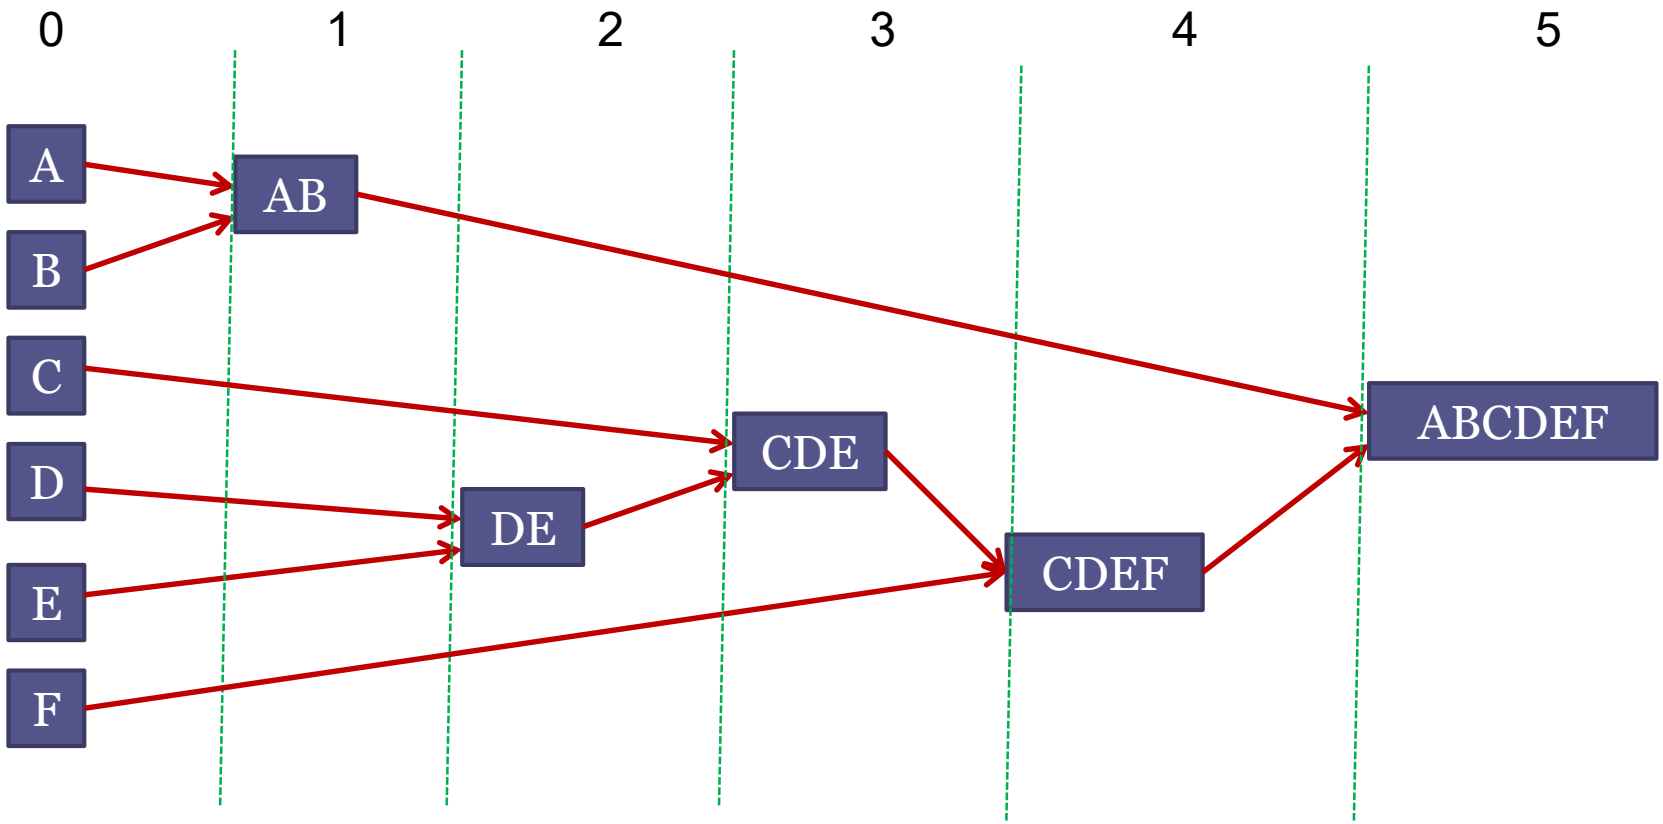


Copyright © 2001, 2004, Andrew W. Moore

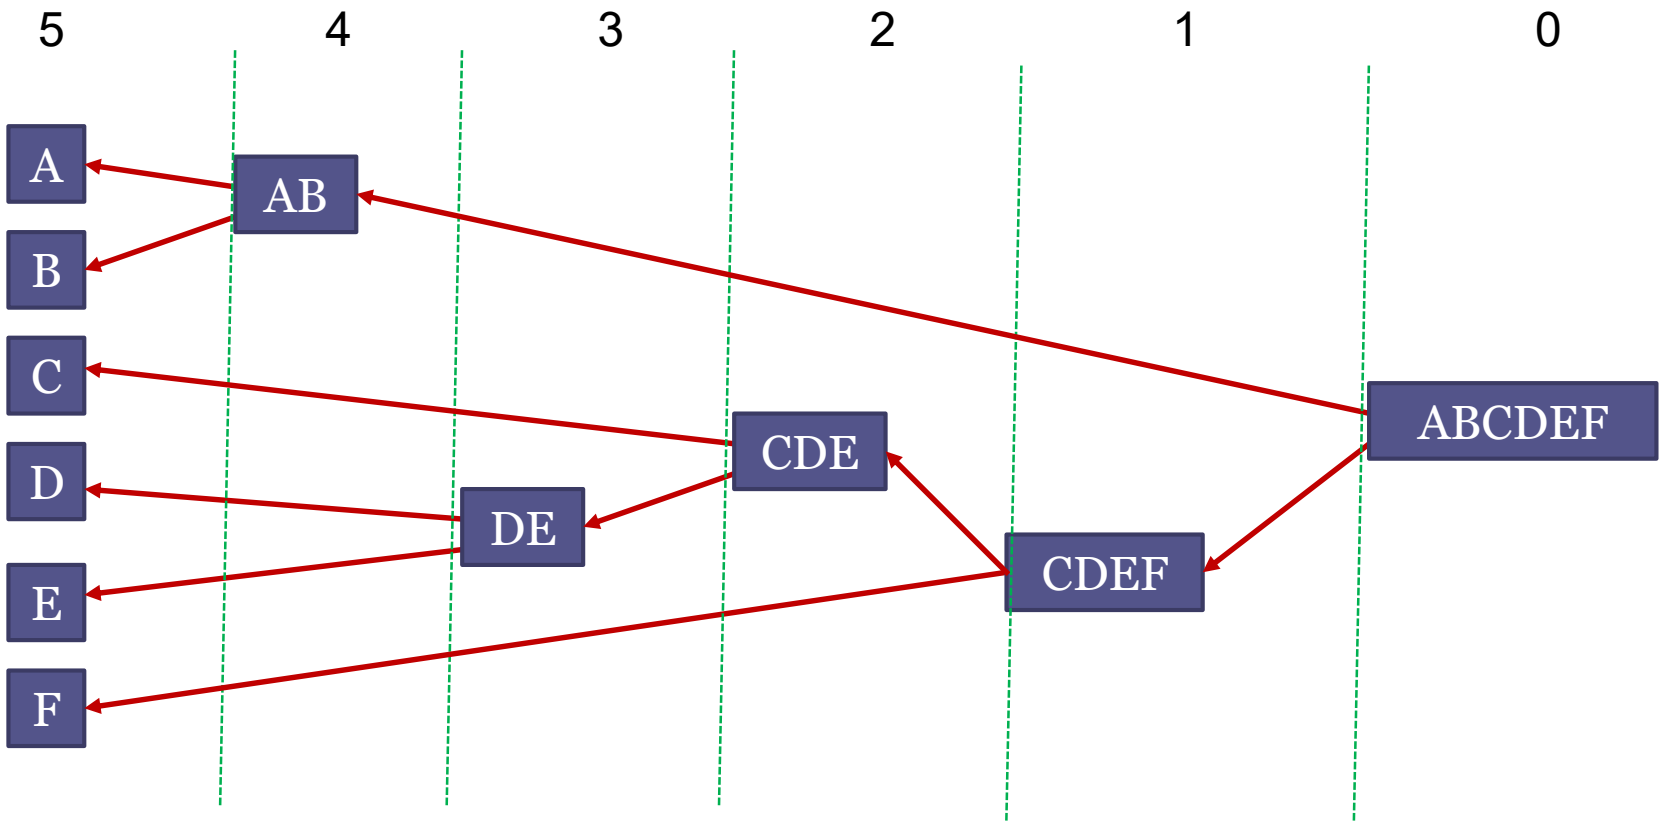


http://www.autonlab.org/tutorials/kmeans.html

# Agglomorative - שיטות היררכיות

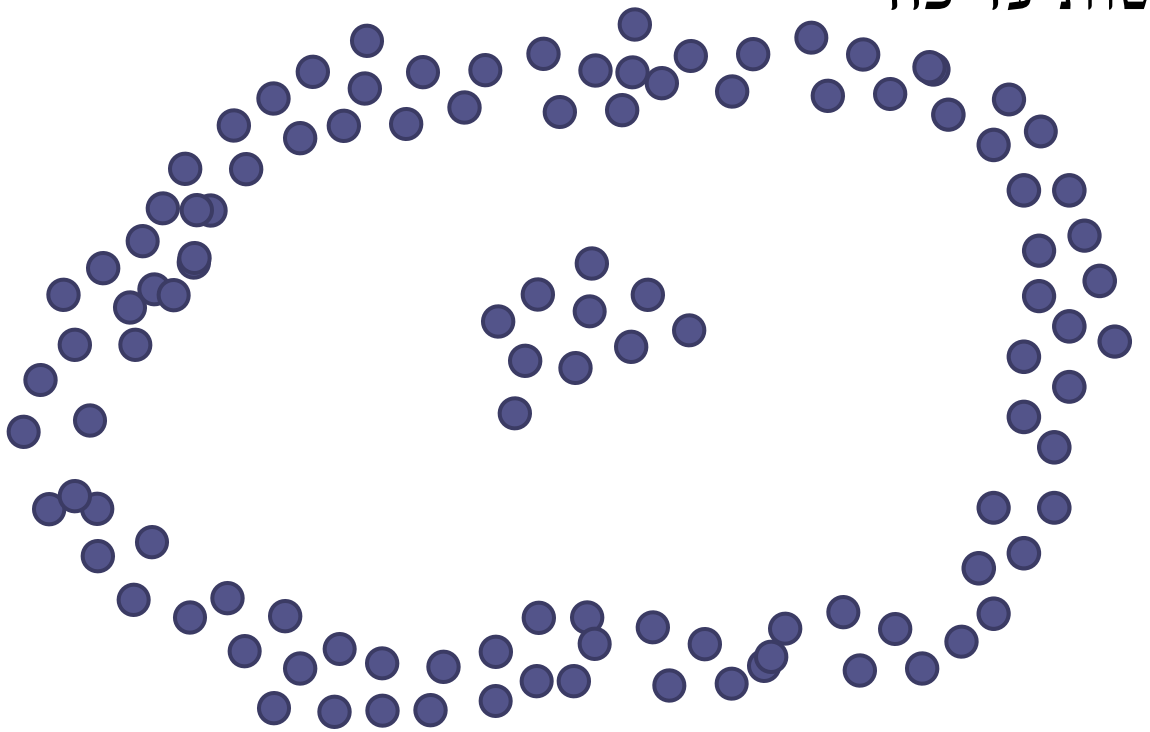


# שיטות היררכיות - Divisive



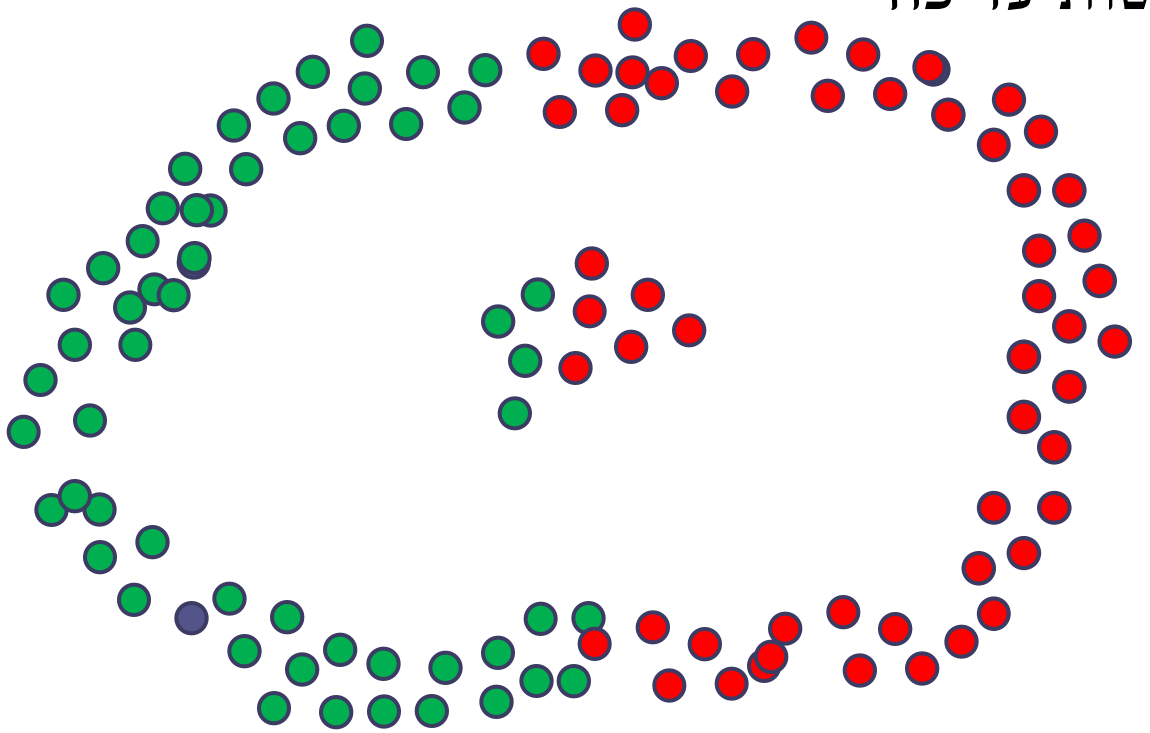
# שיטות מבוססות צפיפות

- הבעיה בשיטות עד כה



# שיטות מבוססות צפיפות

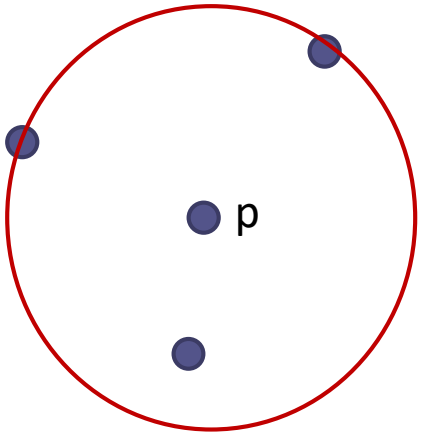
- הבעיה בשיטות עד כה



# אלגוריתמי "אישכול" מבוססי צפיפות - אלגוריתם DBSCAN

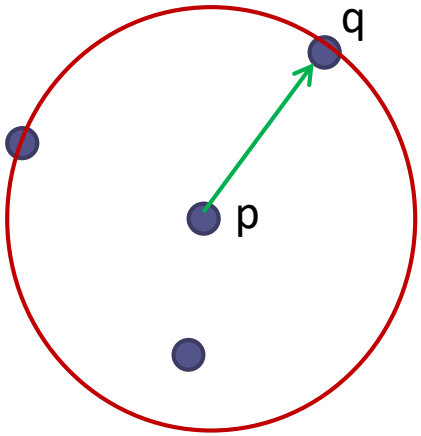
- נגדיר Core Object – אובייקט שיש בסביבה שלו (רדיוס r) לפחות MinPts אובייקטים
- Directly Density Reachable – Core Object עבור q ואובייקט p – נאמר ש-p הינו DDR מ-q אם הוא בסביבה r שלו.
- p הינו Density Reachable מ-q אם קיימים אובייקטים $p_1=q,p_2,p_3,p_4,.....p_n=p$ ומתקיים שכל $p_{i+1}$ הינו Directly Density Reachable מ- $p_i$

# r=2, MinPts=3



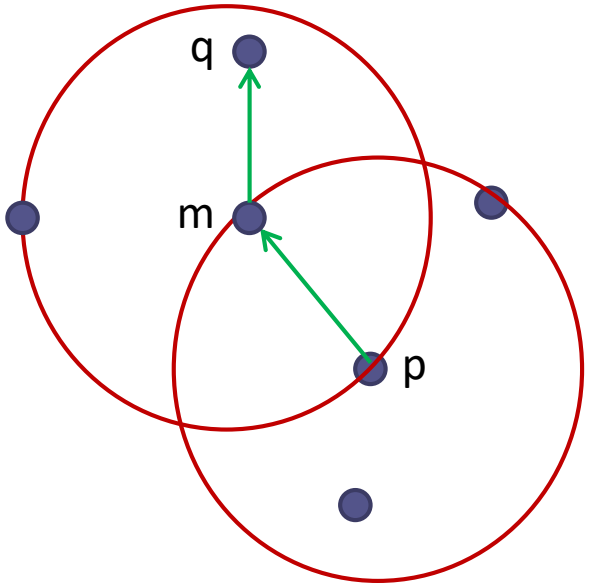

P is a Core Object

# r=2, MinPts=3




*q* is Directly Density Reachable from *p*

# r=2, MinPts=3

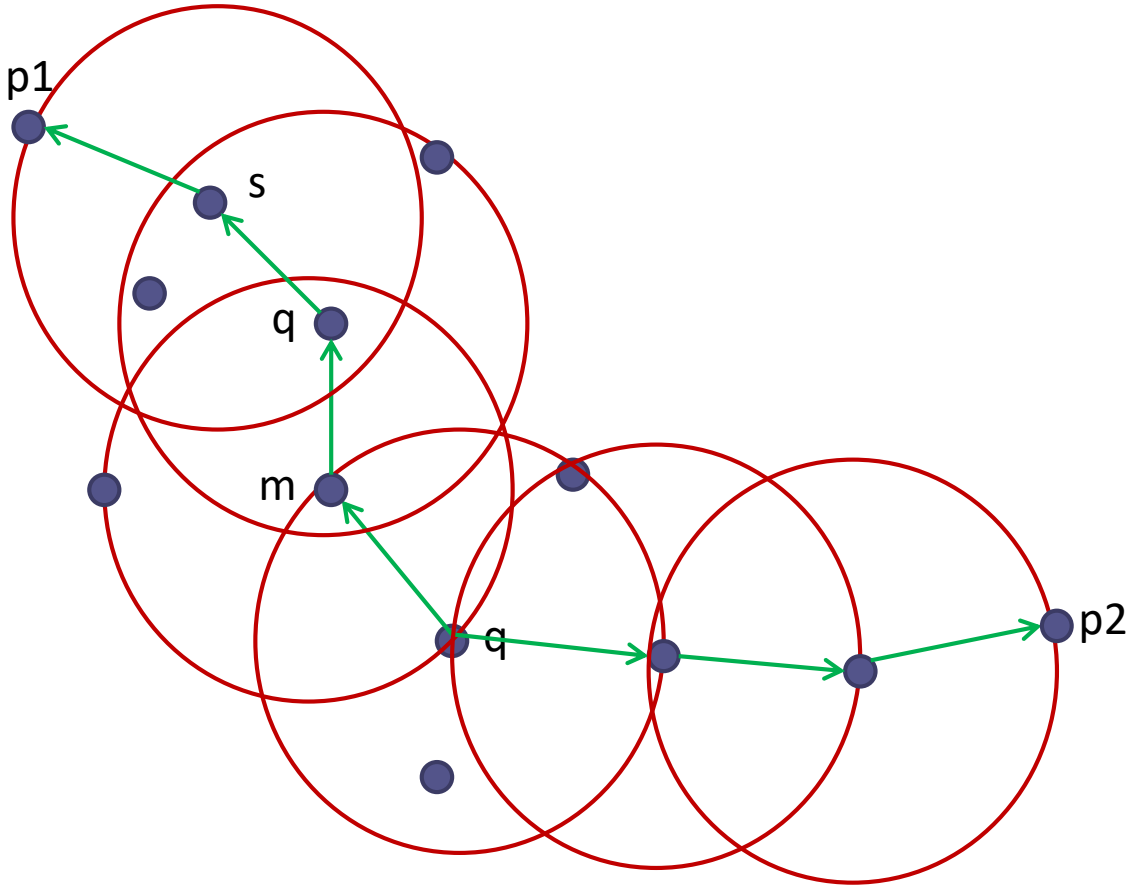



*q* is Density Reachable from *p*

# Density Connected

- נאמר ששני אובייקטים $p_1,p_2$ הינם density connected אם קיים אובייקט q כך שגם $p_1$ וגם $p_2$ הינם density reachable מ-q

# r=2, MinPts=3




*p1 and p2 are density connected*

# DBSCAN(Density Based Clustering Based On Connected Regions with High Density)

- נתונה הקבוצה D
- תת קבוצה $C \subseteq D$ הינה "אשכול" (מבוסס צפיפות) אם:
  - כל שני אובייקטים $o_1, o_2 \in C$ הינם Density Connected
  - לא קיימים אובייקטים $o \in C$ ואובייקט $(o' \in (D-C$ כך ש-o ו-o' הינם Density Connected

# אלגוריתם DBSCAN

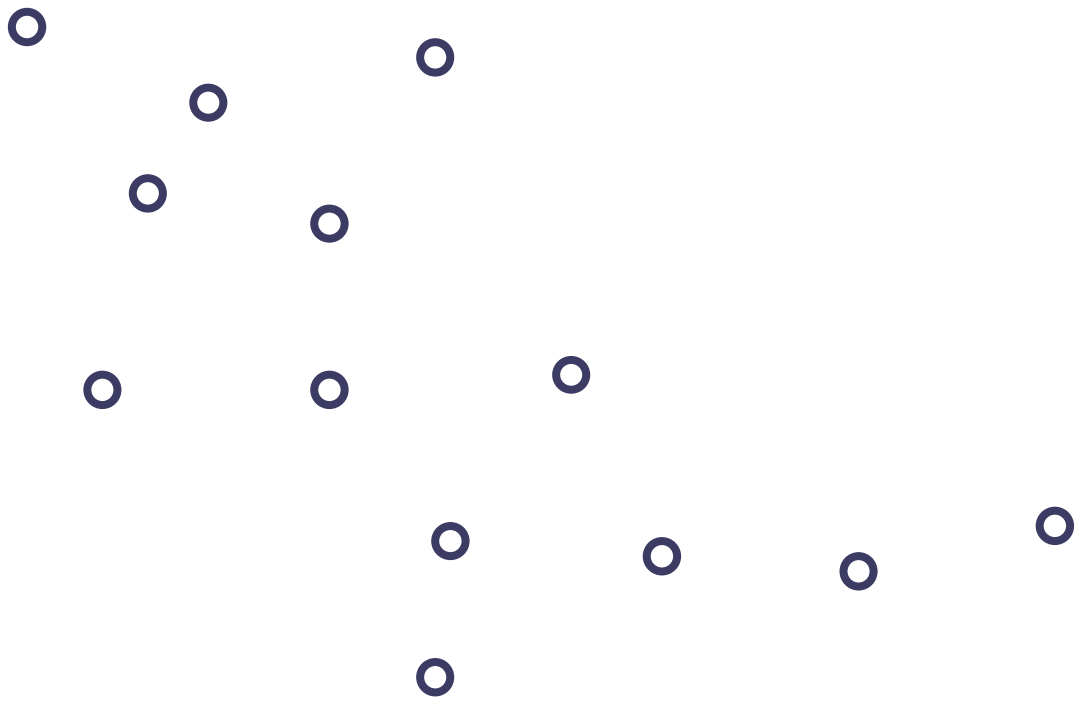
- קלט:
  - D קבוצה המכילה n אובייקטים
  - r פרמטר רדיוס, MinPts
- פלט:
  - קבוצה של אשכולות מבוססי צפיפות

- נגדיר:
  - Core object – אובייקט שיש לו יותר מ-minPts אובייקטים בתוך רדיוס r
  - Border point – יש לו פחות מ-MinPts אובייקטים ברדיוס r, אבל הוא בשכנות ל-Core Object
  - Noise Point – כל אובייקט שאינו border point ואינו core object

# r=2, MinPts=3

הרעיון:

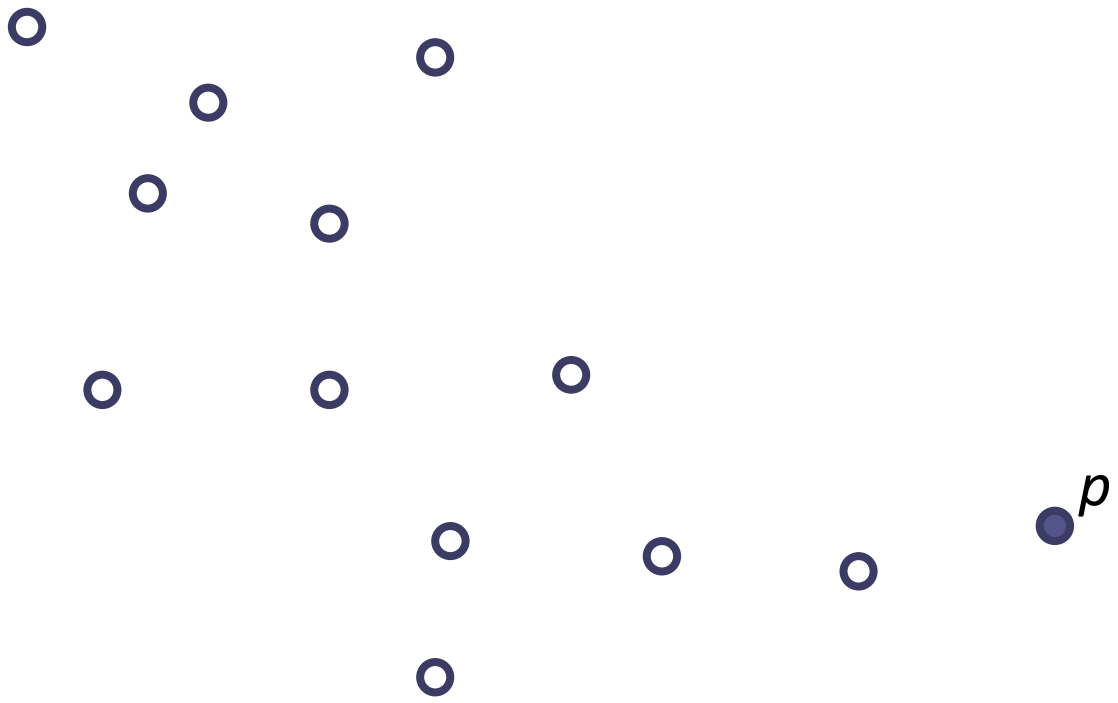
שלב ראשון – כל הווקטורים מסומנים כ-unvisited



# r=2, MinPts=3

הרעיון:

שלב שני – בחר נקודה אקראית p המסומנת כ-unvisited וסמן אותה כ-visited

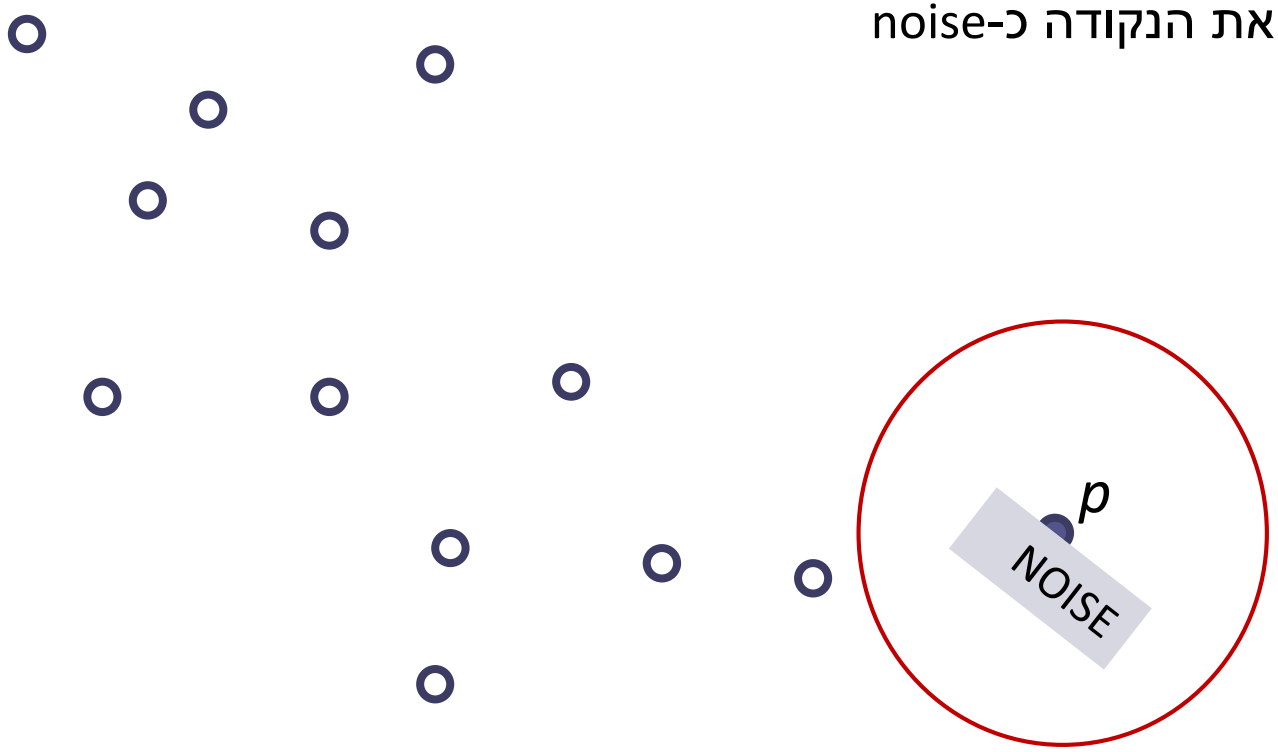


# r=2, MinPts=3

הרעיון:

שלב שני – בדוק האם הנקודה p הינה core object או border point

אם לא – סמן את הנקודה כ-noise

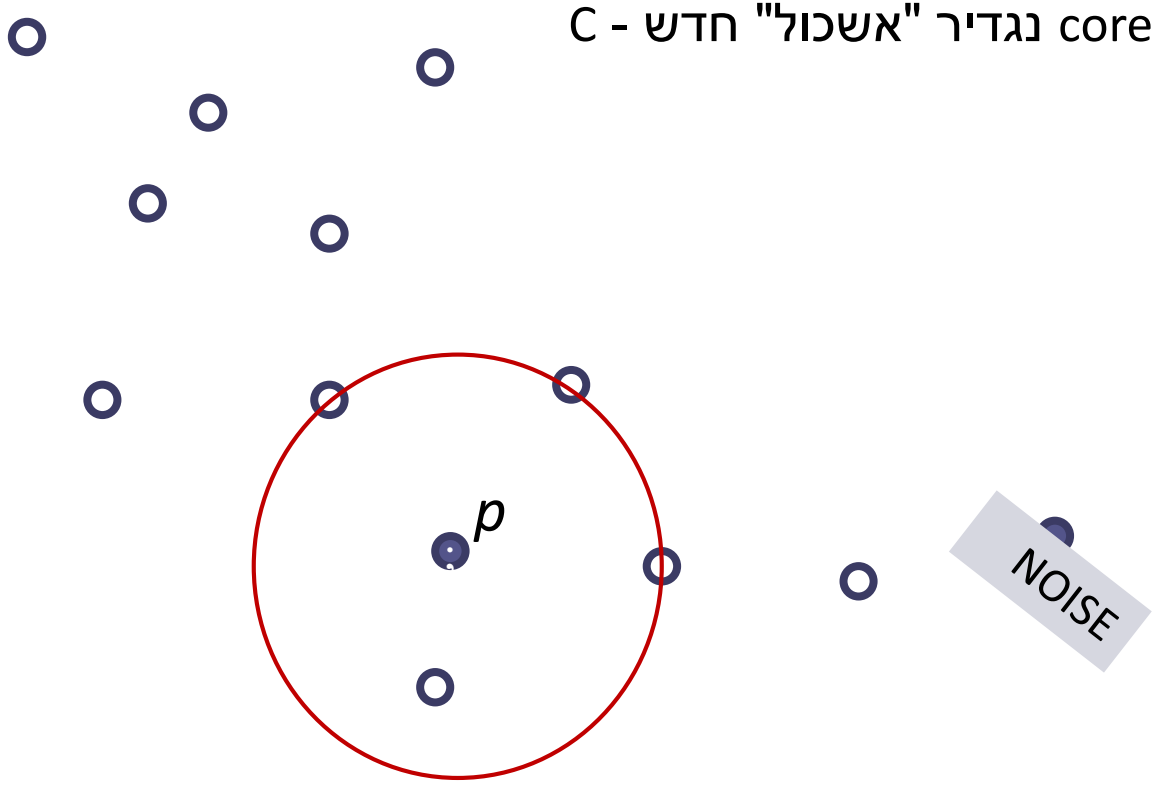


# r=2, MinPts=3

הרעיון:

שלב שני – נבחר נקודה חדשה

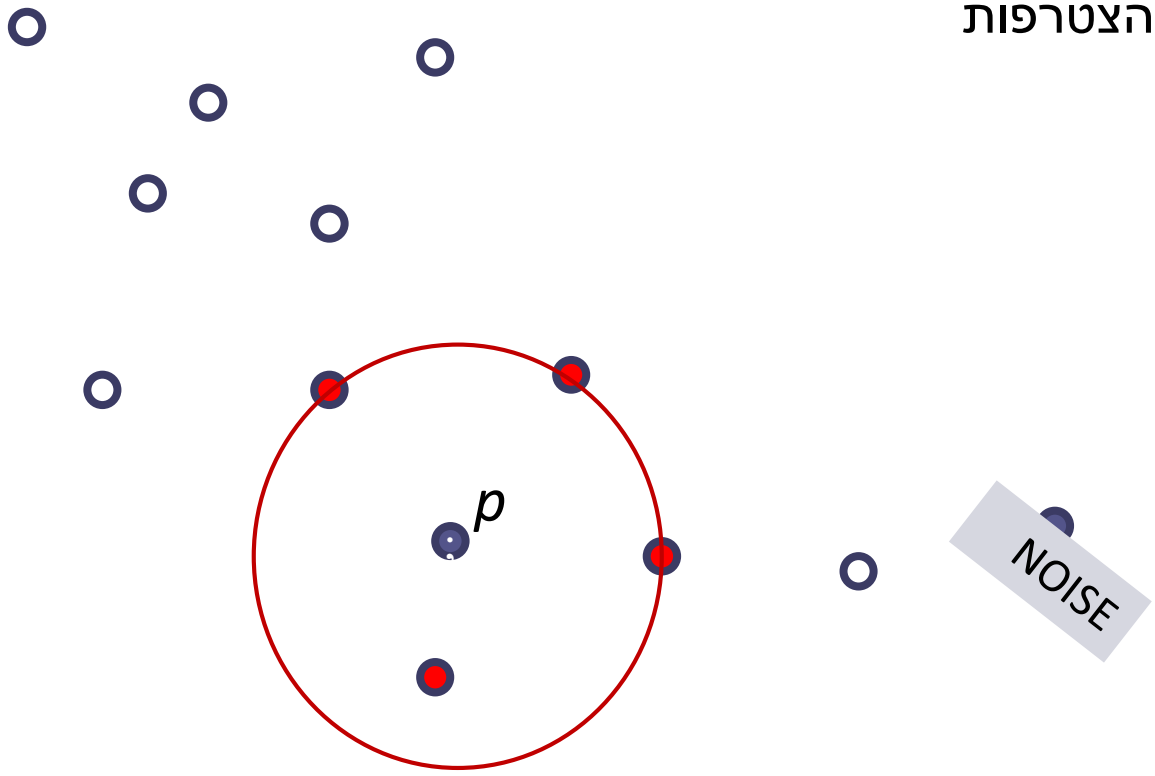
אם היא אכן core object נגדיר "אשכול" חדש - C



# r=2, MinPts=3

הרעיון:

שלב שני – כל הנקודות שנמצאות ברדיוס r מנקודה p נוספות לקבוצה N – קבוצת המועמדים להצטרפות



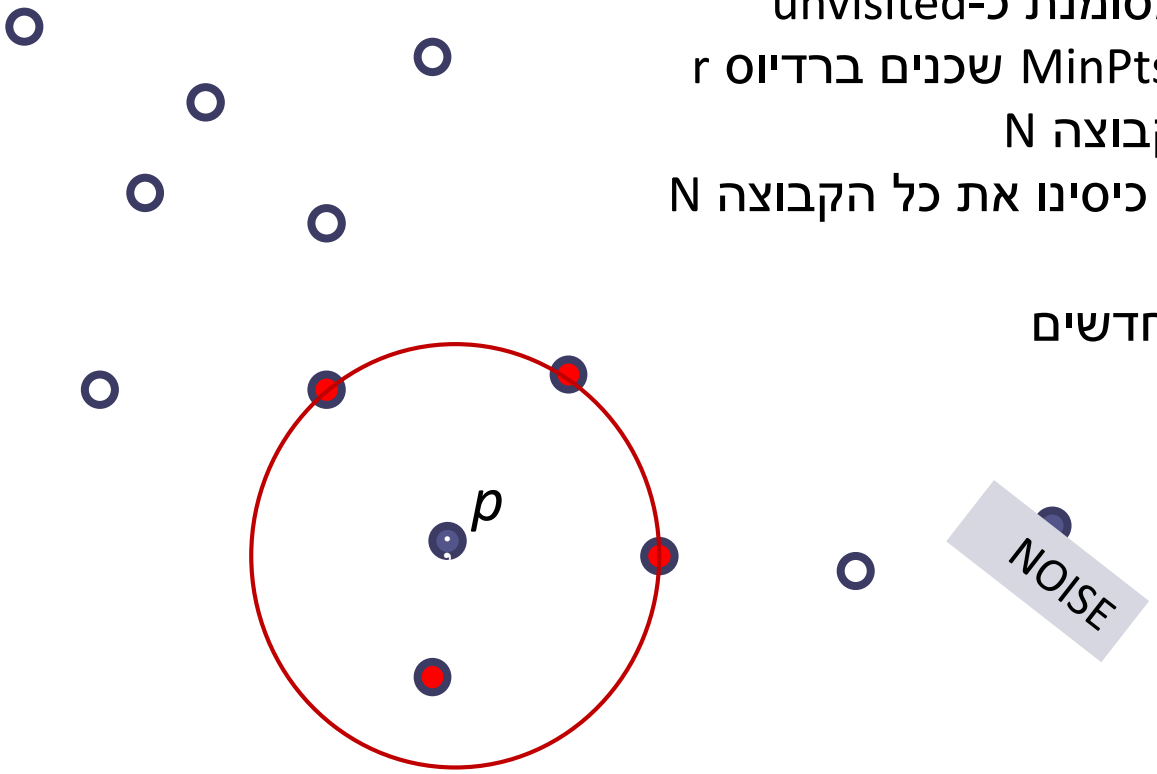
# r=2, MinPts=3

הרעיון:

באופן איטרטיבי נעבור על כל הנקודות שבקבוצה N

- נוסיף לאשכול C את כל הנקודות מ-N שאינן משויכות כבר לאשכול
- לכל נקודה p' שב-N המסומנת כ-unvisited
  - נבדוק האם יש לה MinPts שכנים ברדיוס r
  - נוסיף שכנים אלו לקבוצה N
  - נמשיך בתהליך עד אשר כיסינו את כל הקבוצה N

- באותה דרך נפתח אשכולות חדשים



# COLOR IMAGE SEGMENTATION USING DENSITY-BASED CLUSTERING (*Ye*, *Gao*, *Zeng*)

איך נייצג את התמונה???

מהם הווקטורים ???







