המסלול האקדמי המכללה למינהל

בית הספר למדעי המחשב

<u>פתרון חלק פתוח מבחן בקורס</u>: למידה חישובית וכריית נתונים

<u>קוד נושא</u>: 600089

<u>תאריך הבחינה</u>: 19 ביולי 2019 שעה 9:00

<u>שנה"ל</u>: תשע"ט <u>סמסטר</u>: ב' <u>מועד</u>: א'

שם המרצה: ד"ר משה בוטמן

משך הבחינה: 2.5 שעות

<u>מספר חלקים בבחינה</u>: 2

חלק א' – שאלות פתוחות (40 נקודות)

<u>שאלה פתוחה 1 (20 נקודות)</u>

נתונה טבלת האימון הבאה לבעיית סיווג:

Class	f2	f1
P	-4	-2
P	0	-2
P	2	0
N	2	2
N	-2	2
N	-4	0

א. (7 נק') הרץ/י 2 איטרציות של למידת אלגוריתם פרספטרון. מוד אינקרמנטלי. הרץ/י עפ"י סדר הדוגמאות. יש להוסיף נוירון "דמי" (f0) שערכו 1. יש להתחיל מסט משקולות שכולו 1.
(w0=1, w1=1, w2 = 1)

פתרון:

f0	f1	f2	Class	w0	w1	w2	wx	Sgn(wx)	Update?
1	-2	-4	P	1	1	1	-5	N	Y
1	-2	0	P	2	-1	-3	4	P	N
1	0	2	P	2	-1	-3	-4	N	Y
1	2	2	N	3	-1	-1	-1	N	N
1	2	-2	N	3	-1	-1	3	P	Y
1	0	-4	N	2	-3	1	-2	N	N

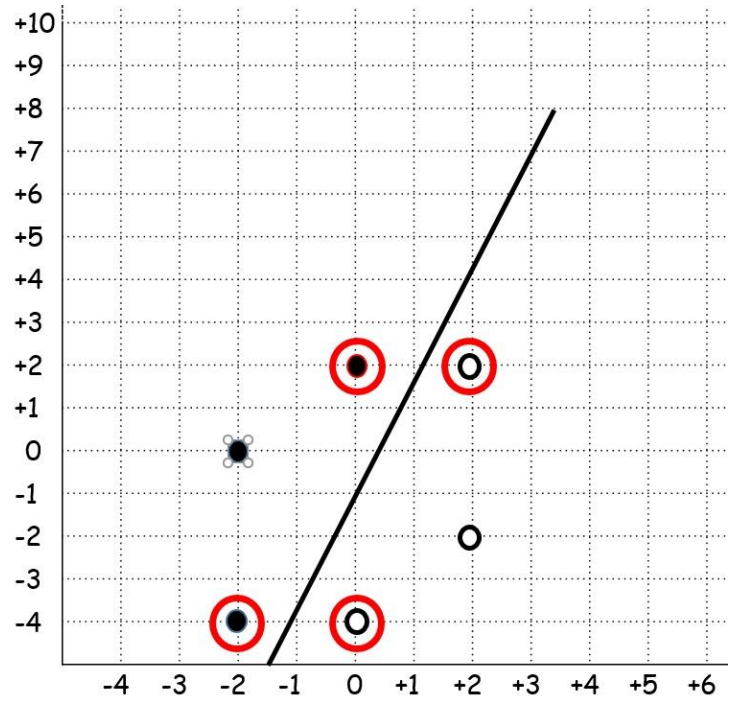
1	-2	-4	P	2	-3	1	4	P	N
1	-2	0	P	2	-3	1	8	P	N
1	0	2	P	2	-3	1	4	P	N
1	2	2	N	2	-3	1	-2	N	N
1	2	-2	N	2	-3	1	-6	N	N
1	0	-4	N	2	-3	1	-2	N	N

סט המשקולות לאחר שתי איטרציות:

(w0 = 2, w1 = -3, w2 = 1)

ב. (5 נק') צייר בצורה סכמטית את הווקטורים על גבי מערכת צירים וסמן מיהם ה-Support Vectors. נמק תשובתך.

פתרון:



הsupport vectors מוקפים בעיגול והם:

ה-SV השליליים - (-2,-4), (0,2),

ה-SV השליליים – (0,-4) (2,2)

ג. (8 נק') בהתבסס על סעיף ב' מצא את משוואת הסיווג של SVM-HARD-MARGIN.

רמז: זכור/זכרי מה אמור להיות ערך המשוואה על ה-SV

פתרון:

בהתאם ל- support vectors נקבל את מערכת המשוואות הבאה:

נזכור שעבור ווקטורים שהינם Support Vectors כאשר נציב אותם במשוואת הסיווג, נקבל עבור SV חיובי את הערך 1 ועבור SV שלילי את הערך 1-

$-2 \cdot w_1 - 4 \cdot w_2 + b = 1$

$0 \cdot w_1 + 2 \cdot w_2 + b = 1$

$2 \cdot w_1 + 2 \cdot w_2 + b = -1$

$0 \cdot w_1 - 4 \cdot w_2 + b = -1$

נפתור את מערכת המשוואות ונקבל:

$w_1 = -1$, $w_2 = 1/3$, $b = 1/3$

<u>שאלה פתוחה 2 (20 נקודות)</u>

נתונים הווקטורים הבאים:

V1 = (2,10), V2 = (2,5), V3 = (8,4), V4 = (5,8), V5 = (7,5), V6 = (6,4), V7 = (1,2), V8 = (4,9)

מטריצה המפרטת את המרחק בריבוע (האוקלידי) בין כל שני ווקטורים נתונה להלן:

	V1	V2	V3	V4	V5	V6	V7	V8
V1	0	25	36	13	50	52	65	5
V2		0	37	18	25	17	10	20
V3			0	25	2	2	53	41
V4				0	13	17	52	2
V5					0	2	45	25
V6						0	29	29
V7							0	58
V8								0

מריצים את אלגוריתם KMEANS עבור K=3

המרכזים הראשונים שנבחרו הינם V1,V4,V7

א. (10 נקודות) הריצו איטרציית KMEANS אחת מלאה. יש להראות את כל החישובים ובסופה יש להציג:

מי האשכולות המתקבלים בתום איטרציה זו, מיהם המרכזים, ציירו דיאגרמה של 10X10 ובצורה סכמטית ציירו את הווקטורים, האשכולות המתקבלים והמרכזים.

פתרון:

נשייך כל ווקטור למרכז הקרוב אליו ביותר. נשתמש בטבלת המרחקים בריבוע. (נכנה לצורך העניין את המרחק בריבוע כ-D). ברור שאם המרחק בריבוע יותר גדול אז גם המרחק עצמו יותר גדול.

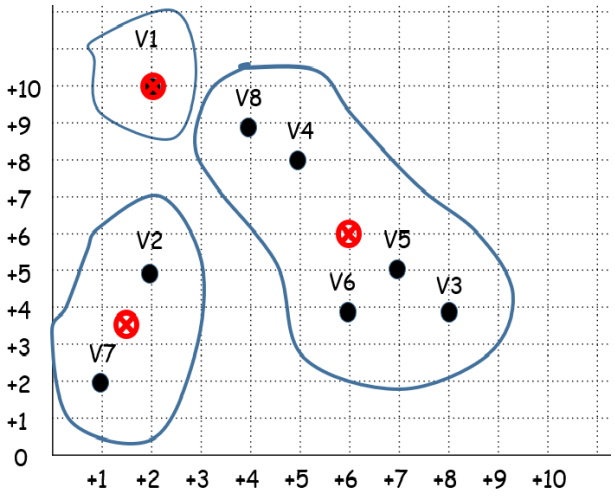
הווקטור	V1	V2	V3	V4	V5	V6	V7	V8
נימוק	נקודת השיוך, המרחק המינימלי, 0	D(V2,V1)=25 D(V2,V4)=18 D(V2,V7)=10 נבחר את המרחק הקצר ביותר	D(V3,V1)=36 D(V3,V4)=25 D(V3,V7)=53 נבחר את המרחק הקצר ביותר	נקודת השיוך, המרחק המינימלי, 0	D(V5,V1)=50 D(V5,V4)=13 D(V5,V7)=45 נבחר את המרחק הקצר ביותר	D(V6,V1)=52 D(V6,V4)=17 D(V6,V7)=29 נבחר את המרחק הקצר ביותר	נקודת השיוך, המרחק המינימלי, 0	D(V8,V1)=5 D(V8,V4)=2 D(V8,V7)=58 נבחר את המרחק הקצר ביותר
השיוך	V1	V7	V4	V4	V4	V4	V7	V4

האשכולות והמרכזים המתקבלים:

Cluster 1: {V1}. Center = (2,10)

Cluster 2: {V2, V7} Center = $(\frac{2+1}{2}, \frac{5+2}{2}) = (1.5, 3.5)$

Cluster 3: {V3,V4,V5,V6,V8} = $(\frac{8+5+7+6+4}{5}, \frac{4+8+5+4+9}{5}) = (6, 6)$



ב. (10 נקודות) הריצו איטרציות נוספות עד לעצירת האלגוריתם. יש לשרטט כל איטרציה בצורה סכמטית.

סיבוב ב:

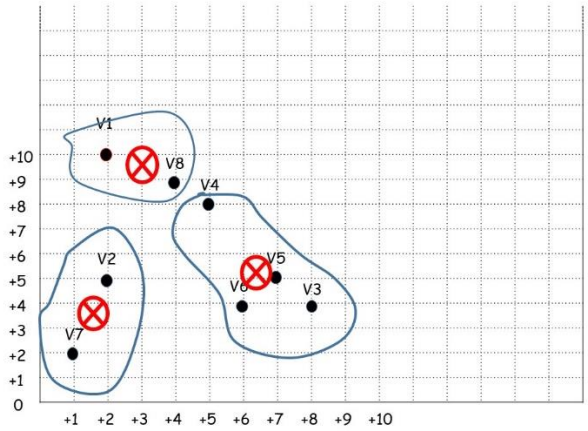
ניתן לראות בבירור מהשרטוט כי הווקטור היחיד שישוייך למרכז שונה הוא V8

לכן האשכולות והמרכזים החדשים הינם:

Cluster 1: {V1,V8}. Center = $(\frac{2+4}{2}, \frac{9+10}{2}) = (3, 9.5)$

Cluster 2: {V2, V7} Center = $(\frac{2+1}{2}, \frac{5+2}{2}) = (1.5, 3.5)$

Cluster 3: {V3,V4,V5,V6 } = $(\frac{8+5+7+6}{4}, \frac{4+8+5+4}{4}) = (6.5, 5.25)$



סיבוב ג:

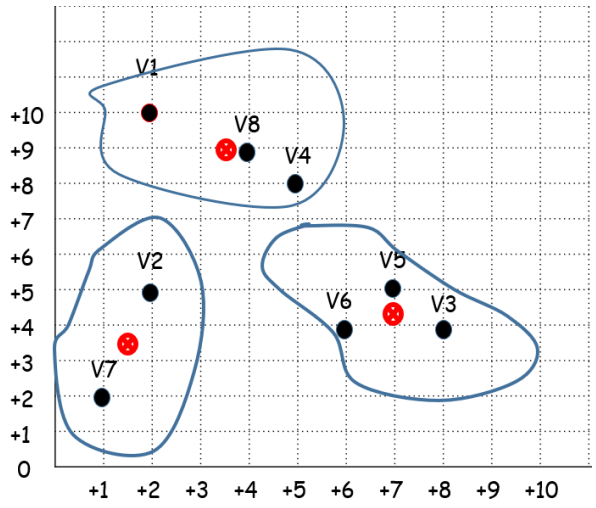
ניתן לראות בבירור מהשרטוט כי הווקטור היחיד שישוייך למרכז שונה הוא V4

לכן האשכולות והמרכזים החדשים הינם:

Cluster 1: {V1,V8,V4}. Center = $(\frac{2+4+5}{3}, \frac{9+10+8}{3}) = (3.66, 9)$

Cluster 2: {V2, V7} Center = $(\frac{2+1}{2}, \frac{5+2}{2}) = (1.5, 3.5)$

Cluster 3: {V3, V5,V6 } = $(\frac{8+7+6}{3}, \frac{4+5+4}{3}) = (7, 4.33)$



בשאלון שלהלן התשובות הנכונות הינן התשובה הראשונה בכל שאלה

חלק ב' – שאלות ברירה (60 נקודות)

לפניך 12 שאלות ברירה. בכל שאלה עליך לסמן את התשובה הנכונה מבין 5 האפשרויות הרשומות.

[Info]

נתון ה-confusion matrix הבא:

		Predicted		
		Class A	Class B	Class C
Actual	Class A	20	2	8
	Class B	10	20	10
	Class C	5	5	20

מהו ה-ACCURACY?

(20+20+20)/100 = 60/100 = 0.6

[q1]
0.6
[a]
0.4
[a]
0.2
[a]
1
[a]
0.75
[a]

נתונה טבלת האימון הבאה:

מס' דוגמא	x1	x2	x3	class
1	2	1	4	P
2	2	1	2	P
3	2	1	4	P
4	2	1	2	N
5	0	2	4	N
6	4	4	3	N

מס' דוגמא	x1	x2	x3	class	Dist from (4,4,4)	
1	2	1	4	P	5=2+3+0	
2	2	1	2	P	7 = 2+3+2	
3	2	1	4	P	5 = 2+3+0	
4	2	1	2	N	7 = 2+3+2	
5	0	2	4	N	6 = 4+2+0	
6	4	4	3	N	1 = 0+0+1	

אלו מהבאים יסווג **<u>בוודאות</u>** כ-N עפ"י אלגוריתם KNN

[q2]

(f1=4, f2=4, f3=4), L1, K=3, עם שקלול מרחקים של 1/d
(שלושת השכנים הקרובים ביותר הם 6#, 1#, 3#.
משקלי ה"חיוביים" הינם

1/5+1/5 = 2/5

משקלי ה"שליליים" הינם

1/1= 1

לכן יסווג כשלילי.
[a]
(f1=3, f2=3, f3=3), L1, K=6, ללא שקלול מרחקים
[a]
אין מספיק נתונים בשאלה
[a]
(f1=2, f2=2, f3=2), L1, K=6, ללא שקלול מרחקים
[a]
(f1=2, f2=1, f3=4), L1, K=1, שקלול מרחקים של 1/d
[a]

באלו מהאלגוריתמים הבאים שינוי סדר הזנת הדוגמאות בקבוצת האימון עשוי להשפיע על תוצאת האלגוריתם?

[q3]

NEURAL NETWORKS ,PERCEPTRON

[a]
SVM-SOFT-MARGIN ,DECISION TREE
[a]
NEURAL NETWORKS ,MARGIN-SOFT-SVM

[a]
NAÏVE BAYES

[a]
DBSCAN
[a]

נתונה טבלת האימון הבאה:

מס' דוגמא	x1	x2	x3	class
1	2	1	4	P
2	2	2	2	P
3	2	1	4	P
4	2	1	2	P
5	2	2	4	N
6	1	2	2	N
7	2	2	4	N
8	1	1	1	N

מהו המאפיין עם ה-IG **<u>הנמוך</u>** ביותר ($IG(class|x_i)$). אין צורך במחשבון אלא רק בהבנה של IG

[q4]

x3
ניתן לראות בבירור מהטבלה שחוסר הוודאות הגדול ביותר הינו עבור *x3*. לעומת המאפיינים האחרים.
[a]
x1
[a]
x2
[a]
ל-*x1* ו- *x3* אותם *INFOGAIN* והוא הנמוך
[a]
ל-*x2* ו- *x3* אותם *INFOGAIN* והוא הנמוך
[a]

לפתרון בעיית ה-underflow באלגוריתם NAÏVE BAYES

[q5]

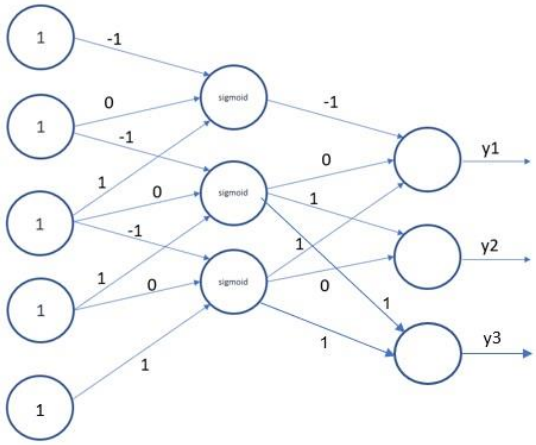
נשתמש בסכום לוגים של ההסתברויות השונות במקום בהכפלת ההסתברויות
[a]
נבצע "החלקה"
[a]
נשתמש גם במכנה *P(X)* בנוסחת בייס
[a]
נבחר את המאפיין *Xi* עם ה- *IG(Y|Xi)* הגבוה ביותר
[a]
נשתמש בפונקציות אקטיבציה לא לינאריות
[a]

אלגוריתם ADABOOST

[q6]

רגיש לווקטורי *outliers* כי מעלה את משקלם של ווקטורי ה- *outliers* עוד ועוד
[a]
רגיש לווקטורי *outliers* כי מוריד את משקלם של ווקטורי ה- *outliers* עוד ועוד
[a]
אינו רגיש לווקטורי *outliers*
[a]
ככל שה-*weak hypothesis* שנבחר יהיה מדוייק יותר, משקלו במסווג הסופי יהיה קטן יותר
[a]
בכל איטרציה מובטח לנו שנמצא היפוטזה טובה מרנדומלית
[a]

רשת נוירונים לסיווג – נתונה הרשת הבאה:



שימו לב – שכבת אקטיבציה sigmoid בשכבה האמצעית

$$Sigmoid(x) = \frac{1}{1+e^{-x}}$$

כיצד יסווג הווקטור שבכניסה (1,1,1,1,1)

In(1) = 1*-1+1*0+1*1= 0
In(2) = 1*-1+1*0+1*1 = 0
In(3) = 1*-1+1*0+1*1 = 0
Out(1) = sigmoid(0) = ½
Out(1) = sigmoid(0) = ½
Out(1) = sigmoid(0) = ½
Y(1) = (-1*1/2+0*1/2+1*1/2) = 0
Y(2) = (1*1/2+0*1/2) = 1/2
Y(3) = (1*1/2+1*1/2) = 1

Y3 gets the highest value

[q7]
y3

[a]
y2
[a]
y1
[a]
y1 ו-y3 בהסתברות שווה
[a]
y2 ו-y3 בהסתברות שווה
[a]

מריצים svm-soft-margin על קבוצת ווקטורים שאינם ניתנים להפרדה לינארית

[q8]
אם "מקדם הענישה" C שואף לאין-סוף הרי אנו כמו ב-*SVM HARD MARGIN*
[a]
אם "מקדם הענישה" C שואף ל-0 הרי אנו כמו ב-*SVM HARD MARGIN*
[a]
נקבל משוואה לא לינארית המפרידה בין הקבוצות
[a]
יש להשתמש בפונקציות אקטיבציה לא לינאריות
[a]
תלוי בקבוצת הווקטורים
[a]

אלגוריתם SVM-HARD-MARGIN

מס' דוגמא	α	x1	x2	x3	class
1	0	2	1	4	P
2	0	2	2	2	P
3	1	2	1	4	P
4	0	2	1	2	P
5	0.5	2	2	4	N
6	1	1	2	2	N
7	0	2	2	4	N
8	0	1	1	1	N

חשב את W

$$W = \sum \alpha_i y_i x_i = \left(1 \times 1 \times (2,1,4)\right) + \left(\frac{1}{2} \times -1 \times (2,2,4)\right) + \left(1 \times -1 \times (1,2,2)\right)$$
$$= (2,1,4) + (-1,-1,-2) + (-1,-2,-2) = (0,-2,0)$$

[q9]

W = (0,-2,0)

[a]

W = (0,0,0)

[a]

W = (1,-2,0)

[a]

W = (1, 2,1)

[a]

W = (2, 2,-1)

[a]

אלגוריתם *NAÏVE BAYES* –
נתונים הווקטורים הבאים:

# וקטור	*f1*	*f2*	*f3*	*class*
1	1	*1*	0	*P*
2	1	*0*	0	*P*
3	0	*0*	0	*N*
4	1	*0*	0	*N*
5	1	*1*	0	*N*
6	0	*1*	0	*P*
7	0	*0*	0	*P*
8	0	*1*	0	*N*

כיצד יסווג הווקטור (f1 = 1, f2 = 1, f3 = 0) לפי אלגוריתם Naïve Bayes?
אותו מספר דוגמאות "חיוביות" ואותו מספר "שליליות" לכן ההסתברות של "מחלקה" לא משפיעה.

$$P(f1=1 \mid P)^* P(f2=1 \mid P)^* P(f1=0 \mid P) = \frac{1}{2} \times \frac{1}{2} \times 1 = \frac{1}{4}$$

$$P(f1=1 \mid N)^* P(f2=1 \mid N)^* P(f1=0 \mid N) = \frac{1}{2} \times \frac{1}{2} \times 1 = \frac{1}{4}$$

[q10]
אותה הסתברות ל-P ול-N
[a]
P
[a]
N
[a]
יש לבצע "החלקה" (smoothing). תלי בפרמטרי ההחלקה.
[a]
אין מספיק נתונים בשאלה
[a]

מה מבין הבאים **<u>אינו נכון</u>** עבור אלגוריתם SVM?

[q11]
SVM-HARD-MARGIN עשוי להביא למס׳ היפוטזות שונות, תלוי בבחירת פרמטרים ראשונית
[a]
SVM-SOFT-MARGIN עשוי להביא למס׳ היפוטזות שונות, תלוי בבחירת פרמטרים ראשונית
[a]
אם יש הפרדה לינארית, אזי מובטח לנו ש-SVM-HARD-MARGIN ימצא היפוטזה
[a]
מיפוי למימד גבוה יותר מאפשר לנו למצוא פתרון גם לבעיה לא לינארית (במימד המקורי של הבעיה)
[a]
SVM-HARD-MARGIN מוצא לנו את המפריד עם ה״שוליים״ (margin) הגדולים ביותר.
[a]

אלגוריתם DBSCAN
עבור פרמטר של MinPts = 1 (כאשר ב-MinPts נספר גם הווקטור עצמו)
[q12]
בסוף תהליך ההרצה, מס׳ האשכולות תלוי ב- R שבחרנו
כי בסופו של דבר אנו מאחדים את כל הווקטורים ברדיוס R
[a]
בסוף תהליך ההרצה, כל ווקטור יהיה אשכול. סה״כ בסוף התהליך – מס׳ האשכולות שווה למס׳ הווקטורים
[a]
בסוף תהליך ההרצה, כל הווקטורים יהיו אשכול אחד
[a]
בסוף תהליך ההרצה, מס׳ האשכולות יהיה שווה ללוג של מס׳ הווקטורים
[a]
בסוף תהליך ההרצה, מס׳ האשכולות יהיה שווה לחצי מס׳ הווקטורים
[a]