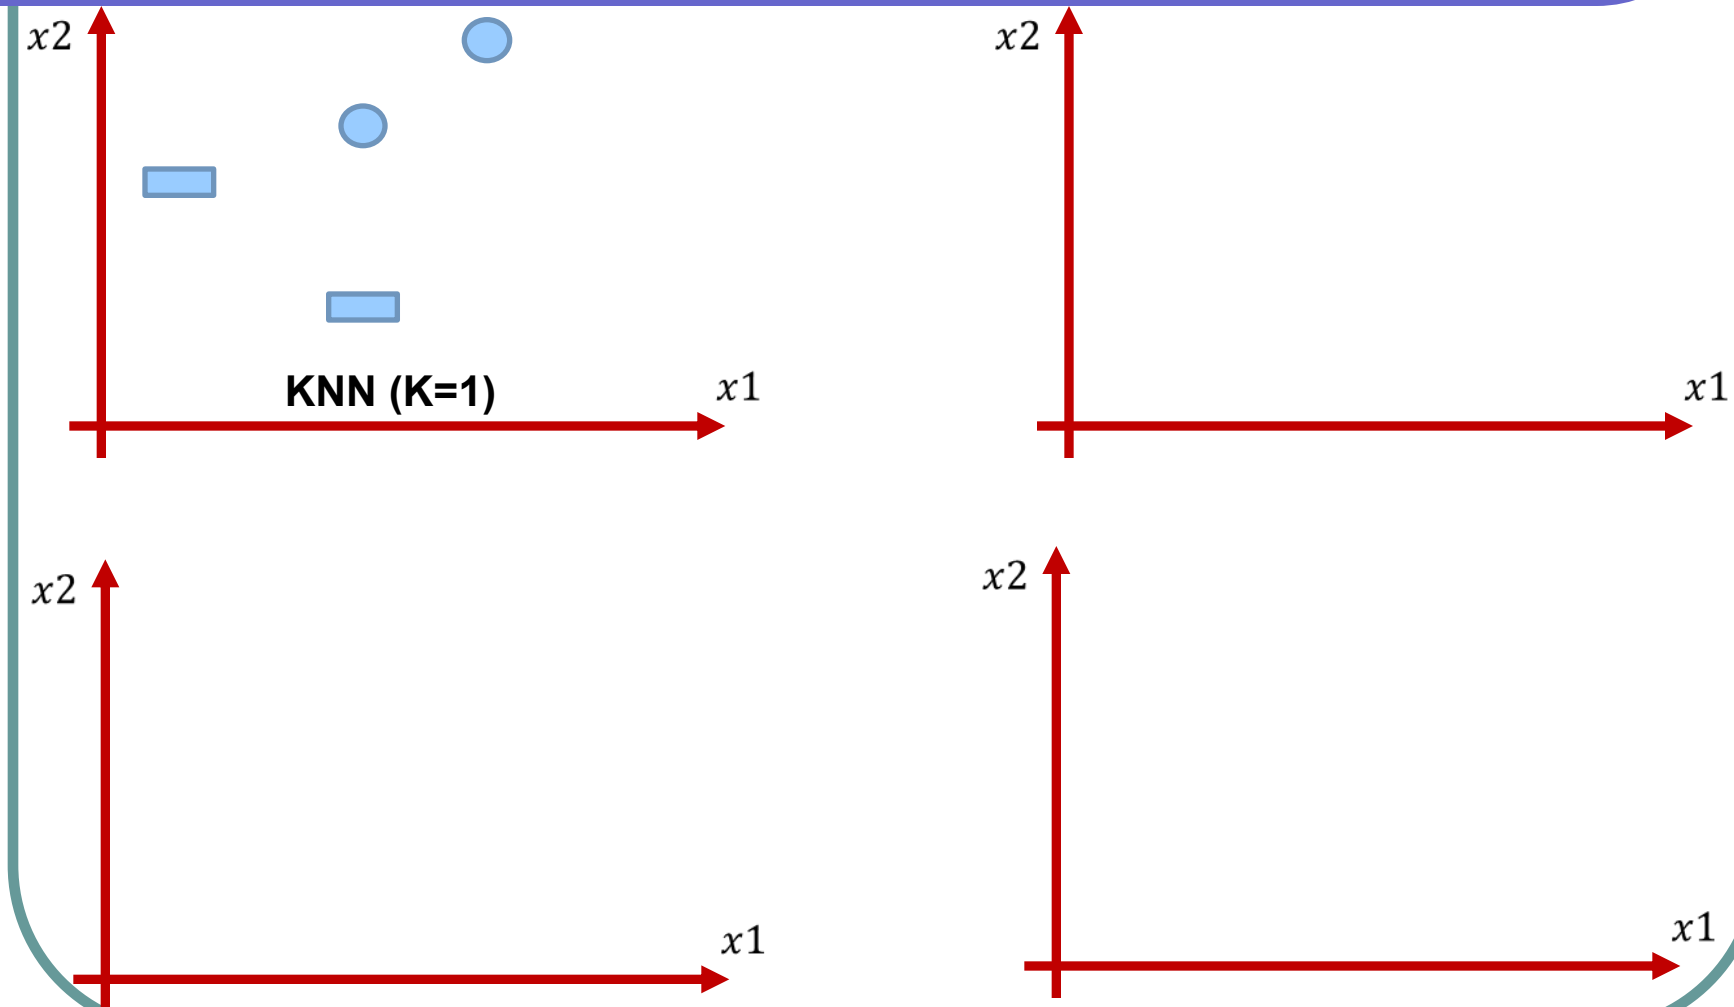
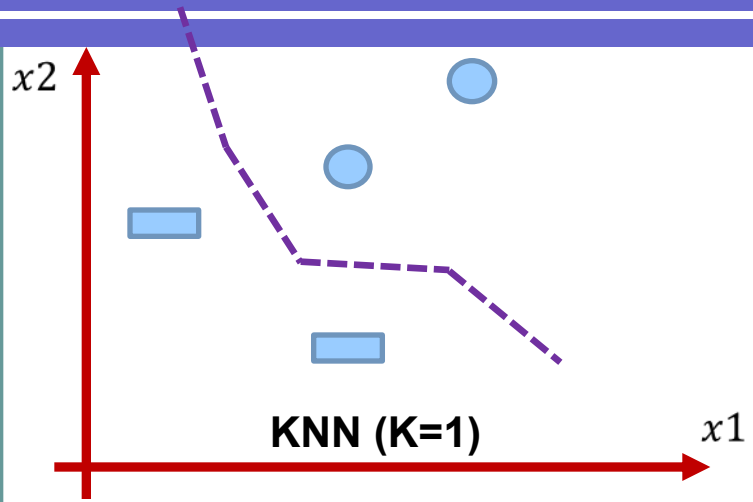
למידת מכונה

Support Vectors Machine (SVM)

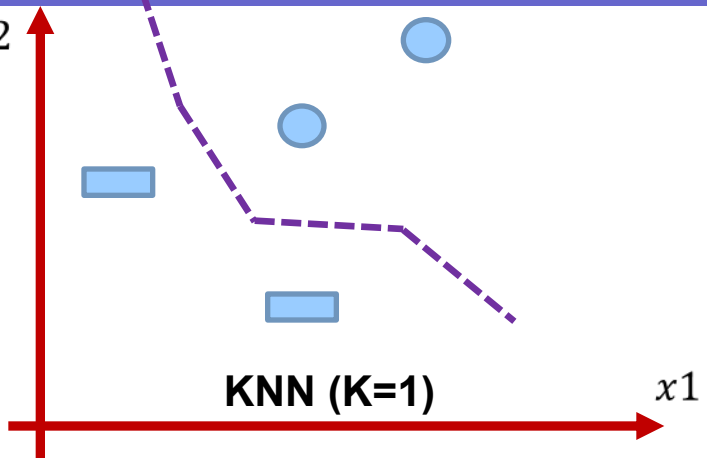

x2
x1
KNN (K=1)
x2
x1
x2
x1
x2
x1

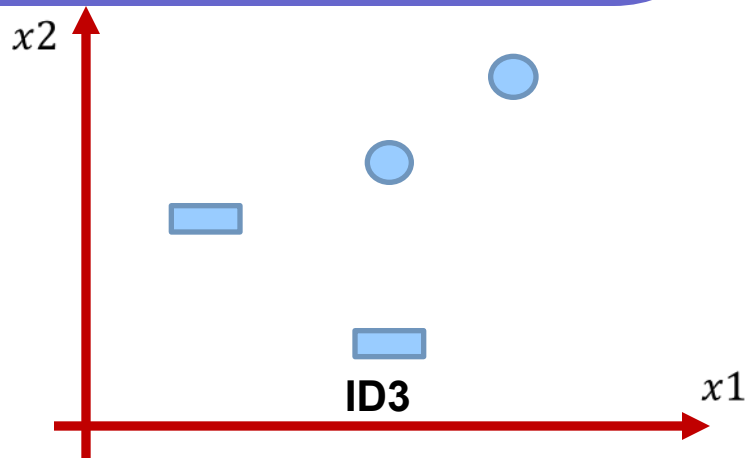

x2
x1
KNN (K=1)


x2
x1


x2
x1

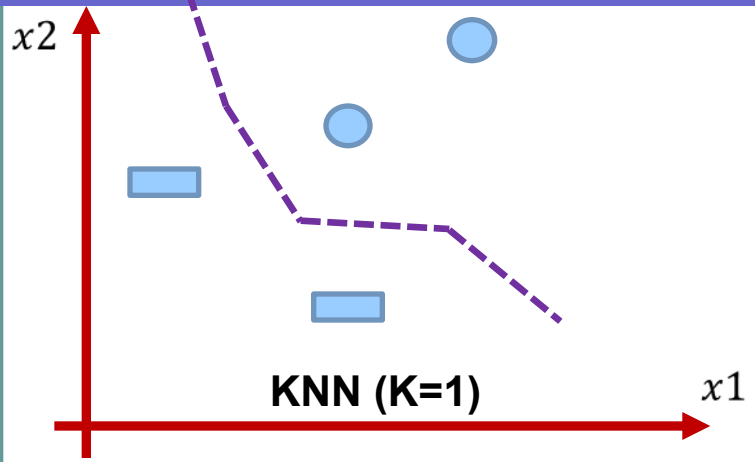

x2
x1


x2
x1
KNN (K=1)

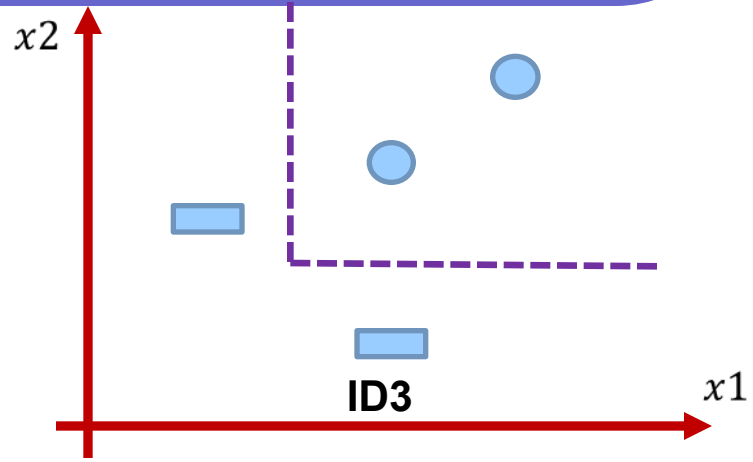

x2
x1
ID3


x2
x1


x2
x1



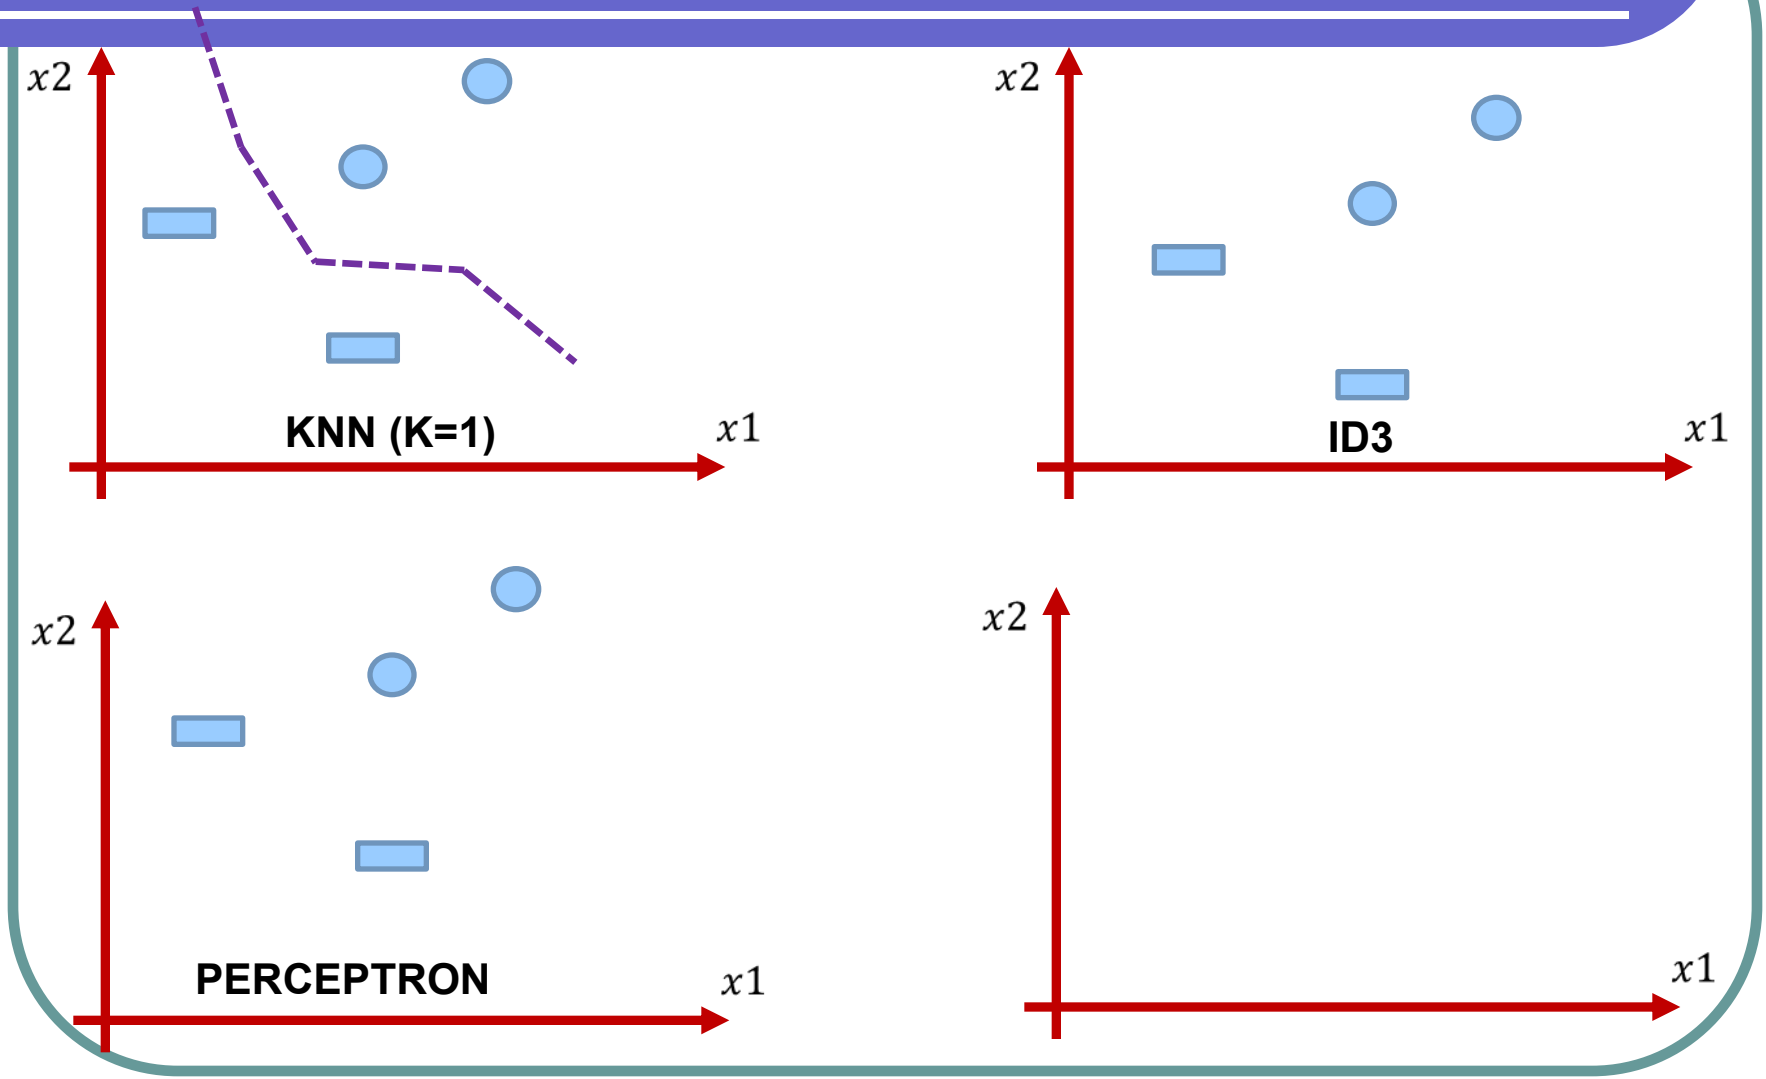
KNN (K=1)

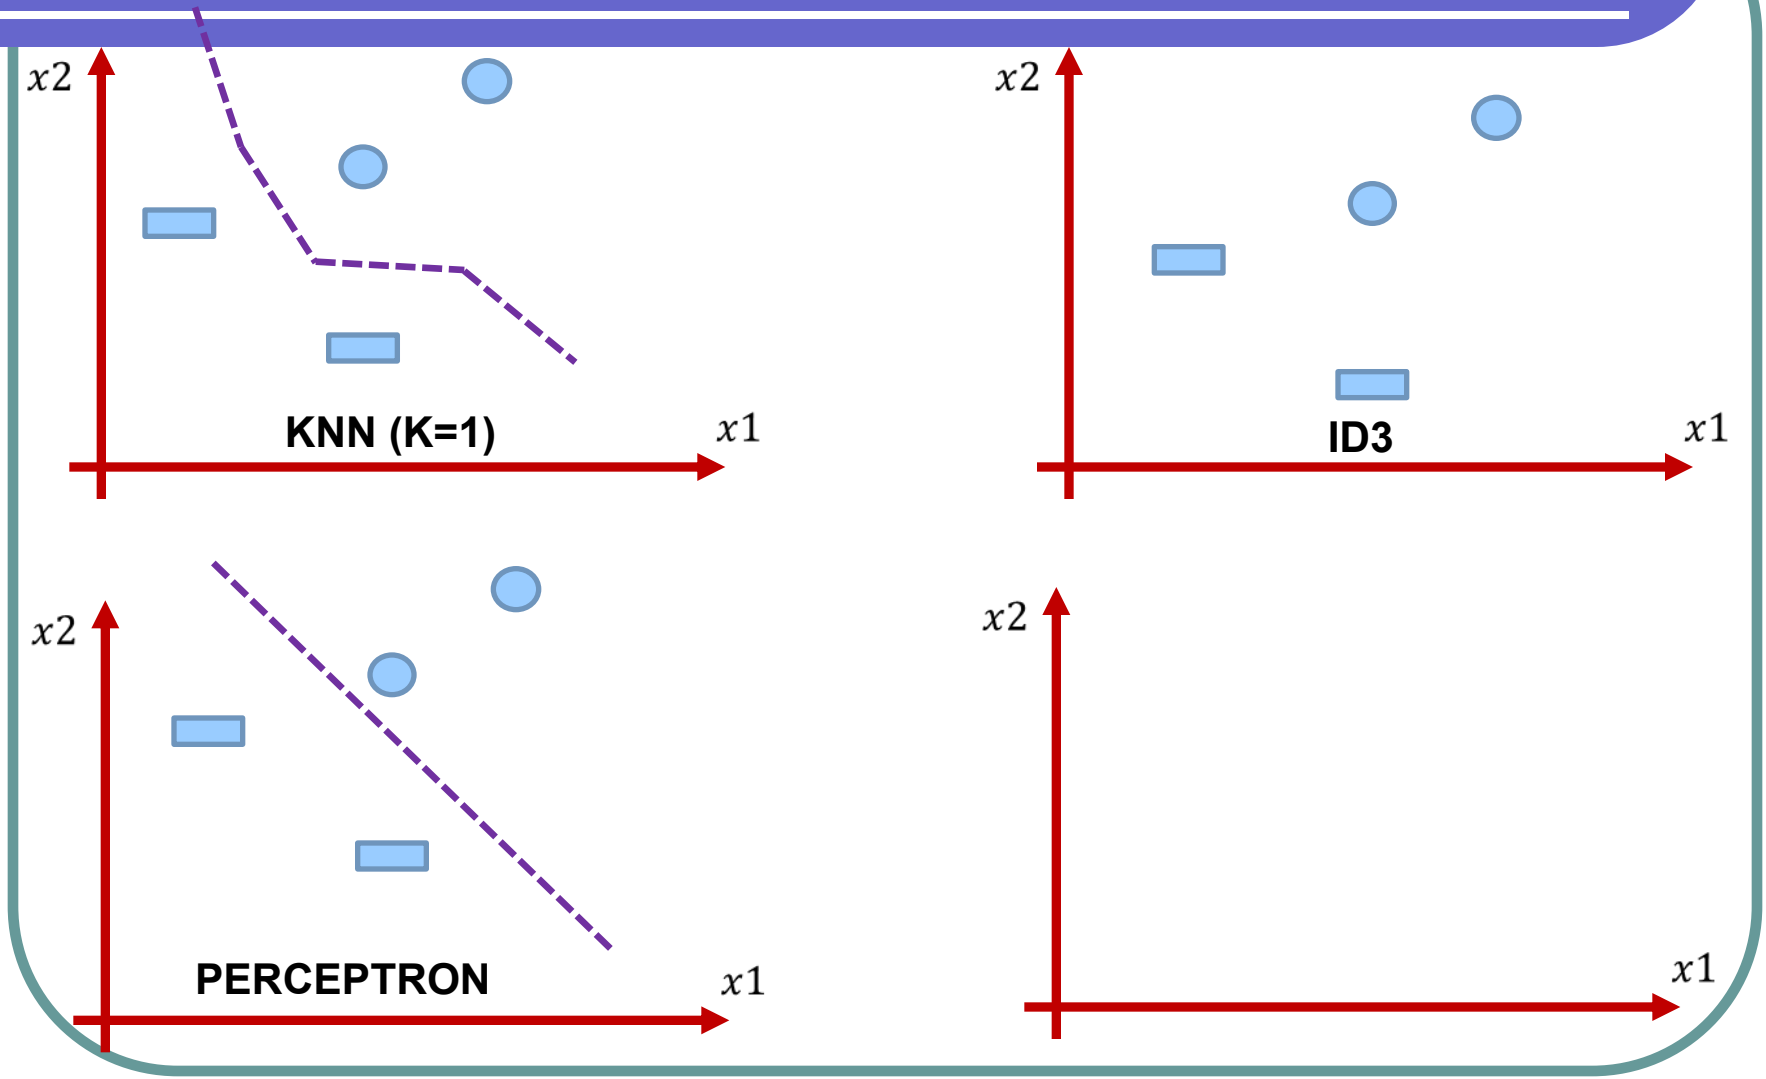


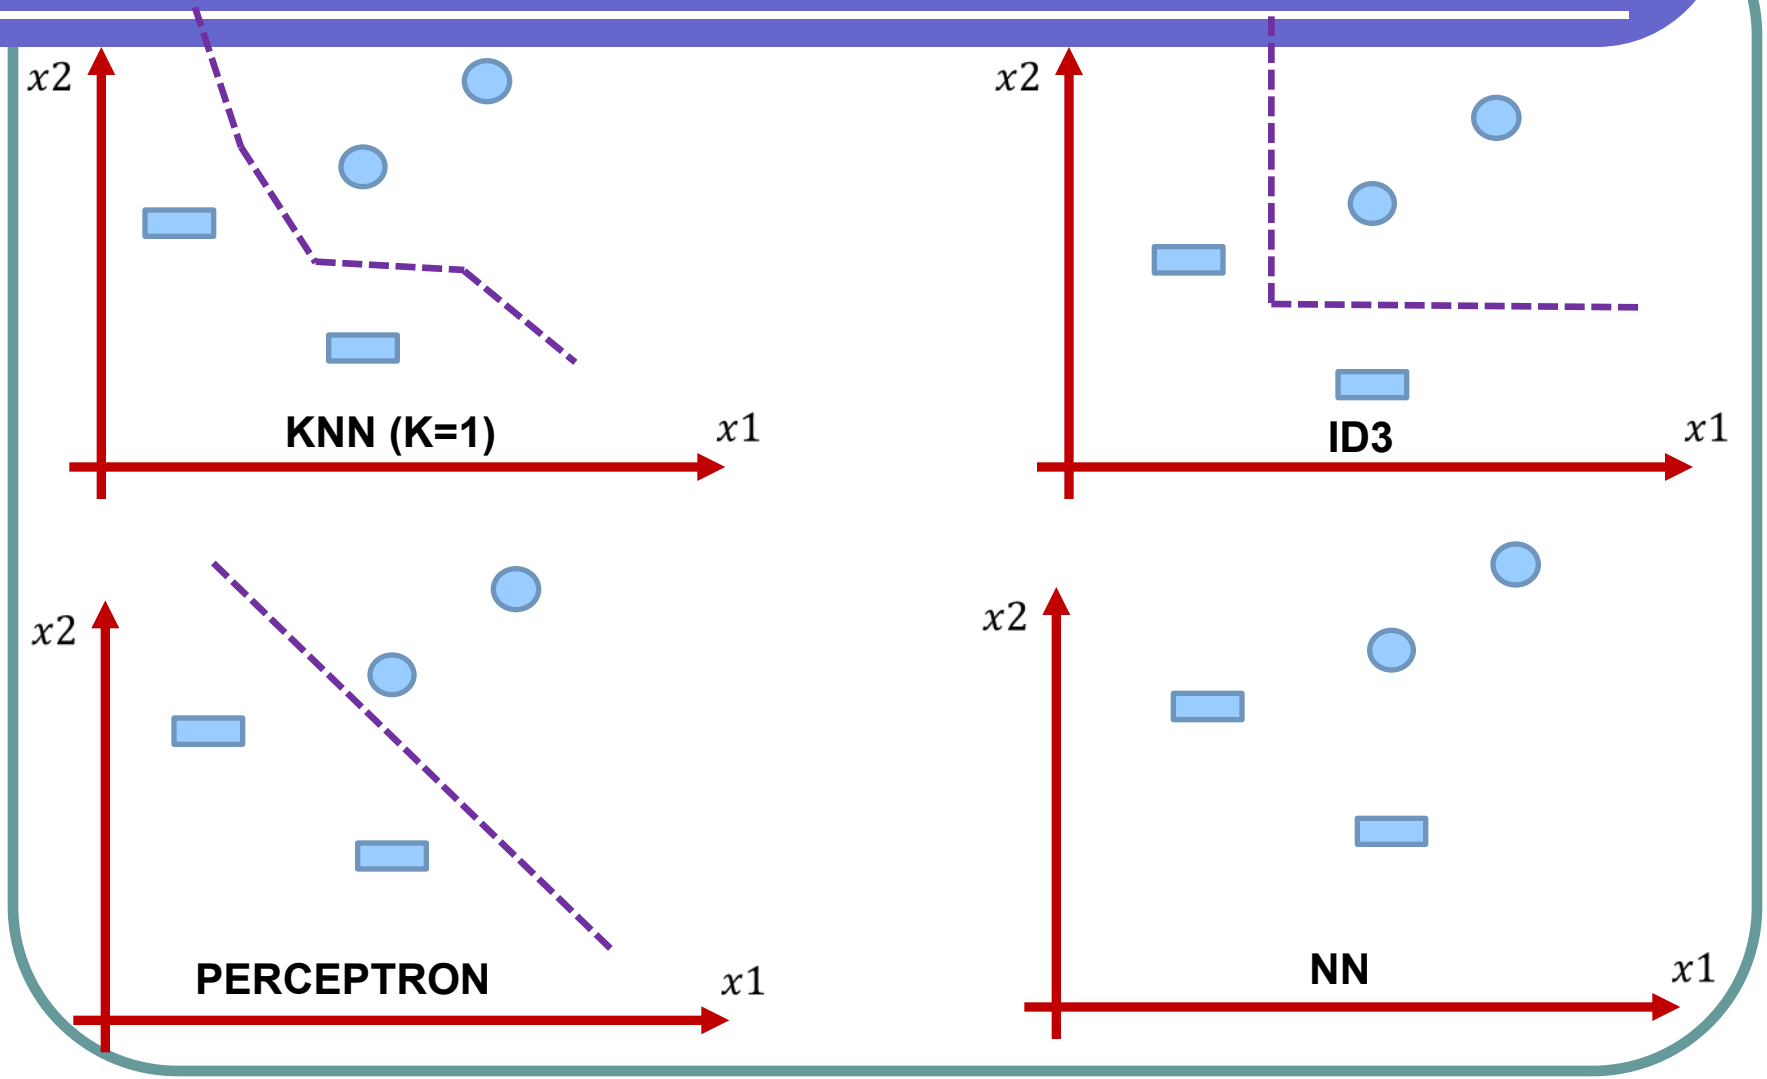
ID3

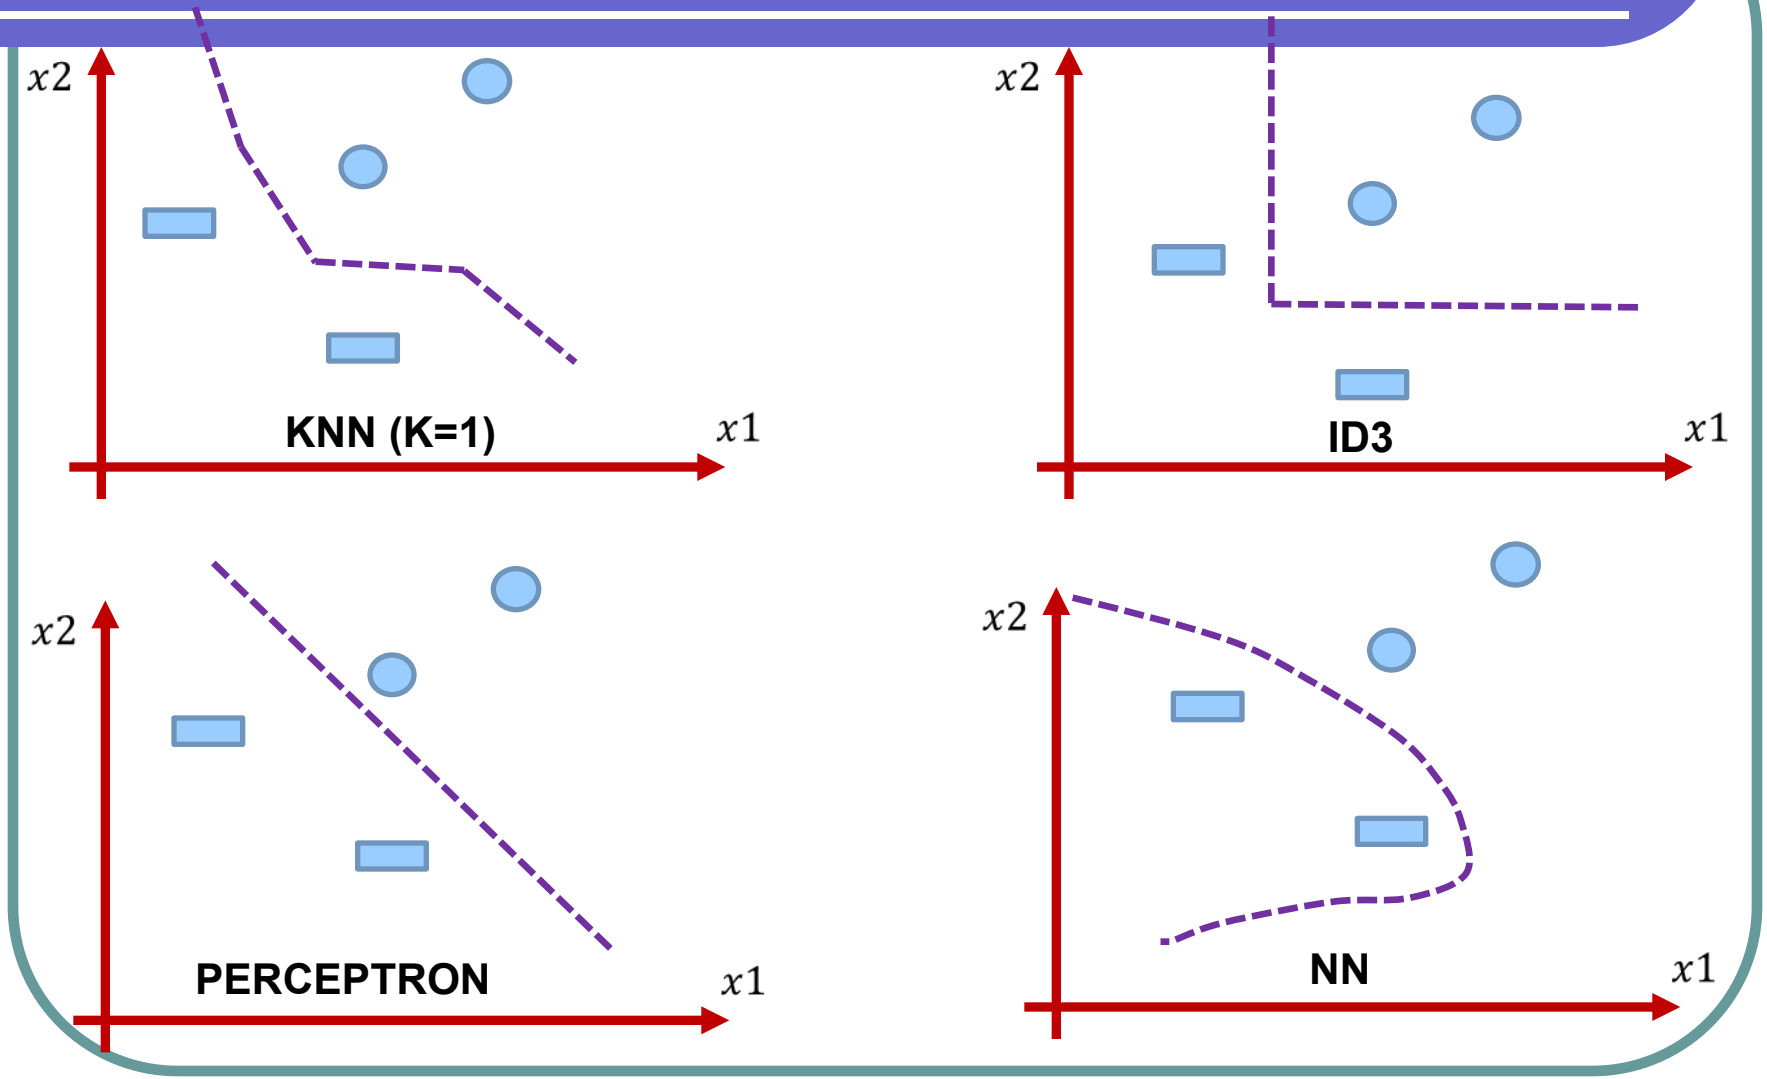




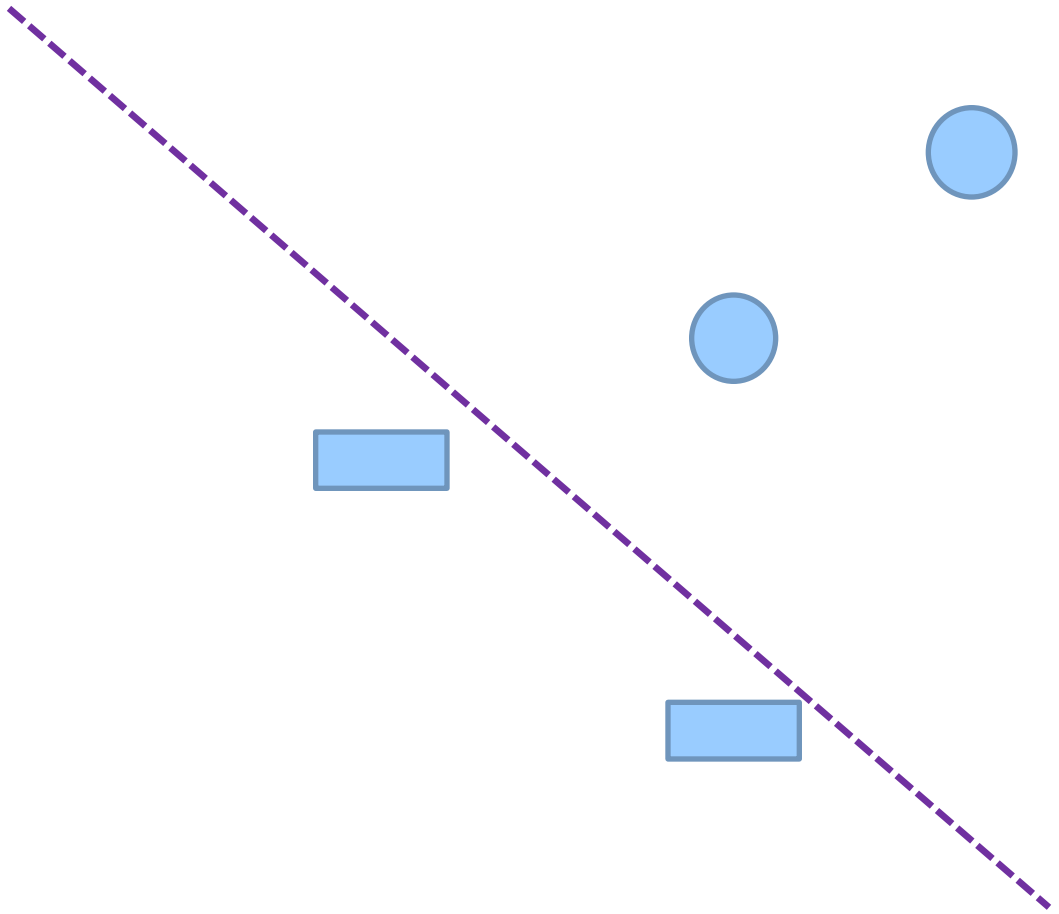

x2
x1
KNN (K=1)
x2
x1
ID3
x2
x1
PERCEPTRON
x2
x1


x2
x1
KNN (K=1)
x2
x1
ID3
x2
x1
PERCEPTRON
x2
x1

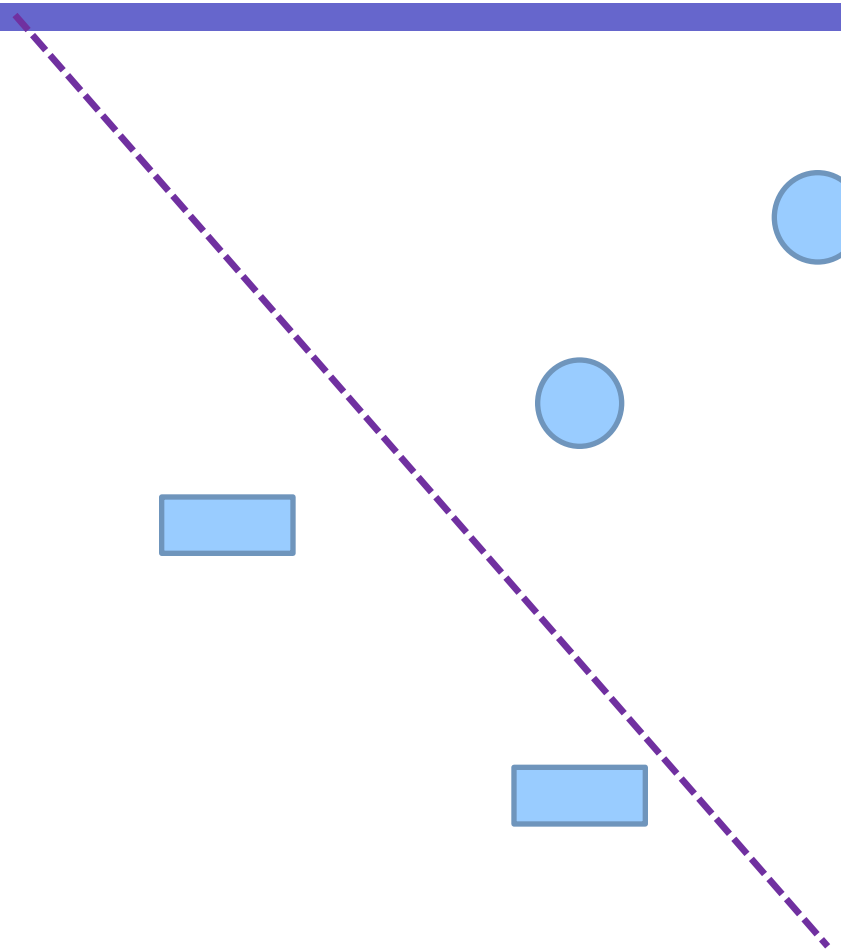

x2
x1
KNN (K=1)
x2
x1
ID3
x2
x1
PERCEPTRON
x2
x1
NN


x2
x1
KNN (K=1)
x2
x1
ID3
x2
x1
PERCEPTRON
x2
x1
NN

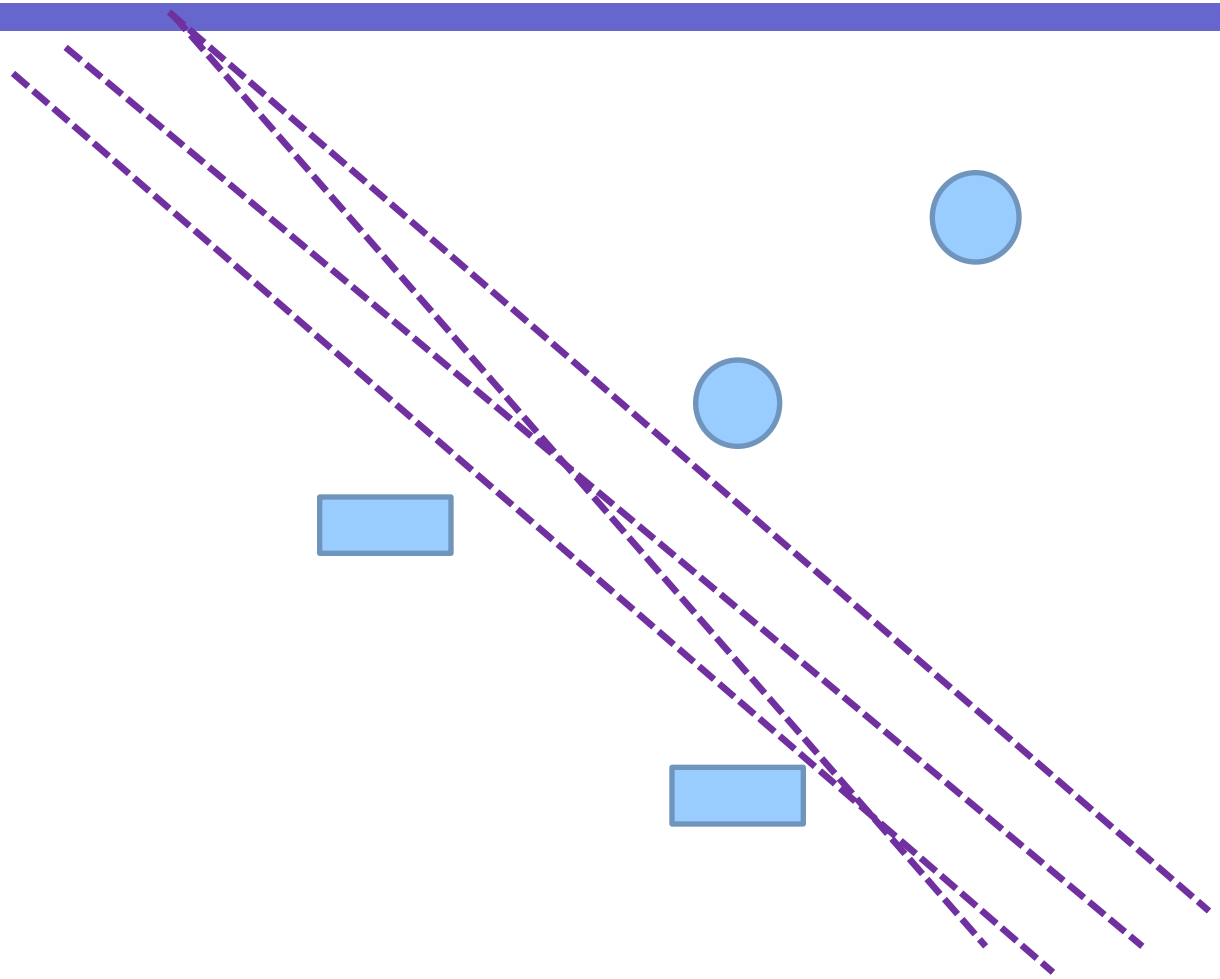
Perceptron – Different possible solutions



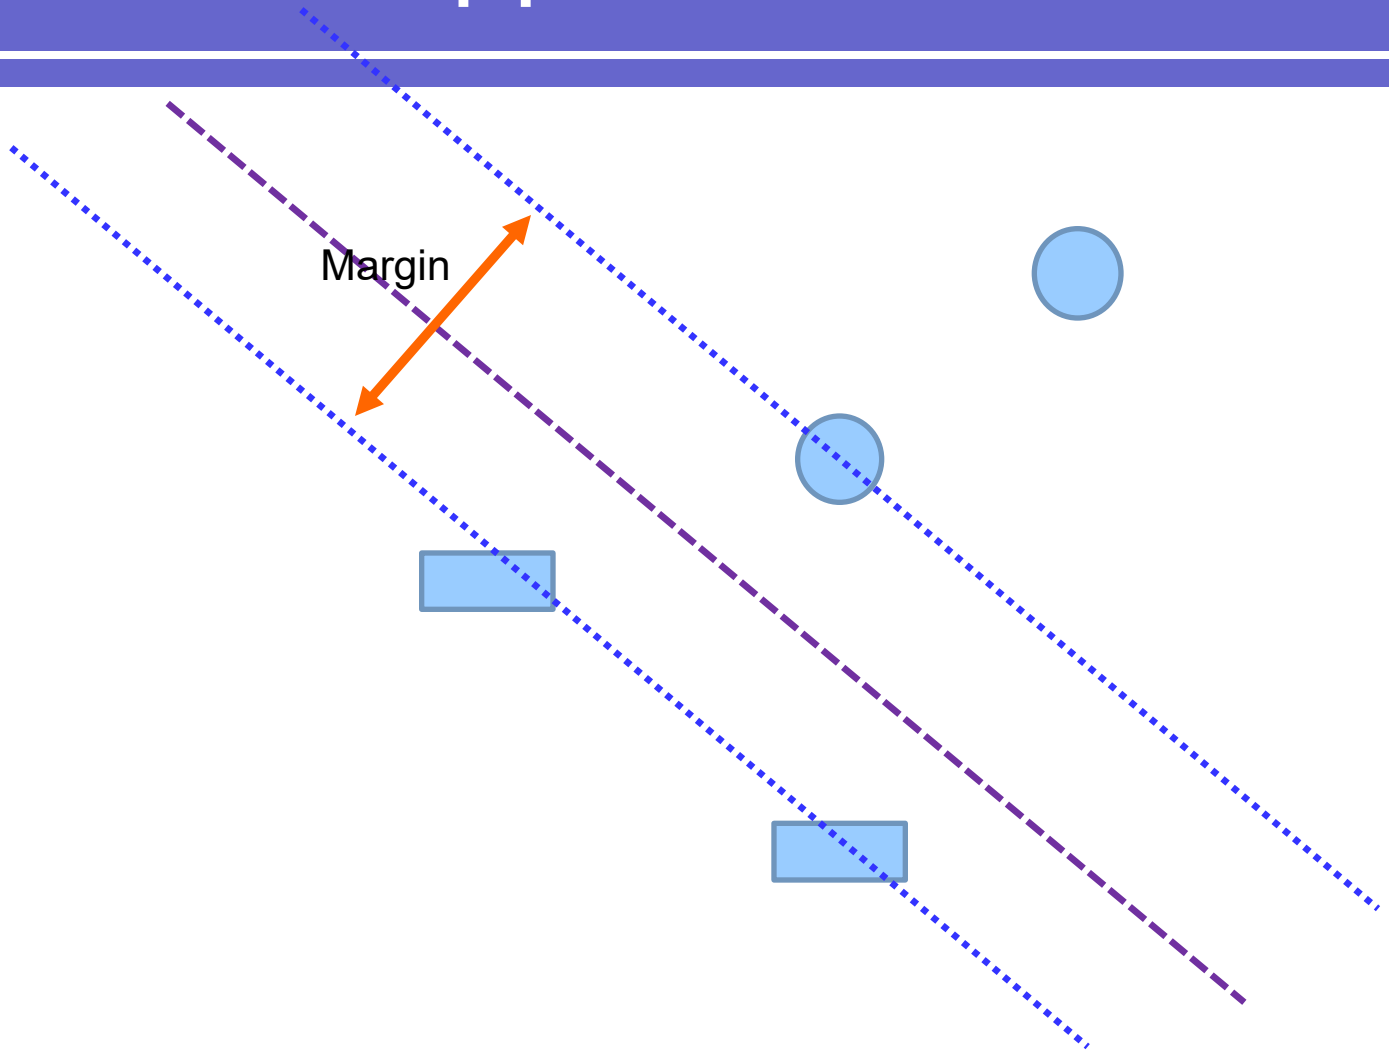
Perceptron – Different possible solutions



Perceptron – Different possible solutions



SVM – Support Vector Machine



SVM – Support Vector Machine

- *Tutorial C.J.C. Burges*.

A Tutorial on Support Vector Machines for Pattern Recognition

- SVM הינה אחת השיטות המוצלחות בשנים האחרונות (הן תיאורטית והן מעשית) ללמידה מונחית

בעיית סיווג

- קלט: n ווקטורים x, כל ווקטור באורך D – $x_i \in \Re^D$
- תווית y_i לכל ווקטור $y_i \in \{1,2,.....n\}$
  נעסוק ב- $y_i \in \{1,-1\}$
- לא ידועה לנו התפלגות הנתונים.

- אנו רוצים למצוא פונקציה $y=f(x)$ כך שבהינתן ווקטור חדש x המערכת תסווג אותו נכון בהסתברות גבוהה

בעיית סיווג

- כלומר, אנו רוצים למצוא היפוטזה במרחב ההיפוטזות H –

$$H \in \Re^D \longrightarrow \{1,-1\}$$

- כך שבהינתן "מחירון ענישה" לטעות

$$loss(y, H(x))$$

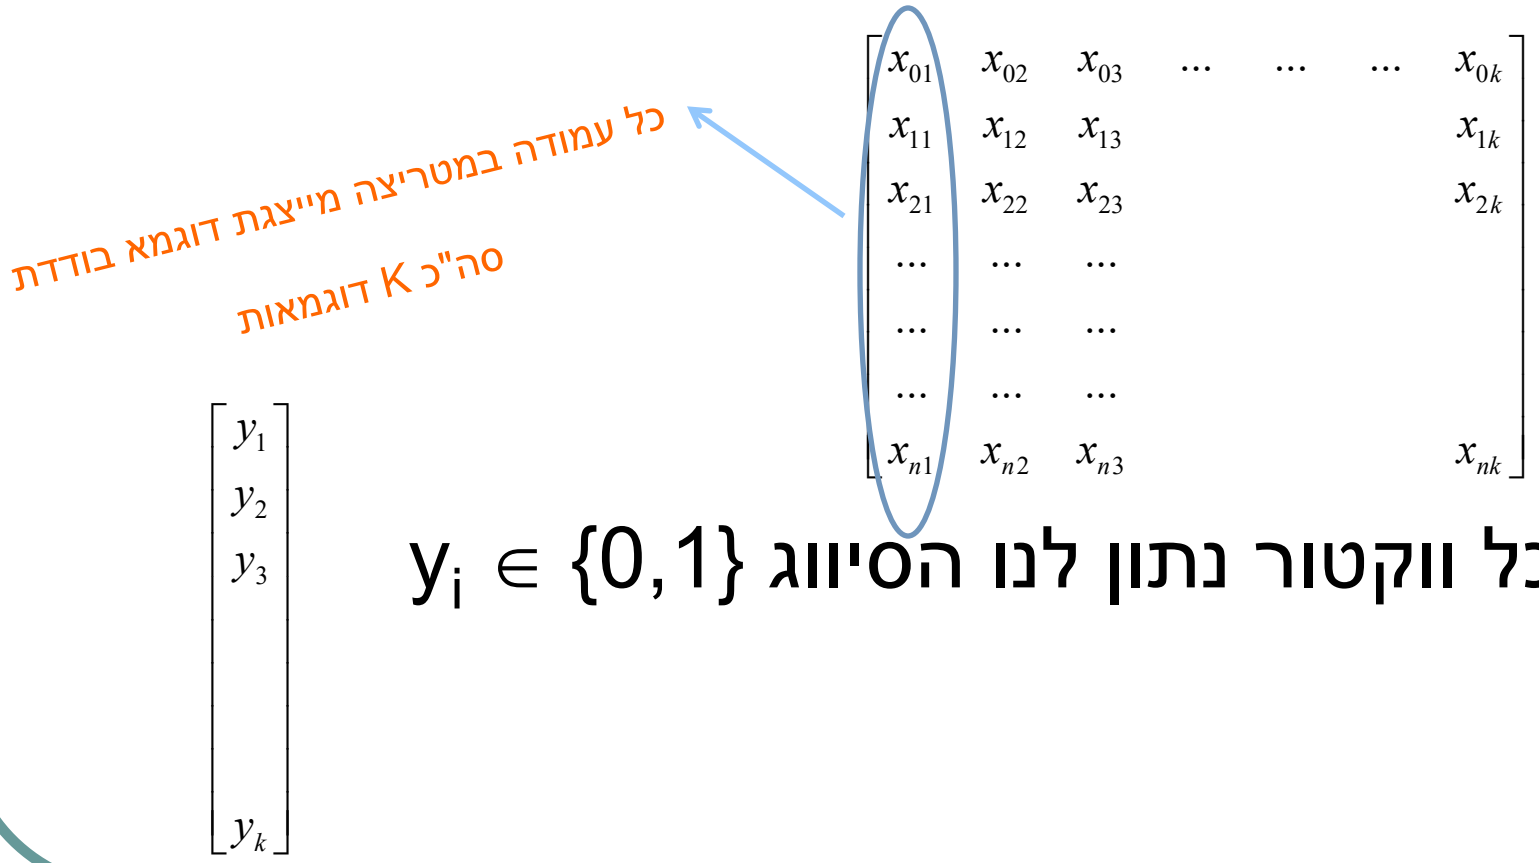
- אנו מחפשים את h שממזערת לנו את הטעות על **ה"עולם האמיתי"**. כלומר יכולת "הכללה"

SVM

- עד כה ראינו, למשל באלגוריתם הפרספטרון, איך אנו מוצאים היפוטזה h שמפרידה בין המחלקות השונות. לא הראינו יכולת הכללה.

תזכורת

- נניח שנתונים לנו k ווקטורים (דוגמאות) $R^n \in X_i$



$$\begin{bmatrix} x_{01} & x_{02} & x_{03} & \dots & \dots & \dots & x_{0k} \\ x_{11} & x_{12} & x_{13} & & & & x_{1k} \\ x_{21} & x_{22} & x_{23} & & & & x_{2k} \\ \dots & \dots & \dots & & & & \\ \dots & \dots & \dots & & & & \\ \dots & \dots & \dots & & & & \\ x_{n1} & x_{n2} & x_{n3} & & & & x_{nk} \end{bmatrix}$$

$$\begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \\ \\ \\ y_k \end{bmatrix}$$

- לכל ווקטור נתון לנו הסיווג $y_i \in \{0,1\}$

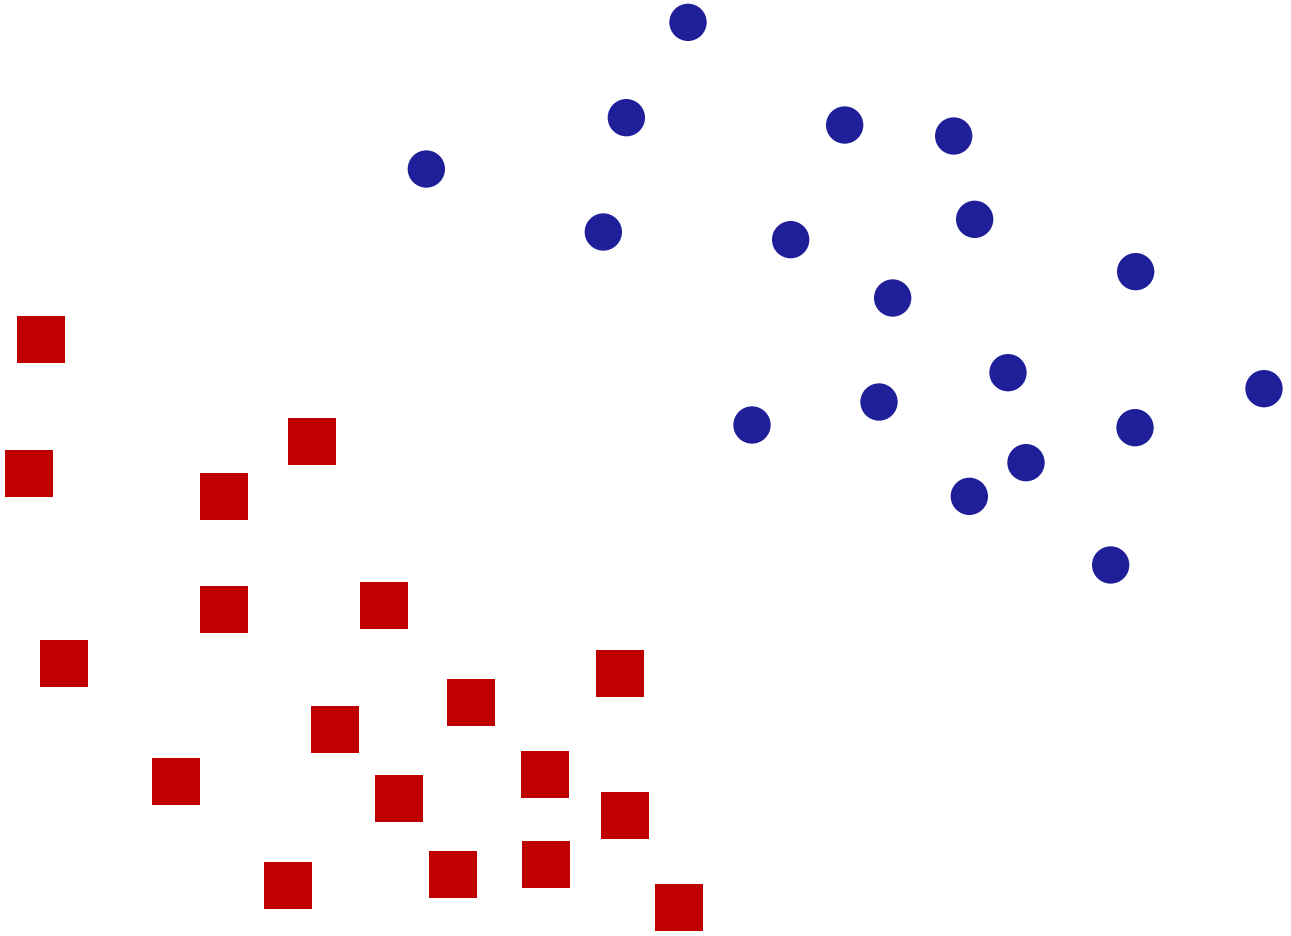
ייצוג מתמטי

- אנו מחפשים קבוצת משקלים כך ש-

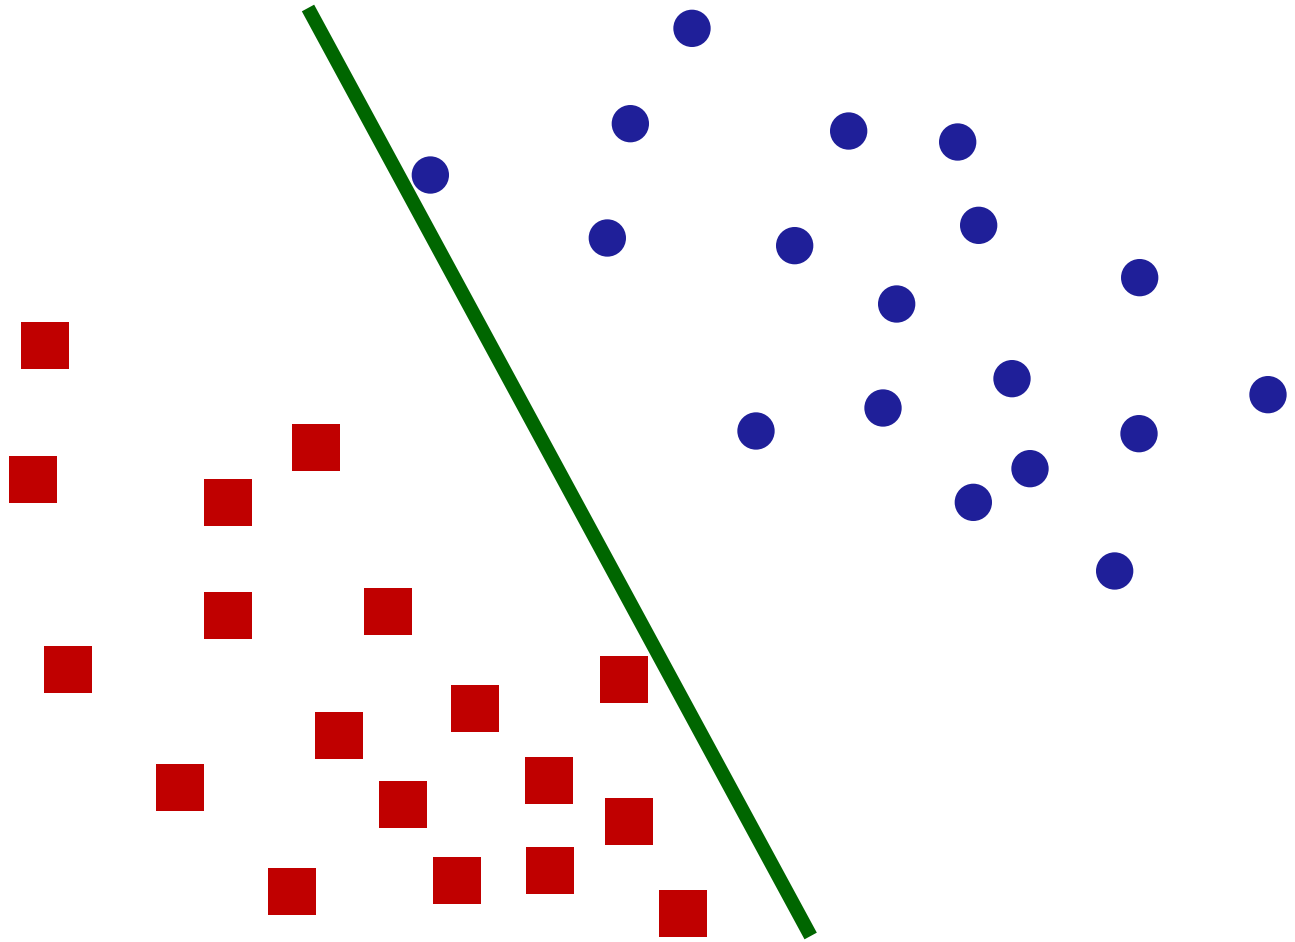
$$\begin{aligned}
&\mathrm{sgn}(w_0 x_{01} + w_1 x_{11} + w_2 x_{21} + \ldots\ldots + w_n x_{n1}) = y_1 \\
&\mathrm{sgn}(w_0 x_{02} + w_1 x_{12} + w_2 x_{22} + \ldots\ldots + w_n x_{n2}) = y_2 \\
&\ldots\ldots \\
&\ldots\ldots
\end{aligned}$$

$$\mathrm{sgn}\left(\left[w_0, w_1, w_2 \ldots\ldots w_n \right] \begin{bmatrix} x_{01} & x_{02} & x_{03} & \ldots & \ldots & \ldots & x_{0k} \\ x_{11} & x_{12} & x_{13} & \ldots & & & x_{1k} \\ x_{21} & x_{22} & x_{23} & \ldots & & & x_{2k} \\ \ldots & \ldots & \ldots & & & & \\ \ldots & \ldots & \ldots & & & & \\ \ldots & \ldots & \ldots & & & & \\ x_{n1} & x_{n2} & x_{n3} & & & & x_{nk} \end{bmatrix} \right) = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ . \\ . \\ . \\ y_k \end{bmatrix}$$

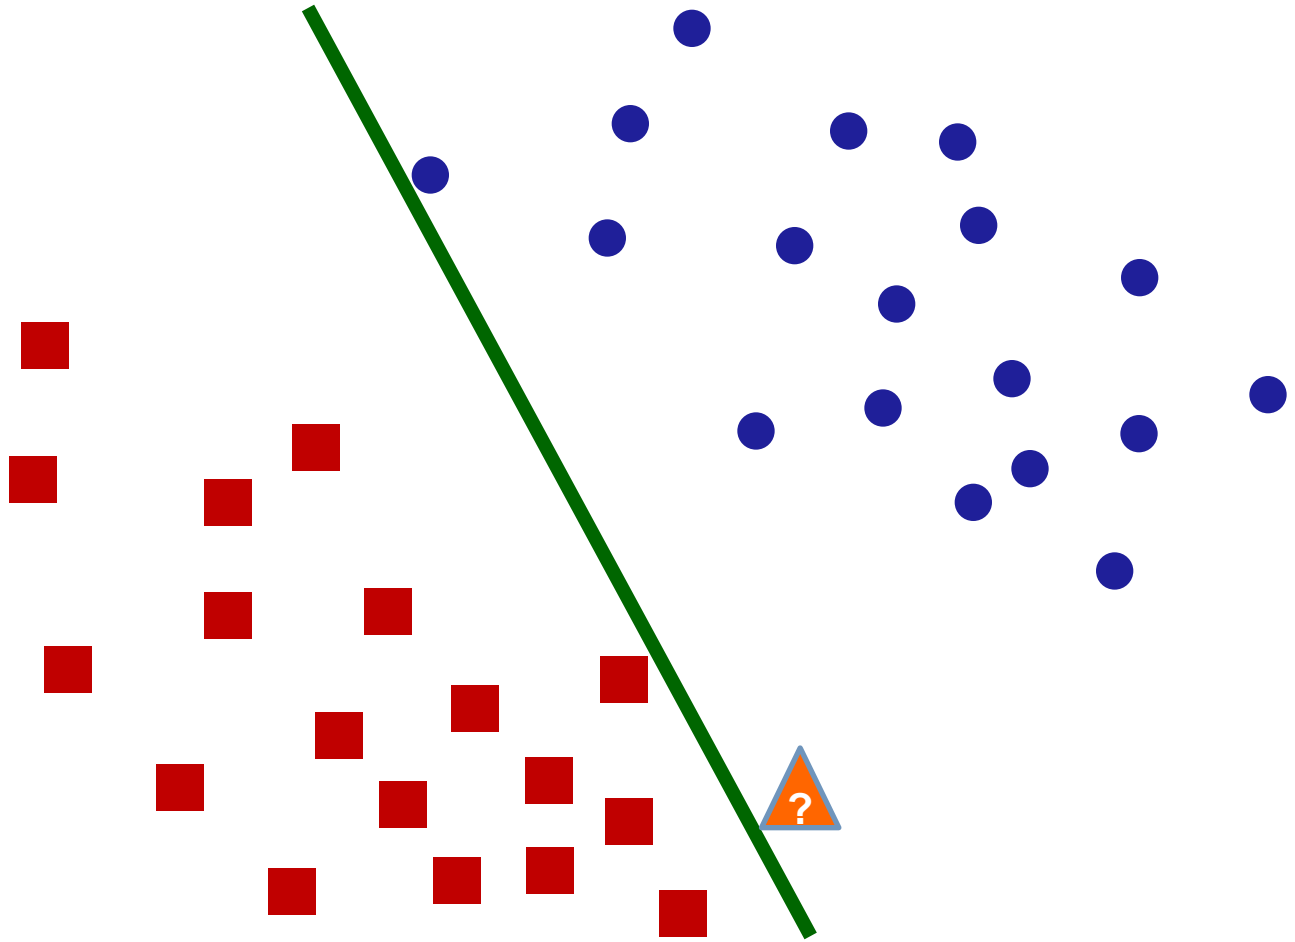
SVM



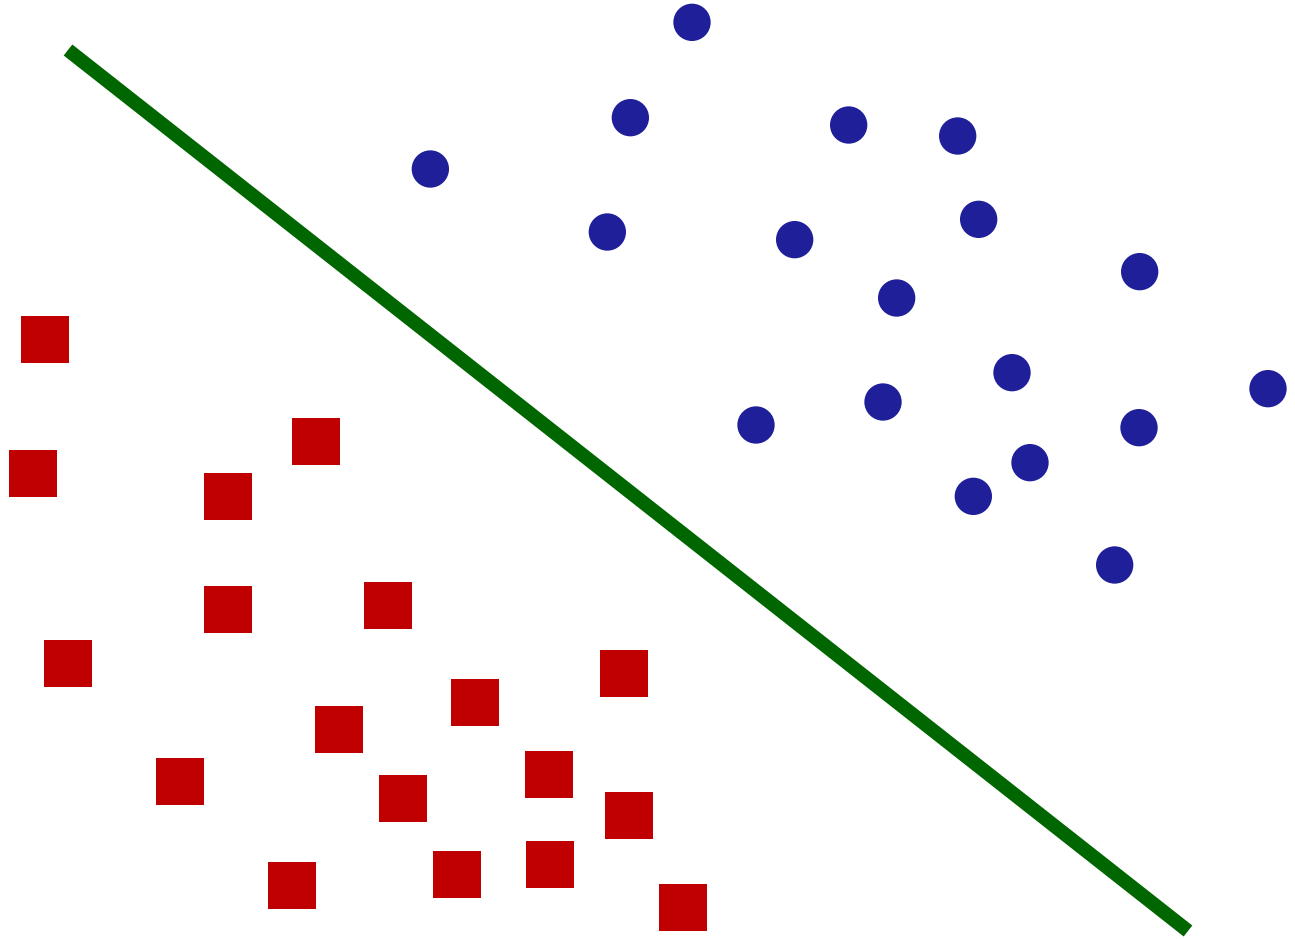
SVM



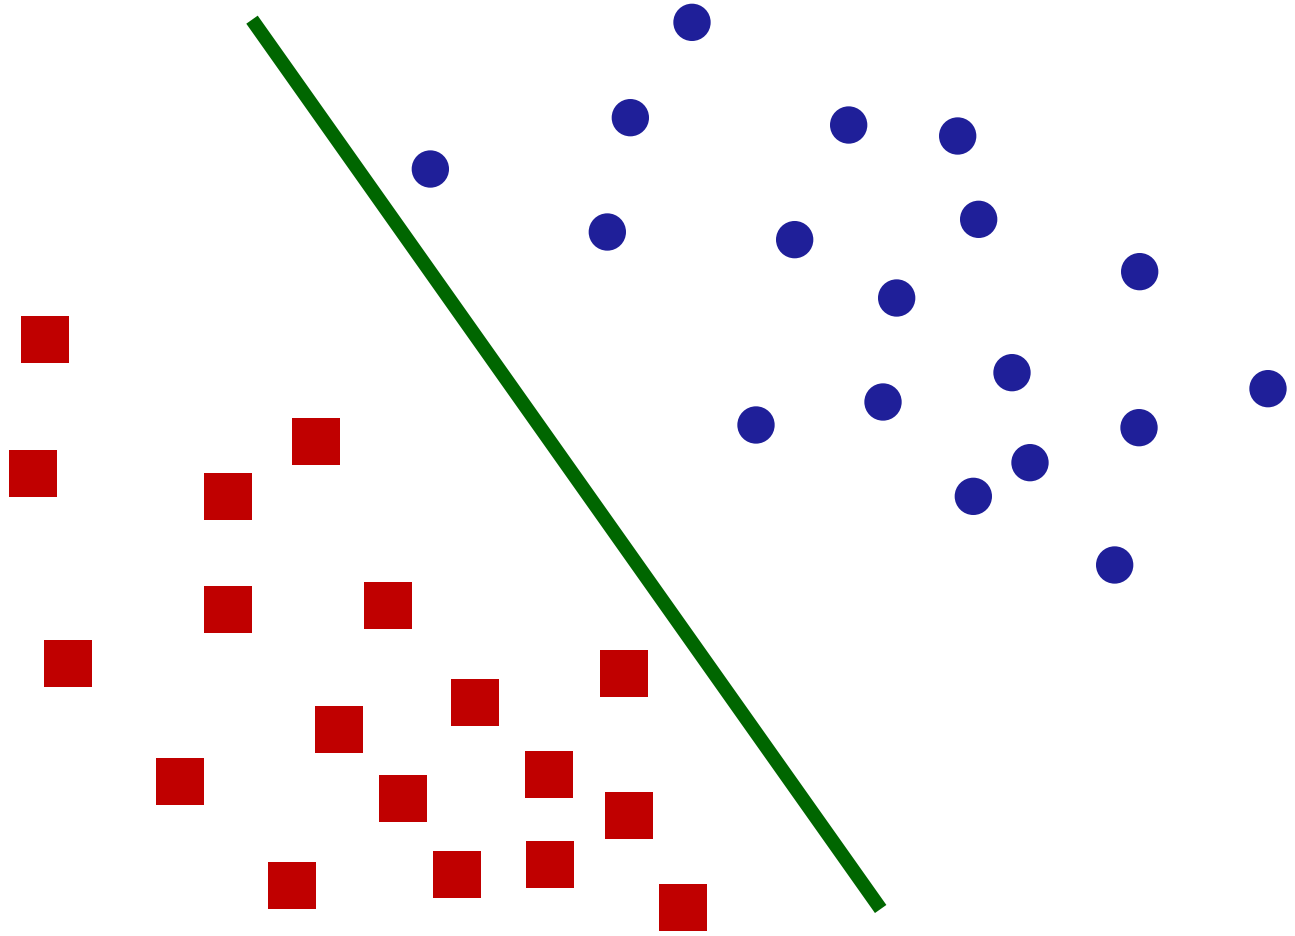
SVM



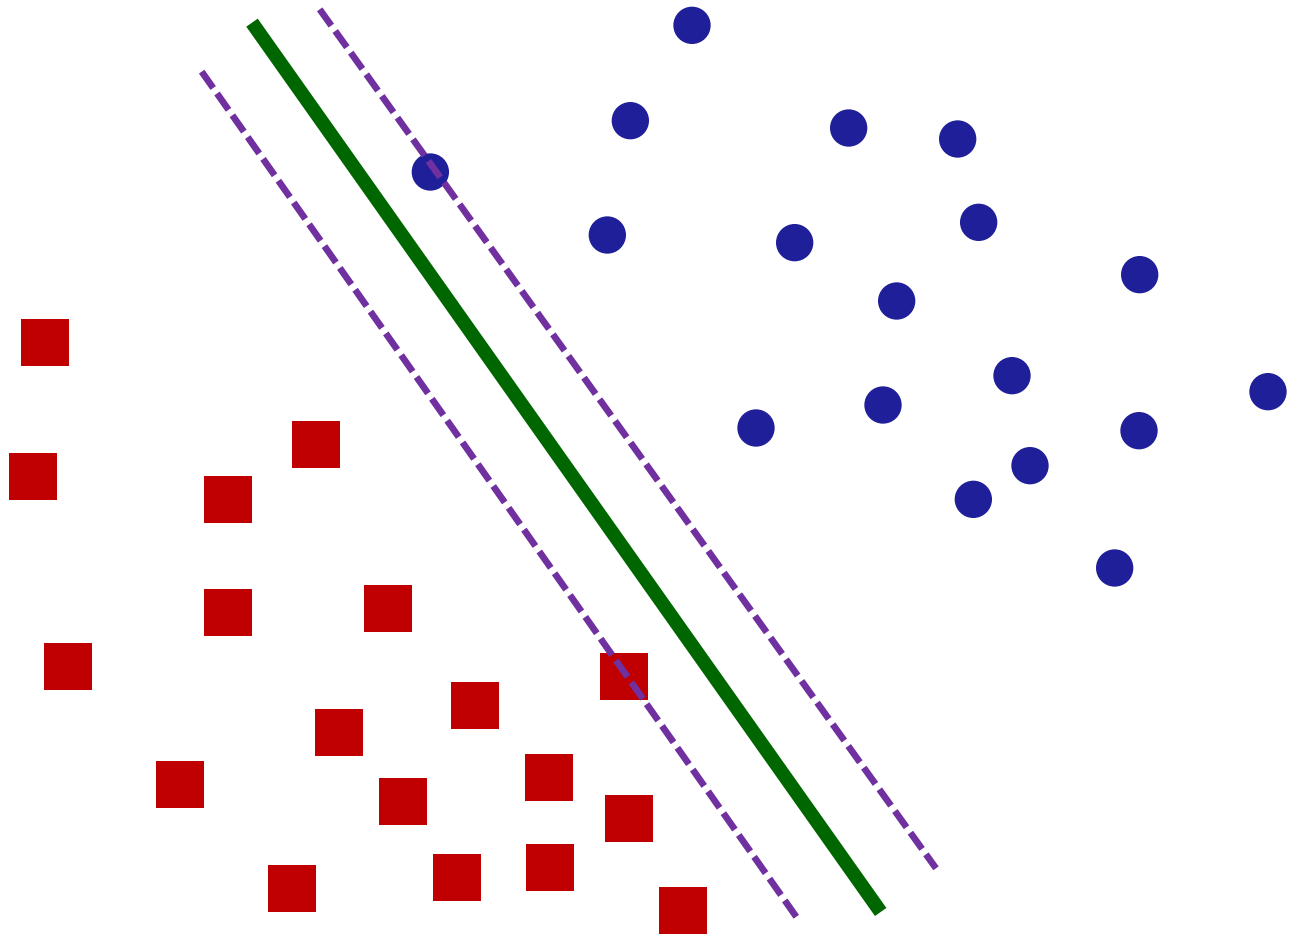
SVM



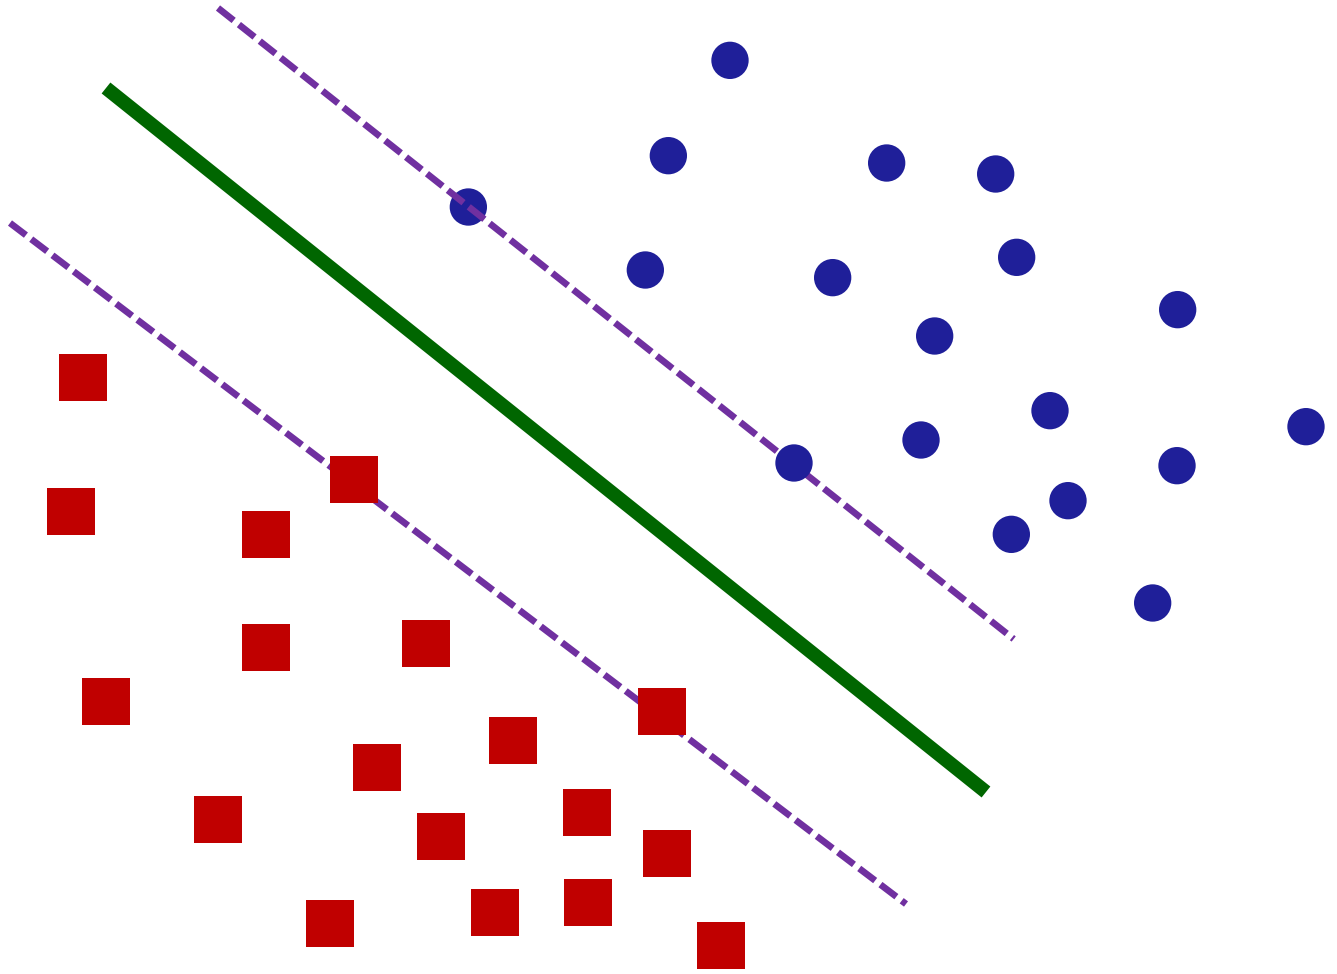
Perceptron – Different possible solutions



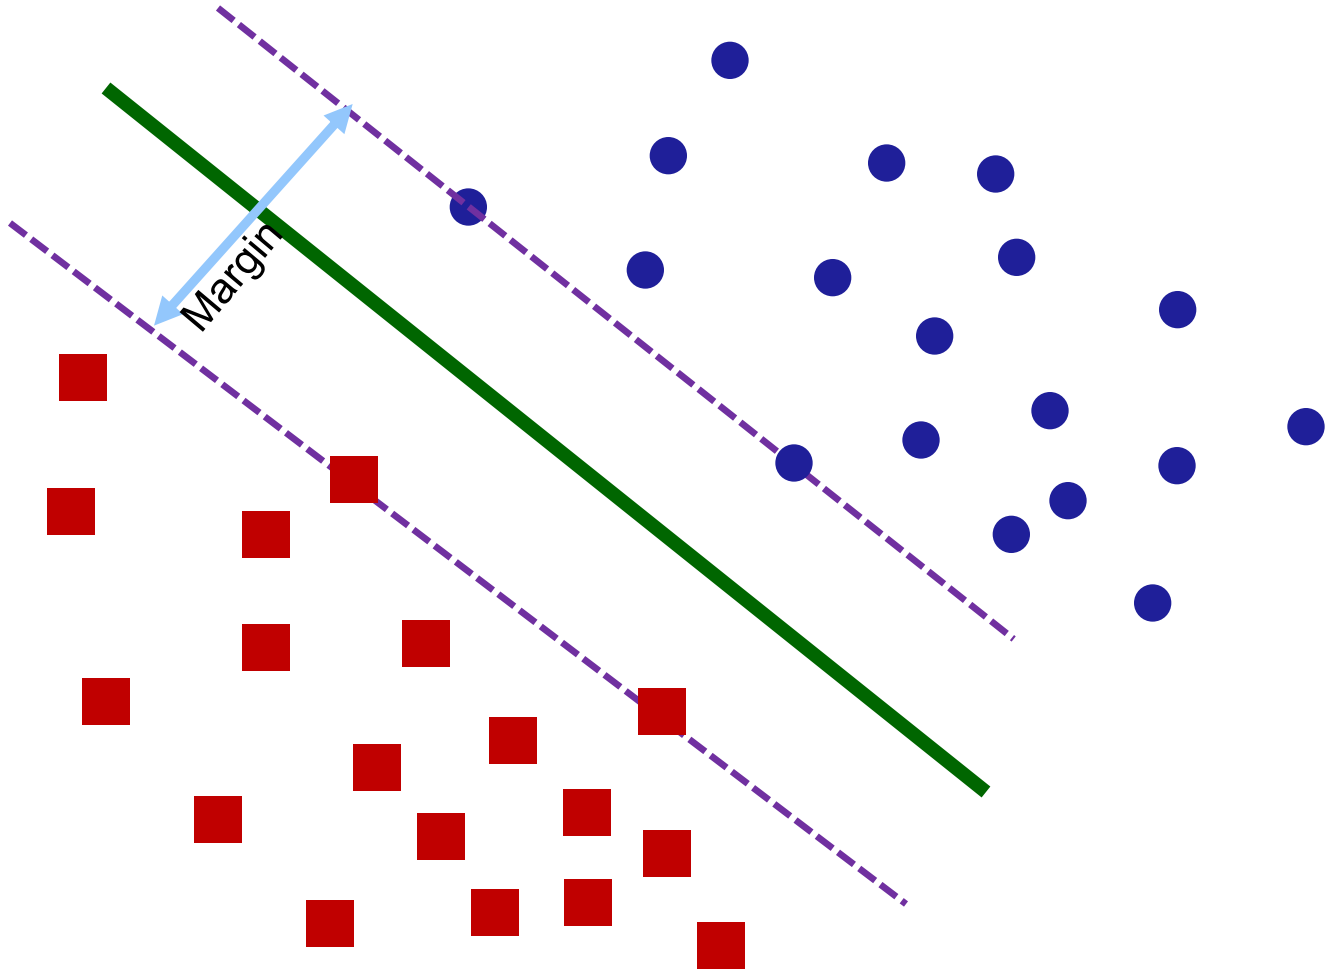
Perceptron – Different possible solutions



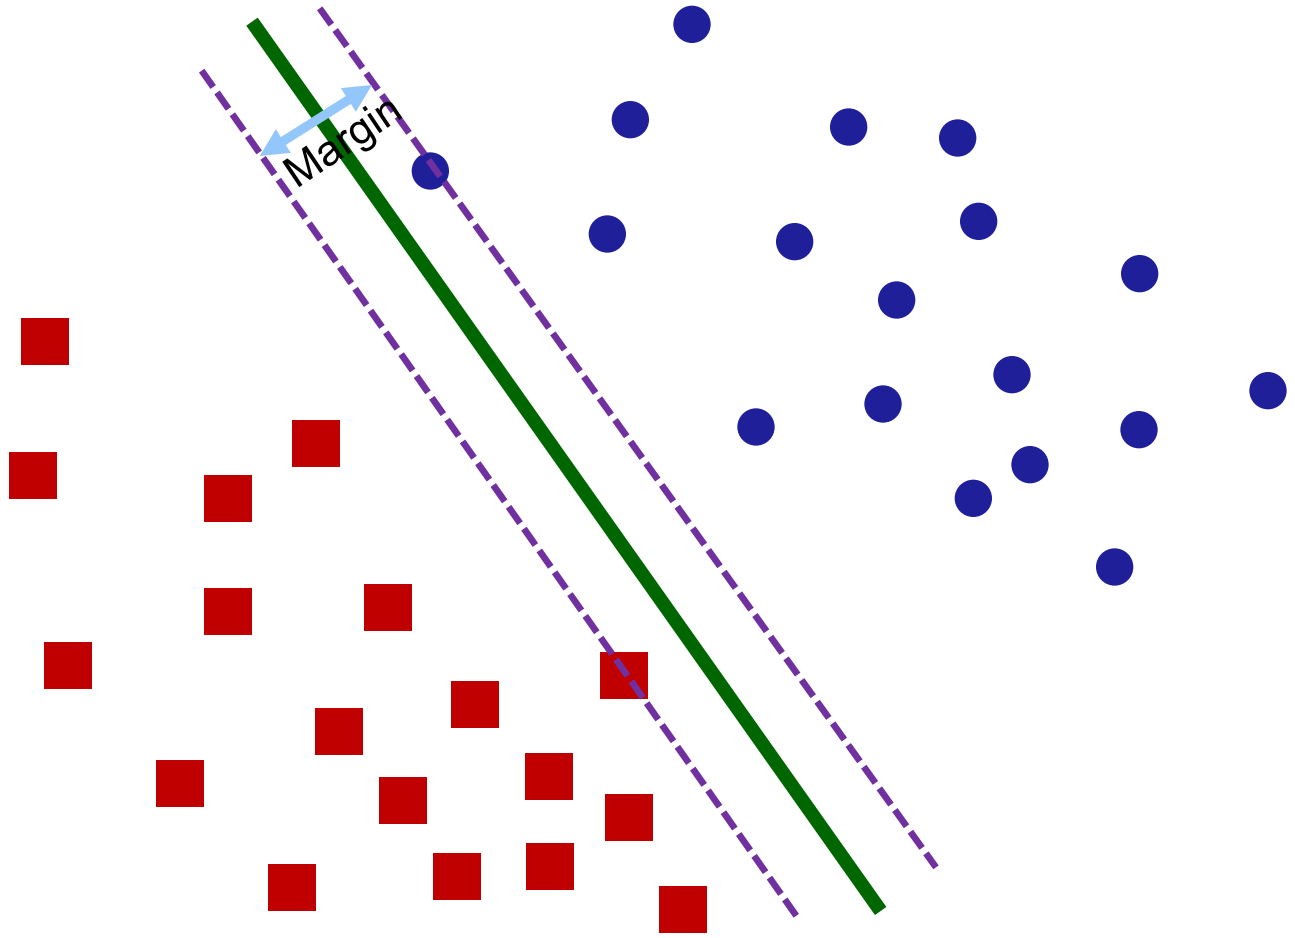
Perceptron – Different possible solutions



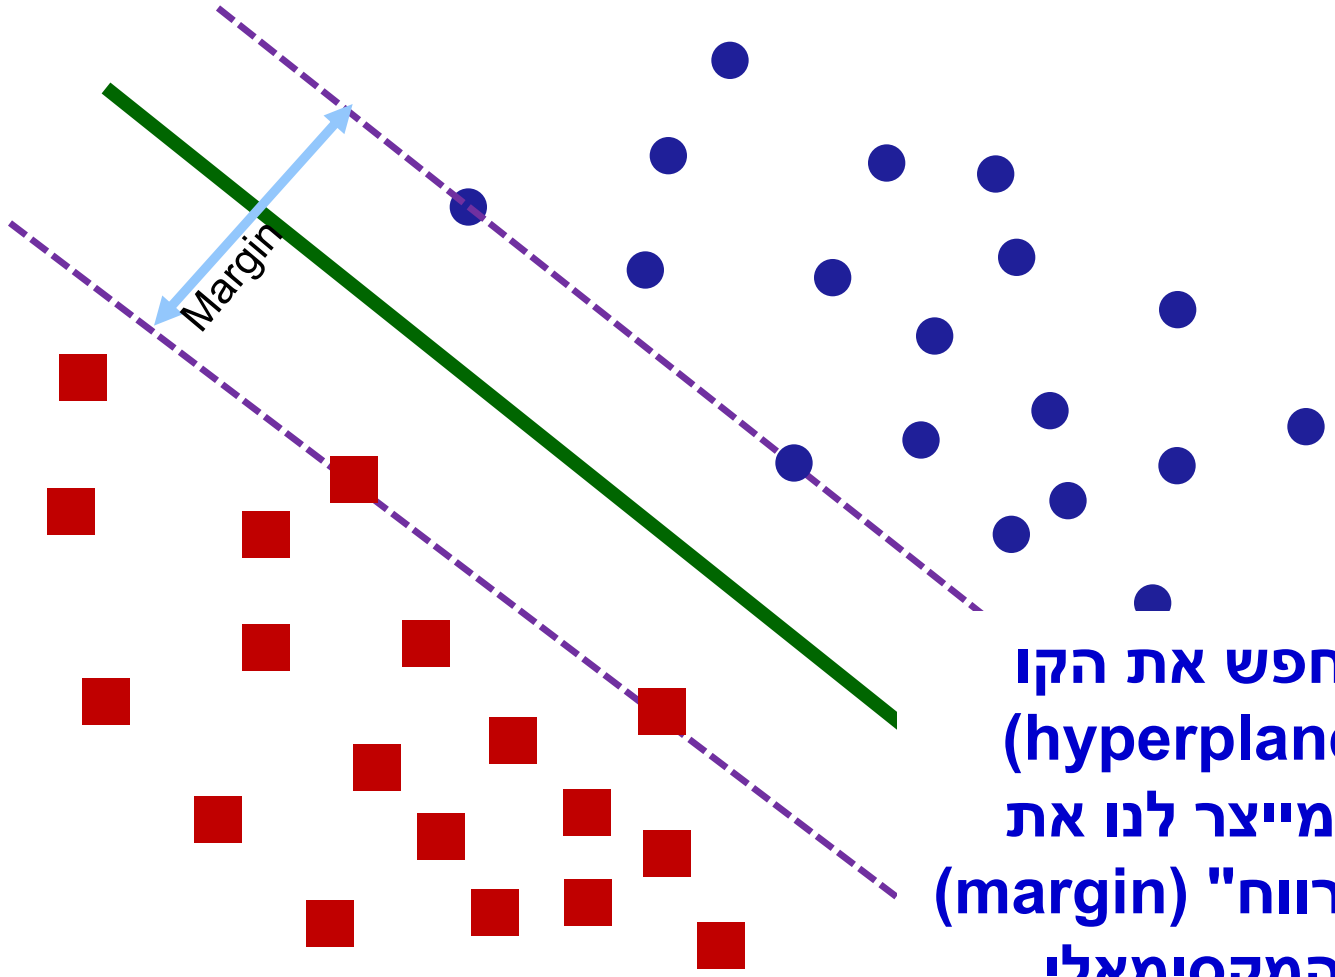
Perceptron – Different possible solutions



Perceptron – Different possible solutions

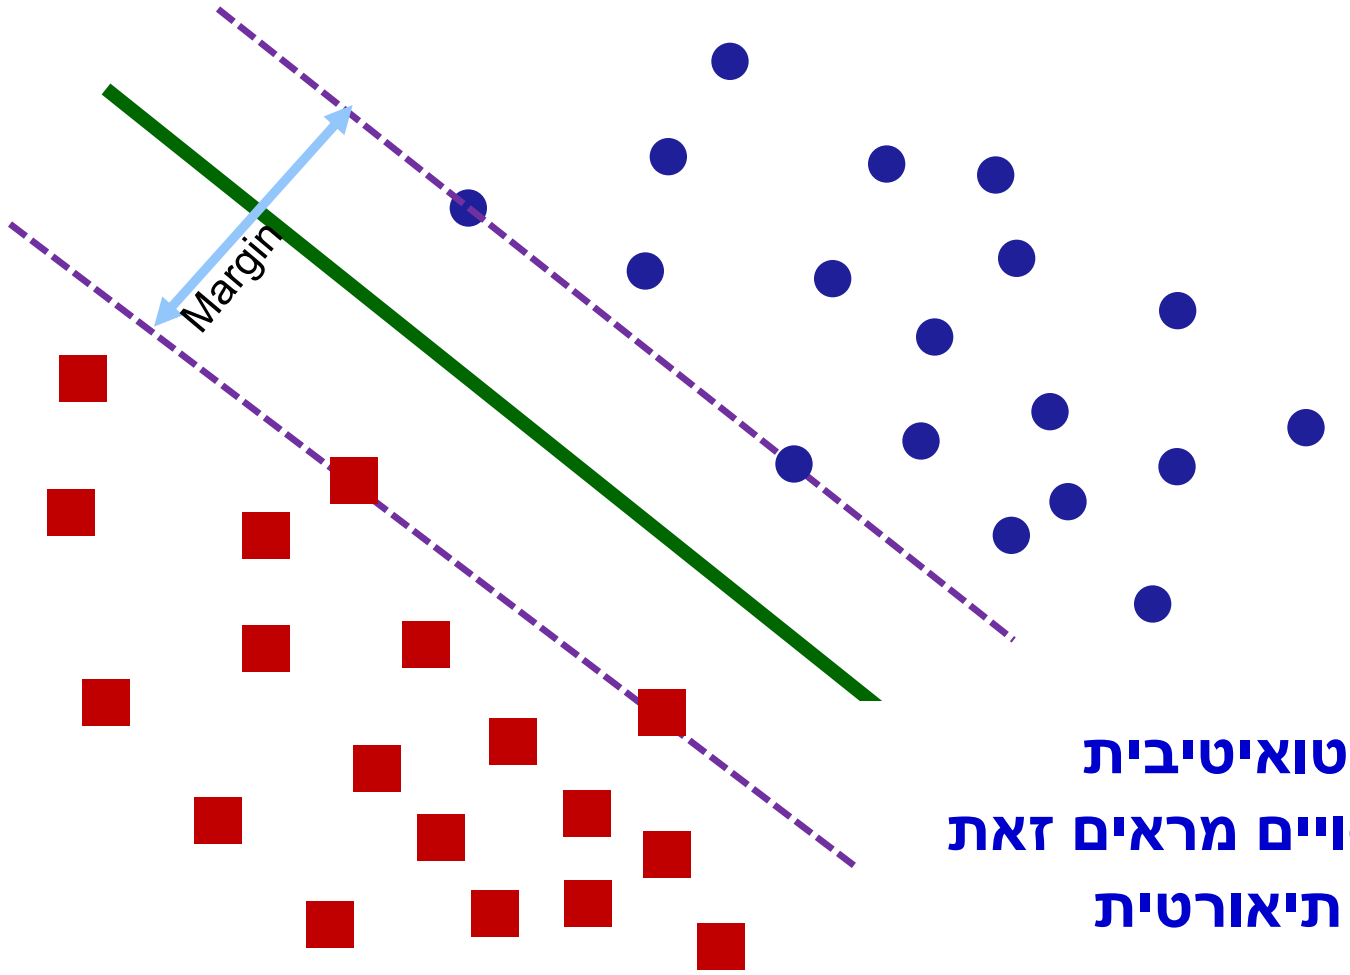


Perceptron – Different possible solutions



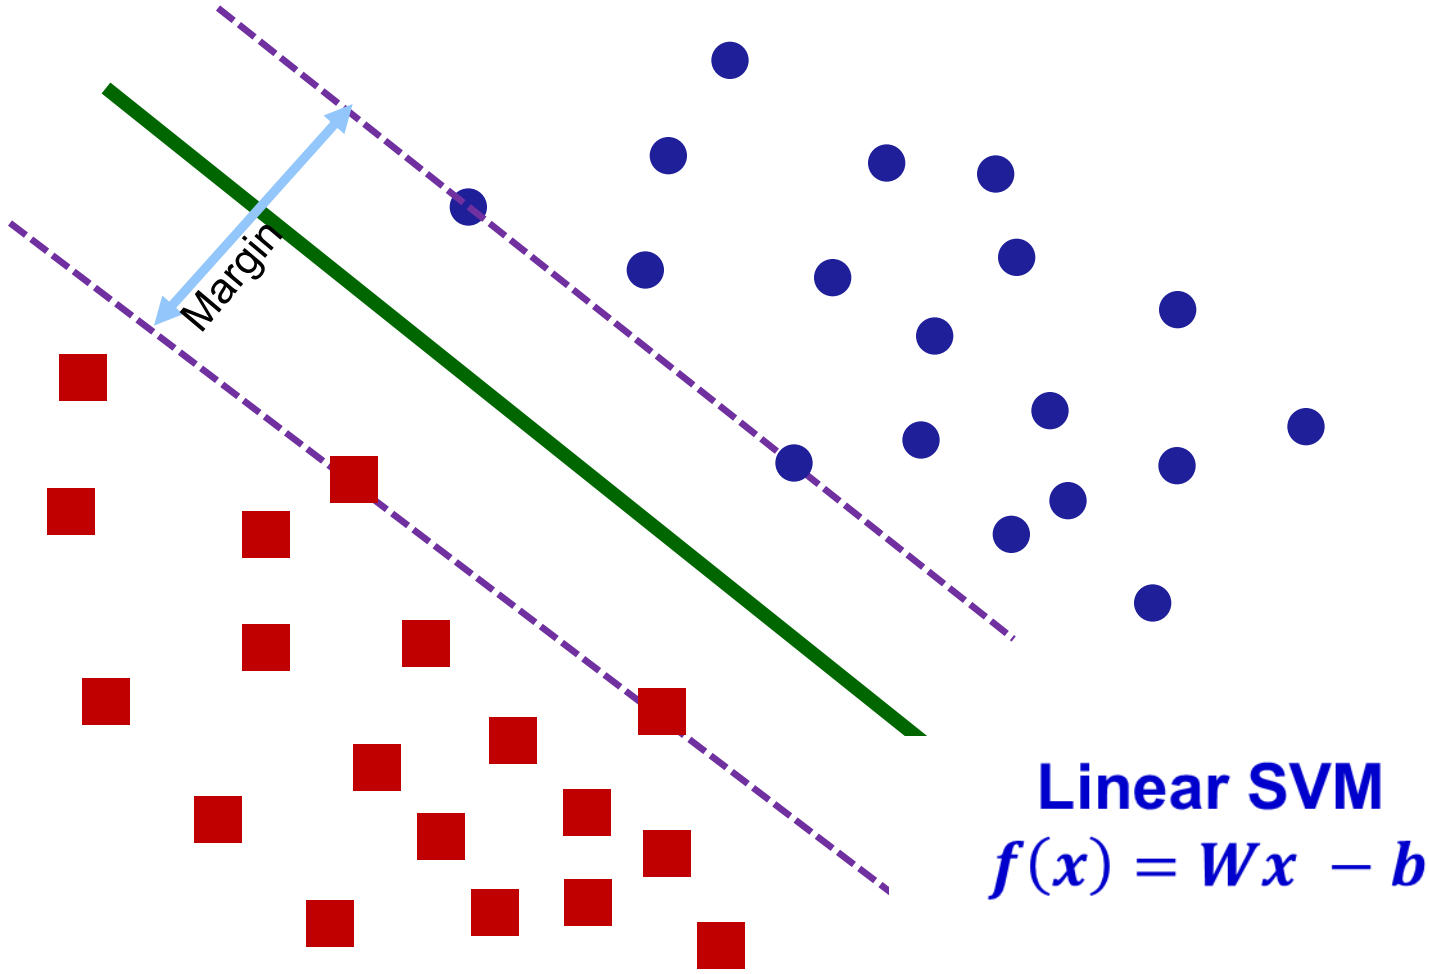
נחפש את הקו (hyperplane) שמייצר לנו את ה"מרווח" (margin) המקסימאלי

Perceptron – Different possible solutions

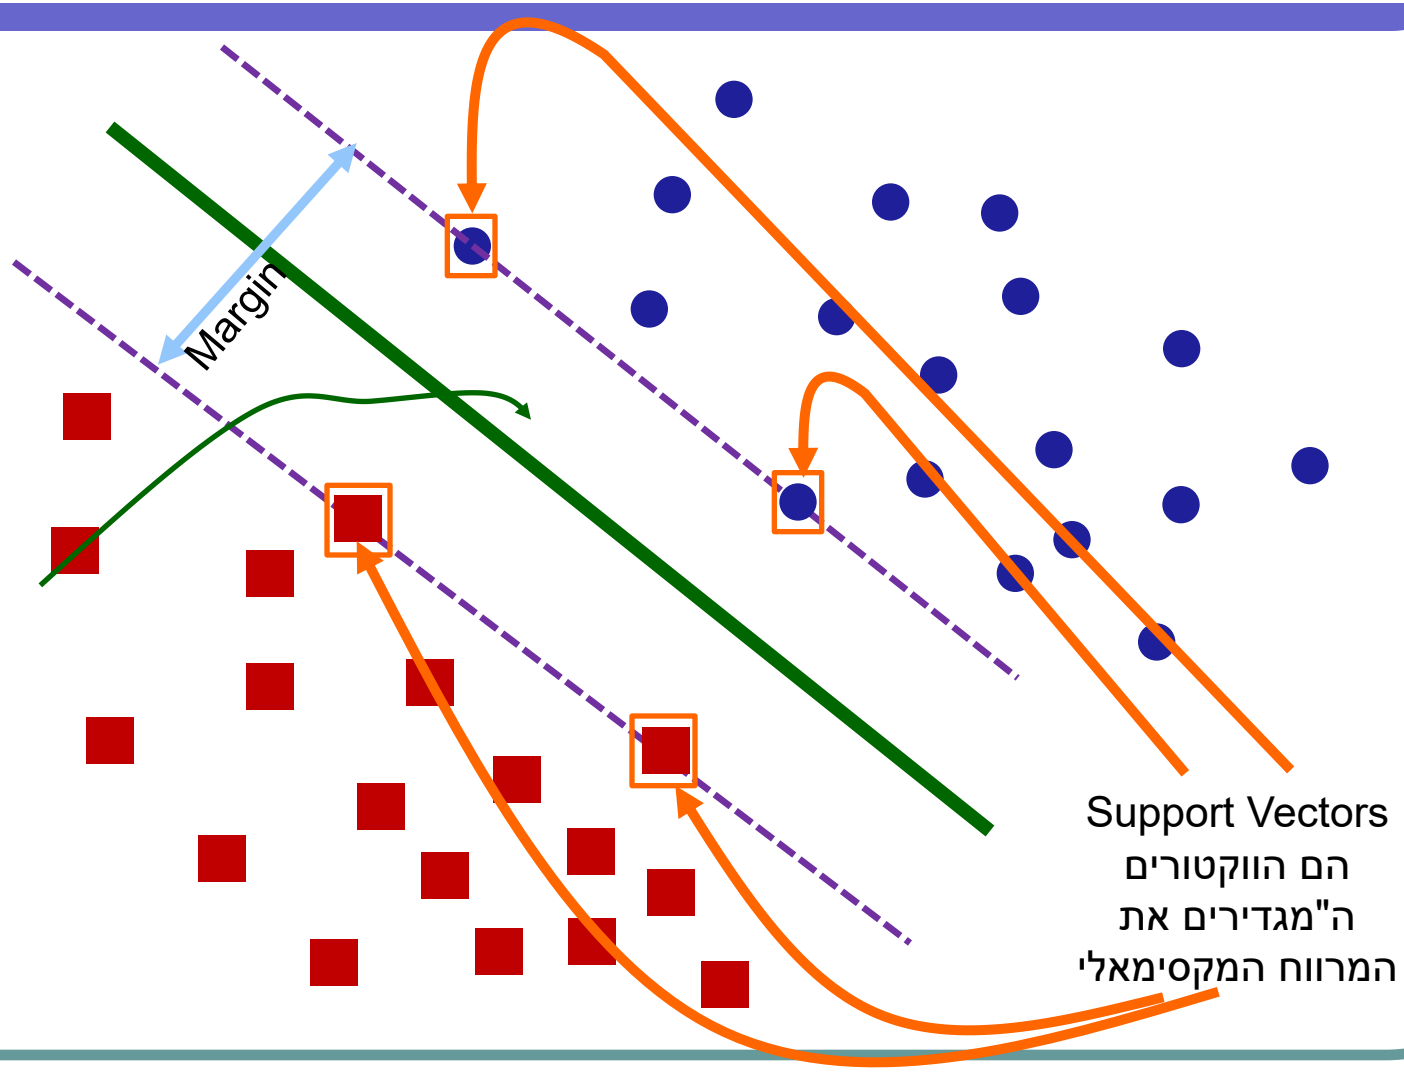


1. אינטואיטיבית
2. ניסויים מראים זאת
3. גם תיאורטית

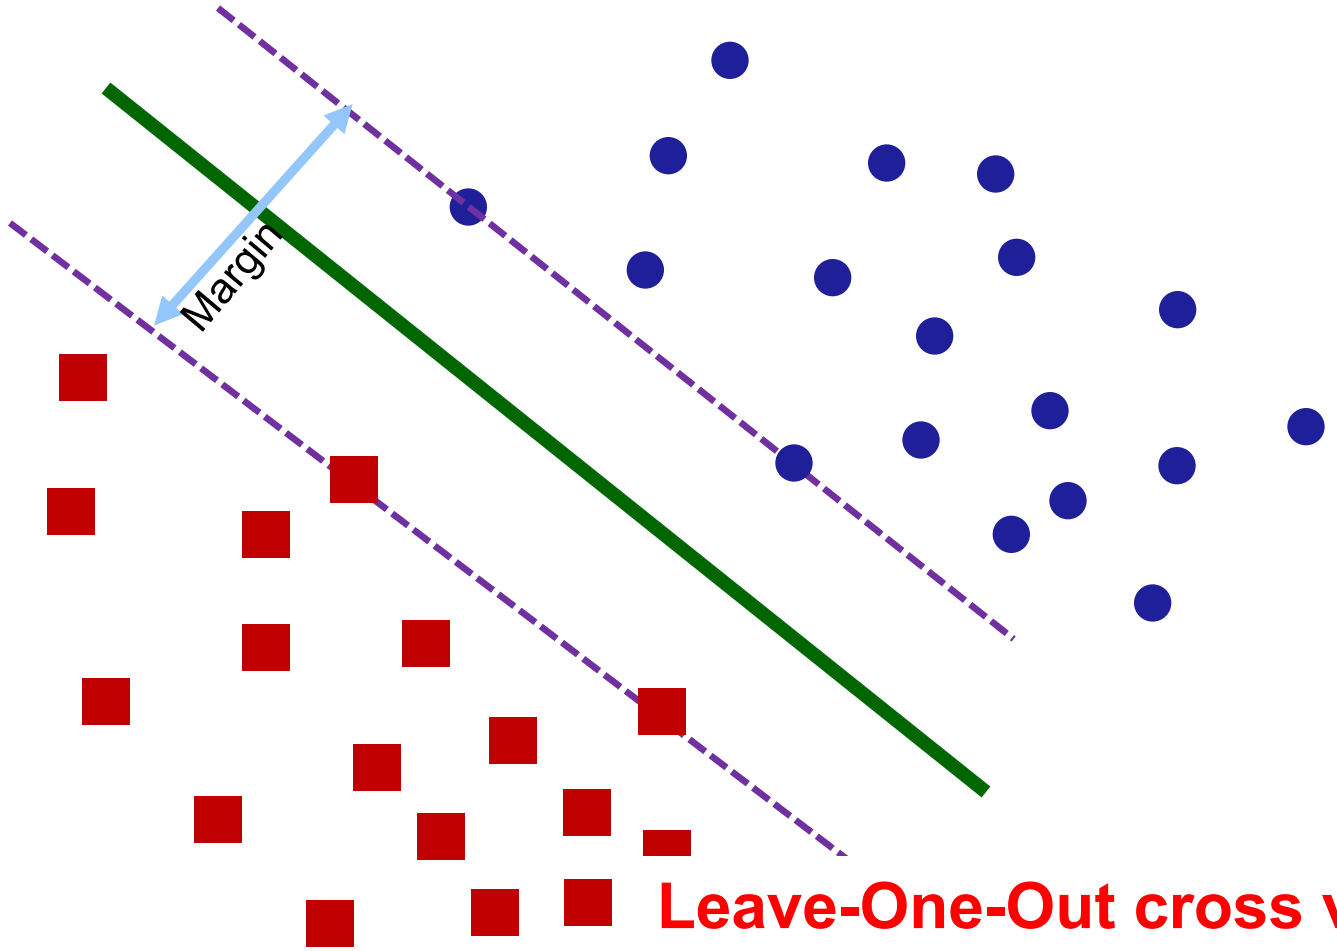
Perceptron – Different possible solutions



Perceptron – Different possible solutions



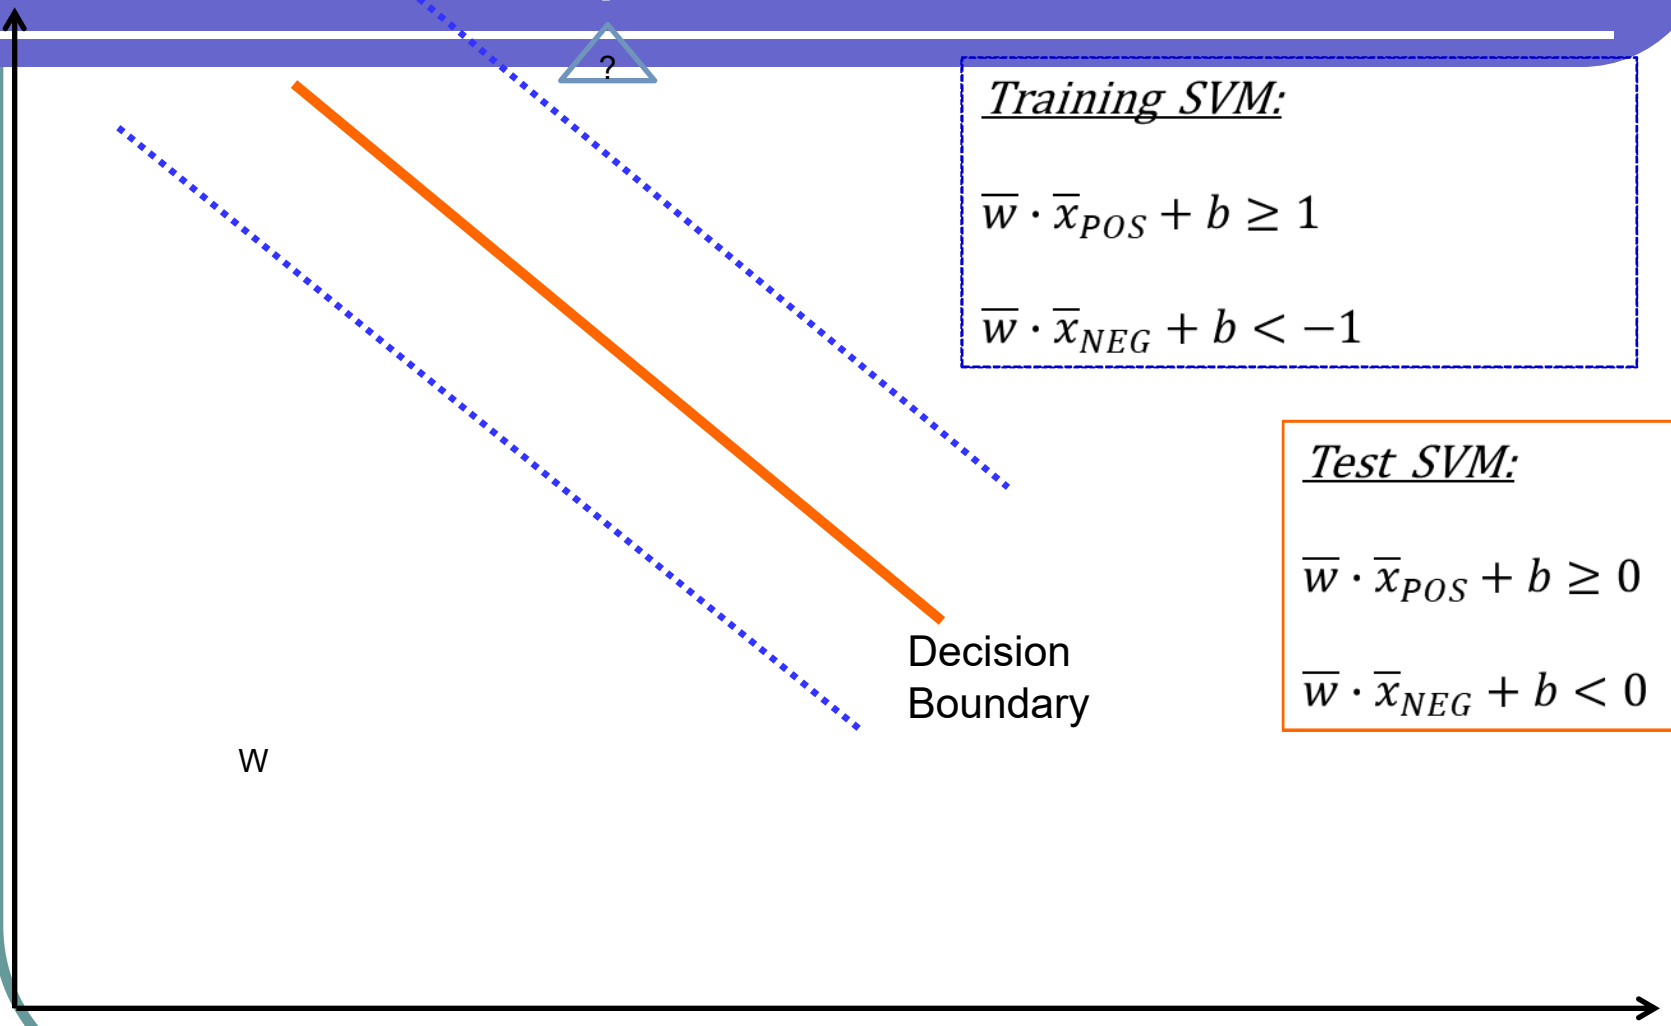
Perceptron – Different possible solutions



Leave-One-Out cross validation

חסין להורדת נקודות שאינן SV

ב-SVM נדרוש דרישה "קשיחה" יותר



Training SVM:

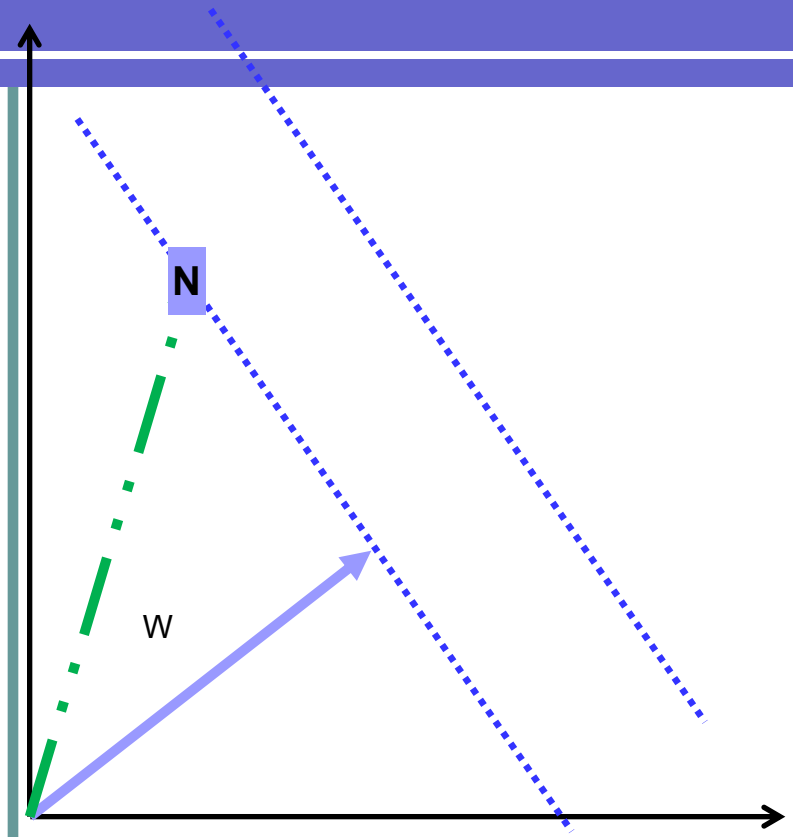
$$\overline{w} \cdot \overline{x}_{POS} + b \geq 1$$

$$\overline{w} \cdot \overline{x}_{NEG} + b < -1$$

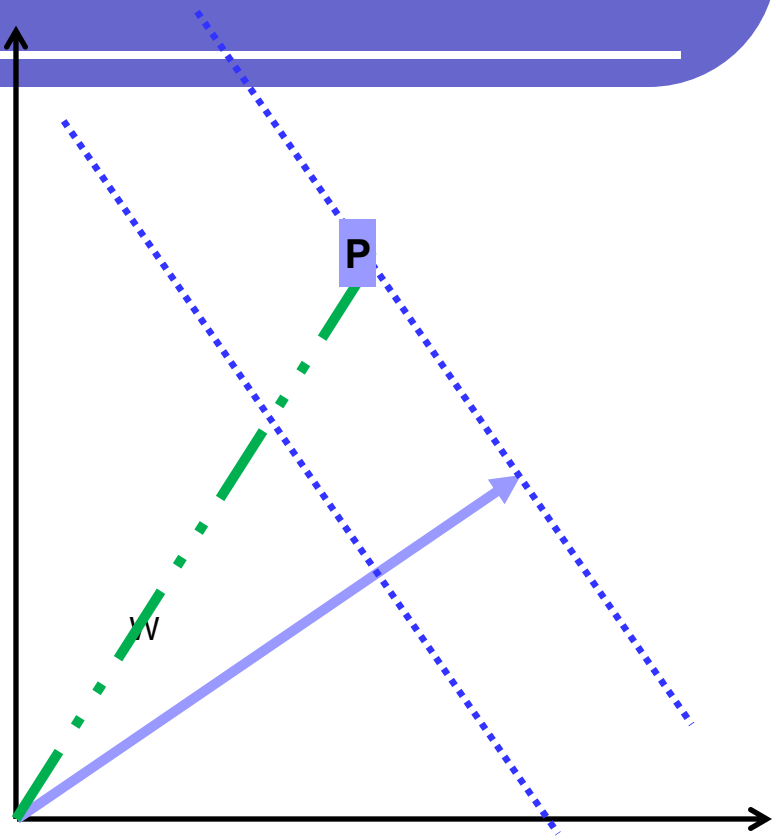
Test SVM:

$$\overline{w} \cdot \overline{x}_{POS} + b \geq 0$$

$$\overline{w} \cdot \overline{x}_{NEG} + b < 0$$

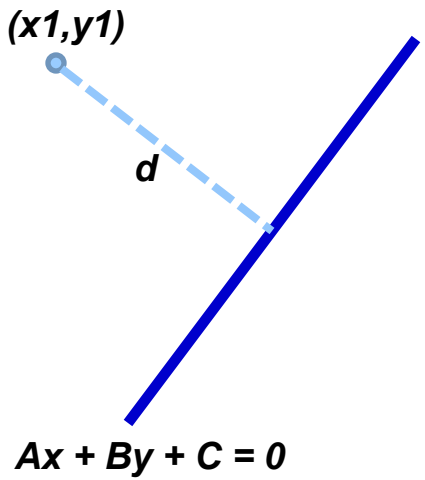


$$\overline{w} \cdot \overline{x}_{SV-NEG} + b = -1$$



$$\overline{w} \cdot \overline{x}_{SV-POS} + b = 1$$

מרחק נקודה מישר



- הישר Ax + By + C = 0

$$d = \frac{|Ax_1 + By_1 + C|}{\sqrt{A^2 + B^2}}$$

- במקרה הכללי – משוואת ה-hyperplane

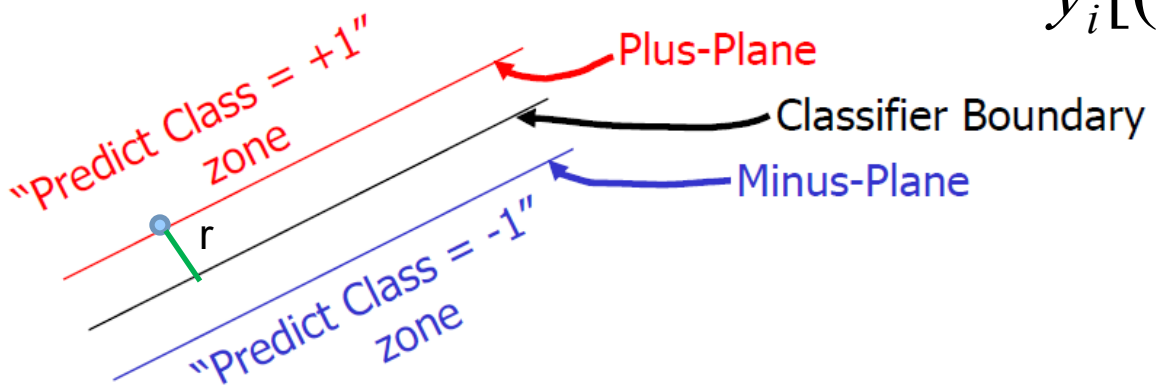
$$\sum w_i x_i + b = 0$$

x_s מרחק הנקודה מה-hyperplane

$$d = \frac{|wx_s + b|}{||w||}$$

איך מחשבים את ה-Support Vectors

$$y_i[(w^T)x_i + b] \geq 1$$



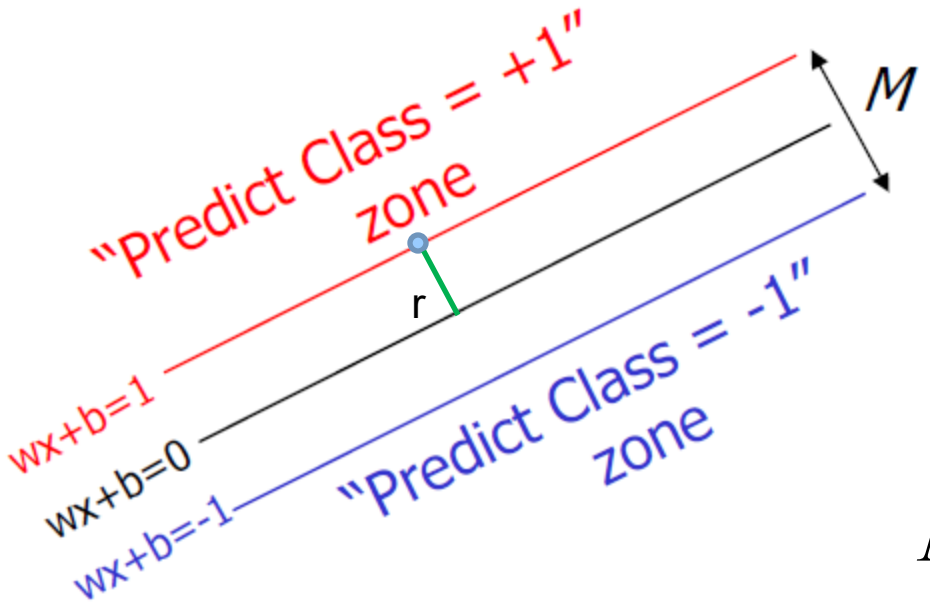
http://www.cs.cmu.edu/~awm/tutorials

עבור ה- Support Vectors מתקיים השיוויון במשוואה

המרחק בין כל Support Vectors למסווג:

$$r = \frac{|(\mathbf{w}^T\mathbf{x}_s + b)|}{\|\mathbf{w}\|} = \frac{1}{\|\mathbf{w}\|}$$

איך מחשבים את ה-Support Vectors

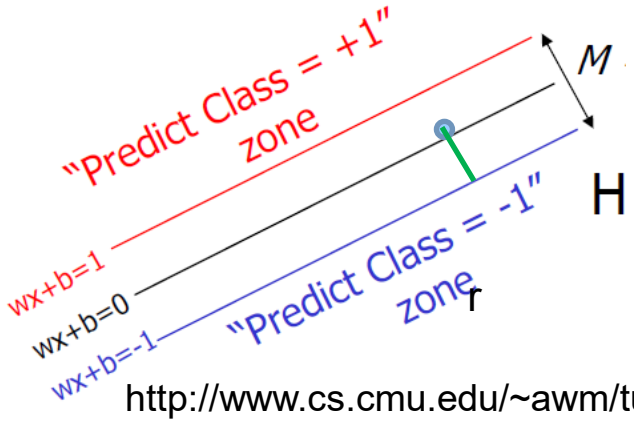


$$r = \frac{(\mathbf{w}^T \mathbf{x}_s + b)}{\|\mathbf{w}\|} = \frac{1}{\|\mathbf{w}\|}$$

$$M = 2r = \frac{2}{\|\mathbf{w}\|}$$

http://www.cs.cmu.edu/~awm/tutorials

איך מחשבים את ה-Support Vectors



http://www.cs.cmu.edu/~awm/tutorials

$$r = \frac{(\mathbf{w}^T \mathbf{x}_s + b)}{\|\mathbf{w}\|} = \frac{1}{\|\mathbf{w}\|}$$

$$M = 2r = \frac{2}{\|\mathbf{w}\|}$$

מצא w,b כך ש-

א. $M = \frac{2}{\|w\|}$ מקבל ערך מקסימאלי

ב. (x_i,y_i) מקבוצת האימון מתקיים: $y_i(w^T x_i + b) \geq 1$

איך מחשבים את ה-Support Vectors

או .....

מצא w,b כך ש-

א. $||W||^2$ מקבל ערך מינימאלי

ב. (x_i,y_i) מקבוצת האימון מתקיים: $y_i(w^T x_i + b) \geq 1$

Learning via Quadratic Programming

Find $\arg\max_{\mathbf{u}} \quad c + \mathbf{d}^T\mathbf{u} + \frac{\mathbf{u}^T R\mathbf{u}}{2}$ ← Quadratic criterion

Subject to

$$\begin{aligned} a_{11}u_1 + a_{12}u_2 + \ldots + a_{1m}u_m &\le b_1 \\ a_{21}u_1 + a_{22}u_2 + \ldots + a_{2m}u_m &\le b_2 \\ &\vdots \\ a_{n1}u_1 + a_{n2}u_2 + \ldots + a_{nm}u_m &\le b_n \end{aligned}$$

} *n* additional linear inequality constraints

And subject to

$$\begin{aligned} a_{(n+1)1}u_1 + a_{(n+1)2}u_2 + \ldots + a_{(n+1)m}u_m &= b_{(n+1)} \\ a_{(n+2)1}u_1 + a_{(n+2)2}u_2 + \ldots + a_{(n+2)m}u_m &= b_{(n+2)} \\ &\vdots \\ a_{(n+e)1}u_1 + a_{(n+e)2}u_2 + \ldots + a_{(n+e)m}u_m &= b_{(n+e)} \end{aligned}$$

} *e* additional linear equality constraints

Linear SVM

- אנו רוצים למצוא ***w,b*** שיסווגו בצורה נכונה את כל הווקטורים בקבוצת האימון $y_i(wx_i + b) \geq 1$
- וימזערו את הערך $\frac{1}{2} \| w \|^2$
- (משוואה קוואדרטית)

בעיה דואלית

- נוכל לפתור את משוואת האילוצים ע"י מעבר לבעיה דואלית
- בבעיה הדואלית במקום למצוא ערכי w נמצא ערכי α
- נראה כמובן איך מתמירים מערכי α לערכי w
- כדאי לעבור לבעיה הדואלית. זה יסייע לנו בהמשך בפתרון בעיות לא לינאריות (מכיוון שבבעיה הדואלית יש לנו מכפלות פנימיות... נראה בהמשך)

An Equivalent QP

Warning: up until Rong Zhang spotted my error in Oct 2003, this equation had been wrong in earlier versions of the notes. This version is correct.

Maximize $\sum_{k=1}^{R} \alpha_k - \frac{1}{2} \sum_{k=1}^{R} \sum_{l=1}^{R} \alpha_k \alpha_l Q_{kl}$ where $Q_{kl} = y_k y_l (\mathbf{x}_k . \mathbf{x}_l)$

Subject to these constraints: $0 \le \alpha_k \le C \quad \forall k$ $\sum_{k=1}^{R} \alpha_k y_k = 0$

Then define:

$$\mathbf{w} = \sum_{k=1}^{R} \alpha_k y_k \mathbf{x}_k$$

$$b = y_K (1 - \varepsilon_K) - \mathbf{x}_K . \mathbf{w}_K$$

where $K = \arg \max_k \alpha_k$

Then classify with:

$f(\mathbf{x}, \mathbf{w}, b) = sign(\mathbf{w}. \mathbf{x} - b)$

איך נחשב את הערך b ?

- אנו יודעים שעבור כל ה- Support Vectors החיוביים ערך משוואת הסיווג (ללא הפעלת פונקציית ה-sgn) שווה ל-1 בדיוק, ועבור כל ה- Support Vectorsהשליליים ערך משוואת הסיווג (ללא הפעלת פונקציית ה-sgn) שווה ל-1- בדיוק.
- **לכן נציב למשל נקודה חיובית במשוואה ונקבל:**

$$(\sum_i \alpha_i y_i x_i - b) = 1$$

$$b = 1 - \sum_i \alpha_i y_i x_i - b)$$

An Equivalent QP

Warning: up until Rong Zhang spotted my error in Oct 2003, this equation had been wrong in earlier versions of the notes. This version is correct.

Maximize $\sum_{k=1}^{R} \alpha_k - \frac{1}{2} \sum_{k=1}^{R} \sum_{l=1}^{R} \alpha_k \alpha_l Q_{kl}$ where $Q_{kl} = y_k y_l (\mathbf{x}_k . \mathbf{x}_l)$

Subject to these constraints: $0 \le \alpha_k \le C \quad \forall k$ $\sum_{k=1}^{R} \alpha_k y_k = 0$

Then define:

$\mathbf{w} = \sum_{k=1}^{R} \alpha_k y_k \mathbf{x}_k$

$b = y_K (1 - \varepsilon_K) - \mathbf{x}_K . \mathbf{w}$

where $K = \arg \max_k \alpha_k$

Datapoints with $\alpha_k > 0$ will be the support vectors

..so this sum only needs to be over the support vectors.

$f(\mathbf{x}, \mathbf{w}, b) = \text{sign}(\mathbf{w} . \mathbf{x} - b)$

SVM – 3 Directions

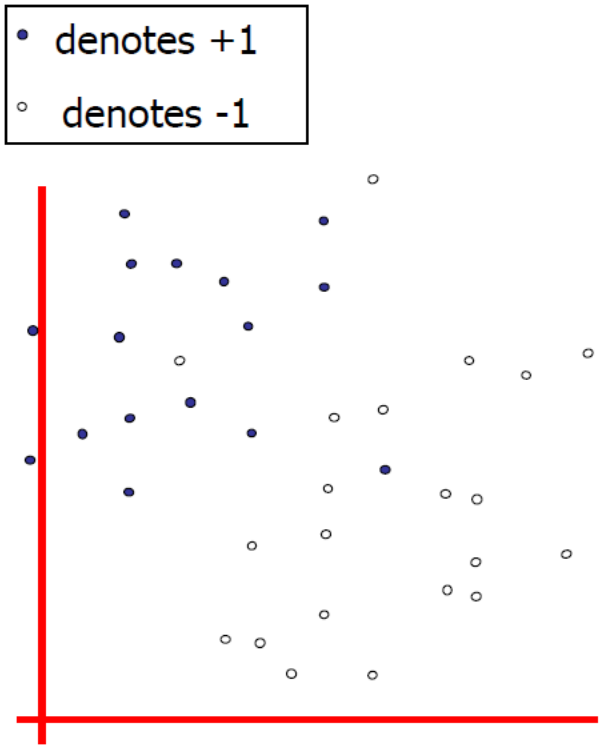
- עבור המקרה הלינארי – maximize margin *(Hard Margin)*
- עבור המקרה הלא-לינארי
  - מדד "ענישה" עבור טעויות *(Soft Margin)*
  - "מיפוי" הנקודות למימד גבוה יותר בו קיימת הפרדה לינארית

מה קורה כאשר אין הפרדה לינארית

Uh-oh!

This is going to be a problem!

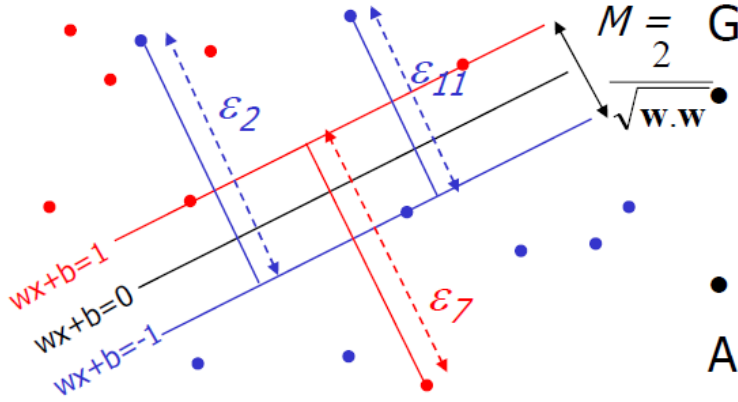
What should we do?



הרעיון: נרשה שנקודות מסויימות
יהיו בחריגה מהשוליים שנקבעו,
אבל "נעניש" על כל טעות

http://www.cs.cmu.edu/~awm/tutorials

מקסימום "מרווח" +"רעש"



Given guess of $\mathbf{w}$, b we can

- Compute sum of distances of points to their correct zones
- Compute the margin width

Assume R datapoints, each $(\mathbf{x}_k, y_k)$ where $y_k = +/- 1$

What should our quadratic optimization criterion be?

Minimize $$\frac{1}{2}\mathbf{w}.\mathbf{w} + C\sum_{k=1}^{R}\varepsilon_k$$

$\mathbf{w} . \mathbf{x}_k + b >= 1-\varepsilon_k$ if $y_k = 1$

$\mathbf{w} . \mathbf{x}_k + b <= -1+\varepsilon_k$ if $y_k = -1$

$\varepsilon_k >= 0$ for all k

http://www.cs.cmu.edu/~awm/tutorials

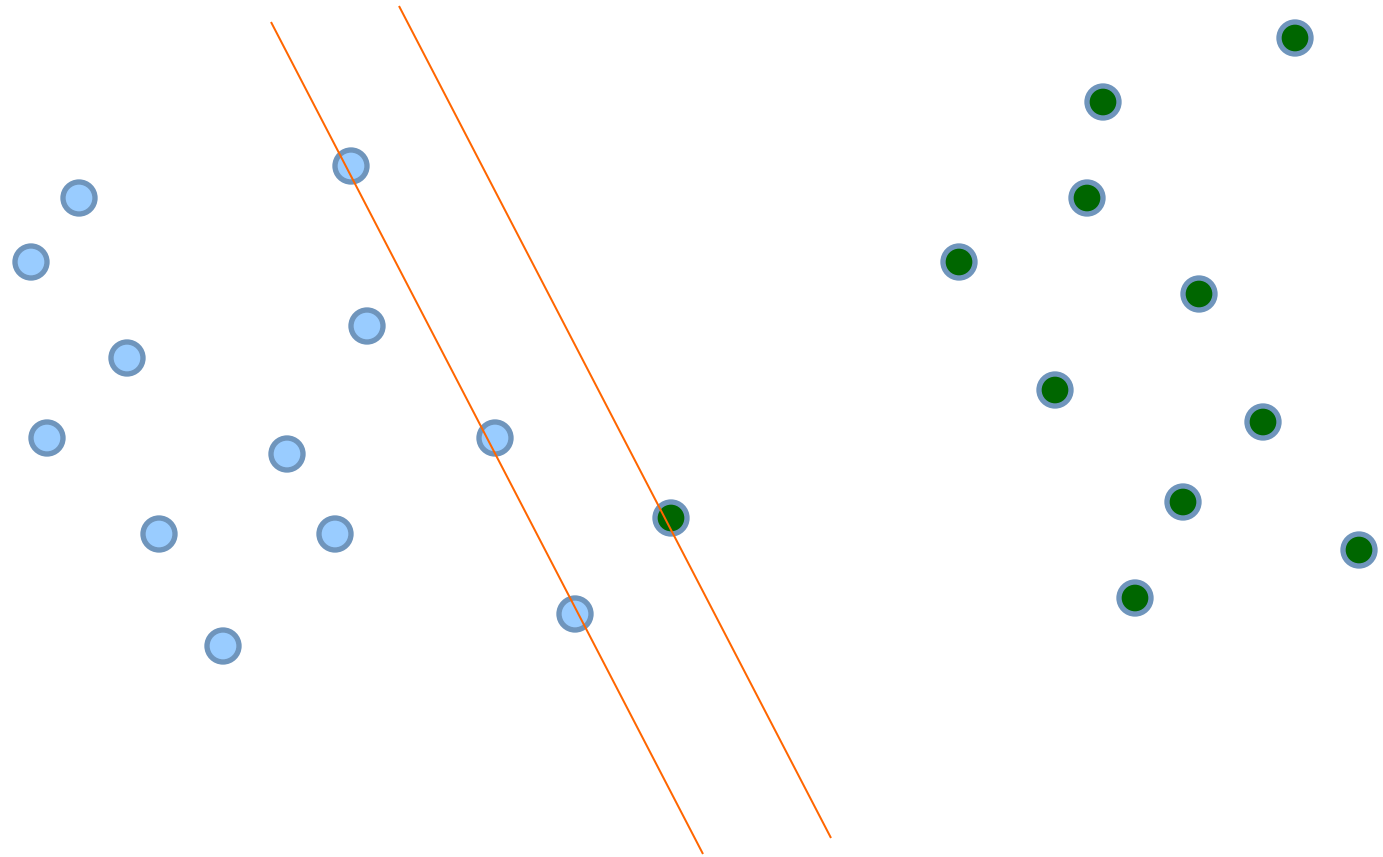
Minimize $\frac{1}{2} w \cdot w + C \sum_{k=1}^{R} \varepsilon_k$

$y_i (w \cdot x_i + b) \geq 1 - \xi_i, \ \forall x_i$

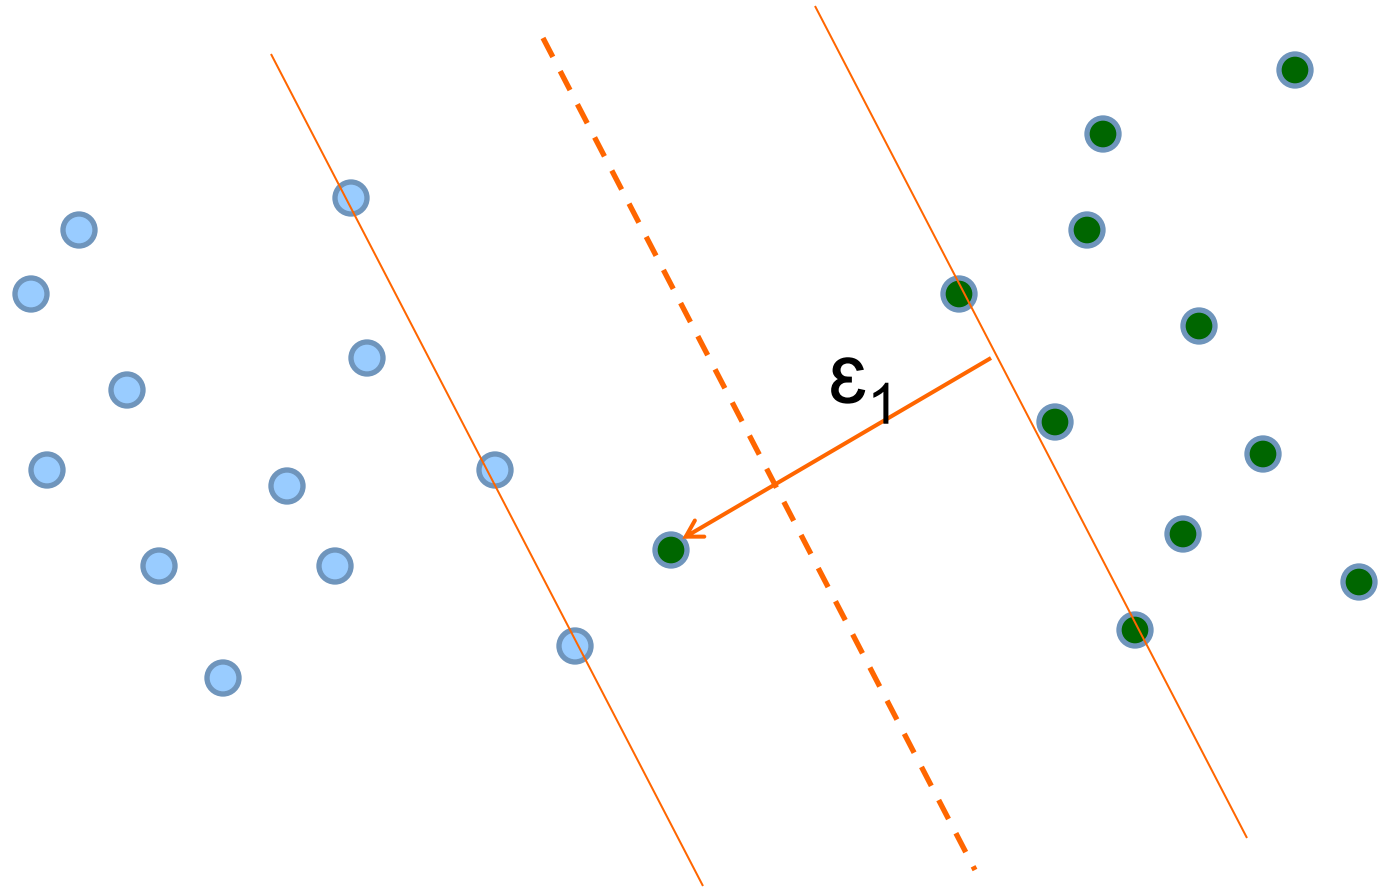
$\xi_i \geq 0$

- The algorithm does not minimize the number of misclassifications but the sum of distances from the hyperplanes
- ככל ש-C גדל (בפרט עבור C שואף לאין-סוף) אנו מתקרבים ל-Hard Margin

Hard Margin



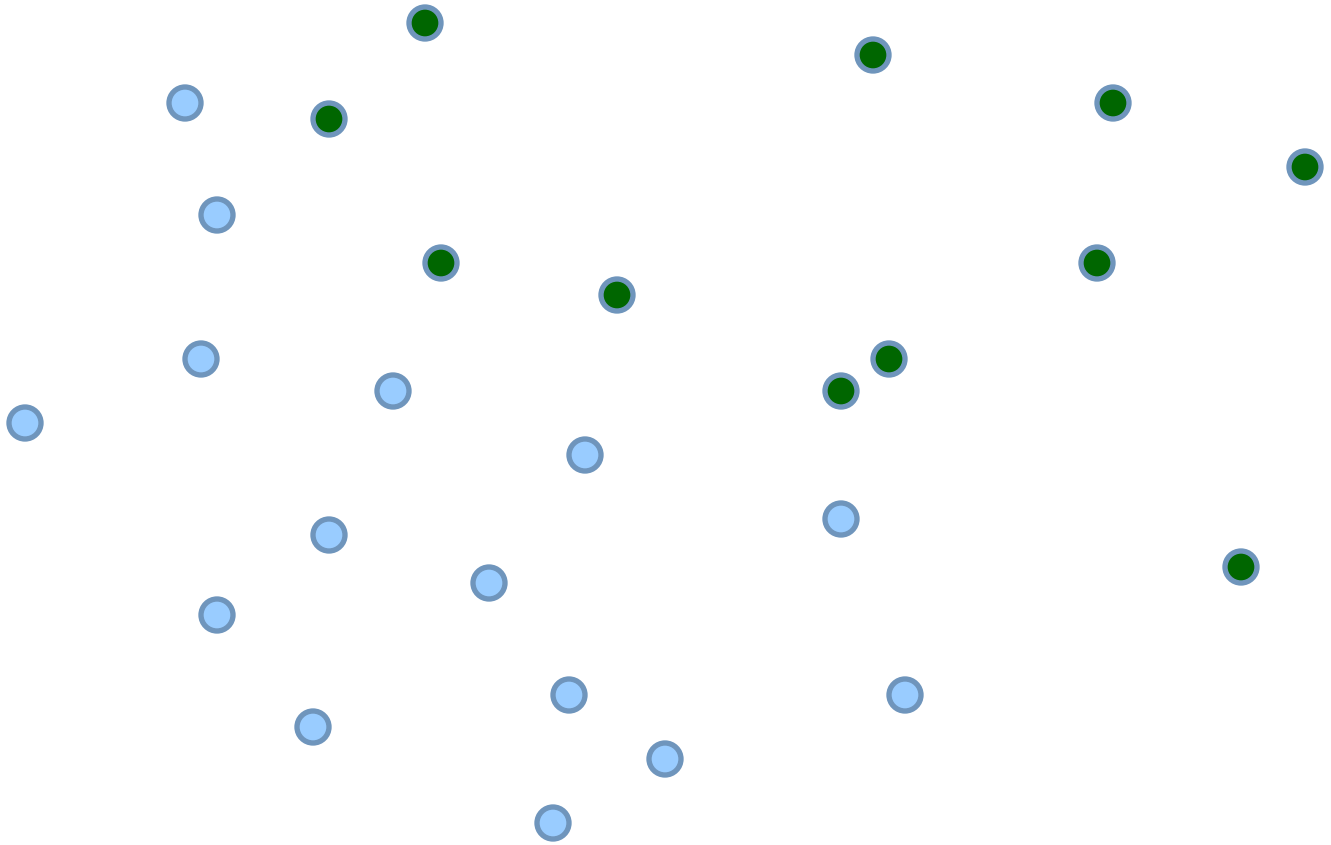
Soft Margin



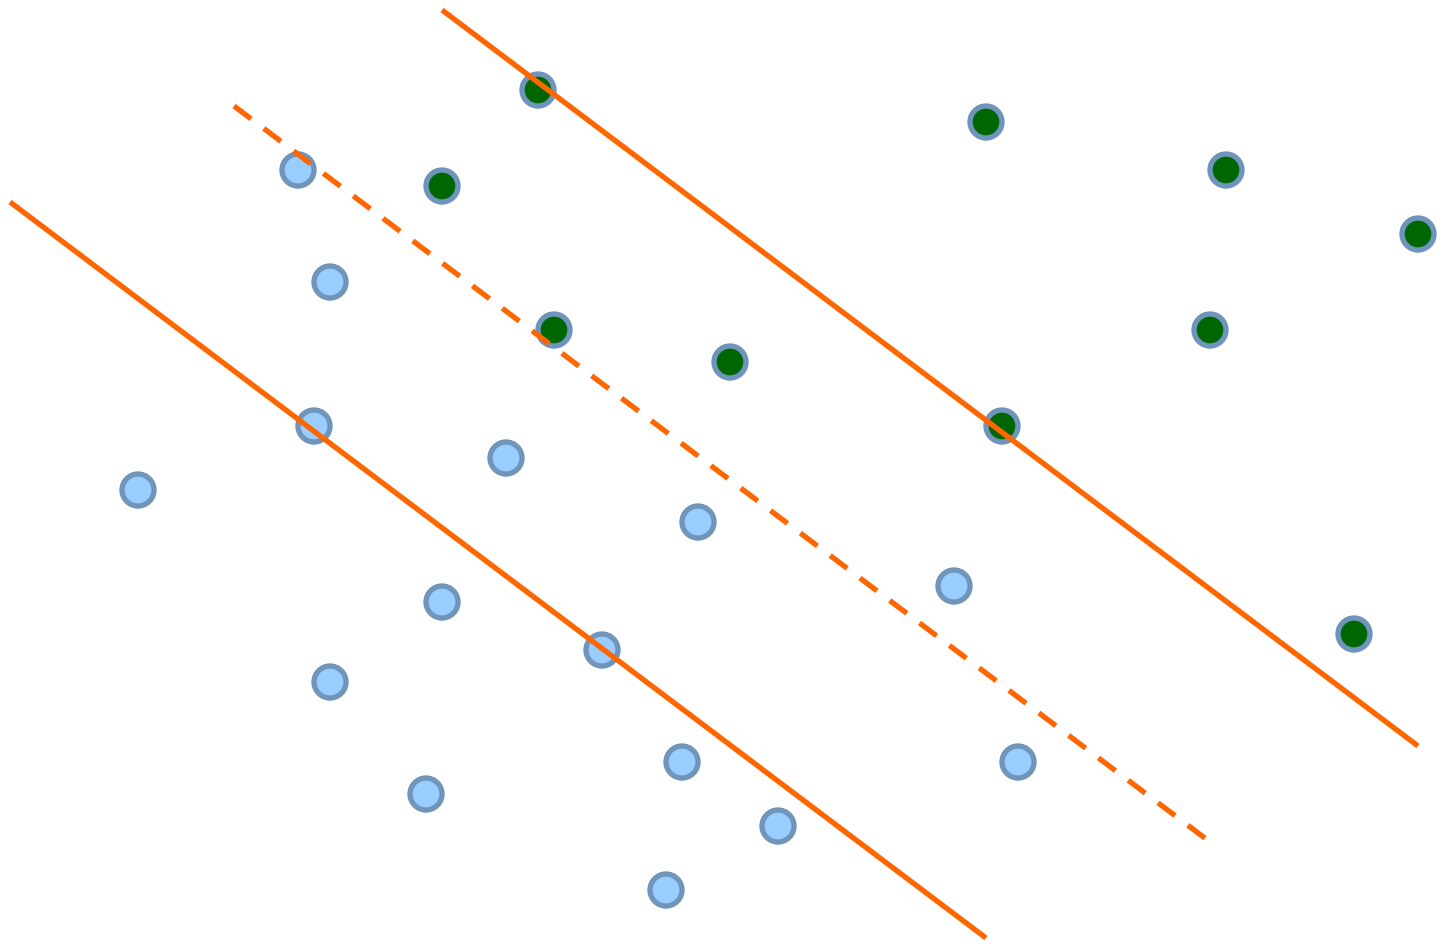
Soft Margin

- יתרונות:
  - תמיד יש פתרון (גם כשאין הפרדה לינארית)
  - עמידות בפני outliers
- חסרונות:
  - צריך לקבוע את C

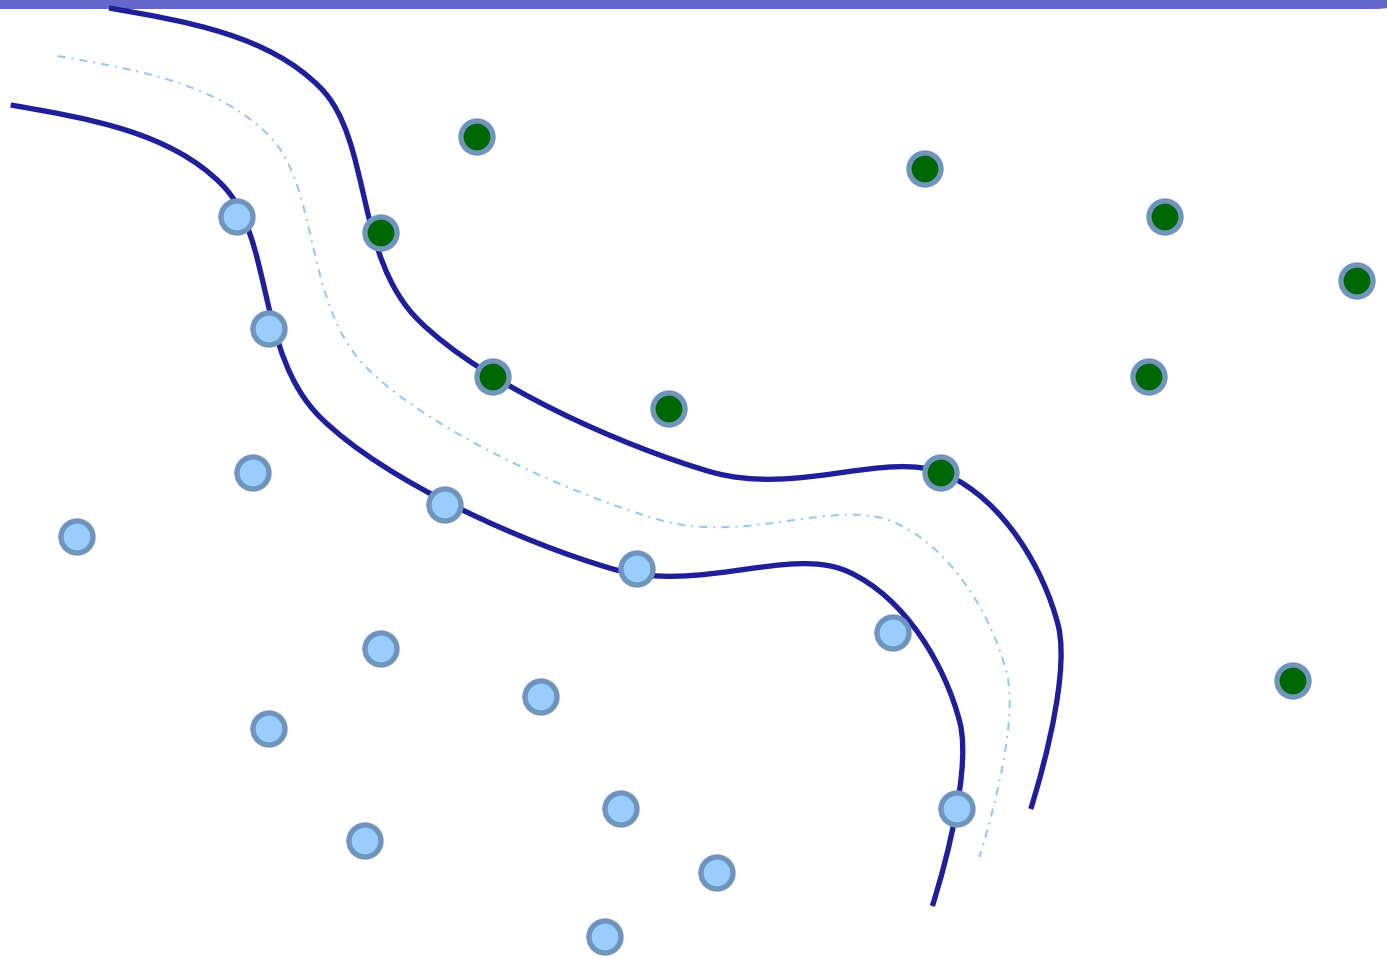
Non-Linear Problem



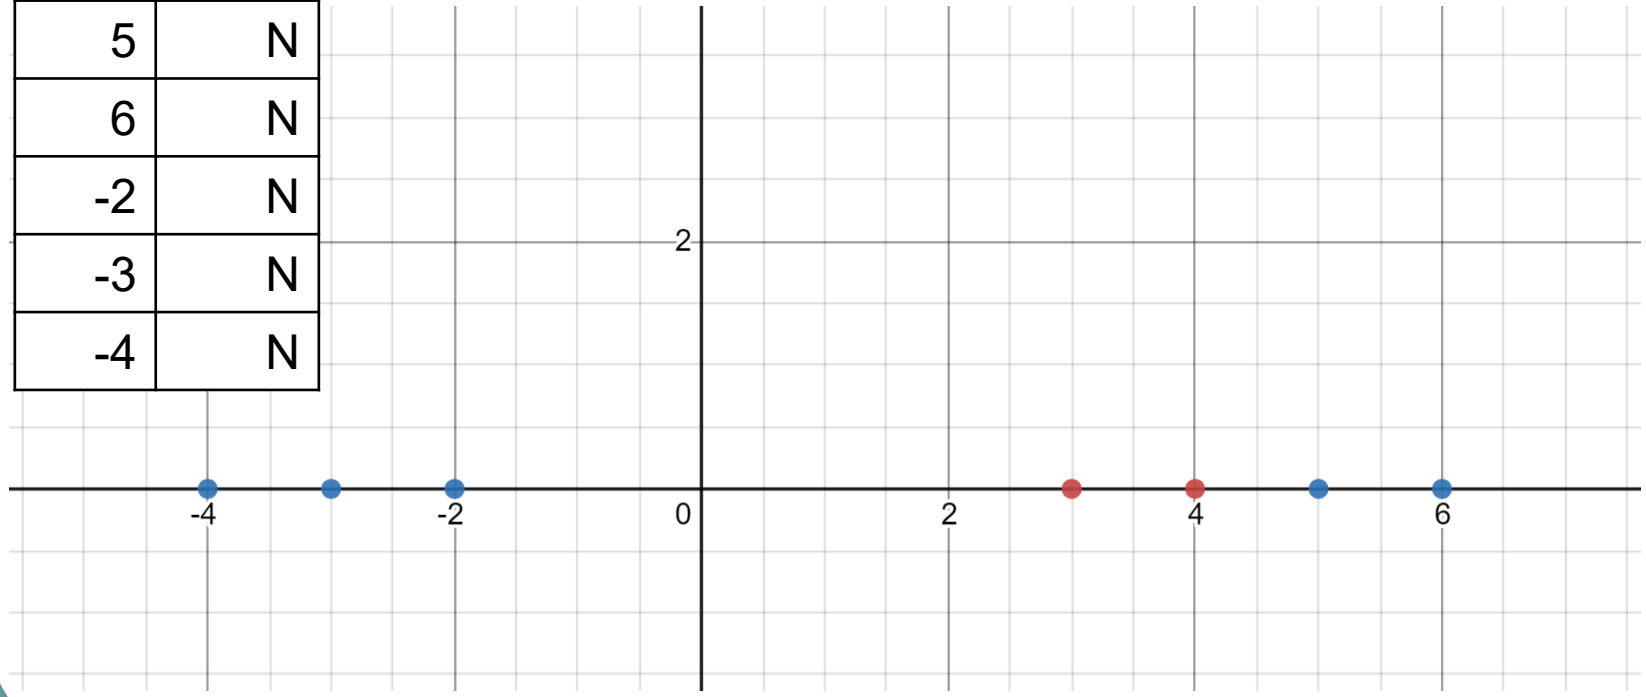
Soft Margin



פתרון ע"י "על-מישור" לא לינארי

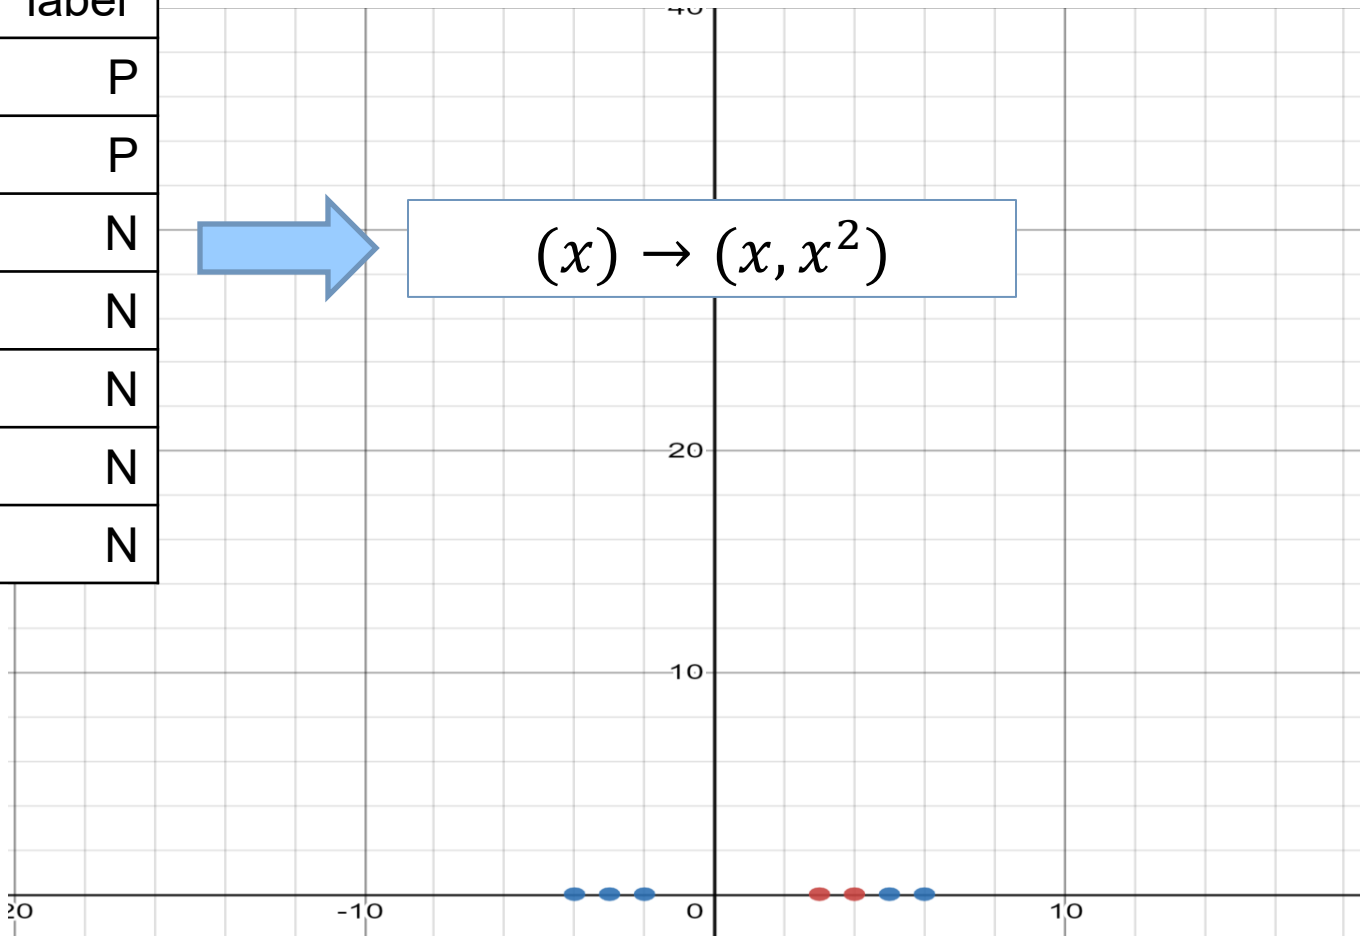


x	label
3	P
4	P
5	N
6	N
-2	N
-3	N
-4	N

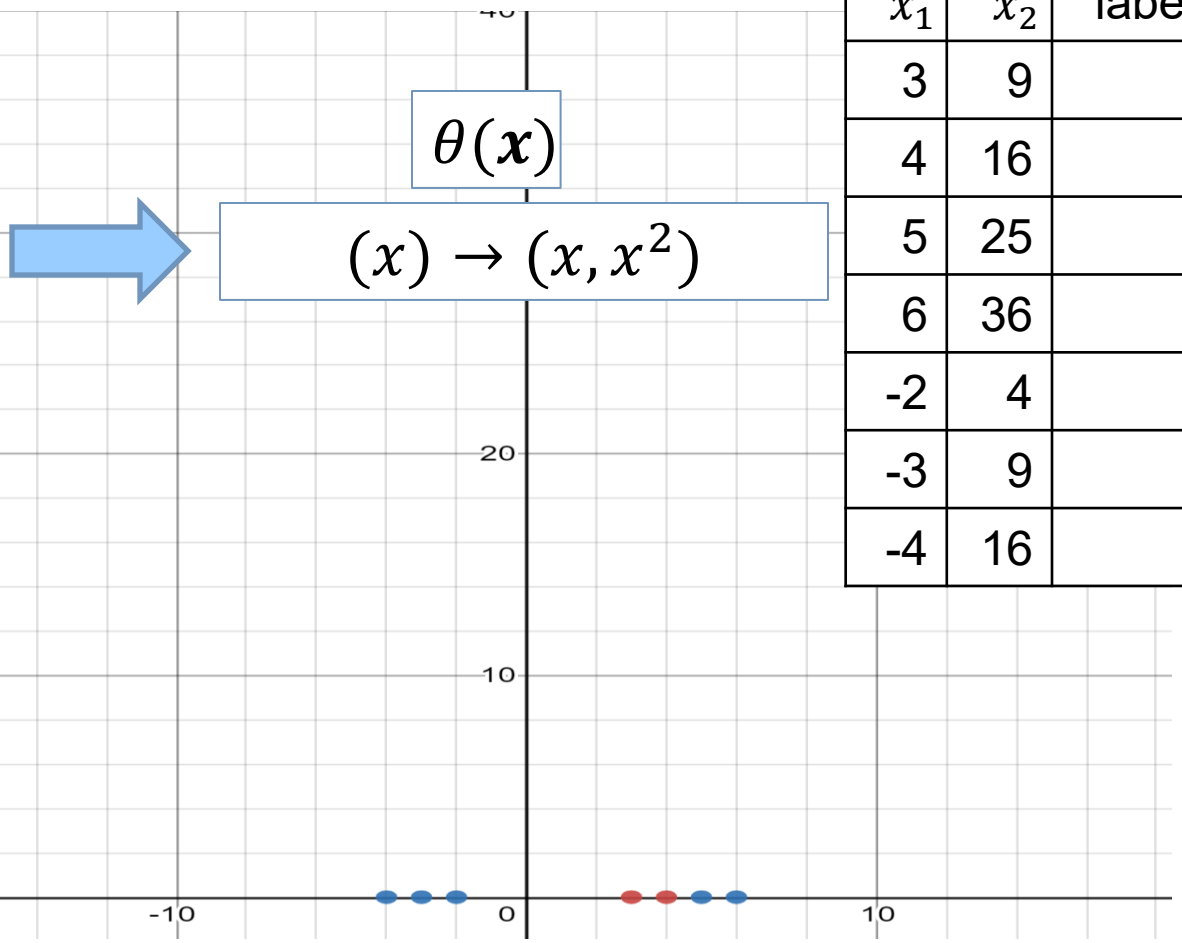


x	label
3	P
4	P
5	N
6	N
-2	N
-3	N
-4	N

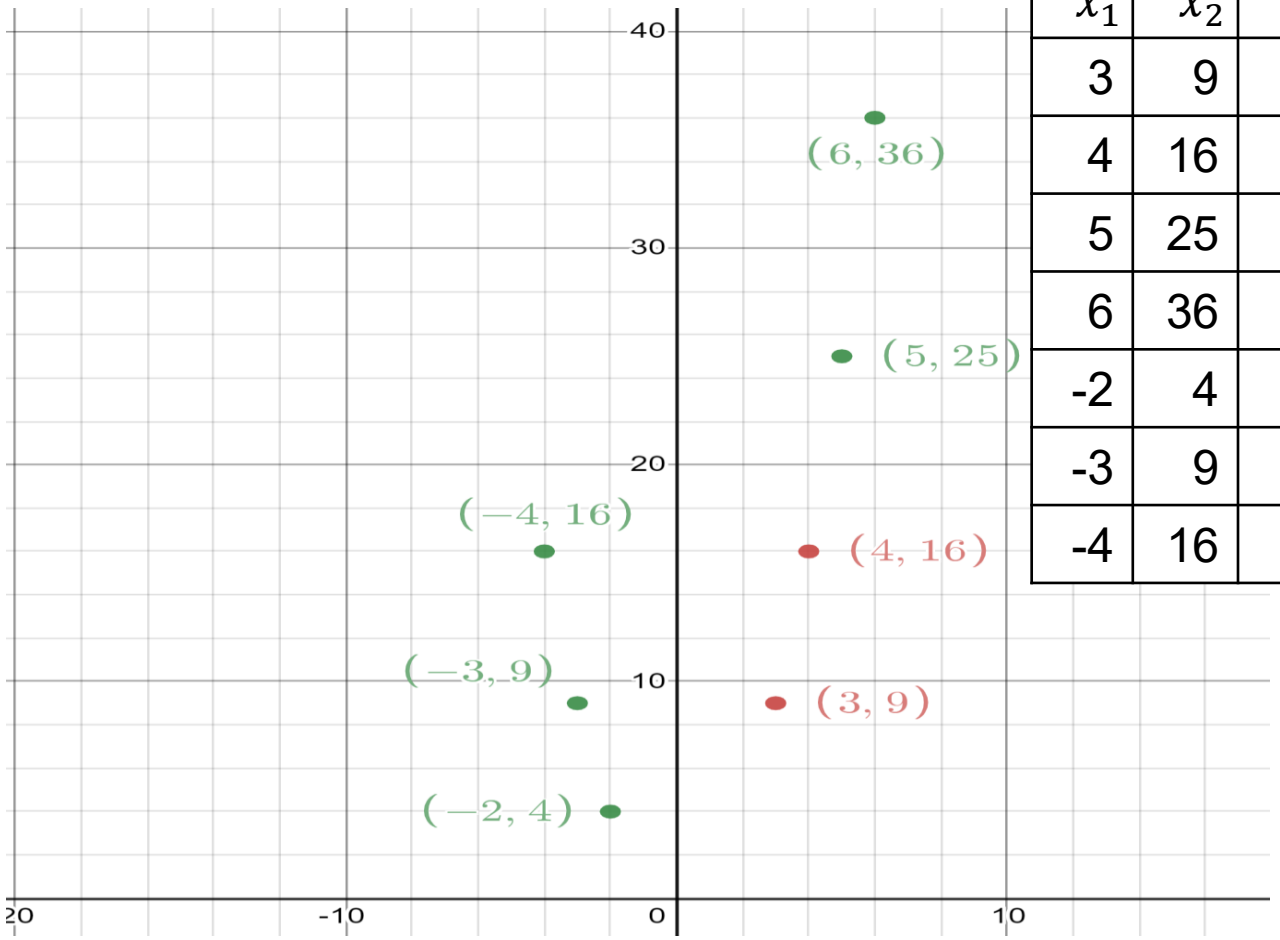
$$(x) \rightarrow (x, x^2)$$



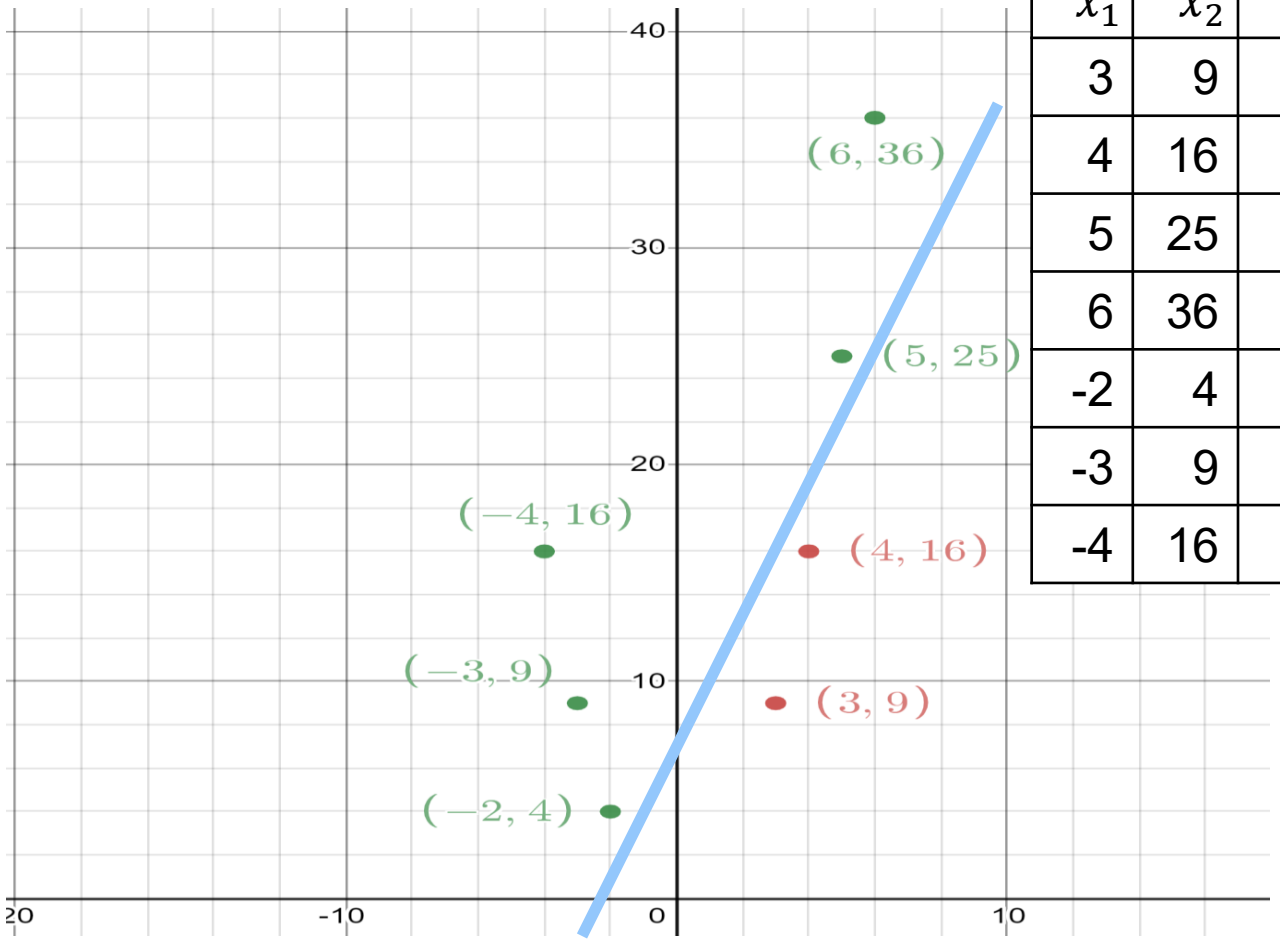
x	label
3	P
4	P
5	N
6	N
-2	N
-3	N
-4	N



x_1	x_2	label
3	9	P
4	16	P
5	25	N
6	36	N
-2	4	N
-3	9	N
-4	16	N



x_1	x_2	label
3	9	P
4	16	P
5	25	N
6	36	N
-2	4	N
-3	9	N
-4	16	N



x_1	x_2	label
3	9	P
4	16	P
5	25	N
6	36	N
-2	4	N
-3	9	N
-4	16	N

QP with basis functions

Warning: up until Rong Zhang spotted my error in Oct 2003, this equation had been wrong in earlier versions of the notes. This version is correct.

Maximize $\sum_{k=1}^{R} \alpha_k - \frac{1}{2} \sum_{k=1}^{R} \sum_{l=1}^{R} \alpha_k \alpha_l Q_{kl}$ where $Q_{kl} = y_k y_l (\boldsymbol{\Phi}(\mathbf{x}_k).\boldsymbol{\Phi}(\mathbf{x}_l))$

Subject to these constraints: $0 \le \alpha_k \le C \quad \forall k$ $\qquad \sum_{k=1}^{R} \alpha_k y_k = 0$

Then define:

$$\mathbf{w} = \sum_{k \text{ s.t. } \alpha_k > 0} \alpha_k y_k \boldsymbol{\Phi}(\mathbf{x}_k)$$

$$b = y_K (1 - \varepsilon_K) - \mathbf{x}_K . \mathbf{w}_K$$

where $K = \arg \max_k \alpha_k$

Then classify with:

$f(\mathbf{x}, \mathbf{w}, b) = sign(\mathbf{w}. \phi(\mathbf{x}) - b)$

$$(x_1, x_2) \xrightarrow{\Phi} \{1, \sqrt{2}x_1, \sqrt{2}x_2, x_1^2, \sqrt{2}x_1x_2, x_2^2\}$$

$$(x_1, x_2) \xrightarrow{\Phi} \{1, \sqrt{2}x_1, \sqrt{2}x_2, x_1^2, \sqrt{2}x_1x_2, x_2^2\}$$

$\boldsymbol{x}$: $(\mathbf{1}, \mathbf{8})$

$\boldsymbol{y}$: $(\mathbf{1}, \mathbf{2})$

$$\boldsymbol{\Phi(x) \cdot \Phi(y) = ?}$$

$$(x_1, x_2) \xrightarrow{\Phi} \{1, \sqrt{2}x_1, \sqrt{2}x_2, x_1^2, \sqrt{2}x_1x_2, x_2^2\}$$

$\boldsymbol{x}$: $\boldsymbol{(1, 8)}$ $\rightarrow \boldsymbol{\Phi(x)}$: $\boldsymbol{\{1, \sqrt{2}, 8\sqrt{2}, 1, 8\sqrt{2}, 64\}}$

$\boldsymbol{y}$: $\boldsymbol{(1, 2)}$ $\rightarrow \boldsymbol{\Phi(y)}$: $\boldsymbol{\{1, \sqrt{2}, 2\sqrt{2}, 1, 2\sqrt{2}, 4\}}$

$$\boldsymbol{\Phi(x) \cdot \Phi(y) = ?}$$

$$(x_1, x_2) \xrightarrow{\Phi} \{1, \sqrt{2}x_1, \sqrt{2}x_2, x_1^2, \sqrt{2}x_1x_2, x_2^2\}$$

$\boldsymbol{x}$: $\boldsymbol{(1, 8)}$ $\rightarrow \boldsymbol{\Phi(x)}$: $\boldsymbol{\{1, \sqrt{2}, 8\sqrt{2}, 1, 8\sqrt{2}, 64\}}$

$\boldsymbol{y}$: $\boldsymbol{(1, 2)}$ $\rightarrow \boldsymbol{\Phi(y)}$: $\boldsymbol{\{1, \sqrt{2}, 2\sqrt{2}, 1, 2\sqrt{2}, 4\}}$

$\boldsymbol{\Phi(x) \cdot \Phi(y) = ?}$

$$\Phi(x)^T \cdot \Phi(y) = \begin{bmatrix} 1 \\ \sqrt{2} \\ 8\sqrt{2} \\ 1 \\ 8\sqrt{2} \\ 64 \end{bmatrix} \begin{bmatrix} 1 \\ \sqrt{2} \\ 2\sqrt{2} \\ 1 \\ 2\sqrt{2} \\ 4 \end{bmatrix} = 1 \times 1 + \sqrt{2} \times \sqrt{2} + 8\sqrt{2} \times 2\sqrt{2} + 1 \times 1 + 8\sqrt{2} \times 8\sqrt{2} + 64 \times 4 =$$

$$= 324$$

Quadratic Basis Functions

$$\Phi(\mathbf{x}) = \begin{pmatrix} 1 \\ \sqrt{2}x_1 \\ \sqrt{2}x_2 \\ \vdots \\ \sqrt{2}x_m \\ x_1^2 \\ x_2^2 \\ \vdots \\ x_m^2 \\ \sqrt{2}x_1x_2 \\ \sqrt{2}x_1x_3 \\ \vdots \\ \sqrt{2}x_1x_m \\ \sqrt{2}x_2x_3 \\ \vdots \\ \sqrt{2}x_1x_m \\ \vdots \\ \sqrt{2}x_{m-1}x_m \end{pmatrix}$$

Constant Term

Linear Terms

Pure Quadratic Terms

Quadratic Cross-Terms

Number of terms (assuming m input dimensions)

= (m+2)(m+1)/2

= (as near as makes no difference) $m^2/2$

You may be wondering what those $\sqrt{2}$'s are doing.

- You should be happy that they do no harm
- You'll find out why they're there soon.

Quadratic Dot Products

$$\Phi(\mathbf{a}) \bullet \Phi(\mathbf{b}) = \begin{pmatrix} 1 \\ \sqrt{2}a_1 \\ \sqrt{2}a_2 \\ \vdots \\ \sqrt{2}a_m \\ a_1^2 \\ a_2^2 \\ \vdots \\ a_m^2 \\ \sqrt{2}a_1a_2 \\ \sqrt{2}a_1a_3 \\ \vdots \\ \sqrt{2}a_1a_m \\ \sqrt{2}a_2a_3 \\ \vdots \\ \sqrt{2}a_1a_m \\ \vdots \\ \sqrt{2}a_{m-1}a_m \end{pmatrix} \bullet \begin{pmatrix} 1 \\ \sqrt{2}b_1 \\ \sqrt{2}b_2 \\ \vdots \\ \sqrt{2}b_m \\ b_1^2 \\ b_2^2 \\ \vdots \\ b_m^2 \\ \sqrt{2}b_1b_2 \\ \sqrt{2}b_1b_3 \\ \vdots \\ \sqrt{2}b_1b_m \\ \sqrt{2}b_2b_3 \\ \vdots \\ \sqrt{2}b_1b_m \\ \vdots \\ \sqrt{2}b_{m-1}b_m \end{pmatrix} = 1 + \sum_{i=1}^{m} 2a_ib_i + \sum_{i=1}^{m} a_i^2b_i^2 + \sum_{i=1}^{m}\sum_{j=i+1}^{m} 2a_ia_jb_ib_j$$

http://www.cs.cmu.edu/~awm/tutorials

Quadratic Dot Products

$$\Phi(\mathbf{a}) \bullet \Phi(\mathbf{b}) = 1 + 2\sum_{i=1}^{m} a_i b_i + \sum_{i=1}^{m} a_i^2 b_i^2 + \sum_{i=1}^{m} \sum_{j=i+1}^{m} 2 a_i a_j b_i b_j$$

Just out of casual, innocent, interest, let's look at another function of ***a*** and ***b***:

$$(\mathbf{a}.\mathbf{b}+1)^2$$

$$= (\mathbf{a}.\mathbf{b})^2 + 2\mathbf{a}.\mathbf{b} + 1$$

$$= \left(\sum_{i=1}^{m} a_i b_i\right)^2 + 2\sum_{i=1}^{m} a_i b_i + 1$$

$$= \sum_{i=1}^{m} \sum_{j=1}^{m} a_i b_i a_j b_j + 2\sum_{i=1}^{m} a_i b_i + 1$$

$$= \sum_{i=1}^{m} (a_i b_i)^2 + 2\sum_{i=1}^{m} \sum_{j=i+1}^{m} a_i b_i a_j b_j + 2\sum_{i=1}^{m} a_i b_i + 1$$

Quadratic Dot Products

$$\Phi(\mathbf{a}) \bullet \Phi(\mathbf{b}) = 1 + 2\sum_{i=1}^{m} a_i b_i + \sum_{i=1}^{m} a_i^2 b_i^2 + \sum_{i=1}^{m} \sum_{j=i+1}^{m} 2 a_i a_j b_i b_j$$

Just out of casual, innocent, interest, let's look at another function of ***a*** and ***b***:

$$(\mathbf{a}.\mathbf{b}+1)^2$$

$$= (\mathbf{a}.\mathbf{b})^2 + 2\mathbf{a}.\mathbf{b} + 1$$

$$= \left(\sum_{i=1}^{m} a_i b_i\right)^2 + 2\sum_{i=1}^{m} a_i b_i + 1$$

$$= \sum_{i=1}^{m} \sum_{j=1}^{m} a_i b_i a_j b_j + 2\sum_{i=1}^{m} a_i b_i + 1$$

$$= \sum_{i=1}^{m} (a_i b_i)^2 + 2\sum_{i=1}^{m} \sum_{j=i+1}^{m} a_i b_i a_j b_j + 2\sum_{i=1}^{m} a_i b_i + 1$$

They're the same!

And this is only O(m) to compute!

The Kernel Trick

- לכאורה, אנחנו צריכים למפות את x_i ל - $\phi(x_i)$ ואת x_j ל - $\phi(x_j)$ ואז לחשב במימד הגבוה את המכפלה ביניהם.
- אבל, בגלל שמצאנו פונקציות עבורם מתקיים: $K(x_i \cdot x_j) = \Phi(x_i) \cdot \Phi(x_j)$, אנו לא צריכים את ה"מיפוי" במפורש

$$(x_1, x_2) \xrightarrow{\Phi} \{1, \sqrt{2}x_1, \sqrt{2}x_2, x_1^2, \sqrt{2}x_1x_2, x_2^2\}$$

x: $(1,8) \quad \rightarrow \Phi(x)$: $\{1, \sqrt{2}, 8\sqrt{2}, 1, 8\sqrt{2}, 64\}$

y: $(1,2) \quad \rightarrow \Phi(y)$: $\{1, \sqrt{2}, 2\sqrt{2}, 1, 2\sqrt{2}, 4\}$

$$\Phi(x) \cdot \Phi(y) = ?$$

$$\Phi(x)^T \cdot \Phi(y) = \begin{bmatrix} 1 \\ \sqrt{2} \\ 8\sqrt{2} \\ 1 \\ 8\sqrt{2} \\ 64 \end{bmatrix} \begin{bmatrix} 1 \\ \sqrt{2} \\ 2\sqrt{2} \\ 1 \\ 2\sqrt{2} \\ 4 \end{bmatrix} = 1 \times 1 + \sqrt{2} \times \sqrt{2} + 8\sqrt{2} \times 2\sqrt{2} + 1 \times 1 + 8\sqrt{2} \times 8\sqrt{2} + 64 \times 4 =$$

$$= 324$$

$$\Phi(x)^T \cdot \Phi(y) = (x \cdot y + 1)^2 = [(1,8)^T \times (1,2) + 1)]^2 = (1 \times 1 + 8 \times 2 + 1)^2 = 324$$

The Kernel Trick

- To classify a new vector x_j

The Kernel Trick

- To classify a new vector $x_j \rightarrow \theta(x_j)$

The Kernel Trick

- To classify a new vector $x_j \rightarrow \theta(x_j)$
- $w = \sum \propto_i y_i \theta(x_i)$

The Kernel Trick

- To classify a new vector $x_j \rightarrow \theta(x_j)$
- $w = \sum \propto_i y_i \theta(x_i)$

$$SGN(wx - b) = SGN(\underbrace{\sum \propto_i y_i \theta(x_i)}_{w} \times \theta(x_j) - b)$$

The Kernel Trick

- To classify a new vector $x_j \rightarrow \theta(x_j)$
- $w = \sum \propto_i y_i \theta(x_i)$

$$SGN(wx - b) = SGN(\underbrace{\sum \propto_i y_i \theta(x_i)}_{w} \times \theta(x_j) - b)$$

$$= SGN(\sum \propto_i y_i \underbrace{\theta(x_i)\ \theta(x_j)}_{K(x_i, x_j)} - b)$$

The Kernel Trick

- To classify a new vector $x_j \rightarrow \theta(x_j)$
- $w = \sum \propto_i y_i \theta(x_i)$

$$SGN(wx - b) = SGN(\underbrace{\sum \propto_i y_i \theta(x_i)}_{w} \times \theta(x_j) - b)$$

$$= SGN(\sum \propto_i y_i \underbrace{\theta(x_i)\ \theta(x_j)}_{K(x_i, x_j)} - b)$$

$$\mathbf{sgn}\left(\sum_i \boldsymbol{\alpha_i y_i K(x_i, x) + b}\right)$$

מימושים ברשת

- LIBSVM -- A Library for Support Vector Machines

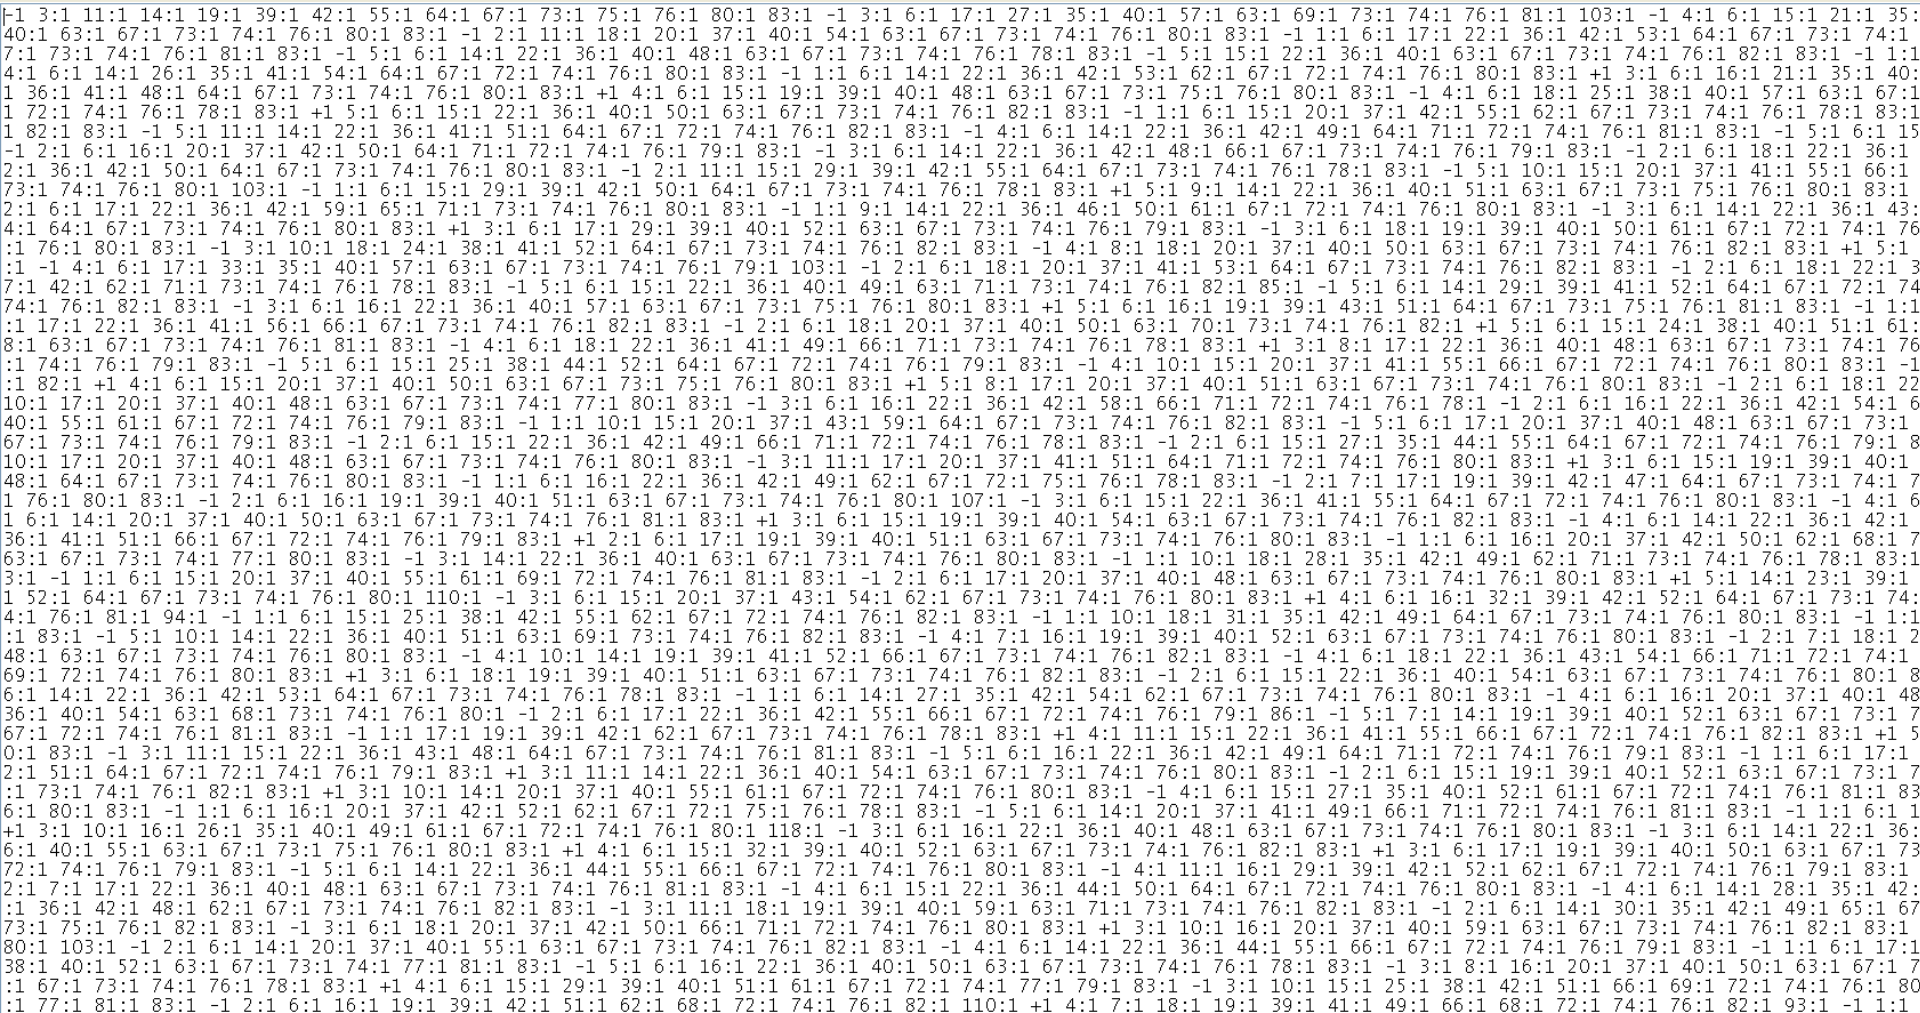
http://www.csie.ntu.edu.tw/~cjlin/libsvm/

DEMO

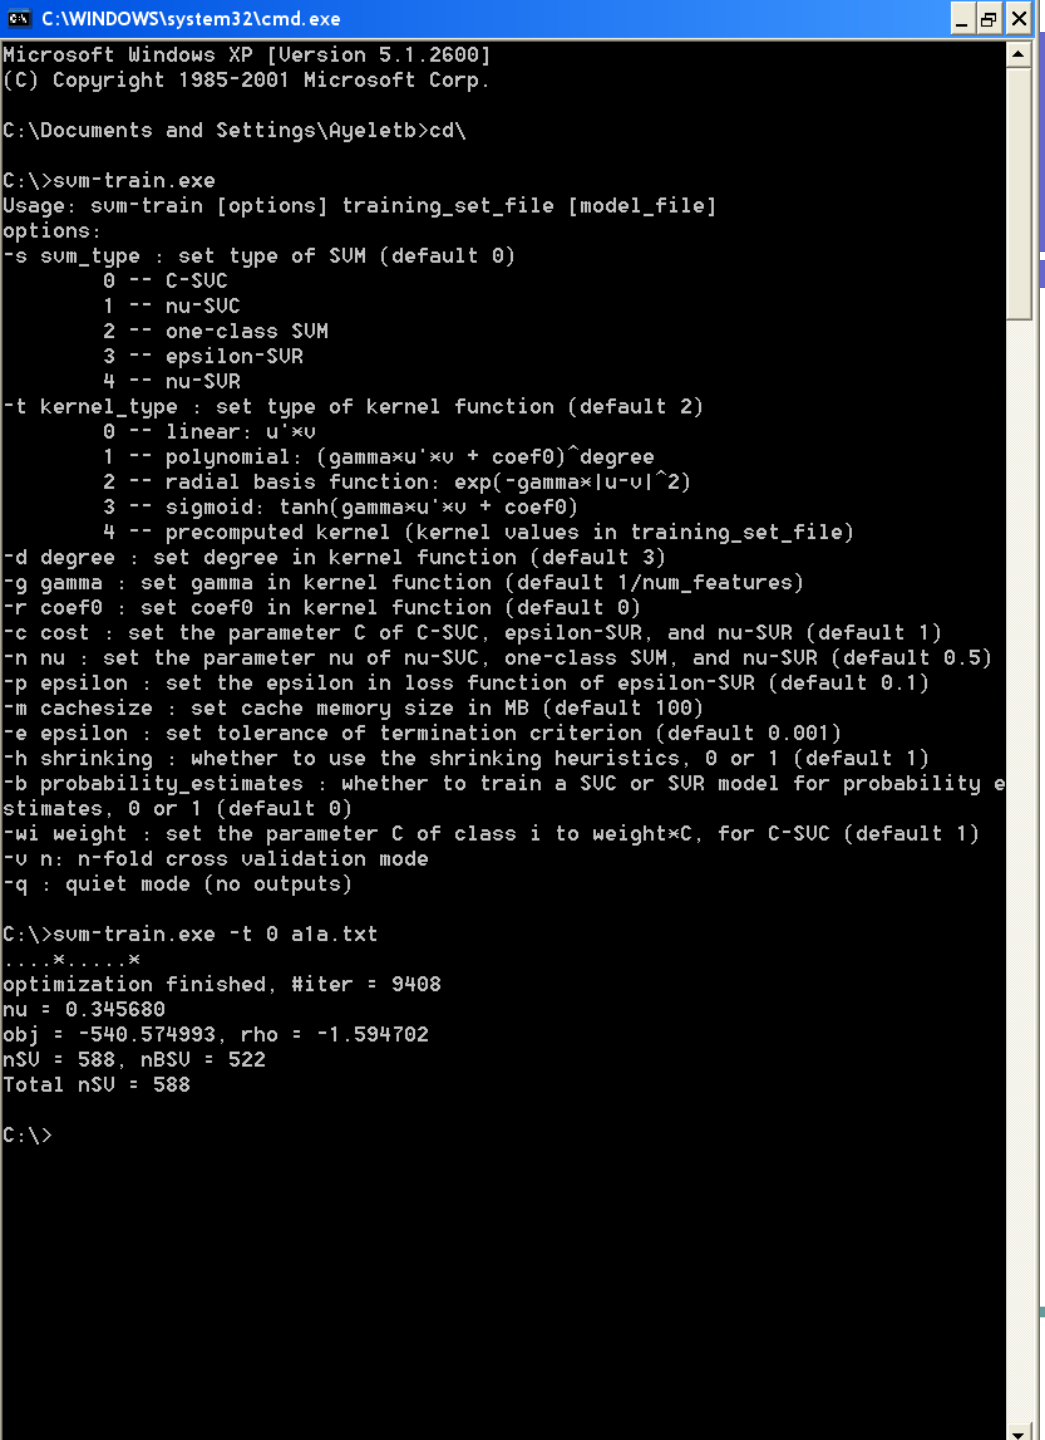
LIBSVM – Train File

a1a.txt - Notepad

File Edit Format View Help



LIBSVM


C:\WINDOWS\system32\cmd.exe
Microsoft Windows XP [Version 5.1.2600]
(C) Copyright 1985-2001 Microsoft Corp.
C:\Documents and Settings\Ayeletb>cd\
C:\>svm-train.exe
Usage: svm-train [options] training_set_file [model_file]
options:
-s svm_type : set type of SVM (default 0)
0 -- C-SVC
1 -- nu-SVC
2 -- one-class SVM
3 -- epsilon-SVR
4 -- nu-SVR
-t kernel_type : set type of kernel function (default 2)
0 -- linear: u'*v
1 -- polynomial: (gamma*u'*v + coef0)^degree
2 -- radial basis function: exp(-gamma*|u-v|^2)
3 -- sigmoid: tanh(gamma*u'*v + coef0)
4 -- precomputed kernel (kernel values in training_set_file)
-d degree : set degree in kernel function (default 3)
-g gamma : set gamma in kernel function (default 1/num_features)
-r coef0 : set coef0 in kernel function (default 0)
-c cost : set the parameter C of C-SVC, epsilon-SVR, and nu-SVR (default 1)
-n nu : set the parameter nu of nu-SVC, one-class SVM, and nu-SVR (default 0.5)
-p epsilon : set the epsilon in loss function of epsilon-SVR (default 0.1)
-m cachesize : set cache memory size in MB (default 100)
-e epsilon : set tolerance of termination criterion (default 0.001)
-h shrinking : whether to use the shrinking heuristics, 0 or 1 (default 1)
-b probability_estimates : whether to train a SVC or SVR model for probability e
stimates, 0 or 1 (default 0)
-wi weight : set the parameter C of class i to weight*C, for C-SVC (default 1)
-v n: n-fold cross validation mode
-q : quiet mode (no outputs)
C:\>svm-train.exe -t 0 a1a.txt
....*.....*
optimization finished, #iter = 9408
nu = 0.345680
obj = -540.574993, rho = -1.594702
nSV = 588, nBSV = 522
Total nSV = 588
C:\>

LIBSVM – Model File

a1a.txt.model - Notepad

File Edit Format View Help

```
svm_type c_svc
kernel_type linear
nr_class 2
total_sv 588
rho -1.5947
label -1 1
nr_sv 302 286
SV
0.9590556668124504 3:1 11:1 14:1 19:1 39:1 42:1 55:1 64:1 67:1 73:1 75:1 76:1 80:1 83:1
1 4:1 6:1 15:1 21:1 35:1 40:1 57:1 63:1 67:1 73:1 74:1 77:1 80:1 83:1
1 2:1 6:1 16:1 22:1 36:1 40:1 54:1 63:1 67:1 73:1 75:1 76:1 80:1 83:1
1 5:1 6:1 15:1 20:1 37:1 40:1 50:1 63:1 67:1 73:1 75:1 76:1 80:1 83:1
1 5:1 7:1 16:1 29:1 39:1 40:1 48:1 63:1 67:1 73:1 74:1 76:1 78:1 83:1
1 2:1 6:1 15:1 19:1 39:1 40:1 52:1 63:1 67:1 73:1 74:1 76:1 82:1 83:1
1 5:1 8:1 14:1 19:1 39:1 40:1 50:1 63:1 67:1 73:1 74:1 76:1 82:1 83:1
0.9785296393558168 2:1 6:1 14:1 20:1 37:1 40:1 48:1 63:1 67:1 73:1 74:1 76:1 81:1 83:1
1 5:1 15:1 22:1 36:1 40:1 63:1 67:1 73:1 74:1 76:1 82:1 83:1
1 2:1 6:1 16:1 25:1 38:1 40:1 55:1 63:1 67:1 73:1 74:1 77:1 81:1 83:1
1 5:1 7:1 14:1 22:1 36:1 40:1 56:1 63:1 67:1 73:1 74:1 77:1 82:1 83:1
1 1:1 6:1 17:1 20:1 37:1 42:1 51:1 64:1 67:1 72:1 75:1 76:1 80:1 83:1
1 3:1 6:1 16:1 29:1 39:1 40:1 52:1 63:1 67:1 73:1 74:1 76:1 78:1 83:1
1 5:1 6:1 15:1 22:1 36:1 40:1 54:1 63:1 67:1 73:1 75:1 76:1 80:1 83:1
0.4028167025995462 2:1 6:1 15:1 19:1 39:1 42:1 50:1 64:1 71:1 72:1 74:1 77:1 80:1 83:1
1 4:1 6:1 18:1 25:1 38:1 40:1 57:1 63:1 67:1 73:1 74:1 76:1 82:1 83:1
1 4:1 6:1 17:1 22:1 36:1 40:1 57:1 63:1 67:1 73:1 74:1 76:1 82:1 83:1
1 5:1 7:1 17:1 20:1 37:1 40:1 50:1 63:1 67:1 73:1 74:1 76:1 82:1 83:1
1 5:1 6:1 18:1 22:1 36:1 40:1 48:1 63:1 67:1 73:1 74:1 76:1 82:1 83:1
1 4:1 6:1 16:1 22:1 36:1 40:1 48:1 63:1 67:1 73:1 74:1 76:1 80:1 83:1
1 5:1 6:1 14:1 20:1 37:1 40:1 48:1 63:1 67:1 73:1 74:1 76:1 80:1 83:1
1 4:1 7:1 16:1 20:1 37:1 40:1 56:1 63:1 67:1 73:1 74:1 76:1 82:1 83:1
1 3:1 11:1 14:1 20:1 37:1 40:1 51:1 63:1 67:1 73:1 74:1 76:1 80:1 83:1
1 3:1 6:1 14:1 20:1 37:1 40:1 48:1 63:1 67:1 73:1 74:1 77:1 81:1 83:1
1 4:1 10:1 15:1 29:1 39:1 41:1 52:1 64:1 67:1 72:1 74:1 76:1 78:1 83:1
1 2:1 9:1 16:1 24:1 38:1 40:1 55:1 63:1 67:1 73:1 74:1 76:1 82:1 83:1
0.003612365079071377 5:1 10:1 16:1 19:1 39:1 43:1 52:1 64:1 67:1 73:1 74:1 76:1 78:1
1 3:1 10:1 17:1 19:1 39:1 40:1 55:1 63:1 67:1 73:1 74:1 76:1 80:1 83:1
1 5:1 8:1 14:1 19:1 39:1 40:1 54:1 63:1 67:1 73:1 75:1 76:1 78:1 83:1
1 3:1 6:1 15:1 19:1 39:1 40:1 52:1 63:1 68:1 73:1 74:1 76:1 81:1
0.8565999802928537 4:1 9:1 18:1 21:1 35:1 42:1 47:1 64:1 67:1 73:1 74:1 77:1 80:1 83:1
1 3:1 6:1 18:1 23:1 39:1 42:1 52:1 64:1 67:1 73:1 74:1 76:1 82:1 83:1
1 3:1 6:1 16:1 20:1 37:1 40:1 52:1 63:1 67:1 73:1 74:1 76:1 82:1 83:1
1 2:1 9:1 18:1 19:1 39:1 40:1 51:1 63:1 67:1 73:1 74:1 76:1 80:1 83:1
0.9339726132246082 4:1 16:1 22:1 36:1 40:1 63:1 67:1 73:1 74:1 76:1 80:1 83:1
0.5738691977077197 1:1 9:1 14:1 22:1 36:1 46:1 50:1 61:1 67:1 72:1 74:1 76:1 80:1 83:1
1 4:1 6:1 17:1 22:1 36:1 40:1 50:1 63:1 67:1 73:1 74:1 76:1 80:1 83:1
1 3:1 6:1 18:1 19:1 39:1 40:1 50:1 61:1 67:1 72:1 74:1 76:1 78:1 83:1
1 3:1 6:1 18:1 20:1 37:1 40:1 51:1 63:1 67:1 73:1 74:1 76:1 80:1 83:1
1 4:1 8:1 18:1 20:1 37:1 40:1 50:1 63:1 67:1 73:1 74:1 76:1 82:1 83:1
1 3:1 6:1 18:1 22:1 36:1 41:1 51:1 66:1 67:1 72:1 74:1 77:1 82:1 83:1
1 4:1 6:1 15:1 22:1 36:1 40:1 50:1 63:1 67:1 73:1 74:1 76:1 80:1 83:1
1 3:1 6:1 14:1 22:1 36:1 40:1 48:1 63:1 67:1 73:1 74:1 77:1 80:1 83:1
1 2:1 6:1 17:1 19:1 39:1 40:1 49:1 63:1 67:1 73:1 74:1 76:1 82:1 83:1
0.09580406919051984 5:1 6:1 14:1 29:1 39:1 41:1 52:1 64:1 67:1 72:1 74:1 76:1 80:1 83:1
1 4:1 6:1 18:1 21:1 35:1 40:1 57:1 63:1 67:1 73:1 74:1 77:1 80:1 83:1
1 2:1 6:1 14:1 22:1 36:1 40:1 51:1 63:1 67:1 73:1 74:1 76:1 82:1 83:1
0.6744306648101427 4:1 11:1 15:1 22:1 36:1 40:1 59:1 63:1 67:1 73:1 74:1 76:1 80:1 83:1
1 5:1 7:1 15:1 25:1 38:1 40:1 56:1 63:1 67:1 73:1 74:1 76:1 80:1 83:1
1 4:1 8:1 16:1 19:1 39:1 42:1 50:1 64:1 67:1 73:1 75:1 76:1 82:1 83:1
1 3:1 6:1 16:1 22:1 36:1 40:1 57:1 63:1 67:1 73:1 75:1 76:1 80:1 83:1
1 4:1 7:1 17:1 27:1 35:1 40:1 48:1 63:1 67:1 73:1 74:1 76:1 80:1 99:1
```

תרגיל

- נתונים ארבעת הווקטורים הבאים והסיווג שלהם:

$$X1 = (1, \sqrt{2}, \sqrt{2}, 1, \sqrt{2}, 1) \longrightarrow y1 = -1$$
$$X2 = (1, -\sqrt{2}, \sqrt{2}, 1, -\sqrt{2}, 1) \longrightarrow y2 = +1$$
$$X3 = (1, \sqrt{2}, -\sqrt{2}, 1, -\sqrt{2}, 1) \longrightarrow y3 = +1$$
$$X4 = (1, -\sqrt{2}, -\sqrt{2}, 1, \sqrt{2}, 1) \longrightarrow y4 = -1$$

- נניח שפתרו עבורינו את בעיית האופטימיזציה של SVM ו"גילו" לנו ש:

$$\alpha_1 = \frac{1}{8}, \alpha_2 = \frac{1}{8}, \alpha_3 = \frac{1}{8}, \alpha_4 = \frac{1}{8}$$

$$b = 0$$

תרגיל (המשך)

- כיצד נסווג את הווקטור

$$(1,1,1,1,1,1)$$

- כיצד נסווג את הווקטור

$$X1 = (1,1,\sqrt{2},1,-\sqrt{2},-\sqrt{2})$$

תרגיל (המשך)

- זה שכל האלפות שונות מ-0, אומר לנו שכל הווקטורים הם SV

- סיווג דוגמא חדשה x, מקרה לינארי פשוט, ללא קרנל נחשב ראשית את ה-W

- $W = \sum_{i=1}^{n} y_i \alpha_i x_i$

- נחשב את b במידת הצורך

- ונסווג: $\text{class(x)} = \text{SGN}(Wx - b)$

חישוב w

- כלומר, נחשב ראשית את w:

$$X1 = (1, \sqrt{2}, \sqrt{2}, 1, \sqrt{2}, 1), \quad y_1 = -1, \alpha_1 = \frac{1}{8}$$
$$X2 = (1, -\sqrt{2}, \sqrt{2}, 1, -\sqrt{2}, 1), \quad y_2 = +1, \alpha_2 = \frac{1}{8}$$
$$X3 = (1, \sqrt{2}, -\sqrt{2}, 1, -\sqrt{2}, 1), \quad y_3 = +1, \alpha_3 = \frac{1}{8}$$
$$X4 = (1, -\sqrt{2}, -\sqrt{2}, 1, \sqrt{2}, 1), \quad y_4 = -1, \alpha_4 = \frac{1}{8}$$
$$w = \sum_i \alpha_i y_i x_i$$

$$w = \sum_i \alpha_i y_i x_i$$
$$\frac{1}{8} \times -1 \times (1, \sqrt{2}, \sqrt{2}, 1, \sqrt{2}, 1) +$$
$$\frac{1}{8} \times +1 \times (1, -\sqrt{2}, \sqrt{2}, 1, -\sqrt{2}, 1) +$$
$$\frac{1}{8} \times +1 \times (1, \sqrt{2}, -\sqrt{2}, 1, -\sqrt{2}, 1) +$$
$$\frac{1}{8} \times -1 \times (1, -\sqrt{2}, -\sqrt{2}, 1, \sqrt{2}, 1) =$$

$$w = \left(0, 0, 0, 0, -\frac{\sqrt{2}}{2}, 0\right)$$

סיווג דוגמא חדשה - לינארי

$$f(x) = \text{sgn}(\sum_i \alpha_i y_i < x_i{}^T, x > - b) = \text{sgn}(wx - b)$$

$X1 = (1,1,1,1,1,1)$ $f(x) = \text{sgn}(w^T x + b) = \text{sgn}(\ (0,0,0,\ 0,-\sqrt{2}/2,\ 0)^T (1,1,1,1,1,1) - b)$

$= \text{sgn}(\ 0 \times 1 + 0 \times 1 + 0 \times 1 + 0 \times 1 - \sqrt{2}/2 \times 1 + 0 \times 1 - b) =$

$= \text{sgn}(\ -\sqrt{2}/2) = -1$

$X1 = (1,1,\sqrt{2},1,-\sqrt{2},-\sqrt{2})$

$f(x) = \text{sgn}(w^T x + b) = \text{sgn}(\ (0,0,0,\ 0,-\sqrt{2}/2,\ 0)^T \left(1,1,\sqrt{2},1,-\sqrt{2},-\sqrt{2}\right) - b)$

$= \text{sgn}(\ 0 + 0 + 0 + 0 + 2/2 + 0 - b) =$

$= \text{sgn}(\ 1) = +1$

תרגיל

- פתור את הבעיה הבאה באמצעות SVM עם קרנל לא לינארי.
- נתונה קבוצת האימון הבאה:

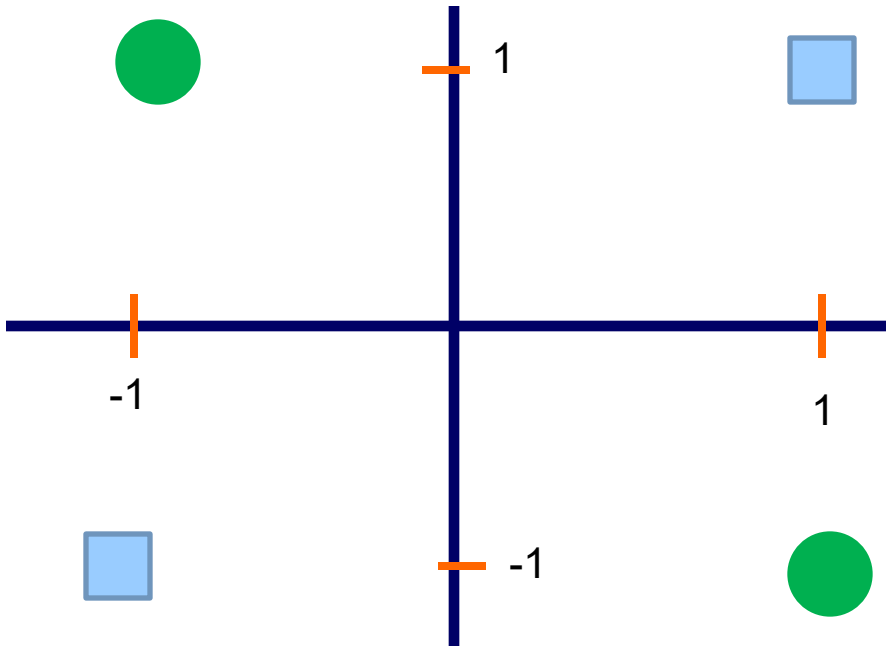
(+1,+1|-1)

(-1,+1|+1)

(+1,-1|+1)

(-1,-1|-1)

תרגיל



$X_1 = (+1, +1)$
$X_2 = (-1, +1)$
$X_3 = (+1, -1)$
$X_4 = (-1, -1)$

$y_1 = -1$
$y_2 = +1$
$y_3 = +1$
$y_4 = -1$

מזכיר את בעיית ה-XOR - אין פתרון לינארי לבעיה במימד בו ניתנה

מהי בעיית האופטימיזציה אותה אנו רוצים לפתור?

אין פתרון לינארי לבעיה. ננסה לפתור את הבעיה עם הקרנל הריבועי:

$$K(x, x_i) = (1 + x^T x_i)^2$$

חישוב b

$$K(x,x_i) = (1 + x^T x_i)^2$$

$$f(example_i) = SGN(\sum_{i=1}^{4} \alpha_i \times label_i \times K(example, example_i)) + b)$$

$$f(example_1) = f(-1,-1) = SGN($$

$$(\frac{1}{8} \times -1 \times (1 + [(-1,-1)^T (-1,-1)]^2) +$$

$$(\frac{1}{8} \times 1 \times (1 + [(-1,-1)^T (-1,1)]^2) +$$

$$(\frac{1}{8} \times 1 \times (1 + [(-1,-1)^T (1,-1)]^2) +$$

$$(\frac{1}{8} \times -1 \times (1 + [(-1,-1)^T (1,1)]^2)$$

$$+ b)$$

$$= SGN((\frac{1}{8} \times -1 \times (1+4) + (\frac{1}{8} \times 1 \times (1+0) + (\frac{1}{8} \times 1 \times (1+0) + (\frac{1}{8} \times -1 \times (1+4))$$

$$= SGN((\frac{-5}{8} + (\frac{1}{8}) + (\frac{1}{8}) + (\frac{-5}{8}) + b) = SGN(-\frac{8}{8} + b) = -1$$

לכן,
b=0 כי זהו SV שלילי
ואנו יודעים שהתוצאה
עבורו (לפני הפעלת ה-
sgn שווה בדיוק ל-1-

סווג את הדוגמא (2,2)

$$K(x,x_i) = (1 + x^T x_i)^2$$

$$f(2,2) = SGN(\sum_{i=1}^{4} \alpha_i label_i \times K([2,2], example_i)) + b)$$

$$SGN($$

$$(\frac{1}{8} \times -1 \times (1 + [(2,2)^T (1,1)]^2) +$$

$$(\frac{1}{8} \times +1 \times (1 + [(2,2)^T (-1,1)]^2) +$$

$$(\frac{1}{8} \times +1 \times (1 + [(2,2)^T (1,-1)]^2) +$$

$$(\frac{1}{8} \times -1 \times (1 + [(2,2)^T (-1,-1)]^2)$$

$$+ 0)$$

$$= SGN((\frac{1}{8} \times -1 \times (1+16) + (\frac{1}{8} \times +1 \times (1+0) + (\frac{1}{8} \times +1 \times (1+0) + (\frac{1}{8} \times -1 \times (1+16) + b)$$

$$= SGN((\frac{-17}{8} + (\frac{1}{8}) + (\frac{1}{8}) + (\frac{-17}{8}) = SGN(\frac{-32}{8}) = -1$$

נמפה כל ווקטור למימד הגבוה

$$\theta(x_1, x_2) = [1, x_1^2, \sqrt{2}x_1x_2, x_2^2, \sqrt{2}x_1, \sqrt{2}x_2]$$

$$example_1 = (-1,-1) \longrightarrow \theta(example_1) = (1, \sqrt{2}, \sqrt{2}, 1, \sqrt{2}, 1)$$

$$example_2 = (-1,+1) \longrightarrow \theta(example_2) = (1, -\sqrt{2}, \sqrt{2}, 1, -\sqrt{2}, 1)$$

$$example_3 = (+1,-1) \longrightarrow \theta(example_3) = (1, \sqrt{2}, -\sqrt{2}, 1, -\sqrt{2}, 1)$$

$$example_4 = (+1,+1) \longrightarrow \theta(example_4) = (1, -\sqrt{2}, -\sqrt{2}, 1, \sqrt{2}, 1)$$

אלו בדיוק הווקטורים מהתרגיל הראשון, רק שבזכות טריק הקרנל חסכנו את המיפוי המפורש למימד הגבוה