שאלה 1:

למדנו שכדי לפתור בעיית multi-class מספיק לדעת כיצד פותרים בעייה בינארית וזאת ע"י יצירת מספר בעיות למידה בינאריות והרצתם. הזכרנו שתי שיטות: One vs. One (שיטה א') או One vs. All (שיטה ב'). עבור 4 "מחלקות". לסיווג ווקטור חדש:

1. **בשיטה א' יש 6 הרצות ובשיטה ב' יש 4 הרצות**
2. בשיטה א' יש 4 הרצות ובשיטה ב' יש 6 הרצות
3. בשיטה א' יש 4 הרצות ובשיטה ב' יש 4 הרצות
4. בשיטה א' יש 6 הרצות ובשיטה ב' יש 6 הרצות
5. בשתי השיטות 6 השוואות

שאלה 2:

שרטטנו את גרף ה ROC-עבור אלגוריתם מסויים. שתי נקודות בגרף הם- נקודה א': עבור TP% השווה ל- 80 יש לנו FP%השווה ל- 10 ונקודה ב': עבור TP%השווה ל- 90 יש לנו FP%השווה ל- 20. מה ניתן לאמר בוודאות על ה-EER

1. ערכו בין 0.1 ל- 0.2
2. ערכו קטן מ-0.1
3. ערכו גדול מ-0.2
4. שווה בדיוק ל-0.2
5. שווה בדיוק ל-0.1

שאלה 3:

"עץ החלטה" –באלגוריתם "עץ החלטה" (ID3) חישבנו את האנתרופיה של "מחלקה" וקיבלנו 1.3

1. **ברור שבעיית הלמידה היא "מרובת מחלקות" (multi-class)**
2. ברור שבעיית הלמידה היא בינארית (שתי מחלקות)
3. לא יכול לצאת אנתרופיה גבוהה מ-1
4. יש לפחות שש מחלקות
5. אף תשובה אינה נכונה

שאלה 4:

אלגוריתם KNN(K Nearest Neighbors) – ד"ר שקשוקה מציע שנשתמש ב-K השווה למספר הווקטורים שבקבוצת האימון

1. **ללא משקול מרחקים, זה יגרום לכך שכל ווקטור חדש לסיווג, יסווג לפי רוב הווקטורים (כלומר, אם רוב הווקטורים בקבוצת האימון הם חיוביים, נכריע "חיובי"). עם משקול מרחקים – לא ניתן לדעת**
2. ללא משקול מרחקים, זה יגרום לכך שכל ווקטור חדש לסיווג, יסווג לפי מיעוט הווקטורים (כלומר, אם רוב הווקטורים בקבוצת האימון הם חיוביים, נכריע "שלילי"). עם משקול מרחקים – לא ניתן לדעת
3. עם משקול מרחקים וללא משקול מרחקים, זה יגרום לכך שכל ווקטור חדש לסיווג, יסווג לפי רוב הווקטורים (כלומר, אם רוב הווקטורים בקבוצת האימון הם חיוביים, נכריע "חיובי").
4. עם משקול מרחקים וללא משקול מרחקים, זה יגרום לכך שכל ווקטור חדש לסיווג, יסווג לפי מיעוט הווקטורים (כלומר, אם רוב הווקטורים בקבוצת האימון הם חיוביים, נכריע "שלילי").
5. אף תשובה אינה נכונה

שאלה 5:

נתונה בעיית למידה (סיווג) בה יש 2 מחלקות סיווג שונות. מהי האנתרופיה המינימאלית והמקסימאלית של "מחלקה" (class)

1. **מינימאלית – 0, מקסימאלית - 1**
2. מינימאלית – 0, מקסימאלית – 1.5
3. מינימאלית – 1-, מקסימאלית – 1
4. מינימאלית – 4, מקסימאלית - 5
5. מינימאלית – $2\log_2 3$, מקסימאלית - 1

שאלה 6:

שיטת gradient-descent באלגוריתם הפרספטרון:

1. **עשוי למצוא לנו מינימום מקומי של הטעות כפונקציה של המשקולות**
2. תמיד ימצא לנו מינימום גלובלי של הטעות כפונקציה של המשקולות
3. תמיד יתכנס לסט משקולות שפותר את הבעיה (לפחות על קבוצת האימון)
4. מתאים רק לבעיית סיווג
5. מתאים רק לבעיית רגרסיה

שאלה 7:

נתונה טבלת האימון הבאה:

X1	X2	X3	X4	Class
1	1	1	1	P
1	1	0	0	P
0	0	1	0	N
0	0	0	0	N

חשב את H(class|x1=1)

1. **0**
2. 1
3. 1/4
4. 1/16
5. 1/2

שאלה 8:

פתרנו את בעיית האופטימיזציה של אלגוריתם SVM עם קרנל לינארי, חישבנו את W וקיבלנו W=(2,2,x). נתון לנו גם שהווקטור (f1=1, f2=1, f3=1) הינו Support Vector, וערכו כפי שקיבלנו מהמנחה הוא: P. אלו מהבאים הינם ערכים אפשריים ל- x ול- b של משוואת הסיווג של אלגוריתם SVM : $f(vector)=W\cdot vector^T+b$

1. **(x=1, b=-4)**
2. (x=2, b=-6)
3. (x=1, b=7)
4. (x=2, b=6)
5. (x=2, b=-2)

שאלה 9:

אלגוריתם Lazy

1. **אינו מחשב מודל למידה בשלב ה"אימון", אלגוריתם KNN הינו אלגוריתם Lazy, חסרון גדול הינו הזמן לסיווג נקודה חדשה**
2. אינו מחשב מודל למידה בשלב ה"אימון", אלגוריתם פרספטרון הינו אלגוריתם Lazy, חסרון גדול הינו הזמן לסיווג נקודה חדשה
3. מחשב מודל למידה כבר בשלב ה"אימון", אלגוריתם פרספטרון הינו אלגוריתם Lazy, חסרון גדול הינו זמן בניית המודל
4. מחשב מודל למידה כבר בשלב ה"אימון", אלגוריתם KNN הינו אלגוריתם Lazy, חסרון גדול הינו זמן בניית המודל
5. מחשב מודל למידה גם בשלב ה"אימון" וגם בזמן סיווג נקודה חדשה, אלגוריתם SVM הינו אלגוריתם Lazy, חסרון גדול הינו הזמן לסיווג נקודה חדשה.

שאלה 10:

אלגוריתם K-means - אחד החסרונות של האלגוריתם הינו שצריך לדעת את K מראש. ד"ר שקשוקה מציע את האלגוריתם הבא (נניח שנתונים לנו n ווקטורים) – הרץ את האלגוריתם עבור כל k אפשרי (מ-1 עד n) ובחר את ה-k שמביא אותנו ל-distortion המינימאלי.

1. **זהו אלגוריתם לא טוב מכיוון שיתכנס לכך ש-k השווה בדיוק ל-n**
2. זהו אלגוריתם לא טוב מכיוון שיתכנס לכך ש-k השווה בדיוק ל-1
3. אלגוריתם מצויין. הבעיה שייקח הרבה זמן עיבוד.
4. עבור המקרה בו ה-k האופטימאלי הוא 3, אלגוריתם זה עשוי להתכנס ל-k=2
5. אף תשובה אינה נכונה.

שאלה 11:

תהליך boosting

1. **באמצעות שקלול של תוצאת מס' מסווגים לינאריים ניתן להגיע למסווג לא לינארי**
2. באמצעות שקלול של תוצאת מס' מסווגים לינאריים לא ניתן להגיע למסווג לא לינארי
3. רק אם משתמשים ב-adaboost ניתן להגיע ליכולת הפרדה לא לינארית ע"י שקלול של תוצאת מסווגים שונים
4. מותר לבצע את התהליך רק אם משקללים יחד מס' אלגוריתמי פרספטרון
5. הינו תהליך להערכת ביצועי מכונת למידה

שאלה 12:

הנחת אי התלות בין המאפיינים באלגוריתם נאיב בייס

1. **מאפשרת לנו לחשב את ההסתברות המותנית הנדרשת בהינתן ווקטור רב מימדי כמכפלה של ההסתברויות בהינתן כל מאפיין בנפרד.**
2. האלגוריתם אוסר להניח אי תלות בין המאפיינים
3. הנחה זו הינה חלק מחוק בייס
4. באה כדי למנוע את בעיית ה-underflow
5. באה כדי למנוע את בעיית ה-overflow