למידת מכונה

עצי החלטה
Decision Trees

1

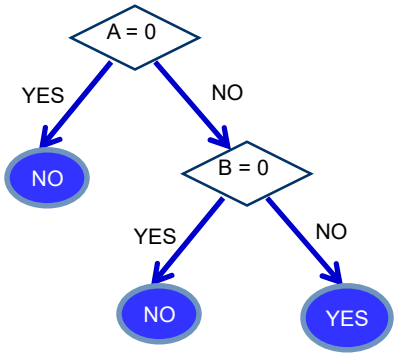
עצי החלטה

- מבוסס על סדרה של "מבחנים" לתבנית הקלט.
  כמו למשל:
  - "האם התבנית צהובה"
  - האם המשקל גדול מ-50"
  - ....
- תשובה לסדרת שאלות מסווגת לנו את התבנית.
  - דוגמא: כתום, עגול, קוטר קטן מ-20 ס"מ ← "תפוז"

2

AND

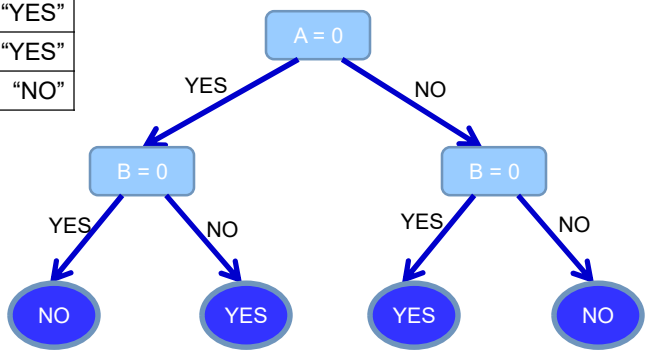
A	B	Decision
0	0	“NO”
0	1	“NO”
1	0	“NO”
1	1	“YES”



3

XOR

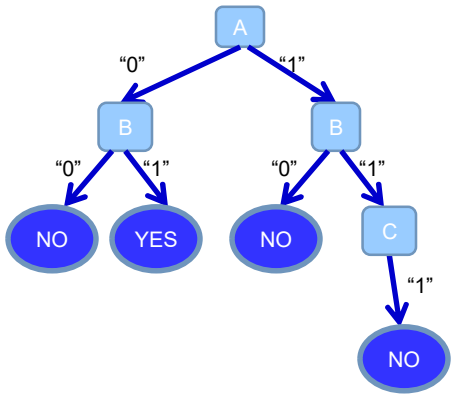
A	B	Decision
0	0	“NO”
0	1	“YES”
1	0	“YES”
1	1	“NO”



4

דוגמא

	A	B	C	Decision
1	0	0	0	“NO”
2	0	1	0	“YES”
3	1	0	1	“NO”
4	1	1	1	“NO”
5	0	0	1	“NO”
6	0	1	1	“YES”
7	1	0	0	“NO”



5

דוגמא

	A	B	C	Decision
1	0	0	0	“NO”
2	0	1	0	“YES”
3	1	0	1	“NO”
4	1	1	1	“NO”
5	0	0	1	“NO”
6	0	1	1	“YES”
7	1	0	0	“NO”

מה עם רשומות חסרות???
איך נסווג את הווקטור A=1 B=1 C=0

בחיים האמיתיים – קבוצת האימון לא תכיל את כל המצבים האפשריים

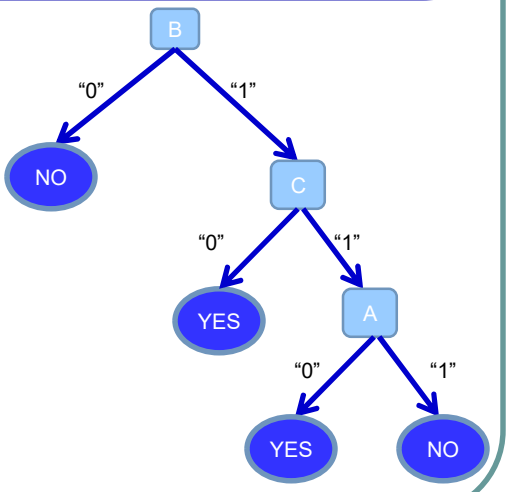
אבל... המטרה שלנו היא כן לדעת לסווג את כל המצבים האפשריים

בדר"כ נעסוק בריבוי מאפיינים (לא 3 אלא מספר מאות מאפיינים ורוב המאפיינים אינם בינאריים)

6

אולי ניתן לייצג באמצעות עץ פשוט יותר

	A	B	C	Decision
1	0	0	0	“NO”
2	0	1	0	“YES”
3	1	0	1	“NO”
4	1	1	1	“NO”
5	0	0	1	“NO”
6	0	1	1	“YES”
7	1	0	0	“NO”



7

התער של אוקמה Occama’s Razor

- עיקרון פילוסופי המיוחס לוויליאם איש אוקאם, נזיר פרנציסקני אנגלי בן המאה ה-14.
- "**אין צורך להניח דבר בלא שניתנה לכך סיבה, אלא אם הוא ברור מאליו, או ידוע מהניסיון, או שהוכחתו ניתנת מכוח סמכותם של ספרי הקודש**."
- כאשר קיימים הסברים שונים לאותה תופעה יש לבחור בהסבר הפשוט ביותר, אשר מערב את המספר המועט ביותר של מושגים וחוקים
- כאשר ישנם שני הסברים שווי ערך לאותה תופעה, יש להעדיף את ההסבר הפשוט או החסכוני יותר

8

התער של אוקמה Occama's Razor

- אם לאחר סערה נבחין בעץ שנפל, נוכל להסיק בפשטות כי "הרוח הפילה את העץ". (שני מרכיבים, ושניהם קיימים אל מול עינינו - הרוח והעץ).
- איננו צריכים ישויות נוספות כגון חוטבי עצים או פילים על מנת להסביר מדוע העץ נפל.
- או .... "העץ נפל כתוצאה מפעולתם של חייזרים זועמים בגובה שלושה מטרים".

מתוך ויקי

9

הרמב"ם – מאתיים שנים לפני...

- "...זה מן הדברים שהאסטרונום אינו דואג להם, מכיוון שמטרת מדע זה להניח מתכונת שעְמָהּ אפשר שתנועת הכוכב תהיה אחת, סיבובית, שאין עִמה האצה ולא האטה ולא שינוי, ושמה שמתחייב מתנועה זאת יתאים למה שרואים. עם זאת **הוא מבקש למעט בתנועות ובמספר הגלגלים ככל האפשר. אם, למשל, יש ביכולתנו להניח מתכונת אשר על-פיה תהיינה אפשריות התנועות הנראות-לעין של כוכב זה על-פי שלושה גלגלים, ומתכונת אחרת אשר על-פיה יתאפשר אותו דבר עצמו על-פי ארבעה גלגלים, ראוי לנו לסמוך על המתכונת אשר מספר התנועות בה קטן יותר... "**

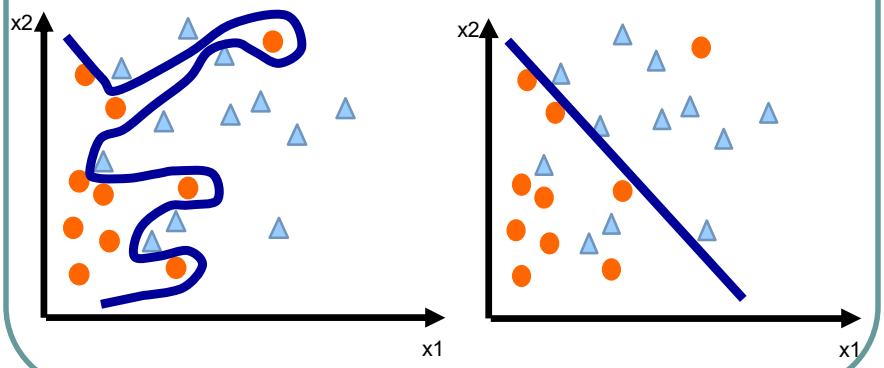
(מורה נבוכים חלק שני פרק י"א)

10

איזה מישור הפרדה נעדיף

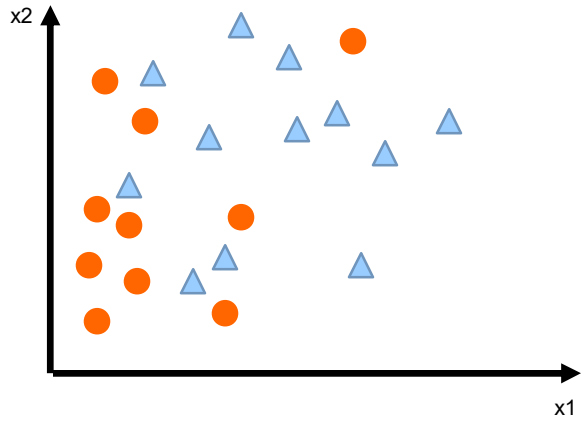
את ההסבר ה"פשוט" ???? **או ההסבר ה"מורכב" ????**

איך "נתמחר" פשטות מפריד לעומת מס' טעויות



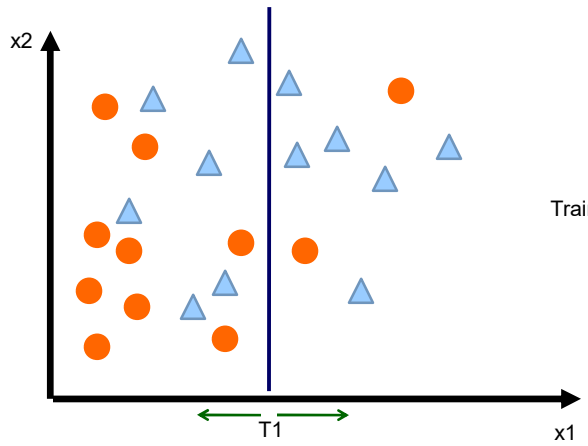
11

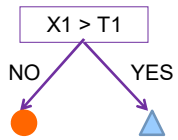
דוגמא לעץ החלטה



12

דוגמא לעץ החלטה

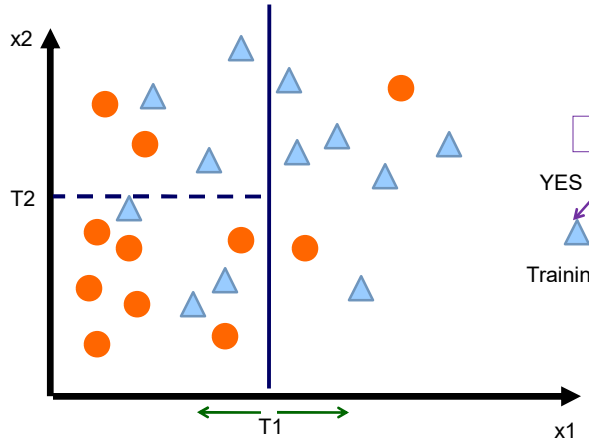


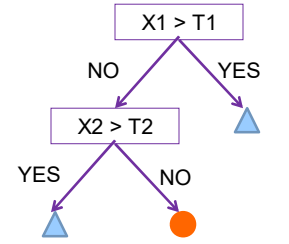


Training Error = 2 + 6 = 8

13

דוגמא לעץ החלטה

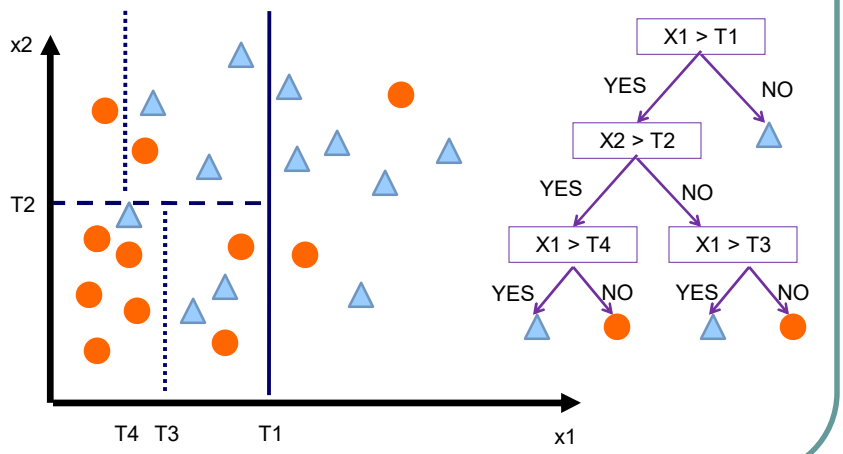




Training Error = 2 + 2 + 3 = 7

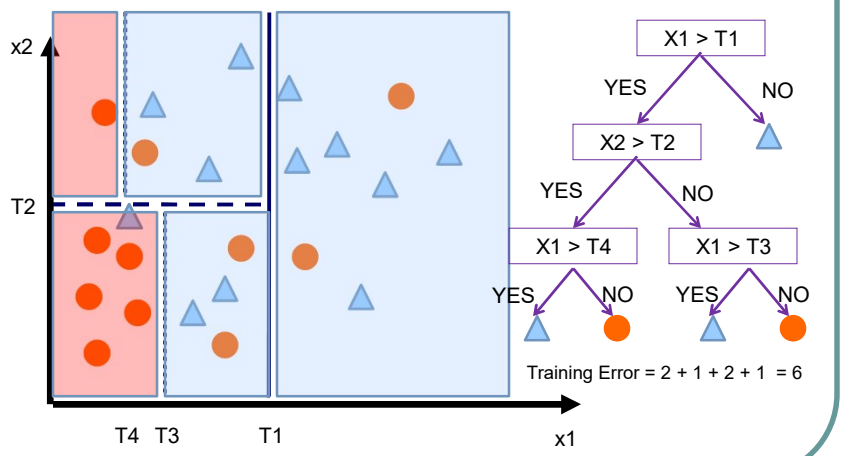
14

דוגמא לעץ החלטה



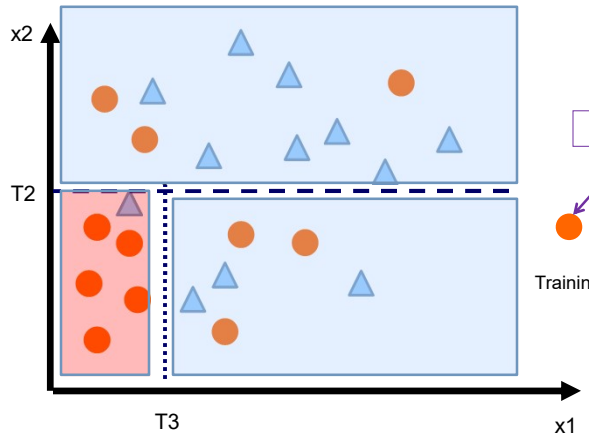
15

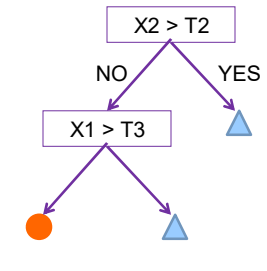
דוגמא לעץ החלטה



16

דוגמא לעץ החלטה פשוט יותר





Training Error = 1 + 3 + 3= 7

17

Poor Attribute

- כאשר התכונה לא מייצרת הפרדה בין המחלקות השונות
- כאשר התכונה לא משנה להחלטה

18

Good Attribute

- אידיאלי כאשר עבור ערך אחד של התכונה נקבל תשובה חיובית ועבור הערך האחר נקבל תשובה שלילית.

19

Here is a dataset

age	employme	education	edun	marital	…	job	relation	race	gender	hour	country	wealth
					…							
39	State_gov	Bachelors	13	Never_mar	…	Adm_cleri	Not_in_fan	White	Male	40	United_Sta	poor
51	Self_emp_	Bachelors	13	Married	…	Exec_man	Husband	White	Male	13	United_Sta	poor
39	Private	HS_grad	9	Divorced	…	Handlers_(	Not_in_fan	White	Male	40	United_Sta	poor
54	Private	11th	7	Married	…	Handlers_(	Husband	Black	Male	40	United_Sta	poor
28	Private	Bachelors	13	Married	…	Prof_speci	Wife	Black	Female	40	Cuba	poor
38	Private	Masters	14	Married	…	Exec_man	Wife	White	Female	40	United_Sta	poor
50	Private	9th	5	Married_sp	…	Other_serv	Not_in_fan	Black	Female	16	Jamaica	poor
52	Self_emp_	HS_grad	9	Married	…	Exec_man	Husband	White	Male	45	United_Sta	rich
31	Private	Masters	14	Never_mar	…	Prof_speci	Not_in_fan	White	Female	50	United_Sta	rich
42	Private	Bachelors	13	Married	…	Exec_man	Husband	White	Male	40	United_Sta	rich
37	Private	Some_coll	10	Married	…	Exec_man	Husband	Black	Male	80	United_Sta	rich
30	State_gov	Bachelors	13	Married	…	Prof_speci	Husband	Asian	Male	40	India	rich
24	Private	Bachelors	13	Never_mar	…	Adm_cleri	Own_child	White	Female	30	United_Sta	poor
33	Private	Assoc_acd	12	Never_mar	…	Sales	Not_in_fan	Black	Male	50	United_Sta	poor
41	Private	Assoc_voc	11	Married	…	Craft_repai	Husband	Asian	Male	40	*MissingV	rich
34	Private	7th_8th	4	Married	…	Transport_	Husband	Amer_Indi	Male	45	Mexico	poor
26	Self_emp_	HS_grad	9	Never_mar	…	Farming_fi	Own_child	White	Male	35	United_Sta	poor
33	Private	HS_grad	9	Never_mar	…	Machine_c	Unmarried	White	Male	40	United_Sta	poor
38	Private	11th	7	Married	…	Sales	Husband	White	Male	50	United_Sta	poor
44	Self_emp_	Masters	14	Divorced	…	Exec_man	Unmarried	White	Female	45	United_Sta	rich
41	Private	Doctorate	16	Married	…	Prof_speci	Husband	White	Male	60	United_Sta	rich
:	:	:	:	:	:	:	:	:	:	:	:	:

48,000 records, 16 attributes [Kohavi 1995]

http://www.cs.cmu.edu/~awm/tutorials

20

About this dataset

- It is a tiny subset of the 1990 US Census.
- It is publicly available online from the UCI Machine Learning Datasets repository

Used Attributes

age	edunum	race	hours_worked
employment	marital	gender	country
taxweighting	job	capitalgain	wealth
education	relation	capitalloss	agegroup

This color = Real-valued This color = Symbol-valued

Successfully loaded a new dataset from the file \tadult.fds. It has 16 attributes and 48842 records.

http://www.cs.cmu.edu/~awm/tutorials

21

שאלות פתוחות בשלב זה

- איזו תכונה (attribute) יש לבחור בכל שלב ?
- מתי נחליט שצומת מסויים הוא "עלה"
- איך מכריעים עבור "עלה"

22

ID3

- שיטה אלגוריתמית לבניית עץ החלטה
- פותחה ע"י J. Ross Quinlan in 1979.
- שימוש בתורת האינפורמציה (Shanon, 1948)
- בניית עץ "מלמעלה-למטה" (ללא backtracking)

23

העיקרון הבסיסי

- ננסה לייצר את "המסלול" הקצר ביותר
  - הרעיון: בכל רמה בעץ ננסה לשאול את השאלה שתשפר לנו בצורה הטובה ביותר את רמת הוודאות בחיזוי

24

בעץ החלטה

- ננסה תמיד לבצע שאילתא על התכונה שמביאה אותנו למקסימום ודאות (מינימום אי-ודאות)
- נשים לב שאם נבצע שאילתא על גובה השכר נקבל רמת ודאות גבוהה:
  - גובה שכר גבוה ← קנה = כן
  - גובה שכר נמוך ← קנה = לא

גובה שכר	גיל	מין	"קנה"?
נמוך	30-40	ז	כן
גבוה	40-50	ז	כן
נמוך	30-40	ז	לא
נמוך	50-60	נ	לא
נמוך	50-60	נ	לא
נמוך	30-40	ז	לא
גבוה	30-40	נ	כן

25

רמת וודאות

- נעדיף תמיד לחזות במקום שבו יש לנו את רמת הוודאות הגבוהה ביותר
- מדד לאי הודאות – **"אנטרופיה"**

26

תזכורות מתורת האינפורמציה – Self Information

- דוגמא – הטלת מטבע
  - עבור מטבע "לא הוגן" **<u>שתמיד נופל על "עץ"</u>** – לא נהיה מופתעים כאשר גם בפעם הבאה יפול על "עץ" – קל לחזות = לא נוספה לנו אינפורמציה.
  - עבור מטבע "הוגן" שנופל בהסתברות 50% על "עץ" – תמיד נהיה מופתעים מתוצאת הזריקה הבאה– קשה לחזות = נוספה לנו "הרבה" אינפורמציה.

27

תזכורות מתורת האינפורמציה – Self Information

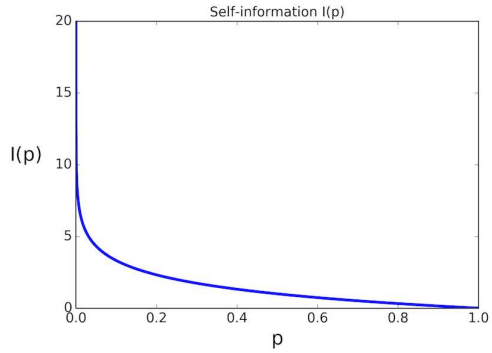
- נחפש פונקציה שמקיימת את התכונות הבאות:
  - ככל שההסתברות לאירוע גדלה, האינפורמציה קטנה (הייצוג בביטים לדוגמא)
  - נרצה שהאינפורמציה עבור X מאורעות בלתי תלויים תהיה שווה לסכום האינפורמציות עבור כל מאורע בנפרד.
    - (דוגמא – האינפורמציה של שתי הטלות מטבע תהיה שווה לסכום האינפורמציות של כל הטלה
    - $I(p_i \cdot p_j) = I(p_i)+I(p_j)$

28

Self Information

- פונקציה המתאימה לדרישות אלו

$$I(p_i) = -\log(p_i)$$



29

Self Information

- נחזור לדוגמת המטבע:
  - עבור הטלת מטבע בודד אנו צריכים ביט אחד כדי לייצג את התוצאות האפשריות. שתי אפשרויות בהסתברות שווה $-log_2 \frac{1}{2} = 1$
  - עבור 3 הטלות מטבע, יש לנו 8 צירופים אפשריים, ההסתברות לכל מאורע הינו $\frac{1}{8}$ צריכים $-log_2 \frac{1}{8}$ ביטים.

שווה ל- 3 ביטים - בעצם שקול לסכום האינפורמציה של ההטלות הנפרדות

30

אנתרופיה

Shannon entropy is the average self-information (expected value) over all possible values of X

$$H(X) = E_{x\sim P}[I(x)] = \sum_{i=1}^{n} p(x_i)\, I(x_i) = -\sum_{i=1}^{n} p(x_i)\, log_b(p(x_i)),$$

31

אנתרופיה

- נתבונן במקרה הכללי בו נתונות לנו הסתברויות:

P(X=α1) = p1, P(X=α2) = p2, ……. P(X=αn) = pn

נגדיר H(X) כאנתרופיה של X (Entropy)

$$H(X) = -p_1 \log_2 p_1 - p_2 \log_2 p_2 - ... - p_n \log_2 p_n$$

$$= -\sum_{j=1}^{n} p_j \log_2 p_j$$

אנתרופיה גבוהה, משמעותה, שההתפלגות יותר דומה לאחידה.

32

תזכורת מתורת האינפורמציה

- נניח שהשפה שלנו מכילה 4 אותיות
  - A,B,C,D
- נניח גם שידוע שההסתברות להופעה של כל אחת מהאותיות שווה (1/4).
- קידוד אפשרי של האותיות יהיה ב"השקעה" של 2 ביטים לכל אות.(A=00, B=01, C=10, D=11)
  - CDDAAABB יקודד כ-
  - 1011110000000101

33

תזכורת מתורת האינפורמציה

- נניח שנתון לנו שההסתברויות אינן שוות –
  - P(A) = 0.125
  - P(B) = 0.25
  - P(C) = 0.125
  - P(D) = 0.5
- כעת, ניתן לקודד בהשקעה ממוצעת של 1.75 ביטים לאות.

34

תזכורת מתורת האינפורמציה

- הרעיון:
  - נשקיע פחות ביטים באותיות שהסתברות ההופעה שלהם גבוהה, ויותר ביטים באותיות שהסתברות ההופעה שלהם נמוכה.

		קידוד
P(A)	0.125	110
P(B)	0.25	10
P(C)	0.125	111
P(D)	0.5	0

0.125 * 3 + 0.25 * 2 + 0.125 * 3 + 0.5 * 1 = **1.75**

35

High vs. Low Entropy

- "High Entropy"
  - A uniform-like distribution
  - קשה לחזות
- "Low Entropy"
  - A varied (peaks and valleys) distribution
  - יותר קל לחזות

36

האתגר – חיזוי מוצלח

- היכן טמונה יותר אינפורמציה – במשחק חזרתי של הטלת מטבע **או** הטלת קוביה ?
- והיכן תעדיפו לשחק? במשחק חזרתי של חיזוי תוצאת סכום של שתי הטלות קוביה

או

בחירת מס' מבין 9 אפשרויות בהסתברות שווה

37

סכום הטלות או בחירה בין 9 אפשרויות

prob	sum
1/36	2
2/36	3
3/36	4
4/36	5
5/36	6
6/36	7
5/36	8
4/36	9
3/36	10
2/36	11
1/36	12

$$-2\times\frac{1}{36}\log_2\frac{1}{36}-2\times\frac{2}{36}\log_2\frac{2}{36}$$
$$-2\times\frac{3}{36}\log_2\frac{3}{36}-2\times\frac{4}{36}\log_2\frac{4}{36}$$
$$-2\times\frac{5}{36}\log_2\frac{5}{36}-\frac{6}{36}\log_2\frac{6}{36}=3.2$$

בחירה בין 9 אפשרויות

$$9\times(-\frac{1}{9}\log_2\frac{1}{9})=3.17$$

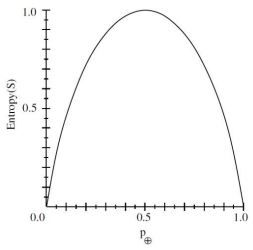
38

איזו תכונה לבחור בכל שלב

- בחר את התכונה שממזערת את האנתרופיה בתת-העץ שהיא יוצרת
- הקשר בין "אי-סדר" ו"אינפורמציה" – ככל שאי הסדר גדל, דרושה יותר אינפורמציה ע"מ לשערך איבר בקבוצה.
- אנו מחפשים את האסטרטגיה שתוביל אותנו במינימום שאלות אל פתרון הבעיה.

39

אנתרופיה עבור 2 מחלקות



- S הינה קבוצת האימון
- P^+ הינו החלק היחסי של הדוגמאות החיוביות בקבוצה
- P^- הינו החלק היחסי של הדוגמאות השליליות בקבוצה
- האנתרופיה של S:

$$H(S) = -p^+ \log_2 p^+ - p^- \log_2 p^-$$

40

דוגמא

- נתונה הטבלה הבאה:

Y "קונה מחשב"	X "גיל"
"כן"	צעיר
"כן"	צעיר
"כן"	בינוני
"לא"	צעיר
"לא"	בינוני
"כן"	זקן
"לא"	צעיר
"לא"	זקן

$$P(Y = \text{כן}) = 0.5$$
$$P(Y = \text{לא}) = 0.5$$
$$H(Y) = -0.5\log_2 0.5 - 0.5\log_2 0.5 = -0.5\times(-1) - 0.5\times(-1) = 1$$

$$P(X = \text{צעיר}) = 0.5$$
$$P(X = \text{בינוני}) = 0.25$$
$$P(X = \text{זקן}) = 0.25$$
$$H(X) = -0.5\log_2 0.5 - 0.25\log_2 0.25 - 0.25\log_2 0.25 = -0.5\times(-1) - 0.25\times(-2) - 0.25\times(-2) = 1.5$$

H(Y) = 1, H(X) = 1.5

41

Specific Conditional Entropy

- נגדיר "אנתרופיה מותנית מסויימת"
- (Specific Conditional Entropy)

H(Y|X= α)

כאנתרופיה של Y בין כל אותם הרשומות שבהן X מקבל את הערך α

Y "קונה מחשב"	X "גיל"
"כן"	צעיר
"כן"	צעיר
"כן"	בינוני
"לא"	צעיר
"לא"	בינוני
"כן"	זקן
"לא"	צעיר
"לא"	זקן

$$P(Y = \text{כן} \mid X = \text{צעיר}) = 0.5$$
$$P(Y = \text{לא} \mid X = \text{צעיר}) = 0.5$$
$$H(Y \mid X = \text{צעיר}) = -0.5\log 0.5 - 0.5\log 0.5 = 1$$

42

Specific Conditional Entropy

H(Y|X= α)

Y "קונה מחשב"	X "גיל"
"כן"	צעיר
"כן"	צעיר
"כן"	בינוני
"לא"	צעיר
"כן"	בינוני
"לא"	זקן
"לא"	צעיר
"לא"	זקן

$P(Y=\text{כן} \mid X=\text{בינוני})=1$
$P(Y=\text{לא} \mid X=\text{בינוני})=0$
$H(Y \mid X=\text{בינוני})=-1\log 1=0$

$P(Y=\text{כן} \mid X=\text{זקן})=0$
$P(Y=\text{לא} \mid X=\text{זקן})=1$
$H(Y \mid X=\text{זקן})=-1\log 1=0$

$P(Y=\text{כן} \mid X=\text{צעיר})=0.5$
$P(Y=\text{לא} \mid X=\text{צעיר})=0.5$
$H(Y \mid X=\text{צעיר})=-0.5\log 0.5-0.5\log 0.5=1$

H(Y|X=צעיר) = 1

H(Y|X=בינוני) = 0

H(Y|X=זקן) = 0

43

אנתרופיה מותנית

Y "קונה מחשב"	X "גיל"
"כן"	צעיר
"כן"	צעיר
"כן"	בינוני
"לא"	צעיר
"כן"	בינוני
"לא"	זקן
"לא"	צעיר
"לא"	זקן

האנתרופיה מותנית H(Y|X) הינה ממוצע משוקלל של האנתרופיות ה"ספציפיות" של Y

$$H(Y \mid X)=\sum_j P(X=\alpha_j)H(Y \mid X=\alpha_j)$$

H(Y|X=צעיר) = 1 P(X=צעיר) = 0.5

H(Y|X=בינוני) = 0 P(X=בינוני) = 0.25

H(Y|X=זקן) = 0 P(X=זקן) = 0.25

H(Y|X) = 0.5 x 1 + 0.25 x 0 + 0.25 x 0 = 0.5

44

Information Gain

- Gain(Y|X) הינה ההפחתה הצפויה באנתרופיה של Y בגלל מיון עפ"י תכונה X

$$Gain(Y \mid X) = H(Y) - H(Y \mid X)$$

צריך לשלוח מסר Y. כמה ביטים יחסכו בממוצע אם שני הצדדים בתקשורת יודעים את X

45

צבע	גיל גדול מ-30	סיווג
שחור	כן	YES
לבן	לא	NO
צהוב	לא	NO
שחור	כן	YES
צהוב	כן	YES
לבן	כן	YES
צהוב	כן	YES
שחור	לא	NO
שחור	לא	NO
לבן	כן	YES
לבן	כן	YES
שחור	לא	NO
צהוב	כן	YES
שחור	לא	NO
צהוב	כן	YES
שחור	לא	NO
צהוב	כן	YES
לבן	כן	YES
לבן	כן	YES
צהוב	לא	NO
צהוב	לא	NO

46

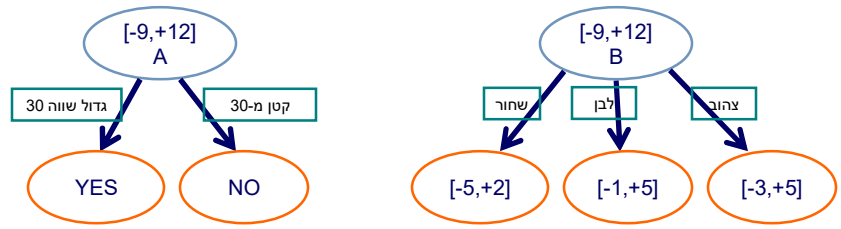
דוגמא

- נתונה קבוצת האימון בה 12 דוגמאות מסווגות כחיובי ו-9 דוגמאות כשלילי.
- נתונה תכונה A (מייצגת "גיל") לה שני פיצולים אפשריים :
  - "אם גדול מ-30" – הסיווג הוא YES, "אם קטן/שווה ל-30" הסיווג הוא NO.
  - נסמן זאת (-9,+0) ו-(-0 ,+12)
- נתונה תכונה B ("צבע") לה שלושה פיצולים אפשריים:
  - "אם שחור – אנו נשארים עם קבוצה של 2חיוביים וחמישה שליליים",
  - "אם לבן – נשארים עם קבוצה של 5 חיוביים ואחד שלילי",
  - "אם צהוב – נשארים עם קבוצה של חמישה חיוביים ושלושה שליליים"
  - (-5,+2), (-1,+5) ו-(-3 ,+5)

איזו תכונה עדיפה כצומת הבא בעץ

47

דוגמא



נחשב IG(A), IG(B) ונבחר את הגדול מבין השניים

$$H(12,9) == -\frac{12}{21}\log_2\frac{12}{21} - \frac{9}{21}\log_2\frac{9}{21} =$$
$$= -\frac{12}{21}(-0.807) - \frac{9}{21}(-1.22) = 0.4611 + 0.5228 = 0.98$$

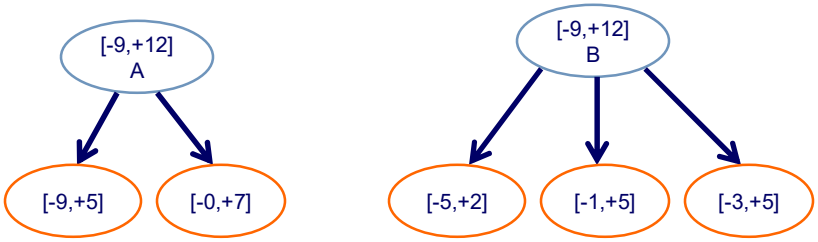
$$H(Y \mid A) = p(A <= 30)H(Y \mid A <= 30) + p(A > 30)H(Y \mid A > 30)$$
$$H(Y \mid A > 30) = H(12,0) == -\frac{12}{12}\log_2\frac{12}{12} - \frac{0}{12}\log_2\frac{0}{12} = 0 - 0 = 0$$
$$H(Y \mid A <= 30) = H(0,9) == -\frac{0}{9}\log_2\frac{0}{9} - \frac{9}{9}\log_2\frac{9}{9} = 0 - 0 = 0$$

$$IG(Y \mid A) = 0.98 - \frac{9}{21}\times 0 - \frac{12}{21}\times 0 = 0.98$$

48

דוגמא

- נתונה קבוצת האימון בה 12 דוגמאות מסווגות כחיובי ו-9 דוגמאות כשליליי.
- נתונה תכונה A שהתשובה עליה מחלקת את העולם לשתי מחלקות (-9,+5) ו-(-0 ,+7)
- נתונה תכונה B שהתשובה עליה מחלקת את העולם לשלוש מחלקות (-5,+2), (-1,+5) ו-(-3 ,+5)



49

$$Gain(Y \mid X) = H(Y) - H(Y \mid X)$$

$$Gain(Y \mid A) =$$
$$H(Y) - p(Y \mid A = "yes") \times H(Y \mid A = "yes") - p(Y \mid A = "no") \times H(Y \mid A = "no")$$
$$0.98 - \frac{14}{21} \times H(5+,9-) - \frac{7}{21} \times H(0+,7-)$$
$$= 0.98 - \frac{14}{21} \times 0.94 - \frac{7}{21} \times 0 = 0.358$$

$$Gain(Y \mid B) =$$
$$H(Y) - [p(Y \mid B = "black") \times H(Y \mid B = "black") + p(Y \mid B = "white") \times H(Y \mid B = "white") + p(Y \mid B = "green") \times H(Y \mid B = "green")]$$
$$= 0.98 - [\frac{7}{21} \times H(2+,5-) + \frac{6}{21} \times H(5+,1-) + \frac{8}{21} \times H(5+,3-)] = 0.14$$

ולכן נבחר ב-A כתכונה בצומת הבא

50

Searching for High Info Gains

Given something (e.g. wealth) you are trying to predict, it is easy to ask the computer to find which attribute has highest information gain for it.

wealth values:	poor	rich	
relation Husband	10870	8846	H(wealth | relation = Husband) = 0.992385
Not_in_family	11307	1276	H(wealth | relation = Not_in_family) = 0.473439
Other_relative	1454	52	H(wealth | relation = Other_relative) = 0.216617
Own_child	7470	111	H(wealth | relation = Own_child) = 0.110192
Unmarried	4816	309	H(wealth | relation = Unmarried) = 0.328606
Wife	1238	1093	H(wealth | relation = Wife) = 0.997207

H(wealth) = 0.793844 H(wealth|relation) = 0.628421

IG(wealth|relation) = 0.165423

http://www.cs.cmu.edu/~awm/tutorials

51

תרגיל

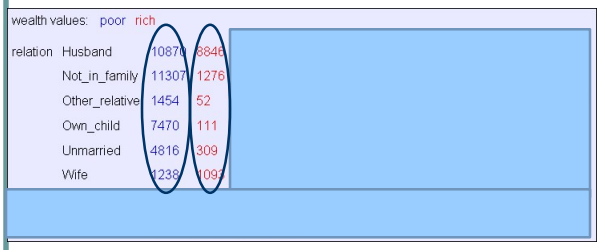
נתונה הטבלה הבאה:

חשב את IG(wealth|relation)

wealth values:	poor	rich
relation Husband	10870	8846
Not_in_family	11307	1276
Other_relative	1454	52
Own_child	7470	111
Unmarried	4816	309
Wife	1238	1093

52

נחשב את האנתרופיה ההתחלתית



נתונה הטבלה הבאה:
חשב את IG(wealth|relation)

$$10870+11307+1454+7470+4816+1238=37,153$$

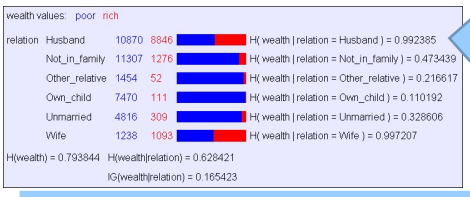
$$8846+1276+52+111+309+1093=11,687$$

$$11,687+37,153=48,840$$

$$-\frac{37155}{48840}\times\log_2(\frac{37155}{48840})-\frac{11687}{48840}\times\log_2(\frac{11687}{48840})=$$

$$=-0.76\times\log_2 0.76-0.24\times\log_2 0.24=0.29+0.49=$$ 0.79

נחשב את האנתרופיה הספציפית המסויימת של כל תכונה

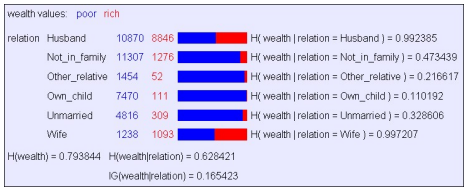


H(wealth|relation = husband)

Relation	
Poor	**Rich**
10,870	**8,846**
total	10,870+8,846 = 19,716
P(Poor) = 10,870/19,716 = 0.551	P(Rich) = 8,846/19,716 = 0.448
$\log_{10}(0.551)=-0.258$	$\log_{10}(0.448)=-0.348$
$\log_{10}(2)=0.301$	$\log_{10}(2)=0.301$
$\log_2(0.551)=-0.258/0.301=-0.857$	$\log_2(0.448)=-0.348/0.301=-1.156$
H = -(0.551) X (-0.857) – (0.448) X (-1.156) = 0.472+0.517≈0.99	

Logarithm base change rule $\log_b(x)=\log_c(x)/\log_c(b)$

נחשב את H(wealth|relation)



$$Total = 10870 + 8846 + 11307 + 1276 + 1454 + 52 + 7470 + 111 + 4816 + 309 + 1238 + 1093 = 48{,}842$$

$$\frac{10870 + 8846}{48842} = 0.403 \qquad \frac{11307 + 1276}{48842} = 0.257$$

$$\frac{1454 + 52}{48842} = 0.030 \qquad \frac{7470 + 111}{48842} = 0.155$$

$$\frac{4816 + 309}{48842} = 0.104 \qquad \frac{1238 + 1093}{48842} = 0.047$$

$$0.99 \times 0.403 + 0.473 \times 0.257 + 0.216 \times 0.030 + 0.110 \times 0.155 + 0.328 \times 0.104 + 0.997 \times 0.047 = 0.62$$

55

Learning Decision Trees

- A Decision Tree is a tree-structured plan of a set of attributes to test in order to predict the output.
- To decide which attribute should be tested first, simply find the one with the highest information gain.
- Then recurse…

http://www.cs.cmu.edu/~awm/tutorials

56

A small dataset: Miles Per Gallon

40 Records

mpg	cylinders	displacement	horsepower	weight	acceleration	modelyear	maker
good	4	low	low	low	high	75to78	asia
bad	6	medium	medium	medium	medium	70to74	america
bad	4	medium	medium	medium	low	75to78	europe
bad	8	high	high	high	low	70to74	america
bad	6	medium	medium	medium	medium	70to74	america
bad	4	low	medium	low	medium	70to74	asia
bad	4	low	medium	low	low	70to74	asia
bad	8	high	high	high	low	75to78	america
:	:	:	:	:	:	:	:
:	:	:	:	:	:	:	:
:	:	:	:	:	:	:	:
bad	8	high	high	high	low	70to74	america
good	8	high	medium	high	high	79to83	america
bad	8	high	high	high	low	75to78	america
good	4	low	low	low	low	79to83	america
bad	6	medium	medium	medium	high	75to78	america
good	4	medium	low	low	low	79to83	america
good	4	low	low	medium	high	79to83	america
bad	8	high	high	high	low	70to74	america
good	4	low	medium	low	medium	75to78	europe
bad	5	medium	medium	medium	medium	75to78	europe

http://www.cs.nyu.edu/courses/fall00/G22.3033-001/weka/weka-3-0-2/data/auto-mpg-test.arff

From the UCI repository (thanks to Ross Quinlan)

http://www.cs.cmu.edu/~awm/tutorials

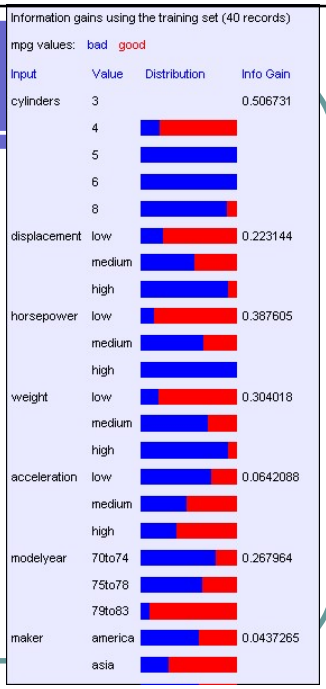
57

MPG dataset

- Number of Attributes: 8 including the class attribute
  - 1. mpg: continuous
  - 2. cylinders: multi-valued discrete
  - 3. displacement: continuous
  - 4. horsepower: continuous
  - 5. weight: continuous
  - 6. acceleration: continuous
  - 7. model year: multi-valued discrete
  - 8. origin: multi-valued discrete (1 = usa; 2 = europe; 3 = japan)

58

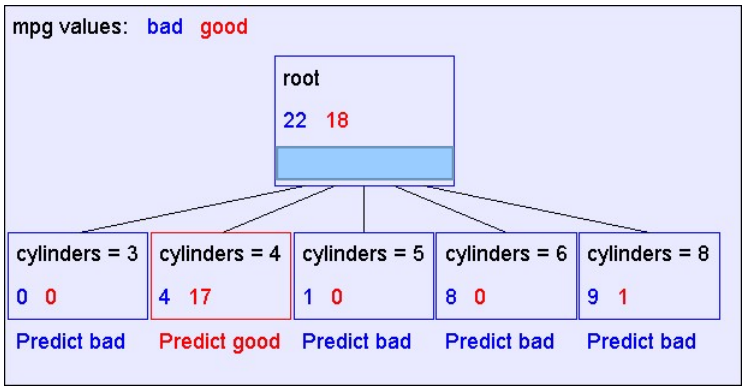
Suppose we want to predict MPG.



http://www.cs.cmu.edu/~awm/tutorials

59

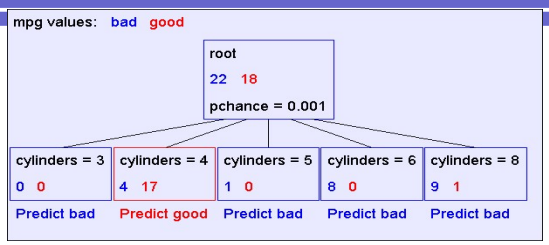
A Decision Stump



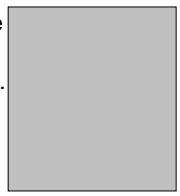
http://www.cs.cmu.edu/~awm/tutorials

60

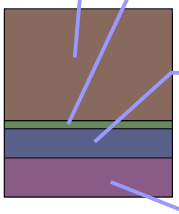
Recursion Step



Take the Original Dataset..



And partition it according to the value of the attribute we split on



Records in which cylinders = 4

Records in which cylinders = 5

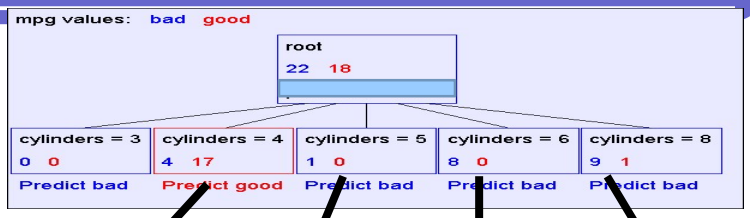
Records in which cylinders = 6

Records in which cylinders = 8

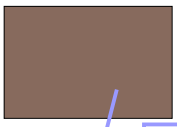
http://www.cs.cmu.edu/~awm/tutorials

61

Recursion Step



Build tree from These records..



Records in which cylinders = 4

Build tree from These records..



Records in which cylinders = 5

Build tree from These records..



Records in which cylinders = 6

Build tree from These records..

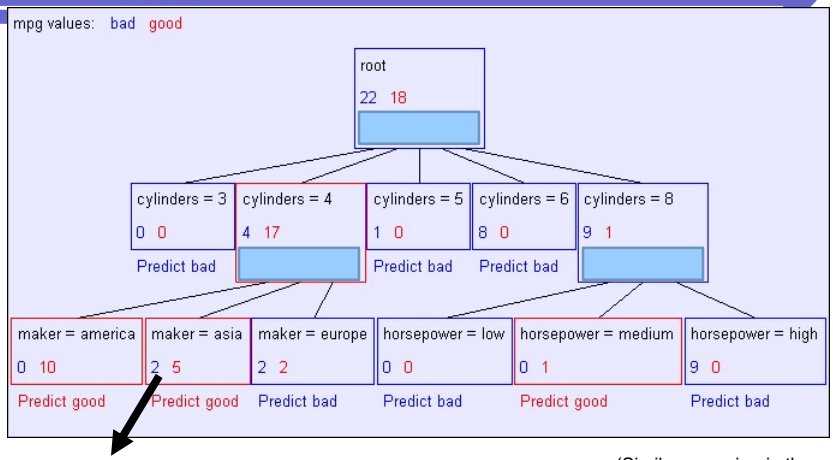


Records in which cylinders = 8

http://www.cs.cmu.edu/~awm/tutorials

62

Second level of tree



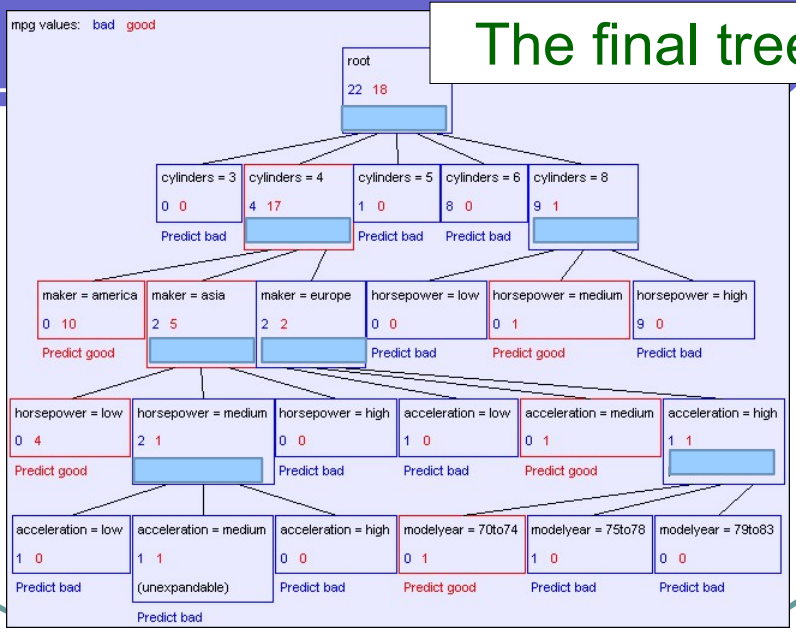
Recursively build a tree from the seven records in which there are four cylinders and the maker was based in Asia

(Similar recursion in the other cases)

http://www.cs.cmu.edu/~awm/tutorials

63

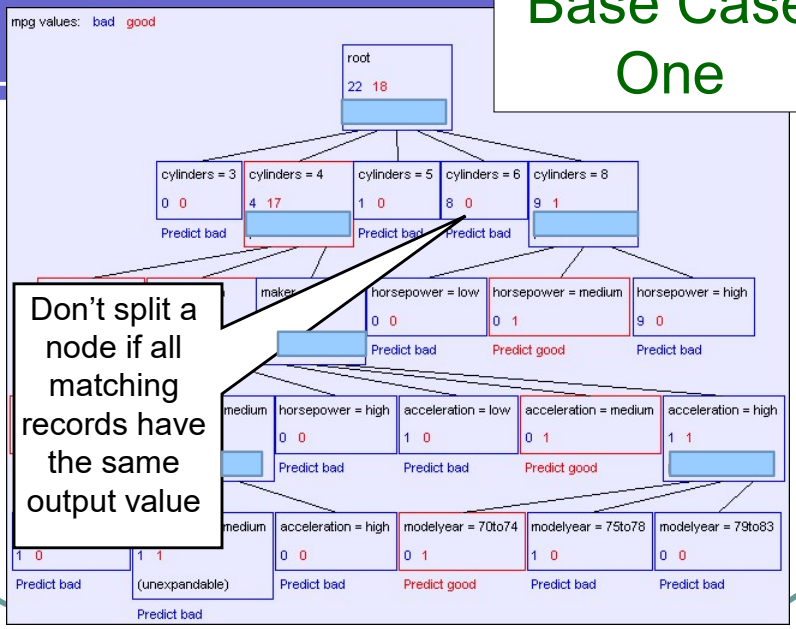
The final tree



http://www.cs.cmu.edu/~awm/tutorials

64

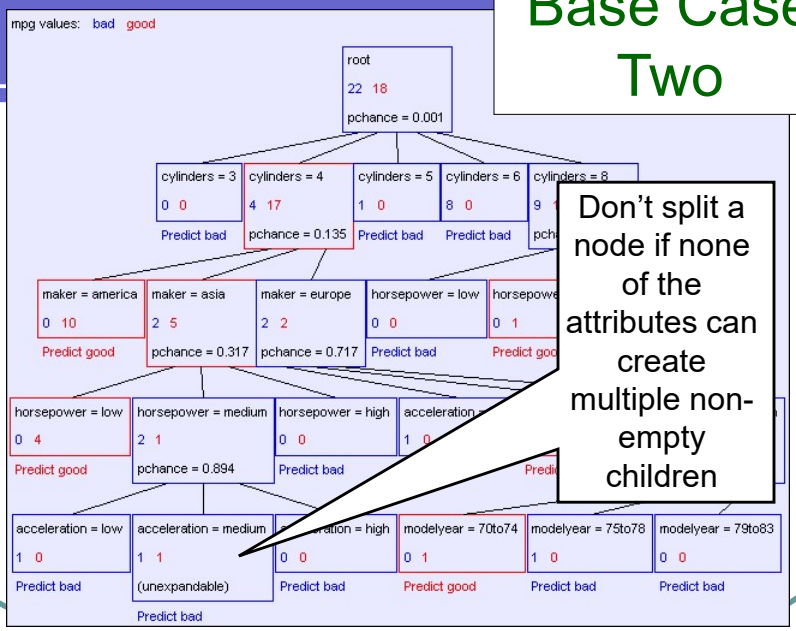
Base Case One



http://www.cs.cmu.edu/~awm/tutorials

65

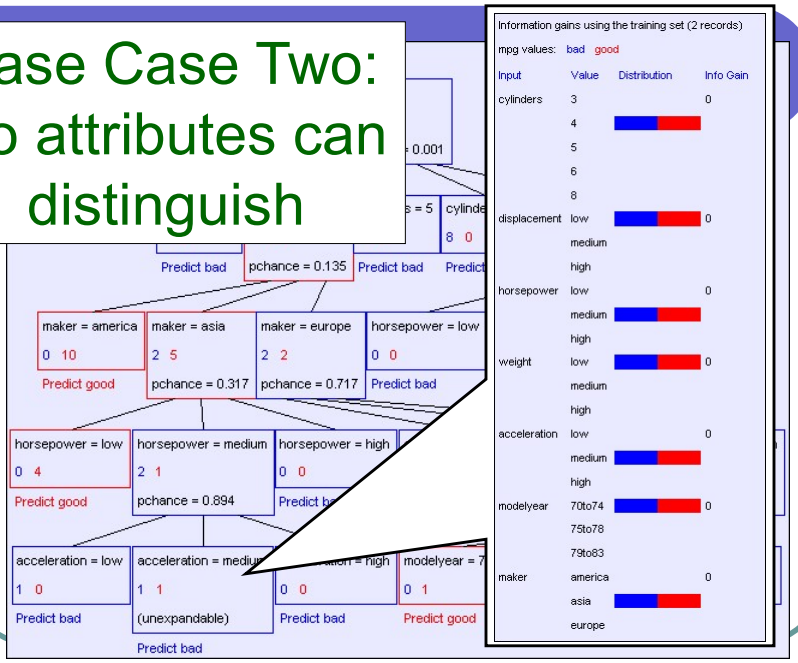
Base Case Two



http://www.cs.cmu.edu/~awm/tutorials

66

Base Case Two: No attributes can distinguish



http://www.cs.cmu.edu/~awm/tutorials

67

Base Cases

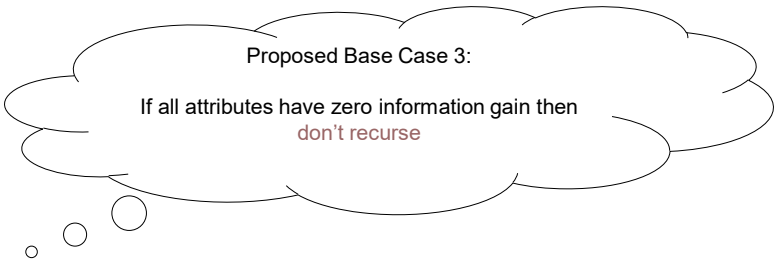
- Base Case One: If all records in current data subset have the same output then don't recurse
- Base Case Two: If all records have exactly the same set of input attributes then don't recurse

http://www.cs.cmu.edu/~awm/tutorials

68

Base Cases: An idea

- Base Case One: If all records in current data subset have the same output then don't recurse
- Base Case Two: If all records have exactly the same set of input attributes then don't recurse



Is this a good idea?•

http://www.cs.cmu.edu/~awm/tutorials

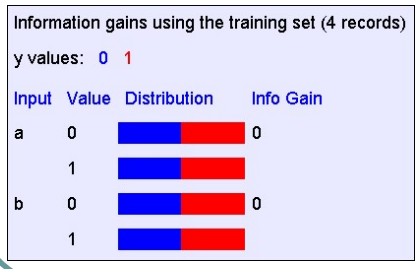
69

The problem with Base Case 3

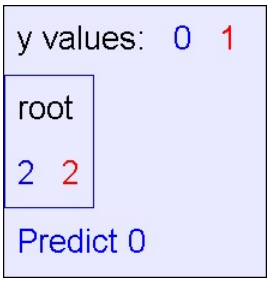
a	b	y
0	0	0
0	1	1
1	0	1
1	1	0

y = a XOR b

The information gains:



The resulting decision tree:



http://www.cs.cmu.edu/~awm/tutorials

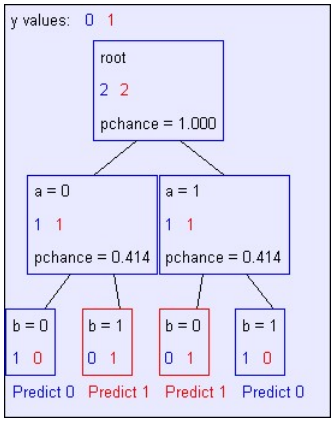
70

If we omit Base Case 3:

a	b	y
0	0	0
0	1	1
1	0	1
1	1	0

y = a XOR b

The resulting decision tree:



http://www.cs.cmu.edu/~awm/tutorials

71

Basic Decision Tree Building Summarized

BuildTree(*DataSet,Output*)

- If all output values are the same in *DataSet*, return a leaf node that says "predict this unique output"
- If all input values are the same, return a leaf node that says "predict the majority output"
- Else find attribute *X* with highest Info Gain
- Suppose *X* has n_X distinct values (i.e. X has arity n_X).
  - Create and return a non-leaf node with n_X children.
  - The *i*'th child should be built by calling

    BuildTree(DS_i,*Output*)

    Where DS_i built consists of all those records in DataSet for which X = *i*th distinct value of X.

http://www.cs.cmu.edu/~awm/tutorials

72

Training Set Error

- For each record, follow the decision tree to see what it would predict

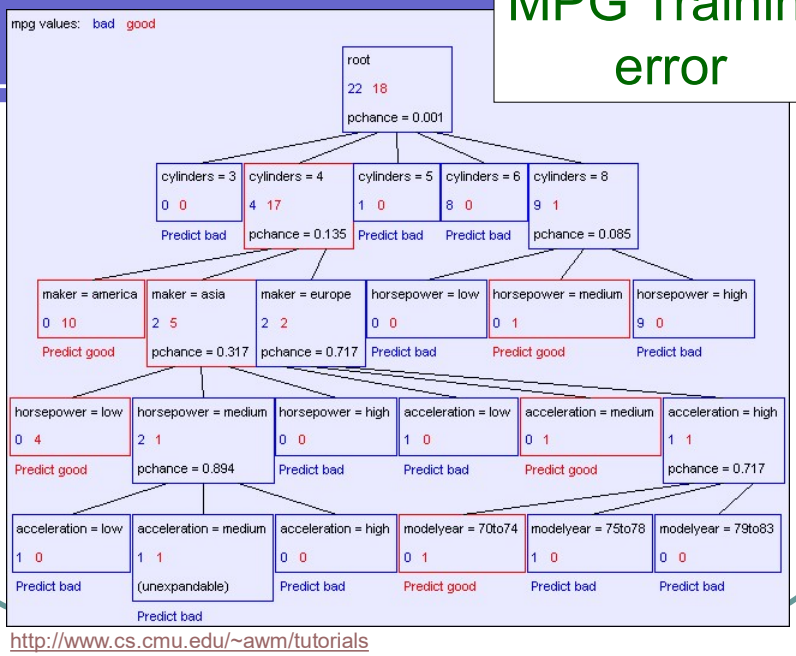
  For what number of records does the decision tree's prediction disagree with the true value in the database?

- This quantity is called the *training set error*. The smaller the better.

http://www.cs.cmu.edu/~awm/tutorials

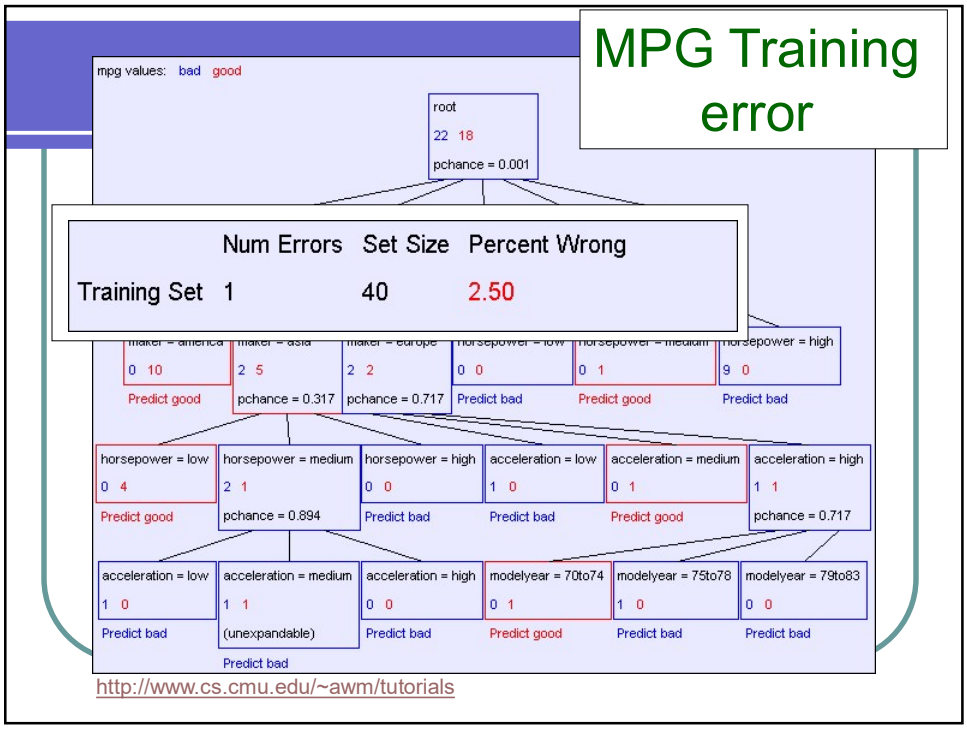
73

MPG Training error



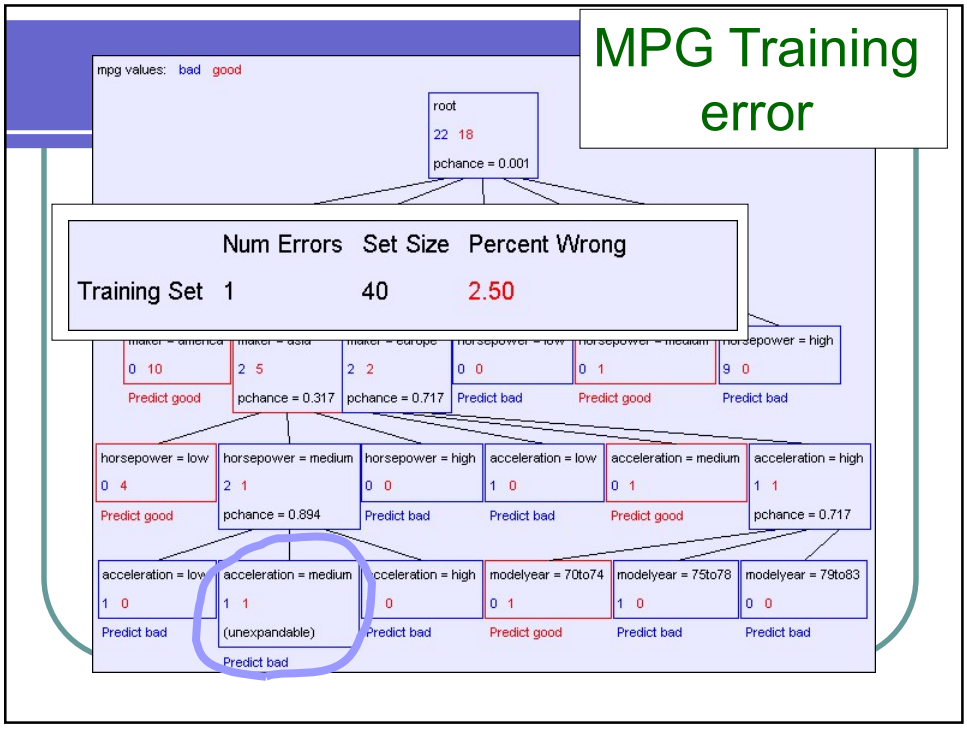
http://www.cs.cmu.edu/~awm/tutorials

74



http://www.cs.cmu.edu/~awm/tutorials

75



76

Stop and reflect: Why are we doing this learning anyway?

- It is not usually in order to predict the training data's output on data we have already seen.

http://www.cs.cmu.edu/~awm/tutorials

77

Stop and reflect: Why are we doing this learning anyway?

- It is not usually in order to predict the training data's output on data we have already seen.
- It is more commonly in order to predict the output value for future data we have not yet seen.

http://www.cs.cmu.edu/~awm/tutorials

78

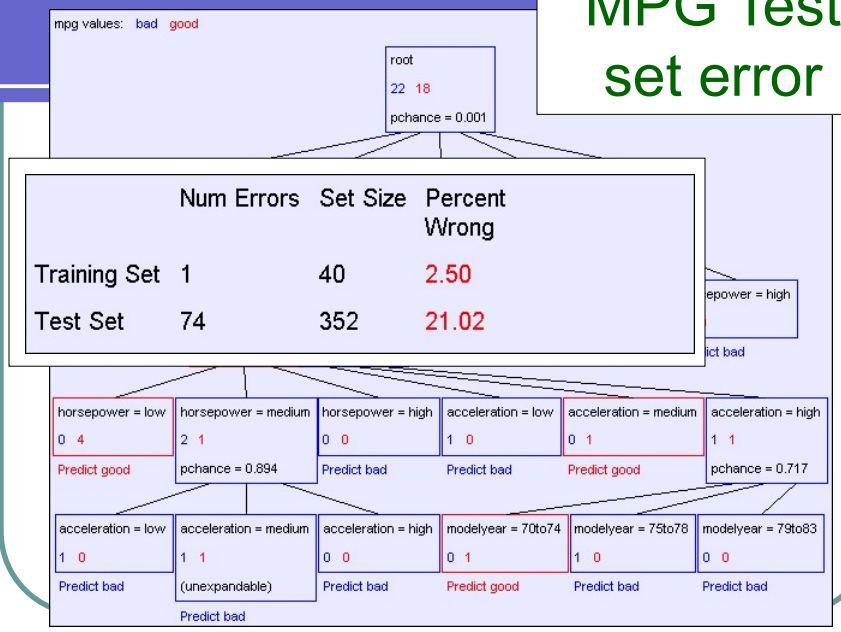
Test Set Error

- Suppose we are forward thinking.
- We hide some data away when we learn the decision tree.
- But once learned, we see how well the tree predicts that data.
- This is a good simulation of what happens when we try to predict future data.
- And it is called Test Set Error.

http://www.cs.cmu.edu/~awm/tutorials

79

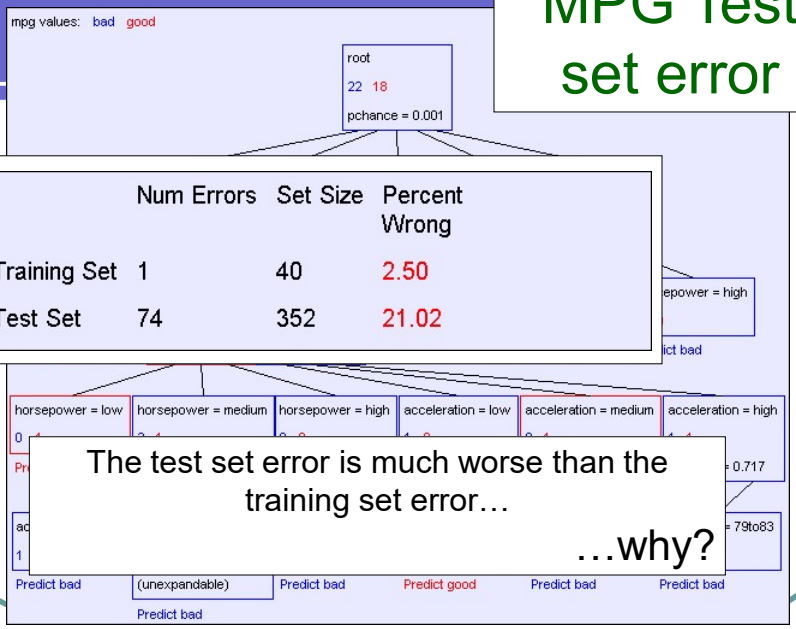
MPG Test set error



http://www.cs.cmu.edu/~awm/tutorials

80

MPG Test set error



http://www.cs.cmu.edu/~awm/tutorials

81

Overfitting

- Definition: If your machine learning algorithm fits noise (i.e. pays attention to parts of the data that are irrelevant) it is overfitting.
- Fact (theoretical and empirical): If your machine learning algorithm is overfitting then it may perform less well on test set data.

http://www.cs.cmu.edu/~awm/tutorials

82

Overfitting

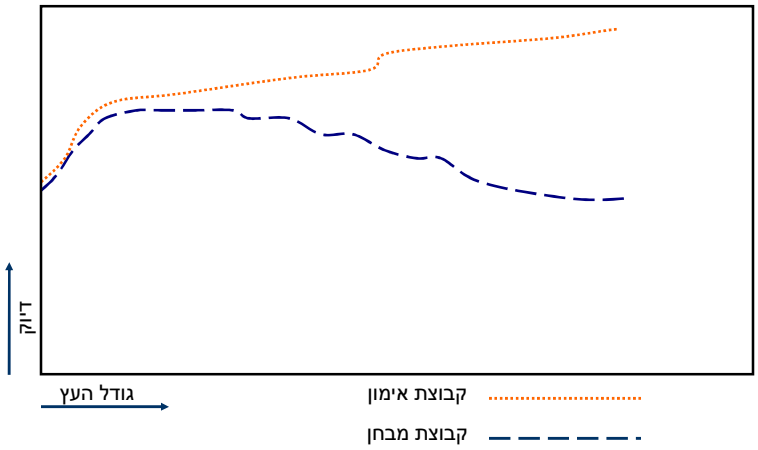
- נסמן את הטעות של h על קבוצת האימון כ- $Error_{train}(h)$
- ואת הטעות של h על כלל ה"עולם" (התפלגות D) כ- $Error_D(h)$

- Hypothesis h ∈ H overfitts the training data if there is another hypothesis h' ∈ H such that:
  - $Error_{train}(h) < Error_{train}(h')$

  And
  - $Error_D(h') < Error_D(h)$

83

Overfitting



84

איך להימנע מ-overfitting

- להפסיק ל"גדל" את העץ כאשר חלוקת הנתונים אינה משמעותית סטטיסטית ***pre-pruning***
- ל"גדל" את העץ עד הסוף לפי האלגוריתם אבל לבצע "קיצוץ" ***post-pruning***

85

Post-Pruning (Reduced-Error Pruning)

- חלק את קבוצת האימון לקבוצת "יצירת עץ" וקבוצת "תיקוף"
- צור עץ החלטה – overfitting תוך שימוש בקבוצת "יצירת עץ"
- שלב קיצוץ בדיעבד – בצע כל זמן שלא נפגעים הביצועים יותר
  - עבור כל צומת פנימי (לא שורש) בצע
    - קצץ את תת-העץ של צומת זה (הפיכת הצומת לעלה) – החלטה עבור צומת זה לפי הצבעת רוב בתת-העץ שלו
    - בחן ביצועי העץ המקוצץ על קבוצת התיקוף והשווה ביצועים לעץ הלא-מקוצץ
  - באופן חמדני קצץ בצומת עם הרווח הגדול ביותר

86

עצי החלטה - סיכום

- <u>יתרונות:</u>
  - קלים להבנה/"למידה"
  - קלים למימוש
  - קלים לשימוש/"הפעלת ה"מכונה" על נתונים חדשים"
  - זולים (יחסית) חישובית
- <u>חסרונות:</u>
  - נוטים ל-overfitting

87

תרגיל – עצי החלטה

88

תרגיל

- נניח שברשותי שלושה מטבעות: מטבע של 10 שקלים, מטבע של חמישה שקלים ומטבע של שקל. אני זורק את שלושת המטבעות בו-זמנית ורושם את תוצאות הזריקה ("עץ" או "פלי"). נתונה טבלת המאורעות:

	"שקל"	10 ש"ח	סיווג - 5ש"ח
1	"עץ"	"עץ"	"פלי"
2	"עץ"	"פלי"	"עץ"
3	"פלי"	"עץ"	"עץ"
4	"עץ"	"פלי"	"פלי"
5	"פלי"	"פלי"	"פלי"
6	"עץ"	"פלי"	"עץ"

חשב עץ החלטה המסווג תוצאת זריקת מטבע של חמישה ₪ על סמך ידיעת הטלת מטבע שקל ומטבע של 10 ₪

האם בכלל ניתן לחזות תוצאת הטלת מטבע 5 ₪ על בסיס ידע של הטלות של מטבעות אחרים???

89

תרגיל

- נניח שברשותי שלושה מטבעות: מטבע של 10 שקלים, מטבע של חמישה שקלים ומטבע של שקל. אני זורק את שלושת המטבעות בו-זמנית ורושם את תוצאות הזריקה ("עץ" או "פלי"). נתונה טבלת המאורעות:

	"שקל"	10 ש"ח	Y - סיווג - 5ש"ח
1	"עץ"	"עץ"	"פלי"
2	"עץ"	"פלי"	"עץ"
3	"פלי"	"עץ"	"עץ"
4	"עץ"	"פלי"	"פלי"
5	"פלי"	"פלי"	"פלי"
6	"עץ"	"פלי"	"עץ"

פתרון: נסמן הטלת מטבע 5 ₪ כ-Y, הטלת מטבע "שקל" ב-A והטלת מטבע 10 ₪ ב-B.
נחשב InformationGain(Y|A) נחשב InformationGain(Y|B) ונכריע לפי איזו תכונה כדאי לשאול בראש העץ

90

תרגיל

- נניח שברשותי שלושה מטבעות: מטבע של 10 שקלים, מטבע של חמישה שקלים ומטבע של שקל. אני זורק את שלושת המטבעות בו-זמנית ורושם את תוצאות הזריקה ("עץ" או "פלי"). נתונה טבלת המאורעות:

	"שקל"	10 ש"ח	Y - סיווג - 5ש"ח
1	"עץ"	"עץ"	"פלי"
2	"עץ"	"פלי"	"עץ"
3	"פלי"	"עץ"	"עץ"
4	"עץ"	"פלי"	"פלי"
5	"פלי"	"פלי"	"פלי"
6	"עץ"	"פלי"	"עץ"

נחשב את האנתרופיה של מטבע 5 ₪ H(Y) עבור ששת הזריקות:

P(ets) = 3/6=0.5

P(Pali) = 3/6 = 0.5

$$H(Y) = -0.5\log_{0.5} - 0.5\log_{0.5} = 0.5 + 0.5 = 1$$

91

תרגיל

	"שקל"	10 ש"ח	Y - סיווג - 5ש"ח
1	"עץ"	"עץ"	"פלי"
2	"עץ"	"פלי"	"עץ"
3	"פלי"	"עץ"	"עץ"
4	"עץ"	"פלי"	"פלי"
5	"פלי"	"פלי"	"פלי"
6	"עץ"	"פלי"	"עץ"

נחשב את האנתרופיה הספציפית של מטבע 5 ₪ בהינתן שתוצאת הטלת מטבע "שקל" הינה "עץ".

$$P(Y = ets \mid A = ets) = 0.5$$
$$P(Y = pali \mid A = ets) = 0.5$$
$$H(Y \mid A = ets) = 1$$

92

תרגיל

	"שקל"	10 ש"ח	Y - סיווג - 5ש"ח
1	"עץ"	"עץ"	"פלי"
2	"עץ"	"פלי"	"עץ"
3	"פלי"	"עץ"	"עץ"
4	"עץ"	"פלי"	"פלי"
5	"פלי"	"פלי"	"פלי"
6	"עץ"	"פלי"	"עץ"

נחשב את האנתרופיה הספציפית של מטבע 5 ₪ בהינתן שתוצאת הטלת מטבע "שקל" הינה "פלי".

$$P(Y = ets \mid A = pali) = 0.5$$
$$P(Y = pali \mid A = pali) = 0.5$$
$$H(Y \mid A = pali) = 1$$

93

תרגיל

	"שקל"	10 ש"ח	Y - סיווג - 5ש"ח
1	"עץ"	"עץ"	"פלי"
2	"עץ"	"פלי"	"עץ"
3	"פלי"	"עץ"	"עץ"
4	"עץ"	"פלי"	"פלי"
5	"פלי"	"פלי"	"פלי"
6	"עץ"	"פלי"	"עץ"

נחשב את האנתרופיה הספציפית של מטבע 5 ₪ בהינתן הטלת מטבע "שקל"

$$H(Y \mid A) = \sum_j P(A = \alpha_j) H(Y \mid A = \alpha_j)$$
$$= p(A = ets) H(Y \mid A = ets) + p(A = pali) H(Y \mid A = pali)$$
$$= \frac{2}{3} \times 1 + \frac{1}{3} \times 1 = 1$$

94

תרגיל

	"שקל"	10 ש"ח	Y - סיווג - 5ש"ח
1	"עץ"	"עץ"	"פלי"
2	"עץ"	"פלי"	"עץ"
3	"פלי"	"עץ"	"עץ"
4	"עץ"	"פלי"	"פלי"
5	"פלי"	"פלי"	"פלי"
6	"עץ"	"פלי"	"עץ"

נחשב את האנתרופיה הספציפית של מטבע 5 ₪ בהינתן הטלת מטבע "10 שקל

$P(Y=ets \mid B=pali)=0.5$	$P(Y=ets \mid B=ets)=0.5$
$P(Y=pali \mid B=pali)=0.5$	$P(Y=pali \mid B=ets)=0.5$
$H(Y \mid B=pali)=1$	$H(Y \mid B=ets)=1$

$$H(Y \mid B)=\sum_j P(B=\alpha_j)H(Y \mid B=\alpha_j)$$
$$=p(B=ets)H(Y \mid B=ets)+p(B=pali)H(Y \mid B=pali)$$
$$=\frac{1}{3}\times 1+\frac{2}{3}\times 1=1$$

95

תרגיל

	"שקל"	10 ש"ח	Y - סיווג - 5ש"ח
1	"עץ"	"עץ"	"פלי"
2	"עץ"	"פלי"	"עץ"
3	"פלי"	"עץ"	"עץ"
4	"עץ"	"פלי"	"פלי"
5	"פלי"	"פלי"	"פלי"
6	"עץ"	"פלי"	"עץ"

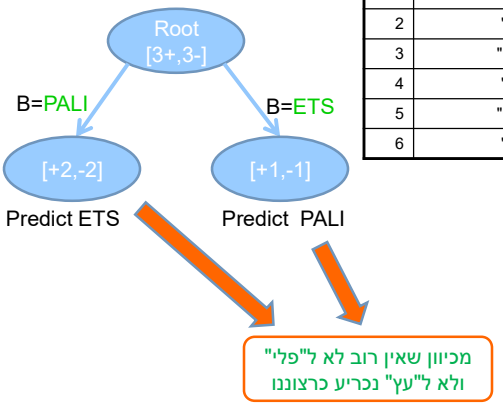
$$IG(Y \mid A)=H(Y)-H(Y \mid A)=1-1=0$$
$$IG(Y \mid B)=H(Y)-H(Y \mid B)=1-1=0$$

שתי התכונות שוות ב"איכות" שלהן. כפי שראינו בהרצאה infoGain=0 זו לא סיבה להפסיק בבניית העץ. נבחר את התכונה 10 ₪ לשורש של העץ

96

תרגיל

	"שקל"	10 ש"ח	Y - סיווג - 5ש"ח
1	"עץ"	"עץ"	"פלי"
2	"עץ"	"פלי"	"עץ"
3	"פלי"	"עץ"	"עץ"
4	"עץ"	"פלי"	"פלי"
5	"פלי"	"פלי"	"פלי"
6	"עץ"	"פלי"	"עץ"



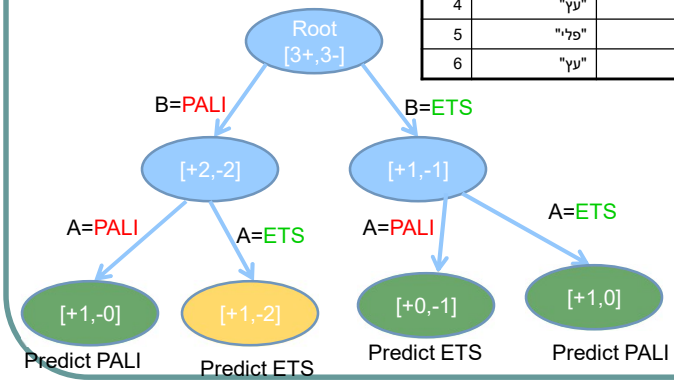
97

תרגיל

PALI = +

ETS = -

	"שקל"	10 ש"ח	Y - סיווג - 5ש"ח
1	"עץ"	"עץ"	"פלי"
2	"עץ"	"פלי"	"עץ"
3	"פלי"	"עץ"	"עץ"
4	"עץ"	"פלי"	"פלי"
5	"פלי"	"פלי"	"פלי"
6	"עץ"	"פלי"	"עץ"

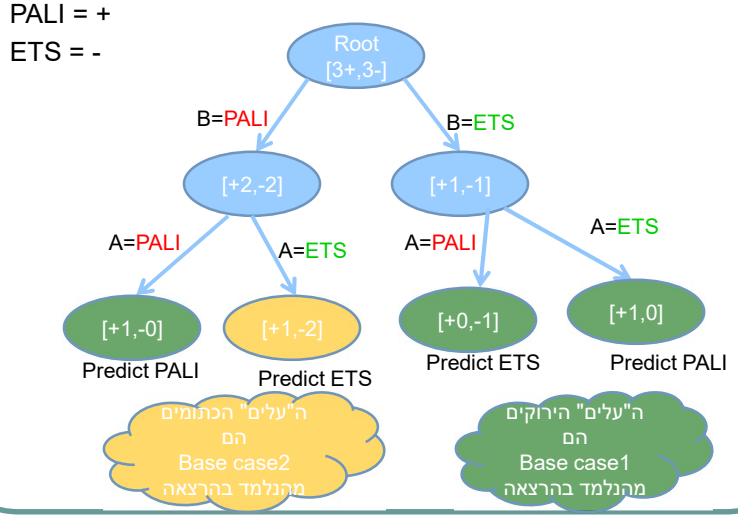


98

תרגיל

PALI = +

ETS = -



99

תרגיל

PALI = +

ETS = -

מהו הדיוק אליו הגענו על **קבוצת האימון**? חשב את ה-TP ואת ה-FP

Positive = PALI, Negative = ETS

תשובה: סה"כ #N = 3, #P = 3

TP = 2/3 = 0.66

FP = 0/3 = 0

האם זה אומר שאני נביא שיכול לחזות ע"י הטלת מטבעות של 1 ₪ ושל 10 ₪ את תוצאת הטלת מטבע 5 ₪ בהסתברות יותר טובה ממקרית?

תשובה: וודאי שלא. זה אומר שקבוצת האימון קטנה מדי. לאחר מספר חזרות רב של הניסוי הטעות שלנו גם על קבוצת האימון תגדל (יהיו שורות עם ערך זהה עבור הטלת 1 ₪ והטלת 10 ₪ אבל ערכים שונים עבור הטלת מטבע 5 ₪)

100