למידת מכונה

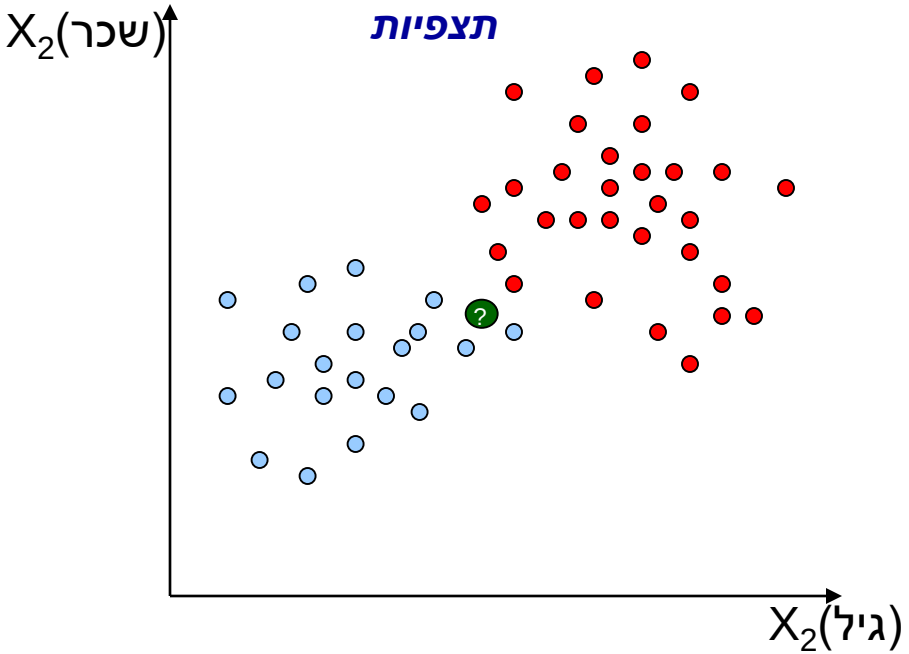
K-Nearest Neighbor (KNN)

בעיית סיווג - Classification

- נתונה קבוצת אימון של ווקטורים "מסווגים"
- בהינתן ווקטור חדש – מצא את הסיווג המתאים לו.

דוגמא (המשך)

- בעיה דו-מימדית (כל ווקטור מכיל שני ערכים)
- בעיה בינארית (כל ווקטור מסווג כאחת משתי אפשרויות)



K-nearest Neighbors

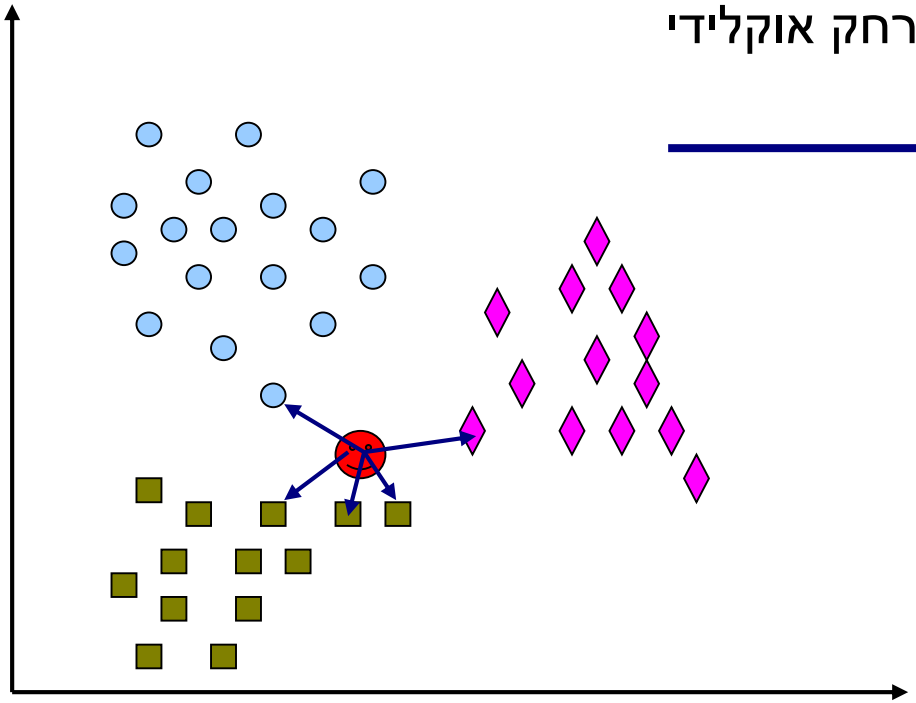
- “Instance-Based” approach
  - אינטואיציה: נסווג דוגמא חדשה בהתבסס על **הדמיון** שלה לדוגמאות מקבוצת האימון.
  - עבור דוגמא חדשה $X \in R^D$ מצא את K ה"שכנים הקרובים" של הדוגמא (כמובן שכנים עליהם ידוע הסיווג) וסווג עפ"י הסיווג של רוב השכנים.

K-nearest Neighbors

- נקבל הכרעה לפי K ה"שכנים הקרובים" ביותר לווקטור עליו "שואלים".
- למשל, עבור K=5, אם לפחות 3 שכנים קרובים אומרים "יקנה" נכריע "יקנה". אם לפחות 3 שכנים אומרים "לא יקנה", נכריע "לא יקנה".
- עבור K=1 נכריע לפי השכן הקרוב ביותר.

דוגמא - K-nearest Neighbors

- בעיה דו-מימדית
- 3 "מחלקות"(classes)
- נשתמש במטריקה של מרחק אוקלידי
- עבור K=5
- נסווג את הדוגמא כ-



K-nearest Neighbors

- “Lazy” learning algorithm כלומר, דוחה את עיבוד הנתונים עד לקבלת נקודה חדשה לסיווג.

KNN לא מניח איזשהם הנחות על התפלגות הנתונים

KNN עובד מיידית גם על "ריבוי מחלקות"

Regression using 1NN

Univariate 1-Nearest Neighbor

Given datapoints (x_1, y_1) (x_2, y_2)..(x_N, y_N), where we assume $y_i = f(x_i)$ for some unknown function f.

Given query point x_q, your job is to predict $\hat{y} = \hat{f}(x_q)$

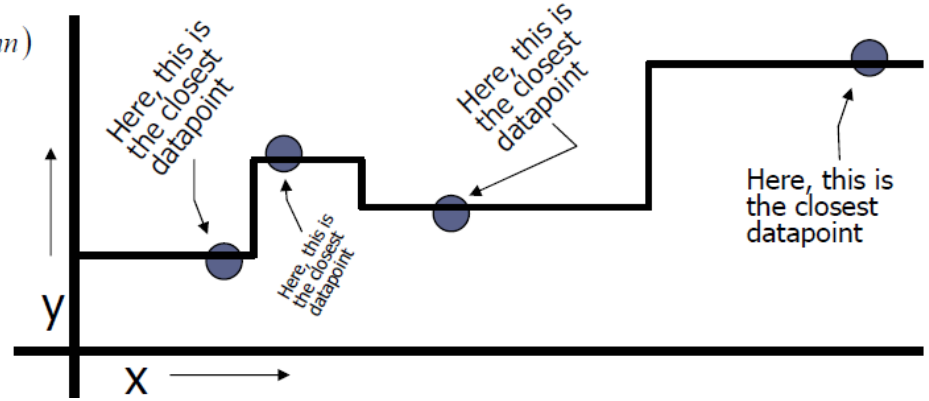
Nearest Neighbor:

1. Find the closest x_i in our set of datapoints

$$i(nn) = \underset{i}{\operatorname{argmin}} |x_i - x_q|$$

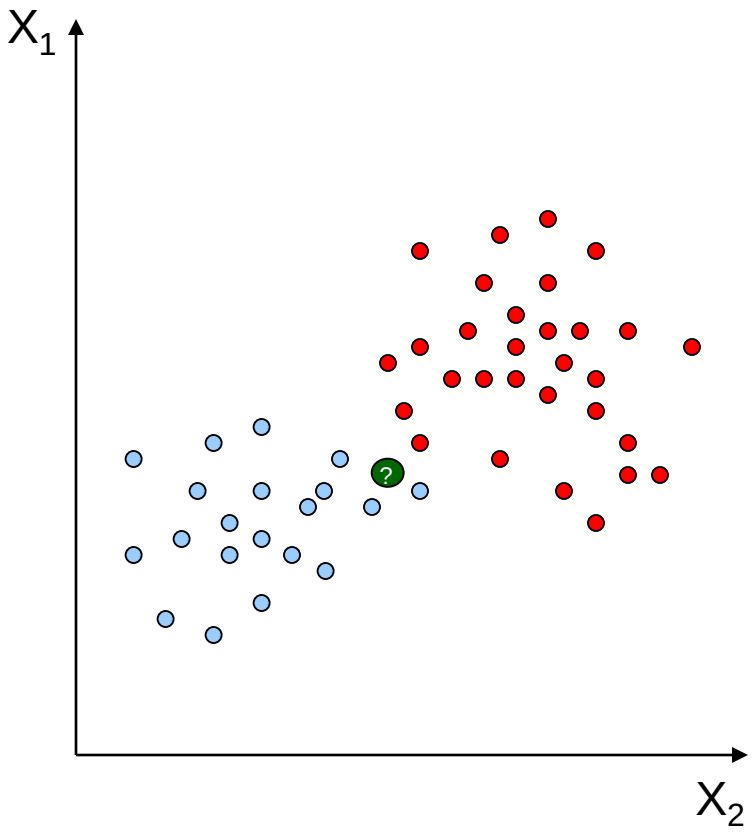
2. Predict $\hat{y} = y_{i(nn)}$

Here's a dataset with one input, one output and four datapoints.



http://www.cs.cmu.edu/~awm/tutorials

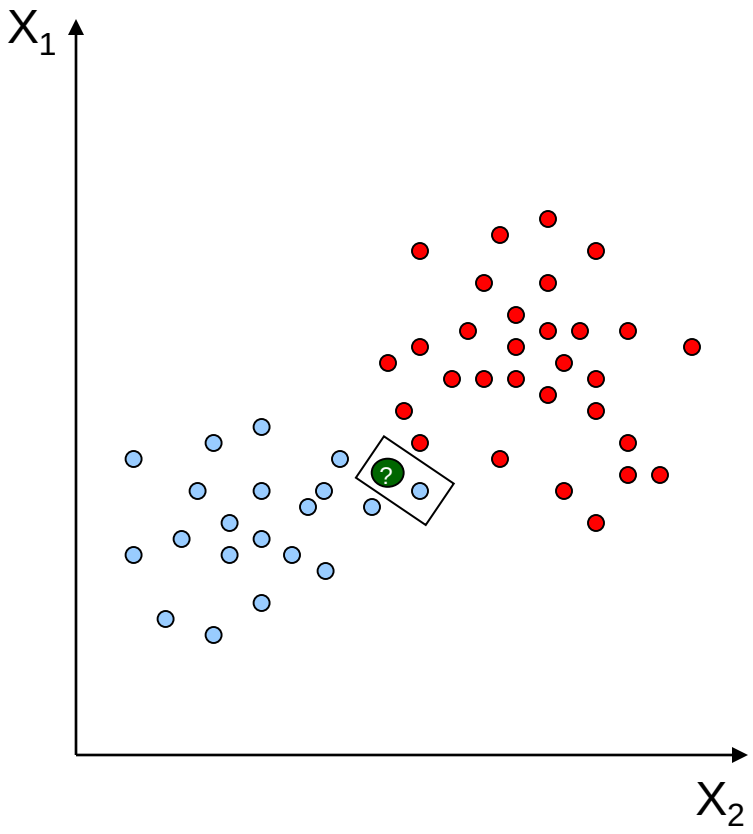
K-nearest Neighbors



An object is classified by a majority vote of its K-neighbors

For k=1: Classify as **blue**

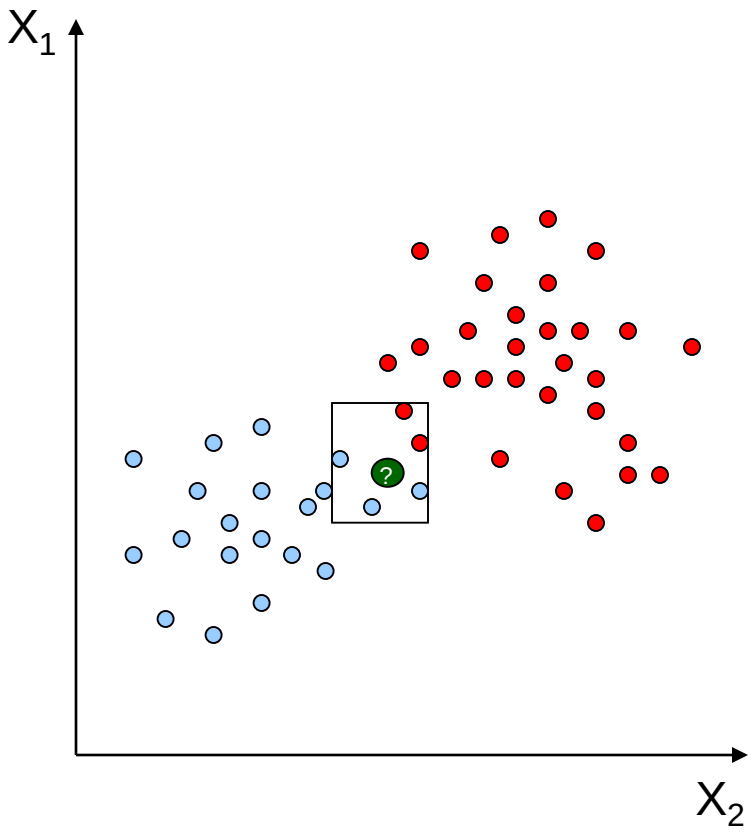
K-nearest Neighbors



An object is classified by a majority vote of its K-neighbors

For k=1: Classify as **blue**

K-nearest Neighbors



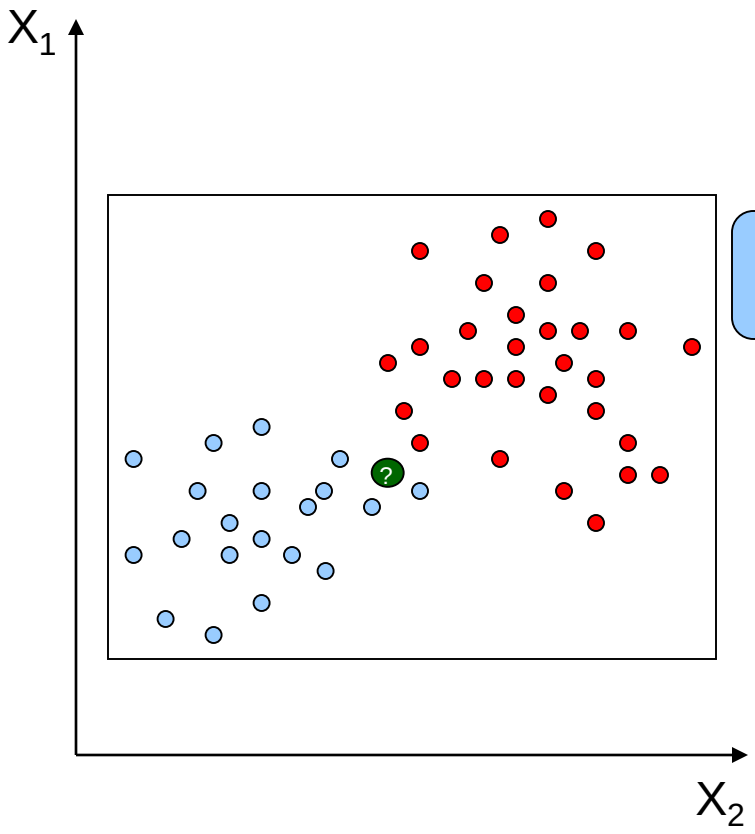
An object is classified by a majority vote of its K-neighbors

For k=1: Classify as blue

For k=5: Classify as blue

(3 “says” blue, 2 says “Red”)

K-nearest Neighbors



An object is classified by a majority vote of its K-neighbors

Likelihood

For k=1: Classify as “blue”

For k=5: Classify as “blue”

(3 says “blue”, 2 says “Red”)

For k=50: Classify as “Red”

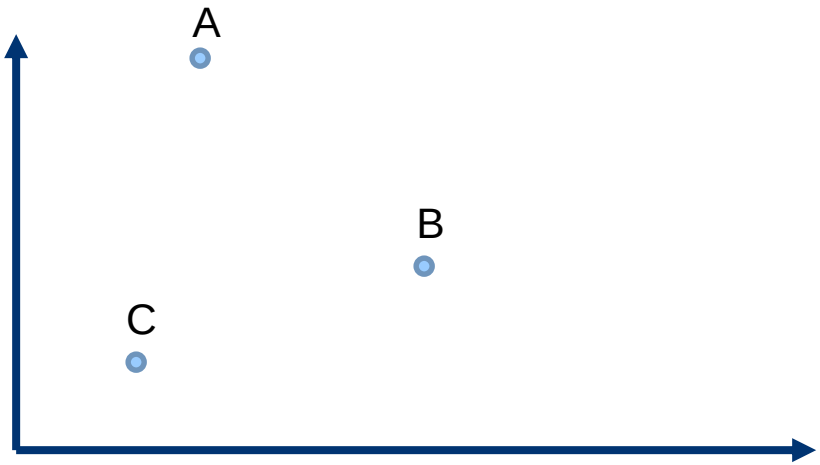
(20 says “blue”, 30 says “Red”)

Prior

KNN

- מטריקת מרחק
- משקול המאפיינים
- משקול מרחקים
- כמה "שכנים" לקחת בחשבון

Distance Metrics



- Metric distances:
  1. $d_{ab} >= 0$
  2. $d_{ab} = d_{ba}$
  3. $d_{aa} = 0$
  4. $d_{ab} <= d_{ac} + d_{cb}$

Distance Metrics

Minkowski distance

$$d(i,j) = \sqrt[q]{(|x_{i_1} - x_{j_1}|^q + |x_{i_2} - x_{j_2}|^q + ... + |x_{i_p} - x_{j_p}|^q)}$$

(*q = 1*), Manhattan distance (semi-metric distance)
(A.K.A Manhattan, taxicab, L_1 norm)

$$d(i,j) = |x_{i_1} - x_{j_1}| + |x_{i_2} - x_{j_2}| + ... + |x_{i_p} - x_{j_p}|$$

(*q = 2*), Euclidean distance (metric distance)

$$d(i,j) = \sqrt{(|x_{i_1} - x_{j_1}|^2 + |x_{i_2} - x_{j_2}|^2 + ... + |x_{i_p} - x_{j_p}|^2)}$$

($q \to \infty$), "supremum" (L_{max} norm, L_∞ norm) distance.
The maximum difference between any component of the vectors

Minkowski distance

- X = (0,2,3,7)
- Y = (2,1,1,3)

- L_1 = |2-0|+|1-2|+|1-3|+|3-7| = 9
- $L_2 = \sqrt{|2-0|^2 + |1-2|^2 + |1-3|^2 + |3-7|^2} = \sqrt{4+1+4+16} = 5$
- L_∞ = max(|2-0|,|1-2|,|1-3|,|3-7|) = 4

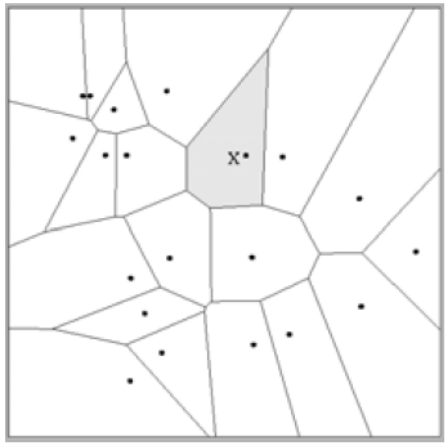
Multivariate analysis

Voronoi Diagram:
Input Description: A set *S* of points *p_1,...,p_n*.
Problem: Decompose the space into regions around each point, such that all the points in the region around *p_i* are closer to *p_i* than any other point in *S*.

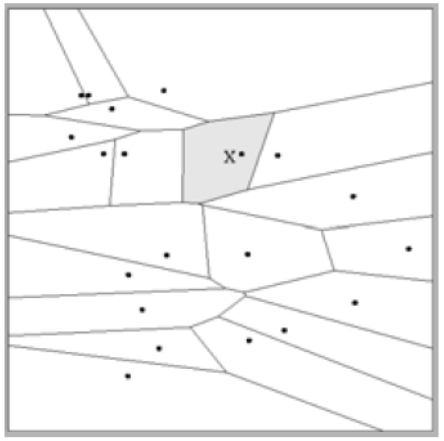
Suppose the input vectors x1, x2, ...xn are two dimensional:

$\mathbf{x}_1 = (x_{11} , x_{12})$, $\mathbf{x}_2 = (x_{21} , x_{22})$, ...$\mathbf{x}_N = (x_{N1} , x_{N2})$.

One can draw the nearest-neighbor regions in input space.



$Dist(\mathbf{x}_i, \mathbf{x}_j) = (x_{i1} - x_{j1})^2 + (x_{i2} - x_{j2})^2$



$Dist(\mathbf{x}_i, \mathbf{x}_j) = (x_{i1} - x_{j1})^2 + (3x_{i2} - 3x_{j2})^2$

The relative scalings in the distance metric affect region shapes.

http://www.cs.cmu.edu/~awm/tutorials

Feature weighting

- KNN רגיש מאוד לצירים "רועשים", טווחי ערכים שונים
- פתרון א': לנרמל את הצירים לתחום קבוע
- פתרון ב': לתת משקל שונה לכל מימד (כך נפתור גם בעיה שעדיין קיימת בפתרון א': לעיתים חלק מהמימדים (כמעט) לא תורמים לסיווג)

For the Euclidean Distance metric

$$D(\mathrm{x},\mathrm{x}') = \sqrt{\sum_i \sigma_i^{\,2}\left(x_i - x'_i\right)^2}$$

Or equivalently,

$$D(\mathrm{x},\mathrm{x}') = \sqrt{(\mathrm{x}-\mathrm{x}')^T \sum (\mathrm{x}-\mathrm{x}')}$$

where

$$\Sigma = \begin{bmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \cdots & \cdots & \cdots & \cdots \\ 0 & 0 & \cdots & \sigma_N^2 \end{bmatrix}$$

http://www.cs.cmu.edu/~awm/tutorials

For the Euclidean Distance metric

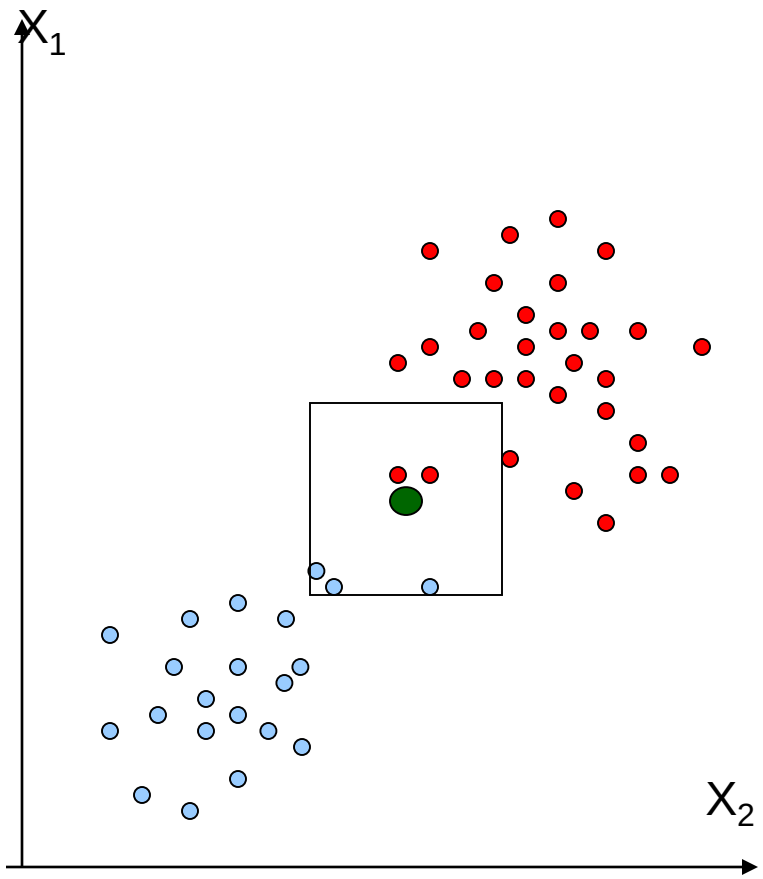
$$X_1 = \begin{bmatrix} 6 \\ 1 \\ 5 \\ 5 \end{bmatrix} \qquad X_2 = \begin{bmatrix} 3 \\ 7 \\ 1 \\ 2 \end{bmatrix} \qquad \Sigma = \begin{bmatrix} 3 & & & \\ & 2 & & \\ & & 1 & \\ & & & 7 \end{bmatrix}$$

$$X_1^1 - X_2^1 = (6-3) = 3$$
$$X_1^2 - X_2^2 = (1-7) = -6$$
$$X_1^3 - X_2^3 = (5-1) = 4$$
$$X_1^4 - X_2^4 = (5-2) = 3$$
$$X_1 - X_2 = (3,-6,4,3)^T$$

$$D(X_1, X_2) = \sqrt{(3,-6,4,3)\begin{bmatrix} 3 & & & \\ & 2 & & \\ & & 1 & \\ & & & 7 \end{bmatrix}\begin{bmatrix} 3 \\ -6 \\ 4 \\ 3 \end{bmatrix}} = \sqrt{[9,-12,4,21]\begin{bmatrix} 3 \\ -6 \\ 4 \\ 3 \end{bmatrix}} = \sqrt{178}$$

http://www.cs.cmu.edu/~awm/tutorials

ומה נעשה במצב כזה?



For k=5: Classify as blue

(3 “says” blue, 2 says “Red”)

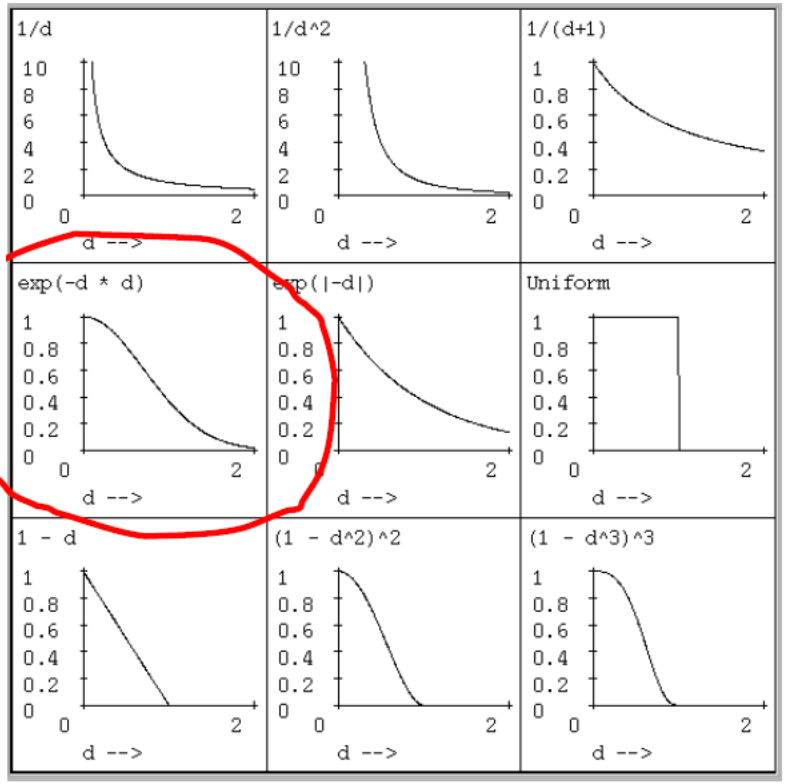
Weighting neighbors

Let

$d = D(x_i, x_{query})/K_W$

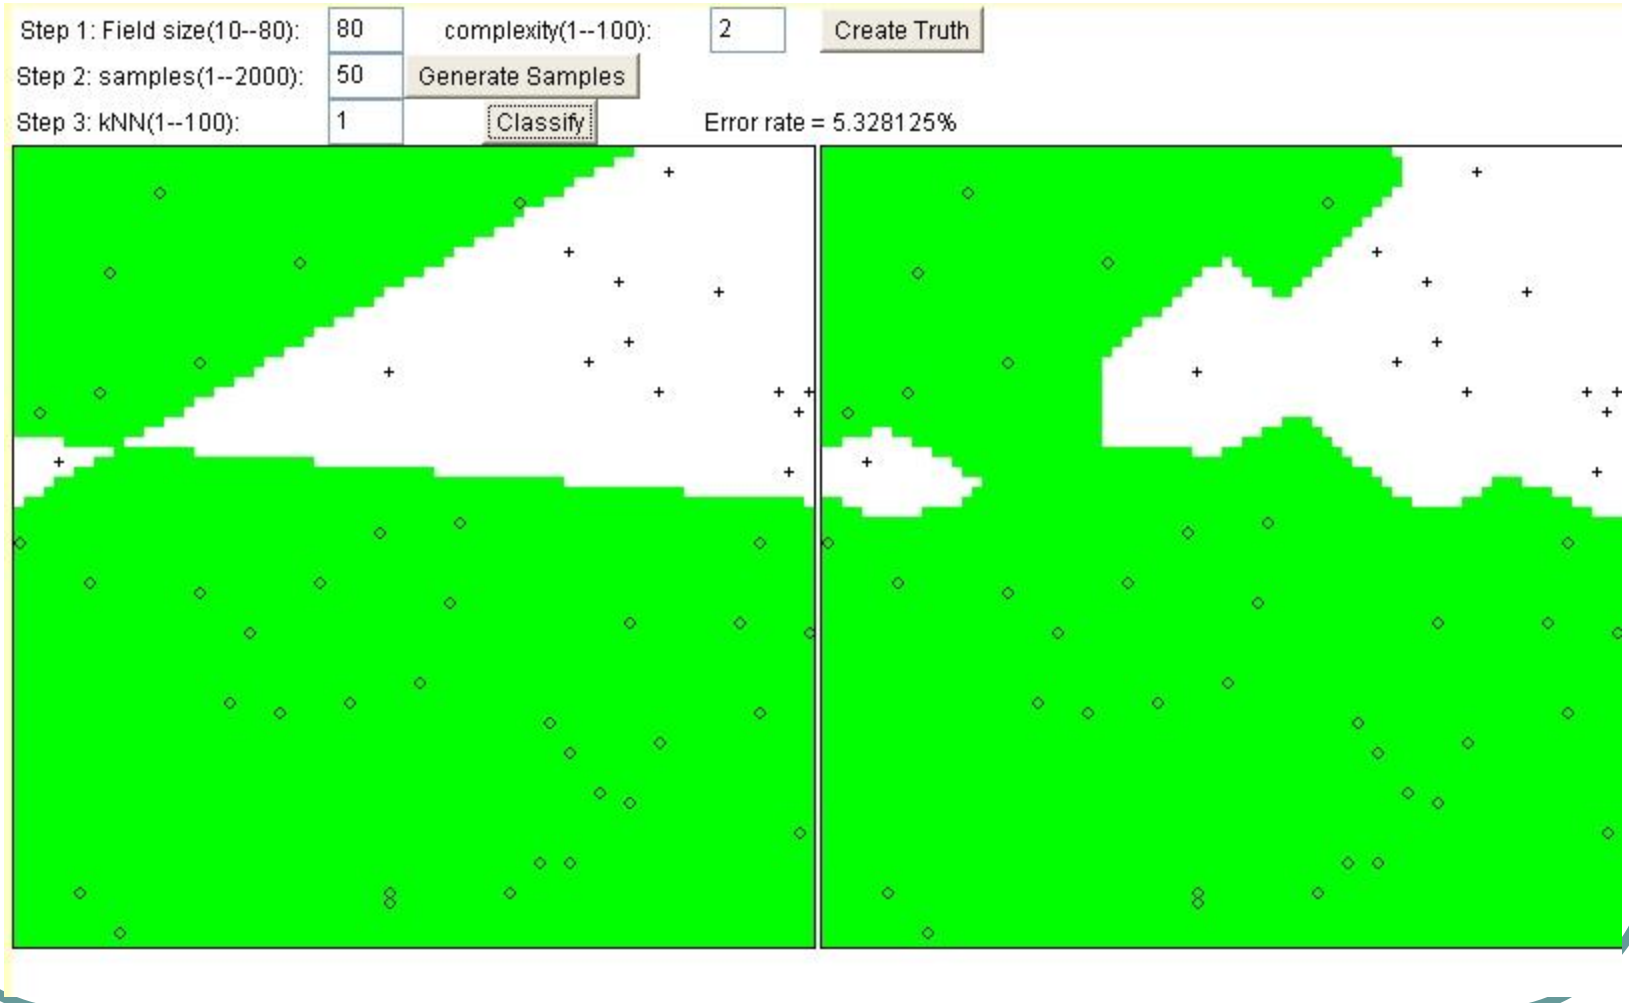
Then here are some commonly used weighting functions…

(we use a Gaussian)



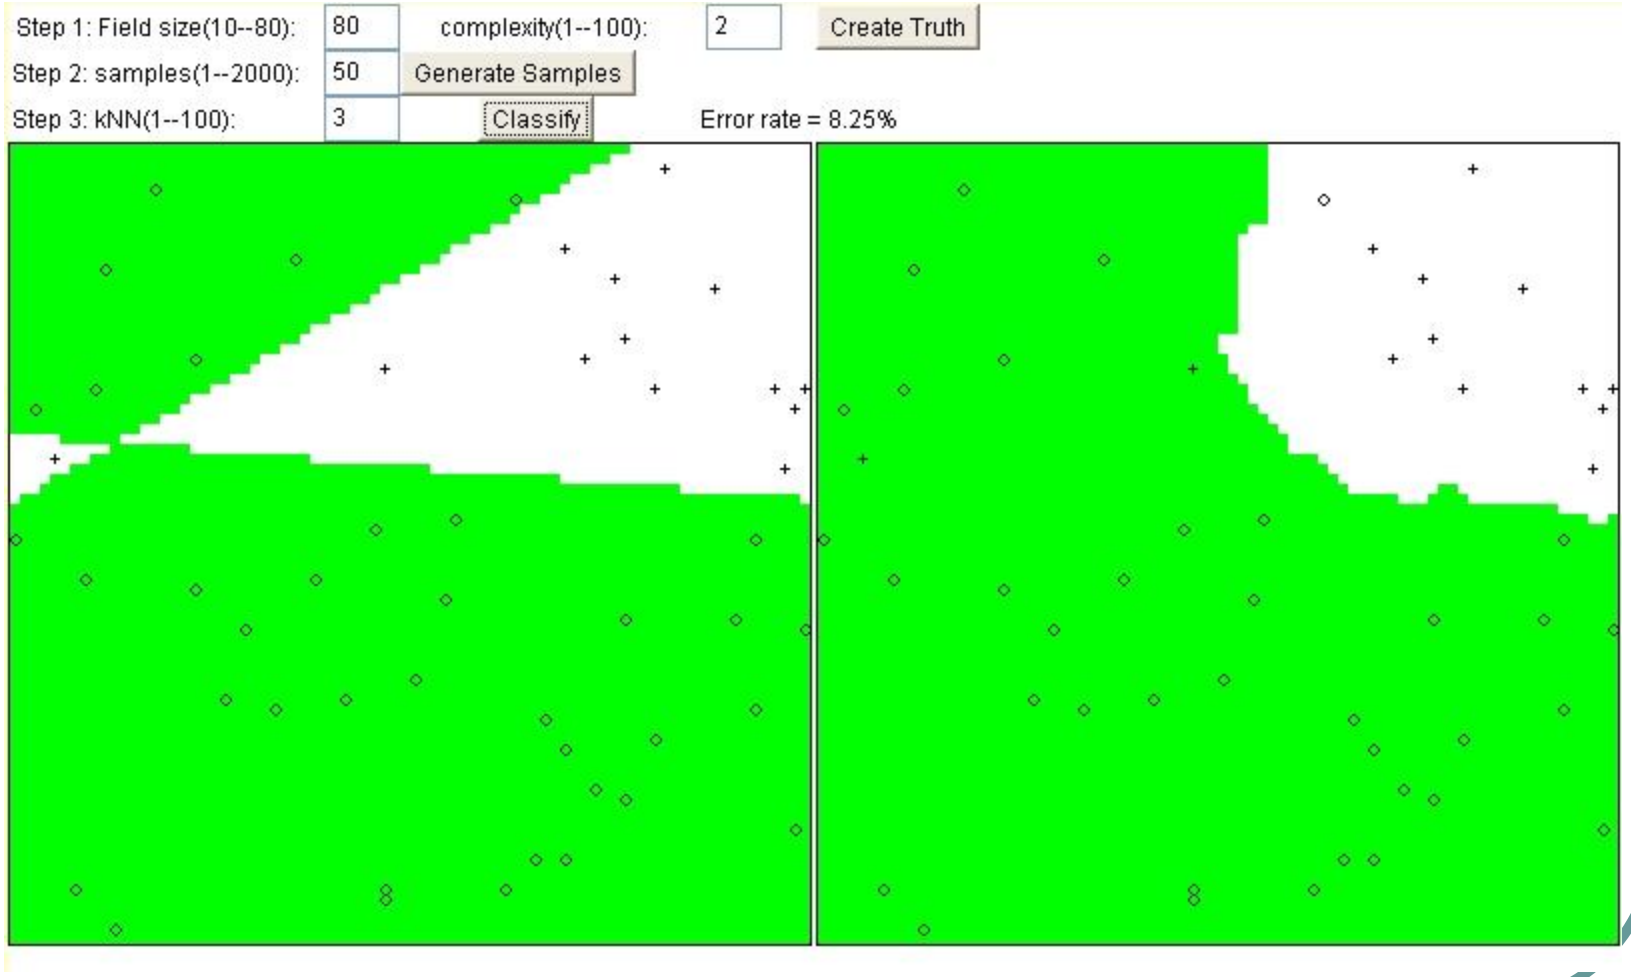
http://www.cs.cmu.edu/~awm/tutorials

KNN demo



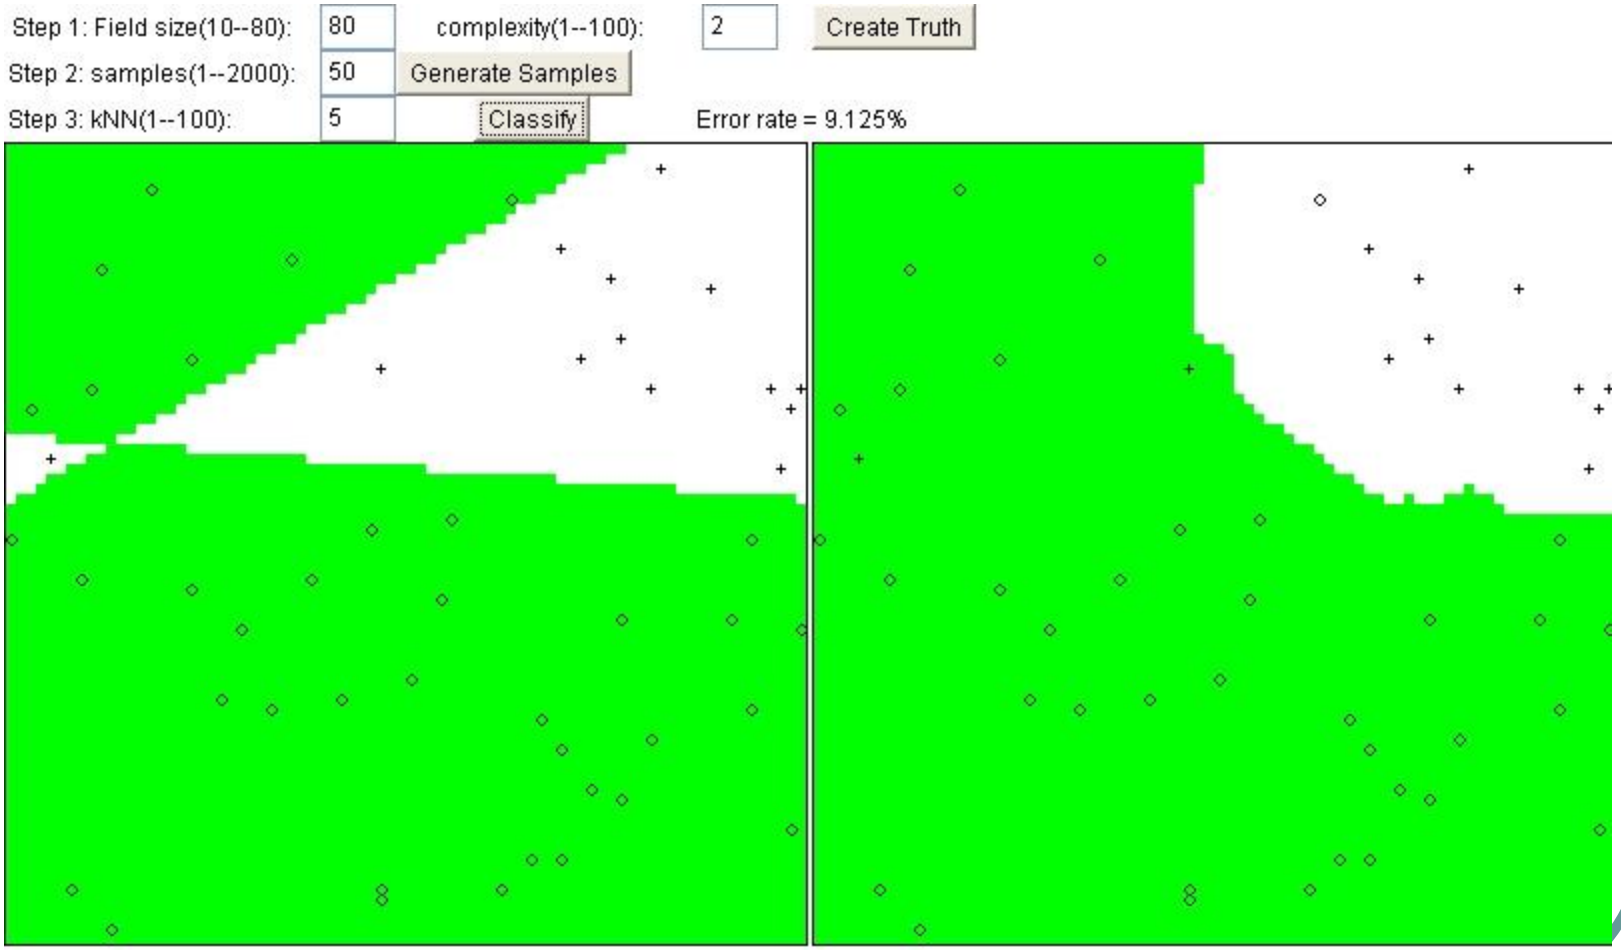
http://www.cs.cmu.edu/~zhuxj/courseproject/knndemo/KNN.html

KNN demo



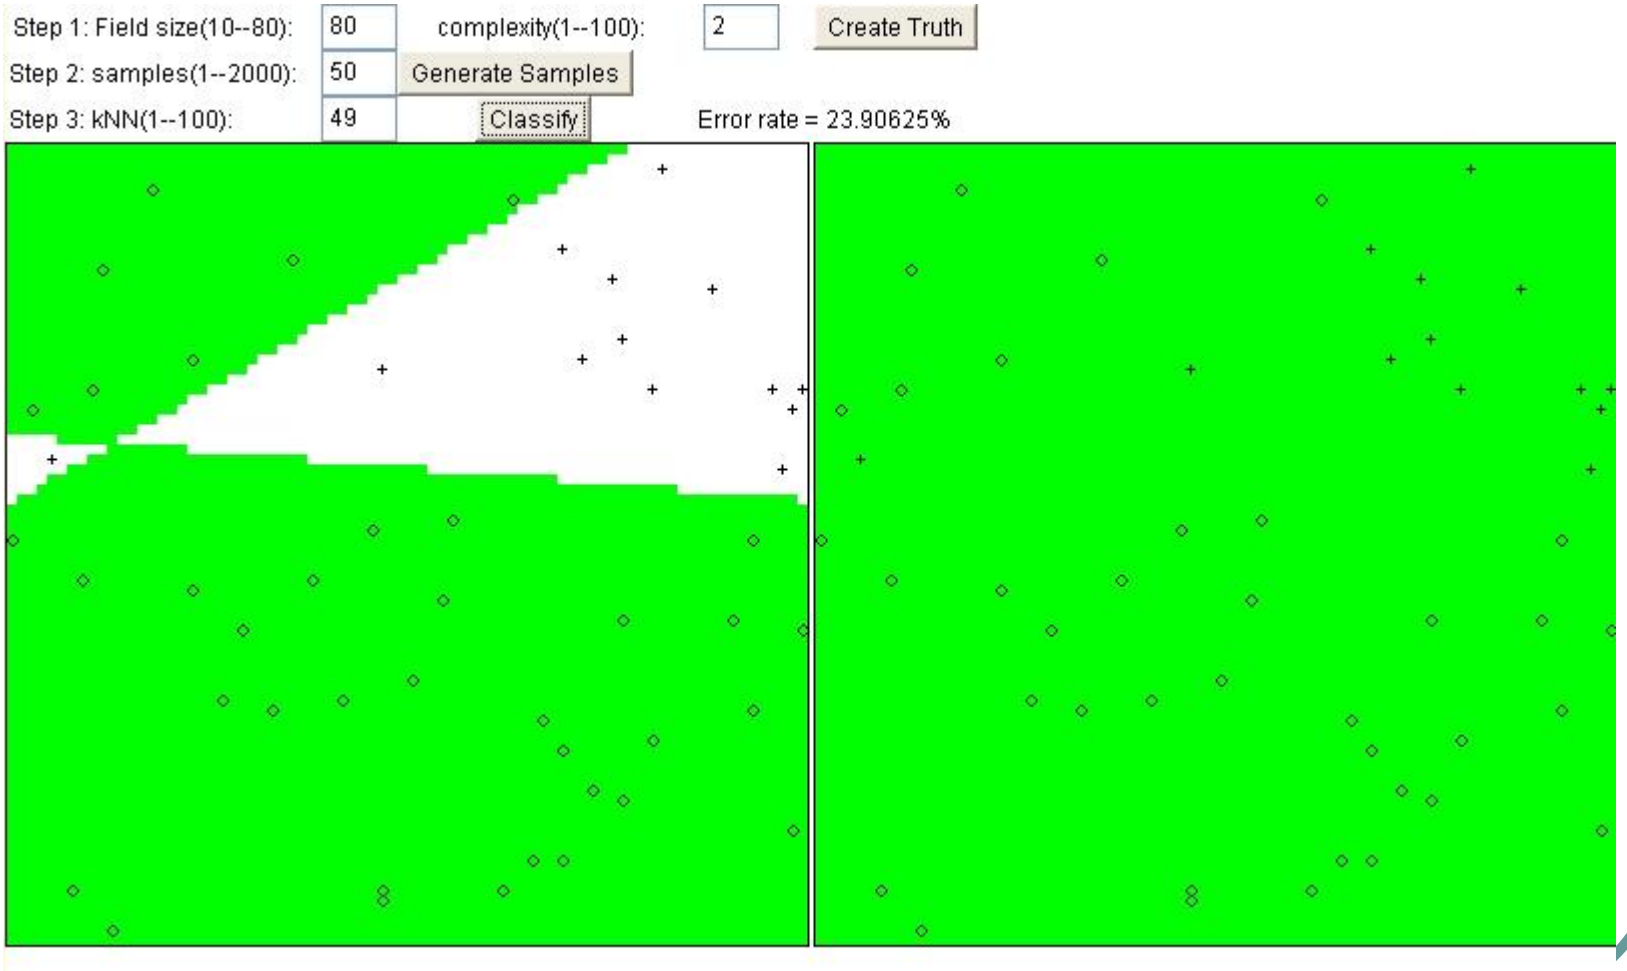
http://www.cs.cmu.edu/~zhuxj/courseproject/knndemo/KNN.html

KNN demo



http://www.cs.cmu.edu/~zhuxj/courseproject/knndemo/KNN.html

KNN demo



http://www.cs.cmu.edu/~zhuxj/courseproject/knndemo/KNN.html

KNN - סיכום

- יתרונות:
  - תכנות "קריא", ניתן לעקיבה
  - מימוש פשוט
  - קל לממש באופן מקבילי
- חסרונות:
  - נדרש שטח איחסון גדול לנתונים
  - יקר לסיווג דוגמא חדשה

תרגיל KNN

- נתונים הווקטורים הבאים (x1,x2) והסיווג שלהם (c) : (x1,x2|c)
  - (3,1|-1),(1,4|1),(3,5|-1),(4,2|1),(1,1|-1),(1,0|1),(0,0|1)
- מצא באמצעות אלגוריתם KNN את הסיווג של הווקטור (3,2)

פתרון

- דרוש k – נבחן עבור k=1,k=7,k=3,
- דרושה מטריקת מרחק – נשתמש במטריקה אוקלידית

- פתרון: נחשב את המרחק של (3,2) משאר הנקודות בקבוצת האימון ונראה מיהו השכן הקרוב ביותר ומיהם 3 השכנים הקרובים ביותר. עבור K=7 המצב פשוט יותר

פתרון (המשך)

	מרחק מ-(3,2)	סיווג	ווקטור
3.6	$\sqrt{(3-0)^2+(2-0)^2}=\sqrt{13}$	1	(0,0)
2.8	$\sqrt{(3-1)^2+(2-0)^2}=\sqrt{8}$	1	(1,0)
2.2	$\sqrt{(3-1)^2+(2-1)^2}=\sqrt{5}$	-1	(1,1)
1	$\sqrt{(3-4)^2+(2-2)^2}=\sqrt{1}$	1	(4,2)
3	$\sqrt{(3-3)^2+(2-5)^2}=\sqrt{9}$	-1	(3,5)
2.8	$\sqrt{(3-1)^2+(2-4)^2}=\sqrt{8}$	1	(1,4)
1	$\sqrt{(3-3)^2+(2-1)^2}=\sqrt{1}$	-1	(3,1)

עבור k=1 – שני שכנים קרובים אחד מסווג "1" והשני מסווג "1-" נחליט לפי הצבעת רוב - **1**

עבור k=3 – שני שכנים מצביעים "1-" ושכן אחד מצביע "1" – נסווג **1-**

עבור k=7 – הצבעת רוב – נסווג **1**

ועם שקלול מרחקים

- נניח שעובדים עם שקלול מרחקים $\frac{1}{d^2}$
- סיווג 1 – מרחקים 1, שקלול: $\frac{1}{1^2}=1$
- סיווג 1- – מרחקים 1, 2.2

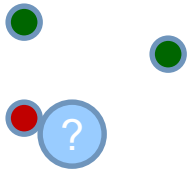
$$\frac{1}{1^2}+\frac{1}{2.2^2}>\frac{1}{1^2}$$

- ולכן נסווג כ: 1-

תרגיל

- כיצד יסווג הווקטור (f_1,f_2,f_3) עבור k=3 בהינתן טבלת המרחקים הבאה:

dist	סיווג	ווקטור#
1	1	1
1	1	2
0.1	-1	3



- ללא שקלול מרחקים – שני ווקטורים "מצביעים" 1, ווקטור אחד מצביע 1-, לכן נסווג כ: 1
- עם שקלול מרחקים של $1/d^2$ $\frac{1}{1^2}+\frac{1}{1^2}<\frac{1}{0.1^2}=100$ לכן נסווג כ:1-